

Машинное обучение и искусственные нейронные сети как обратные задачи. Регуляризация

Вопрос 02

Крохалев Е. М.

2026

- Один объект — три имени: регуляризация Тихонова (обратные задачи) = гребневая регрессия (*ridge regression*, статистика) = L_2 -регуляризация, или снижение весов (*weight decay*, машинное обучение).
- Прямая задача: по параметрам модели q вычисляется выход $f = Aq$; обратная — по наблюдаемому выходу f определить причину q [42] (Галанин).
- Три группы обратных задач [42] (Галанин): по постановке (характеристики среды по замерам решения); структура и параметры модели по опытным данным; синтез системы по желаемому выходу. Обучение модели — задача второй группы.
- План: основная часть — обратные задачи и регуляризация; расширенная часть — ИНС и методы обучения.


Сквозной пример

Восстановление функции пяти переменных — суммы двух гауссовых «спектральных линий» — по шумным измерениям в базисе полиномов Чебышёва:

$$u(x) = e^{-\|x-a\|^2/(2 \cdot 0,5^2)} + 0,7 e^{-\|x-b\|^2/(2 \cdot 0,2^2)},$$

$$x = (x_1, \dots, x_5) \in [-1, 1]^5 \subset \mathbb{R}^5.$$

- Измерения $y_i = u(x_i) + \varepsilon_i$ в $m = 500$ точках, равномерных в кубе; шум независим, $E\varepsilon_i = 0$, $D\varepsilon_i = \sigma^2$, $\sigma = 0,05$.
- Базис $\varphi_k(x) = T_{k_1}(x_1) \cdots T_{k_5}(x_5)$, $k_1 + \dots + k_5 \leq 6$: $n = \binom{5+6}{5} = 462$ функции.
- Подстановка измерений — операторное уравнение первого рода $Xw = y$, $X_{ik} = \varphi_k(x_i)$; оператор выборки в точках сознательно плохо обусловлен (проклятие размерности).



Пусть A отображает Q в F ; вместо f задано приближение f_δ с уровнем погрешности $\delta > 0$, $\|f - f_\delta\| \leq \delta$; точное решение — q_T .

Определение 1

Задача $Aq = f$ **корректна на паре пространств Q и F (корректна по Адамару)**, если выполнены три условия [14] (Кабанихин):


- 1) для любого $f \in F$ существует решение $q_T \in Q$, то есть $R(A) = F$ (существование);
- 2) решение единственно, то есть существует обратный оператор A^{-1} (единственность);
- 3) для любой окрестности $O(q_T) \subset Q$ найдётся окрестность $O(f) \subset F$ такая, что $A^{-1}O(f) \subset O(q_T)$, то есть A^{-1} непрерывен (устойчивость).

Определение 2

Задача $Aq = f$ **некорректна** (англ. *ill-posed problem* — [32], [39]) на паре Q, F , если нарушено хотя бы одно из трёх требований определения [14] (Кабанихин).

Примеры неустойчивости

- Дифференцирование: $f_\delta = f + \delta \sin(x/\delta^2)$, тогда $\|f_\delta - f\|_C = \delta$, но $\|(f_\delta - f)'\|_C = 1/\delta \rightarrow \infty$ [14] (Кабанихин). Численно: наклон $\log h^*$ против $\log \delta$ равен 0,527 при предсказанных 1/2.
- Фредгольм 1-го рода: $q_n = q_T + n \sin(n^2 s)$ — $\|q_n - q_T\|_C \rightarrow \infty$ при $\|Aq_n - f\|_C \leq K_1/n^2 \rightarrow 0$ [14] (Кабанихин).
- Теплопроводность, обратное время: ошибка δ_n в n -й моде превращается в $\delta_n e^{a^2 \pi^2 n^2 T/l^2}$ [14] (Кабанихин).
- Задача Коши для Лапласа: $u_n = \frac{1}{n} \sin(ny) \cosh(nx)$ — данные $\rightarrow 0$, решение растёт как $e^{nx}/(2n)$ [14].



Определение 3

Задача $Aq = f$ **условно корректна** на множестве $M \subset Q$ (корректна по Тихонову), если $f \in A(M)$ и выполнены условия [14] (Кабанихин):

- 1) решение q_T единственно на M ;
- 2) для любой окрестности $O(q_T)$ существует окрестность $O(f)$ такая, что $A^{-1}(O(f) \cap A(M)) \subset O(q_T)$ (условная устойчивость).

Множество M называется **множеством корректности** [14] (Кабанихин).

Теорема 4 (непрерывность обратного оператора на компакте)

Пусть Q и F – метрические пространства, $M \subset Q$ компактно, отображение $A : Q \rightarrow F$ непрерывно и взаимно однозначно переводит M в $A(M) \subset F$. Тогда обратное отображение $A^{-1} : A(M) \rightarrow M$ непрерывно.

Модуль непрерывности $\omega(\delta) = \sup\{\rho_Q(A^{-1}f_1, A^{-1}f_2) : f_1, f_2 \in A(M), \rho_F(f_1, f_2) \leq \delta\}$ – лучшая гарантированная оценка погрешности на классе M .

Определение 5

Регуляризирующим семейством для задачи $Aq = f$ называется семейство операторов $\{R_\alpha\}_{\alpha>0}$, $R_\alpha : F \rightarrow Q$, такое что [14] (Кабанихин):

- 1) для любого $\alpha > 0$ оператор R_α непрерывен;
- 2) для любого $f \in R(A)$ и $q_T = A^{-1}f \lim_{\alpha \rightarrow +0} R_\alpha f = q_T$.

Определение 6

Пусть вместо f задано f_δ с $\|f - f_\delta\| \leq \delta$. Отображение $R_{\alpha(\delta, f_\delta)}$, сопоставляющее данным элемент $q_{\alpha\delta} = R_{\alpha(\delta, f_\delta)} f_\delta$, — **регуляризирующий алгоритм** (англ. *regularization algorithm*), если $\sup_{\|f - f_\delta\| \leq \delta} \|R_{\alpha(\delta, f_\delta)} f_\delta - A^{-1}f\| \rightarrow 0$ ($\delta \rightarrow 0$) для всех $f \in R(A)$; выбор $\alpha = \alpha(\delta, f_\delta)$ — **согласование параметра регуляризации с погрешностью данных**.

Ключевая оценка: $\|q_T - q_{\alpha\delta}\| \leq \gamma(q_T, \alpha) + \|R_\alpha\| \delta$; уклонение γ мало при малых α , а $\|R_\alpha\| \rightarrow \infty$ при $\alpha \rightarrow 0$ — точность и устойчивость **балансируются параметром α** .

Определение 7

Пусть Q, F — гильбертовы пространства, $A : Q \rightarrow F$ — линейный ограниченный оператор, $f_\delta \in F, q^0 \in Q$ — пробное решение (априорное приближение). **Функционалом Тихонова** называется

$$M^\alpha[q] = \|Aq - f_\delta\|^2 + \alpha \|q - q^0\|^2, \quad \alpha > 0,$$

а **методом регуляризации А. Н. Тихонова** — построение приближённого решения по правилу $q_{\alpha\delta} = \arg \min_{q \in Q} M^\alpha[q]$ [14] (Кабанихин).

Теорема 8 (существование и единственность минимизатора)

Пусть Q и F — гильбертовы пространства, $A : Q \rightarrow F$ — линейный ограниченный оператор, $\alpha > 0, q^0 \in Q$. Тогда для любого $f_\delta \in F$ функционал M^α достигает своей нижней грани на единственном элементе $q_\alpha \in Q$.

Предложение 1 (нормальное уравнение)

Минимизатор q_α функционала Тихонова удовлетворяет уравнению Эйлера

$$(A^*A + \alpha I) q_\alpha = A^*f_\delta + \alpha q^0, \text{ причём оператор } A^*A + \alpha I \text{ обратим и } \|(A^*A + \alpha I)^{-1}\| \leq 1/\alpha.$$

Теорема 9 (сходимость метода Тихонова)

Пусть Q, F – гильбертовы пространства, $A : Q \rightarrow F$ – линейный вполне непрерывный оператор, $f \in R(A)$, решение q_T уравнения $Aq = f$ единственно. Пусть $\|f - f_\delta\| \leq \delta$, и параметр выбран по правилу $\alpha = \alpha(\delta)$ так, что

$$\lim_{\delta \rightarrow 0} \alpha(\delta) = 0, \quad \lim_{\delta \rightarrow 0} \frac{\delta^2}{\alpha(\delta)} = 0.$$

Тогда регуляризованные решения $q_{\alpha(\delta), \delta}$ сходятся к точному: $\|q_{\alpha(\delta), \delta} - q_T\| \rightarrow 0$ при $\delta \rightarrow 0$.

Схема доказательства: ограниченность $\|q_{\alpha\delta} - q^0\|^2 \leq \delta^2/\alpha + \|q_T - q^0\|^2 \rightarrow$ слабая сходимость подпоследовательностей, которую вполне непрерывность A переводит в сильную $\rightarrow$ сильная сходимость через раскрытие квадрата нормы. Полное доказательство – в theory.pdf.

Скорость: в конечномерном разрешимом случае из нормального уравнения

$\|q_{\alpha\delta} - q_T\| \leq \frac{\alpha}{\lambda_r} \|q_T\| + \frac{\delta}{2\sqrt{\alpha}}$ (λ_r – наименьшее положительное собственное значение A^*A);
балансировка двух членов при $\delta \sim \varepsilon$ даёт $\alpha \sim \varepsilon^{2/3}$ и точность $O(\varepsilon^{2/3})$ [14] (Кабанихин).

Лемма 10 (монотонность невязки)

Пусть $A : \mathbb{R}^n \rightarrow \mathbb{R}^m$ – линейный оператор, $f_\delta \in \mathbb{R}^m$, $q^0 = 0$, $q_\alpha = (A^*A + \alpha I)^{-1} A^* f_\delta$, и пусть $X = UDV^\top$ – сингулярное разложение A с сингулярными числами $d_1 \geq \dots \geq d_r > 0$.

Тогда невязка

$$\rho(\alpha) = \|Aq_\alpha - f_\delta\|^2 = \sum_{j=1}^r \left(\frac{\alpha}{d_j^2 + \alpha} \right)^2 (u_j^\top f_\delta)^2 + \|(I - P)f_\delta\|^2,$$

где P – ортогональный проектор на $R(A) = \text{lin}\{u_1, \dots, u_r\}$. В частности, ρ непрерывна и (строго) монотонно возрастает по α при условии $Pf_\delta \neq 0$, причём

$$\lim_{\alpha \rightarrow 0} \rho(\alpha) = \|(I - P)f_\delta\|^2 = \text{dist}^2(f_\delta, R(A)), \quad \lim_{\alpha \rightarrow \infty} \rho(\alpha) = \|f_\delta\|^2.$$

Теорема 11 (принцип невязки)

В условиях леммы пусть дополнительно $f \in R(A)$, $\|f - f_\delta\| \leq \delta$ и $\text{dist}(f_\delta, R(A)) < \delta < \|f_\delta\|$. Тогда уравнение $\rho(\alpha) = \delta^2$ имеет единственный корень $\alpha(\delta) > 0$.


Предложение 2 (спектральный анализ гребня)

Пусть $X = UDV^T$. Тогда

$$X\hat{w} = \sum_{j=1}^r \frac{d_j^2}{d_j^2 + \alpha} (u_j^T y) u_j.$$

В частности, гребень оставляет направления u_j и коэффициенты $u_j^T y$ нетронутыми, но сжимает каждый на множитель $d_j^2 / (d_j^2 + \alpha) \in (0, 1)$; сжатие сильнее всего там, где $d_j^2 \lesssim \alpha$, то есть вдоль малых сингулярных направлений [16] (Хасты, Тибширани, Фридман).

- Эффективное число степеней свободы:
 $\text{df}(\alpha) = \text{tr } S = \sum_j \frac{d_j^2}{d_j^2 + \alpha}$ — от r при $\alpha \rightarrow 0$ до 0.
- Механизм: вклад шума вдоль v_j умножается на $d_j / (d_j^2 + \alpha) \leq 1 / (2\sqrt{\alpha})$ — вместо $1/d_r$ у МНК; цена — смещение.
- Тот же фильтр $\lambda / (\lambda + \alpha)$ у квазирешения Иванова: ограничение $\leftrightarrow$ штраф.



Словарь: X — роль A , w — роль q , y — роль f_δ ; m — число примеров, n — число параметров.

Определение 12

Пусть $g(x, w)$ — модель с параметрами $w \in \mathbb{R}^n$, $\ell(\hat{y}, y)$ — функция потерь. **Эмпирическим риском** (англ. *empirical risk* — [51]) называется средняя потеря по обучающей выборке $Q(w) = \frac{1}{m} \sum_{i=1}^m \ell(g(x_i, w), y_i)$ [53] (Воронцов); метод эмпирического риска ищет $\hat{w} \in \arg \min_w Q(w)$ [53] (Воронцов).

При квадратичной потере $\ell(\hat{y}, y) = (\hat{y} - y)^2$ это ровно МНК: $Q(w) = \frac{1}{m} \|Xw - y\|^2$, $\delta \sim \sqrt{m} \sigma$.

Переобучение — проявление некорректности по устойчивости: в квадратной ситуации

$$\hat{w} = X^{-1}y \text{ и}$$

$$\frac{\|\delta w\|}{\|w\|} \leq \kappa(X) \frac{\|\delta y\|}{\|y\|};$$

в сквозном примере $\kappa(X^\top X) = 2,4367 \cdot 10^6$: ёмкость даёт существование под любые данные, малые собственные значения — неустойчивость.

Искусственная нейронная сеть (англ. *artificial neural network*) — модель $f(x; \theta)$ из композиций простых функций (слоёв); нейрон — звено $z = \varphi(w^\top x + b)$; персептрон — нейрон со знаковой φ .

Обучение — минимизация эмпирического риска $J(\theta) = \frac{1}{m} \sum_{i=1}^m L(f(x_i; \theta), y_i) \rightarrow \min_{\theta}$ (нелинейный аналог уравнения первого рода) [51]. Невыпуклость: гарантий корректности нет, инициализация — малые случайные значения; градиент — обратное распространение по вычислительному графу, цена $\approx$ одного прямого прохода [51].

Теорема 13 (универсальная теорема аппроксимации Цыбенко — Хорника)

Сеть прямого распространения с линейным выходным слоем и хотя бы одним скрытым слоем с произвольной «сплюсчивающей» функцией активации может аппроксимировать любую борелевскую функцию, отображающую одно конечномерное пространство в другое, с любой заданной ненулевой точностью, если скрытых блоков достаточно [51] (Гудфеллоу, Бенджио, Курвилль).

Оговорки: аппроксимируемость не означает обучаемости; число блоков в худшем случае экспоненциально [51].

Стохастический оракул вместо $\nabla f(x)$ выдаёт несмещённую оценку $\hat{g}$ с конечной дисперсией: $E \hat{g} = \nabla f(x)$, $E \|\hat{g} - \nabla f(x)\|^2 \leq D$ [37] (Гасников). Минибатч из r независимых оценок уменьшает дисперсию в r раз: $E \|\hat{g}_r - \nabla f\|^2 \leq D/r$ [37] (Гасников).

Теорема 14 (сходимость SGD с постоянным шагом)

Пусть f дифференцируема и μ -сильно выпукла с минимумом в точке x^* , на каждом шаге используется несмещённая оценка $\hat{g}_k$ с $E \|\hat{g}_k\|^2 \leq B^2$ при любом x_k , шаг h постоянен и $h \leq \frac{1}{2\mu}$.

Тогда

$$E \|x_k - x^*\|^2 \leq (1 - 2h\mu)^k \|x_0 - x^*\|^2 + \frac{hB^2}{2\mu}.$$

Плато $hB^2/(2\mu)$ — цена стохастики; точность ε достигается за $k = O\left(\frac{B^2}{\mu^2} \frac{\ln(1/\varepsilon)}{\varepsilon}\right)$ итераций [37] (Гасников). По значению функции: $O(1/\sqrt{k})$ выпуклый и $O(1/k)$ сильно выпуклый случаи, обе неулучшаемы [37], [51].

Импульс (англ. *momentum*) — экспоненциально затухающее скользящее среднее градиентов [51]:

$$v^{k+1} = \beta v^k - \varepsilon \nabla J(\theta^k), \quad \theta^{k+1} = \theta^k + v^{k+1}, \quad \beta \in [0, 1).$$

Раскрытие $v^{k+1} = \theta^{k+1} - \theta^k$ даёт шаг тяжёлого шарика (мост к вопросу о минимизации функций многих переменных); локально знаменатель $q = \frac{\sqrt{\kappa}-1}{\sqrt{\kappa}+1}$ [63] (Меркулов).

Нестеров — градиент в экстраполированной точке $\tilde{\theta}^k = \theta^k + \beta v^k$:

$$v^{k+1} = \beta v^k - \varepsilon \nabla J(\theta^k + \beta v^k), \quad \theta^{k+1} = \theta^k + v^{k+1}.$$

Пакетно $O(1/k) \rightarrow O(1/k^2)$; в стохастике ускорения по оценкам нет [51].

Adam — моменты s_k, r_k , исправление смещения, покомпонентный шаг:

$$s_k = \rho_1 s_{k-1} + (1 - \rho_1) g_k, \quad r_k = \rho_2 r_{k-1} + (1 - \rho_2) g_k \odot g_k, \quad \hat{s}_k = \frac{s_k}{1 - \rho_1^k}, \quad \hat{r}_k = \frac{r_k}{1 - \rho_2^k},$$
$$\theta_{k+1} = \theta_k - \varepsilon \hat{s}_k / (\sqrt{\hat{r}_k} + \delta_0).$$

Умолчания $\varepsilon = 0,001, \rho_1 = 0,9, \rho_2 = 0,999$; статус слабее SGD: контрпримеры расходимости (Reddi et al., 2019).

Регуляризатор как априорное распределение

Теорема 15 (байесовский вывод L_2 -регуляризатора)

Пусть модель линейна: $y = Xw + \varepsilon$, шум гауссовский и гомоскедастичен: ε_i независимы, $\varepsilon_i \sim \mathcal{N}(0, \sigma^2)$; априорное распределение весов гауссовское: $w \sim \mathcal{N}(0, \nu^2 I)$. Тогда MAP-оценка (англ. *maximum a posteriori* – максимум апостериорной плотности)

$\hat{w}^{\text{MAP}} = \arg \max_w [\log p(y | X, w) + \log p(w)]$ совпадает с регуляризованным решением Тихонова при $q^0 = 0$ с параметром $\alpha = \frac{\sigma^2}{\nu^2}$.

Следствие 16 (L_1 и лапласовский априор)

Если априорное распределение произведение лапласовских: $p(w) \propto \exp(-\|w\|_1 / C)$, то MAP-оценка совпадает с минимизатором $\|y - Xw\|^2 + \frac{2\sigma^2}{C} \|w\|_1$.

(лассо: разрежённость, отбор признаков).

Три имени одного объекта [51]: регуляризация Тихонова = гребневая регрессия = L_2 -регуляризация / снижение весов; $\alpha = \sigma^2 / \nu^2$ – отношение неопределённости данных к априорной уверенности.

Теорема 17 (разложение смещение–дисперсия)

Пусть $y = f + \varepsilon$ с $f = (f(x_1), \dots, f(x_m))^T$, $E\varepsilon = 0$, $E\varepsilon\varepsilon^T = \sigma^2 I$, и оценка $\hat{f}(x_0) = h(x_0)^T y$ линейна по y . Тогда для прогноза в точке x_0 , где $y_0 = f(x_0) + \varepsilon_0$ с ε_0 независим от ε и $E\varepsilon_0^2 = \sigma^2$,

$$E[(y_0 - \hat{f}(x_0))^2] = \sigma^2 + \text{Bias}^2(\hat{f}(x_0)) + D(\hat{f}(x_0)),$$

где $\text{Bias}(\hat{f}(x_0)) = E\hat{f}(x_0) - f(x_0)$; слагаемое σ^2 не зависит от модели (неустраняемая ошибка).

Для $\hat{f}(x_0) = h(x_0)^T y$

$$D(\hat{f}(x_0)) = \|h(x_0)\|^2 \sigma^2.$$

Следствие 18 (гребень: смещение растёт, дисперсия падает)


Для гребневой оценки в точке x_0 дисперсия равна

$$D(\hat{f}_\alpha(x_0)) = \|X(X^T X + \alpha I)^{-1} x_0\|^2 \sigma^2.$$

При росте α она монотонно не возрастает, а квадрат смещения не убывает; сумма – U-образная кривая [16] (Хасты, Тибширани, Фридман).

U-кривая и выбор параметра

Сквозной пример, $\delta^2 = m\sigma^2$: - МНК: контрольная MSE = 0,66048 — на три порядка хуже гребня. - Принцип невязки, корень $\rho(\alpha) = \delta^2$: $\alpha = 103,21$, контрольная MSE = 0,0011210. - Перекрёстная проверка, правило одной стандартной ошибки: $\alpha = 63,10$, контрольная MSE = 0,00097243. - Дно U-образной кривой — при $\alpha \approx 56$; обе точки в дне и отличаются менее чем вдвое. Оба правила оценивают дно одной и той же кривой: невязка — по уровню шума (теория обратных задач), перекрёстная проверка — непосредственно ошибку обобщения (переносится на несовпадение модели и реальности).



Дно U-образной кривой достижимо и без сетки по α — остановкой обучения. Ранняя остановка — самая распространённая регуляризация в машинном обучении: остановка обучения, когда ошибка на отложенной контрольной части перестаёт убывать [51].

Теорема 19 (эквивалентность ранней остановки и L_2 -регуляризации)

Пусть $J(w) = \frac{1}{2}(w - w^*)^T H(w - w^*) + \text{const}$ — квадратичная функция с $H = Q\Lambda Q^T \succeq 0$, градиентный спуск с шагом ε (таким, что $\varepsilon\lambda_i < 1$) стартует из $w^{(0)} = 0$. Тогда:


- 1) после τ итераций $Q^T w^{(\tau)} = [I - (I - \varepsilon\Lambda)^\tau] Q^T w^*$;
- 2) минимум регуляризованного функционала $J(w) + \frac{\alpha}{2} \|w\|^2$ равен $Q^T \tilde{w} = (\Lambda + \alpha I)^{-1} \Lambda Q^T w^*$;
- 3) покомпонентные множители совпадают тогда и только тогда, когда $(I - \varepsilon\Lambda)^\tau = \alpha(\Lambda + \alpha I)^{-1}$; для малых собственных значений λ при $\varepsilon\lambda \ll 1$ условие выполнено при $\alpha \approx \frac{1}{\varepsilon\tau}$, то есть $\tau \approx \frac{1}{\varepsilon\alpha}$.

Сквозной пример: $\tau^* = 20$, $\tau^* \varepsilon \alpha_{\text{disc}} = 0,985 \approx 1$; $1/(\varepsilon\tau^*) = 104,8$ против $\alpha_{\text{disc}} = 103,2$.

Ранняя остановка — итерационная регуляризация Тихонова (метод Ландвебера) [14].

Пример: малая ИНС

- Сеть: 24 tanh-блока (≈ 169 весов), полный градиентный спуск, $\eta = 0,02$; обучение – 70 точек, контроль – остальные.
- Голый спуск переобучился: обучающая MSE 0,0019 против контрольной 0,0140.
- Контрольная MSE: 0,01402 (голый спуск) $\rightarrow$ 0,01302 (снижение весов) $\rightarrow$ 0,01247 (ранняя остановка, $\tau = 2800$) $\rightarrow$ 0,01209 (оба регуляризатора).
- Норма весов при снижении весов:
 $4,03 \rightarrow 1,59$ – тот самый множитель $(1 - \varepsilon\alpha)$.



Определение 20 (Гудфеллоу, Бенджио, Курвилль, регуляризация)

«Регуляризация — это любая модификация алгоритма обучения, предпринятая с целью уменьшить его ошибку обобщения, не уменьшая ошибку обучения» [51] (Гудфеллоу, Бенджио, Курвилль).

Снижение весов: $\tilde{J}(\theta) = J(\theta) + \frac{\alpha}{2} \|w\|^2$, штраф только на веса, не на смещения (смещение — параметр положения отклика, а не чувствительности к входу); шаг градиентного спуска $w \leftarrow (1 - \varepsilon\alpha) w - \varepsilon \nabla_w J$ [51]. Бэггинг — усреднение k моделей: ошибка среднего $E[(\frac{1}{k} \sum_i \varepsilon_i)^2] = \frac{v}{k} + (1 - \frac{1}{k})c$ [51]. Пакетная нормировка (англ. *batch normalization* — [64]): перепараметризация ради оптимизации; регуляризирующий эффект её шума побочен [51].

| Метод | Механизм | Что покупается | |—|—|—| | Снижение весов | штраф $\frac{\alpha}{2} \|w\|^2$; шаг $(1 - \varepsilon\alpha)w - \varepsilon \nabla J$ | сжатие малых сингулярных направлений; устойчивость к шуму | | Ранняя остановка | мониторинг контрольной ошибки; $\tau \approx 1/(\varepsilon\alpha)$ | тот же эффект, что у гребня, без подбора α | | Прореживание | случайное выключение блоков | адаптивный L_2 (линейный случай); робастность к соседству решений | | Бэггинг | усреднение k моделей | дисперсия v/k при сохранении общей части c | | Аугментация, шум к входу | расширение выборки, неопределённость входа | инвариантности; штраф $\|w\|^2$ в линейном случае | | Пакетная нормировка | перепараметризация: стандартизация преактиваций по мини-пакету, шум статистик | главным образом оптимизация; регуляризирующий побочный эффект [51] | | Инвариантности архитектуры (пулинг) | ограничение вида решения: инвариантность к малым сдвигам (переносам) признаков | то, что покупает аугментация, заданное архитектурой [51] |

Прореживание (англ. *dropout*): каждый скрытый блок выключается независимо с вероятностью $1 - p$ (обычно $p = 0,5$); на применении выходы масштабируются на p [51].

Предложение 3 (dropout и адаптивный L_2 для линейной регрессии)


Применение прореживания к линейной регрессии эквивалентно снижению весов по норме L_2 , где для каждого входного признака задаётся свой коэффициент снижения (Wager et al., 2013 – [51] (Гудфеллоу, Бенджио, Курвилль)). Именно: если $\mu_j \in \{0, 1\}$ – независимые индикаторы включения признака с $P\{\mu_j = 1\} = p$, то обучение по ожидаемой потере

$$E_{\mu} \|y - X(w \odot \mu)\|^2 = \|y - p Xw\|^2 + p(1 - p) \sum_j \|X_{\cdot j}\|^2 w_j^2$$

есть гребневая регрессия с признакозависимым штрафом; для глубоких моделей такой эквивалентности нет [51] (Гудфеллоу, Бенджио, Курвилль).

Замкнутая форма совпала с гребнем до машинного нуля;

Монте-Карло: зазор $\approx 4,3\%$, наклон $\approx -0,46$.



Разобранные задачи

1. Псевдорешение и критерий Пикара:
почему систему $Xw = y$ нельзя решать
«в лоб» — деление на d_j раздувает шум.
2. Гребневая регрессия сквозного примера:
фильтры, выбор α невязкой и
перекрёстной проверкой.
3. Ранняя остановка против гребня:
экспоненциальный фильтр против
рационального.
4. Принцип невязки: корень $\rho(\alpha) = \delta^2$
бисекцией.

Вопросы, которые стоит ожидать

- Назовите три имени одной конструкции.
- Почему большая регуляризованная модель
лучше малой нерегуляризованной?
- Как выбирать параметр α ?
- Чем ранняя остановка отличается от гребня?
- Почему смещения не регуляризуют?
- Как регуляризация связана с байесовским
выводом?

- [14] (Кабанихин) — профильный: корректность по Адамару и по Тихонову, теоремы Тихонова, квазирешение Иванова, принцип невязки, метод Ландвебера, оценки точности.
- [42] (Галанин) — обратные задачи математического моделирования: три группы задач, примеры некорректности, сглаживающий функционал.
- [16] (Хасты, Тибширани, Фридман) — гребень и лассо с SVD-анализом, байесовская интерпретация, смещение–дисперсия, перекрёстная проверка.
- [51] (Гудфеллоу, Бенджио, Курвилль) — эмпирический риск, регуляризация, ранняя остановка, dropout, бэггинг, универсальная аппроксимация, обратное распространение, оптимизация.
- [53] (Воронцов) — обучение по прецедентам: эмпирический риск, регуляризация как MAP, скользящий контроль.
- [37] (Гасников) — стохастическая оптимизация: оракул с дисперсией, минибатчи, оценки SGD.
- [63], [64] (Меркулов, снимки курсов) — импульс, Adam, автодифференцирование; сверены с первичными книгами.