Машинное обучение и искусственные нейронные сети как обратные задачи. Регуляризация

Вопрос 02

Крохалев Е. М.

2026

План и мотивация

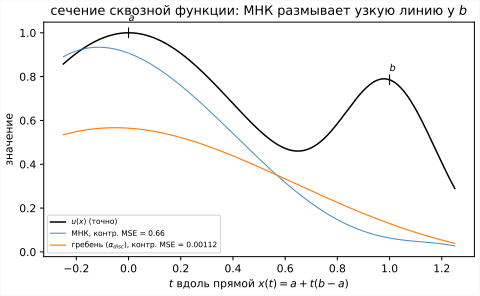
- Один объект — три имени: регуляризация Тихонова (обратные задачи) = гребневая регрессия (*ridge regression*, статистика) = L_2-регуляризация, или снижение весов (*weight decay*, машинное обучение).
- Прямая задача: по параметрам модели q вычисляется выход $f = Aq$; обратная — по наблюдаемому выходу f определить причину q [42] (Галанин).
- Три группы обратных задач [42] (Галанин): по постановке (характеристики среды по замерам решения); структура и параметры модели по опытным данным; синтез системы по желаемому выходу. Обучение модели — задача второй группы.
- План: основная часть — обратные задачи и регуляризация; расширенная часть — ИНС и методы обучения.

Сквозной пример

Восстановление функции пяти переменных — суммы двух гауссовых «спектральных линий» — по шумным измерениям в базисе полиномов Чебышёва:

$$u(x) = e^{-\|x-a\|^2/(2\cdot 0{,}5^2)} + 0{,}7\, e^{-\|x-b\|^2/(2\cdot 0{,}2^2)}, \qquad x = (x_1, \dots, x_5) \in [-1, 1]^5 \subset \mathbb{R}^5.$$

- Измерения $y_i = u(x_i) + \varepsilon_i$ в $m = 500$ точках, равномерных в кубе; шум независим, $\mathrm{E}\varepsilon_i = 0$, $\mathrm{D}\varepsilon_i = \sigma^2$, $\sigma = 0{,}05$.
- Базис $\varphi_k(x) = T_{k_1}(x_1) \cdots T_{k_5}(x_5)$, $k_1 + \dots + k_5 \le 6$: $n = \binom{5+6}{5} = 462$ функции.
- Подстановка измерений — операторное уравнение первого рода $Xw = y$, $X_{ik} = \varphi_k(x_i)$; оператор выборки в точках сознательно плохо обусловлен (проклятие размерности).



Корректность по Адамару

Пусть A отображает Q в F; вместо f задано приближение f_δ с уровнем погрешности $\delta > 0$, $\|f - f_\delta\| \leq \delta$; точное решение — q_T.

Определение 1

Задача $Aq = f$ **корректна на паре пространств** Q **и** F **(корректна по Адамару)**, если выполнены три условия [14] (Кабанихин):

1) для любого $f \in F$ существует решение $q_T \in Q$, то есть $R(A) = F$ (существование);

2) решение единственно, то есть существует обратный оператор A^{-1} (единственность);

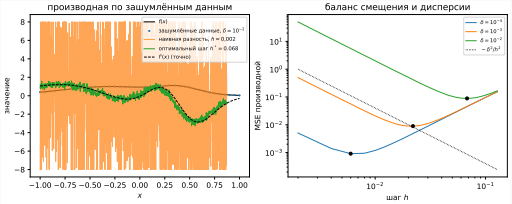
3) для любой окрестности $O(q_T) \subset Q$ найдётся окрестность $O(f) \subset F$ такая, что $A^{-1}O(f) \subset O(q_T)$, то есть A^{-1} непрерывен (устойчивость).

Определение 2

Задача $Aq = f$ **некорректна** (англ. *ill-posed problem* — [32], [39]) на паре Q, F, если нарушено хотя бы одно из трёх требований определения [14] (Кабанихин).

Примеры неустойчивости

- Дифференцирование: $f_\delta = f + \delta \sin(x/\delta^2)$, тогда $\|f_\delta - f\|_C = \delta$, но $\|(f_\delta - f)'\|_C = 1/\delta \to \infty$ [14] (Кабанихин). Численно: наклон $\log h^*$ против $\log \delta$ равен $0{,}527$ при предсказанных $1/2$.
- Фредгольм 1-го рода: $q_n = q_T + n \sin(n^2 s)$ – $\|q_n - q_T\|_C \to \infty$ при $\|Aq_n - f\|_C \le K_1/n^2 \to 0$ [14] (Кабанихин).
- Теплопроводность, обратное время: ошибка δ_n в n-й моде превращается в $\delta_n e^{a^2\pi^2 n^2 T/l^2}$ [14] (Кабанихин).
- Задача Коши для Лапласа: $u_n = \frac{1}{n}\sin(ny)\cosh(nx)$ – данные $\to 0$, решение растёт как $e^{nx}/(2n)$ [14].



Условная корректность

Определение 3

Задача $Aq = f$ **условно корректна на множестве** $M \subset Q$ **(корректна по Тихонову)**, если $f \in A(M)$ и выполнены условия [14] (Кабанихин):

1) решение q_T единственно на M;

2) для любой окрестности $O(q_T)$ существует окрестность $O(f)$ такая, что $A^{-1}(O(f) \cap A(M)) \subset O(q_T)$ (условная устойчивость).

Множество M называется **множеством корректности** [14] (Кабанихин).

Теорема 4 (непрерывность обратного оператора на компакте)

Пусть Q и F – метрические пространства, $M \subset Q$ компактно, отображение $A : Q \to F$ непрерывно и взаимно однозначно переводит M в $A(M) \subset F$. Тогда обратное отображение $A^{-1} : A(M) \to M$ непрерывно.

Модуль непрерывности $\omega(\delta) = \sup\{\rho_Q(A^{-1}f_1, A^{-1}f_2) : f_1, f_2 \in A(M),\ \rho_F(f_1, f_2) \leq \delta\}$ – лучшая гарантированная оценка погрешности на классе M.

Регуляризирующий алгоритм

Определение 5

Регуляризирующим семейством для задачи $Aq = f$ называется семейство операторов $\{R_\alpha\}_{\alpha>0}$, $R_\alpha : F \to Q$, такое что [14] (Кабанихин):

1) для любого $\alpha > 0$ оператор R_α непрерывен;

2) для любого $f \in R(A)$ и $q_T = A^{-1} f$ $\lim_{\alpha\to+0} R_\alpha f = q_T$.

Определение 6

Пусть вместо f задано f_δ с $\|f - f_\delta\| \le \delta$. Отображение $R_{\alpha(\delta, f_\delta)}$, сопоставляющее данным элемент $q_{\alpha\delta} = R_{\alpha(\delta,f_\delta)} f_\delta$, – **регуляризирующий алгоритм** (англ. *regularization algorithm*), если $\sup_{\|f-f_\delta\|\le\delta} \left\| R_{\alpha(\delta,f_\delta)} f_\delta - A^{-1} f \right\| \longrightarrow 0$ $(\delta \to 0)$ для всех $f \in R(A)$; выбор $\alpha = \alpha(\delta, f_\delta)$ – **согласование параметра регуляризации с погрешностью данных**.

Ключевая оценка: $\|q_T - q_{\alpha\delta}\| \le \gamma(q_T, \alpha) + \|R_\alpha\|\ \delta$; уклонение γ мало при малых α, а $\|R_\alpha\| \to \infty$ при $\alpha \to 0$ – точность и устойчивость **балансируются параметром** α.

Определение 7

Пусть Q, F — гильбертовы пространства, $A : Q \to F$ — линейный ограниченный оператор, $f_\delta \in F$, $q^0 \in Q$ — пробное решение (априорное приближение). **Функционалом Тихонова** называется

$$M^\alpha[q] = \|Aq - f_\delta\|^2 + \alpha \left\|q - q^0\right\|^2, \qquad \alpha > 0,$$

а **методом регуляризации А. Н. Тихонова** — построение приближённого решения по правилу $q_{\alpha\delta} = \arg\min_{q \in Q} M^\alpha[q]$ [14] (Кабанихин).

Теорема 8 (существование и единственность минимизатора)

Пусть Q и F — гильбертовы пространства, $A : Q \to F$ — линейный ограниченный оператор, $\alpha > 0$, $q^0 \in Q$. Тогда для любого $f_\delta \in F$ функционал M^α достигает своей нижней грани на единственном элементе $q_\alpha \in Q$.

Предложение 1 (нормальное уравнение)

Минимизатор q_α функционала Тихонова удовлетворяет уравнению Эйлера $(A^*A + \alpha I)\, q_\alpha = A^* f_\delta + \alpha q^0$, *причём оператор $A^*A + \alpha I$ обратим и* $\left\|(A^*A + \alpha I)^{-1}\right\| \le 1/\alpha$.

Сходимость и скорость

Теорема 9 (сходимость метода Тихонова)

Пусть Q, F — гильбертовы пространства, $A : Q \to F$ — линейный вполне непрерывный оператор, $f \in R(A)$, решение q_T уравнения $Aq = f$ единственно. Пусть $\|f - f_\delta\| \le \delta$, и параметр выбран по правилу $\alpha = \alpha(\delta)$ так, что

$$\lim_{\delta \to 0} \alpha(\delta) = 0, \qquad \lim_{\delta \to 0} \frac{\delta^2}{\alpha(\delta)} = 0.$$

Тогда регуляризованные решения $q_{\alpha(\delta),\delta}$ сходятся к точному: $\left\|q_{\alpha(\delta),\delta} - q_T\right\| \to 0$ при $\delta \to 0$.

Схема доказательства: ограниченность $\left\|q_{\alpha\delta} - q^0\right\|^2 \le \delta^2/\alpha + \left\|q_T - q^0\right\|^2 \to$ слабая сходимость подпоследовательностей, которую вполне непрерывность A переводит в сильную $\to$ сильная сходимость через раскрытие квадрата нормы. Полное доказательство — в theory.pdf.

Скорость: в конечномерном разрешимом случае из нормального уравнения $\|q_{\alpha\delta} - q_T\| \le \frac{\alpha}{\lambda_r}\|q_T\| + \frac{\delta}{2\sqrt{\alpha}}$ (λ_r — наименьшее положительное собственное значение A^*A); балансировка двух членов при $\delta \sim \varepsilon$ даёт $\alpha \sim \varepsilon^{2/3}$ и точность $O(\varepsilon^{2/3})$ [14] (Кабанихин).

Лемма 10 (монотонность невязки)

Пусть $A : \mathbb{R}^n \to \mathbb{R}^m$ – линейный оператор, $f_\delta \in \mathbb{R}^m$, $q^0 = 0$, $q_\alpha = (A^*A + \alpha I)^{-1} A^* f_\delta$, и пусть $X = UDV^\intercal$ – сингулярное разложение A с сингулярными числами $d_1 \geq \ldots \geq d_r > 0$. Тогда невязка

$$\rho(\alpha) = \|Aq_\alpha - f_\delta\|^2 = \sum_{j=1}^{r} \left(\frac{\alpha}{d_j^2 + \alpha} \right)^2 (u_j^\intercal f_\delta)^2 + \|(I - P) f_\delta\|^2 ,$$

где P – ортогональный проектор на $R(A) = \operatorname{lin}\{u_1, \ldots, u_r\}$. В частности, ρ непрерывна и (строго) монотонно возрастает по α при условии $Pf_\delta \neq 0$, причём

$$\lim_{\alpha \to 0} \rho(\alpha) = \|(I - P) f_\delta\|^2 = \operatorname{dist}^2(f_\delta, R(A)), \qquad \lim_{\alpha \to \infty} \rho(\alpha) = \|f_\delta\|^2 .$$

Теорема 11 (принцип невязки)

В условиях леммы пусть дополнительно $f \in R(A)$, $\|f - f_\delta\| \leq \delta$ и $\operatorname{dist}(f_\delta, R(A)) < \delta < \|f_\delta\|$. Тогда уравнение $\rho(\alpha) = \delta^2$ имеет единственный корень $\alpha(\delta) > 0$.

Гребневой фильтр

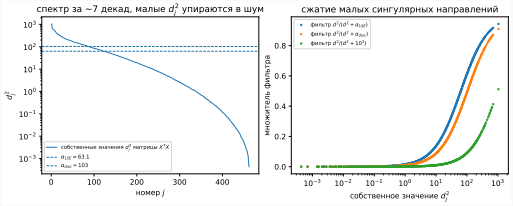
Предложение 2 (спектральный анализ гребня)

Пусть $X = UDV^{\mathsf{T}}$. *Тогда*

$$X\widehat{w} = \sum_{j=1}^{r} \frac{d_j^2}{d_j^2 + \alpha} \left(u_j^{\mathsf{T}} y\right) u_j.$$

В частности, гребень оставляет направления u_j *и коэффициенты* $u_j^{\mathsf{T}} y$ *нетронутыми, но сжимает каждый на множитель* $d_j^2/(d_j^2 + \alpha) \in (0, 1)$; *сжатие сильнее всего там, где* $d_j^2 \lesssim \alpha$, *то есть вдоль малых сингулярных направлений [16] (Хасти, Тибширани, Фридман).*

- Эффективное число степеней свободы: $\mathrm{df}(\alpha) = \operatorname{tr} S = \sum_j \frac{d_j^2}{d_j^2+\alpha}$ — от r при $\alpha \to 0$ до 0.
- Механизм: вклад шума вдоль v_j умножается на $d_j/(d_j^2 + \alpha) \le 1/(2\sqrt{\alpha})$ — вместо $1/d_r$ у МНК; цена — смещение.
- Тот же фильтр $\lambda/(\lambda + \alpha)$ у квазирешения Иванова: ограничение $\leftrightarrow$ штраф.



Эмпирический риск и переобучение

Словарь: X — роль A, w — роль q, y — роль f_δ; m — число примеров, n — число параметров.

Определение 12

Пусть $g(x, w)$ — модель с параметрами $w \in \mathbb{R}^n$, $\ell(\widehat{y}, y)$ — функция потерь. **Эмпирическим риском** (англ. *empirical risk* — [51]) называется средняя потеря по обучающей выборке $Q(w) = \frac{1}{m}\sum_{i=1}^{m} \ell(g(x_i, w),\, y_i)$ [53] (Воронцов); метод эмпирического риска ищет $\widehat{w} \in \arg\min_w Q(w)$ [53] (Воронцов).

При квадратичной потере $\ell(\widehat{y}, y) = (\widehat{y} - y)^2$ это ровно МНК: $Q(w) = \frac{1}{m}\left\|Xw - y\right\|^2$, $\delta \sim \sqrt{m}\,\sigma$.

Переобучение — проявление некорректности по устойчивости: в квадратной ситуации $\widehat{w} = X^{-1}y$ и

$$\frac{\|\delta w\|}{\|w\|} \le \varkappa(X)\,\frac{\|\delta y\|}{\|y\|};$$

в сквозном примере $\varkappa(X^{\mathsf{T}}X) = 2{,}4367 \cdot 10^6$: ёмкость даёт существование под любые данные, малые собственные значения — неустойчивость.

ИНС и универсальная аппроксимация

Искусственная нейронная сеть (англ. *artificial neural network*) — модель $f(x;\theta)$ из композиций простых функций (слоёв); нейрон — звено $z=\varphi(w^{\top}x+b)$; персептрон — нейрон со знаковой φ.

Обучение — минимизация эмпирического риска $J(\theta)=\frac{1}{m}\sum_{i=1}^{m}L(f(x_i;\theta),\,y_i)\to\min_{\theta}$ (нелинейный аналог уравнения первого рода) [51]. Невыпуклость: гарантий корректности нет, инициализация — малые случайные значения; градиент — обратное распространение по вычислительному графу, цена ≈ одного прямого прохода [51].

Теорема 13 (универсальная теорема аппроксимации Цыбенко — Хорника)

Сеть прямого распространения с линейным выходным слоем и хотя бы одним скрытым слоем с произвольной «сплющивающей» функцией активации может аппроксимировать любую борелевскую функцию, отображающую одно конечномерное пространство в другое, с любой заданной ненулевой точностью, если скрытых блоков достаточно [51] (Гудфеллоу, Бенджио, Курвилль).

Оговорки: аппроксимируемость не означает обучаемости; число блоков в худшем случае экспоненциально [51].

Стохастический градиент

Стохастический оракул вместо $\nabla f(x)$ выдаёт несмещённую оценку $\hat{g}$ с конечной дисперсией: $\mathsf{E}\,\hat{g} = \nabla f(x)$, $\mathsf{E}\left\|\hat{g} - \nabla f(x)\right\|^2 \le D$ [37] (Гасников). Минибатч из r независимых оценок уменьшает дисперсию в r раз: $\mathsf{E}\left\|\hat{g}_r - \nabla f\right\|^2 \le D/r$ [37] (Гасников).

Теорема 14 (сходимость SGD с постоянным шагом)

Пусть f дифференцируема и μ-сильно выпукла с минимумом в точке x^*, на каждом шаге используется несмещённая оценка $\hat{g}_k$ с $\mathsf{E}\left\|\hat{g}_k\right\|^2 \le B^2$ при любом x_k, шаг h постоянен и $h \le \frac{1}{2\mu}$. Тогда

$$\mathsf{E}\left\|x_k - x^*\right\|^2 \le (1 - 2h\mu)^k \left\|x_0 - x^*\right\|^2 + \frac{hB^2}{2\mu}.$$

Плато $hB^2/(2\mu)$ — цена стохастики; точность ε достигается за $k = O\left(\frac{B^2}{\mu^2}\frac{\ln(1/\varepsilon)}{\varepsilon}\right)$ итераций [37] (Гасников). По значению функции: $O(1/\sqrt{k})$ выпуклый и $O(1/k)$ сильно выпуклый случаи, обе неулучшаемы [37], [51].

Импульс, Нестеров, Adam

Импульс (англ. *momentum*) — экспоненциально затухающее скользящее среднее градиентов [51]:

$$v^{k+1} = \beta v^k - \varepsilon \nabla J(\theta^k), \qquad \theta^{k+1} = \theta^k + v^{k+1}, \qquad \beta \in [0, 1).$$

Раскрытие $v^{k+1} = \theta^{k+1} - \theta^k$ даёт шаг тяжёлого шарика (мост к вопросу о минимизации функций многих переменных); локально знаменатель $q = \frac{\sqrt{\varkappa}-1}{\sqrt{\varkappa}+1}$ [63] (Меркулов).

Нестеров — градиент в экстраполированной точке $\tilde{\theta}^k = \theta^k + \beta v^k$:

$$v^{k+1} = \beta v^k - \varepsilon \nabla J(\theta^k + \beta v^k), \qquad \theta^{k+1} = \theta^k + v^{k+1}.$$

Пакетно $O(1/k) \to O(1/k^2)$; в стохастике ускорения по оценкам нет [51].

Adam — моменты s_k, r_k, исправление смещения, покомпонентный шаг:

$$s_k = \rho_1 s_{k-1} + (1-\rho_1)\, g_k, \quad r_k = \rho_2 r_{k-1} + (1-\rho_2)\, g_k \odot g_k, \quad \hat{s}_k = \tfrac{s_k}{1-\rho_1^k}, \quad \hat{r}_k = \tfrac{r_k}{1-\rho_2^k},$$

$$\theta_{k+1} = \theta_k - \varepsilon\, \hat{s}_k \big/ (\sqrt{\hat{r}_k} + \delta_0).$$

Умолчания $\varepsilon = 0{,}001$, $\rho_1 = 0{,}9$, $\rho_2 = 0{,}999$; статус слабее SGD: контрпримеры расходимости (Reddi et al., 2019).

Регуляризатор как априорное распределение

Теорема 15 (байесовский вывод L_2-регуляризатора)

Пусть модель линейна: $y = Xw + \varepsilon$, шум гауссовский и гомоскедастичен: ε_i независимы, $\varepsilon_i \sim \mathcal{N}(0, \sigma^2)$; априорное распределение весов гауссовское: $w \sim \mathcal{N}(0, \nu^2 I)$. Тогда MAP-оценка (англ. maximum a posteriori — максимум апостериорной плотности) $\widehat{w}^{\mathrm{MAP}} = \arg\max_w [\log p(y \mid X, w) + \log p(w)]$ *совпадает с регуляризованным решением Тихонова при $q^0 = 0$ с параметром $\alpha = \frac{\sigma^2}{\nu^2}$.*

Следствие 16 (L_1 и лапласовский априор)

Если априорное распределение произведение лапласовских: $p(w) \propto \exp(-\|w\|_1 / C)$, то MAP-оценка совпадает с минимизатором $\|y - Xw\|^2 + \frac{2\sigma^2}{C} \|w\|_1$.

(лассо: разрежённость, отбор признаков).

Три имени одного объекта [51]: регуляризация Тихонова = гребневая регрессия = L_2-регуляризация / снижение весов; $\alpha = \sigma^2/\nu^2$ — отношение неопределённости данных к априорной уверенности.

Теорема 17 (разложение смещение–дисперсия)

Пусть $y = f + \varepsilon$ *с* $f = (f(x_1), \dots, f(x_m))^{\mathsf{T}}$, $\mathsf{E}\varepsilon = 0$, $\mathsf{E}\varepsilon\varepsilon^{\mathsf{T}} = \sigma^2 I$, *и оценка* $\hat{f}(x_0) = h(x_0)^{\mathsf{T}} y$ *линейна по* y. *Тогда для прогноза в точке* x_0, *где* $y_0 = f(x_0) + \varepsilon_0$ *с* ε_0 *независим от* ε *и* $\mathsf{E}\varepsilon_0^2 = \sigma^2$,

$$\mathsf{E}\big[(y_0 - \hat{f}(x_0))^2\big] = \sigma^2 + \mathrm{Bias}^2(\hat{f}(x_0)) + \mathsf{D}(\hat{f}(x_0)),$$

где $\mathrm{Bias}(\hat{f}(x_0)) = \mathsf{E}\hat{f}(x_0) - f(x_0)$; *слагаемое* σ^2 *не зависит от модели (неустранимая ошибка). Для* $\hat{f}(x_0) = h(x_0)^{\mathsf{T}} y$

$$\mathsf{D}(\hat{f}(x_0)) = \|h(x_0)\|^2 \sigma^2.$$

Следствие 18 (гребень: смещение растёт, дисперсия падает)

Для гребневой оценки в точке x_0 *дисперсия равна*

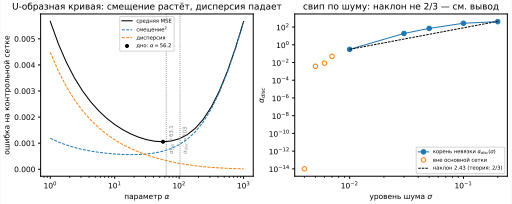
$$\mathsf{D}(\hat{f}_\alpha(x_0)) = \left\| X(X^{\mathsf{T}}X + \alpha I)^{-1} x_0 \right\|^2 \sigma^2.$$

При росте α *она монотонно не возрастает, а квадрат смещения не убывает; сумма — U-образная кривая [16] (Хасти, Тибширани, Фридман).*

U-кривая и выбор параметра

Сквозной пример, $\delta^2 = m\sigma^2$: - МНК: контрольная MSE $= 0{,}66048$ — на три порядка хуже гребня. - Принцип невязки, корень $\rho(\alpha) = \delta^2$: $\alpha = 103{,}21$, контрольная MSE $= 0{,}0011210$. - Перекрёстная проверка, правило одной стандартной ошибки: $\alpha = 63{,}10$, контрольная MSE $= 0{,}00097243$. - Дно U-образной кривой — при $\alpha \approx 56$; обе точки в дне и отличаются менее чем вдвое.

Оба правила оценивают дно одной и той же кривой: невязка — по уровню шума (теория обратных задач), перекрёстная проверка — непосредственно ошибку обобщения (переносится на несовпадение модели и реальности).



Ранняя остановка и гребень

Дно U-образной кривой достижимо и без сетки по α — остановкой обучения. Ранняя остановка — самая распространённая регуляризация в машинном обучении: остановка обучения, когда ошибка на отложенной контрольной части перестаёт убывать [51].

Теорема 19 (эквивалентность ранней остановки и L_2-регуляризации)

Пусть $J(w) = \frac{1}{2}(w - w^*)^{\mathsf{T}} H (w - w^*) + \text{const}$ — квадратичная функция с $H = Q \Lambda Q^{\mathsf{T}} \succeq 0$, градиентный спуск с шагом ε (таким, что $\varepsilon \lambda_i < 1$) стартует из $w^{(0)} = 0$. Тогда:

1) после τ итераций $Q^{\mathsf{T}} w^{(\tau)} = \bigl[I - (I - \varepsilon \Lambda)^{\tau} \bigr] Q^{\mathsf{T}} w^*$;

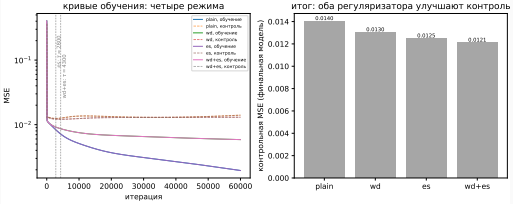
2) минимум регуляризованного функционала $J(w) + \frac{\alpha}{2} \|w\|^2$ равен $Q^{\mathsf{T}} \widetilde{w} = (\Lambda + \alpha I)^{-1} \Lambda \, Q^{\mathsf{T}} w^*$;

3) покомпонентные множители совпадают тогда и только тогда, когда $(I - \varepsilon \Lambda)^{\tau} = \alpha (\Lambda + \alpha I)^{-1}$; для малых собственных значений λ при $\varepsilon \lambda \ll 1$ условие выполнено при $\alpha \approx \frac{1}{\varepsilon \tau}$, то есть $\tau \approx \frac{1}{\varepsilon \alpha}$.

Сквозной пример: $\tau^* = 20$, $\tau^* \varepsilon \alpha_{\text{disc}} = 0{,}985 \approx 1$; $1/(\varepsilon \tau^*) = 104{,}8$ против $\alpha_{\text{disc}} = 103{,}2$. Ранняя остановка — итерационная регуляризация Тихонова (метод Ландвебера) [14].

Пример: малая ИНС

- Сеть: 24 tanh-блока (≈ 169 весов), полный градиентный спуск, $\eta = 0{,}02$; обучение — 70 точек, контроль — остальные.
- Голый спуск переобучился: обучающая MSE $0{,}0019$ против контрольной $0{,}0140$.
- Контрольная MSE: $0{,}01402$ (голый спуск) $\to$ $0{,}01302$ (снижение весов) $\to$ $0{,}01247$ (ранняя остановка, $\tau = 2800$) $\to$ $0{,}01209$ (оба регуляризатора).
- Норма весов при снижении весов: $4{,}03 \to 1{,}59$ — тот самый множитель $(1 - \varepsilon\alpha)$.



Определение 20 (Гудфеллоу, Бенджио, Курвилль, регуляризация)

«Регуляризация — это любая модификация алгоритма обучения, предпринятая с целью уменьшить его ошибку обобщения, не уменьшая ошибку обучения» [51] (Гудфеллоу, Бенджио, Курвилль).

Снижение весов: $\widetilde{J}(\theta) = J(\theta) + \frac{\alpha}{2}\|w\|^2$, штраф только на веса, не на смещения (смещение — параметр положения отклика, а не чувствительности к входу); шаг градиентного спуска $w \leftarrow (1-\varepsilon\alpha)\, w - \varepsilon\, \nabla_w J$ [51]. Бэггинг — усреднение k моделей: ошибка среднего $\mathsf{E}\big[\big(\frac{1}{k}\sum_i \varepsilon_i\big)^2\big] = \frac{v}{k} + \big(1-\frac{1}{k}\big)c$ [51]. Пакетная нормировка (англ. *batch normalization* — [64]): перепараметризация ради оптимизации; регуляризующий эффект её шума побочен [51].

Метод	Механизм	Что покупается
Снижение весов	штраф $\frac{\alpha}{2}\|w\|^2$; шаг $(1-\varepsilon\alpha)w - \varepsilon\nabla J$	сжатие малых сингулярных направлений; устойчивость к шуму
Ранняя остановка	мониторинг контрольной ошибки; $\tau \approx 1/(\varepsilon\alpha)$	тот же эффект, что у гребня, без подбора α
Прореживание	случайное выключение блоков	адаптивный L_2 (линейный случай); робастность к соседству решений
Бэггинг	усреднение k моделей	дисперсия v/k при сохранении общей части c
Аугментация, шум к входу	расширение выборки, неопределённость входа	инвариантности; штраф $\|w\|^2$ в линейном случае
Пакетная нормировка	перепараметризация: стандартизация преактиваций по мини-пакету, шум статистик	главным образом оптимизация; регуляризующий побочный эффект [51]
Инвариантности архитектуры (пулинг)	ограничение вида решения: инвариантность к малым сдвигам (переносам) признаков	то, что покупает аугментация, заданное архитектурой [51]

Прореживание

Прореживание (англ. *dropout*): каждый скрытый блок выключается независимо с вероятностью $1 - p$ (обычно $p = 0{,}5$); на применении выходы масштабируются на p [51].

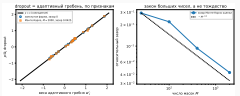
Предложение 3 (dropout и адаптивный L_2 для линейной регрессии)

Применение прореживания к линейной регрессии эквивалентно снижению весов по норме L_2, где для каждого входного признака задаётся свой коэффициент снижения (Wager et al., 2013 — [51] (Гудфеллоу, Бенджио, Курвилль)). Именно: если $\mu_j \in \{0, 1\}$ — независимые индикаторы включения признака с $\mathsf{P}\{\mu_j = 1\} = p$, то обучение по ожидаемой потере

$$\mathsf{E}_{\mu} \left\| y - X(w \odot \mu) \right\|^2 = \left\| y - p\, Xw \right\|^2 + p(1-p) \sum_j \left\| X_{\cdot j} \right\|^2 w_j^2$$

есть гребневая регрессия с признакозависимым штрафом; для глубоких моделей такой эквивалентности нет [51] (Гудфеллоу, Бенджио, Курвилль).

Замкнутая форма совпала с гребнем до машинного нуля;
Монте-Карло: зазор $\approx 4{,}3\%$, наклон $\approx -0{,}46$.



Разобранные задачи и вопросы экзаменатора

Разобранные задачи

1. Псевдорешение и критерий Пикара: почему систему $Xw = y$ нельзя решать «в лоб» — деление на d_j раздувает шум.
2. Гребневая регрессия сквозного примера: фильтры, выбор α невязкой и перекрёстной проверкой.
3. Ранняя остановка против гребня: экспоненциальный фильтр против рационального.
4. Принцип невязки: корень $\rho(\alpha) = \delta^2$ бисекцией.

Вопросы, которые стоит ожидать

- Назовите три имени одной конструкции.
- Почему большая регуляризованная модель лучше малой нерегуляризованной?
- Как выбирать параметр α?
- Чем ранняя остановка отличается от гребня?
- Почему смещения не регуляризуют?
- Как регуляризация связана с байесовским выводом?

Источники

- [14] (Кабанихин) — профильный: корректность по Адамару и по Тихонову, теоремы Тихонова, квазирешение Иванова, принцип невязки, метод Ландвебера, оценки точности.
- [42] (Галанин) — обратные задачи математического моделирования: три группы задач, примеры некорректности, сглаживающий функционал.
- [16] (Хасти, Тибширани, Фридман) — гребень и лассо с SVD-анализом, байесовская интерпретация, смещение–дисперсия, перекрёстная проверка.
- [51] (Гудфеллоу, Бенджио, Курвилль) — эмпирический риск, регуляризация, ранняя остановка, dropout, бэггинг, универсальная аппроксимация, обратное распространение, оптимизация.
- [53] (Воронцов) — обучение по прецедентам: эмпирический риск, регуляризация как MAP, скользящий контроль.
- [37] (Гасников) — стохастическая оптимизация: оракул с дисперсией, минибатчи, оценки SGD.
- [63], [64] (Меркулов, снимки курсов) — импульс, Adam, автодифференцирование; сверены с первичными книгами.