Вопрос 02. Машинное обучение и искусственные нейронные сети как обратные задачи. Регуляризация

Конспект теории с полными доказательствами

Крохалев Е. М.

2026

Содержание

I. Основная часть **2**

1. Постановка и мотивация **2**

2. Корректность по Адамару и условная корректность **3**

3. Регуляризирующие алгоритмы **5**

4. Машинное обучение как обратная задача **11**
4.1. Эмпирический риск и переобучение 12
4.2. Регуляризатор как априорное распределение 12
4.3. Гребневая регрессия 13
4.4. Смещение, дисперсия и выбор параметра 14
4.5. Лассо и эластичная сеть 16

II. Расширенная часть **16**

5. ИНС как обратная задача **16**

6. Методы обучения **18**

7. Регуляризация в глубоком обучении **21**

8. Разобранные задачи **24**

9. Вопросы, которые стоит ожидать **25**

Часть I.
Основная часть

1. Постановка и мотивация

Сюжет вопроса — сшивка трёх традиций, дающих одной конструкции три имени: регуляризация Тихонова в теории обратных задач, гребневая регрессия в статистике и L_2-регуляризация (снижение весов) в машинном обучении — один и тот же объект, и конспект построен так, чтобы читатель узнавал его под любым из имён.

Обратные задачи в моделировании. Прямая задача состоит в определении результата по заданной причине: по параметрам модели q вычисляется выход $f = Aq$, где A — оператор прямой задачи. Обратная задача (англ. *inverse problem* — [57]) ставится в обратную сторону: по наблюдаемому выходу f определить причину q [42] (Галанин). Обратные задачи делятся на три группы [42] (Галанин): обратные по постановке (восстановление характеристик среды по замерам решения уравнения — классические задачи геофизики); определение структуры и параметров модели по опытным данным; синтез, где по желаемому выходу подбирается сама система (проектирование).

Обучение модели по данным — задача второй группы: модель $g(x, w)$ с параметрами w играет роль оператора A, точки x_i — роль точек измерения, значения y_i — роль правой части f. Восстановление параметров по выходу — операторное уравнение первого рода, и вся теория раздела 2 переносится на обучение без изменений. Это и есть ответ на заголовок вопроса: машинное обучение — частный случай обратной задачи, а регуляризация — механизм, делающий её устойчивой.

Сквозной пример. Через весь конспект и через численные примеры в `examples.ipynb` ведётся одна задача: восстановление функции пяти переменных

$$u(x) = e^{-\|x-a\|^2/(2\cdot 0{,}5^2)} + 0{,}7\, e^{-\|x-b\|^2/(2\cdot 0{,}2^2)}, \qquad x = (x_1, \dots, x_5) \in [-1, 1]^5 \subset \mathbb{R}^5, \tag{1}$$

по m измерениям $y_i = u(x_i) + \varepsilon_i$ в точках x_i, независимо равномерно распределённых в кубе $[-1, 1]^5$; шум независим, $\mathsf{E}\varepsilon_i = 0$, $\mathsf{D}\varepsilon_i = \sigma^2$. Функция (1) — сумма двух гауссовых «спектральных линий»: широкой (центр $a = (-0{,}3;\ 0{,}2;\ -0{,}1;\ 0{,}4;\ 0{,}1)$, ширина $0{,}5$) и узкой (центр $b = (0{,}4;\ -0{,}3;\ 0{,}2;\ -0{,}2;\ 0{,}3)$, ширина $0{,}2$, амплитуда $0{,}7$); именно вторая делает задачу чувствительной к высоким частотам: её пространственный масштаб в 2,5 раза меньше, и базис обязан разрешать в 2,5 раза больше осцилляций по каждой координате. Решение разыскивается в базисе тензорных произведений полиномов Чебышёва

$$\varphi_k(x) = T_{k_1}(x_1) \cdots T_{k_5}(x_5), \qquad k = (k_1, \dots, k_5), \quad k_1 + \dots + k_5 \le 6, \tag{2}$$

их $n = \binom{5+6}{5} = 462$: $\hat{u}(x) = \sum_k w_k\, T_{k_1}(x_1) \cdots T_{k_5}(x_5)$. Подстановка измерений даёт систему $Xw \approx y$, где $X_{ik} = T_{k_1}(x_{i,1}) \cdots T_{k_5}(x_{i,5})$ — матрица плана (строки — значения базисных функций в точках измерения), $w \in \mathbb{R}^n$ — вектор весов, $y \in \mathbb{R}^m$ — целевой вектор. Оператор $A = X$ отображает $\mathbb{R}^n$ в $\mathbb{R}^m$; уравнение

$$Xw = y \tag{3}$$

— конечномерное операторное уравнение первого рода, вокруг которого строится весь вопрос.

Предварительная демонстрация неустойчивости. Прямой способ решить (3) — метод наименьших квадратов (МНК): $\widehat{w} \in \arg\min_w \|Xw - y\|^2$, что при полном ранге и $m \ge n$ даёт $\widehat{w} = (X^{\mathsf{T}}X)^{-1}X^{\mathsf{T}}y$. Когда m близко к n и данные зашумлены, это решение неустойчиво:

сквозной пример с $m = 500$, $n = 462$, $\sigma = 0{,}05$ показывает разрыв отдельных коэффициентов $\widehat{w}_j$ до двух порядков (наихудшее покоординатное отношение $|\widehat{w}_j - w_j^*|/|w_j^*|$ среди значимых коэффициентов, $|w_j^*| > 0{,}05 \max |w^*|$, равно ≈ 63; буквальный максимум по всем координатам ≈ 646) и размытие узкого пика; регуляризованный метод (раздел 3) те же данные восстанавливает (числа — в `examples.ipynb`, пример 2). Механизм неустойчивости разобран ниже: определение — в разделе 2, лечение — в разделе 3, статистика и обучение — в разделах 4–7.

Базис сознательно выбран плохо обусловленным. Механизм здесь — тензоризация: высокочастотные тензорные произведения на конечном наборе точек почти линейно зависимы, малые собственные значения $X^{\mathsf{T}}X$ упираются в уровень шума, и число обусловленности $\varkappa(X^{\mathsf{T}}X)$ оказывается огромным уже при n, близком к m (замер: $\varkappa \approx 2{,}4 \cdot 10^6$ в примере 2). Одномерный прототип того же механизма для степенных функций — матрица Грама мономов, близкая к матрице Гильберта: её собственные значения стремятся к нулю экспоненциально с ростом степени (счёт — в вопросе 09 (метрические и нормированные пространства, теорема Рисса)). На одной постановке видны и плохая обусловленность МНК, и сжатие малых сингулярных направлений, и связь итерационных методов с ранней остановкой.

Два содержательных моста: минимизация невязки — безусловная минимизация (методы — вопрос 10 (методы минимизации функций многих переменных)); псевдорешение несовместной системы — ортогональная проекция (вопрос 09 (метрические и нормированные пространства, теорема Рисса)).

2. Корректность по Адамару и условная корректность

Операторная форма обратной задачи: пусть A отображает топологическое пространство Q в топологическое пространство F; требуется по $f \in F$ найти $q \in Q$ из уравнения $Aq = f$. Обозначения: $D(A)$ — область определения, $R(A)$ — область значений, точное решение — q_T ($Aq_T = f$). Пусть вместо f задано приближение f_δ с известным уровнем погрешности $\delta > 0$, $\|f - f_\delta\| \le \delta$.

Определение 2.1. Задача $Aq = f$ **корректна на паре пространств Q и F (корректна по Адамару)**, если выполнены три условия [14] (Кабанихин):

1) для любого $f \in F$ существует решение $q_T \in Q$, то есть $R(A) = F$ (существование);

2) решение единственно, то есть существует обратный оператор A^{-1} (единственность);

3) для любой окрестности $O(q_T) \subset Q$ найдётся окрестность $O(f) \subset F$ такая, что $A^{-1}O(f) \subset O(q_T)$, то есть A^{-1} непрерывен (устойчивость).

Топологические пространства в определении можно конкретизировать: метрические, банаховы, гильбертовы, евклидовы; неизменными остаются требования существования, единственности и устойчивости [14] (Кабанихин).

Определение 2.2. Задача $Aq = f$ **некорректна** (англ. *ill-posed problem* — [32], [39]) на паре Q, F, если нарушено хотя бы одно из трёх требований определения 2.1 [14] (Кабанихин).

Обратные задачи почти всегда некорректны [42] (Галанин): нарушение существования типично (зашумленные данные вне образа A), нарушение устойчивости — главное: примеры ниже показывают, что малые возмущения f порождают неограниченные возмущения q. Парадоксальная формула этого явления: «неприятности» начинаются тогда, когда оператор прямой задачи слишком хорош — например компактен (замечание 2.11). Некорректную задачу нельзя решать «в лоб»: нужна дополнительная априорная информация о решении, и стандартный её источник — знание о принадлежности решения компактному множеству.

Определение 2.3. Задача $Aq = f$ **условно корректна на множестве** $M \subset Q$ **(корректна по Тихонову)**, если $f \in A(M)$ и выполнены условия [14] (Кабанихин):

1) решение q_T единственно на M;

2) для любой окрестности $O(q_T)$ существует окрестность $O(f)$ такая, что $A^{-1}\big(O(f) \cap A(M)\big) \subset O(q_T)$ (условная устойчивость).

Множество M называется **множеством корректности** [14] (Кабанихин).

Идея: устойчивость требуется не на всём пространстве, а лишь на той части, где решение заведомо лежит; возмущения, выводящие за пределы M, не рассматриваются. Почему компакт — главный пример множества корректности, показывает следующая теорема.

Теорема 2.4 (непрерывность обратного оператора на компакте)**.** *Пусть Q и F — метрические пространства, $M \subset Q$ компактно, отображение $A : Q \to F$ непрерывно и взаимно однозначно переводит M в $A(M) \subset F$. Тогда обратное отображение $A^{-1} : A(M) \to M$ непрерывно.*

Доказательство. Зафиксируем $f \in A(M)$ и положим $q_T = A^{-1}f \in M$. Докажем непрерывность A^{-1} в точке f от противного. Пусть она нарушена: тогда существует $\varepsilon^* > 0$ такое, что для любого $\delta > 0$ найдётся элемент $f_\delta \in A(M)$ с

$$\rho_F(f_\delta, f) < \delta, \qquad \rho_Q(A^{-1}f_\delta,\, q_T) \geq \varepsilon^*.$$

Применяя это к $\delta = 1/n$, $n \in \mathbb{N}$, получаем последовательность $f_n \in A(M)$ такую, что

$$\rho_F(f_n, f) < \tfrac{1}{n}, \qquad \rho_Q(q_n, q_T) \geq \varepsilon^*, \qquad q_n := A^{-1}f_n \in M. \tag{4}$$

Последовательность $\{q_n\} \subset M$ содержится в компакте, поэтому из неё можно выделить сходящуюся подпоследовательность: $q_{n_k} \to q^* \in M$ (замкнутость компакта в метрическом пространстве). По непрерывности A $Aq_{n_k} \to Aq^*$. С другой стороны, $Aq_{n_k} = f_{n_k} \to f$ по первому условию (4). По единственности предела $Aq^* = f = Aq_T$, а поскольку A взаимно однозначно на M и $q^*, q_T \in M$, получаем $q^* = q_T$. Но тогда $\rho_Q(q_{n_k}, q_T) \to 0$, что противоречит второму условию (4): $\rho_Q(q_{n_k}, q_T) \geq \varepsilon^* > 0$ для всех k. Противоречие доказывает непрерывность A^{-1} в f; точка f произвольна, значит A^{-1} непрерывен на всём $A(M)$. $\square$

Замечание 2.5. Компактность M — существенная посылка: из неё следует сходимость подпоследовательности q_{n_k}. На некомпактных множествах взаимная однозначность непрерывного оператора обратной непрерывности не даёт — все четыре примера ниже устроены так: возмущённые данные сходятся, а решения убегают на бесконечность. Существенна и взаимная однозначность: без неё предел подпоследовательности не определён однозначно. Наконец, теорема даёт непрерывность, но не способ вычислить $A^{-1}f_\delta$: приближённые данные вне $A(M)$, и A^{-1} на них не определён — это предмет раздела 3.

Определение 2.6. Пусть Q, F — метрические пространства, $M \subset Q$ компактно, A непрерывен и взаимно однозначно на M. **Модулем непрерывности** (англ. *modulus of continuity* — [57]) оператора A^{-1} на множестве $A(M)$ называется функция

$$\omega(\delta) \;=\; \sup\Big\{\rho_Q(A^{-1}f_1, A^{-1}f_2) \;:\; f_1, f_2 \in A(M),\; \rho_F(f_1, f_2) \leq \delta\Big\}. \tag{5}$$

По теореме 2.4 множество в (5) непусто и ограничено, а сама функция ω имеет смысл количественной меры условной устойчивости. Если $q_T \in M$ — точное решение, $q_\delta \in M$ — решение с данными f_δ, $\rho_F(f, f_\delta) \leq \delta$, то непосредственно из определения $\rho_Q(q_T, q_\delta) \leq \omega(\delta)$. Модуль непрерывности — лучшая возможная гарантированная оценка погрешности на классе M: по определению супремума она достигается (или приближается) на какой-нибудь паре данных. Чем медленнее $\omega(\delta) \to 0$ при $\delta \to 0$, тем ниже предельная точность любого метода восстановления; вопросы 03 (принятие решения: байесовский и минимаксный подходы) и

19 (наилучшее равномерное приближение) используют ту же конструкцию как меру трудности задачи.

Четыре классических примера показывают, как устроена неустойчивость: в каждом явно построено возмущение, сходящееся в F, и элементы, убегающие в Q.

Пример 2.7 (дифференцирование)**.** $Aq = q'$ для $q \in C^1[0,1]$ с $q(0) = 0$, пространства $Q = C^1$ с нормой C, $F = C[0,1]$. Возьмём $f_\delta = f + \delta \sin(x/\delta^2)$: тогда $\|f_\delta - f\|_C = \delta$, но

$$(f_\delta - f)' = \tfrac{1}{\delta}\cos(x/\delta^2), \qquad \|(f_\delta - f)'\|_C = \tfrac{1}{\delta} \to \infty.$$

Задача некорректна по устойчивости [14] (Кабанихин). Смена метрики в Q на слабую не спасает: для L_2 неустойчивость сохраняется с другой скоростью.

Пример 2.8 (уравнение Фредгольма 1-го рода)**.** $Aq = \int_a^b K(x,s)\,q(s)\,ds$ с непрерывным ядром K; A компактен в C и в L_2. Пусть $Aq = f$ разрешимо; положим $q_n(s) = q_T(s) + n\sin(n^2 s)$. Тогда $\|q_n - q_T\|_C \to \infty$, но $(A(q_n - q_T))(x) = \int_a^b K(x,s)\,n\sin(n^2 s)\,ds$. Заменой $t = n^2 s$ и интегрированием по частям при $K \in C^1$ по второму аргументу получаем $\|Aq_n - f\|_C \le K_1/n^2 \to 0$: возмущение решения бесконечно велико при возмущении данных бесконечно малом [14] (Кабанихин). Некорректность здесь двойная: $R(A)$ нигде не плотен и не замкнут (компактный оператор не может иметь замкнутый образ, если он бесконечномерен), что нарушает и существование, и устойчивость.

Пример 2.9 (обратное время в задаче теплопроводности)**.** Прямая задача: $u_t = a^2 u_{xx}$, $u(0,t) = u(l,t) = 0$, начальное условие $u(x,0) = q(x)$; наблюдение $u(x,T)$. Мода $q_n(x) = \frac{1}{n}\sin(\pi n x/l)$ порождает $u_n(x,t) = \frac{1}{n}e^{-a^2\pi^2 n^2 t/l^2}\sin(\pi n x/l)$, и наблюдаемое значение $\frac{1}{n}e^{-a^2\pi^2 n^2 T/l^2}\sin(\pi n x/l)$ равномерно стремится к нулю. Обратный оператор восстанавливает моду с множителем $e^{a^2\pi^2 n^2 T/l^2}$, то есть ошибка данных амплитуды δ_n в n-й моде превращается в ошибку решения $\delta_n e^{a^2\pi^2 n^2 T/l^2}$ — экспоненциальный рост по номеру моды [14] (Кабанихин). Чем точнее модель прямой задачи описывает сглаживание, тем сильнее обратная задача усиливает высокие частоты.

Пример 2.10 (задача Коши для уравнения Лапласа)**.** Ищется гармоническая в полосе функция по данным Коши на границе: $u_{xx} + u_{yy} = 0$, $u(0,y) = f(y)$, $u_x(0,y) = 0$. Мода $f_n(y) = \frac{1}{n}\sin(ny)$ порождает решение $u_n(x,y) = \frac{1}{n}\sin(ny)\,\frac{e^{nx}+e^{-nx}}{2} = \frac{1}{n}\sin(ny)\cosh(nx)$, гармоническое при каждом n; данные стремятся к нулю равномерно по y, а при $x > 0$ решение неограниченно растёт как $e^{nx}/(2n)$ [14] (Кабанихин). Задача Коши для эллиптического уравнения — классический образец некорректности по Адамару.

Замечание 2.11. Примеры 2.8–2.10 иллюстрируют общий принцип: чем «лучше» оператор прямой задачи (компактен, сильно сглаживает), тем хуже обратная задача. Компактный оператор переводит слабую сходимость в сильную; его обратный переводит сильную в слабую — и потому не ограничен. Интуиция: сглаживание стирает высокие частоты, и их восстановление из зашумлённых данных требует деления на бесконечно малые множители (критерий Пикара, раздел 8).

3. Регуляризирующие алгоритмы

Теорема 2.4 гарантирует устойчивость на компакте, но не говорит, как вычислить решение: приближённые данные f_δ лежат вне образа $A(M)$, и обратный оператор на них не действует. Регуляризация устраняет этот пробел: вместо несуществующего A^{-1} строится непрерывное приближение, сходящееся к A^{-1} при $\delta \to 0$.

Определение 3.1. Регуляризирующим семейством для задачи $Aq = f$ называется семейство операторов $\{R_\alpha\}_{\alpha>0}$, $R_\alpha : F \to Q$, такое что [14] (Кабанихин):

1) для любого $\alpha > 0$ оператор R_α непрерывен;

2) для любого $f \in R(A)$ и $q_T = A^{-1}f$

$$\lim_{\alpha\to+0} R_\alpha f = q_T. \tag{6}$$

Число α — **параметр регуляризации** (в статистике тот же параметр обозначают λ [16] (Хасти, Тибширани, Фридман), в ранних работах по обучению — τ [53] (Воронцов); во всём конспекте основное обозначение — α).

Определение 3.2. Пусть вместо f задано f_δ с $\|f - f_\delta\| \le \delta$. Отображение $R_{\alpha(\delta,f_\delta)}$, сопоставляющее данным элемент $q_{\alpha\delta} = R_{\alpha(\delta,f_\delta)}f_\delta$, — **регуляризирующий алгоритм** (англ. *regularization algorithm*), если

$$\sup_{\|f-f_\delta\|\le\delta} \left\| R_{\alpha(\delta,f_\delta)}f_\delta - A^{-1}f \right\| \longrightarrow 0 \qquad (\delta \to 0) \tag{7}$$

для всех $f \in R(A)$; выбор $\alpha = \alpha(\delta, f_\delta)$ — **согласование параметра регуляризации с погрешностью данных**.

Ключевая оценка для линейного R_α выводится в две строки:

$$\|q_T - q_{\alpha\delta}\| \le \|q_T - R_\alpha f\| + \|R_\alpha f - R_\alpha f_\delta\| \le \gamma(q_T, \alpha) + \|R_\alpha\|\,\delta,$$

где

$$\gamma(q_T, \alpha) = \|q_T - R_\alpha f\| \tag{8}$$

— уклонение регуляризованного решения от точного на точных данных. Первый член мала при малых α по (6); второй растёт при уменьшении α, поскольку $\|R_\alpha\| \to \infty$ при $\alpha \to 0$ (иначе предел (6) был бы ограниченным оператором и задача была бы корректной). Это противоречивое требование — ядро всей теории: **точность решения и устойчивость к шуму балансируются параметром** α.

Лемма 3.3 (о балансировке)**.** *Пусть $\{R_\alpha\}$ — регуляризирующее семейство для $Aq = f$ с линейными непрерывными R_α. Тогда величина*

$$\omega(q_T, \delta) = \inf_{\alpha>0}\{\gamma(q_T, \alpha) + \|R_\alpha\|\,\delta\} \tag{9}$$

стремится к нулю при $\delta \to 0$.

Доказательство. Зафиксируем $\varepsilon > 0$. По свойству (6) найдётся $\alpha_0 = \alpha_0(\varepsilon) > 0$ такое, что $\gamma(q_T, \alpha) = \|q_T - R_\alpha f\| < \varepsilon/2$ для всех $\alpha \in (0, \alpha_0)$. Каждый оператор R_α при $\alpha > 0$ непрерывен, поэтому $\mu_0(\varepsilon) = \inf_{\alpha\in(0,\alpha_0)} \|R_\alpha\| \le \left\|R_{\alpha_0/2}\right\| < \infty$ [14] (Кабанихин); возьмём $\delta_0(\varepsilon) = \varepsilon/(2\mu_0(\varepsilon))$. Тогда для всех $\delta \in (0, \delta_0(\varepsilon))$

$$\omega(q_T, \delta) = \inf_{\alpha>0}\{\gamma(q_T, \alpha) + \|R_\alpha\|\,\delta\} \le \inf_{\alpha\in(0,\alpha_0)}\left\{\frac{\varepsilon}{2} + \|R_\alpha\|\,\delta\right\} = \frac{\varepsilon}{2} + \mu_0(\varepsilon)\,\delta < \frac{\varepsilon}{2} + \frac{\varepsilon}{2} = \varepsilon.$$

Поскольку $\omega(q_T, \delta) \ge 0$, это и есть $\lim_{\delta\to0}\omega(q_T, \delta) = 0$. □

Замечание 3.4. Лемма доказывает существование какого-то согласования, но не даёт его явно; конструктивные правила — принцип невязки, квазирешение, контроль по отложенной выборке — разобраны ниже. Существенна линейность R_α: она позволила вынести $\|R_\alpha\|\,\delta$ за скобки; для нелинейных операторов оценка усложняется, идея балансировки сохраняется.

Самый известный способ построить регуляризующее семейство — минимизация функционала Тихонова.

Определение 3.5. Пусть Q, F — гильбертовы пространства, $A : Q \to F$ — линейный ограниченный оператор, $f_\delta \in F$, $q^0 \in Q$ — пробное решение (априорное приближение). **Функционалом Тихонова** называется

$$M^\alpha[q] = \|Aq - f_\delta\|^2 + \alpha \left\|q - q^0\right\|^2, \qquad \alpha > 0, \tag{10}$$

а **методом регуляризации А. Н. Тихонова** — построение приближённого решения по правилу $q_{\alpha\delta} = \arg\min_{q \in Q} M^\alpha[q]$ [14] (Кабанихин). Слагаемое $\alpha \left\|q - q^0\right\|^2$ называется стабилизирующим функционалом; в общем виде вместо нормы берётся полунорма, отвечающая априорной информации о гладкости решения.

Теорема 3.6 (существование и единственность минимизатора)**.** *Пусть Q и F — гильбертовы пространства, $A : Q \to F$ — линейный ограниченный оператор, $\alpha > 0$, $q^0 \in Q$. Тогда для любого $f_\delta \in F$ функционал M^α (10) достигает своей нижней грани на единственном элементе $q_\alpha \in Q$.*

Доказательство. Обозначим $m = \inf_{q \in Q} M^\alpha[q] \geq 0$ и выберем минимизирующую последовательность q_n так, что $M^\alpha[q_n] \leq m + \frac{1}{n}$. Из неравенства $\alpha \left\|q_n - q^0\right\|^2 \leq M^\alpha[q_n] \leq m + 1$ следует, что последовательность q_n ограничена: $\left\|q_n - q^0\right\| \leq \sqrt{(m+1)/\alpha}$. В гильбертовом пространстве из всякой ограниченной последовательности выделяется слабо сходящаяся подпоследовательность: существует $q_\alpha \in Q$ и подпоследовательность q_{n_k} такие, что $q_{n_k} - q^0 \rightharpoonup q_\alpha - q^0$.

Норма в гильбертовом пространстве слабо полунепрерывна снизу: $\left\|q_\alpha - q^0\right\| \leq \liminf_k \left\|q_{n_k} - q^0\right\|$. Покажем, что и первое слагаемое не увеличивается при слабом пределе. Оператор A слабо непрерывен: если $q_{n_k} \rightharpoonup q_\alpha$, то для любого $h \in F$ $\left\langle Aq_{n_k}, h \right\rangle = \left\langle q_{n_k}, A^* h \right\rangle \to \langle q_\alpha, A^* h \rangle = \langle Aq_\alpha, h \rangle$, то есть $Aq_{n_k} \rightharpoonup Aq_\alpha$, и потому $\|Aq_\alpha - f_\delta\| \leq \liminf_k \left\|Aq_{n_k} - f_\delta\right\|$. Складывая, $m \leq M^\alpha[q_\alpha] \leq \liminf_k M^\alpha[q_{n_k}] = \lim_k M^\alpha[q_{n_k}] = m$, то есть $M^\alpha[q_\alpha] = m$ и q_α — минимизатор.

Докажем единственность. Для любых $q_1, q_2 \in Q$ по тождеству параллелограмма

$$M^\alpha\left[\tfrac{q_1+q_2}{2}\right] = \tfrac{1}{2}M^\alpha[q_1] + \tfrac{1}{2}M^\alpha[q_2] - \tfrac{1}{4}\|A(q_1 - q_2)\|^2 - \tfrac{\alpha}{4}\|q_1 - q_2\|^2.$$

Пусть $q_1 \neq q_2$ — два минимизатора, $M^\alpha[q_1] = M^\alpha[q_2] = m$. Тогда $m \leq M^\alpha\left[\frac{q_1+q_2}{2}\right] \leq m - \frac{\alpha}{4}\|q_1 - q_2\|^2 < m$ — противоречие. Значит минимизатор единствен. □

Замечание 3.7. Существенны три посылки. (1) Гильбертова структура: слабая компактность шара и полунепрерывность нормы снизу гильбертовы; в банаховом пространстве существование в той же форме не гарантируется. (2) Строгая выпуклость стабилизатора ($\alpha > 0$): она даёт единственность; при $\alpha = 0$ минимизатор — всякое псевдорешение, единственность теряется при $\ker A \neq \{0\}$. (3) Ограниченность A нужна для полунепрерывности первого слагаемого. Полная непрерывность A здесь не требуется — она нужна в теореме 3.9.

Предложение 3.8 (нормальное уравнение)**.** *Минимизатор q_α функционала (10) удовлетворяет уравнению Эйлера*

$$(A^*A + \alpha I)\, q_\alpha = A^* f_\delta + \alpha q^0, \tag{11}$$

причём оператор $A^*A + \alpha I$ обратим и $\left\|(A^*A + \alpha I)^{-1}\right\| \leq 1/\alpha$.

Доказательство. При любом $v \in Q$ и $t \in \mathbb{R}$ $M^\alpha[q_\alpha + tv] = M^\alpha[q_\alpha] + 2t\left(\langle Aq_\alpha - f_\delta, Av\rangle + \alpha\langle q_\alpha - q^0, v\rangle\right) + t^2(\|Av\|^2 + \alpha\|v\|^2)$. Поскольку q_α — точка минимума, коэффициент при t обязан обращаться в нуль для всех v: $\langle Aq_\alpha - f_\delta, Av\rangle + \alpha\langle q_\alpha - q^0, v\rangle = \langle A^*(Aq_\alpha - f_\delta) + \alpha(q_\alpha - q^0), v\rangle = 0 \quad \forall v$, откуда $A^*Aq_\alpha + \alpha q_\alpha = A^*f_\delta + \alpha q^0$, то есть (11). Далее, для любого $q \in Q$ $\langle (A^*A + \alpha I)q, q\rangle = \|Aq\|^2 + \alpha\|q\|^2 \geq \alpha\|q\|^2$, то есть оператор $A^*A + \alpha I$ сильно положителен, обратим по теореме Люмера — Минтера — Филлипса (или непосредственно: инъективен и имеет замкнутый образ, совпадающий с ортогональным дополнением ядра сопряжённого, то есть со всем Q), и $\|(A^*A + \alpha I)^{-1}\| \leq 1/\alpha$. □

Из (11) получаем явную формулу регуляризованного решения

$$q_{\alpha\delta} = (A^*A + \alpha I)^{-1}(A^*f_\delta + \alpha q^0), \tag{12}$$

а при $q^0 = 0$ — $q_{\alpha\delta} = (A^*A + \alpha I)^{-1}A^*f_\delta$. Семейство $R_\alpha = (A^*A + \alpha I)^{-1}A^*$ состоит из ограниченных операторов: $\|R_\alpha\| \leq \sup_\sigma \sigma/(\sigma^2 + \alpha) = 1/(2\sqrt{\alpha})$ по спектральной теореме, и $\|R_\alpha\| \to \infty$ при $\alpha \to 0$, как и положено регуляризующему семейству.

Теорема 3.9 (сходимость метода Тихонова)**.** *Пусть Q, F — гильбертовы пространства, $A : Q \to F$ — линейный вполне непрерывный оператор, $f \in R(A)$, решение q_T уравнения $Aq = f$ единственно. Пусть $\|f - f_\delta\| \leq \delta$, и параметр выбран по правилу $\alpha = \alpha(\delta)$ так, что*

$$\lim_{\delta\to 0}\alpha(\delta) = 0, \qquad \lim_{\delta\to 0}\frac{\delta^2}{\alpha(\delta)} = 0. \tag{13}$$

Тогда регуляризованные решения $q_{\alpha(\delta),\delta}$ (12) сходятся к точному: $\|q_{\alpha(\delta),\delta} - q_T\| \to 0$ при $\delta \to 0$.

Доказательство. Разобьём доказательство на три шага.

Шаг 1 (ограниченность решений). По определению минимизатора $M^\alpha[q_{\alpha\delta}] \leq M^\alpha[q_T] \leq \delta^2 + \alpha\|q_T - q^0\|^2$. Отсюда

$$\|q_{\alpha\delta} - q^0\|^2 \leq \frac{\delta^2}{\alpha} + \|q_T - q^0\|^2, \qquad \|Aq_{\alpha\delta} - f_\delta\|^2 \leq \delta^2 + \alpha\|q_T - q^0\|^2. \tag{14}$$

По условию (13) первая оценка даёт равномерную по δ ограниченность $q_{\alpha\delta} - q^0$, а вторая — сходимость образов:

$$Aq_{\alpha\delta} \to f \quad (\delta \to 0), \tag{15}$$

поскольку $\|Aq_{\alpha\delta} - f\| \leq \|Aq_{\alpha\delta} - f_\delta\| + \delta \leq \sqrt{\delta^2 + \alpha\|q_T - q^0\|^2} + \delta \to 0$.

Шаг 2 (слабая сходимость подпоследовательностей). Ограниченная последовательность $q_{\alpha\delta} - q^0$ содержит слабо сходящуюся подпоследовательность: $q_{\alpha_k\delta_k} - q^0 \rightharpoonup q_* - q^0$. Так как A вполне непрерывен, компактный оператор переводит слабую сходимость в сильную: $Aq_{\alpha_k\delta_k} \to Aq_*$ (по норме F). Сравнивая с (15), получаем $Aq_* = f = Aq_T$; по единственности решения $q_* = q_T$. Значит, всякая слабо сходящаяся подпоследовательность $q_{\alpha\delta}$ сходится слабо к q_T, и вся сеть $q_{\alpha\delta}$ сходится к q_T слабо.

Шаг 3 (сильная сходимость). Раскроем квадрат нормы:

$$\|q_{\alpha\delta} - q_T\|^2 = \|q_{\alpha\delta} - q^0\|^2 + \|q_T - q^0\|^2 - 2\langle q_{\alpha\delta} - q^0, q_T - q^0\rangle.$$

Первое слагаемое ограничено сверху оценкой (14): $\limsup\|q_{\alpha\delta} - q^0\|^2 \leq \limsup\delta^2/\alpha + \|q_T - q^0\|^2 = \|q_T - q^0\|^2$ по (13); скалярное произведение стремится к $\|q_T - q^0\|^2$ по слабой сходимости (шаг 2). Следовательно, $\limsup_{\delta\to 0}\|q_{\alpha\delta} - q_T\|^2 \leq \|q_T - q^0\|^2 + \|q_T - q^0\|^2 - 2\|q_T - q^0\|^2 = 0$, то есть $q_{\alpha\delta} \to q_T$ по норме. □

Замечание 3.10. Проанализируем посылки. (1) Условие $\delta^2/\alpha \to 0$ существенно: при $\alpha \sim \delta^2$ оценка (14) даёт лишь ограниченность $\limsup \|q_{\alpha\delta} - q^0\|^2 \le 1 + \|q_T - q^0\|^2$, и сходимость теряется; слишком быстрый рост α ломает аппроксимацию. Именно поэтому α нельзя выбирать ни слишком малым, ни слишком большим — нужно согласование (13). (2) Вполне непрерывность A использована только на шаге 2 для перевода слабой сходимости в сильную; для обратимого ограниченного оператора шаг 2 не нужен: образы сходятся по построению, а слабая сходимость $q_{\alpha\delta}$ к q_T следует из сходимости $Aq_{\alpha\delta} \to Aq_T$ и обратимости A. (3) Единственность решения заменяется сходимостью к нормальному решению (элементу, ближайшему к q^0); формулировка и доказательство усложняются, качественный вывод тот же [14] (Кабанихин).

Теорема 3.9 гарантирует сходимость без скорости: скорость требует условий на гладкость решения (истокопредставимость $q_T = (A^*A)^{p/2}v$), иначе она может быть сколь угодно низкой. В конечномерном случае оценка выводится напрямую из нормального уравнения.

Лемма 3.11 (скорость сходимости в конечномерном разрешимом случае)**.** *Пусть $A : \mathbb{R}^n \to \mathbb{R}^m$ — линейный оператор, уравнение $Aq = f$ разрешимо, q_T — его нормальное решение (то есть $q_T \perp \ker A$), $\|f - f_\delta\| \le \delta$, $q^0 = 0$. Обозначим через $\lambda_r > 0$ наименьшее положительное собственное значение матрицы A^*A ($r = \operatorname{rank} A$). Тогда*

$$\|q_{\alpha\delta} - q_T\| \;\le\; \frac{\alpha}{\lambda_r}\,\|q_T\| + \frac{\delta}{2\sqrt{\alpha}}. \tag{16}$$

Доказательство. Применим оператор A^* к равенству $Aq_T = f$: $A^*Aq_T = A^*f$. Вычитая из нормального уравнения (11) (при $q^0 = 0$) это равенство, получаем $(A^*A + \alpha I)(q_{\alpha\delta} - q_T) = A^*(f_\delta - f) - \alpha q_T$, то есть $q_{\alpha\delta} - q_T = (A^*A + \alpha I)^{-1}A^*(f_\delta - f) - \alpha(A^*A + \alpha I)^{-1}q_T$. Оценим слагаемые по очереди. Первое: в сингулярном базисе A матрица $(A^*A + \alpha I)^{-1}A^*$ имеет сингулярные числа $\sigma_j/(\sigma_j^2 + \alpha)$, а функция $\sigma \mapsto \sigma/(\sigma^2 + \alpha)$ достигает максимума $1/(2\sqrt{\alpha})$ в точке $\sigma = \sqrt{\alpha}$; поэтому $\|(A^*A + \alpha I)^{-1}A^*(f_\delta - f)\| \le \frac{1}{2\sqrt{\alpha}}\,\delta$. Второе: так как $q_T \perp \ker A = \ker A^*A$, вектор q_T разложим по собственным векторам φ_j, отвечающим положительным собственным значениям $\lambda_1 \ge \ldots \ge \lambda_r > 0$, и действие $\alpha(A^*A + \alpha I)^{-1}$ на φ_j есть умножение на $\alpha/(\lambda_j + \alpha) \le \alpha/\lambda_r$; следовательно,

$$\left\|\alpha(A^*A + \alpha I)^{-1}q_T\right\| \le \frac{\alpha}{\lambda_r + \alpha}\,\|q_T\| \le \frac{\alpha}{\lambda_r}\,\|q_T\|\,.$$

Суммой двух оценок и является (16). □

Следствие 3.12 (балансировка $\varepsilon^{2/3}$)**.** *Пусть данные заданы с точностью порядка ε: $\delta \sim \varepsilon$. Тогда минимальное по порядку значение правой части* (16) *достигается при*

$$\alpha \sim \varepsilon^{2/3} \tag{17}$$

и равно $O(\varepsilon^{2/3})$: задача восстанавливается с точностью порядка $\varepsilon^{2/3}$ [14] (Кабанихин). Здесь ε — точность данных, а не шаг обучения.

Доказательство. Минимизируем по α функцию $\varphi(\alpha) = c_1\alpha + c_2\varepsilon\alpha^{-1/2}$ с $c_1 = \|q_T\|/\lambda_r$, $c_2 = 1/2$. Приравнивая производную к нулю: $\varphi'(\alpha) = c_1 - \frac{1}{2}c_2\varepsilon\alpha^{-3/2} = 0$, получаем $\alpha^{3/2} = c_2\varepsilon/(2c_1)$, то есть $\alpha \sim \varepsilon^{2/3}$ (константы c_1, c_2 лишь фиксируют пропорциональность). Подстановка даёт $\varphi \sim c_1\varepsilon^{2/3} + c_2\varepsilon^{1-1/3} = O(\varepsilon^{2/3})$. □

Замечание 3.13. Число $\varepsilon^{2/3}$ — цена устойчивости: при данных точности ε решение восстанавливается лишь с точностью $\varepsilon^{2/3} \gg \varepsilon$. Показатель определяется соперничеством двух членов (16): смещения, линейного по α, и дисперсии $\delta/\sqrt{\alpha}$; лемма 3.11 — прямой аналог разложения теоремы 4.9. Для неразрешимого уравнения (псевдорешение) точность падает до $O(\varepsilon^{1/2})$ при $\alpha \sim \varepsilon^{1/2}$ [14] (Кабанихин).

Теория даёт асимптотическое согласование (13); прикладная задача обычно имеет фиксированный δ и требует конкретного числа. Разберём главный принцип выбора по уровню шума; сводка всех трёх — в замечании 3.20.

Лемма 3.14 (монотонность невязки)**.** *Пусть $A : \mathbb{R}^n \to \mathbb{R}^m$ — линейный оператор, $f_\delta \in \mathbb{R}^m$, $q^0 = 0$, $q_\alpha = (A^*A + \alpha I)^{-1} A^* f_\delta$, и пусть $X = UDV^{\mathsf{T}}$ — сингулярное разложение A с сингулярными числами $d_1 \geq \ldots \geq d_r > 0$. Тогда невязка*

$$\rho(\alpha) = \|Aq_\alpha - f_\delta\|^2 = \sum_{j=1}^{r} \Big(\frac{\alpha}{d_j^2 + \alpha}\Big)^2 \big(u_j^{\mathsf{T}} f_\delta\big)^2 + \|(I - P) f_\delta\|^2 , \tag{18}$$

где P — ортогональный проектор на $R(A) = \operatorname{lin}\{u_1, \ldots, u_r\}$. В частности, ρ непрерывна и (строго) монотонно возрастает по α при условии $Pf_\delta \neq 0$, причём

$$\lim_{\alpha \to 0} \rho(\alpha) = \|(I - P) f_\delta\|^2 = \operatorname{dist}^2(f_\delta, R(A)), \qquad \lim_{\alpha \to \infty} \rho(\alpha) = \|f_\delta\|^2 . \tag{19}$$

Доказательство. Подставим $q_\alpha = V(D^2 + \alpha I)^{-1} D U^{\mathsf{T}} f_\delta$ в невязку: $Aq_\alpha = UD(D^2 + \alpha I)^{-1} DU^{\mathsf{T}} f_\delta = \sum_{j=1}^{r} \frac{d_j^2}{d_j^2 + \alpha} \big(u_j^{\mathsf{T}} f_\delta\big)\, u_j$. Тогда $Aq_\alpha - f_\delta = -\sum_{j=1}^{r} \frac{\alpha}{d_j^2 + \alpha} (u_j^{\mathsf{T}} f_\delta) u_j - (I - P) f_\delta$. Оба слагаемых ортогональны (первое лежит в $R(A)$, второе в $R(A)^\perp$), поэтому квадрат нормы раскладывается в сумму квадратов, и мы получаем (18). Каждая функция $\alpha \mapsto \big(\alpha/(d_j^2 + \alpha)\big)^2 = \big(1 - d_j^2/(d_j^2 + \alpha)\big)^2$ непрерывна и строго возрастает от 0 до 1 при α от 0 до ∞; при $u_j^{\mathsf{T}} f_\delta \neq 0$ хотя бы для одного j (то есть при $Pf_\delta \neq 0$) сумма строго возрастает. Пределы (19) — пределы слагаемых при $\alpha \to 0$ и $\alpha \to \infty$; вторая часть первого равенства — определение расстояния до подпространства (теорема о проекции, вопрос 09). □

Теорема 3.15 (принцип невязки)**.** *В условиях леммы 3.14 пусть дополнительно $f \in R(A)$, $\|f - f_\delta\| \leq \delta$ и*

$$\operatorname{dist}(f_\delta, R(A)) < \delta < \|f_\delta\| . \tag{20}$$

Тогда уравнение

$$\rho(\alpha) = \delta^2 \tag{21}$$

имеет единственный корень $\alpha(\delta) > 0$.

Доказательство. По лемме 3.14 ρ непрерывна и строго возрастает от $\rho(0+) = \operatorname{dist}^2(f_\delta, R(A))$ до $\rho(\infty) = \|f_\delta\|^2$ (строгое возрастание обеспечено вторым неравенством (20): $\|f_\delta\| > \delta > 0$ влечёт $Pf_\delta \neq 0$). Оба краевых значения строго по разные стороны от δ^2 по (20): точнее, по теореме о проекции $\operatorname{dist}(f_\delta, R(A)) \leq \|f_\delta - f\| \leq \delta$, а по условию первое неравенство строгое. По теореме о промежуточном значении непрерывная монотонная функция принимает значение δ^2 ровно один раз. □

Замечание 3.16. Условие (20) — точная граница применимости. Если $\operatorname{dist}(f_\delta, R(A)) = \delta$ (например, $f_\delta \in R(A)$ и шум исчерпал бюджет точности), положительного корня нет — нужна обобщённая невязка: при $\|A - A_h\| \leq h$ параметр выбирают из $\big\|A_h q^\delta_{\alpha h} - f_\delta\big\| = h \big\|q^\delta_{\alpha h}\big\| + \delta$ [14] (Кабанихин). Мост в обучение: невязка — ошибка на обучении; принцип невязки говорит остановиться, когда она сравнялась с уровнем шума, а его роль играет ошибка на отложенной выборке (раздел 4; численный поиск корня — задача 8.4).

Второй классический способ согласования — выбор на компакте.

Определение 3.17. Пусть Q, F — метрические пространства, $M \subset Q$, $A : Q \to F$. **Квазирешением** уравнения $Aq = f$ на множестве M называется элемент $q_K \in M$, на котором достигается нижняя грань невязки: $\rho_F(Aq_K, f) = \inf_{q \in M} \rho_F(Aq, f)$ [14] (Кабанихин).

Теорема 3.18 (В. К. Иванов о квазирешении)**.** *Пусть $M \subset Q$ компактно, A непрерывен и взаимно однозначен на M, причём проекция каждого $f \in F$ на $A(M)$ единственна. Тогда квазирешение существует, единственно и непрерывно зависит от f.*

Идея доказательства. Существование: отображение $q \mapsto \rho_F(Aq, f)$ непрерывно на M (композиция непрерывных), поэтому достигает на компакте своей нижней грани.

Единственность: пусть q_K, q'_K — два квазирешения. Тогда Aq_K и Aq'_K — два ближайших к f элемента множества $A(M)$; по единственности проекции $Aq_K = Aq'_K$, а по взаимной однозначности A на M: $q_K = q'_K$.

Непрерывность: пусть $f_n \to f$, q_n — квазирешения для f_n. По компактности из q_n выделяется сходящаяся подпоследовательность $q_{n_k} \to q^* \in M$; по непрерывности A образы сходятся: $Aq_{n_k} \to Aq^*$. С другой стороны, обозначив через π проекцию на $A(M)$, $\rho_F(Aq_{n_k}, f) \le \rho_F(Aq_{n_k}, f_{n_k}) + \rho_F(f_{n_k}, f) = \rho_F(\pi f_{n_k}, f_{n_k}) + \rho_F(f_{n_k}, f) \to \rho_F(\pi f, f)$, то есть Aq^* — элемент $A(M)$, ближайший к f; по единственности проекции $Aq^* = \pi f = Aq_K(f)$, по взаимной однозначности $q^* = q_K(f)$. Предел единствен, значит сходится вся последовательность. □

Замечание 3.19. Доказательство целиком стоит на компактности (существование, выделение подпоследовательности), непрерывности A и единственности проекции — тот же набор посылок, что в теореме 2.4. Единственность проекции выполнена, например, когда F строго выпукло (гильбертово), а $A(M)$ выпукло и замкнуто.

Для линейного A и шара $M = B(0, r)$ квазирешение записывается явно. Пусть $\{\lambda_n, \varphi_n\}$ — собственные значения и векторы A^*A, $\lambda_1 \ge \lambda_2 \ge \ldots$, $f_n = \langle A^* f, \varphi_n \rangle$. Тогда [14] (Кабанихин)

$$q_K = \sum_n \frac{f_n}{\lambda_n}\varphi_n, \quad \text{если } \sum_n \frac{f_n^2}{\lambda_n^2} < r^2; \qquad q_K = \sum_n \frac{f_n}{\alpha + \lambda_n}\varphi_n, \quad \text{если } \sum_n \frac{f_n^2}{\lambda_n^2} \ge r^2, \tag{22}$$

где во втором случае α — корень уравнения $\sum_n f_n^2/(\alpha + \lambda_n)^2 = r^2$ (левая часть строго убывает по α от $+\infty$ до 0, так что корень единствен). Сравните со (12): коэффициент при f_n/λ_n равен $\lambda_n/(\alpha + \lambda_n)$ — **тот же фильтр** $\lambda/(\lambda + \alpha)$, что и у метода Тихонова при $q^0 = 0$. Квазирешение на шаре с активным ограничением и решение Тихонова — одна кривая в пространстве Q, параметризованная двумя способами: радиусом (Иванов) или α (Тихонов). Это первый пример эквивалентности «ограничение ↔ штраф», который вернётся в разделе 4.

Замечание 3.20 (три способа выбора параметра). Теория предлагает три принципа согласования α с данными: по уровню шума (принцип невязки, корень (21)), по контролю (отложенная выборка или перекрёстная проверка), по квазиоптимуму (минимизация (9)). В обучении работают второй и эвристические правила; принцип невязки остаётся эталоном сравнения (раздел 4, задача 8.4).

4. Машинное обучение как обратная задача

Словарь перевода: матрица плана X (строки — примеры) играет роль A, веса w — роль q, целевой вектор y — роль f_δ; m — число примеров, n — число параметров. Обозначения разделов 2–3 и этого раздела взаимозаменяемы по этому словарю.

4.1. Эмпирический риск и переобучение

Определение 4.1. Пусть $g(x, w)$ — модель с параметрами $w \in \mathbb{R}^n$, $\ell(\hat{y}, y)$ — функция потерь. **Эмпирическим риском** (англ. *empirical risk* — [51]) называется средняя потеря по обучающей выборке

$$Q(w) = \frac{1}{m} \sum_{i=1}^{m} \ell(g(x_i, w),\, y_i) \tag{23}$$

[53] (Воронцов); метод эмпирического риска ищет $\widehat{w} \in \arg\min_w Q(w)$ [53] (Воронцов). Цель обучения — малый риск на новых данных (ошибка обобщения); минимизация (23) сама по себе уязвима для переобучения: модели высокой ёмкости способны просто запомнить обучающий набор [51] (Гудфеллоу, Бенджио, Курвилль).

Для квадратичной потери $\ell(\hat{y}, y) = (\hat{y} - y)^2$ минимизация (23) — ровно задача МНК из построения сквозного примера: $Q(w) = \frac{1}{m} \|Xw - y\|^2$, и вся теория раздела 3 применяется слово в слово (q читается как w, A как X, f_δ как y с уровнем шума $\delta \sim \sqrt{m}\,\sigma$).

Переобучение как некорректность. Решение МНК по данным существует всегда (псевдорешение есть для любой выборки), но при близких m и n и шуме оно неустойчиво. Формальная картина та же, что в разделе 2: в квадратной невырожденной ситуации $m = n$ имеем $\widehat{w} = X^{-1}y$, и возмущение данных δy порождает возмущение решения

$$\frac{\|\delta w\|}{\|w\|} \le \varkappa(X)\, \frac{\|\delta y\|}{\|y\|}, \tag{24}$$

то есть при $\varkappa(X) \gg 1$ малый шум данных многократно усиливается. Источник плохой обусловленности в сквозном примере — тензоризация: высокочастотные тензорные произведения полиномов Чебышёва на конечном наборе точек почти линейно зависимы, и малые собственные значения $X^{\mathsf{T}}X$ упираются в уровень шума. Одномерный прототип того же механизма — степенные функции: матрица Грама мономов близка к матрице Гильберта, и её собственные значения стремятся к нулю экспоненциально с ростом степени (счёт — в вопросе 09 (метрические и нормированные пространства, теорема Рисса)). Похожая ситуация — мультиколлинеарность в статистике: почти линейно зависимые столбцы X делают $X^{\mathsf{T}}X$ почти вырожденной; у [53] (Воронцов) практическим признаком служит число обусловленности порядка 10^2–10^4 и выше. Геометрический смысл: плохо обусловленная задача имеет долину минимумов — вдоль малых собственных направлений функционал почти не меняется, и решение гуляет по ней под действием шума; то же явление замедляет градиентные методы (вопрос 10 (методы минимизации функций многих переменных), где число обусловленности $\varkappa$ задаёт знаменатель сходимости).

Итак: переобучение — это не «слишком сложная модель» вообще, а **конкретное проявление некорректности по устойчивости**: ёмкость даёт существование решения под любые данные, а малые собственные значения матрицы плана — его неустойчивость к шуму. Лекарство — регуляризация, то есть возврат задачи в класс корректных с заменой исходного уравнения близкой корректной задачей (определение 3.2).

4.2. Регуляризатор как априорное распределение

Тихоновский стабилизатор $\alpha \|q - q^0\|^2$ имеет точный вероятностный смысл: это логарифм гауссовского априорного распределения. Покажем это полностью.

Теорема 4.2 (байесовский вывод L_2-регуляризатора)**.** *Пусть модель линейна: $y = Xw + \varepsilon$, шум гауссовский и гомоскедастичен: ε_i независимы, $\varepsilon_i \sim \mathcal{N}(0, \sigma^2)$; априорное распределение весов гауссовское: $w \sim \mathcal{N}(0, \nu^2 I)$. Тогда MAP-оценка (англ. *maximum a posteriori* — максимум апостериорной плотности, вопрос 03 (принятие решения: байесовский и минимаксный подходы))*

$$\widehat{w}^{\mathrm{MAP}} = \arg\max_w \big[\log p(y \mid X, w) + \log p(w)\big] \tag{25}$$

совпадает с регуляризованным решением Тихонова (12) *при* $q^0 = 0$ *с параметром*

$$\alpha = \frac{\sigma^2}{\nu^2}. \tag{26}$$

Доказательство. Логарифм правдоподобия: независимость ε_i даёт $p(y \mid X, w) = \prod_{i=1}^{m} \frac{1}{\sqrt{2\pi}\sigma} \exp(-(y_i - x_i^{\mathsf{T}} w)^2/(2\sigma^2)) = (2\pi\sigma^2)^{-m/2} \exp(-\|y - Xw\|^2/(2\sigma^2))$. Априорная плотность: $p(w) = \frac{1}{(2\pi\nu^2)^{n/2}} \exp\left(-\frac{\|w\|^2}{2\nu^2}\right)$. Подставляя в (25) и отбрасывая постоянные члены, получаем $\widehat{w}^{\text{MAP}} = \arg\min_w \left[\|y - Xw\|^2 + \frac{\sigma^2}{\nu^2}\|w\|^2\right]$. Это функционал Тихонова (10) с $A = X$, $q^0 = 0$ и $\alpha = \sigma^2/\nu^2$, и по теореме 3.6 минимум достигается на единственном элементе, явный вид которого дан формулой (12) [16] (Хасти, Тибширани, Фридман), [51] (Гудфеллоу, Бенджио, Курвилль). □

Следствие 4.3 (L_1 и лапласовский априор)**.** *Если априорное распределение произведение лапласовских:* $p(w) \propto \exp(-\|w\|_1/C)$*, то MAP-оценка* (25) *совпадает с минимизатором*

$$\|y - Xw\|^2 + \frac{2\sigma^2}{C}\|w\|_1. \tag{27}$$

Доказательство. Как и в теореме 4.2, $\log p(y \mid X, w) = -\|y - Xw\|^2/(2\sigma^2) + \text{const}$, а $\log p(w) = -\|w\|_1/C + \text{const}$. Сумма, домноженная на $2\sigma^2$, даёт (27). □

Замечание 4.4. Связка «регуляризатор = логарифм априорного» объясняет и происхождение теоремы 4.2, и её границы: подходящий априор реализует и L_1 (следствие 4.3), и любой штраф вида $-\log p(w)$, но не всякий регуляризатор имеет байесовскую интерпретацию [51] (Гудфеллоу, Бенджио, Курвилль). Формула (26) связывает α с отношением сигнал/шум: большой шум ($\sigma \gg \nu$) требует сильной регуляризации — α — не произвольная константа, а отношение неопределённости данных к априорной уверенности.

Теперь сшивка имён. Конструкция (10) с $q^0 = 0$ в трёх традициях носит три имени: **регуляризация Тихонова** (обратные задачи), **гребневая регрессия** (*ridge regression*) (статистика), **L_2-регуляризация**, или **снижение весов** (*weight decay* — [63], [64]), (машинное обучение). Отождествление проговорено прямо у [51] (Гудфеллоу, Бенджио, Курвилль): «регуляризацию по норме L_2 называют также гребневой регрессией, или регуляризацией Тихонова».

4.3. Гребневая регрессия

Задача гребневой регрессии:

$$\widehat{w} = \arg\min_w \left\{\|y - Xw\|^2 + \alpha\|w\|^2\right\}; \tag{28}$$

эквивалентная ограниченная форма — минимизация $\|y - Xw\|^2$ при условии $\|w\|^2 \le t$ (та же «ограничение ↔ штраф», что и в (22)).

Предложение 4.5 (явное решение)**.** *Минимизатор задачи* (28) *существует, единствен и равен*

$$\widehat{w} = (X^{\mathsf{T}}X + \alpha I)^{-1}X^{\mathsf{T}}y. \tag{29}$$

Доказательство. Это частный случай теоремы 3.6 (Кабанихин) ($Q = \mathbb{R}^n$, $F = \mathbb{R}^m$) и предложения 3.8: нормальное уравнение $(X^{\mathsf{T}}X + \alpha I)w = X^{\mathsf{T}}y$ разрешимо однозначно, поскольку $X^{\mathsf{T}}X + \alpha I \succeq \alpha I \succ 0$. □

Главное, что покупает гребень, видно в сингулярном базисе (запись $X = UDV^{\mathsf{T}}$ с $D = \operatorname{diag}(d_1, \dots, d_r)$, $d_1 \geq \dots \geq d_r > 0$ — та же, что в вопросе 16 (PCA и ICA)).

Предложение 4.6 (спектральный анализ гребня)**.** *Пусть $X = UDV^{\mathsf{T}}$. Тогда*

$$X\widehat{w} = \sum_{j=1}^{r} \frac{d_j^2}{d_j^2 + \alpha} \, (u_j^{\mathsf{T}} y) \, u_j. \tag{30}$$

В частности, гребень оставляет направления u_j и коэффициенты $u_j^{\mathsf{T}} y$ нетронутыми, но сжимает каждый на множитель $d_j^2/(d_j^2+\alpha) \in (0,1)$; сжатие сильнее всего там, где $d_j^2 \lesssim \alpha$, то есть вдоль малых сингулярных направлений [16] (Хасти, Тибширани, Фридман).

Доказательство. Подставим (29) в $X\widehat{w}$: $X\widehat{w} = UDV^{\mathsf{T}}(VD^2V^{\mathsf{T}} + \alpha I)^{-1} VDU^{\mathsf{T}} y$. Так как $VD^2V^{\mathsf{T}} + \alpha I = V(D^2 + \alpha I)V^{\mathsf{T}}$ (приписывание αI в любом ортонормированном базисе), обратная матрица равна $V(D^2 + \alpha I)^{-1}V^{\mathsf{T}}$, и $V^{\mathsf{T}}V = I$ сокращает всё выражение до

$$X\widehat{w} = UD(D^2 + \alpha I)^{-1} DU^{\mathsf{T}} y = \sum_{j=1}^{r} \frac{d_j^2}{d_j^2 + \alpha} (u_j^{\mathsf{T}} y) \, u_j,$$

поскольку $D(D^2 + \alpha I)^{-1} D = \operatorname{diag}(d_j^2/(d_j^2 + \alpha))$. Монотонность и границы множителя очевидны: $d_j^2/(d_j^2 + \alpha) \to 1$ при $d_j^2 \gg \alpha$ и $\to 0$ при $d_j^2 \ll \alpha$. □

Замечание 4.7. Фильтр $d_j^2/(d_j^2 + \alpha)$ — ровно $\lambda_j/(\lambda_j + \alpha)$ с $\lambda_j = d_j^2$: тот, что был в квазирешении Иванова (22) и в следствии 3.12. Третье появление одной конструкции в трёх традициях. Механизм устойчивости виден из леммы 3.11: вклад шума вдоль v_j умножается на $d_j/(d_j^2 + \alpha) \leq 1/(2\sqrt{\alpha})$ — усиление шума ограничено $O(1/\sqrt{\alpha})$ вместо $O(1/d_r)$ у МНК. Цена — смещение: вклад точного решения вдоль v_j умножается на $d_j^2/(d_j^2 + \alpha) < 1$.

Определение 4.8. Для линейной оценки $\widehat{y} = Sy$ с $S = X(X^{\mathsf{T}}X + \alpha I)^{-1}X^{\mathsf{T}}$ **эффективным числом степеней свободы** называется

$$\operatorname{df}(\alpha) = \operatorname{tr} S = \sum_{j=1}^{r} \frac{d_j^2}{d_j^2 + \alpha} \tag{31}$$

Равенство следует из доказательства предложения 4.6: $S = UD(D^2 + \alpha I)^{-1}DU^{\mathsf{T}}$, и след ортогонально подобной матрицы равен следу диагональной части. При $\alpha \to 0$ оно равно r, при $\alpha \to \infty$ стремится к нулю: регуляризация «экономит» степени свободы пропорционально сжатию собственных направлений.

4.4. Смещение, дисперсия и выбор параметра

Точность регуляризованной оценки раскладывается на три независимых источника; теорема — для общей линейной оценки $\widehat{y} = Sy$, гребень — её частный случай.

Теорема 4.9 (разложение смещение–дисперсия)**.** *Пусть $y = f + \varepsilon$ с $f = (f(x_1), \dots, f(x_m))^{\mathsf{T}}$, $\mathsf{E}\varepsilon = 0$, $\mathsf{E}\varepsilon\varepsilon^{\mathsf{T}} = \sigma^2 I$, и оценка $\widehat{f}(x_0) = h(x_0)^{\mathsf{T}} y$ линейна по y. Тогда для прогноза в точке x_0, где $y_0 = f(x_0) + \varepsilon_0$ с ε_0 независим от ε и $\mathsf{E}\varepsilon_0^2 = \sigma^2$,*

$$\mathsf{E}\big[(y_0 - \widehat{f}(x_0))^2\big] = \sigma^2 + \operatorname{Bias}^2\big(\widehat{f}(x_0)\big) + \mathsf{D}\big(\widehat{f}(x_0)\big), \tag{32}$$

где $\operatorname{Bias}(\hat f(x_0)) = \mathsf{E}\hat f(x_0) - f(x_0)$*; слагаемое* σ^2 *не зависит от модели (неустранимая ошибка). Для* $\hat f(x_0) = h(x_0)^{\mathsf{T}} y$

$$\mathsf{D}(\hat f(x_0)) = \|h(x_0)\|^2 \sigma^2. \tag{33}$$

Доказательство. Впишем и вычтем среднее: $y_0 - \hat f = (f(x_0) - \mathsf{E}\hat f) + \varepsilon_0 + (\mathsf{E}\hat f - \hat f)$. Возведём в квадрат и возьмём математическое ожидание. Первое слагаемое — константа: даёт Bias^2. Второе: $\mathsf{E}\varepsilon_0^2 = \sigma^2$. Третье: $\mathsf{E}(\mathsf{E}\hat f - \hat f)^2 = \mathsf{D}(\hat f)$ по определению дисперсии. Перекрёстные члены обращаются в нуль: $\mathsf{E}[(\mathsf{E}\hat f - \hat f)] = 0$; $\mathsf{E}[\varepsilon_0(\mathsf{E}\hat f - \hat f)] = \mathsf{E}\varepsilon_0 \cdot \mathsf{E}[\mathsf{E}\hat f - \hat f] = 0$ по независимости; $\mathsf{E}[\varepsilon_0(f(x_0) - \mathsf{E}\hat f)] = 0$ по той же причине; член $2\mathsf{E}[(f(x_0) - \mathsf{E}\hat f)(\mathsf{E}\hat f - \hat f)] = 2(f(x_0) - \mathsf{E}\hat f)\,\mathsf{E}[\mathsf{E}\hat f - \hat f] = 0$. Остаются три слагаемых (32).

Для линейной оценки $\mathsf{D}(\hat f(x_0)) = \mathsf{E}(h^{\mathsf{T}}\varepsilon)^2 = h^{\mathsf{T}}\mathsf{E}(\varepsilon\varepsilon^{\mathsf{T}})h = \sigma^2\|h(x_0)\|^2$ — это (33). □

Следствие 4.10 (гребень: смещение растёт, дисперсия падает)**.** *Для гребневой оценки в точке* x_0 *дисперсия равна*

$$\mathsf{D}(\hat f_\alpha(x_0)) = \left\|X(X^{\mathsf{T}}X + \alpha I)^{-1}x_0\right\|^2 \sigma^2. \tag{34}$$

При росте α *она монотонно не возрастает, а квадрат смещения не убывает; сумма — U-образная кривая [16] (Хасти, Тибширани, Фридман).*

Доказательство. Гребневая оценка линейна: $\hat f_\alpha(x_0) = x_0^{\mathsf{T}}\widehat{w} = h(x_0)^{\mathsf{T}} y$ с $h(x_0) = X(X^{\mathsf{T}}X + \alpha I)^{-1}x_0$; подстановка в (33) даёт (34). В собственном базисе $X^{\mathsf{T}}X = VD^2V^{\mathsf{T}}$ получаем $\mathsf{D} = \sigma^2 \sum_j \frac{d_j^2}{(d_j^2+\alpha)^2}(x_0^{\mathsf{T}}v_j)^2$, и каждое слагаемое — невозрастающая функция α. Смещение: $\mathsf{E}\hat f_\alpha(x_0) = x_0^{\mathsf{T}}(X^{\mathsf{T}}X + \alpha I)^{-1}X^{\mathsf{T}}X\,w^*$ (w^* — истинный вектор весов), отклонение от $x_0^{\mathsf{T}}w^*$ равно $-\alpha\, x_0^{\mathsf{T}}(X^{\mathsf{T}}X + \alpha I)^{-1}w^*$, норма которого не убывает по α. □

U-образная сумма $\sigma^2 + \text{смещение}^2 + \text{дисперсия}$ — кривая ошибки обобщения по сложности: слева недообучение (большое смещение), справа — вторая ветвь, где слишком сильная регуляризация тоже портит ошибку. Регуляризация покупает устойчивость ценой смещения, и теорема 4.9 показывает, что сделка выгодна ровно до дна U-образной кривой. В терминах раздела 3: смещение — уклонение $\gamma(q_T, \alpha)$, дисперсия — член $\|R_\alpha\|\,\delta$; балансировка следствия 3.12 и есть минимизация этой суммы. Численная картина — в `examples.ipynb`, пример 2.

Выбор параметра: невязка против перекрёстной проверки. Принцип невязки (теорема 3.15) требует знания δ — в обучении его нет: неизвестен ни шум прибора, ни сдвиг модели. Стандарт заменяет его перекрёстной проверкой (англ. *cross-validation* — [16]): выборка делится на K частей, модель обучается на $K-1$ частях и проверяется на оставшейся; средняя контрольная ошибка как функция α есть прямая оценка ошибки обобщения, и параметр выбирается в её минимуме [16] (Хасти, Тибширани, Фридман), [53] (Воронцов). Практическое правило — «одна стандартная ошибка»: выбирается наиболее экономная модель (самое большое α), чья контрольная ошибка не превосходит минимальную более чем на одну стандартную ошибку оценки [16] (Хасти, Тибширани, Фридман).

Оба правила — оценивание оптимума одной и той же U-образной кривой (32); разница в оценщике. Принцип невязки пользуется уровнем шума и потому работает в теории обратных задач; CV оценивает ошибку обобщения непосредственно и потому переносится на задачи, где «шум» — это несовпадение модели и реальности, а не погрешность прибора. Точки выбора α на сквозном примере почти совпадают — `examples.ipynb`, пример 2.

4.5. Лассо и эластичная сеть

Гребень не зануляет коэффициенты. Для отбора признаков служит L_1-штраф — лассо (англ. *lasso* — [16], least absolute shrinkage and selection operator — [53] (Воронцов)):

$$\widehat{w} = \arg\min_{w} \left\{ \tfrac{1}{2} \|y - Xw\|^2 + \alpha \|w\|_1 \right\}, \tag{35}$$

эквивалентно — минимизация $\|y - Xw\|^2$ при $\sum_j |w_j| \le t$ [16] (Хасти, Тибширани, Фридман). Свойства: некоторые коэффициенты оценки ровно равны нулю, и (35) одновременно обучает модель и отбирает признаки [16] (Хасти, Тибширани, Фридман). Геометрическая причина — форма ограничительного множества: у (35) это многогранник, и линии уровня невязки касаются его на гранях и вершинах (координатные плоскости); у гребня — шар, касание почти всегда внутри грани, и нули не возникают. Вероятностный смысл — лапласовский априор (следствие 4.3); у [53] (Воронцов) тот же вывод через замену $w_j = u_j - v_j$, $u_j, v_j \ge 0$. Смещение у лассо больше, чем у гребня на сигнальных направлениях, зато получаем разрежённость и интерпретируемость.

Эластичная сеть объединяет оба штрафа:

$$\arg\min_{w} \left\{ \|y - Xw\|^2 + \lambda \sum_j \left(\eta\, w_j^2 + (1-\eta)\, |w_j| \right) \right\} \tag{36}$$

[16] (Хасти, Тибширани, Фридман): L_1 отбирает признаки, L_2 стабилизирует группы коррелированных признаков, которые у чистого лассо выбираются произвольно.

Где работает конструкция.

Постановка	Что минимизируется	Ответ	Что покупается
МНК без шума, $m \ge n$, полный ранг	$\|Xw - y\|^2$	$\widehat{w} = X^+ y$ — псевдорешение (вопрос 09)	точность при отсутствии шума
МНК с шумом, $m \approx n$	$\|Xw - y\|^2$	неустойчив: $\|\delta w\| / \|w\| \le \varkappa(X)\, \|\delta y\| / \|y\|$	— (переобучение)
Гребневая регрессия	$\|Xw - y\|^2 + \alpha \|w\|^2$	$(X^\intercal X + \alpha I)^{-1} X^\intercal y$	устойчивость ценой смещения
Лассо	$\|Xw - y\|^2 + \alpha \|w\|_1$	разрежённое $\widehat{w}$	отбор признаков ценой смещения
Ранняя остановка	градиентные итерации по $Q(w)$	$w^{(\tau)}$ по контрольной ошибке	то же, что гребень, без выбора α (раздел 7)

Часть II. Расширенная часть

5. ИНС как обратная задача

Искусственная нейронная сеть (англ. *artificial neural network* — [51]) — модель $f(x;\theta)$, составленная из композиций простых функций (слоёв); обучение — та же обратная задача, что в разделе 4, с нелинейным оператором $A : \theta \mapsto (f(x_i;\theta))_{i=1}^m$.

Постановка обучения. Обучение — минимизация эмпирического риска по параметрам θ:

$$J(\theta) = \frac{1}{m}\sum_{i=1}^{m} L\big(f(x_i;\theta),\, y_i\big) \;\to\; \min_{\theta} \tag{37}$$

[51] (Гудфеллоу, Бенджио, Курвилль). Отличие от линейного случая — невыпуклость: из-за нелинейности сети большинство интересных функций потерь невыпуклы, гарантий типа теоремы 3.6 нет, инициализация берётся малыми случайными значениями, а критерий качества метода — эмпирический [51] (Гудфеллоу, Бенджио, Курвилль). В терминах раздела 2: нарушена даже корректность по единственности (много эквивалентных минимумов из-за симметрий), и надежда — на регуляризацию и раннюю остановку (раздел 7).

Универсальная аппроксимация.

Теорема 5.1 (универсальная теорема аппроксимации Цыбенко — Хорника)**.** *Сеть прямого распространения с линейным выходным слоем и хотя бы одним скрытым слоем с произвольной «сплющивающей» функцией активации может аппроксимировать любую борелевскую функцию, отображающую одно конечномерное пространство в другое, с любой заданной ненулевой точностью, если скрытых блоков достаточно [51] (Гудфеллоу, Бенджио, Курвилль).*

Две оговорки принципиальны [51] (Гудфеллоу, Бенджио, Курвилль). Во-первых, теорема не гарантирует, что обучение найдёт нужные параметры: оптимизация может не найти соответствующего минимума, а найдя — выбрать не ту функцию из-за переобучения; аппроксимируемость не означает обучаемости. Во-вторых, число скрытых блоков в худшем случае экспоненциально. Теорема отвечает о выразительной силе, но не о цене вычисления.

Обратное распространение и автоматическое дифференцирование. Градиент функционала (37) вычисляется обратным распространением (англ. *backpropagation* — [51]): применением правила цепочки к вычислительному графу программы [64] (Меркулов). Вычисление — граф вершин $v_1, \dots, v_N$ (промежуточные значения) с рёбрами — зависимостями $v_j = \varphi_j(v_i : i \in \mathrm{parents}(j))$; прямой проход вычисляет вершины в топологическом порядке. Обратный проход вычисляет сопряжённые переменные $\bar{v}_i = \partial z / \partial v_i$ (z — итоговый выход) по рекуррентному правилу [64] (Меркулов):

$$\bar{v}_i = \sum_{j \in \mathrm{children}(i)} \bar{v}_j \,\frac{\partial v_j}{\partial v_i}, \qquad \bar{v}_N = 1, \tag{38}$$

то есть для каждой операции якобиан перемножается с градиентом по её выходу; локальное правило для звена $x \to y \to z$ [51] (Гудфеллоу, Бенджио, Курвилль):

$$\nabla_x z = \left(\frac{\partial y}{\partial x}\right)^{\mathsf{T}} \nabla_y z. \tag{39}$$

Цена: для цепного графа число операций обратного прохода пропорционально числу рёбер, а градиент по всем входам стоит примерно столько же, сколько один прямой проход [51] (Гудфеллоу, Бенджио, Курвилль), [64] (Меркулов); автоматическое дифференцирование (англ. *automatic differentiation* — [37]) по программе функции строит программу градиента, работающую не более чем в константное число раз дольше исходной [37] (Гасников). Это принципиально другой способ, чем конечные разности (погрешность округления, цена n прямых проходов для n параметров) и символьное дифференцирование (комбинаторный взрыв выражений) [63] (Меркулов): обратный режим хранит промежуточные значения ценой памяти. История одной фразой: идея восходит к Келли (1960), окончательная форма — обратное аккумулирование Линнайнмаа (1976), введённое в обучение сетей Вербосом (1981) [51] (Гудфеллоу, Бенджио, Курвилль).

6. Методы обучения

Задачу (37) решают итерационными методами первого порядка — градиентными методами вопроса 10 (методы минимизации функций многих переменных), перенесёнными на оценку градиента по выборке.

Стохастический градиент и минибатчи. При большом m полный градиент (37) стоит m вычислений слагаемых; стохастический оракул (англ. *stochastic oracle* (?)) выдаёт вместо $\nabla f(x)$ его несмещённую оценку $\hat{g}$ с конечной дисперсией,

$$\mathsf{E}\,\hat{g} = \nabla f(x), \qquad \mathsf{E}\,\|\hat{g} - \nabla f(x)\|^2 \le D \tag{40}$$

[37] (Гасников). В обучении такой оценкой служит градиент по одному случайно выбранному примеру (или по минибатчу из r независимых): усреднение по r независимым оценкам уменьшает дисперсию в r раз [37] (Гасников):

$$\hat{g}_r = \frac{1}{r}\sum_{l=1}^{r} \hat{g}^{(l)}, \qquad \mathsf{E}\,\|\hat{g}_r - \nabla f\|^2 \le \frac{D}{r}. \tag{41}$$

Доказательство оценки дисперсии в (41). Независимость и несмещённость дают $\mathsf{E}\,\|\hat{g}_r - \nabla f\|^2 = \frac{1}{r^2}\sum_{l=1}^{r} \mathsf{E}\,\|\hat{g}^{(l)} - \nabla f\|^2 \le \frac{1}{r^2}\cdot rD = D/r$ (перекрёстные члены обращаются в нуль: $\mathsf{E}\,\langle \hat{g}^{(l)} - \nabla f, \hat{g}^{(k)} - \nabla f\rangle = \langle \mathsf{E}(\hat{g}^{(l)} - \nabla f), \mathsf{E}(\hat{g}^{(k)} - \nabla f)\rangle = 0$ при $l \ne k$). □

Размер минибатча — компромисс: r велико уменьшает дисперсию, но каждая итерация дороже; оценки ниже показывают, что итоговая стоимость $\sim D/r$ при прочих равных [37] (Гасников).

Теорема 6.1 (сходимость SGD с постоянным шагом)**.** *Пусть f дифференцируема и μ-сильно выпукла с минимумом в точке x^*, на каждом шаге используется несмещённая оценка $\hat{g}_k$ с $\mathsf{E}\,\|\hat{g}_k\|^2 \le B^2$ при любом x_k, шаг h постоянен и $h \le \frac{1}{2\mu}$. Тогда*

$$\mathsf{E}\,\|x_k - x^*\|^2 \le (1 - 2h\mu)^k\,\|x_0 - x^*\|^2 + \frac{hB^2}{2\mu}. \tag{42}$$

Доказательство. Обозначим $r_k = \|x_k - x^*\|^2$ и запишем шаг $x_{k+1} = x_k - h\hat{g}_k$ через x^*: $r_{k+1} = \|x_k - x^*\|^2 - 2h\,\langle \hat{g}_k, x_k - x^*\rangle + h^2\,\|\hat{g}_k\|^2$. Возьмём условное при данном x_k математическое ожидание. Несмещённость даёт $\mathsf{E}[\hat{g}_k \mid x_k] = \nabla f(x_k)$; сильная выпуклость даёт оценку скалярного произведения: применим определяющее неравенство сильной выпуклости в точках x и x^* и сложим: $f(x^*) \ge f(x) + \langle \nabla f(x), x^* - x\rangle + \frac{\mu}{2}r$, $f(x) \ge f(x^*) + \langle \nabla f(x^*), x - x^*\rangle + \frac{\mu}{2}r$ (второе неравенство — с $\nabla f(x^*) = 0$); сложив, получаем $\langle \nabla f(x), x - x^*\rangle \ge \mu r$. Поэтому $\mathsf{E}[r_{k+1} \mid x_k] \le r_k - 2h\mu r_k + h^2B^2 = (1-2h\mu)\,r_k + h^2B^2$. Полное математическое ожидание: $\mathsf{E}r_{k+1} \le (1-2h\mu)\,\mathsf{E}r_k + h^2B^2$. Раскручивая рекуррентность от 0 до k и суммируя геометрическую прогрессию, $\mathsf{E}r_k \le (1-2h\mu)^k r_0 + h^2B^2\sum_{j=0}^{k-1}(1-2h\mu)^j \le (1-2h\mu)^k r_0 + \frac{h^2B^2}{2h\mu}$, поскольку $1-2h\mu \in [0,1)$ и сумма прогрессии не превосходит $1/(2h\mu)$. Последнее слагаемое и есть $hB^2/(2\mu)$. □

Следствие 6.2 (стоимость $O(1/\varepsilon)$)**.** *При $h \sim \varepsilon$ точность $\mathsf{E}\,\|x_k - x^*\|^2 \le \varepsilon$ достигается за*

$$k = O\Big(\frac{B^2}{\mu^2}\,\frac{\ln(1/\varepsilon)}{\varepsilon}\Big) \tag{43}$$

итераций. Здесь ε — допуск по норме, а не шаг обучения.

Доказательство. Выбираем h из двух требований: $hB^2/(2\mu) \le \varepsilon/2$ (плато) и $(1-2h\mu)^k r_0 \le \varepsilon/2$ (затухание). Первое даёт $h \le \mu\varepsilon/B^2$; берём $h = \mu\varepsilon/B^2$ (это $\le 1/(2\mu)$, поскольку $\varepsilon \le B^2/(2\mu^2)$ — иначе и нулевой шаг подошёл). Второе с $\ln(1-t) \le -t$ даёт $k \ge \ln(2r_0/\varepsilon)/(2h\mu) = B^2\ln(2r_0/\varepsilon)/(2\mu^2\varepsilon)$. □

Замечание 6.3. Три замечания. (1) Плато $hB^2/(2\mu)$ — цена стохастики: метод не сходится к точному минимуму, а застывает в окрестности; убывающий шаг в конце убирает плато, и классические условия $\sum_k h_k = \infty$, $\sum_k h_k^2 < \infty$ дают сходимость [51] (Гудфеллоу, Бенджио, Курвилль). (2) Оценки по значению функции: $O(1/\sqrt{k})$ для выпуклой и $O(1/k)$ для сильно выпуклой задачи, обе неулучшаемы для класса с оракулом (40) [37] (Гасников), [51] (Гудфеллоу, Бенджио, Курвилль). (3) Посылка $\mathsf{E}\,\|\hat{g}\|^2 \le B^2$ существенна: при неограниченной дисперсии плато не контролируется; посылка гладкости f для самой теоремы 6.1 избыточна (нужна только сильная выпуклость), но она стоит за оценками по значению и за практическим выбором $h \le 1/L$.

Импульс. Импульсный метод (англ. *momentum* — [51], [63]) вычисляет экспоненциально затухающее скользящее среднее прошлых градиентов и движется по нему [51] (Гудфеллоу, Бенджио, Курвилль):

$$v^{k+1} = \beta v^k - \varepsilon\,\nabla J(\theta^k), \qquad \theta^{k+1} = \theta^k + v^{k+1}, \qquad \beta \in [0,1). \tag{44}$$

Раскрыв $v^{k+1} = \theta^{k+1} - \theta^k$ и подставив в первое равенство, получаем $\theta^{k+1} = \theta^k - \varepsilon\,\nabla J(\theta^k) + \beta\,(\theta^k - \theta^{k-1})$, — метод тяжёлого шарика Поляка (англ. *heavy ball* — [64]) из вопроса 10 (методы минимизации функций многих переменных) с шагом $\alpha = \varepsilon$ и коэффициентом инерции β. Это тождество, а не аналогия: импульс в обучении — буквально тот же двухшаговый процесс.

Теорема 6.4 (локальная сходимость импульса на квадратичной функции)**.** *Пусть J квадратична: $J(\theta) = \frac{1}{2}(\theta-\theta^*)^{\mathsf{T}} H(\theta-\theta^*) + \mathit{const}$, $\mu I \preceq H \preceq LI$, $\varkappa = L/\mu$, метод (44) стартует достаточно близко от θ^* (для квадратичной — откуда угодно). Тогда при*

$$\varepsilon^* = \frac{4}{(\sqrt{L}+\sqrt{\mu})^2}, \qquad \beta^* = \Big(\frac{\sqrt{L}-\sqrt{\mu}}{\sqrt{L}+\sqrt{\mu}}\Big)^2 \tag{45}$$

метод сходится со знаменателем

$$q = \frac{\sqrt{\varkappa}-1}{\sqrt{\varkappa}+1}, \qquad \big\|\theta^k - \theta^*\big\| \le c\,q^k, \tag{46}$$

а для любых других ε, β из области сходимости знаменатель не меньше [63] (Меркулов).

Доказательство. Сдвигом $\theta^* = 0$ добьёмся $J(\theta) = \frac{1}{2}\theta^{\mathsf{T}} H\theta$. Раскрытая форма (44): $\theta^{k+1} = (1+\beta)\theta^k - \beta\theta^{k-1} - \varepsilon H\theta^k$. Пусть $He_i = \lambda_i e_i$; проекции $s_i^k = \langle \theta^k, e_i\rangle$ удовлетворяют скалярным рекуррентностям

$$\begin{pmatrix} s_i^{k+1} \\ s_i^k \end{pmatrix} = M_i \begin{pmatrix} s_i^k \\ s_i^{k-1} \end{pmatrix}, \qquad M_i = \begin{pmatrix} 1+\beta-\varepsilon\lambda_i & -\beta \\ 1 & 0 \end{pmatrix}.$$

Характеристическое уравнение матрицы M_i:

$$\rho^2 - (1+\beta-\varepsilon\lambda_i)\,\rho + \beta = 0. \tag{47}$$

При комплексных корнях ($D = (1+\beta-\varepsilon\lambda_i)^2 - 4\beta < 0$) их произведение равно β, значит $|\rho| = \sqrt{\beta}$ для обоих. Скорость равна $\max_i \max|\rho(\lambda_i)|$; равномерная по $\lambda_i \in [\mu, L]$ оптимизация по ε, β приводит к равенству дискриминантов на концах отрезка: $(1+\beta-\varepsilon\mu)^2 = (1+\beta-\varepsilon L)^2 = 4\beta$, то есть

$$1+\beta-\varepsilon\mu = 2\sqrt{\beta}, \qquad 1+\beta-\varepsilon L = -2\sqrt{\beta}. \tag{48}$$

Вычитая и складывая равенства, получаем $\varepsilon(L-\mu)=4\sqrt{\beta}$ и $2(1+\beta)=\varepsilon(L+\mu)$; с $t=\sqrt{\beta}$ второе даёт $1+t^2=2t\,\frac{L+\mu}{L-\mu}$, и меньший корень $t=\frac{\sqrt{L}-\sqrt{\mu}}{\sqrt{L}+\sqrt{\mu}}$, откуда $\beta^*=t^2$ и $\varepsilon^*=4\sqrt{\beta}/(L-\mu)=4/(\sqrt{L}+\sqrt{\mu})^2$ — это (45). Для $\lambda\in[\mu,L]$ значение $S(\lambda)=1+\beta^*-\varepsilon^*\lambda$ линейно и $|S(\lambda)|\le 2\sqrt{\beta^*}$ (по построению на концах), значит дискриминант (47) неположителен и $|\rho|=\sqrt{\beta^*}=q$ — это (46).

Оптимальность пары (45). Для произвольных $\varepsilon>0$, $\beta\in(0,1)$ значение $S(\lambda)=1+\beta-\varepsilon\lambda$ по-прежнему линейно по λ, поэтому максимум $\max|\rho|$ на $[\mu,L]$ достигается на концах: в комплексной зоне ($D<0$) $|\rho|=\sqrt{\beta}$ не зависит от λ, а при $D\ge 0$ больший по модулю корень $(|S|+\sqrt{D})/2$ монотонно растёт в $|S|$, максимум которого на отрезке — на концах. Обозначим этот максимум через $r(\varepsilon,\beta)$ и предположим, что $r(\varepsilon,\beta)<q$. (1) Произведение корней равно β, значит $r(\varepsilon,\beta)\ge\sqrt{\beta}$, и с $t:=\sqrt{\beta}$ имеем $t<q$. (2) Если оба корня трёхчлена $\rho^2-S\rho+\beta$ лежат в $(-q,q)$, то $|S|<q+\beta/q$: для вещественных корней сумма $\rho_1+\rho_2$ при $\rho_1\rho_2=\beta$ по модулю меньше $q+\beta/q$ (граница отвечает корням q и β/q), а для комплексных $|S|\le 2\sqrt{\beta}<q+\beta/q$ при $t<q$. По предположению оба корня лежат в $(-q,q)$ на обоих концах спектра, поэтому

$$|S(\mu)|<q+\frac{t^2}{q},\qquad |S(L)|<q+\frac{t^2}{q}.$$

Отсюда

$$\varepsilon\mu=1+t^2-S(\mu)>(1-q)\,\frac{q-t^2}{q},\qquad \varepsilon L=1+t^2-S(L)<(1+q)\,\frac{q+t^2}{q},$$

и деление второго неравенства на первое даёт

$$\varkappa=\frac{L}{\mu}<\frac{(1+q)(q+t^2)}{(1-q)(q-t^2)}.$$

Правая часть монотонно растёт по t^2 и равна $\varkappa$ ровно при $t^2=q^2$ (подстановка $q=(\sqrt{\varkappa}-1)/(\sqrt{\varkappa}+1)$), поэтому неравенство выполнимо лишь при $t>q$ — противоречие с (1). Следовательно, $r(\varepsilon,\beta)\ge q$ при всех ε,β, а равенство возможно лишь при $t=q$, $S(\mu)=2q$, $S(L)=-2q$, то есть только в точке (45). Оценка $\|\theta^k-\theta^*\|\le cq^k$ следует из распада на скалярные рекуррентности. □

Замечание 6.5. Сравнение с вопросом 10 (методы минимизации функций многих переменных): градиентный спуск на такой задаче сходится со знаменателем $(\varkappa-1)/(\varkappa+1)$, импульс — с $(\sqrt{\varkappa}-1)/(\sqrt{\varkappa}+1)$: выигрыш — корень из числа обусловленности; та же асимптотика у чебышёвских полуитераций, сопряжённых градиентов и метода Нестерова. Оговорки: теорема 6.4 детерминированная и для квадратичной задачи глобальна; оценок сходимости стохастического импульса в общей постановке нет, и на практике $\beta=0{,}9$ берётся эмпирически [51] (Гудфеллоу, Бенджио, Курвилль). Область сходимости по шагу шире, чем у градиентного спуска: $0<\varepsilon\lambda<2+2\beta$ против $0<\varepsilon\lambda<2$ [64] (Меркулов).

Нестеров. Метод Нестерова отличается от (44) тем, что градиент берётся не в текущей точке θ^k, а в экстраполированной $\tilde\theta^k=\theta^k+\beta v^k$:

$$v^{k+1}=\beta v^k-\varepsilon\,\nabla J(\theta^k+\beta v^k),\qquad \theta^{k+1}=\theta^k+v^{k+1}. \tag{49}$$

Это та же схема ускорения, что и в вопросе 10: для пакетной выпуклой оптимизации ошибка $O(1/k)$ градиентного спуска улучшается до $O(1/k^2)$; для стохастического спуска ускорение по оценкам не получается [51] (Гудфеллоу, Бенджио, Курвилль) — ценность Нестерова в обучении преимущественно эмпирическая.

Adam. Адаптивный метод оценивает первый и второй моменты градиента экспоненциаль-

ным сглаживанием и нормирует шаг по второму моменту:

$$s_k = \rho_1 s_{k-1} + (1-\rho_1)\, g_k, \quad r_k = \rho_2 r_{k-1} + (1-\rho_2)\, g_k \odot g_k,$$
$$\hat{s}_k = \frac{s_k}{1-\rho_1^k}, \qquad \hat{r}_k = \frac{r_k}{1-\rho_2^k}, \qquad \theta_{k+1} = \theta_k - \varepsilon\, \frac{\hat{s}_k}{\sqrt{\hat{r}_k} + \delta_0}, \tag{50}$$

где g_k — стохастический градиент, $\odot$ и деление — покомпонентные, а дробь в обновлении — покомпонентная [51] (Гудфеллоу, Бенджио, Курвилль), [63] (Меркулов), [64] (Меркулов). Деление на $1-\rho_i^k$ — исправление смещения (англ. *bias correction* — [64]): при инициализации $s_0 = r_0 = 0$ моменты занижены, и без поправки шаги первых итераций слишком малы [64] (Меркулов). Умолчания: $\varepsilon = 0{,}001$, $\rho_1 = 0{,}9$, $\rho_2 = 0{,}999$, $\delta_0 = 10^{-8}$ [51] (Гудфеллоу, Бенджио, Курвилль). Здесь и выше ε — шаг обучения (в сквозном примере той же буквой обозначен шум измерения; области действия не пересекаются).

Замечание 6.6. Adam относится к адаптивным методам (AdaGrad и RMSProp предшествуют): каждый параметр получает эффективный шаг, обратный корню из среднего квадрата его градиента — удобно при разнородных кривизнах, но теоретический статус слабее, чем у SGD: известны примеры, где Adam не сходится (Reddi et al., 2019), и практика ответила модификациями (AdamW, декаплинг снижения весов).

7. Регуляризация в глубоком обучении

Начнём с канонического определения — оно объясняет всё остальное.

Определение 7.1 (Гудфеллоу, Бенджио, Курвилль, регуляризация)**.** «Регуляризация — это любая модификация алгоритма обучения, предпринятая с целью уменьшить его ошибку обобщения, не уменьшая ошибку обучения» [51] (Гудфеллоу, Бенджио, Курвилль).

Формулировка шире тихоновского функционала: тихоновский штраф — частный случай, и в глубоком обучении работают и штрафы, и неявные приёмы. Смысл тот же, что в разделе 4: «смысл регуляризации оценки — в увеличении смещения в обмен на уменьшение дисперсии» [51] (Гудфеллоу, Бенджио, Курвилль), и «наилучшая эмпирическая модель — это большая модель, подходящим образом регуляризированная» [51] (Гудфеллоу, Бенджио, Курвилль): ёмкость нужна для малого смещения, регуляризация — для контролируемой дисперсии.

Снижение весов. Штрафная форма — функционал

$$\widetilde{J}(\theta; X, y) = J(\theta; X, y) + \frac{\alpha}{2}\, \|w\|^2, \tag{51}$$

где w — все веса (не смещения) [51] (Гудфеллоу, Бенджио, Курвилль). Градиент $\nabla_w \widetilde{J} = \alpha w + \nabla_w J$ даёт шаг градиентного спуска с шагом ε:

$$w \leftarrow w - \varepsilon(\alpha w + \nabla_w J) = (1 - \varepsilon\alpha)\, w - \varepsilon\, \nabla_w J. \tag{52}$$

Каждая итерация сначала умножает веса на $(1-\varepsilon\alpha) < 1$ — отсюда имя снижение весов [51] (Гудфеллоу, Бенджио, Курвилль). Это ровно гребневая регрессия (теорема 4.2), и вывод (52) — эквивалентность штрафа и множителя для полного градиентного шага; для стохастического шага эквивалентность приближённая, и в современных библиотеках снижение весов реализуют отдельной операцией (AdamW).

Замечание 7.2. Смещения в (51) не регуляризуются [51] (Гудфеллоу, Бенджио, Курвилль) — практика, у которой есть содержательная причина: смещение — параметр положения отклика, а не его чувствительности к входу. Штраф на смещение тянуло бы отклик модели к нулю при сдвиге входов и порождало бы систематическое недообучение; в байесовской интерпретации это отвечает априору только на веса (теорема 4.2).

Ранняя остановка. Самая распространённая форма регуляризации в машинном обучении [51] (Гудфеллоу, Бенджио, Курвилль): обучение ведётся по обучающей части и останавливается, когда ошибка на отложенной контрольной части перестаёт убывать.

Теорема 7.3 (эквивалентность ранней остановки и L_2-регуляризации)**.** *Пусть $J(w) = \frac{1}{2}(w-w^*)^{\mathsf{T}}H(w-w^*) + \text{const}$ — квадратичная функция с $H = Q\Lambda Q^{\mathsf{T}} \succeq 0$, градиентный спуск с шагом ε (таким, что $\varepsilon\lambda_i < 1$) стартует из $w^{(0)} = 0$. Тогда:*

1) после τ итераций

$$Q^{\mathsf{T}}w^{(\tau)} = \bigl[I - (I-\varepsilon\Lambda)^{\tau}\bigr]Q^{\mathsf{T}}w^*; \tag{53}$$

2) минимум регуляризованного функционала $J(w) + \frac{\alpha}{2}\|w\|^2$ равен

$$Q^{\mathsf{T}}\widetilde{w} = (\Lambda + \alpha I)^{-1}\Lambda\, Q^{\mathsf{T}}w^*; \tag{54}$$

3) покомпонентные множители в (53) и (54) совпадают тогда и только тогда, когда

$$(I-\varepsilon\Lambda)^{\tau} = \alpha(\Lambda+\alpha I)^{-1}; \tag{55}$$

для малых собственных значений λ при $\varepsilon\lambda \ll 1$ условие (55) выполнено при

$$\alpha \approx \frac{1}{\varepsilon\tau}, \qquad \text{то есть} \qquad \tau \approx \frac{1}{\varepsilon\alpha}. \tag{56}$$

Доказательство. 1) Градиент: $\nabla J(w) = H(w-w^*)$; итерация $w^{(t)} = w^{(t-1)} - \varepsilon H(w^{(t-1)} - w^*)$ даёт $w^{(t)} - w^* = (I-\varepsilon H)^t(w^{(0)}-w^*)$. При $w^{(0)}=0$: $w^{(\tau)} = \bigl[I-(I-\varepsilon H)^{\tau}\bigr]w^*$; переход к собственному базису $H = Q\Lambda Q^{\mathsf{T}}$ (с $Q^{\mathsf{T}}Q = I$) даёт (53).

2) Минимизируем $J + \frac{\alpha}{2}\|w\|^2$: нормальное уравнение $(H+\alpha I)\widetilde{w} = Hw^*$ (предложение 3.8 при $q^0 = 0$), откуда $\widetilde{w} = (H+\alpha I)^{-1}Hw^*$; в собственном базисе — (54).

3) Множитель ранней остановки по направлению i: $1-(1-\varepsilon\lambda_i)^{\tau}$; множитель гребня: $\lambda_i/(\lambda_i+\alpha) = 1 - \alpha/(\lambda_i+\alpha)$. Равенство множителей — ровно (55). Докажем (56): для малых $\varepsilon\lambda_i$ разложение $(1-\varepsilon\lambda_i)^{\tau} = e^{\tau\ln(1-\varepsilon\lambda_i)} \approx e^{-\varepsilon\tau\lambda_i}$, а при $\lambda_i \ll \alpha$ правая часть (55): $\alpha/(\lambda_i+\alpha) = e^{\ln\alpha - \ln(\lambda_i+\alpha)} \approx e^{-\lambda_i/\alpha}$. Логарифмируя приближённое равенство $e^{-\varepsilon\tau\lambda_i} \approx e^{-\lambda_i/\alpha}$ и сокращая $\lambda_i \neq 0$, получаем $\varepsilon\tau \approx 1/\alpha$ — это (56); при $\lambda_i \to 0$ оба множителя стремятся к единице согласованно. □

Замечание 7.4. Три вывода. (1) Число итераций τ обратно пропорционально параметру регуляризации, а $\varepsilon\tau$ — мера эффективной ёмкости [51] (Гудфеллоу, Бенджио, Курвилль): ранняя остановка — тот же гребень, параметризованный временем обучения. (2) Теорема — пример **итерационной регуляризации Тихонова**: метод Ландвебера — градиентный спуск по невязке $J(q) = \|Aq-f\|^2$ — сам по себе регуляризующий алгоритм при остановке по невязке или контролю; число итераций играет роль α [14] (Кабанихин). Это замыкает круг: явная регуляризация и ранняя остановка — две параметризации одной кривой решений. (3) Преимущество ранней остановки — автоматический подбор эффективного α вместо сетки по α [51] (Гудфеллоу, Бенджио, Курвилль).

Прореживание (dropout). На каждом шаге обучения каждый скрытый блок выключается независимо с вероятностью $1-p$ (входные — с меньшей, скрытые обычно с $p = 0{,}5$) [51] (Гудфеллоу, Бенджио, Курвилль): модель обучается на случайном подграфе сети; на применении блоки не выключаются, а выходы масштабируются на p. Для линейной регрессии механизм точный.

Предложение 7.5 (dropout и адаптивный L_2 для линейной регрессии)**.** *Применение прореживания к линейной регрессии эквивалентно снижению весов по норме L_2, где для каждого входного признака задаётся свой коэффициент снижения (Wager et al., 2013*

— [51] (Гудфеллоу, Бенджио, Курвилль)). Именно: если $\mu_j \in \{0,1\}$ — независимые индикаторы включения признака с $\mathsf{P}\{\mu_j = 1\} = p$, то обучение по ожидаемой потере $\mathsf{E}_\mu \|y - X(w \odot \mu)\|^2 = \|y - p\,Xw\|^2 + p(1-p)\sum_j \|X_{\cdot j}\|^2 w_j^2$ есть гребневая регрессия с признакозависимым штрафом; для глубоких моделей такой эквивалентности нет [51] (Гудфеллоу, Бенджио, Курвилль).

Доказательство. Равенство для ожидаемой потери: $\mathsf{E}_\mu[(w \odot \mu)^\mathsf{T} X^\mathsf{T} X (w \odot \mu)] = \sum_{j,k} w_j w_k (\mathsf{E}\mu_j\mu_k) X_{\cdot j}^\mathsf{T} X_{\cdot k}$; при $j \neq k$ независимость даёт $\mathsf{E}\mu_j\mu_k = p^2$, при $j = k$: $\mathsf{E}\mu_j^2 = p$. Поэтому $\mathsf{E}_\mu \|y - X(w \odot \mu)\|^2 = \|y\|^2 - 2p\, y^\mathsf{T} Xw + p^2 \|Xw\|^2 + p(1-p)\sum_j \|X_{\cdot j}\|^2 w_j^2$, что после выделения полного квадрата $\|y - pXw\|^2$ даёт формулу. Замена $w' = pw$ показывает, что минимизация по w эквивалентна гребню с признакозависимым коэффициентом штрафа, пропорциональным $\|X_{\cdot j}\|^2$. □

Бэггинг. Обучаются k моделей на бутстрэп-подвыборках или подмножествах признаков, и их ответы усредняются. Если ошибки моделей ε_i имеют $\mathsf{E}\varepsilon_i^2 = v$ и $\mathsf{E}\varepsilon_i\varepsilon_j = c$ при $i \neq j$, то ошибка среднего

$$\mathsf{E}\Big[\Big(\frac{1}{k}\sum_i \varepsilon_i\Big)^2\Big] = \frac{v}{k} + \Big(1 - \frac{1}{k}\Big)c \tag{57}$$

[51] (Гудфеллоу, Бенджио, Курвилль).

Доказательство (57). Раскрываем квадрат суммы: $\mathsf{E}(\sum_i \varepsilon_i)^2 = \sum_i \mathsf{E}\varepsilon_i^2 + \sum_{i \neq j} \mathsf{E}\varepsilon_i\varepsilon_j = kv + k(k-1)c$; деление на k^2 даёт $v/k + (1 - 1/k)c$. □

Итак, усреднение убивает дисперсионную часть (v/k), но оставляет общую коррелированную составляющую c: выигрыш тем больше, чем независимее модели. Регуляризующая роль — в усреднении нерегулярной части ответа.

Аугментация и шум к входу. Аугментация порождает новые примеры преобразованиями, не меняющими ответа (повороты, сдвиги изображений): эмпирический риск минимизируется по расширенной выборке. Добавление шума ко входу в линейной модели эквивалентно штрафу по норме весов: $\mathsf{E}_\eta \big\|y - w^\mathsf{T}(x + \eta)\big\|^2 = \big\|y - w^\mathsf{T} x\big\|^2 + \mathsf{E}(\eta^\mathsf{T} w)^2$, и последнее слагаемое при белом шуме равно $\text{const} \cdot \|w\|^2$ — гребень из неопределённости входа [51] (Гудфеллоу, Бенджио, Курвилль). Шум к весам — стохастическая реализация байесовского вывода (теорема 4.2) [51] (Гудфеллоу, Бенджио, Курвилль).

Пакетная нормировка. Пакетная нормировка (англ. *batch normalization* — [64]) — метод адаптивной перепараметризации: преактивации слоя стандартизуются по среднему и дисперсии мини-пакета, а затем масштабируются собственными обучаемыми параметрами. Основная цель — улучшить оптимизацию (снять проблему согласования одновременных обновлений многих слоёв), но вносимый статистиками мини-пакета аддитивный и мультипликативный шум может давать регуляризирующий эффект, так что прореживание при пакетной нормировке иногда оказывается излишним [51] (Гудфеллоу, Бенджио, Курвилль). Поэтому в итоговой таблице метод стоит с оговоркой: регуляризатор здесь — побочный эффект, а не замысел.

Итоговая таблица: регуляризация в глубоком обучении.

Метод	Механизм	Что покупается
Снижение весов	штраф $\frac{\alpha}{2}\|w\|^2$; шаг $(1-\varepsilon\alpha)w - \varepsilon\nabla J$	сжатие малых сингулярных направлений; устойчивость к шуму
Ранняя остановка	мониторинг контрольной ошибки; $\tau \approx 1/(\varepsilon\alpha)$	тот же эффект, что у гребня, без подбора α

Метод	Механизм	Что покупается
Прореживание	случайное выключение блоков	адаптивный L_2 (линейный случай); робастность к соседству решений
Бэггинг	усреднение k моделей	дисперсия v/k при сохранении общей части c
Аугментация, шум к входу	расширение выборки, неопределённость входа	инвариантности; штраф $\|w\|^2$ в линейном случае
Пакетная нормировка	перепараметризация: стандартизация преактиваций по мини-пакету, шум статистик	главным образом оптимизация; регуляризующий побочный эффект [51]
Инвариантности архитектуры (пулинг)	ограничение вида решения: инвариантность к малым сдвигам (переносам) признаков	то, что покупает аугментация, заданное архитектурой [51]

8. Разобранные задачи

Четыре задачи разбирают вычислительную сторону вопроса на сквозном примере; все числа считаются в `examples.ipynb`.

Задача 8.1 (псевдорешение и критерий Пикара)**.** Почему систему $Xw = y$ сквозного примера нельзя решать «в лоб» через псевдообратную матрицу? Сформулировать критерий разрешимости [14] (Кабанихин).

Решение. Пусть $X = UDV^{\mathsf{T}}$, $d_1 \geq \ldots \geq d_r > 0$ — сингулярное разложение. МНК-решение минимальной нормы (псевдорешение): $\widehat{w} = X^{+}y = \sum_{j=1}^{r} \frac{u_j^{\mathsf{T}} y}{d_j}\, v_j$. Коэффициент при v_j получается делением проекции y на u_j на малое число d_j: вклад шума в этом направлении умножается на $1/d_j$ — это и есть неустойчивость. Критерий Пикара [14] (Кабанихин) отвечает на вопрос о разрешимости для компактного оператора A с сингулярной системой $\{u_j, v_j; d_j\}$: уравнение $Aq = f$ разрешимо тогда и только тогда, когда $f \perp \ker A^{*}$ и сходится ряд $\sum_j (f, u_j)^2 / d_j^2$; при выполнении условий нормальное решение равно $\sum_j (f, u_j)/d_j\, v_j$ (для инъективного A с плотным образом $\ker A^{*} = \{0\}$ и остаётся одна сходимость ряда). Для конечной матрицы ряд состоит из конечного числа слагаемых и потому всегда конечен: псевдорешение существует при любом y, и проблема не в существовании, а в величине. Шум имеет ненулевые проекции на все u_j, и вклад каждой в квадрат нормы псевдорешения имеет среднее $\sigma^2 \sum_j d_j^{-2}$; наименьшее сингулярное число входит с множителем $1/d_r$ ($\|X^{+}\|_2 = 1/d_r \approx 48{,}2$ на данных примера 2). Там же: ряд по чистым данным равен 2,02 (это $\|w^{*}\|^2$), по зашумлённым — 47,2 (это $\|\widehat{w}_{\text{МНК}}\|^2$), то есть псевдорешение раздуто шумом примерно в 23 раза. Выход — обрезать ряд фильтром $d_j^2/(d_j^2 + \alpha)$: вклад направления v_j становится $\frac{d_j}{d_j^2+\alpha}(u_j^{\mathsf{T}} y)\, v_j$, и сжатие малых d_j гасит раздутие (задача 8.2).

Задача 8.2 (гребневая регрессия сквозного примера)**.** Провести явный счёт гребневой оценки для данных (3): матрица X, оценка $\widehat{w}(\alpha)$, фильтры, выбор α невязкой и перекрёстной проверкой.

Решение. Схема счёта (числа — в `examples.ipynb`, пример 2): (1) $X_{ik} = T_{k_1}(x_{i,1}) \cdots T_{k_5}(x_{i,5})$, $i = 1, \ldots, m$, мультииндекс $k = (k_1, \ldots, k_5)$ пробегает $k_1 + \cdots + k_5 \leq 6$ ($n = 462$); точки x_i независимы и равномерны в $[-1, 1]^5$; $y_i = u(x_i) + \varepsilon_i$ при $m = 500$, $\sigma = 0{,}05$. (2) Сингулярное разложение $X = UDV^{\mathsf{T}}$: сингулярные числа убывают быстро — высокочастотные

тензорные произведения почти линейно зависимы на 500 точках (одномерный прототип механизма для степенных функций — матрица Грама мономов, близкая к матрице Гильберта, вопрос 09). (3) Оценка по предложению 4.6: $\widehat{w}(\alpha) = \sum_j \frac{d_j}{d_j^2+\alpha}(u_j^\intercal y)\, v_j$; сжатые направления — последние v_j. (4) Невязка $\rho(\alpha) = \|X\widehat{w}(\alpha) - y\|^2$ по лемме 3.14 монотонно возрастает от $\operatorname{dist}^2(y, R(X))$ до $\|y\|^2$; с ростом α решение сначала устойчиво, затем смещение растёт и узкий пик размывается. (5) Выбор α: (а) принцип невязки — корень $\rho(\alpha) = \delta^2$ с $\delta^2 = m\sigma^2$; (б) K-кратная перекрёстная проверка с правилом одной стандартной ошибки. Обе точки лежат в дне U-образной кривой (32) и близки между собой (замер в `examples.ipynb`).

Задача 8.3 (ранняя остановка против гребня)**.** Сравнить фильтры ранней остановки и гребня на квадратичной задаче $J(w) = \frac{1}{2}\|Xw - y\|^2$.

Решение. По теореме 7.3 с $H = X^\intercal X$, $\Lambda = D^2$: гребень даёт фильтр $d_j^2/(d_j^2+\alpha)$, ранняя остановка после τ итераций с шагом ε — фильтр $1-(1-\varepsilon d_j^2)^\tau$; условие совпадения (55): $(1-\varepsilon d_j^2)^\tau = \alpha/(d_j^2+\alpha)$. Для малых d_j^2 (именно они отвечают за неустойчивость) при $\varepsilon d_j^2 \ll 1$: $1-(1-\varepsilon d_j^2)^\tau \approx 1 - e^{-\varepsilon\tau d_j^2}$, а гребень $d_j^2/(d_j^2+\alpha) \approx 1 - e^{-d_j^2/\alpha}$ при $d_j^2 \ll \alpha$; равенство при $\alpha = 1/(\varepsilon\tau)$. Отличие — на больших d_j^2: итерационный фильтр чисто экспоненциальный (полиномиальный), гребень рациональный и сходится к 1 быстрее: на гладких направлениях гребень точнее при той же защите от шума. Сравнение профилей на сквозном примере — `examples.ipynb`, пример 3.

Задача 8.4 (принцип невязки на сквозном примере)**.** Найти параметр α из уравнения $\rho(\alpha) = \delta^2$ для данных (3).

Решение. По лемме 3.14 $\rho(\alpha) = \operatorname{dist}^2(y, R(X)) + \sum_{j=1}^{r}\left(\frac{\alpha}{d_j^2+\alpha}\right)^2 (u_j^\intercal y)^2$: здесь $r = n = 462 < m = 500$, y почти наверное не лежит в $R(X)$ и $\operatorname{dist}^2(y, R(X)) \approx 0{,}096 > 0$ — это левая граница ρ при $\alpha \to 0$ и левый член условия (20). Алгоритм: (1) $\delta^2 = m\sigma^2$; проверяем условие (20): $\operatorname{dist}^2(y, R(X)) < m\sigma^2 = \delta^2$ (равенство — вырожденный случай нулевой вероятности, замечание 3.16), а $\delta^2 < \|y\|^2$ очевидно. (2) Корень $\rho(\alpha) = \delta^2$ ищем бисекцией: 5–7 итераций дают α с точностью процента, так как ρ монотонна. (3) Контроль: $\alpha \sim \delta^{2/3}$ по следствию 3.12 — при его посылках о спектральном распределении решения. Численные значения $\alpha(\delta)$ и уклонение $\|\widehat{w}(\alpha) - w^*\|$ — в `examples.ipynb`, пример 2: наклон $\log\alpha$ против $\log\sigma$ там $\approx 2{,}4$, а не $2/3$, а на основной сетке шума уклонение зажато около $\|w^*\|$ — 71% массы w^* лежит в направлениях с $d_j^2 < 10^{-2}$ и решение живёт в подавленном гребнем хвосте, так что посылки следствия не выполнены; убывание уклонения к нулю видно только при малых σ, где корень невязки уходит под машинный этаж и метод сливается с МНК.

9. Вопросы, которые стоит ожидать

- **Назовите три имени одной конструкции.** Регуляризация Тихонова (обратные задачи) = гребневая регрессия (статистика) = L_2-регуляризация = снижение весов (машинное обучение): минимум $\|Aq - f\|^2 + \alpha\|q\|^2$; явный фильтр $\lambda/(\lambda+\alpha)$ (сшивка — в разделе 4).
- **Почему большая регуляризованная модель лучше малой нерегуляризованной?** Разложение (32): ёмкость покупает малое смещение, регуляризация — малую дисперсию; «наилучшая эмпирическая модель — это большая модель, подходящим образом регуляризированная» [51] (Гудфеллоу, Бенджио, Курвилль).
- **Как выбирать параметр α?** Три принципа (замечание 3.20): по уровню шума (принцип невязки, теорема 3.15), по контролю (перекрёстная проверка, правило одной стандартной ошибки), по квазиоптимуму; при $\delta \sim \varepsilon$ оптимум $\alpha \sim \varepsilon^{2/3}$ (следствие 3.12).

- **Чем ранняя остановка отличается от гребня?** Путь в пространстве решений: ранняя остановка — движение по градиентной траектории из начального приближения (полиномиальный фильтр $1-(1-\varepsilon\lambda)^{\tau}$), гребень — прямой рациональный фильтр $\lambda/(\lambda+\alpha)$ (теорема 7.3, задача 8.3); ранняя остановка не требует сетки по α и есть итерационная регуляризация Тихонова — метод Ландвебера [14] (Кабанихин).
- **Почему смещения не регуляризируют?** Смещение — параметр положения отклика, а не чувствительности к входу; штраф на него вёл бы к систематическому недообучению (замечание 7.2).
- **Почему Adam не гарантирует сходимости?** Адаптивная нормировка шага покомпонентно уменьшает эффективный шаг, и при некоторых последовательностях градиентов сумма шагов конечна: есть контрпримеры расходимости (Reddi et al., 2019; замечание 6.6).
- **Dropout и бэггинг — чем они регуляризуют?** Dropout для линейной регрессии — адаптивный L_2 с коэффициентом на признак (предложение 7.5); бэггинг усредняет ошибки моделей: дисперсия падает до v/k, остаётся общая часть c (формула (57)).
- **Как регуляризация связана с байесовским выводом?** Регуляризатор = минус логарифм априорной плотности: гауссовский априор даёт L_2 с $\alpha=\sigma^2/\nu^2$ (теорема 4.2), лапласовский — L_1 (следствие 4.3); MAP-оценка — то же, что минимум функционала Тихонова.

10. Источники

- **[14]** (Кабанихин) — профильный источник по обратным и некорректным задачам: корректность по Адамару и по Тихонову, непрерывность обратного оператора на компакте, модуль непрерывности, регуляризирующие семейства и балансировка, функционал и теоремы Тихонова (в книге без доказательств — доказаны в конспекте по формулировкам книги), квазирешение Иванова с явными формулами, принцип и обобщённый принцип невязки, критерий Пикара, метод Ландвебера как итерационная регуляризация, оценки точности $\varepsilon^{2/3}$ и $\varepsilon^{1/2}$.
- **[42]** (Галанин) — рамка обратных задач математического моделирования: три группы обратных задач, примеры некорректности, сглаживающий функционал и принцип невязки с численным примером.
- **[16]** (Хасти, Тибширани, Фридман) — статистическая сторона: гребень и лассо с ограниченными формами, байесовская интерпретация $\lambda=\sigma^2/\nu^2$, SVD-анализ и эффективное число степеней свободы, разложение смещение–дисперсия, перекрёстная проверка и правило одной стандартной ошибки, эластичная сеть.
- **[51]** (Гудфеллоу, Бенджио, Курвилль) — сторона глубокого обучения: эмпирический риск и переобучение, каноническое определение регуляризации и смысл «смещение против дисперсии», снижение весов, ранняя остановка с выводом эквивалентности L_2, dropout (Wager et al., 2013), бэггинг, шум к входу, универсальная теорема аппроксимации, обратное распространение, оптимизация (SGD, импульс, Нестеров, Adam).
- **[53]** (Воронцов) — постановка обучения по прецедентам: эмпирический риск и ERM, регуляризация как максимум совместного правдоподобия, weight decay, связь SVM с регуляризацией по Тихонову, мультиколлинеарность, гребень и лассо, скользящий контроль.
- **[37]** (Гасников) — стохастическая оптимизация: оракул с дисперсией D, минибатчинг, неулучшаемые оценки SGD, автоматическое дифференцирование, тяжёлый шарик и Нестеров как основа импульса.
- **[63]** (Меркулов, снимок курса) — обзор методов оптимизации: Adam, heavy ball с оптимальными α^*, β^* и знаменателем $(\sqrt{\varkappa}-1)/(\sqrt{\varkappa}+1)$, таблица скоростей SGD, автодифференцирование. Утверждения сверены с первичными книгами.
- **[64]** (Меркулов, вводные лекции) — вычислительный граф и обратное распространение, исправление смещения в Adam, оговорка Reddi et al.

2019. Утверждения сверены с первичными книгами.