

Вопрос 02. Машинное обучение и искусственные нейронные сети как обратные задачи. Регуляризация

Конспект теории с полными доказательствами

Крохалев Е. М.

2026

Содержание

I. Основная часть	2
1. Постановка и мотивация	2
2. Корректность по Адамару и условная корректность	3
3. Регуляризирующие алгоритмы	5
4. Машинное обучение как обратная задача	11
4.1. Эмпирический риск и переобучение	12
4.2. Регуляризатор как априорное распределение	12
4.3. Гребневая регрессия	13
4.4. Смещение, дисперсия и выбор параметра	14
4.5. Лассо и эластичная сеть	16
II. Расширенная часть	16
5. ИНС как обратная задача	16
6. Методы обучения	18
7. Регуляризация в глубоком обучении	21
8. Разобранные задачи	24
9. Вопросы, которые стоит ожидать	25

Часть I.

Основная часть

1. Постановка и мотивация

Сюжет вопроса — сшивка трёх традиций, дающих одной конструкции три имени: регуляризация Тихонова в теории обратных задач, гребневая регрессия в статистике и L_2 -регуляризация (снижение весов) в машинном обучении — один и тот же объект, и конспект построен так, чтобы читатель узнавал его под любым из имён.

Обратные задачи в моделировании. Прямая задача состоит в определении результата по заданной причине: по параметрам модели q вычисляется выход $f = Aq$, где A — оператор прямой задачи. Обратная задача (англ. *inverse problem* — [57]) ставится в обратную сторону: по наблюдаемому выходу f определить причину q [42] (Галанин). Обратные задачи делятся на три группы [42] (Галанин): обратные по постановке (восстановление характеристик среды по замерам решения уравнения — классические задачи геофизики); определение структуры и параметров модели по опытным данным; синтез, где по желаемому выходу подбирается сама система (проектирование).

Обучение модели по данным — задача второй группы: модель $g(x, w)$ с параметрами w играет роль оператора A , точки x_i — роль точек измерения, значения y_i — роль правой части f . Восстановление параметров по выходу — операторное уравнение первого рода, и вся теория раздела 2 переносится на обучение без изменений. Это и есть ответ на заголовок вопроса: машинное обучение — частный случай обратной задачи, а регуляризация — механизм, делающий её устойчивой.

Сквозной пример. Через весь конспект и через численные примеры в `examples.ipynb` ведётся одна задача: восстановление функции пяти переменных

$$u(x) = e^{-\|x-a\|^2/(2 \cdot 0,5^2)} + 0,7 e^{-\|x-b\|^2/(2 \cdot 0,2^2)}, \quad x = (x_1, \dots, x_5) \in [-1, 1]^5 \subset \mathbb{R}^5, \quad (1)$$

по m измерениям $y_i = u(x_i) + \varepsilon_i$ в точках x_i , независимо равномерно распределённых в кубе $[-1, 1]^5$; шум независим, $E\varepsilon_i = 0$, $D\varepsilon_i = \sigma^2$. Функция (1) — сумма двух гауссовых «спектральных линий»: широкой (центр $a = (-0,3; 0,2; -0,1; 0,4; 0,1)$, ширина 0,5) и узкой (центр $b = (0,4; -0,3; 0,2; -0,2; 0,3)$, ширина 0,2, амплитуда 0,7); именно вторая делает задачу чувствительной к высоким частотам: её пространственный масштаб в 2,5 раза меньше, и базис обязан разрешать в 2,5 раза больше осцилляций по каждой координате. Решение разыскивается в базисе тензорных произведений полиномов Чебышёва

$$\varphi_k(x) = T_{k_1}(x_1) \cdots T_{k_5}(x_5), \quad k = (k_1, \dots, k_5), \quad k_1 + \dots + k_5 \leq 6, \quad (2)$$

их $n = \binom{5+6}{5} = 462$: $\hat{u}(x) = \sum_k w_k T_{k_1}(x_1) \cdots T_{k_5}(x_5)$. Подстановка измерений даёт систему $Xw \approx y$, где $X_{ik} = T_{k_1}(x_{i,1}) \cdots T_{k_5}(x_{i,5})$ — матрица плана (строки — значения базисных функций в точках измерения), $w \in \mathbb{R}^n$ — вектор весов, $y \in \mathbb{R}^m$ — целевой вектор. Оператор $A = X$ отображает $\mathbb{R}^n$ в $\mathbb{R}^m$; уравнение

$$Xw = y \quad (3)$$

— конечномерное операторное уравнение первого рода, вокруг которого строится весь вопрос.

Предварительная демонстрация неустойчивости. Прямой способ решить (3) — метод наименьших квадратов (МНК): $\hat{w} \in \arg \min_w \|Xw - y\|^2$, что при полном ранге и $m \geq n$ даёт $\hat{w} = (X^T X)^{-1} X^T y$. Когда m близко к n и данные зашумлены, это решение неустойчиво:

сквозной пример с $m = 500$, $n = 462$, $\sigma = 0,05$ показывает разрыв отдельных коэффициентов $\widehat{w}_j$ до двух порядков (наихудшее покоординатное отношение $|\widehat{w}_j - w_j^*|/|w_j^*|$ среди значимых коэффициентов, $|w_j^*| > 0,05 \max |w^*|$, равно ≈ 63 ; буквальный максимум по всем координатам ≈ 646) и размытие узкого пика; регуляризованный метод (раздел 3) те же данные восстанавливает (числа — в `examples.ipynb`, пример 2). Механизм неустойчивости разобран ниже: определение — в разделе 2, лечение — в разделе 3, статистика и обучение — в разделах 4–7.

Базис сознательно выбран плохо обусловленным. Механизм здесь — тензоризация: высокочастотные тензорные произведения на конечном наборе точек почти линейно зависимы, малые собственные значения $X^T X$ упираются в уровень шума, и число обусловленности $\kappa(X^T X)$ оказывается огромным уже при n , близком к m (замер: $\kappa \approx 2,4 \cdot 10^6$ в примере 2). Одномерный прототип того же механизма для степенных функций — матрица Грама мономов, близкая к матрице Гильберта: её собственные значения стремятся к нулю экспоненциально с ростом степени (счёт — в вопросе 09 (метрические и нормированные пространства, теорема Рисса)). На одной постановке видны и плохая обусловленность МНК, и сжатие малых сингулярных направлений, и связь итерационных методов с ранней остановкой.

Два содержательных моста: минимизация невязки — безусловная минимизация (методы — вопрос 10 (методы минимизации функций многих переменных)); псевдорешение несовместной системы — ортогональная проекция (вопрос 09 (метрические и нормированные пространства, теорема Рисса)).

2. Корректность по Адамару и условная корректность

Операторная форма обратной задачи: пусть A отображает топологическое пространство Q в топологическое пространство F ; требуется по $f \in F$ найти $q \in Q$ из уравнения $Aq = f$. Обозначения: $D(A)$ — область определения, $R(A)$ — область значений, точное решение — q_T ($Aq_T = f$). Пусть вместо f задано приближение f_δ с известным уровнем погрешности $\delta > 0$, $\|f - f_\delta\| \leq \delta$.

Определение 2.1. Задача $Aq = f$ **корректна на паре пространств Q и F (корректна по Адамару)**, если выполнены три условия [14] (Кабанихин):

- 1) для любого $f \in F$ существует решение $q_T \in Q$, то есть $R(A) = F$ (существование);
- 2) решение единственно, то есть существует обратный оператор A^{-1} (единственность);
- 3) для любой окрестности $O(q_T) \subset Q$ найдётся окрестность $O(f) \subset F$ такая, что $A^{-1}O(f) \subset O(q_T)$, то есть A^{-1} непрерывен (устойчивость).

Топологические пространства в определении можно конкретизировать: метрические, банаховы, гильбертовы, евклидовы; неизменными остаются требования существования, единственности и устойчивости [14] (Кабанихин).

Определение 2.2. Задача $Aq = f$ **некорректна** (англ. *ill-posed problem* — [32], [39]) на паре Q, F , если нарушено хотя бы одно из трёх требований определения 2.1 [14] (Кабанихин).

Обратные задачи почти всегда некорректны [42] (Галанин): нарушение существования типично (зашумленные данные вне образа A), нарушение устойчивости — главное: примеры ниже показывают, что малые возмущения f порождают неограниченные возмущения q . Парадоксальная формула этого явления: «неприятности» начинаются тогда, когда оператор прямой задачи слишком хорош — например компактен (замечание 2.11). Некорректную задачу нельзя решать «в лоб»: нужна дополнительная априорная информация о решении, и стандартный её источник — знание о принадлежности решения компактному множеству.

Определение 2.3. Задача $Aq = f$ **условно корректна на множестве** $M \subset Q$ (**корректна по Тихонову**), если $f \in A(M)$ и выполнены условия [14] (Кабанихин):

- 1) решение q_T единственно на M ;
- 2) для любой окрестности $O(q_T)$ существует окрестность $O(f)$ такая, что $A^{-1}(O(f) \cap A(M)) \subset O(q_T)$ (условная устойчивость).

Множество M называется **множеством корректности** [14] (Кабанихин).

Идея: устойчивость требуется не на всём пространстве, а лишь на той части, где решение заведомо лежит; возмущения, выводящие за пределы M , не рассматриваются. Почему компакт — главный пример множества корректности, показывает следующая теорема.

Теорема 2.4 (непрерывность обратного оператора на компакте). Пусть Q и F — метрические пространства, $M \subset Q$ компактно, отображение $A : Q \rightarrow F$ непрерывно и взаимно однозначно переводит M в $A(M) \subset F$. Тогда обратное отображение $A^{-1} : A(M) \rightarrow M$ непрерывно.

Доказательство. Зафиксируем $f \in A(M)$ и положим $q_T = A^{-1}f \in M$. Докажем непрерывность A^{-1} в точке f от противного. Пусть она нарушена: тогда существует $\varepsilon^* > 0$ такое, что для любого $\delta > 0$ найдётся элемент $f_\delta \in A(M)$ с

$$\rho_F(f_\delta, f) < \delta, \quad \rho_Q(A^{-1}f_\delta, q_T) \geq \varepsilon^*.$$

Применяя это к $\delta = 1/n$, $n \in \mathbb{N}$, получаем последовательность $f_n \in A(M)$ такую, что

$$\rho_F(f_n, f) < \frac{1}{n}, \quad \rho_Q(q_n, q_T) \geq \varepsilon^*, \quad q_n := A^{-1}f_n \in M. \quad (4)$$

Последовательность $\{q_n\} \subset M$ содержится в компакте, поэтому из неё можно выделить сходящуюся подпоследовательность: $q_{n_k} \rightarrow q^* \in M$ (замкнутость компакта в метрическом пространстве). По непрерывности A $Aq_{n_k} \rightarrow Aq^*$. С другой стороны, $Aq_{n_k} = f_{n_k} \rightarrow f$ по первому условию (4). По единственности предела $Aq^* = f = Aq_T$, а поскольку A взаимно однозначно на M и $q^*, q_T \in M$, получаем $q^* = q_T$. Но тогда $\rho_Q(q_{n_k}, q_T) \rightarrow 0$, что противоречит второму условию (4): $\rho_Q(q_{n_k}, q_T) \geq \varepsilon^* > 0$ для всех k . Противоречие доказывает непрерывность A^{-1} в f ; точка f произвольна, значит A^{-1} непрерывен на всём $A(M)$. $\square$

Замечание 2.5. Компактность M — существенная посылка: из неё следует сходимость подпоследовательности q_{n_k} . На некомпактных множествах взаимная однозначность непрерывного оператора обратной непрерывности не даёт — все четыре примера ниже устроены так: возмущённые данные сходятся, а решения убегают на бесконечность. Существенна и взаимная однозначность: без неё предел подпоследовательности не определён однозначно. Наконец, теорема даёт непрерывность, но не способ вычислить $A^{-1}f_\delta$: приближённые данные вне $A(M)$, и A^{-1} на них не определён — это предмет раздела 3.

Определение 2.6. Пусть Q, F — метрические пространства, $M \subset Q$ компактно, A непрерывен и взаимно однозначно на M . **Модулем непрерывности** (англ. *modulus of continuity* — [57]) оператора A^{-1} на множестве $A(M)$ называется функция

$$\omega(\delta) = \sup \left\{ \rho_Q(A^{-1}f_1, A^{-1}f_2) : f_1, f_2 \in A(M), \rho_F(f_1, f_2) \leq \delta \right\}. \quad (5)$$

По теореме 2.4 множество в (5) непусто и ограничено, а сама функция ω имеет смысл количественной меры условной устойчивости. Если $q_T \in M$ — точное решение, $q_\delta \in M$ — решение с данными f_δ , $\rho_F(f, f_\delta) \leq \delta$, то непосредственно из определения $\rho_Q(q_T, q_\delta) \leq \omega(\delta)$. Модуль непрерывности — лучшая возможная гарантированная оценка погрешности на классе M : по определению супремума она достигается (или приближается) на какой-нибудь паре данных. Чем медленнее $\omega(\delta) \rightarrow 0$ при $\delta \rightarrow 0$, тем ниже предельная точность любого метода восстановления; вопросы 03 (принятие решения: байесовский и минимаксный подходы) и

19 (наилучшее равномерное приближение) используют ту же конструкцию как меру трудности задачи.

Четыре классических примера показывают, как устроена неустойчивость: в каждом явно построено возмущение, сходящееся в F , и элементы, убегающие в Q .

Пример 2.7 (дифференцирование). $Aq = q'$ для $q \in C^1[0, 1]$ с $q(0) = 0$, пространства $Q = C^1$ с нормой C , $F = C[0, 1]$. Возьмём $f_\delta = f + \delta \sin(x/\delta^2)$: тогда $\|f_\delta - f\|_C = \delta$, но

$$(f_\delta - f)' = \frac{1}{\delta} \cos(x/\delta^2), \quad \|(f_\delta - f)'\|_C = \frac{1}{\delta} \rightarrow \infty.$$

Задача некорректна по устойчивости [14] (Кабанихин). Смена метрики в Q на слабую не спасает: для L_2 неустойчивость сохраняется с другой скоростью.

Пример 2.8 (уравнение Фредгольма 1-го рода). $Aq = \int_a^b K(x, s) q(s) ds$ с непрерывным ядром K ; A компактен в C и в L_2 . Пусть $Aq = f$ разрешимо; положим $q_n(s) = q_T(s) + n \sin(n^2 s)$. Тогда $\|q_n - q_T\|_C \rightarrow \infty$, но $(A(q_n - q_T))(x) = \int_a^b K(x, s) n \sin(n^2 s) ds$. Заменим $t = n^2 s$ и интегрированием по частям при $K \in C^1$ по второму аргументу получаем $\|Aq_n - f\|_C \leq K_1/n^2 \rightarrow 0$: возмущение решения бесконечно велико при возмущении данных бесконечно малом [14] (Кабанихин). Некорректность здесь двойная: $R(A)$ нигде не плотен и не замкнут (компактный оператор не может иметь замкнутый образ, если он бесконечномерен), что нарушает и существование, и устойчивость.

Пример 2.9 (обратное время в задаче теплопроводности). Прямая задача: $u_t = a^2 u_{xx}$, $u(0, t) = u(l, t) = 0$, начальное условие $u(x, 0) = q(x)$; наблюдение $u(x, T)$. Мода $q_n(x) = \frac{1}{n} \sin(\pi n x / l)$ порождает $u_n(x, t) = \frac{1}{n} e^{-a^2 \pi^2 n^2 t / l^2} \sin(\pi n x / l)$, и наблюдаемое значение $\frac{1}{n} e^{-a^2 \pi^2 n^2 T / l^2} \sin(\pi n x / l)$ равномерно стремится к нулю. Обратный оператор восстанавливает моду с множителем $e^{a^2 \pi^2 n^2 T / l^2}$, то есть ошибка данных амплитуды δ_n в n -й моде превращается в ошибку решения $\delta_n e^{a^2 \pi^2 n^2 T / l^2}$ — экспоненциальный рост по номеру моды [14] (Кабанихин). Чем точнее модель прямой задачи описывает сглаживание, тем сильнее обратная задача усиливает высокие частоты.

Пример 2.10 (задача Коши для уравнения Лапласа). Ищется гармоническая в полосе функция по данным Коши на границе: $u_{xx} + u_{yy} = 0$, $u(0, y) = f(y)$, $u_x(0, y) = 0$. Мода $f_n(y) = \frac{1}{n} \sin(ny)$ порождает решение $u_n(x, y) = \frac{1}{n} \sin(ny) \frac{e^{nx} + e^{-nx}}{2} = \frac{1}{n} \sin(ny) \cosh(nx)$, гармоническое при каждом n ; данные стремятся к нулю равномерно по y , а при $x > 0$ решение неограниченно растёт как $e^{nx} / (2n)$ [14] (Кабанихин). Задача Коши для эллиптического уравнения — классический образец некорректности по Адамару.

Замечание 2.11. Примеры 2.8–2.10 иллюстрируют общий принцип: чем «лучше» оператор прямой задачи (компактен, сильно сглаживает), тем хуже обратная задача. Компактный оператор переводит слабую сходимости в сильную; его обратный переводит сильную в слабую — и потому не ограничен. Интуиция: сглаживание стирает высокие частоты, и их восстановление из зашумлённых данных требует деления на бесконечно малые множители (критерий Пикара, раздел 8).

3. Регуляризирующие алгоритмы

Теорема 2.4 гарантирует устойчивость на компакте, но не говорит, как вычислить решение: приближённые данные f_δ лежат вне образа $A(M)$, и обратный оператор на них не действует. Регуляризация устраняет этот пробел: вместо несуществующего A^{-1} строится непрерывное приближение, сходящееся к A^{-1} при $\delta \rightarrow 0$.

Определение 3.1. Регуляризирующим семейством для задачи $Aq = f$ называется семейство операторов $\{R_\alpha\}_{\alpha>0}$, $R_\alpha : F \rightarrow Q$, такое что [14] (Кабанихин):

1) для любого $\alpha > 0$ оператор R_α непрерывен;

2) для любого $f \in R(A)$ и $q_T = A^{-1}f$

$$\lim_{\alpha \rightarrow +0} R_\alpha f = q_T. \quad (6)$$

Число α — **параметр регуляризации** (в статистике тот же параметр обозначают λ [16] (Хасты, Тибширани, Фридман), в ранних работах по обучению — τ [53] (Воронцов); во всём конспекте основное обозначение — α).

Определение 3.2. Пусть вместо f задано f_δ с $\|f - f_\delta\| \leq \delta$. Отображение $R_{\alpha(\delta, f_\delta)}$, сопоставляющее данным элемент $q_{\alpha\delta} = R_{\alpha(\delta, f_\delta)} f_\delta$, — **регуляризирующий алгоритм** (англ. *regularization algorithm*), если

$$\sup_{\|f - f_\delta\| \leq \delta} \|R_{\alpha(\delta, f_\delta)} f_\delta - A^{-1}f\| \rightarrow 0 \quad (\delta \rightarrow 0) \quad (7)$$

для всех $f \in R(A)$; выбор $\alpha = \alpha(\delta, f_\delta)$ — **согласование параметра регуляризации с погрешностью данных**.

Ключевая оценка для линейного R_α выводится в две строки:

$$\|q_T - q_{\alpha\delta}\| \leq \|q_T - R_\alpha f\| + \|R_\alpha f - R_\alpha f_\delta\| \leq \gamma(q_T, \alpha) + \|R_\alpha\| \delta,$$

где

$$\gamma(q_T, \alpha) = \|q_T - R_\alpha f\| \quad (8)$$

— уклонение регуляризованного решения от точного на точных данных. Первый член мала при малых α по (6); второй растёт при уменьшении α , поскольку $\|R_\alpha\| \rightarrow \infty$ при $\alpha \rightarrow 0$ (иначе предел (6) был бы ограниченным оператором и задача была бы корректной). Это противоречивое требование — ядро всей теории: **точность решения и устойчивость к шуму балансируются параметром α** .

Лемма 3.3 (о балансировке). Пусть $\{R_\alpha\}$ — регуляризирующее семейство для $Aq = f$ с линейными непрерывными R_α . Тогда величина

$$\omega(q_T, \delta) = \inf_{\alpha>0} \{\gamma(q_T, \alpha) + \|R_\alpha\| \delta\} \quad (9)$$

стремится к нулю при $\delta \rightarrow 0$.

Доказательство. Зафиксируем $\varepsilon > 0$. По свойству (6) найдётся $\alpha_0 = \alpha_0(\varepsilon) > 0$ такое, что $\gamma(q_T, \alpha) = \|q_T - R_\alpha f\| < \varepsilon/2$ для всех $\alpha \in (0, \alpha_0)$. Каждый оператор R_α при $\alpha > 0$ непрерывен, поэтому $\mu_0(\varepsilon) = \inf_{\alpha \in (0, \alpha_0)} \|R_\alpha\| \leq \|R_{\alpha_0/2}\| < \infty$ [14] (Кабанихин); возьмём $\delta_0(\varepsilon) = \varepsilon/(2\mu_0(\varepsilon))$. Тогда для всех $\delta \in (0, \delta_0(\varepsilon))$

$$\omega(q_T, \delta) = \inf_{\alpha>0} \{\gamma(q_T, \alpha) + \|R_\alpha\| \delta\} \leq \inf_{\alpha \in (0, \alpha_0)} \left\{ \frac{\varepsilon}{2} + \|R_\alpha\| \delta \right\} = \frac{\varepsilon}{2} + \mu_0(\varepsilon) \delta < \frac{\varepsilon}{2} + \frac{\varepsilon}{2} = \varepsilon.$$

Поскольку $\omega(q_T, \delta) \geq 0$, это и есть $\lim_{\delta \rightarrow 0} \omega(q_T, \delta) = 0$. $\square$

Замечание 3.4. Лемма доказывает существование какого-то согласования, но не даёт его явно; конструктивные правила — принцип невязки, квазирешение, контроль по отложенной выборке — разобраны ниже. Существенна линейность R_α : она позволила вынести $\|R_\alpha\| \delta$ за скобки; для нелинейных операторов оценка усложняется, идея балансировки сохраняется.

Самый известный способ построить регуляризующее семейство — минимизация функционала Тихонова.

Определение 3.5. Пусть Q, F — гильбертовы пространства, $A : Q \rightarrow F$ — линейный ограниченный оператор, $f_\delta \in F$, $q^0 \in Q$ — пробное решение (априорное приближение). **Функционалом Тихонова** называется

$$M^\alpha[q] = \|Aq - f_\delta\|^2 + \alpha \|q - q^0\|^2, \quad \alpha > 0, \quad (10)$$

а **методом регуляризации А. Н. Тихонова** — построение приближённого решения по правилу $q_{\alpha\delta} = \arg \min_{q \in Q} M^\alpha[q]$ [14] (Кабанихин). Слагаемое $\alpha \|q - q^0\|^2$ называется стабилизирующим функционалом; в общем виде вместо нормы берётся полунорма, отвечающая априорной информации о гладкости решения.

Теорема 3.6 (существование и единственность минимизатора). Пусть Q и F — гильбертовы пространства, $A : Q \rightarrow F$ — линейный ограниченный оператор, $\alpha > 0$, $q^0 \in Q$. Тогда для любого $f_\delta \in F$ функционал M^α (10) достигает своей нижней грани на единственном элементе $q_\alpha \in Q$.

Доказательство. Обозначим $m = \inf_{q \in Q} M^\alpha[q] \geq 0$ и выберем минимизирующую последовательность q_n так, что $M^\alpha[q_n] \leq m + \frac{1}{n}$. Из неравенства $\alpha \|q_n - q^0\|^2 \leq M^\alpha[q_n] \leq m + 1$ следует, что последовательность q_n ограничена: $\|q_n - q^0\| \leq \sqrt{(m+1)/\alpha}$. В гильбертовом пространстве из всякой ограниченной последовательности выделяется слабо сходящаяся подпоследовательность: существует $q_\alpha \in Q$ и подпоследовательность q_{n_k} такие, что $q_{n_k} - q^0 \rightharpoonup q_\alpha - q^0$.

Норма в гильбертовом пространстве слабо полунепрерывна снизу: $\|q_\alpha - q^0\| \leq \liminf_k \|q_{n_k} - q^0\|$. Покажем, что и первое слагаемое не увеличивается при слабом пределе. Оператор A слабо непрерывен: если $q_{n_k} \rightharpoonup q_\alpha$, то для любого $h \in F$ $\langle Aq_{n_k}, h \rangle = \langle q_{n_k}, A^*h \rangle \rightarrow \langle q_\alpha, A^*h \rangle = \langle Aq_\alpha, h \rangle$, то есть $Aq_{n_k} \rightharpoonup Aq_\alpha$, и потому $\|Aq_\alpha - f_\delta\| \leq \liminf_k \|Aq_{n_k} - f_\delta\|$. Складывая, $m \leq M^\alpha[q_\alpha] \leq \liminf_k M^\alpha[q_{n_k}] = \lim_k M^\alpha[q_{n_k}] = m$, то есть $M^\alpha[q_\alpha] = m$ и q_α — минимизатор.

Докажем единственность. Для любых $q_1, q_2 \in Q$ по тождеству параллелограмма

$$M^\alpha \left[\frac{q_1 + q_2}{2} \right] = \frac{1}{2} M^\alpha[q_1] + \frac{1}{2} M^\alpha[q_2] - \frac{1}{4} \|A(q_1 - q_2)\|^2 - \frac{\alpha}{4} \|q_1 - q_2\|^2.$$

Пусть $q_1 \neq q_2$ — два минимизатора, $M^\alpha[q_1] = M^\alpha[q_2] = m$. Тогда $m \leq M^\alpha \left[\frac{q_1 + q_2}{2} \right] \leq m - \frac{\alpha}{4} \|q_1 - q_2\|^2 < m$ — противоречие. Значит минимизатор единствен. $\square$

Замечание 3.7. Существенны три посылки. (1) Гильбертова структура: слабая компактность шара и полунепрерывность нормы снизу гильбертовы; в банаховом пространстве существование в той же форме не гарантируется. (2) Строгая выпуклость стабилизатора ($\alpha > 0$): она даёт единственность; при $\alpha = 0$ минимизатор — всякое псевдорешение, единственность теряется при $\ker A \neq \{0\}$. (3) Ограниченность A нужна для полунепрерывности первого слагаемого. Полная непрерывность A здесь не требуется — она нужна в теореме 3.9.

Предложение 3.8 (нормальное уравнение). Минимизатор q_α функционала (10) удовлетворяет уравнению Эйлера

$$(A^*A + \alpha I) q_\alpha = A^*f_\delta + \alpha q^0, \quad (11)$$

причём оператор $A^*A + \alpha I$ обратим и $\|(A^*A + \alpha I)^{-1}\| \leq 1/\alpha$.

Доказательство. При любом $v \in Q$ и $t \in \mathbb{R}$ $M^\alpha[q_\alpha + tv] = M^\alpha[q_\alpha] + 2t(\langle Aq_\alpha - f_\delta, Av \rangle + \alpha \langle q_\alpha - q^0, v \rangle) + t^2(\|Av\|^2 + \alpha \|v\|^2)$. Поскольку q_α — точка минимума, коэффициент при t обязан обращаться в нуль для всех v : $\langle Aq_\alpha - f_\delta, Av \rangle + \alpha \langle q_\alpha - q^0, v \rangle = \langle A^*(Aq_\alpha - f_\delta) + \alpha(q_\alpha - q^0), v \rangle = 0 \quad \forall v$, откуда $A^*Aq_\alpha + \alpha q_\alpha = A^*f_\delta + \alpha q^0$, то есть (11). Далее, для любого $q \in Q$ $\langle (A^*A + \alpha I)q, q \rangle = \|Aq\|^2 + \alpha \|q\|^2 \geq \alpha \|q\|^2$, то есть оператор $A^*A + \alpha I$ сильно положителен, обратим по теореме Люмера — Минтера — Филлипса (или непосредственно: инъективен и имеет замкнутый образ, совпадающий с ортогональным дополнением ядра сопряжённого, то есть со всем Q), и $\|(A^*A + \alpha I)^{-1}\| \leq 1/\alpha$. $\square$

Из (11) получаем явную формулу регуляризованного решения

$$q_{\alpha\delta} = (A^*A + \alpha I)^{-1}(A^*f_\delta + \alpha q^0), \quad (12)$$

а при $q^0 = 0$ — $q_{\alpha\delta} = (A^*A + \alpha I)^{-1}A^*f_\delta$. Семейство $R_\alpha = (A^*A + \alpha I)^{-1}A^*$ состоит из ограниченных операторов: $\|R_\alpha\| \leq \sup_\sigma \sigma/(\sigma^2 + \alpha) = 1/(2\sqrt{\alpha})$ по спектральной теореме, и $\|R_\alpha\| \rightarrow \infty$ при $\alpha \rightarrow 0$, как и положено регуляризующему семейству.

Теорема 3.9 (сходимость метода Тихонова). Пусть Q, F — гильбертовы пространства, $A : Q \rightarrow F$ — линейный вполне непрерывный оператор, $f \in R(A)$, решение q_T уравнения $Aq = f$ единственно. Пусть $\|f - f_\delta\| \leq \delta$, и параметр выбран по правилу $\alpha = \alpha(\delta)$ так, что

$$\lim_{\delta \rightarrow 0} \alpha(\delta) = 0, \quad \lim_{\delta \rightarrow 0} \frac{\delta^2}{\alpha(\delta)} = 0. \quad (13)$$

Тогда регуляризованные решения $q_{\alpha(\delta),\delta}$ (12) сходятся к точному: $\|q_{\alpha(\delta),\delta} - q_T\| \rightarrow 0$ при $\delta \rightarrow 0$.

Доказательство. Разобьём доказательство на три шага.

Шаг 1 (ограниченность решений). По определению минимизатора $M^\alpha[q_{\alpha\delta}] \leq M^\alpha[q_T] \leq \delta^2 + \alpha \|q_T - q^0\|^2$. Отсюда

$$\|q_{\alpha\delta} - q^0\|^2 \leq \frac{\delta^2}{\alpha} + \|q_T - q^0\|^2, \quad \|Aq_{\alpha\delta} - f_\delta\|^2 \leq \delta^2 + \alpha \|q_T - q^0\|^2. \quad (14)$$

По условию (13) первая оценка даёт равномерную по δ ограниченность $q_{\alpha\delta} - q^0$, а вторая — сходимость образов:

$$Aq_{\alpha\delta} \rightarrow f \quad (\delta \rightarrow 0), \quad (15)$$

поскольку $\|Aq_{\alpha\delta} - f\| \leq \|Aq_{\alpha\delta} - f_\delta\| + \delta \leq \sqrt{\delta^2 + \alpha \|q_T - q^0\|^2} + \delta \rightarrow 0$.

Шаг 2 (слабая сходимость подпоследовательностей). Ограниченная последовательность $q_{\alpha\delta} - q^0$ содержит слабо сходящуюся подпоследовательность: $q_{\alpha_k\delta_k} - q^0 \rightharpoonup q_* - q^0$. Так как A вполне непрерывен, компактный оператор переводит слабую сходимость в сильную: $Aq_{\alpha_k\delta_k} \rightarrow Aq_*$ (по норме F). Сравнивая с (15), получаем $Aq_* = f = Aq_T$; по единственности решения $q_* = q_T$. Значит, всякая слабо сходящаяся подпоследовательность $q_{\alpha\delta}$ сходится слабо к q_T , и вся сеть $q_{\alpha\delta}$ сходится к q_T слабо.

Шаг 3 (сильная сходимость). Раскроем квадрат нормы:

$$\|q_{\alpha\delta} - q_T\|^2 = \|q_{\alpha\delta} - q^0\|^2 + \|q_T - q^0\|^2 - 2 \langle q_{\alpha\delta} - q^0, q_T - q^0 \rangle.$$

Первое слагаемое ограничено сверху оценкой (14): $\limsup \|q_{\alpha\delta} - q^0\|^2 \leq \limsup \delta^2/\alpha + \|q_T - q^0\|^2 = \|q_T - q^0\|^2$ по (13); скалярное произведение стремится к $\|q_T - q^0\|^2$ по слабой сходимости (шаг 2). Следовательно, $\limsup_{\delta \rightarrow 0} \|q_{\alpha\delta} - q_T\|^2 \leq \|q_T - q^0\|^2 + \|q_T - q^0\|^2 - 2\|q_T - q^0\|^2 = 0$, то есть $q_{\alpha\delta} \rightarrow q_T$ по норме. $\square$

Замечание 3.10. Проанализируем посылки. (1) Условие $\delta^2/\alpha \rightarrow 0$ существенно: при $\alpha \sim \delta^2$ оценка (14) даёт лишь ограниченность $\limsup \|q_{\alpha\delta} - q^0\|^2 \leq 1 + \|q_T - q^0\|^2$, и сходимость теряется; слишком быстрый рост α ломает аппроксимацию. Именно поэтому α нельзя выбирать ни слишком малым, ни слишком большим — нужно согласование (13). (2) Вполне непрерывность A использована только на шаге 2 для перевода слабой сходимости в сильную; для обратимого ограниченного оператора шаг 2 не нужен: образы сходятся по построению, а слабая сходимость $q_{\alpha\delta}$ к q_T следует из сходимости $Aq_{\alpha\delta} \rightarrow Aq_T$ и обратимости A . (3) Единственность решения заменяется сходимостью к нормальному решению (элементу, ближайшему к q^0); формулировка и доказательство усложняются, качественный вывод тот же [14] (Кабанихин).

Теорема 3.9 гарантирует сходимость без скорости: скорость требует условий на гладкость решения (истокпредставимость $q_T = (A^*A)^{p/2}v$), иначе она может быть сколь угодно низкой. В конечномерном случае оценка выводится напрямую из нормального уравнения.

Лемма 3.11 (скорость сходимости в конечномерном разрешимом случае). Пусть $A : \mathbb{R}^n \rightarrow \mathbb{R}^m$ — линейный оператор, уравнение $Aq = f$ разрешимо, q_T — его нормальное решение (то есть $q_T \perp \ker A$), $\|f - f_\delta\| \leq \delta$, $q^0 = 0$. Обозначим через $\lambda_r > 0$ наименьшее положительное собственное значение матрицы A^*A ($r = \text{rank } A$). Тогда

$$\|q_{\alpha\delta} - q_T\| \leq \frac{\alpha}{\lambda_r} \|q_T\| + \frac{\delta}{2\sqrt{\alpha}}. \quad (16)$$

Доказательство. Применим оператор A^* к равенству $Aq_T = f$: $A^*Aq_T = A^*f$. Вычитая из нормального уравнения (11) (при $q^0 = 0$) это равенство, получаем $(A^*A + \alpha I)(q_{\alpha\delta} - q_T) = A^*(f_\delta - f) - \alpha q_T$, то есть $q_{\alpha\delta} - q_T = (A^*A + \alpha I)^{-1}A^*(f_\delta - f) - \alpha(A^*A + \alpha I)^{-1}q_T$. Оценим слагаемые по очереди. Первое: в сингулярном базисе A матрица $(A^*A + \alpha I)^{-1}A^*$ имеет сингулярные числа $\sigma_j/(\sigma_j^2 + \alpha)$, а функция $\sigma \mapsto \sigma/(\sigma^2 + \alpha)$ достигает максимума $1/(2\sqrt{\alpha})$ в точке $\sigma = \sqrt{\alpha}$; поэтому $\|(A^*A + \alpha I)^{-1}A^*(f_\delta - f)\| \leq \frac{1}{2\sqrt{\alpha}} \delta$. Второе: так как $q_T \perp \ker A = \ker A^*A$, вектор q_T разложим по собственным векторам φ_j , отвечающим положительным собственным значениям $\lambda_1 \geq \dots \geq \lambda_r > 0$, и действие $\alpha(A^*A + \alpha I)^{-1}$ на φ_j есть умножение на $\alpha/(\lambda_j + \alpha) \leq \alpha/\lambda_r$; следовательно,

$$\|\alpha(A^*A + \alpha I)^{-1}q_T\| \leq \frac{\alpha}{\lambda_r + \alpha} \|q_T\| \leq \frac{\alpha}{\lambda_r} \|q_T\|.$$

Суммой двух оценок и является (16). □

Следствие 3.12 (балансировка $\varepsilon^{2/3}$). Пусть данные заданы с точностью порядка ε : $\delta \sim \varepsilon$. Тогда минимальное по порядку значение правой части (16) достигается при

$$\alpha \sim \varepsilon^{2/3} \quad (17)$$

и равно $O(\varepsilon^{2/3})$: задача восстанавливается с точностью порядка $\varepsilon^{2/3}$ [14] (Кабанихин). Здесь ε — точность данных, а не шаг обучения.

Доказательство. Минимизируем по α функцию $\varphi(\alpha) = c_1\alpha + c_2\varepsilon\alpha^{-1/2}$ с $c_1 = \|q_T\|/\lambda_r$, $c_2 = 1/2$. Приравнявая производную к нулю: $\varphi'(\alpha) = c_1 - \frac{1}{2}c_2\varepsilon\alpha^{-3/2} = 0$, получаем $\alpha^{3/2} = c_2\varepsilon/(2c_1)$, то есть $\alpha \sim \varepsilon^{2/3}$ (константы c_1, c_2 лишь фиксируют пропорциональность). Подстановка даёт $\varphi \sim c_1\varepsilon^{2/3} + c_2\varepsilon^{1-1/3} = O(\varepsilon^{2/3})$. □

Замечание 3.13. Число $\varepsilon^{2/3}$ — цена устойчивости: при данных точности ε решение восстанавливается лишь с точностью $\varepsilon^{2/3} \gg \varepsilon$. Показатель определяется соперничеством двух членов (16): смещения, линейного по α , и дисперсии $\delta/\sqrt{\alpha}$; лемма 3.11 — прямой аналог разложения теоремы 4.9. Для неразрешимого уравнения (псевдорешение) точность падает до $O(\varepsilon^{1/2})$ при $\alpha \sim \varepsilon^{1/2}$ [14] (Кабанихин).

Теория даёт асимптотическое согласование (13); прикладная задача обычно имеет фиксированный δ и требует конкретного числа. Разберём главный принцип выбора по уровню шума; сводка всех трёх — в замечании 3.20.

Лемма 3.14 (монотонность невязки). Пусть $A : \mathbb{R}^n \rightarrow \mathbb{R}^m$ — линейный оператор, $f_\delta \in \mathbb{R}^m$, $q^0 = 0$, $q_\alpha = (A^*A + \alpha I)^{-1} A^* f_\delta$, и пусть $X = UDV^\top$ — сингулярное разложение A с сингулярными числами $d_1 \geq \dots \geq d_r > 0$. Тогда невязка

$$\rho(\alpha) = \|Aq_\alpha - f_\delta\|^2 = \sum_{j=1}^r \left(\frac{\alpha}{d_j^2 + \alpha} \right)^2 (u_j^\top f_\delta)^2 + \|(I - P)f_\delta\|^2, \quad (18)$$

где P — ортогональный проектор на $R(A) = \text{lin}\{u_1, \dots, u_r\}$. В частности, ρ непрерывна и (строго) монотонно возрастает по α при условии $Pf_\delta \neq 0$, причём

$$\lim_{\alpha \rightarrow 0} \rho(\alpha) = \|(I - P)f_\delta\|^2 = \text{dist}^2(f_\delta, R(A)), \quad \lim_{\alpha \rightarrow \infty} \rho(\alpha) = \|f_\delta\|^2. \quad (19)$$

Доказательство. Подставим $q_\alpha = V(D^2 + \alpha I)^{-1} D U^\top f_\delta$ в невязку: $Aq_\alpha = U D (D^2 + \alpha I)^{-1} D U^\top f_\delta = \sum_{j=1}^r \frac{d_j^2}{d_j^2 + \alpha} (u_j^\top f_\delta) u_j$. Тогда $Aq_\alpha - f_\delta = -\sum_{j=1}^r \frac{\alpha}{d_j^2 + \alpha} (u_j^\top f_\delta) u_j - (I - P)f_\delta$. Оба слагаемых ортогональны (первое лежит в $R(A)$, второе в $R(A)^\perp$), поэтому квадрат нормы раскладывается в сумму квадратов, и мы получаем (18). Каждая функция $\alpha \mapsto (\alpha/(d_j^2 + \alpha))^2 = (1 - d_j^2/(d_j^2 + \alpha))^2$ непрерывна и строго возрастает от 0 до 1 при α от 0 до ∞ ; при $u_j^\top f_\delta \neq 0$ хотя бы для одного j (то есть при $Pf_\delta \neq 0$) сумма строго возрастает. Пределы (19) — пределы слагаемых при $\alpha \rightarrow 0$ и $\alpha \rightarrow \infty$; вторая часть первого равенства — определение расстояния до подпространства (теорема о проекции, вопрос 09). $\square$

Теорема 3.15 (принцип невязки). В условиях леммы 3.14 пусть дополнительно $f \in R(A)$, $\|f - f_\delta\| \leq \delta$ и

$$\text{dist}(f_\delta, R(A)) < \delta < \|f_\delta\|. \quad (20)$$

Тогда уравнение

$$\rho(\alpha) = \delta^2 \quad (21)$$

имеет единственный корень $\alpha(\delta) > 0$.

Доказательство. По лемме 3.14 ρ непрерывна и строго возрастает от $\rho(0+) = \text{dist}^2(f_\delta, R(A))$ до $\rho(\infty) = \|f_\delta\|^2$ (строгое возрастание обеспечено вторым неравенством (20): $\|f_\delta\| > \delta > 0$ влечёт $Pf_\delta \neq 0$). Оба крайних значения строго по разные стороны от δ^2 по (20); точнее, по теореме о проекции $\text{dist}(f_\delta, R(A)) \leq \|f_\delta - f\| \leq \delta$, а по условию первое неравенство строгое. По теореме о промежуточном значении непрерывная монотонная функция принимает значение δ^2 ровно один раз. $\square$

Замечание 3.16. Условие (20) — точная граница применимости. Если $\text{dist}(f_\delta, R(A)) = \delta$ (например, $f_\delta \in R(A)$ и шум исчерпал бюджет точности), положительного корня нет — нужна обобщённая невязка: при $\|A - A_h\| \leq h$ параметр выбирают из $\|A_h q_{\alpha h}^\delta - f_\delta\| = h \|q_{\alpha h}^\delta\| + \delta$ [14] (Кабанихин). Мост в обучение: невязка — ошибка на обучении; принцип невязки говорит остановиться, когда она сравнялась с уровнем шума, а его роль играет ошибка на отложенной выборке (раздел 4; численный поиск корня — задача 8.4).

Второй классический способ согласования — выбор на компакте.

Определение 3.17. Пусть Q, F — метрические пространства, $M \subset Q$, $A : Q \rightarrow F$. **Квази-решением** уравнения $Aq = f$ на множестве M называется элемент $q_K \in M$, на котором достигается нижняя грань невязки: $\rho_F(Aq_K, f) = \inf_{q \in M} \rho_F(Aq, f)$ [14] (Кабанихин).

Теорема 3.18 (В. К. Иванов о квазирешении). Пусть $M \subset Q$ компактно, A непрерывен и взаимно однозначен на M , причём проекция каждого $f \in F$ на $A(M)$ единственна. Тогда квазирешение существует, единственно и непрерывно зависит от f .

Идея доказательства. Существование: отображение $q \mapsto \rho_F(Aq, f)$ непрерывно на M (композиция непрерывных), поэтому достигает на компакте своей нижней грани.

Единственность: пусть q_K, q'_K — два квазирешения. Тогда Aq_K и Aq'_K — два ближайших к f элемента множества $A(M)$; по единственности проекции $Aq_K = Aq'_K$, а по взаимной однозначности A на M : $q_K = q'_K$.

Непрерывность: пусть $f_n \rightarrow f$, q_n — квазирешения для f_n . По компактности из q_n выделяется сходящаяся подпоследовательность $q_{n_k} \rightarrow q^* \in M$; по непрерывности A образы сходятся: $Aq_{n_k} \rightarrow Aq^*$. С другой стороны, обозначив через π проекцию на $A(M)$, $\rho_F(Aq_{n_k}, f) \leq \rho_F(Aq_{n_k}, f_{n_k}) + \rho_F(f_{n_k}, f) = \rho_F(\pi f_{n_k}, f_{n_k}) + \rho_F(f_{n_k}, f) \rightarrow \rho_F(\pi f, f)$, то есть Aq^* — элемент $A(M)$, ближайший к f ; по единственности проекции $Aq^* = \pi f = Aq_K(f)$, по взаимной однозначности $q^* = q_K(f)$. Предел единствен, значит сходится вся последовательность. $\square$

Замечание 3.19. Доказательство целиком стоит на компактности (существование, выделение подпоследовательности), непрерывности A и единственности проекции — тот же набор посылок, что в теореме 2.4. Единственность проекции выполнена, например, когда F строго выпукло (гильбертово), а $A(M)$ выпукло и замкнуто.

Для линейного A и шара $M = B(0, r)$ квазирешение записывается явно. Пусть $\{\lambda_n, \varphi_n\}$ — собственные значения и векторы A^*A , $\lambda_1 \geq \lambda_2 \geq \dots$, $f_n = \langle A^*f, \varphi_n \rangle$. Тогда [14] (Кабанихин)

$$q_K = \sum_n \frac{f_n}{\lambda_n} \varphi_n, \quad \text{если } \sum_n \frac{f_n^2}{\lambda_n^2} < r^2; \quad q_K = \sum_n \frac{f_n}{\alpha + \lambda_n} \varphi_n, \quad \text{если } \sum_n \frac{f_n^2}{\lambda_n^2} \geq r^2, \quad (22)$$

где во втором случае α — корень уравнения $\sum_n f_n^2 / (\alpha + \lambda_n)^2 = r^2$ (левая часть строго убывает по α от $+\infty$ до 0, так что корень единствен). Сравните со (12): коэффициент при f_n / λ_n равен $\lambda_n / (\alpha + \lambda_n)$ — **тот же фильтр** $\lambda / (\lambda + \alpha)$, что и у метода Тихонова при $q^0 = 0$. Квазирешение на шаре с активным ограничением и решение Тихонова — одна кривая в пространстве Q , параметризованная двумя способами: радиусом (Иванов) или α (Тихонов). Это первый пример эквивалентности «ограничение $\leftrightarrow$ штраф», который вернётся в разделе 4.

Замечание 3.20 (три способа выбора параметра). Теория предлагает три принципа согласования α с данными: по уровню шума (принцип невязки, корень (21)), по контролю (отложенная выборка или перекрёстная проверка), по квазиоптимуму (минимизация (9)). В обучении работают второй и эвристические правила; принцип невязки остаётся эталоном сравнения (раздел 4, задача 8.4).

4. Машинное обучение как обратная задача

Словарь перевода: матрица плана X (строки — примеры) играет роль A , веса w — роль q , целевой вектор y — роль f_δ ; m — число примеров, n — число параметров. Обозначения разделов 2–3 и этого раздела взаимозаменяемы по этому словарю.

4.1. Эмпирический риск и переобучение

Определение 4.1. Пусть $g(x, w)$ — модель с параметрами $w \in \mathbb{R}^n$, $\ell(\hat{y}, y)$ — функция потерь. **Эмпирическим риском** (англ. *empirical risk* — [51]) называется средняя потеря по обучающей выборке

$$Q(w) = \frac{1}{m} \sum_{i=1}^m \ell(g(x_i, w), y_i) \quad (23)$$

[53] (Воронцов); метод эмпирического риска ищет $\hat{w} \in \arg \min_w Q(w)$ [53] (Воронцов). Цель обучения — малый риск на новых данных (ошибка обобщения); минимизация (23) сама по себе уязвима для переобучения: модели высокой ёмкости способны просто запомнить обучающий набор [51] (Гудфеллоу, Бенджио, Курвил).

Для квадратичной потери $\ell(\hat{y}, y) = (\hat{y} - y)^2$ минимизация (23) — ровно задача МНК из построения сквозного примера: $Q(w) = \frac{1}{m} \|Xw - y\|^2$, и вся теория раздела 3 применяется слово в слово (q читается как w , A как X , f_δ как y с уровнем шума $\delta \sim \sqrt{m} \sigma$).

Переобучение как некорректность. Решение МНК по данным существует всегда (псевдорешение есть для любой выборки), но при близких m и n и шуме оно неустойчиво. Формальная картина та же, что в разделе 2: в квадратной невырожденной ситуации $m = n$ имеем $\hat{w} = X^{-1}y$, и возмущение данных δy порождает возмущение решения

$$\frac{\|\delta w\|}{\|w\|} \leq \kappa(X) \frac{\|\delta y\|}{\|y\|}, \quad (24)$$

то есть при $\kappa(X) \gg 1$ малый шум данных многократно усиливается. Источник плохой обусловленности в сквозном примере — тензоризация: высокочастотные тензорные произведения полиномов Чебышёва на конечном наборе точек почти линейно зависимы, и малые собственные значения $X^T X$ упираются в уровень шума. Одномерный прототип того же механизма — степенные функции: матрица Грама мономов близка к матрице Гильберта, и её собственные значения стремятся к нулю экспоненциально с ростом степени (счёт — в вопросе 09 (метрические и нормированные пространства, теорема Рисса)). Похожая ситуация — мультиколлинеарность в статистике: почти линейно зависимые столбцы X делают $X^T X$ почти вырожденной; у [53] (Воронцов) практическим признаком служит число обусловленности порядка 10^2 – 10^4 и выше. Геометрический смысл: плохо обусловленная задача имеет долину минимумов — вдоль малых собственных направлений функционал почти не меняется, и решение гуляет по ней под действием шума; то же явление замедляет градиентные методы (вопрос 10 (методы минимизации функций многих переменных), где число обусловленности κ задаёт знаменатель сходимости).

Итак: переобучение — это не «слишком сложная модель» вообще, а **конкретное проявление некорректности по устойчивости**: ёмкость даёт существование решения под любые данные, а малые собственные значения матрицы плана — его неустойчивость к шуму. Лекарство — регуляризация, то есть возврат задачи в класс корректных с заменой исходного уравнения близкой корректной задачей (определение 3.2).

4.2. Регуляризатор как априорное распределение

Тихоновский стабилизатор $\alpha \|q - q^0\|^2$ имеет точный вероятностный смысл: это логарифм гауссовского априорного распределения. Покажем это полностью.

Теорема 4.2 (байесовский вывод L_2 -регуляризатора). Пусть модель линейна: $y = Xw + \varepsilon$, шум гауссовский и гомоскедастичен: ε_i независимы, $\varepsilon_i \sim \mathcal{N}(0, \sigma^2)$; априорное распределение весов гауссовское: $w \sim \mathcal{N}(0, \nu^2 I)$. Тогда MAP-оценка (англ. **maximum a posteriori** — максимум апостериорной плотности, вопрос 03 (принятие решения: байесовский и минимаксный подходы))

$$\hat{w}^{\text{MAP}} = \arg \max_w [\log p(y | X, w) + \log p(w)] \quad (25)$$

совпадает с регуляризованным решением Тихонова (12) при $q^0 = 0$ с параметром

$$\alpha = \frac{\sigma^2}{\nu^2}. \quad (26)$$

Доказательство. Логарифм правдоподобия: независимость ε_i даёт $p(y \mid X, w) = \prod_{i=1}^m \frac{1}{\sqrt{2\pi}\sigma} \exp(-(y_i - x_i^\top w)^2 / (2\sigma^2)) = (2\pi\sigma^2)^{-m/2} \exp(-\|y - Xw\|^2 / (2\sigma^2))$. Априорная плотность: $p(w) = \frac{1}{(2\pi\nu^2)^{n/2}} \exp\left(-\frac{\|w\|^2}{2\nu^2}\right)$. Подставляя в (25) и отбрасывая постоянные члены, получаем $\hat{w}^{\text{MAP}} = \arg \min_w [\|y - Xw\|^2 + \frac{\sigma^2}{\nu^2} \|w\|^2]$. Это функционал Тихонова (10) с $A = X$, $q^0 = 0$ и $\alpha = \sigma^2/\nu^2$, и по теореме 3.6 минимум достигается на единственном элементе, явный вид которого дан формулой (12) [16] (Хасты, Тибширани, Фридман), [51] (Гудфеллоу, Бенджио, Курвил). $\square$

Следствие 4.3 (L_1 и лапласовский априор). Если априорное распределение произведение лапласовских: $p(w) \propto \exp(-\|w\|_1 / C)$, то MAP-оценка (25) совпадает с минимизатором

$$\|y - Xw\|^2 + \frac{2\sigma^2}{C} \|w\|_1. \quad (27)$$

Доказательство. Как и в теореме 4.2, $\log p(y \mid X, w) = -\|y - Xw\|^2 / (2\sigma^2) + \text{const}$, а $\log p(w) = -\|w\|_1 / C + \text{const}$. Сумма, домноженная на $2\sigma^2$, даёт (27). $\square$

Замечание 4.4. Связка «регуляризатор = логарифм априорного» объясняет и происхождение теоремы 4.2, и её границы: подходящий априор реализует и L_1 (следствие 4.3), и любой штраф вида $-\log p(w)$, но не всякий регуляризатор имеет байесовскую интерпретацию [51] (Гудфеллоу, Бенджио, Курвил). Формула (26) связывает α с отношением сигнал/шум: большой шум ($\sigma \gg \nu$) требует сильной регуляризации — α — не произвольная константа, а отношение неопределённости данных к априорной уверенности.

Теперь сшивка имён. Конструкция (10) с $q^0 = 0$ в трёх традициях носит три имени: **регуляризация Тихонова** (обратные задачи), **гребневая регрессия** (*ridge regression*) (статистика), **L_2 -регуляризация**, или **снижение весов** (*weight decay* — [63], [64]), (машинное обучение). Отождествление проговорено прямо у [51] (Гудфеллоу, Бенджио, Курвил): «регуляризацию по норме L_2 называют также гребневой регрессией, или регуляризацией Тихонова».

4.3. Гребневая регрессия

Задача гребневой регрессии:

$$\hat{w} = \arg \min_w \left\{ \|y - Xw\|^2 + \alpha \|w\|^2 \right\}; \quad (28)$$

эквивалентная ограниченная форма — минимизация $\|y - Xw\|^2$ при условии $\|w\|^2 \leq t$ (та же «ограничение $\leftrightarrow$ штраф», что и в (22)).

Предложение 4.5 (явное решение). Минимизатор задачи (28) существует, единствен и равен

$$\hat{w} = (X^\top X + \alpha I)^{-1} X^\top y. \quad (29)$$

Доказательство. Это частный случай теоремы 3.6 (Кабанихин) ($Q = \mathbb{R}^n$, $F = \mathbb{R}^m$) и предложения 3.8: нормальное уравнение $(X^\top X + \alpha I)w = X^\top y$ разрешимо однозначно, поскольку $X^\top X + \alpha I \succeq \alpha I \succ 0$. $\square$

Главное, что покупает гребень, видно в сингулярном базисе (запись $X = UDV^\top$ с $D = \text{diag}(d_1, \dots, d_r)$, $d_1 \geq \dots \geq d_r > 0$ — та же, что в вопросе 16 (PCA и ICA)).

Предложение 4.6 (спектральный анализ гребня). Пусть $X = UDV^\top$. Тогда

$$X\hat{w} = \sum_{j=1}^r \frac{d_j^2}{d_j^2 + \alpha} (u_j^\top y) u_j. \quad (30)$$

В частности, гребень оставляет направления u_j и коэффициенты $u_j^\top y$ нетронутыми, но сжимает каждый на множитель $d_j^2/(d_j^2 + \alpha) \in (0, 1)$; сжатие сильнее всего там, где $d_j^2 \lesssim \alpha$, то есть вдоль малых сингулярных направлений [16] (Хасты, Тибширани, Фридман).

Доказательство. Подставим (29) в $X\hat{w}$: $X\hat{w} = UDV^\top(VD^2V^\top + \alpha I)^{-1}VDU^\top y$. Так как $VD^2V^\top + \alpha I = V(D^2 + \alpha I)V^\top$ (приписывание αI в любом ортонормированном базисе), обратная матрица равна $V(D^2 + \alpha I)^{-1}V^\top$, и $V^\top V = I$ сокращает всё выражение до

$$X\hat{w} = UD(D^2 + \alpha I)^{-1}DU^\top y = \sum_{j=1}^r \frac{d_j^2}{d_j^2 + \alpha} (u_j^\top y) u_j,$$

поскольку $D(D^2 + \alpha I)^{-1}D = \text{diag}(d_j^2/(d_j^2 + \alpha))$. Монотонность и границы множителя очевидны: $d_j^2/(d_j^2 + \alpha) \rightarrow 1$ при $d_j^2 \gg \alpha$ и $\rightarrow 0$ при $d_j^2 \ll \alpha$. $\square$

Замечание 4.7. Фильтр $d_j^2/(d_j^2 + \alpha)$ — ровно $\lambda_j/(\lambda_j + \alpha)$ с $\lambda_j = d_j^2$: тот, что был в квази-решении Иванова (22) и в следствии 3.12. Третье появление одной конструкции в трёх традициях. Механизм устойчивости виден из леммы 3.11: вклад шума вдоль v_j умножается на $d_j/(d_j^2 + \alpha) \leq 1/(2\sqrt{\alpha})$ — усиление шума ограничено $O(1/\sqrt{\alpha})$ вместо $O(1/d_r)$ у МНК. Цена — смещение: вклад точного решения вдоль v_j умножается на $d_j^2/(d_j^2 + \alpha) < 1$.

Определение 4.8. Для линейной оценки $\hat{y} = Sy$ с $S = X(X^\top X + \alpha I)^{-1}X^\top$ **эффективным числом степеней свободы** называется

$$\text{df}(\alpha) = \text{tr } S = \sum_{j=1}^r \frac{d_j^2}{d_j^2 + \alpha} \quad (31)$$

Равенство следует из доказательства предложения 4.6: $S = UD(D^2 + \alpha I)^{-1}DU^\top$, и след ортогонально подобной матрицы равен следу диагональной части. При $\alpha \rightarrow 0$ оно равно r , при $\alpha \rightarrow \infty$ стремится к нулю: регуляризация «экономит» степени свободы пропорционально сжатию собственных направлений.

4.4. Смещение, дисперсия и выбор параметра

Точность регуляризованной оценки раскладывается на три независимых источника; теорема — для общей линейной оценки $\hat{y} = Sy$, гребень — её частный случай.

Теорема 4.9 (разложение смещение-дисперсия). Пусть $y = f + \varepsilon$ с $f = (f(x_1), \dots, f(x_m))^\top$, $E\varepsilon = 0$, $E\varepsilon\varepsilon^\top = \sigma^2 I$, и оценка $\hat{f}(x_0) = h(x_0)^\top y$ линейна по y . Тогда для прогноза в точке x_0 , где $y_0 = f(x_0) + \varepsilon_0$ с ε_0 независим от ε и $E\varepsilon_0^2 = \sigma^2$,

$$E[(y_0 - \hat{f}(x_0))^2] = \sigma^2 + \text{Bias}^2(\hat{f}(x_0)) + D(\hat{f}(x_0)), \quad (32)$$

где $\text{Bias}(\hat{f}(x_0)) = \mathbb{E}\hat{f}(x_0) - f(x_0)$; слагаемое σ^2 не зависит от модели (неустраняемая ошибка). Для $\hat{f}(x_0) = h(x_0)^\top y$

$$\mathbb{D}(\hat{f}(x_0)) = \|h(x_0)\|^2 \sigma^2. \quad (33)$$

Доказательство. Впишем и вычтем среднее: $y_0 - \hat{f} = (f(x_0) - \mathbb{E}\hat{f}) + \varepsilon_0 + (\mathbb{E}\hat{f} - \hat{f})$. Возведём в квадрат и возьмём математическое ожидание. Первое слагаемое — константа: даёт Bias^2 . Второе: $\mathbb{E}\varepsilon_0^2 = \sigma^2$. Третье: $\mathbb{E}(\mathbb{E}\hat{f} - \hat{f})^2 = \mathbb{D}(\hat{f})$ по определению дисперсии. Перекрёстные члены обращаются в нуль: $\mathbb{E}[(\mathbb{E}\hat{f} - \hat{f})] = 0$; $\mathbb{E}[\varepsilon_0(\mathbb{E}\hat{f} - \hat{f})] = \mathbb{E}\varepsilon_0 \cdot \mathbb{E}[\mathbb{E}\hat{f} - \hat{f}] = 0$ по независимости; $\mathbb{E}[\varepsilon_0(f(x_0) - \mathbb{E}\hat{f})] = 0$ по той же причине; член $2\mathbb{E}[(f(x_0) - \mathbb{E}\hat{f})(\mathbb{E}\hat{f} - \hat{f})] = 2(f(x_0) - \mathbb{E}\hat{f}) \mathbb{E}[\mathbb{E}\hat{f} - \hat{f}] = 0$. Остаются три слагаемых (32).

Для линейной оценки $\mathbb{D}(\hat{f}(x_0)) = \mathbb{E}(h^\top \varepsilon)^2 = h^\top \mathbb{E}(\varepsilon \varepsilon^\top) h = \sigma^2 \|h(x_0)\|^2$ — это (33). $\square$

Следствие 4.10 (гребень: смещение растёт, дисперсия падает). Для гребневой оценки в точке x_0 дисперсия равна

$$\mathbb{D}(\hat{f}_\alpha(x_0)) = \|X(X^\top X + \alpha I)^{-1} x_0\|^2 \sigma^2. \quad (34)$$

При росте α она монотонно не возрастает, а квадрат смещения не убывает; сумма — U-образная кривая [16] (Хасты, Тибширани, Фридман).

Доказательство. Гребневая оценка линейна: $\hat{f}_\alpha(x_0) = x_0^\top \hat{w} = h(x_0)^\top y$ с $h(x_0) = X(X^\top X + \alpha I)^{-1} x_0$; подстановка в (33) даёт (34). В собственном базисе $X^\top X = V D^2 V^\top$ получаем $\mathbb{D} = \sigma^2 \sum_j \frac{d_j^2}{(d_j^2 + \alpha)^2} (x_0^\top v_j)^2$, и каждое слагаемое — невозрастающая функция α . Смещение: $\mathbb{E}\hat{f}_\alpha(x_0) = x_0^\top (X^\top X + \alpha I)^{-1} X^\top X w^*$ (w^* — истинный вектор весов), отклонение от $x_0^\top w^*$ равно $-\alpha x_0^\top (X^\top X + \alpha I)^{-1} w^*$, норма которого не убывает по α . $\square$

U-образная сумма $\sigma^2 + \text{смещение}^2 + \text{дисперсия}$ — кривая ошибки обобщения по сложности: слева недообучение (большое смещение), справа — вторая ветвь, где слишком сильная регуляризация тоже портит ошибку. Регуляризация покупает устойчивость ценой смещения, и теорема 4.9 показывает, что сделка выгодна ровно до дна U-образной кривой. В терминах раздела 3: смещение — уклонение $\gamma(q_T, \alpha)$, дисперсия — член $\|R_\alpha\| \delta$; балансировка следствия 3.12 и есть минимизация этой суммы. Численная картина — в `examples.ipynb`, пример 2.

Выбор параметра: невязка против перекрёстной проверки. Принцип невязки (теорема 3.15) требует знания δ — в обучении его нет: неизвестен ни шум прибора, ни сдвиг модели. Стандарт заменяет его перекрёстной проверкой (англ. *cross-validation* — [16]): выборка делится на K частей, модель обучается на $K - 1$ частях и проверяется на оставшейся; средняя контрольная ошибка как функция α есть прямая оценка ошибки обобщения, и параметр выбирается в её минимуме [16] (Хасты, Тибширани, Фридман), [53] (Воронцов). Практическое правило — «одна стандартная ошибка»: выбирается наиболее экономная модель (самое большое α), чья контрольная ошибка не превосходит минимальную более чем на одну стандартную ошибку оценки [16] (Хасты, Тибширани, Фридман).

Оба правила — оценивание оптимума одной и той же U-образной кривой (32); разница в оценщике. Принцип невязки пользуется уровнем шума и потому работает в теории обратных задач; CV оценивает ошибку обобщения непосредственно и потому переносится на задачи, где «шум» — это несовпадение модели и реальности, а не погрешность прибора. Точки выбора α на сквозном примере почти совпадают — `examples.ipynb`, пример 2.

4.5. Лассо и эластичная сеть

Гребень не зануляет коэффициенты. Для отбора признаков служит L_1 -штраф — лассо (англ. *lasso* — [16], *least absolute shrinkage and selection operator* — [53] (Воронцов)):

$$\hat{w} = \arg \min_w \left\{ \frac{1}{2} \|y - Xw\|^2 + \alpha \|w\|_1 \right\}, \quad (35)$$

эквивалентно — минимизация $\|y - Xw\|^2$ при $\sum_j |w_j| \leq t$ [16] (Хасты, Тибширани, Фридман). Свойства: некоторые коэффициенты оценки ровно равны нулю, и (35) одновременно обучает модель и отбирает признаки [16] (Хасты, Тибширани, Фридман). Геометрическая причина — форма ограничительного множества: у (35) это многогранник, и линии уровня невязки касаются его на гранях и вершинах (координатные плоскости); у гребня — шар, касание почти всегда внутри грани, и нули не возникают. Вероятностный смысл — лапласовский априор (следствие 4.3); у [53] (Воронцов) тот же вывод через замену $w_j = u_j - v_j$, $u_j, v_j \geq 0$. Смещение у лассо больше, чем у гребня на сигнальных направлениях, зато получаем разрежённость и интерпретируемость.

Эластичная сеть объединяет оба штрафа:

$$\arg \min_w \left\{ \|y - Xw\|^2 + \lambda \sum_j (\eta w_j^2 + (1 - \eta) |w_j|) \right\} \quad (36)$$

[16] (Хасты, Тибширани, Фридман): L_1 отбирает признаки, L_2 стабилизирует группы коррелированных признаков, которые у чистого лассо выбираются произвольно.

Где работает конструкция.

Постановка	Что минимизируется	Ответ	Что покупается
МНК без шума, $m \geq n$, полный ранг	$\ Xw - y\ ^2$	$\hat{w} = X^+y$ — псевдорешение (вопрос 09)	точность при отсутствии шума
МНК с шумом, $m \approx n$	$\ Xw - y\ ^2$	неустойчив: $\ \delta w\ / \ w\ \leq$ $\kappa(X) \ \delta y\ / \ y\ $	— (переобучение)
Гребневая регрессия	$\ Xw - y\ ^2 + \alpha \ w\ ^2$	$(X^T X + \alpha I)^{-1} X^T y$	устойчивость ценой смещения
Лассо	$\ Xw - y\ ^2 + \alpha \ w\ _1$	разрежённое $\hat{w}$	отбор признаков ценой смещения
Ранняя остановка	градиентные итерации по $Q(w)$	$w^{(\tau)}$ по контрольной ошибке	то же, что гребень, без выбора α (раздел 7)

Часть II.

Расширенная часть

5. ИНС как обратная задача

Искусственная нейронная сеть (англ. *artificial neural network* — [51]) — модель $f(x; \theta)$, составленная из композиций простых функций (слоёв); обучение — та же обратная задача, что в разделе 4, с нелинейным оператором $A : \theta \mapsto (f(x_i; \theta))_{i=1}^m$.

Постановка обучения. Обучение — минимизация эмпирического риска по параметрам θ :

$$J(\theta) = \frac{1}{m} \sum_{i=1}^m L(f(x_i; \theta), y_i) \rightarrow \min_{\theta} \quad (37)$$

[51] (Гудфеллоу, Бенджио, Курвил). Отличие от линейного случая — невыпуклость: из-за нелинейности сети большинство интересных функций потерь невыпуклы, гарантий типа теоремы 3.6 нет, инициализация берётся малыми случайными значениями, а критерий качества метода — эмпирический [51] (Гудфеллоу, Бенджио, Курвил). В терминах раздела 2: нарушена даже корректность по единственности (много эквивалентных минимумов из-за симметрий), и надежда — на регуляризацию и раннюю остановку (раздел 7).

Универсальная аппроксимация.

Теорема 5.1 (универсальная теорема аппроксимации Цыбенко — Хорника). *Сеть прямого распространения с линейным выходным слоем и хотя бы одним скрытым слоем с произвольной «сплюсывающей» функцией активации может аппроксимировать любую борелевскую функцию, отображающую одно конечномерное пространство в другое, с любой заданной ненулевой точностью, если скрытых блоков достаточно [51] (Гудфеллоу, Бенджио, Курвил).*

Две оговорки принципиальны [51] (Гудфеллоу, Бенджио, Курвил). Во-первых, теорема не гарантирует, что обучение найдёт нужные параметры: оптимизация может не найти соответствующего минимума, а найдя — выбрать не ту функцию из-за переобучения; аппроксимируемость не означает обучаемости. Во-вторых, число скрытых блоков в худшем случае экспоненциально. Теорема отвечает о выразительной силе, но не о цене вычисления.

Обратное распространение и автоматическое дифференцирование. Градиент функционала (37) вычисляется обратным распространением (англ. *backpropagation* — [51]): применением правила цепочки к вычислительному графу программы [64] (Меркулов). Вычисление — граф вершин $v_1, \dots, v_N$ (промежуточные значения) с рёбрами — зависимостями $v_j = \varphi_j(v_i : i \in \text{parents}(j))$; прямой проход вычисляет вершины в топологическом порядке. Обратный проход вычисляет сопряжённые переменные $\bar{v}_i = \partial z / \partial v_i$ (z — итоговый выход) по рекуррентному правилу [64] (Меркулов):

$$\bar{v}_i = \sum_{j \in \text{children}(i)} \bar{v}_j \frac{\partial v_j}{\partial v_i}, \quad \bar{v}_N = 1, \quad (38)$$

то есть для каждой операции якобиан перемножается с градиентом по её выходу; локальное правило для звена $x \rightarrow y \rightarrow z$ [51] (Гудфеллоу, Бенджио, Курвил):

$$\nabla_x z = \left(\frac{\partial y}{\partial x} \right)^\top \nabla_y z. \quad (39)$$

Цена: для цепного графа число операций обратного прохода пропорционально числу рёбер, а градиент по всем входам стоит примерно столько же, сколько один прямой проход [51] (Гудфеллоу, Бенджио, Курвил), [64] (Меркулов); автоматическое дифференцирование (англ. *automatic differentiation* — [37]) по программе функции строит программу градиента, работающую не более чем в константное число раз дольше исходной [37] (Гасников). Это принципиально другой способ, чем конечные разности (погрешность округления, цена n прямых проходов для n параметров) и символьное дифференцирование (комбинаторный взрыв выражений) [63] (Меркулов): обратный режим хранит промежуточные значения цепной памяти. История одной фразой: идея восходит к Келли (1960), окончательная форма — обратное аккумулирование Линнаймаа (1976), введённое в обучение сетей Вербосом (1981) [51] (Гудфеллоу, Бенджио, Курвил).

6. Методы обучения

Задачу (37) решают итерационными методами первого порядка — градиентными методами вопроса 10 (методы минимизации функций многих переменных), перенесёнными на оценку градиента по выборке.

Стохастический градиент и минибатчи. При большом m полный градиент (37) стоит m вычислений слагаемых; стохастический оракул (англ. *stochastic oracle* (?)) выдаёт вместо $\nabla f(x)$ его несмещённую оценку $\hat{g}$ с конечной дисперсией,

$$\mathbb{E} \hat{g} = \nabla f(x), \quad \mathbb{E} \|\hat{g} - \nabla f(x)\|^2 \leq D \quad (40)$$

[37] (Гасников). В обучении такой оценкой служит градиент по одному случайно выбранному примеру (или по минибатчу из r независимых): усреднение по r независимым оценкам уменьшает дисперсию в r раз [37] (Гасников):

$$\hat{g}_r = \frac{1}{r} \sum_{l=1}^r \hat{g}^{(l)}, \quad \mathbb{E} \|\hat{g}_r - \nabla f\|^2 \leq \frac{D}{r}. \quad (41)$$

Доказательство оценки дисперсии в (41). Независимость и несмещённость дают $\mathbb{E} \|\hat{g}_r - \nabla f\|^2 = \frac{1}{r^2} \sum_{l=1}^r \mathbb{E} \|\hat{g}^{(l)} - \nabla f\|^2 \leq \frac{1}{r^2} \cdot rD = D/r$ (перекрёстные члены обращаются в нуль: $\mathbb{E} \langle \hat{g}^{(l)} - \nabla f, \hat{g}^{(k)} - \nabla f \rangle = \langle \mathbb{E}(\hat{g}^{(l)} - \nabla f), \mathbb{E}(\hat{g}^{(k)} - \nabla f) \rangle = 0$ при $l \neq k$). $\square$

Размер минибатча — компромисс: r велико уменьшает дисперсию, но каждая итерация дороже; оценки ниже показывают, что итоговая стоимость $\sim D/r$ при прочих равных [37] (Гасников).

Теорема 6.1 (сходимость SGD с постоянным шагом). Пусть f дифференцируема и μ -сильно выпукла с минимумом в точке x^* , на каждом шаге используется несмещённая оценка $\hat{g}_k$ с $\mathbb{E} \|\hat{g}_k\|^2 \leq B^2$ при любом x_k , шаг h постоянен и $h \leq \frac{1}{2\mu}$. Тогда

$$\mathbb{E} \|x_k - x^*\|^2 \leq (1 - 2h\mu)^k \|x_0 - x^*\|^2 + \frac{hB^2}{2\mu}. \quad (42)$$

Доказательство. Обозначим $r_k = \|x_k - x^*\|^2$ и запишем шаг $x_{k+1} = x_k - h\hat{g}_k$ через x^* : $r_{k+1} = \|x_k - x^*\|^2 - 2h \langle \hat{g}_k, x_k - x^* \rangle + h^2 \|\hat{g}_k\|^2$. Возьмём условное при данном x_k математическое ожидание. Несмещённость даёт $\mathbb{E}[\hat{g}_k | x_k] = \nabla f(x_k)$; сильная выпуклость даёт оценку скалярного произведения: применим определяющее неравенство сильной выпуклости в точках x и x^* и сложим: $f(x^*) \geq f(x) + \langle \nabla f(x), x^* - x \rangle + \frac{\mu}{2}r$, $f(x) \geq f(x^*) + \langle \nabla f(x^*), x - x^* \rangle + \frac{\mu}{2}r$ (второе неравенство — с $\nabla f(x^*) = 0$); сложив, получаем $\langle \nabla f(x), x - x^* \rangle \geq \mu r$. Поэтому $\mathbb{E}[r_{k+1} | x_k] \leq r_k - 2h\mu r_k + h^2 B^2 = (1 - 2h\mu) r_k + h^2 B^2$. Полное математическое ожидание: $\mathbb{E} r_{k+1} \leq (1 - 2h\mu) \mathbb{E} r_k + h^2 B^2$. Раскручивая рекуррентность от 0 до k и суммируя геометрическую прогрессию, $\mathbb{E} r_k \leq (1 - 2h\mu)^k r_0 + h^2 B^2 \sum_{j=0}^{k-1} (1 - 2h\mu)^j \leq (1 - 2h\mu)^k r_0 + \frac{h^2 B^2}{2h\mu}$, поскольку $1 - 2h\mu \in [0, 1]$ и сумма прогрессии не превосходит $1/(2h\mu)$. Последнее слагаемое и есть $hB^2/(2\mu)$. $\square$

Следствие 6.2 (стоимость $O(1/\varepsilon)$). При $h \sim \varepsilon$ точность $\mathbb{E} \|x_k - x^*\|^2 \leq \varepsilon$ достигается за

$$k = O\left(\frac{B^2}{\mu^2} \frac{\ln(1/\varepsilon)}{\varepsilon}\right) \quad (43)$$

итераций. Здесь ε — допуск по норме, а не шаг обучения.

Доказательство. Выбираем h из двух требований: $hB^2/(2\mu) \leq \varepsilon/2$ (плато) и $(1-2h\mu)^k r_0 \leq \varepsilon/2$ (затухание). Первое даёт $h \leq \mu\varepsilon/B^2$; берём $h = \mu\varepsilon/B^2$ (это $\leq 1/(2\mu)$, поскольку $\varepsilon \leq B^2/(2\mu^2)$ — иначе и нулевой шаг подошёл). Второе с $\ln(1-t) \leq -t$ даёт $k \geq \ln(2r_0/\varepsilon)/(2h\mu) = B^2 \ln(2r_0/\varepsilon)/(2\mu^2\varepsilon)$. $\square$

Замечание 6.3. Три замечания. (1) Плато $hB^2/(2\mu)$ — цена стохастики: метод не сходится к точному минимуму, а застывает в окрестности; убывающий шаг в конце убирает плато, и классические условия $\sum_k h_k = \infty$, $\sum_k h_k^2 < \infty$ дают сходимость [51] (Гудфеллоу, Бенджио, Курвил). (2) Оценки по значению функции: $O(1/\sqrt{k})$ для выпуклой и $O(1/k)$ для сильно выпуклой задачи, обе неулучшаемы для класса с оракулом (40) [37] (Гасников), [51] (Гудфеллоу, Бенджио, Курвил). (3) Посылка $E \|\hat{g}\|^2 \leq B^2$ существенна: при неограниченной дисперсии плато не контролируется; посылка гладкости f для самой теоремы 6.1 избыточна (нужна только сильная выпуклость), но она стоит за оценками по значению и за практическим выбором $h \leq 1/L$.

Импульс. Импульсный метод (англ. *momentum* — [51], [63]) вычисляет экспоненциально затухающее скользящее среднее прошлых градиентов и движется по нему [51] (Гудфеллоу, Бенджио, Курвил):

$$v^{k+1} = \beta v^k - \varepsilon \nabla J(\theta^k), \quad \theta^{k+1} = \theta^k + v^{k+1}, \quad \beta \in [0, 1]. \quad (44)$$

Раскрыв $v^{k+1} = \theta^{k+1} - \theta^k$ и подставив в первое равенство, получаем $\theta^{k+1} = \theta^k - \varepsilon \nabla J(\theta^k) + \beta(\theta^k - \theta^{k-1})$, — метод тяжёлого шарика Поляка (англ. *heavy ball* — [64]) из вопроса 10 (методы минимизации функций многих переменных) с шагом $\alpha = \varepsilon$ и коэффициентом инерции β . Это тождество, а не аналогия: импульс в обучении — буквально тот же двухшаговый процесс.

Теорема 6.4 (локальная сходимость импульса на квадратичной функции). Пусть J квадратична: $J(\theta) = \frac{1}{2}(\theta - \theta^*)^\top H(\theta - \theta^*) + \text{const}$, $\mu I \preceq H \preceq LI$, $\varkappa = L/\mu$, метод (44) стартует достаточно близко от θ^* (для квадратичной — откуда угодно). Тогда при

$$\varepsilon^* = \frac{4}{(\sqrt{L} + \sqrt{\mu})^2}, \quad \beta^* = \left(\frac{\sqrt{L} - \sqrt{\mu}}{\sqrt{L} + \sqrt{\mu}} \right)^2 \quad (45)$$

метод сходится со знаменателем

$$q = \frac{\sqrt{\varkappa} - 1}{\sqrt{\varkappa} + 1}, \quad \|\theta^k - \theta^*\| \leq c q^k, \quad (46)$$

а для любых других ε, β из области сходимости знаменатель не меньше [63] (Меркулов).

Доказательство. Сдвигом $\theta^* = 0$ добьёмся $J(\theta) = \frac{1}{2}\theta^\top H\theta$. Раскрытая форма (44): $\theta^{k+1} = (1+\beta)\theta^k - \beta\theta^{k-1} - \varepsilon H\theta^k$. Пусть $He_i = \lambda_i e_i$; проекции $s_i^k = \langle \theta^k, e_i \rangle$ удовлетворяют скалярным рекуррентностям

$$\begin{pmatrix} s_i^{k+1} \\ s_i^k \end{pmatrix} = M_i \begin{pmatrix} s_i^k \\ s_i^{k-1} \end{pmatrix}, \quad M_i = \begin{pmatrix} 1 + \beta - \varepsilon\lambda_i & -\beta \\ 1 & 0 \end{pmatrix}.$$

Характеристическое уравнение матрицы M_i :

$$\rho^2 - (1 + \beta - \varepsilon\lambda_i)\rho + \beta = 0. \quad (47)$$

При комплексных корнях ($D = (1 + \beta - \varepsilon\lambda_i)^2 - 4\beta < 0$) их произведение равно β , значит $|\rho| = \sqrt{\beta}$ для обоих. Скорость равна $\max_i \max |\rho(\lambda_i)|$; равномерная по $\lambda_i \in [\mu, L]$ оптимизация по ε, β приводит к равенству дискриминантов на концах отрезка: $(1 + \beta - \varepsilon\mu)^2 = (1 + \beta - \varepsilon L)^2 = 4\beta$, то есть

$$1 + \beta - \varepsilon\mu = 2\sqrt{\beta}, \quad 1 + \beta - \varepsilon L = -2\sqrt{\beta}. \quad (48)$$

Вычитая и складывая равенства, получаем $\varepsilon(L - \mu) = 4\sqrt{\beta}$ и $2(1 + \beta) = \varepsilon(L + \mu)$; с $t = \sqrt{\beta}$ второе даёт $1 + t^2 = 2t \frac{L+\mu}{L-\mu}$, и меньший корень $t = \frac{\sqrt{L}-\sqrt{\mu}}{\sqrt{L}+\sqrt{\mu}}$, откуда $\beta^* = t^2$ и $\varepsilon^* = 4\sqrt{\beta}/(L - \mu) = 4/(\sqrt{L} + \sqrt{\mu})^2$ — это (45). Для $\lambda \in [\mu, L]$ значение $S(\lambda) = 1 + \beta^* - \varepsilon^* \lambda$ линейно и $|S(\lambda)| \leq 2\sqrt{\beta^*}$ (по построению на концах), значит дискриминант (47) неположителен и $|\rho| = \sqrt{\beta^*} = q$ — это (46).

Оптимальность пары (45). Для произвольных $\varepsilon > 0$, $\beta \in (0, 1)$ значение $S(\lambda) = 1 + \beta - \varepsilon \lambda$ по-прежнему линейно по λ , поэтому максимум $\max |\rho|$ на $[\mu, L]$ достигается на концах: в комплексной зоне ($D < 0$) $|\rho| = \sqrt{\beta}$ не зависит от λ , а при $D \geq 0$ больший по модулю корень $(|S| + \sqrt{D})/2$ монотонно растёт в $|S|$, максимум которого на отрезке — на концах. Обозначим этот максимум через $r(\varepsilon, \beta)$ и предположим, что $r(\varepsilon, \beta) < q$. (1) Произведение корней равно β , значит $r(\varepsilon, \beta) \geq \sqrt{\beta}$, и с $t := \sqrt{\beta}$ имеем $t < q$. (2) Если оба корня трёхчлена $\rho^2 - S\rho + \beta$ лежат в $(-q, q)$, то $|S| < q + \beta/q$: для вещественных корней сумма $\rho_1 + \rho_2$ при $\rho_1 \rho_2 = \beta$ по модулю меньше $q + \beta/q$ (граница отвечает корням q и β/q), а для комплексных $|S| \leq 2\sqrt{\beta} < q + \beta/q$ при $t < q$. По предположению оба корня лежат в $(-q, q)$ на обоих концах спектра, поэтому

$$|S(\mu)| < q + \frac{t^2}{q}, \quad |S(L)| < q + \frac{t^2}{q}.$$

Отсюда

$$\varepsilon\mu = 1 + t^2 - S(\mu) > (1 - q) \frac{q - t^2}{q}, \quad \varepsilon L = 1 + t^2 - S(L) < (1 + q) \frac{q + t^2}{q},$$

и деление второго неравенства на первое даёт

$$\varkappa = \frac{L}{\mu} < \frac{(1 + q)(q + t^2)}{(1 - q)(q - t^2)}.$$

Правая часть монотонно растёт по t^2 и равна $\varkappa$ ровно при $t^2 = q^2$ (подстановка $q = (\sqrt{\varkappa} - 1)/(\sqrt{\varkappa} + 1)$), поэтому неравенство выполнимо лишь при $t > q$ — противоречие с (1). Следовательно, $r(\varepsilon, \beta) \geq q$ при всех ε, β , а равенство возможно лишь при $t = q$, $S(\mu) = 2q$, $S(L) = -2q$, то есть только в точке (45). Оценка $\|\theta^k - \theta^*\| \leq cq^k$ следует из распада на скалярные рекуррентности. $\square$

Замечание 6.5. Сравнение с вопросом 10 (методы минимизации функций многих переменных): градиентный спуск на такой задаче сходится со знаменателем $(\varkappa - 1)/(\varkappa + 1)$, импульс — с $(\sqrt{\varkappa} - 1)/(\sqrt{\varkappa} + 1)$: выигрыш — корень из числа обусловленности; та же асимптотика у чебышёвских полуитераций, сопряжённых градиентов и метода Нестерова. Оговорки: теорема 6.4 детерминированная и для квадратичной задачи глобальна; оценок сходимости стохастического импульса в общей постановке нет, и на практике $\beta = 0,9$ берётся эмпирически [51] (Гудфеллоу, Бенджио, Курвил). Область сходимости по шагу шире, чем у градиентного спуска: $0 < \varepsilon\lambda < 2 + 2\beta$ против $0 < \varepsilon\lambda < 2$ [64] (Меркулов).

Нестеров. Метод Нестерова отличается от (44) тем, что градиент берётся не в текущей точке θ^k , а в экстраполированной $\tilde{\theta}^k = \theta^k + \beta v^k$:

$$v^{k+1} = \beta v^k - \varepsilon \nabla J(\theta^k + \beta v^k), \quad \theta^{k+1} = \theta^k + v^{k+1}. \quad (49)$$

Это та же схема ускорения, что и в вопросе 10: для пакетной выпуклой оптимизации ошибка $O(1/k)$ градиентного спуска улучшается до $O(1/k^2)$; для стохастического спуска ускорение по оценкам не получается [51] (Гудфеллоу, Бенджио, Курвил) — ценность Нестерова в обучении преимущественно эмпирическая.

Adam. Адаптивный метод оценивает первый и второй моменты градиента экспоненциаль-

ным сглаживанием и нормирует шаг по второму моменту:

$$\begin{aligned} s_k &= \rho_1 s_{k-1} + (1 - \rho_1) g_k, & r_k &= \rho_2 r_{k-1} + (1 - \rho_2) g_k \odot g_k, \\ \hat{s}_k &= \frac{s_k}{1 - \rho_1^k}, & \hat{r}_k &= \frac{r_k}{1 - \rho_2^k}, & \theta_{k+1} &= \theta_k - \varepsilon \frac{\hat{s}_k}{\sqrt{\hat{r}_k + \delta_0}}, \end{aligned} \quad (50)$$

где g_k — стохастический градиент, $\odot$ и деление — покомпонентные, а дробь в обновлении — покомпонентная [51] (Гудфеллоу, Бенджио, Курвил), [63] (Меркулов), [64] (Меркулов). Деление на $1 - \rho_i^k$ — исправление смещения (англ. *bias correction* — [64]): при инициализации $s_0 = r_0 = 0$ моменты занижены, и без поправки шаги первых итераций слишком малы [64] (Меркулов). Умолчания: $\varepsilon = 0,001$, $\rho_1 = 0,9$, $\rho_2 = 0,999$, $\delta_0 = 10^{-8}$ [51] (Гудфеллоу, Бенджио, Курвил). Здесь и выше ε — шаг обучения (в сквозном примере той же буквой обозначен шум измерения; области действия не пересекаются).

Замечание 6.6. Adam относится к адаптивным методам (AdaGrad и RMSProp предшествуют): каждый параметр получает эффективный шаг, обратный корню из среднего квадрата его градиента — удобно при разнородных кривизнах, но теоретический статус слабее, чем у SGD: известны примеры, где Adam не сходится (Reddi et al., 2019), и практика ответила модификациями (AdamW, декаплинг снижения весов).

7. Регуляризация в глубоком обучении

Начнём с канонического определения — оно объясняет всё остальное.

Определение 7.1 (Гудфеллоу, Бенджио, Курвил, регуляризация). «Регуляризация — это любая модификация алгоритма обучения, предпринятая с целью уменьшить его ошибку обобщения, не уменьшая ошибку обучения» [51] (Гудфеллоу, Бенджио, Курвил).

Формулировка шире тихоновского функционала: тихоновский штраф — частный случай, и в глубоком обучении работают и штрафы, и неявные приёмы. Смысл тот же, что в разделе 4: «смысл регуляризации оценки — в увеличении смещения в обмен на уменьшение дисперсии» [51] (Гудфеллоу, Бенджио, Курвил), и «наилучшая эмпирическая модель — это большая модель, подходящим образом регуляризованная» [51] (Гудфеллоу, Бенджио, Курвил): ёмкость нужна для малого смещения, регуляризация — для контролируемой дисперсии.

Снижение весов. Штрафная форма — функционал

$$\tilde{J}(\theta; X, y) = J(\theta; X, y) + \frac{\alpha}{2} \|w\|^2, \quad (51)$$

где w — все веса (не смещения) [51] (Гудфеллоу, Бенджио, Курвил). Градиент $\nabla_w \tilde{J} = \alpha w + \nabla_w J$ даёт шаг градиентного спуска с шагом ε :

$$w \leftarrow w - \varepsilon(\alpha w + \nabla_w J) = (1 - \varepsilon\alpha) w - \varepsilon \nabla_w J. \quad (52)$$

Каждая итерация сначала умножает веса на $(1 - \varepsilon\alpha) < 1$ — отсюда имя снижение весов [51] (Гудфеллоу, Бенджио, Курвил). Это ровно гребневая регрессия (теорема 4.2), и вывод (52) — эквивалентность штрафа и множителя для полного градиентного шага; для стохастического шага эквивалентность приближённая, и в современных библиотеках снижение весов реализуют отдельной операцией (AdamW).

Замечание 7.2. Смещения в (51) не регуляризуются [51] (Гудфеллоу, Бенджио, Курвил) — практика, у которой есть содержательная причина: смещение — параметр положения отклика, а не его чувствительности к входу. Штраф на смещение тянуло бы отклик модели к нулю при сдвиге входов и порождало бы систематическое недообучение; в байесовской интерпретации это отвечает априору только на веса (теорема 4.2).

Ранняя остановка. Самая распространённая форма регуляризации в машинном обучении [51] (Гудфеллоу, Бенджио, Курвил): обучение ведётся по обучающей части и останавливается, когда ошибка на отложенной контрольной части перестаёт убывать.

Теорема 7.3 (эквивалентность ранней остановки и L_2 -регуляризации). Пусть $J(w) = \frac{1}{2}(w - w^*)^\top H(w - w^*) + \text{const}$ — квадратичная функция с $H = Q\Lambda Q^\top \succeq 0$, градиентный спуск с шагом ε (таким, что $\varepsilon\lambda_i < 1$) стартует из $w^{(0)} = 0$. Тогда:

1) после τ итераций

$$Q^\top w^{(\tau)} = [I - (I - \varepsilon\Lambda)^\tau] Q^\top w^*; \quad (53)$$

2) минимум регуляризованного функционала $J(w) + \frac{\alpha}{2} \|w\|^2$ равен

$$Q^\top \tilde{w} = (\Lambda + \alpha I)^{-1} \Lambda Q^\top w^*; \quad (54)$$

3) покомпонентные множители в (53) и (54) совпадают тогда и только тогда, когда

$$(I - \varepsilon\Lambda)^\tau = \alpha(\Lambda + \alpha I)^{-1}; \quad (55)$$

для малых собственных значений λ при $\varepsilon\lambda \ll 1$ условие (55) выполнено при

$$\alpha \approx \frac{1}{\varepsilon\tau}, \quad \text{то есть} \quad \tau \approx \frac{1}{\varepsilon\alpha}. \quad (56)$$

Доказательство. 1) Градиент: $\nabla J(w) = H(w - w^*)$; итерация $w^{(t)} = w^{(t-1)} - \varepsilon H(w^{(t-1)} - w^*)$ даёт $w^{(t)} - w^* = (I - \varepsilon H)^t (w^{(0)} - w^*)$. При $w^{(0)} = 0$: $w^{(\tau)} = [I - (I - \varepsilon H)^\tau] w^*$; переход к собственному базису $H = Q\Lambda Q^\top$ (с $Q^\top Q = I$) даёт (53).

2) Минимизируем $J + \frac{\alpha}{2} \|w\|^2$: нормальное уравнение $(H + \alpha I)\tilde{w} = Hw^*$ (предложение 3.8 при $q^0 = 0$), откуда $\tilde{w} = (H + \alpha I)^{-1} Hw^*$; в собственном базисе — (54).

3) Множитель ранней остановки по направлению i : $1 - (1 - \varepsilon\lambda_i)^\tau$; множитель гребня: $\lambda_i/(\lambda_i + \alpha) = 1 - \alpha/(\lambda_i + \alpha)$. Равенство множителей — ровно (55). Докажем (56): для малых $\varepsilon\lambda_i$ разложение $(1 - \varepsilon\lambda_i)^\tau = e^{\tau \ln(1 - \varepsilon\lambda_i)} \approx e^{-\varepsilon\tau\lambda_i}$, а при $\lambda_i \ll \alpha$ правая часть (55): $\alpha/(\lambda_i + \alpha) = e^{\ln \alpha - \ln(\lambda_i + \alpha)} \approx e^{-\lambda_i/\alpha}$. Логарифмируя приближённое равенство $e^{-\varepsilon\tau\lambda_i} \approx e^{-\lambda_i/\alpha}$ и сокращая $\lambda_i \neq 0$, получаем $\varepsilon\tau \approx 1/\alpha$ — это (56); при $\lambda_i \rightarrow 0$ оба множителя стремятся к единице согласованно. $\square$

Замечание 7.4. Три вывода. (1) Число итераций τ обратно пропорционально параметру регуляризации, а $\varepsilon\tau$ — мера эффективной ёмкости [51] (Гудфеллоу, Бенджио, Курвил): ранняя остановка — тот же гребень, параметризованный временем обучения. (2) Теорема — пример **итерационной регуляризации Тихонова**: метод Ландвебера — градиентный спуск по невязке $J(q) = \|Aq - f\|^2$ — сам по себе регуляризирующий алгоритм при остановке по невязке или контролю; число итераций играет роль α [14] (Кабанихин). Это замыкает круг: явная регуляризация и ранняя остановка — две параметризации одной кривой решений. (3) Преимущество ранней остановки — автоматический подбор эффективного α вместо сетки по α [51] (Гудфеллоу, Бенджио, Курвил).

Прореживание (dropout). На каждом шаге обучения каждый скрытый блок выключается независимо с вероятностью $1 - p$ (входные — с меньшей, скрытые обычно с $p = 0,5$) [51] (Гудфеллоу, Бенджио, Курвил): модель обучается на случайном подграфе сети; на применении блоки не выключаются, а выходы масштабируются на p . Для линейной регрессии механизм точный.

Предложение 7.5 (dropout и адаптивный L_2 для линейной регрессии). Применение прореживания к линейной регрессии эквивалентно снижению весов по норме L_2 , где для каждого входного признака задаётся свой коэффициент снижения (Wager et al., 2013 — [51] (Гудфеллоу, Бенджио, Курвил)). Именно: если $\mu_j \in \{0, 1\}$ — независимые

индикаторы включения признака с $P\{\mu_j = 1\} = p$, то обучение по ожидаемой потере $E_\mu \|y - X(w \odot \mu)\|^2 = \|y - pXw\|^2 + p(1-p) \sum_j \|X_{\cdot j}\|^2 w_j^2$ есть гребневая регрессия с признакозависимым штрафом; для глубоких моделей такой эквивалентности нет [51] (Гудфеллоу, Бенджио, Курвил).

Доказательство. Равенство для ожидаемой потери: $E_\mu [(w \odot \mu)^\top X^\top X (w \odot \mu)] = \sum_{j,k} w_j w_k (E\mu_j \mu_k) X_{\cdot j}^\top X_{\cdot k}$; при $j \neq k$ независимость даёт $E\mu_j \mu_k = p^2$, при $j = k$: $E\mu_j^2 = p$. Поэтому $E_\mu \|y - X(w \odot \mu)\|^2 = \|y\|^2 - 2p y^\top Xw + p^2 \|Xw\|^2 + p(1-p) \sum_j \|X_{\cdot j}\|^2 w_j^2$, что после выделения полного квадрата $\|y - pXw\|^2$ даёт формулу. Замена $w' = pw$ показывает, что минимизация по w эквивалентна гребню с признакозависимым коэффициентом штрафа, пропорциональным $\|X_{\cdot j}\|^2$. $\square$

Бэггинг. Обучаются k моделей на бутстрэп-подвыборках или подмножествах признаков, и их ответы усредняются. Если ошибки моделей ε_i имеют $E\varepsilon_i^2 = v$ и $E\varepsilon_i \varepsilon_j = c$ при $i \neq j$, то ошибка среднего

$$E\left[\left(\frac{1}{k} \sum_i \varepsilon_i\right)^2\right] = \frac{v}{k} + \left(1 - \frac{1}{k}\right)c \quad (57)$$

[51] (Гудфеллоу, Бенджио, Курвил).

Доказательство (57). Раскрываем квадрат суммы: $E(\sum_i \varepsilon_i)^2 = \sum_i E\varepsilon_i^2 + \sum_{i \neq j} E\varepsilon_i \varepsilon_j = kv + k(k-1)c$; деление на k^2 даёт $v/k + (1 - 1/k)c$. $\square$

Итак, усреднение убивает дисперсионную часть (v/k), но оставляет общую коррелированную составляющую c : выигрыш тем больше, чем независимее модели. Регуляризирующая роль — в усреднении нерегулярной части ответа.

Аугментация и шум к входу. Аугментация порождает новые примеры преобразованиями, не меняющими ответа (повороты, сдвиги изображений): эмпирический риск минимизируется по расширенной выборке. Добавление шума ко входу в линейной модели эквивалентно штрафу по норме весов: $E_\eta \|y - w^\top (x + \eta)\|^2 = \|y - w^\top x\|^2 + E(\eta^\top w)^2$, и последнее слагаемое при белом шуме равно $\text{const} \cdot \|w\|^2$ — гребень из неопределённости входа [51] (Гудфеллоу, Бенджио, Курвил). Шум к весам — стохастическая реализация байесовского вывода (теорема 4.2) [51] (Гудфеллоу, Бенджио, Курвил).

Итоговая таблица: регуляризация в глубоком обучении.

Метод	Механизм	Что покупается
Снижение весов	штраф $\frac{\alpha}{2} \ w\ ^2$; шаг $(1 - \varepsilon\alpha)w - \varepsilon \nabla J$	сжатие малых сингулярных направлений; устойчивость к шуму
Ранняя остановка	мониторинг контрольной ошибки; $\tau \approx 1/(\varepsilon\alpha)$	тот же эффект, что у гребня, без подбора α
Прореживание	случайное выключение блоков	адаптивный L_2 (линейный случай); робастность к соседству решений
Бэггинг	усреднение k моделей	дисперсия v/k при сохранении общей части c
Аугментация, шум к входу	расширение выборки, неопределённость входа	инвариантности; штраф $\ w\ ^2$ в линейном случае

8. Разобранные задачи

Четыре задачи разбирают вычислительную сторону вопроса на сквозном примере; все числа считаются в `examples.ipynb`.

Задача 8.1 (псевдорешение и критерий Пикара). Почему систему $Xw = y$ сквозного примера нельзя решать «в лоб» через псевдообратную матрицу? Сформулировать критерий разрешимости [14] (Кабанихин).

Решение. Пусть $X = UDV^\top$, $d_1 \geq \dots \geq d_r > 0$ — сингулярное разложение. МНК-решение минимальной нормы (псевдорешение): $\hat{w} = X^+y = \sum_{j=1}^r \frac{u_j^\top y}{d_j} v_j$. Коэффициент при v_j получается делением проекции y на u_j на малое число d_j : вклад шума в этом направлении умножается на $1/d_j$ — это и есть неустойчивость. Критерий Пикара [14] (Кабанихин) отвечает на вопрос о разрешимости для компактного оператора A с сингулярной системой $\{u_j, v_j; d_j\}$: уравнение $Aq = f$ разрешимо тогда и только тогда, когда $f \perp \ker A^*$ и сходится ряд $\sum_j (f, u_j)^2 / d_j^2$; при выполнении условий нормальное решение равно $\sum_j (f, u_j) / d_j v_j$ (для инъективного A с плотным образом $\ker A^* = \{0\}$ и остаётся одна сходимость ряда). Для конечной матрицы ряд состоит из конечного числа слагаемых и потому всегда конечен: псевдорешение существует при любом y , и проблема не в существовании, а в величине. Шум имеет ненулевые проекции на все u_j , и вклад каждой в квадрат нормы псевдорешения имеет среднее $\sigma^2 \sum_j d_j^{-2}$; наименьшее сингулярное число входит с множителем $1/d_r$ ($\|X^+\|_2 = 1/d_r \approx 48,2$ на данных примера 2). Там же: ряд по чистым данным равен 2,02 (это $\|w^*\|^2$), по зашумлённым — 47,2 (это $\|\hat{w}_{\text{МНК}}\|^2$), то есть псевдорешение раздуто шумом примерно в 23 раза. Выход — обрезать ряд фильтром $d_j^2 / (d_j^2 + \alpha)$: вклад направления v_j становится $\frac{d_j}{d_j^2 + \alpha} (u_j^\top y) v_j$, и сжатие малых d_j гасит раздутие (задача 8.2).

Задача 8.2 (гребневая регрессия сквозного примера). Провести явный счёт гребневой оценки для данных (3): матрица X , оценка $\hat{w}(\alpha)$, фильтры, выбор α невязкой и перекрёстной проверкой.

Решение. Схема счёта (числа — в `examples.ipynb`, пример 2): (1) $X_{ik} = T_{k_1}(x_{i,1}) \cdots T_{k_5}(x_{i,5})$, $i = 1, \dots, m$, мультииндекс $k = (k_1, \dots, k_5)$ пробегает $k_1 + \dots + k_5 \leq 6$ ($n = 462$); точки x_i независимы и равномерны в $[-1, 1]^5$; $y_i = u(x_i) + \varepsilon_i$ при $m = 500$, $\sigma = 0,05$. (2) Сингулярное разложение $X = UDV^\top$: сингулярные числа убывают быстро — высокочастотные тензорные произведения почти линейно зависимы на 500 точках (одномерный прототип механизма для степенных функций — матрица Грама мономов, близкая к матрице Гильберта, вопрос 09). (3) Оценка по предложению 4.6: $\hat{w}(\alpha) = \sum_j \frac{d_j}{d_j^2 + \alpha} (u_j^\top y) v_j$; сжатые направления — последние v_j . (4) Невязка $\rho(\alpha) = \|X\hat{w}(\alpha) - y\|^2$ по лемме 3.14 монотонно возрастает от $\text{dist}^2(y, R(X))$ до $\|y\|^2$; с ростом α решение сначала устойчиво, затем смещение растёт и узкий пик размывается. (5) Выбор α : (а) принцип невязки — корень $\rho(\alpha) = \delta^2$ с $\delta^2 = m\sigma^2$; (б) K -кратная перекрёстная проверка с правилом одной стандартной ошибки. Обе точки лежат в дне U-образной кривой (32) и близки между собой (замер в `examples.ipynb`).

Задача 8.3 (ранняя остановка против гребня). Сравнить фильтры ранней остановки и гребня на квадратичной задаче $J(w) = \frac{1}{2} \|Xw - y\|^2$.

Решение. По теореме 7.3 с $H = X^\top X$, $\Lambda = D^2$: гребень даёт фильтр $d_j^2 / (d_j^2 + \alpha)$, ранняя остановка после τ итераций с шагом ε — фильтр $1 - (1 - \varepsilon d_j^2)^\tau$; условие совпадения (55): $(1 - \varepsilon d_j^2)^\tau = \alpha / (d_j^2 + \alpha)$. Для малых d_j^2 (именно они отвечают за неустойчивость) при $\varepsilon d_j^2 \ll 1$: $1 - (1 - \varepsilon d_j^2)^\tau \approx 1 - e^{-\varepsilon \tau d_j^2}$, а гребень $d_j^2 / (d_j^2 + \alpha) \approx 1 - e^{-d_j^2/\alpha}$ при $d_j^2 \ll \alpha$; равенство при

$\alpha = 1/(\varepsilon\tau)$. Отличие — на больших d_j^2 : итерационный фильтр чисто экспоненциальный (полиномиальный), гребень рациональный и сходится к 1 быстрее: на гладких направлениях гребень точнее при той же защите от шума. Сравнение профилей на сквозном примере — `examples.ipynb`, пример 3.

Задача 8.4 (принцип невязки на сквозном примере). Найти параметр α из уравнения $\rho(\alpha) = \delta^2$ для данных (3).

Решение. По лемме 3.14 $\rho(\alpha) = \text{dist}^2(y, R(X)) + \sum_{j=1}^r \left(\frac{\alpha}{d_j^2 + \alpha}\right)^2 (u_j^\top y)^2$: здесь $r = n = 462 < m = 500$, y почти наверное не лежит в $R(X)$ и $\text{dist}^2(y, R(X)) \approx 0,096 > 0$ — это левая граница ρ при $\alpha \rightarrow 0$ и левый член условия (20). Алгоритм: (1) $\delta^2 = m\sigma^2$; проверяем условие (20): $\text{dist}^2(y, R(X)) < m\sigma^2 = \delta^2$ (равенство — вырожденный случай нулевой вероятности, замечание 3.16), а $\delta^2 < \|y\|^2$ очевидно. (2) Корень $\rho(\alpha) = \delta^2$ ищем бисекцией: 5–7 итераций дают α с точностью процента, так как ρ монотонна. (3) Контроль: $\alpha \sim \delta^{2/3}$ по следствию 3.12 — при его посылках о спектральном распределении решения. Численные значения $\alpha(\delta)$ и уклонение $\|\hat{w}(\alpha) - w^*\|$ — в `examples.ipynb`, пример 2: наклон $\log \alpha$ против $\log \sigma$ там $\approx 2,4$, а не $2/3$, а на основной сетке шума уклонение зажато около $\|w^*\|$ — 71% массы w^* лежит в направлениях с $d_j^2 < 10^{-2}$ и решение живёт в подавленном гребнем хвосте, так что посылки следствия не выполнены; убывание уклонения к нулю видно только при малых σ , где корень невязки уходит под машинный этаж и метод сливается с МНК.

9. Вопросы, которые стоит ожидать

- **Назовите три имени одной конструкции.** Регуляризация Тихонова (обратные задачи) = гребневая регрессия (статистика) = L_2 -регуляризация = снижение весов (машинное обучение): минимум $\|Aq - f\|^2 + \alpha \|q\|^2$; явный фильтр $\lambda/(\lambda + \alpha)$ (сшивки — в разделе 4).
- **Почему большая регуляризованная модель лучше малой нерегуляризованной?** Разложение (32): ёмкость покупает малое смещение, регуляризация — малую дисперсию; «наилучшая эмпирическая модель — это большая модель, подходящим образом регуляризованная» [51] (Гудфеллоу, Бенджио, Курвил).
- **Как выбирать параметр α ?** Три принципа (замечание 3.20): по уровню шума (принцип невязки, теорема 3.15), по контролю (перекрёстная проверка, правило одной стандартной ошибки), по квазиоптимуму; при $\delta \sim \varepsilon$ оптимум $\alpha \sim \varepsilon^{2/3}$ (следствие 3.12).
- **Чем ранняя остановка отличается от гребня?** Путь в пространстве решений: ранняя остановка — движение по градиентной траектории из начального приближения (полиномиальный фильтр $1 - (1 - \varepsilon\lambda)^\tau$), гребень — прямой рациональный фильтр $\lambda/(\lambda + \alpha)$ (теорема 7.3, задача 8.3); ранняя остановка не требует сетки по α и есть итерационная регуляризация Тихонова — метод Ландвебера [14] (Кабанихин).
- **Почему смещения не регуляризуют?** Смещение — параметр положения отклика, а не чувствительности к входу; штраф на него вёл бы к систематическому недообучению (замечание 7.2).
- **Почему Adam не гарантирует сходимости?** Адаптивная нормировка шага покомпонентно уменьшает эффективный шаг, и при некоторых последовательностях градиентов сумма шагов конечна: есть контрпримеры расходимости (Reddi et al., 2019; замечание 6.6).
- **Dropout и бэггинг — чем они регуляризуют?** Dropout для линейной регрессии — адаптивный L_2 с коэффициентом на признак (предложение 7.5); бэггинг усредняет ошибки моделей: дисперсия падает до v/k , остаётся общая часть c (формула (57)).
- **Как регуляризация связана с байесовским выводом?** Регуляризатор = минус логарифм априорной плотности: гауссовский априор даёт L_2 с $\alpha = \sigma^2/\nu^2$ (теорема 4.2), лапласовский — L_1 (следствие 4.3); MAP-оценка — то же, что минимум функционала Тихонова.

10. Источники

- **[14]** (Кабанихин) — профильный источник по обратным и некорректным задачам: корректность по Адамару и по Тихонову, непрерывность обратного оператора на компакте, модуль непрерывности, регуляризирующие семейства и балансировка, функционал и теоремы Тихонова (в книге без доказательств — доказаны в конспекте по формулировкам книги), квазирешение Иванова с явными формулами, принцип и обобщённый принцип невязки, критерий Пикара, метод Ландвебера как итерационная регуляризация, оценки точности $\varepsilon^{2/3}$ и $\varepsilon^{1/2}$.
- **[42]** (Галанин) — рамка обратных задач математического моделирования: три группы обратных задач, примеры некорректности, сглаживающий функционал и принцип невязки с численным примером.
- **[16]** (Хасты, Тибширани, Фридман) — статистическая сторона: гребень и лассо с ограниченными формами, байесовская интерпретация $\lambda = \sigma^2/\nu^2$, SVD-анализ и эффективное число степеней свободы, разложение смещение–дисперсия, перекрёстная проверка и правило одной стандартной ошибки, эластичная сеть.
- **[51]** (Гудфеллоу, Бенджио, Курвил) — сторона глубокого обучения: эмпирический риск и переобучение, каноническое определение регуляризации и смысл «смещение против дисперсии», снижение весов, ранняя остановка с выводом эквивалентности L_2 , dropout (Wager et al., 2013), бэггинг, шум к входу, универсальная теорема аппроксимации, обратное распространение, оптимизация (SGD, импульс, Нестеров, Adam).
- **[53]** (Воронцов) — постановка обучения по прецедентам: эмпирический риск и ERM, регуляризация как максимум совместного правдоподобия, weight decay, связь SVM с регуляризацией по Тихонову, мультиколлинеарность, гребень и лассо, скользящий контроль.
- **[37]** (Гасников) — стохастическая оптимизация: оракул с дисперсией D , минибатчинг, неулучшаемые оценки SGD, автоматическое дифференцирование, тяжёлый шарик и Нестеров как основа импульса.
- **[63]** (Меркулов, снимок курса) — обзор методов оптимизации: Adam, heavy ball с оптимальными α^* , β^* и знаменателем $(\sqrt{\eta} - 1)/(\sqrt{\eta} + 1)$, таблица скоростей SGD, автодифференцирование. Утверждения сверены с первичными книгами.
- **[64]** (Меркулов, вводные лекции) — вычислительный граф и обратное распространение, исправление смещения в Adam, оговорка Reddi et al.

2019. Утверждения сверены с первичными книгами.