

Вопрос 03. Общая проблема принятия решения. Функция потерь. Байесовский и минимаксный подходы

Конспект теории с полными доказательствами

Крохалев Е. М.

2026

Содержание

1	Постановка и мотивация	1
2	Задача принятия решения и функция потерь	2
3	Байесовский подход	3
4	Минимаксный подход	6
5	Детектирование как задача принятия решения	9
6	Байесовская оценка и регуляризация Тихонова	10
7	Вычислительная сторона	10
8	Разобранные задачи	11
9	Что спросят	12
10	Расширенная часть	12
10.1	Отделение и минимакс	13
10.2	Рао — Блэкуэлл: улучшение через достаточную статистику	15
10.3	Минимакс и оптимальное восстановление	15

1 Постановка и мотивация

Прикладная задача, от которой ведём сюжет: по наблюдаемым данным с неизвестным уровнем шума нужно принять решение — восстановить параметр модели, выбрать модель из нескольких, оценить функционал решения (в SIR-примере — базовый индекс $R_0 = \beta/\gamma$). Это и есть **задача принятия решения** (англ. *statistical decision problem*): неизвестное состояние «природы» θ (параметр модели, внешние условия) не контролируется исследователем, наблюдение X несёт о θ лишь шумную информацию, а выбранное решение a оценивается функцией потерь $\rho(a, \theta)$. Примеры решений: точечная оценка параметра, выбор одной из конкурирующих гипотез, выбор метода вычисления. Теория принятия решений сравнивает **решающие правила** — отображения наблюдения в решение — по средним потерям и выделяет два критерия оптимальности: байесовский (среднее по априорному распределению на θ) и минимаксный (гарантия в наихудшем случае).

Сюжет закрывает блок «Решения и статистика»: проверка гипотез из соседнего вопроса — частный случай с потерей 0-1 (критерий есть решающее правило), а интервальное оценивание — решение со значением в классе множеств; регуляризация Тихонова в обратных

задачах оказывается байесовской оценкой при гауссовском априорном распределении; минимаксная рамка — это же язык теории наилучшего равномерного приближения и оптимального восстановления; последовательный вариант задачи — марковский процесс принятия решения.

Сквозной пример — SIR-модель эпидемии: по дневной заболеваемости оценить коэффициент передачи β , скорость выздоровления γ и базовый индекс $R_0 = \beta/\gamma$ (среднее число заражений от одного инфицированного в восприимчивой популяции). Модель задаётся системой

$$\dot{S} = -\beta \frac{SI}{N_{\text{pop}}}, \quad \dot{I} = \beta \frac{SI}{N_{\text{pop}}} - \gamma I, \quad \dot{R} = \gamma I,$$

и дневные числа новых случаев y_t моделируются как считающие величины с ожиданием, равным интегралу $\beta SI/N_{\text{pop}}$ за сутки. Пример проводим через всю теорию: априорные знания (« β положительно и не огромно», «средний инфекционный период около 7 суток») задают байесовский подход, а вопрос «какая оценка хуже всего ведёт себя при неудачном истинном θ » — минимаксный. Численная сторона примера — в `examples.ipynb` (пример 1).

2 Задача принятия решения и функция потерь

Определение 2.1 (Статистическая задача принятия решения). *Статистической задачей принятия решения* называется набор $(\Theta, \mathcal{X}, \{P_\theta\}_{\theta \in \Theta}, \mathcal{A}, \rho)$, где Θ — множество состояний природы, $\mathcal{X}$ — выборочное пространство, $\{P_\theta\}$ — параметрическое семейство распределений на $\mathcal{X}$, $\mathcal{A}$ — множество решений (действий), а $\rho: \mathcal{A} \times \Theta \rightarrow [0, \infty)$ — функция потерь. Наблюдение X порождается распределением P_θ с неизвестным $\theta \in \Theta$.

Определение 2.2 (Функция потерь). *Функцией потерь* (англ. *loss function*) называется борелевская неотрицательная функция $\rho(a, \theta)$ двух аргументов; величина $\rho(a, \theta)$ есть плата за выбор решения a , когда природа находится в состоянии θ . Для оценки $\hat{\theta} = \delta(X)$ величиной потерь называется $\rho(\hat{\theta}, \theta)$.

Типовые функции потерь и их приложения собраны в таблице 1 (последний столбец — по [16]).

Название	Формула ($u = a - \theta$)	Применение в моделировании
Квадратичная	$\rho = u^2$	оценка параметров, МНК, регуляризация Тихонова
Абсолютная	$\rho = u $	робастные оценки, медианные фильтры
Нуль-один	$\rho = \mathbb{I}\{u \neq 0\}$	классификация, проверка гипотез
Хьюбера	$\rho = \frac{u^2}{2}$ при $ u \leq c$; $c u - \frac{c^2}{2}$ при $ u > c$	помехоустойчивое оценивание
Квантильная (Винцента)	$\rho_\tau = u(\tau - \mathbb{I}\{u < 0\})$	квантильная регрессия, интервальное прогнозирование
Экспоненциальная	$\rho = e^{-\lambda u}$	бустинг, классификация [16]

Таблица 1: Типовые функции потерь и приложения в моделировании

Замечание 2.3. Квадратичная и абсолютная потери **не инвариантны к смене единиц измерения**: удвоение единиц удваивает $|a - \theta|$ и учетверяет $(a - \theta)^2$. Поэтому выбор между ними — содержательное решение о цене больших отклонений, а не произвол: квадратичная штрафует выбросы как ошибку в квадрате, абсолютная и потеря Хьюбера (квадратичная в полосе $|a - \theta| \leq c$ и линейная вне её) — лишь линейно, оставаясь робастными.

Определение 2.4 (Решающее правило). *Решающим правилом* (англ. *decision rule*) называется измеримое отображение $\delta: \mathcal{X} \rightarrow \mathcal{A}$. *Рандомизированным правилом* называется отображение $x \mapsto \delta(\cdot | x)$, сопоставляющее каждому наблюдению распределение на $\mathcal{A}$;

нерандомизированное правило отвечает вырожденным распределениям. Рандомизация понадобится в теореме фон Неймана (раздел «Расширенная часть»): она делает множество допустимых стратегий выпуклым.

Определение 2.5 (Функция риска). *Риском* (англ. *risk function*) решающего правила δ в состоянии θ называется математическое ожидание потерь

$$R(\delta, \theta) = \mathbb{E}_\theta \rho(\delta(X), \theta) = \int_X \rho(\delta(x), \theta) P_\theta(dx).$$

Риск — функция двух переменных, и «хорошие» правила должны делать её малой одновременно по всем θ . Прямая попытка даёт провал.

Замечание 2.6 (Равномерный подход и оценки-константы). Естественное правило сравнения: δ лучше δ' , если $R(\delta, \theta) \leq R(\delta', \theta)$ для всех $\theta \in \Theta$ и строго хотя бы в одной точке. Во всём классе правил наилучшего по этому критерию нет: для любого правила δ оценка-константа $\delta_{\theta_0} \equiv \theta_0$ имеет $R(\delta_{\theta_0}, \theta_0) = 0 \leq R(\delta, \theta_0)$, поэтому любое правило, не совпадающее с δ_{θ_0} на P_{θ_0} -почти всех наблюдениях, хуже константы хотя бы в одной точке. Отсюда два обходных пути: сгладить зависимость от θ усреднением (байесовский подход) или перейти к гарантии (минимаксный).

Обозначения. Локальные обозначения вопроса: $\mathcal{A}$ — множество решений; ρ — функция потерь; δ — решающее правило; $R(\delta, \theta)$ — риск; π — априорное распределение на Θ ; $r(\pi, \delta)$ — байесовский риск; $\bar{R}(\delta) = \sup_\theta R(\delta, \theta)$ — максимальный риск; R^* — минимаксный риск (значение игры). Объём выборки — N (зарезервировано), число дней наблюдений в SIR-примере — T .

3 Байесовский подход

Байесовский подход (англ. *Bayesian approach*) приписывает состоянию природы случайный характер: θ считается элементом, распределённым по некоторому *априорному* закону π на Θ . Тогда риск $R(\delta, \theta)$ усредняется по π , и оптимальным объявляется правило с наименьшим средним риском.

Определение 3.1 (Априорное и апостериорное распределения). Пусть семейство $\{P_\theta\}$ доминируется мерой μ с плотностями $p_\theta(x)$, а π — распределение на Θ с плотностью $\pi(\theta)$ по мере λ . Тогда π называется *априорным распределением* (англ. *prior distribution*), а условное распределение элемента θ при наблюдении $X = x$ с плотностью

$$\pi(\theta | x) = \frac{p_\theta(x) \pi(\theta)}{\int_\Theta p_\tau(x) \pi(\tau) \lambda(d\tau)} = \frac{p_\theta(x) \pi(\theta)}{p(x)}$$

— *апостериорным распределением* (англ. *posterior distribution*); знаменатель $p(x)$ называется предельной плотностью наблюдения. Формула — теорема Байеса в плотностях.

Определение 3.2 (Апостериорный и байесовский риски). *Апостериорным риском* действия a при наблюдении x называется

$$r_\pi(a | x) = \int_\Theta \rho(a, \theta) \pi(\theta | x) \lambda(d\theta).$$

Байесовским риском правила δ относительно априорного распределения π называется

$$r(\pi, \delta) = \int_\Theta R(\delta, \theta) \pi(\theta) \lambda(d\theta).$$

Правило δ_π называется *байесовским* (англ. *Bayes rule*) относительно π , если

$$r(\pi, \delta_\pi) = \inf_{\delta} r(\pi, \delta),$$

причём нижняя грань берётся по всем (в том числе рандомизированным) правилам.

Связь двух рисков — прямое следствие теоремы Тонелли (неотрицательная измеримая функция двух переменных), и она сводит построение байесовского правила к поточечной задаче.

Теорема 3.3 (Байесовское правило минимизирует апостериорный риск). Пусть $\rho \geq 0$ измерима, а апостериорный риск $r_\pi(a | x)$ конечен для всех a при почти всех x (по мере $p(x) \mu(dx)$). Тогда:

1. $r(\pi, \delta) = \mathbb{E} r_\pi(\delta(X) | X)$, где внешнее математическое ожидание берётся по предельному распределению наблюдения.
2. Если для почти каждого x существует действие $\delta_\pi(x) \in \arg \min_{a \in \mathcal{A}} r_\pi(a | x)$ и отображение $x \mapsto \delta_\pi(x)$ измеримо, то δ_π — байесовское правило относительно π .

Доказательство. По определению риска и апостериорного риска, с помощью формулы для $\pi(\theta | x)$ и теоремы Тонелли (функция неотрицательна и измерима):

$$\begin{aligned} r(\pi, \delta) &= \int_{\Theta} \int_X \rho(\delta(x), \theta) p_\theta(x) \mu(dx) \pi(\theta) \lambda(d\theta) \\ &= \int_X \left[\int_{\Theta} \rho(\delta(x), \theta) \pi(\theta | x) \lambda(d\theta) \right] p(x) \mu(dx) = \mathbb{E} r_\pi(\delta(X) | X). \end{aligned}$$

Внешнее ожидание по $p(x) \mu(dx)$ существует: после свёртки оно равно $r(\pi, \delta) \leq \infty$. Пункт 1 доказан. Для пункта 2 заметим, что если для P -почти каждого x выполнено $r_\pi(\delta_\pi(x) | x) \leq r_\pi(\delta(x) | x)$ для любого правила δ , то усреднение по X сохраняет неравенство: $r(\pi, \delta_\pi) \leq r(\pi, \delta)$. Следовательно, δ_π — байесовское правило. $\square$

Теорема сводит бесконечномерную минимизацию по правилам к конечномерной (по $a \in \mathcal{A}$) для каждого x . Решение этой задачи для трёх типовых потерь даёт три классических ответа.

Следствие 3.4 (Квадратичная потеря: апостериорное среднее). Пусть $\mathcal{A} = \Theta \subseteq \mathbb{R}$, $\rho(a, \theta) = (a - \theta)^2$ и для почти каждого x апостериорное распределение имеет конечное среднее $m(x) = \mathbb{E}(\theta | X = x)$. Тогда байесовское правило — $\delta_\pi(x) = m(x)$, то есть апостериорное среднее.

Доказательство. При фиксированном x распишем среднеквадратичное отклонение действия s от θ вокруг апостериорного среднего (все ожидания — по апостериорному распределению):

$$\mathbb{E}(\theta - s)^2 = \mathbb{E}(\theta - m(x))^2 + 2 \mathbb{E}[(\theta - m(x))(m(x) - s)] + (m(x) - s)^2 = D(\theta | x) + (m(x) - s)^2,$$

поскольку $\mathbb{E}(\theta - m(x) | x) = 0$. Первое слагаемое не зависит от s , второе неотрицательно и обращается в нуль при $s = m(x)$. Значит, точечный минимум апостериорного риска достигается при $a = m(x)$, и по теореме 3.3 правило $x \mapsto m(x)$ байесовское. $\square$

Следствие 3.5 (Абсолютная потеря: апостериорная медиана). Пусть $\mathcal{A} = \Theta \subseteq \mathbb{R}$, $\rho(a, \theta) = |a - \theta|$ и для почти каждого x апостериорное распределение имеет конечное среднее абсолютное отклонение. Тогда байесовское правило — любая апостериорная медиана $\text{med}(\theta | X = x)$.

Доказательство. Пусть F — апостериорная функция распределения, s — произвольное действие, m — медиана: $F(m-) \leq \frac{1}{2} \leq F(m)$. Используем интегральные представления $E(\theta - s)^+ = \int_s^\infty P(\theta \geq t) dt$ и $E(s - \theta)^+ = \int_{-\infty}^s F(u) du$ (теорема Тонелли для индикаторов) и оценим разность для симметричного случая $s > m$:

$$\begin{aligned} E(\theta - s)^+ - E(\theta - m)^+ &= - \int_m^s P(\theta \geq t) dt, \\ E(s - \theta)^+ - E(m - \theta)^+ &= \int_m^s P(\theta < t) dt, \end{aligned}$$

где $(u)^+ = \max(u, 0)$. Складывая, получаем

$$E|\theta - s| - E|\theta - m| = \int_m^s [P(\theta < t) - P(\theta \geq t)] dt = \int_m^s (2F(t-) - 1) dt \geq 0,$$

так как $t > m$ влечёт $F(t-) \geq F(m) \geq \frac{1}{2}$. Случай $s < m$ симметричен. Значит, каждая медиана минимизирует апостериорный риск, и по теореме 3.3 соответствующее правило байесовское. $\square$

Для потери Хьюбера минимум апостериорного риска достигается в корне a уравнения $E[\psi_c(\theta - a) | x] = 0$, где $\psi_c(u) = \max(-c, \min(u, c))$: апостериорный риск выпукл по a , его производная равна $-E[\psi_c(\theta - a) | x]$ и меняет знак с $-c$ на $+c$ при росте a , так что корень существует; он единствен, если апостериорная масса в открытой полосе $|\theta - a| < c$ положительна (иначе корней может быть целый отрезок: риск не строго выпукл). Это *винзоризованное апостериорное среднее*: равенство переписывается как $a = E[w(\theta)\theta | x] / E[w(\theta) | x]$ с весами $w(\theta) = \min(1, c/|\theta - a|)$ — взвешенное апостериорное среднее с обрезанными весами. При этом существует апостериорная медиана m с $|a - m| \leq c$: для наибольшей медианы m^+ при $a > m^+ + c$ имели бы $\psi_c(\theta - a) = -c$ на $\{\theta \leq m^+\}$ и $\psi_c(\theta - a) \leq c$ на $\{\theta > m^+\}$, откуда $E[\psi_c(\theta - a) | x] < 0$ — равенство нулю потребовало бы $P(\theta \leq m^+ | x) = 1/2$ и $\theta \geq a + c$ почти всюду на $\{\theta > m^+\}$, то есть существования медианы больше, чем m^+ ; случай $a < m^- - c$ для наименьшей медианы m^- симметричен, и вместе это даёт $m^- - c \leq a \leq m^+ + c$, а множество медиан — отрезок $[m^-, m^+]$. При $c \rightarrow 0$ правило Хьюбера вырождается в апостериорную медиану, при $c \rightarrow \infty$ — в апостериорное среднее.

Следствие 3.6 (Потеря 0-1: МАР). Пусть $\Theta = \{\theta_1, \dots, \theta_m\}$ конечно, $\rho(a, \theta) = \mathbb{I}\{a \neq \theta\}$ и априорные вероятности $\pi_j = \pi(\theta_j)$ положительны. Тогда байесовское правило — МАР-правило (*maximum a posteriori*):

$$\delta_\pi(x) = \arg \max_{j=1, \dots, m} p_{\theta_j}(x) \pi_j.$$

При равных априорных $\pi_j = 1/m$ оно совпадает с правилом максимального правдоподобия.

Доказательство. Апостериорный риск действия $a = \theta_j$ равен $1 - \pi(\theta_j | x) = 1 - \frac{p_{\theta_j}(x)\pi_j}{p(x)}$. Знаменатель не зависит от j , поэтому минимум риска достигается при максимуме $p_{\theta_j}(x)\pi_j$; остаётся применить теорему 3.3. $\square$

Замечание 3.7 (Разбор посылок байесовской конструкции). Три условия постановки существенны. **Доминируемость** семейства $\{P_\theta\}$ общей мерой: без плотностей p_θ формула Байеса в плотностях не работает — апостериорное распределение как мера может существовать и без доминированности (теорема Радона — Никодима для мер на Θ), но это уже другая постановка. **Конечность апостериорного риска**: если при квадратичной потере $E(\theta | x) = \infty$ на множестве положительной предельной вероятности, апостериорный риск любого действия бесконечен и минимизировать нечего. **Измеримость селектора** $x \mapsto \delta_\pi(x)$: без неё

поточечный минимум не собирается в решающее правило. Наконец, уход априорного «с концентрацией» ($\tau \rightarrow \infty$ в примере 4.6) показывает предельную связь с минимаксом: байесовские риски приближаются к минимаксному риску, хотя предельного «равномерного» априорного распределения на $\mathbb{R}$ не существует.

Для квадратичной потери байесовская оценка строится явно уже в простейшей нормальной модели; этот пример даёт и первую встречу со сжатием.

Пример 3.8 (Нормальная модель с нормальным априорным распределением). Пусть $X_1, \dots, X_N$ — независимые, $X_k \sim \mathcal{N}(\theta, \sigma^2)$, причём σ^2 известно, и $\theta \sim \mathcal{N}(a, \tau^2)$. Логарифм произведения правдоподобия на априорную плотность с точностью до аддитивной константы равен

$$-\frac{1}{2\sigma^2} \sum_{k=1}^N (x_k - \theta)^2 - \frac{(\theta - a)^2}{2\tau^2} = -\frac{1}{2} \left(\frac{N}{\sigma^2} + \frac{1}{\tau^2} \right) \left(\theta - \frac{\frac{N}{\sigma^2} \bar{X}_N + \frac{a}{\tau^2}}{\frac{N}{\sigma^2} + \frac{1}{\tau^2}} \right)^2 + \text{const},$$

то есть апостериорное распределение нормально,

$$\theta | X \sim \mathcal{N} \left(\frac{\frac{N}{\sigma^2} \bar{X}_N + \frac{a}{\tau^2}}{\frac{N}{\sigma^2} + \frac{1}{\tau^2}}, \left(\frac{N}{\sigma^2} + \frac{1}{\tau^2} \right)^{-1} \right),$$

и байесовская оценка при квадратичной потере — апостериорное среднее

$$\delta_\pi(x) = \frac{\frac{N}{\sigma^2} \bar{X}_N + \frac{a}{\tau^2}}{\frac{N}{\sigma^2} + \frac{1}{\tau^2}} = \frac{N\tau^2}{\sigma^2 + N\tau^2} \bar{X}_N + \frac{\sigma^2}{\sigma^2 + N\tau^2} a,$$

взвешенное среднее выборочного среднего и априорного центра: оценка *сжата* к a относительно $\bar{X}_N$.

Замечание 3.9 (Риск сжатой оценки). Риск оценки из примера 3.8 как функция θ выписывается прямо: с коэффициентом сжатия $c = \frac{N\tau^2}{\sigma^2 + N\tau^2}$ имеем $\delta_\pi(X) = c \bar{X}_N + (1 - c)a$, откуда

$$R(\delta_\pi, \theta) = \frac{c^2 \sigma^2}{N} + (1 - c)^2 (\theta - a)^2.$$

При $\theta = a$ риск $\frac{c^2 \sigma^2}{N} < \frac{\sigma^2}{N}$ меньше риска $\bar{X}_N$, но при $|\theta - a| \rightarrow \infty$ он неограниченно растёт, тогда как риск $\bar{X}_N$ равен σ^2/N всюду. Сжатие покупает точность вблизи априорного центра ценой худшего гарантированного поведения — та же сделка, которую минимаксный подход отклоняет (пример 2 ноутбука измеряет обе стороны).

В SIR-примере сопряжённого априорного распределения нет: априорное для β экспоненциальное, для γ — гамма-распределение около $1/7$, а правдоподобие Пуассона зависит от (β, γ) через решение системы ОДУ. Апостериорное среднее $E(R_0 | y)$ и разброс оцениваются численно: сначала по данным $y = (y_1, \dots, y_T)$ находится максимум апостериорной плотности (МАР-оценка), затем гессиан логарифма апостериорной плотности в максимуме даёт лапласову аппроксимацию апостериорного распределения нормальным законом (пример 1 ноутбука). При квадратичной потере байесовская оценка R_0 — среднее апостериорного распределения отношения β/γ ; она существует, пока апостериорный хвост по γ интегрируем, что обеспечивают положительные априорные плотности.

4 Минимаксный подход

Минимаксный подход (англ. *minimax approach*) отказывается приписывать θ случайный характер и ориентируется на гарантию в наихудшем случае.

Определение 4.1 (Максимальный риск и минимаксное правило). *Максимальным риском* правила δ называется $\bar{R}(\delta) = \sup_{\theta \in \Theta} R(\delta, \theta)$. Правило δ^* называется *минимаксным*, если

$$\bar{R}(\delta^*) = \inf_{\delta} \bar{R}(\delta) =: R^*,$$

а величина R^* — *минимаксным риском*, или *значением игры*.

Прямая связь минимаксной постановки с байесовской даётся леммой о минимаксном неравенстве, теоремой о достаточном условии минимаксности и леммой о последовательности апприорных; последние две — рабочие инструменты проверки минимаксности конкретных оценок.

Лемма 4.2 (О минимаксном неравенстве). *Для любого апприорного распределения π и любого правила δ*

$$r^*(\pi) := \inf_{\delta'} r(\pi, \delta') \leq \sup_{\theta} R(\delta, \theta),$$

в частности $\sup_{\pi} r^*(\pi) \leq R^*$.

Доказательство. Для каждого δ' имеем $r(\pi, \delta') = \int R(\delta', \theta) \pi(d\theta) \leq \sup_{\theta} R(\delta', \theta)$. Берём нижнюю грань по δ' слева и инфимум по δ' справа. $\square$

Теорема 4.3 (Достаточное условие минимаксности). *Пусть δ_{π} — байесовское правило относительно апприорного распределения π и его риск всюду не превосходит байесовского риска:*

$$R(\delta_{\pi}, \theta) \leq r(\pi, \delta_{\pi}) \quad \text{для всех } \theta \in \Theta.$$

Тогда δ_{π} минимаксно и π — наименее благоприятное (англ. least favourable) апприорное распределение: $r^(\pi) = \sup_{\pi'} r^*(\pi') = R^*$. В частности, условию удовлетворяет всякое байесовское правило с постоянным риском $R(\delta_{\pi}, \theta) \equiv c$.*

Доказательство. Для любого правила δ' по лемме 4.2 и определению байесовского правила

$$\bar{R}(\delta') = \sup_{\theta} R(\delta', \theta) \geq r(\pi, \delta') \geq r(\pi, \delta_{\pi}).$$

С другой стороны, посылке $\bar{R}(\delta_{\pi}) = \sup_{\theta} R(\delta_{\pi}, \theta) \leq r(\pi, \delta_{\pi})$. Следовательно, $\bar{R}(\delta') \geq r(\pi, \delta_{\pi}) \geq \bar{R}(\delta_{\pi})$ для всех δ' , то есть δ_{π} минимаксно, и оба неравенства обращаются в равенства: $r(\pi, \delta_{\pi}) = \bar{R}(\delta_{\pi}) = R^*$. Тогда по лемме 4.2 $\sup_{\pi'} r^*(\pi') \leq R^* = r^*(\pi)$, то есть π наименее благоприятно. Если $R(\delta_{\pi}, \theta) \equiv c$, то $r(\pi, \delta_{\pi}) = c$, и посылка выполняется равенством. $\square$

Постоянство риска проверять удобно, но не обязательно; равномерного доминирования байесовского риска достаточно. Следующая лемма снимает требование, чтобы правило было в точности байесовским: достаточно быть пределом байесовских.

Лемма 4.4 (О последовательности апприорных распределений). *Пусть δ — правило, $\{\pi_k\}$ — последовательность апприорных распределений и*

$$R(\delta, \theta) \leq \liminf_{k \rightarrow \infty} r(\pi_k, \delta_{\pi_k}) \quad \text{для всех } \theta \in \Theta,$$

где δ_{π_k} — байесовское правило относительно π_k . Тогда δ минимаксно.

Доказательство. По лемме 4.2 для любого правила δ' и любого k

$$\bar{R}(\delta') \geq r(\pi_k, \delta') \geq r(\pi_k, \delta_{\pi_k}).$$

Переходя к нижнему пределу и используя посылку, получаем $\bar{R}(\delta') \geq R(\delta, \theta)$ для всех θ , то есть $\bar{R}(\delta') \geq \bar{R}(\delta)$ для всех δ' . $\square$

Пример 4.5 (Биномиальная модель: постоянный риск). Пусть $X_1, \dots, X_N$ — независимые, $X_k \sim \text{Bin}(1, \theta)$, $\theta \in [0, 1]$, потеря квадратичная. Рассмотрим линейную оценку

$$\delta(X) = a \bar{X}_N + b, \quad a = \frac{1}{1 + \frac{1}{\sqrt{N}}}, \quad b = \frac{1}{2(\sqrt{N} + 1)}.$$

Её риск как функция θ :

$$R(\delta, \theta) = \frac{a^2}{N} \theta(1 - \theta) + (b - (1 - a)\theta)^2 = \frac{\theta - \theta^2 + (\frac{1}{2} - \theta)^2}{(\sqrt{N} + 1)^2} = \frac{1}{4(\sqrt{N} + 1)^2},$$

поскольку $a^2/N = 1/(\sqrt{N} + 1)^2$ и $b = (1 - a)/2$. Риск постоянный. С другой стороны, при априорном распределении $\theta \sim \text{Beta}(\alpha, \alpha)$ апостериорное распределение $\theta | X$ имеет плотность $\propto \theta^{N\bar{X}_N + \alpha - 1} (1 - \theta)^{N(1 - \bar{X}_N) + \alpha - 1}$, то есть это $\text{Beta}(N\bar{X}_N + \alpha, N(1 - \bar{X}_N) + \alpha)$, и байесовская оценка — апостериорное среднее $\delta_\alpha(X) = \frac{N\bar{X}_N + \alpha}{N + 2\alpha}$. При $\alpha = \frac{\sqrt{N}}{2}$ она совпадает с $\delta(X)$. По теореме 4.3 оценка δ минимаксна, минимаксный риск равен $\frac{1}{4(\sqrt{N} + 1)^2}$, а априорное $\text{Beta}(\frac{\sqrt{N}}{2}, \frac{\sqrt{N}}{2})$ наименее благоприятно и *собственное* — максимум байесовского риска по априорным распределениям здесь достигается.

Пример 4.6 (Нормальное среднее: последовательность уходящих априорных). Пусть $X_1, \dots, X_N$ — независимые, $X_k \sim \mathcal{N}(\theta, \sigma^2)$, $\theta \in \mathbb{R}$, потеря квадратичная. Выборочное среднее $\bar{X}_N$ имеет постоянный риск $R(\bar{X}_N, \theta) = \sigma^2/N$, но не является байесовским ни для какого априорного распределения (при конечном τ в примере 3.8 байесовская оценка — сжатое среднее). Возьмём последовательность априорных распределений $\pi_k = \mathcal{N}(0, \tau_k^2)$ с $\tau_k \rightarrow \infty$. Байесовская оценка — сжатое среднее с коэффициентом $c_k = \frac{N\tau_k^2}{\sigma^2 + N\tau_k^2}$, и её байесовский риск равен средней апостериорной дисперсии (следствие 3.4):

$$r(\pi_k, \delta_{\pi_k}) = \mathbb{E} D(\theta | X) = \frac{\sigma^2 \tau_k^2}{\sigma^2 + N\tau_k^2} \xrightarrow{k \rightarrow \infty} \frac{\sigma^2}{N}.$$

По лемме 4.4 оценка $\bar{X}_N$ минимаксна, а равенство $\lim_k r(\pi_k, \delta_{\pi_k}) = \sigma^2/N = R(\bar{X}_N, \theta)$ показывает, что минимаксный риск $R^* = \sigma^2/N$. При этом наименее благоприятного априорного распределения не существует: для любого собственного π оценка $\bar{X}_N$ даёт $r^*(\pi) \leq r(\pi, \bar{X}_N) = \sigma^2/N$, поэтому $\sup_\pi r^*(\pi) = \sigma^2/N$ — супремум, не достигаемый ни на одном π . Значение игры совпадает с верхней гранью, но седловая точка — только предельная, при $\tau \rightarrow \infty$.

Два примера показывают обе стороны явления: при конечном Θ (биномиальном) наименее благоприятное априорное достигается, при бесконечном (нормальном) — только приближается. Общее основание даёт теорема фон Неймана: равенство $\min \max = \max \min$ в игре «статистик против природы».

Теорема 4.7 (Фон Неймана о седловой точке). Пусть $\Theta = \{\theta_1, \dots, \theta_m\}$ и $\mathcal{A}$ конечны. Тогда

$$R^* := \min_\delta \max_{\theta \in \Theta} R(\delta, \theta) = \max_\pi \min_\delta r(\pi, \delta) =: r^*(\pi^*),$$

где минимум берётся по всем рандомизированным правилам, максимум — по всем априорным распределениям π на Θ ; существуют минимаксное правило δ^* и априорное π^* , для которых

$$r(\pi, \delta^*) \leq r(\pi^*, \delta^*) \leq r(\pi^*, \delta) \quad \text{для всех } \pi, \delta,$$

то есть (δ^*, π^*) — седловая точка (англ. saddle point) байесовского риска, а π^* — наименее благоприятное априорное распределение.

Здесь минимум по правилам достигается (а не только инфимум) благодаря рандомизации: множество рандомизированных правил компактно, а риск — непрерывен и линеен по нему; максимум по π достигается, поскольку множество распределений на конечном Θ — симплекс. Полное доказательство — в расширенной части (теорема 10.3); для матричных игр, где $\mathcal{X}$ также конечно, тот же факт даёт двойственность линейного программирования [39].

Замечание 4.8 (Границы теоремы). Без конечности Θ равенство $\inf_{\delta} \sup_{\theta} = \sup_{\pi} \inf_{\delta}$ требует регулярности (компактности и непрерывности), и даже при равенстве значений максимум по π может не достигаться — пример 4.6; поиск минимаксного правила уже не сводится к конечной игре.

5 Детектирование как задача принятия решения

Частный, но важный случай: решение — выбор одной из конкурирующих гипотез. Пусть $\Theta = \{1, \dots, m\}$, гипотеза H_j : наблюдение X имеет плотность p_j относительно меры μ , $\mathcal{A} = \Theta$, $\rho(a, \theta) = \mathbb{I}\{a \neq \theta\}$. Решающее правило здесь — *детектор* (англ. detector); его риск в состоянии j — вероятность ошибки $P_j(\delta \neq j)$. Для бинарного случая $m = 2$ говорят о вероятности ложной тревоги $P_{fa} = P_0(\delta = 1)$ и пропуска $P_{fn} = P_1(\delta = 0)$.

Теорема 3.3 со следствием 3.6 немедленно дают два классических ответа.

Теорема 5.1 (Байесовский детектор). Пусть априорные вероятности гипотез π_j положительны. Байесовский детектор относительно π при потере 0-1 — МАР-детектор

$$\delta_{\pi}(x) = \arg \max_j p_j(x) \pi_j,$$

его байесовский риск — средняя вероятность ошибки $\sum_j \pi_j P_j(\delta_{\pi} \neq j)$. При равных $\pi_j = 1/m$ он совпадает с детектором максимального правдоподобия $\arg \max_j p_j(x)$ [39].

Теорема 5.2 (Минимаксный детектор). При конечном $\mathcal{X}$ минимаксный детектор $\delta^* \in \arg \min_{\delta} \max_j P_j(\delta \neq j)$ существует, а значение игры совпадает с максимумом байесовского риска по априорным распределениям по теореме 4.7. Если гипотезы симметричны (есть преобразование выборочного пространства, переводящее p_0 в p_1), то среди минимаксных детекторов есть детектор с равными вероятностями ошибок: $P_{fa} = P_{fn}$.

Доказательство. Существование — частный случай теоремы 4.7 (конечны Θ и $\mathcal{A}$). Пусть τ — симметрия: если $X \sim p_0$, то $\tau(X) \sim p_1$ и наоборот. Тогда для любого детектора δ детектор $\delta'(x) = 1 - \delta(\tau x)$ меняет ошибки местами, а их полусумма $\frac{1}{2}(\delta + \delta')$ (рандомизация «подбросить монету») имеет $P_{fa} = P_{fn} = \frac{1}{2}(P_{fa}(\delta) + P_{fn}(\delta)) \leq \max_j P_j(\delta \neq j)$. Значит, среди минимаксных детекторов есть детектор с равными ошибками, а его значение равно общему значению игры по теореме 4.7. $\square$

При потерях $W_{ij} \geq 0$ общего вида ($W_{jj} = 0$) байесовский детектор решает задачу $\min_a \sum_j W_{aj} p_j(x) \pi_j$ и в бинарном случае становится детектором отношения правдоподобия с порогом: $\delta(x) = 1$ тогда и только тогда, когда $p_1(x)/p_0(x) \geq \text{const}$, где const зависит от π и W [39]. Лемма Неймана — Пирсона из вопроса о проверке гипотез выбирает тот же порог из условия на вероятность ложной тревоги, а минимаксный детектор — из условия равенства ошибок: одно семейство детекторов обслуживает все три критерия. Если $\mathcal{X}$ конечно, байесовский и минимаксный детекторы находятся решением задачи линейного программирования [39]; пример 3 ноутбука считает трёхточечный случай аналитически и подтверждает равенство значений игры численно.

6 Байесовская оценка и регуляризация Тихонова

Байесовский взгляд объясняет происхождение регуляризующих слагаемых: они — логарифм априорной плотности.

Теорема 6.1 (MAP = регуляризация Тихонова). Пусть линейная модель $Y = A\theta + \varepsilon$ с $\varepsilon \sim \mathcal{N}(0, \sigma^2 I_m)$ и априорное распределение $\theta \sim \mathcal{N}(0, \tau^2 I_n)$, причём матрица $A^\top A + \frac{\sigma^2}{\tau^2} I_n$ обратима. Тогда апостериорное распределение нормально с математическим ожиданием

$$\mathbb{E}(\theta | Y) = \left(A^\top A + \frac{\sigma^2}{\tau^2} I_n \right)^{-1} A^\top Y,$$

которое совпадает с минимизатором регуляризованного функционала Тихонова

$$\min_{\theta} \|A\theta - Y\|^2 + \frac{\sigma^2}{\tau^2} \|\theta\|^2,$$

то есть MAP-оценкой при квадратичной потере.

Доказательство. Логарифм апостериорной плотности с точностью до аддитивной константы равен

$$-\frac{1}{2\sigma^2} \|Y - A\theta\|^2 - \frac{1}{2\tau^2} \|\theta\|^2.$$

Выделим в первом слагаемом полный квадрат по θ . Для любого z имеем $\|Y - A\theta\|^2 = \|(Y - Az) - A(\theta - z)\|^2$; раскрывая квадрат и группируя линейное по $\theta - z$ слагаемое, получаем, что логарифм апостериорной плотности с точностью до константы есть

$$-\frac{1}{2}(\theta - \mu)^\top \left(\frac{A^\top A}{\sigma^2} + \frac{I_n}{\tau^2} \right) (\theta - \mu), \quad \mu = \left(A^\top A + \frac{\sigma^2}{\tau^2} I_n \right)^{-1} A^\top Y,$$

то есть апостериорное распределение $\mathcal{N}(\mu, \sigma^2 \tau^2 (\tau^2 A^\top A + \sigma^2 I_n)^{-1})$. По следствию 3.4 байесовская оценка при квадратичной потере — μ . С другой стороны, μ — стационарная точка (и, в силу строгой выпуклости, единственный минимизатор) функционала: градиент $2A^\top(A\theta - Y) + 2\frac{\sigma^2}{\tau^2}\theta$ обращается в нуль при $\theta = \mu$. $\square$

Замечание 6.2 (Что это даёт обратным задачам). Теорема связывает три вопроса программы. Обратная задача $A\theta = Y$ с гауссовым шумом некорректна из-за неустойчивости псевдорешения к ошибкам в Y ; регуляризация Тихонова поправляет её вырожденность. Теорема 6.1 показывает: регуляризатор $\frac{\sigma^2}{\tau^2} \|\theta\|^2$ — это априорное предположение « θ невелико», а параметр регуляризации есть отношение дисперсий шума и априорного разброса. Помехоустойчивость (выбор потери Хьюбера) и минимаксные гарантии — два других, не байесовских способа обосновать ту же поправку; вопросы про обратные задачи, регрессии и робастное оценивание развивают их.

7 Вычислительная сторона

Байесовская оценка при квадратичной потере требует апостериорного среднего. Три рабочих случая:

1. **Сопряжённые априорные распределения:** апостериорное семейство замкнуто (нормальное — пример 3.8, бета-распределение — пример 4.5); апостериорное среднее — по формуле. Подходит, когда правдоподобие — экспоненциального типа с конечномерной достаточной статистикой.

2. **Лапласова аппроксимация:** максимизируем логарифм апостериорной плотности (MAP), гессиан в максимуме даёт обратную ковариационную матрицу нормальной аппроксимации; апостериорное среднее функции параметра — интеграл по ней (для $R_0 = \beta/\gamma$ в SIR-примере — пример 1 ноутбука). Работает при унимодальном апостериорном распределении и среднем числе параметров.
3. **Методы Монте-Карло по апостериорному распределению** (Метрополис — Гастингс, гиббсовская выборка): для сложных апостериорных ландшафтов; оценка — выборочное среднее цепи. Дороже, но не требует гладкости и унимодальности.

Минимаксное правило не строится оптимизацией по θ напрямую (это бесконечномерная минимизация по δ с внутренним супремумом). Рабочие приёмы: поиск байесовского правила с постоянным риском (теорема 4.3) — примеры 4.5, 4.6; двойственные оценки через последовательность априорных (лемма 4.4); для детекторов — конечные ЛП [39].

Где работает конструкция.

Постановка	Потеря	Оптимальное правило	Что покупается
Оценка параметра (МНК, Тихонов)	квадратичная	апостериорное среднее; MAP = регуляризованное решение	точность в среднем по априорному распределению
Робастное оценивание, медианный фильтр	абсолютная	апостериорная медиана	устойчивость к выбросам (плата — гладкость)
Помехоустойчивое оценивание	Хьюбера	винзоризованное апостериорное среднее	устойчивость к выбросам при гладкости в полосе
Классификация, проверка гипотез	0-1, матрица потерь W	MAP / минимаксный детектор	минимальная средняя вероятность ошибки / гарантия
Квантильная регрессия	квантильная (Винцента)	квантиль апостериорного распределения	интервальное прогнозирование
Оценивание без априорного распределения	квадратичная	минимаксное правило (постоянный риск)	гарантия в наихудшем случае

8 Разобранные задачи

Задача 8.1 (Минимаксная оценка среднего нормального закона). $X_1, \dots, X_N$ независимы, $X_k \sim \mathcal{N}(\theta, \sigma^2)$, σ^2 известно, $\theta \in \mathbb{R}$ неизвестно, потеря квадратичная. Доказать, что $\bar{X}_N$ — минимаксная оценка θ и найти минимаксный риск.

Решение. Риск $\bar{X}_N$ постоянен: $R(\bar{X}_N, \theta) = D\bar{X}_N = \sigma^2/N$. Прямое применение теоремы 4.3 невозможно: $\bar{X}_N$ не байесовское ни для какого собственного априорного распределения. Возьмём $\pi_k = \mathcal{N}(0, \tau_k^2)$ с $\tau_k \rightarrow \infty$ (пример 3.8). Байесовский риск сжатого среднего $\delta_k = c_k \bar{X}_N$ с $c_k = \frac{N\tau_k^2}{\sigma^2 + N\tau_k^2}$ равен средней апостериорной дисперсии:

$$r(\pi_k, \delta_k) = \frac{\sigma^2 \tau_k^2}{\sigma^2 + N\tau_k^2} \rightarrow \frac{\sigma^2}{N}.$$

По лемме 4.4 $\bar{X}_N$ минимаксна; минимаксный риск $R^* = \sigma^2/N$, так как сверху его оценивает риск $\bar{X}_N$, а снизу — предел байесовских рисков. Наименее благоприятного априорного распределения нет: $\sup_{\pi} r^*(\pi) = \sigma^2/N$, но достигается только предельно: у последовательности $\mathcal{N}(0, \tau_k^2)$ с $\tau_k \rightarrow \infty$ нет предела среди собственных распределений на прямой.

Задача 8.2 (Байесовский и минимаксный детекторы на трёхточечном пространстве). Наблюдение X принимает три значения. Простые гипотезы: $H_0: P_0(X = k) = p_k$, $H_1: P_1(X = k) = q_k$ с

$$p = \left(\frac{1}{2}, \frac{3}{10}, \frac{1}{5}\right), \quad q = \left(\frac{1}{5}, \frac{3}{10}, \frac{1}{2}\right).$$

Потеря 0-1. Найти байесовский детектор для равных априорных вероятностей, байесовский риск как функцию априорной вероятности $\pi = P(H_1)$ и минимаксный детектор.

Решение. По следствию 3.6 байесовский детектор для априорных $(1 - \pi, \pi)$ выбирает H_1 на значениях, где $\pi q_k \geq (1 - \pi)p_k$. Точки переключения: для $k = 3$ неравенство $\pi/2 \geq (1 - \pi)/5$ даёт $\pi \geq 2/7$; для $k = 2$ — $\pi \geq 1/2$; для $k = 1$ — $\pi \geq 5/7$. Средняя вероятность ошибки (байесовский риск)

$$r^*(\pi) = \begin{cases} \pi, & 0 \leq \pi \leq \frac{2}{7}, \\ \frac{1}{5} + \frac{3}{10}\pi, & \frac{2}{7} \leq \pi \leq \frac{1}{2}, \\ \frac{1}{2} - \frac{3}{10}\pi, & \frac{1}{2} \leq \pi \leq \frac{5}{7}, \\ 1 - \pi, & \frac{5}{7} \leq \pi \leq 1. \end{cases}$$

При равных априорных $\pi = 1/2$ обе ошибки равны $7/20$: байесовский детектор при $\pi = 1/2$ выбирает H_0 на $k = 1$, H_1 на $k = 3$, а на $k = 2$ (равенство $\pi q_2 = (1 - \pi)p_2$) рандомизирует с вероятностью $1/2$; его максимальный риск равен байесовскому риску $7/20$: риск не зависит от π (правило зафиксировано), вектор риска $(7/20, 7/20)$ постоянен по θ (обе ошибки равны), поэтому $\bar{R} = 7/20 = r(\pi, \delta)$ при $\pi = 1/2$. По теореме 4.3 этот детектор минимаксен, $\pi = 1/2$ — наименее благоприятное априорное распределение, значение игры равно $7/20$; максимум байесовского риска по π достигается в $\pi = 1/2$ и равен той же величине — равенство из теоремы 4.7 проверено на конечной игре прямым счётом (пример 3 ноутбука воспроизводит его численно).

9 Что спросят

- **Частотный или байесовский доверительный интервал?** Частотный интервал — правило, покрывающее θ с вероятностью γ до эксперимента; байесовский — случайная область под апостериорной плотностью. Совпадают по форме в сопряжённых моделях; расходятся по трактовке и в малых выборках.
- **Какая потеря и почему?** Квадратичная — гладкость и МНК; абсолютная и Хьюбера — робастность; 0-1 — классификация и гипотезы; квантильная — прогноз интервалов. Потеря определяет и оптимальное правило (следствия 3.4–3.6).
- **Когда байесовское правило минимаксно?** Когда его риск постоянен или не превосходит байесовского риска (теорема 4.3); если байесовского правила с постоянным риском нет — искать предел по априорным (лемма 4.4, пример 4.6).
- **Почему минимакс осторожнее байеса?** Он минимизирует худший случай, поэтому риск сжатой оценки растёт вне априорного центра, а минимаксное правило выравнивает риск по Θ ; плата — меньшая точность «в среднем».
- **Откуда отношение правдоподобия?** Из байесовского правила при потере 0-1: порог зависит от априорных и потерь; лемма Неймана — Пирсона переносит тот же порог на критерий с заданным размером (соседний вопрос).
- **Что даёт рандомизация?** Выпуклость класса правил: без неё минимаксное правило в конечных играх может не существовать (пример 3 ноутбука: детерминированные детекторы дают значение игры $1/2$, рандомизированный — $7/20$).
- **Что без априорного распределения?** Минимаксный критерий; он же — предельный случай байесовского при размытии априорного (пример 4.6).

10 Расширенная часть

Здесь — полное доказательство теоремы фон Неймана и два приложения. Что использовано без воспроизведения: теорема Тонелли (нужна для перестановки порядка интегрирования

в теореме 3.3) и неравенство Йенсена (однострочное применение в теореме Рао — Блэкуэлла); проекция точки на замкнутое выпуклое множество евклидова пространства (доказательство леммы об отделении приведено полностью); критерий факторизации достаточных статистик (вопрос про интервальное оценивание и проверку гипотез; [06], [07]).

10.1 Отделение и минимакс

Лемма 10.1 (Об отделении точки от открытого выпуклого множества). Пусть $C \subset \mathbb{R}^m$ выпукло и открыто и $0 \notin C$. Тогда существует $q \in \mathbb{R}^m$, $q \neq 0$, такой что $\langle q, c \rangle > 0$ для всех $c \in C$.

Доказательство. Если $0 \notin \bar{C}$, выберем в $\bar{C}$ точку p , ближайшую к 0: она существует, так как расстояние до замкнутого множества достигается на его пересечении с компактным шаром $\bar{B}(0, \|c_0\|)$ для любой фиксированной $c_0 \in C$. Тогда $p \neq 0$, и для всякой точки $x \in \bar{C}$ и всех $t \in [0, 1]$ точка $(1-t)p + tx$ лежит в $\bar{C}$ (выпуклость), и минимальность расстояния даёт

$$\|(1-t)p + tx\|^2 \geq \|p\|^2 \implies 2t\langle p, x-p \rangle + t^2\|x-p\|^2 \geq 0.$$

При $t \downarrow 0$ получаем $\langle p, x \rangle \geq \|p\|^2 > 0$ для всех $x \in \bar{C}$. Берём $q = p$.

Остаётся случай $0 \in \bar{C} \setminus C$ (то есть $0 \in \partial C$). Всякий шар $B(0, \varepsilon)$ содержит точку вне $\bar{C}$: иначе 0 была бы внутренней точкой $\bar{C}$, а внутренность замыкания открытого выпуклого множества совпадает с самим множеством — тогда $0 \in C$, противоречие. Выберем $a_n \notin \bar{C}$, $a_n \rightarrow 0$. Каждую точку a_n отделяем от $\bar{C}$ так же, как в первом случае: ближайшая к a_n точка $p_n \in \bar{C}$ существует, для $q_n = (p_n - a_n)/\|p_n - a_n\|$ имеем $\|q_n\| = 1$ и при $t \downarrow 0$

$$\|(1-t)p_n + tx - a_n\|^2 \geq \|p_n - a_n\|^2 \implies \langle q_n, x - a_n \rangle \geq \|p_n - a_n\| > 0 \quad \text{для всех } x \in \bar{C}.$$

По компактности единичной сферы $q_{n_k} \rightarrow q$, $\|q\| = 1$; в пределе (правая часть неотрицательна) получаем $\langle q, x \rangle \geq 0$ для всех $x \in \bar{C}$. Строгость на C : если $\langle q, c \rangle = 0$ для некоторого $c \in C$, то $c+h \in C$ и $c-h \in C$ для всех достаточно малых h , значит $\langle q, h \rangle \geq 0$ и $-\langle q, h \rangle \geq 0$ одновременно, то есть $\langle q, h \rangle = 0$ для всех малых h и $q = 0$ — противоречие. Итак, $\langle q, c \rangle > 0$ для всех $c \in C$. $\square$

Лемма 10.2 (Минимаксное равенство для платёжной матрицы). Пусть $M \in \mathbb{R}^{n \times m}$ — произвольная матрица. Тогда

$$\min_{u \in \Delta_n} \max_{\pi \in \Delta_m} \langle \pi, Mu \rangle = \max_{\pi \in \Delta_m} \min_{u \in \Delta_n} \langle \pi, Mu \rangle,$$

где $\Delta_r = \{v \in \mathbb{R}^r : v_i \geq 0, \sum_i v_i = 1\}$ — симплекс, и обе экстремальные точки существуют.

Доказательство. Правая часть не превосходит левой: для любых u, π $\min_{u'} \langle \pi, Mu' \rangle \leq \langle \pi, Mu \rangle \leq \max_{\pi'} \langle \pi', Mu \rangle$, остаётся взять экстремумы. Обозначим $v = \min_{u \in \Delta_n} \max_{\pi \in \Delta_m} \langle \pi, Mu \rangle$; так как $\max_{\pi \in \Delta_m} \langle \pi, Mu \rangle = \max_i (Mu)_i$ (максимум линейной функции по симплексу достигается в вершине) и $u \mapsto \max_i (Mu)_i$ непрерывна на компактном симплексе, минимум достигается. Множество $T = \{Mu : u \in \Delta_n\} - v\mathbf{1}$ — сдвинутый образ симплекса: выпуклая оболочка n точек, компакт и выпукло. По определению v всякая точка Mu имеет хотя бы одну координату $\geq v$, поэтому открытый органт $P = \{z : z_i < 0 \forall i\}$ не пересекается с T ; тогда $C = P - T$ — открытое выпуклое множество, не содержащее 0. По лемме 10.1 найдётся $q \neq 0$ с $\langle q, p-t \rangle > 0$ для всех $p \in P, t \in T$. Если какая-то координата q_j положительна, то уходя $p_j \rightarrow -\infty$ (координаты P неограничены снизу), получаем противоречие с конечностью $\langle q, t \rangle$; значит $q \leq 0$, $q \neq 0$, и $\pi^* = -q/\sum_i (-q_i) \in \Delta_m$. Неравенство $\langle q, p \rangle > \langle q, t \rangle$ переписывается как $\langle \pi^*, p \rangle < \langle \pi^*, t \rangle$; устремляя $p = -\varepsilon\mathbf{1} \rightarrow 0$ по координатам, получаем $\langle \pi^*, t \rangle \geq 0$ для всех $t \in T$, то есть $\langle \pi^*, Mu \rangle \geq v$ для всех $u \in \Delta_n$.

Тогда $\min_{u \in \Delta_n} \langle \pi^*, Mu \rangle \geq v$, и правая часть не меньше левой. Вместе с уже доказанным неравенством получаем равенство; максимум по π достигнут в π^* . $\square$

Теорема 10.3 (Фон Неймана: доказательство). Пусть $\Theta = \{\theta_1, \dots, \theta_m\}$ и $\mathcal{A}$ конечны, а $\mathcal{X}$ не более чем счётно. Тогда

$$\min_{\delta} \max_{\theta} R(\delta, \theta) = \max_{\pi} \min_{\delta} r(\pi, \delta),$$

где слева минимум по рандомизированным правилам, справа — по априорным распределениям π на Θ ; обе экстремальные точки существуют и дают седловую точку байесовского риска.

Доказательство. Сведение к платёжной матрице при конечном $\mathcal{X}$. Если $\mathcal{X}$ конечно, чистых правил $\delta: \mathcal{X} \rightarrow \mathcal{A}$ конечно; пронумеруем их и положим $M_{ji} = R(\delta_j, \theta_i)$. Смешанная стратегия $u \in \Delta_n$ — это рандомизированное правило $\delta_u(\cdot | x) = \sum_j u_j \mathbb{I}\{\delta_j(x) = \cdot\}$, и $\langle \pi, Mu \rangle = r(\pi, \delta_u)$: матричная минимаксная лемма 10.2 даёт равенство, а её экстремальные точки — минимаксное правило и наименее благоприятное априорное.

Общий случай: компактность множества рисков. Пусть $\mathcal{A} = \{a_1, \dots, a_r\}$. Каждое рандомизированное правило — измеримое отображение $x \mapsto (\delta(a_1 | x), \dots, \delta(a_r | x))$ в симплекс Δ_r ; обозначим $\mathcal{D}$ множество всех таких отображений с поточечной (покоординатной) сходимостью. Симплекс Δ_r компактен, поэтому произведение $\Delta_r^{\mathcal{X}}$ компактно (теорема Тихонова о произведении компактов), а $\mathcal{D} \subseteq \Delta_r^{\mathcal{X}}$ замкнуто: при счётном $\mathcal{X}$ поточечная топология метризуема (например, $d(\delta, \delta') = \sum_n 2^{-n} \|\delta(\cdot | x_n) - \delta'(\cdot | x_n)\|_1$), поэтому замыкание описывается пределами последовательностей, а поточечный предел измеримых функций измерим. Отображение $\delta \mapsto R(\delta, \theta_i)$ непрерывно: при поточечной сходимости $\delta_\alpha(\cdot | x) \rightarrow \delta(\cdot | x)$ интегрант в

$$R(\delta, \theta_i) = \int_{\mathcal{X}} \sum_{j=1}^r \rho(a_j, \theta_i) \delta(a_j | x) p_i(x) \mu(dx)$$

сходится поточечно по x и ограничен константой $\max_{j,i} \rho(a_j, \theta_i)$, поэтому по лемме о мажорируемой сходимости интегралы сходятся. Множество рисков $S = \{(R(\delta, \theta_1), \dots, R(\delta, \theta_m)) : \delta \in \mathcal{D}\}$ — непрерывный образ компакта, компактно; оно выпукло: смешение правил $\lambda \delta_1 + (1 - \lambda) \delta_2$ (покоординатное по симплексу) даёт риск $\lambda R(\delta_1, \cdot) + (1 - \lambda) R(\delta_2, \cdot)$.

Положим $w := \min_{s \in S} \max_i s_i$; минимум достигается, так как S компактно, а функция $s \mapsto \max_i s_i$ непрерывна. По построению $w = \inf_{\delta} \max_{\theta} R(\delta, \theta) = R^*$, и минимум достигается в некотором $s^* = R(\delta^*, \cdot)$, то есть δ^* — минимаксное правило. Множество $P = \{z \in \mathbb{R}^m : z_i < w \ \forall i\}$ — открытый ортант; $P \cap S = \emptyset$ по определению w . Множество $C = P - S$ открыто (сумма открытого множества с любым множеством) и выпукло: для $c_i = p_i - s_i$, $i = 1, 2$, и $\lambda \in (0, 1)$

$$\lambda c_1 + (1 - \lambda) c_2 = (\lambda p_1 + (1 - \lambda) p_2) - (\lambda s_1 + (1 - \lambda) s_2) \in P - S$$

по выпуклости P и S ; при этом $0 \notin C$. По лемме 10.1 найдётся $q \neq 0$ с $\langle q, c \rangle > 0$ для всех $c \in C$; поскольку P неограничен снизу по каждой координате, отсюда $q \leq 0$ (иначе $\langle q, p \rangle \rightarrow -\infty$ при $p_j \rightarrow -\infty$, что противоречит $\langle q, p \rangle > \langle q, s \rangle$), и $\pi^* = -q / \sum_i (-q_i) \in \Delta_m$. Тогда $\langle \pi^*, s \rangle \geq w$ для всех $s \in S$: для $p = w \mathbf{1} - \varepsilon \mathbf{1} \in P$ неравенство $\langle \pi^*, p \rangle < \langle \pi^*, s \rangle$ даёт $\langle \pi^*, s \rangle > w - \varepsilon$ при каждом $\varepsilon > 0$, значит $\langle \pi^*, s \rangle \geq w$. То есть

$$r(\pi^*, \delta) \geq w \quad \text{для всех } \delta, \quad \text{в частности } \inf_{\delta} r(\pi^*, \delta) \geq w.$$

С другой стороны, для $v := \sup_{\pi \in \Delta_m} \inf_{\delta} r(\pi, \delta)$ лемма 4.2 даёт $v \leq R^* = w$, а по определению супремума $\inf_{\delta} r(\pi^*, \delta) \leq v$. Значит, $v = w = R^*$, и максимум по π достигается в π^* . Наконец, $v = r(\pi^*, \delta^*) \leq r(\pi^*, \delta)$ для всех δ (так как $r(\pi^*, \delta) \geq w$), а $r(\pi^*, \delta^*) = \langle \pi^*, s^* \rangle \leq \max_i s_i^* = w$ для всех π — это и есть седловая точка. $\square$

Замечание 10.4 (Счётность $\mathcal{X}$ существенна). При несчётном $\mathcal{X}$ поточечная топология на $\Delta_r^{\mathcal{X}}$ неметризуема: замыкание $\mathcal{D}$ перестаёт описываться пределами последовательностей (в него попадают, в частности, неизмеримые функции), и компактность множества рисков этим аргументом не обосновывается. Равенство при этом остаётся верным: та же схема проходит в слабой топологии $\sigma(L^\infty(\mu), L^1(\mu))$ — единичный шар слабо компактен (Алаоглу — Банах), $\mathcal{D}$ слабо замкнуто, а риск слабо непрерывен, так как плотности p_i интегрируемы. В приложениях вопроса $\mathcal{X}$ конечно, поэтому слабая топология не понадобилась.

Замечание 10.5 (Второй путь: двойственность ЛП). При конечном $\mathcal{X}$ равенство леммы 10.2 — это сильная двойственность пары линейных программ $\min\{t : (Mu)_i \leq t \ \forall i, u \in \Delta_n\}$ и $\max\{s : (\pi^T M)_j \geq s \ \forall j, \pi \in \Delta_m\}$ [39]; та же пара программ описывает матричные игры (смешанные стратегии платящего и получающего игроков), и равенство их значений — теорема фон Неймана — Моргенштерна [39]. Разделяющая гиперплоскость и двойственность ЛП — два лица одного факта.

10.2 Рао — Блэкуэлл: улучшение через достаточную статистику

Определение 10.6 (Достаточная статистика). Статистика $T = T(X)$ называется *достаточной* (англ. *sufficient statistic*) для семейства $\{P_\theta\}$, если условное распределение X при условии $T(X) = t$ не зависит от θ . Эквивалентная проверка — критерий факторизации: для доминируемого семейства с плотностями p_θ статистика T достаточна тогда и только тогда, когда $p_\theta(x) = g_\theta(T(x)) h(x)$ для неотрицательных измеримых функций g_θ и h [06], [07].

Теорема 10.7 (Рао — Блэкуэлл). Пусть T — достаточная статистика, $\mathcal{A} \subseteq \mathbb{R}^d$ выпукло и $\rho(\cdot, \theta)$ выпукла на $\mathcal{A}$ для каждого θ . Тогда для всякого правила δ с $E_\theta \|\delta(X)\| < \infty$ правило $\delta^*(t) = E_\theta[\delta(X) | T(X) = t]$ корректно определено (не зависит от θ) и

$$R(\delta^*, \theta) \leq R(\delta, \theta) \quad \text{для всех } \theta \in \Theta.$$

Доказательство. Независимость δ^* от θ — прямая перефразировка определения 10.6: условное распределение X при $T = t$ одно для всех θ , поэтому и условное среднее $E_\theta[\delta(X) | T = t]$ одно. По неравенству Йенсена для выпуклой $\rho(\cdot, \theta)$:

$$\rho(\delta^*(t), \theta) = \rho(E_\theta[\delta(X) | T = t], \theta) \leq E_\theta[\rho(\delta(X), \theta) | T = t].$$

Берём математическое ожидание по t относительно распределения $T(X)$ (закон полного математического ожидания — вопрос про случайные величины и корреляционную теорию):

$$R(\delta^*, \theta) = E_\theta \rho(\delta^*(T), \theta) \leq E_\theta \rho(\delta(X), \theta) = R(\delta, \theta). \quad \square$$

Замечание 10.8 (Что даёт теорема). Если есть достаточная статистика, искать хорошие правила нужно среди функций T : любое правило улучшается усреднением по достаточной статистике, а усреднение не увеличивает риск. Для квадратичной потери усреднение — ортогональная проекция (связь с геометрией условного ожидания); ровно так устроено улучшение оценок в задачах с достаточными статистиками в соседних вопросах программы.

10.3 Минимакс и оптимальное восстановление

Минимаксный критерий — не только статистический. В теории приближения та же постановка называется *оптимальным восстановлением* (англ. *optimal recovery*): по наблюдению $y = Kx + z$ с $x \in X$ (выпуклое множество) и шумом z восстановить значение линейного функционала $L(x)$, гарантируя наихудший случай по x и z . Связь измерена точно [57]:

- пусть $\omega(\varepsilon) = \sup\{|L(x_1) - L(x_2)| : \|K(x_1 - x_2)\| \leq \varepsilon, x_1, x_2 \in X\}$ — модуль непрерывности L по наблюдательной полунорме (англ. *modulus of continuity*); тогда для квадратичного риска статистического оценивания (гауссовский шум с дисперсией σ^2)

$$\nu_N(\tfrac{1}{2}, 1) \omega^2(\sigma) \leq R_N^*(\sigma) \leq R_A^*(\sigma) \leq \tfrac{1}{4} \omega^2(2\sigma),$$

где R_N^*, R_A^* — минимаксный риск по всем и по аффинным оценкам, а $\nu_N(\tfrac{1}{2}, 1)$ (в [57] обозначается $\rho_N(\tfrac{1}{2}, 1)$) — минимаксный риск ограниченного нормального среднего на отрезке $[-\tfrac{1}{2}, \tfrac{1}{2}]$;

- для самого оптимального восстановления (детерминистический шум $\|z\| \leq \varepsilon$) минимаксная ошибка равна $E^*(\varepsilon) = \omega(2\varepsilon)/2$, причём $(E_A^*(\sigma))^2/4 \leq R_A^*(\sigma) \leq (E_A^*(\sigma))^2$: статистическая задача при калибровке уровней шума совпадает с детерминистической с точностью до константы;
- при чистом показателе $\omega(\varepsilon) = A\varepsilon^r$ константа сходимости аффинного минимаксного риска выписывается явно: $R_A^*(\sigma) = 2^{2r-2}r^r(1-r)^{1-r}\omega^2(\sigma)(1+o(1))$ при $\sigma \rightarrow 0$ [57];
- для оценивания *целого объекта* в равномерной норме аналогичная связь восстанавливается через псевдо-уровень шума $\tilde{\rho} = \sqrt{2\gamma \log(1/\varepsilon)}\varepsilon$ и даёт асимптотический минимаксный риск через решение той же задачи оптимального восстановления [59].

Значение для программы: скорость минимаксного оценивания по шумным данным — свойство *модуля непрерывности* восстанавливаемой величины, а не выбранной оценки; задача о наилучшем равномерном приближении и сплайн-аппроксимация (соседние вопросы) дают тот же язык. Оговорки измерены: связь с модулем верна для линейных функционалов и не переносится на оценивание целого объекта в L_2 -норме [57].