Случайные величины и векторы. Элементы корреляционной теории

Вопрос 08

Крохалев Е. М.

2026

Постановка

Зачем сводить распределение к двум моментам

Полное описание случайного вектора — распределение, то есть мера на $\mathcal{B}(\mathbb{R}^n)$. Пользоваться им напрямую почти никогда не удаётся: это функция n переменных, и по данным её не оценить уже при $n = 5$.

Зачем сводить распределение к двум моментам

Полное описание случайного вектора — распределение, то есть мера на $\mathcal{B}(\mathbb{R}^n)$. Пользоваться им напрямую почти никогда не удаётся: это функция n переменных, и по данным её не оценить уже при $n = 5$.

Корреляционной теорией (англ. *second-order theory*) называется теория, основанная на изучении моментов первого и второго порядка. Вместо распределения берётся пара

$$a = \mathsf{E}\xi, \qquad \Gamma = \mathsf{E}(\xi - a)(\xi - a)^{\mathsf{T}}.$$

Зачем сводить распределение к двум моментам

Полное описание случайного вектора — распределение, то есть мера на $\mathcal{B}(\mathbb{R}^n)$. Пользоваться им напрямую почти никогда не удаётся: это функция n переменных, и по данным её не оценить уже при $n = 5$.

Корреляционной теорией (англ. *second-order theory*) называется теория, основанная на изучении моментов первого и второго порядка. Вместо распределения берётся пара

$$a = \mathsf{E}\xi, \qquad \Gamma = \mathsf{E}(\xi - a)(\xi - a)^{\mathsf{T}}.$$

Это сделка, и вопрос целиком — о том, что в ней покупается и чем платится.

Три вопроса

Какие пары «вектор — матрица» бывают ковариационными? Ответ полный: ровно симметричные неотрицательно определённые, и никаких других условий.

Три вопроса

Какие пары «вектор — матрица» бывают ковариационными? Ответ полный: ровно симметричные неотрицательно определённые, и никаких других условий.

Что по двум моментам можно посчитать, не зная распределения? Дисперсию любой линейной комбинации, наилучший линейный прогноз и его точность, главные оси рассеяния, оценку вероятности большого уклонения.

Три вопроса

Какие пары «вектор — матрица» бывают ковариационными? Ответ полный: ровно симметричные неотрицательно определённые, и никаких других условий.

Что по двум моментам можно посчитать, не зная распределения? Дисперсию любой линейной комбинации, наилучший линейный прогноз и его точность, главные оси рассеяния, оценку вероятности большого уклонения.

Когда двух моментов хватает полностью? Ровно в гауссовском случае: там распределение определяется парой (a, Γ), некоррелированность равносильна независимости, а наилучший прогноз линеен.

Сквозной пример: два датчика

Две системы дают оценки одной величины μ:

$$\eta_1 = \mu + \varepsilon_1, \qquad \eta_2 = \mu + \varepsilon_2,$$

погрешности имеют нулевые средние, дисперсии σ_1^2, σ_2^2 и коэффициент корреляции r.
Корреляция не надуманная: общий дрейф температуры входит в обе погрешности.

Сквозной пример: два датчика

Две системы дают оценки одной величины μ:

$$\eta_1 = \mu + \varepsilon_1, \qquad \eta_2 = \mu + \varepsilon_2,$$

погрешности имеют нулевые средние, дисперсии σ_1^2, σ_2^2 и коэффициент корреляции r. Корреляция не надуманная: общий дрейф температуры входит в обе погрешности.

Спрашивается, как объединить два показания. Ответ окажется содержательнее, чем можно ожидать: **корреляция — это информация, а не только помеха.**

Определения

Случайная величина и случайный вектор

Всюду $(\Omega, \mathcal{F}, \mathsf{P})$ — вероятностное пространство, $\mathcal{B}(\mathbb{R}^n)$ — борелевская σ-алгебра на $\mathbb{R}^n$, $\xi^\circ = \xi - \mathsf{E}\xi$ — центрирование; запись $A \succeq B$ значит, что $A - B$ симметрична и неотрицательно определена.

Определение 1 (случайный вектор)

Случайным вектором (англ. *random vector*) размерности n называется измеримое отображение $\xi\colon \Omega \to \mathbb{R}^n$, то есть такое, что $\xi^{-1}(B) \in \mathcal{F}$ при всех $B \in \mathcal{B}(\mathbb{R}^n)$. При $n = 1$ он называется **случайной величиной** (англ. *random variable*). **Распределением** вектора ξ называется мера $F_\xi(B) = \mathsf{P}\{\xi \in B\}$ на $\mathcal{B}(\mathbb{R}^n)$, **функцией распределения** — функция

$$F_\xi(x_1, \dots, x_n) = \mathsf{P}\{\xi_1 \le x_1, \dots, \xi_n \le x_n\}.$$

Случайная величина и случайный вектор

Всюду $(\Omega, \mathcal{F}, \mathsf{P})$ — вероятностное пространство, $\mathcal{B}(\mathbb{R}^n)$ — борелевская σ-алгебра на $\mathbb{R}^n$, $\xi^\circ = \xi - \mathsf{E}\xi$ — центрирование; запись $A \succeq B$ значит, что $A - B$ симметрична и неотрицательно определена.

Определение 1 (случайный вектор)

Случайным вектором (англ. *random vector*) размерности n называется измеримое отображение $\xi\colon \Omega \to \mathbb{R}^n$, то есть такое, что $\xi^{-1}(B) \in \mathcal{F}$ при всех $B \in \mathcal{B}(\mathbb{R}^n)$. При $n = 1$ он называется **случайной величиной** (англ. *random variable*). **Распределением** вектора ξ называется мера $F_\xi(B) = \mathsf{P}\{\xi \in B\}$ на $\mathcal{B}(\mathbb{R}^n)$, **функцией распределения** — функция

$$F_\xi(x_1, \dots, x_n) = \mathsf{P}\{\xi_1 \le x_1, \dots, \xi_n \le x_n\}.$$

Теорема 2 (критерий измеримости по компонентам)

Отображение $\xi = (\xi_1, \dots, \xi_n)^\mathsf{T}$ из Ω в $\mathbb{R}^n$ является случайным вектором тогда и только тогда, когда каждая его компонента ξ_k является случайной величиной.

Схема доказательства критерия

Класс множеств с измеримым прообразом — σ-алгебра: прообраз перестановочен с дополнением и со счётным объединением.

Схема доказательства критерия

Класс множеств с измеримым прообразом — σ-алгебра: прообраз перестановочен с дополнением и со счётным объединением.

Он содержит параллелепипеды $\prod_k (-\infty, x_k]$, потому что прообраз такого множества есть $\bigcap_k \{\xi_k \le x_k\}$.

Схема доказательства критерия

Класс множеств с измеримым прообразом — σ-алгебра: прообраз перестановочен с дополнением и со счётным объединением.

Он содержит параллелепипеды $\prod_k (-\infty, x_k]$, потому что прообраз такого множества есть $\bigcap_k \{\xi_k \le x_k\}$.

А параллелепипеды порождают $\mathcal{B}(\mathbb{R}^n)$.

Функция распределения

Теорема 3 (свойства функции распределения и обратная теорема)

Пусть ξ — случайная величина. Тогда её функция распределения $F = F_\xi$

1. *не убывает;*
2. *удовлетворяет $\lim_{x\to-\infty} F(x) = 0$ и $\lim_{x\to+\infty} F(x) = 1$;*
3. *непрерывна справа в каждой точке.*

Обратно, всякая функция $F\colon \mathbb{R} \to [0,1]$ со свойствами 1–3 является функцией распределения некоторой случайной величины, заданной на интервале $(0,1)$ с мерой Лебега.

Функция распределения

Теорема 3 (свойства функции распределения и обратная теорема)

Пусть ξ — случайная величина. Тогда её функция распределения $F = F_\xi$

1. *не убывает;*
2. *удовлетворяет $\lim_{x\to-\infty} F(x) = 0$ и $\lim_{x\to+\infty} F(x) = 1$;*
3. *непрерывна справа в каждой точке.*

Обратно, всякая функция $F\colon \mathbb{R} \to [0,1]$ со свойствами 1–3 является функцией распределения некоторой случайной величины, заданной на интервале $(0,1)$ с мерой Лебега.

Схема обратной части. На $(0,1)$ с мерой Лебега положить

$$\xi(u) = F^-(u) = \inf\{x\colon F(x) \geq u\}$$

и проверить равносильность $F^-(u) \leq x \iff u \leq F(x)$; тогда $\mathsf{P}\{\xi \leq x\} = F(x)$.

Попутно получен **метод обратной функции** для моделирования — и он не требует ни непрерывности F, ни строгой монотонности.

Плотность, маргинальные распределения, независимость

Определение 4 (плотность, маргинальные распределения, независимость)

Плотностью распределения вектора ξ называется такая борелевская $p \geq 0$, что $F_\xi(B) = \int_B p(x)\,dx$ при всех $B \in \mathcal{B}(\mathbb{R}^n)$; тогда $\mathsf{E} g(\xi) = \int_{\mathbb{R}^n} g(x)p(x)\,dx$ для всякой борелевской $g \geq 0$ и всякой g с $\mathsf{E}\,|g(\xi)| < \infty$.

Маргинальным (частным) распределением компоненты ξ_k называется её собственное распределение; оно получается из совместного предельным переходом $F_{\xi_k}(x_k) = \lim F_\xi(x_1, \dots, x_n)$ при $x_j \to +\infty, j \neq k$.

Случайные векторы $\xi \in \mathbb{R}^n$ и $\eta \in \mathbb{R}^m$ **независимы**, если их совместное распределение есть произведение распределений: $F_{(\xi,\eta)} = F_\xi \otimes F_\eta$. Набор $\xi_1, \dots, \xi_n$ независим **в совокупности**, если совместное распределение есть произведение всех n распределений.

Проверять независимость достаточно на функциях распределения: $F_{(\xi,\eta)}(x, y) = F_\xi(x)F_\eta(y)$ — прямоугольники образуют π-систему, порождающую борелевскую σ-алгебру.

Ковариация и коэффициент корреляции

Определение 5 (ковариация и коэффициент корреляции)

Пусть $\mathsf{E}\xi^2 < \infty$ и $\mathsf{E}\eta^2 < \infty$. **Ковариацией** (англ. *covariance*; в русской традиции также *корреляционный момент* — [24], гл. 14 §17) называется число

$$\operatorname{cov}(\xi, \eta) = \mathsf{E}(\xi - \mathsf{E}\xi)(\eta - \mathsf{E}\eta) = \mathsf{E}\xi\eta - \mathsf{E}\xi\,\mathsf{E}\eta.$$

Если $\sigma_\xi > 0$ и $\sigma_\eta > 0$, **коэффициентом корреляции** (англ. *correlation coefficient*) называется

$$r(\xi, \eta) = \frac{\operatorname{cov}(\xi, \eta)}{\sigma_\xi \sigma_\eta}.$$

Величины с $\operatorname{cov}(\xi, \eta) = 0$ называются **некоррелированными**.

Ковариация и коэффициент корреляции

Определение 5 (ковариация и коэффициент корреляции)

Пусть $\mathsf{E}\xi^2 < \infty$ и $\mathsf{E}\eta^2 < \infty$. **Ковариацией** (англ. *covariance*; в русской традиции также *корреляционный момент* — [24], гл. 14 §17) называется число

$$\operatorname{cov}(\xi, \eta) = \mathsf{E}(\xi - \mathsf{E}\xi)(\eta - \mathsf{E}\eta) = \mathsf{E}\xi\eta - \mathsf{E}\xi\,\mathsf{E}\eta.$$

Если $\sigma_\xi > 0$ и $\sigma_\eta > 0$, **коэффициентом корреляции** (англ. *correlation coefficient*) называется

$$r(\xi, \eta) = \frac{\operatorname{cov}(\xi, \eta)}{\sigma_\xi \sigma_\eta}.$$

Величины с $\operatorname{cov}(\xi, \eta) = 0$ называются **некоррелированными**.

Зачем нужен второй, если есть первый: ковариация имеет размерность произведения величин. Одни и те же данные в сантиметрах дают 2, в миллиметрах — 200; коэффициент корреляции безразмерен.

Ковариационная матрица

Определение 6 (вектор средних и ковариационная матрица)

Пусть у всех компонент вектора $\xi \in \mathbb{R}^n$ конечны вторые моменты. Его **вектор средних** — $a = \mathsf{E}\xi$, **ковариационная матрица** (англ. *covariance matrix*) —

$$\Gamma_\xi = \mathsf{E}(\xi - a)(\xi - a)^\mathsf{T}, \qquad (\Gamma_\xi)_{kj} = \operatorname{cov}(\xi_k, \xi_j).$$

Для пары векторов $\xi \in \mathbb{R}^n$, $\eta \in \mathbb{R}^m$ **взаимной ковариационной матрицей** называется прямоугольная матрица $\Gamma_{\xi\eta} = \mathsf{E}(\xi - \mathsf{E}\xi)(\eta - \mathsf{E}\eta)^\mathsf{T}$ размера $n \times m$; транспонирование переставляет сомножители, поэтому $\Gamma_{\eta\xi} = \Gamma_{\xi\eta}^\mathsf{T}$. **Корреляционной матрицей** называется матрица $R_\xi = [r(\xi_k, \xi_j)]$ (определена при всех $\sigma_{\xi_k} > 0$); она получается из Γ_ξ нормировкой: $R_\xi = S^{-1}\Gamma_\xi S^{-1}$, где $S = \operatorname{diag}(\sigma_{\xi_1}, \dots, \sigma_{\xi_n})$.

На диагонали — дисперсии компонент, у корреляционной матрицы — единицы.

Имя смотрится по формуле

Нормированная матрица — R_ξ, ненормированная — Γ_ξ; они совпадают ровно тогда, когда все дисперсии компонент равны единице.

Имя смотрится по формуле

Нормированная матрица — R_ξ, ненормированная — Γ_ξ; они совпадают ровно тогда, когда все дисперсии компонент равны единице.

Имя «корреляционная» у части прикладных авторов носит вторая из них. Поэтому при чтении литературы величину опознают по формуле, а не по названию.

Коэффициент корреляции

Неравенство Коши — Буняковского

Теорема 7 (неравенство Коши — Буняковского для моментов)

(В переводной литературе то же неравенство зовут неравенством Шварца, в части курсов — неравенством Коши — Буняковского — Шварца.) Пусть $\mathsf{E}\xi^2 < \infty$ *и* $\mathsf{E}\eta^2 < \infty$. *Тогда* $\mathsf{E}\,|\xi\eta| < \infty$ *и*

$$(\mathsf{E}\xi\eta)^2 \leq \mathsf{E}\xi^2 \cdot \mathsf{E}\eta^2.$$

Равенство достигается тогда и только тогда, когда найдётся пара чисел $(\alpha, \beta) \neq (0, 0)$, *при которой* $\alpha\xi + \beta\eta = 0$ *почти наверное.*

Неравенство Коши — Буняковского

Теорема 7 (неравенство Коши — Буняковского для моментов)

(В переводной литературе то же неравенство зовут неравенством Шварца, в части курсов — неравенством Коши — Буняковского — Шварца.) Пусть $\mathsf{E}\xi^2 < \infty$ *и* $\mathsf{E}\eta^2 < \infty$. *Тогда* $\mathsf{E}\,|\xi\eta| < \infty$ *и*

$$(\mathsf{E}\xi\eta)^2 \le \mathsf{E}\xi^2 \cdot \mathsf{E}\eta^2.$$

Равенство достигается тогда и только тогда, когда найдётся пара чисел $(\alpha, \beta) \neq (0, 0)$, *при которой* $\alpha\xi + \beta\eta = 0$ *почти наверное.*

Схема: трёхчлен $q(\lambda) = \mathsf{E}(\lambda\xi + \eta)^2 \ge 0$ при всех λ, значит дискриминант неположителен. Равенство означает корень, то есть $\mathsf{E}(\lambda_0\xi + \eta)^2 = 0$.

Следствие: $|\operatorname{cov}(\xi, \eta)| \le \sigma_\xi\sigma_\eta$ и $|r| \le 1$.

Теорема 8 (критерий $|r| = 1$)

Пусть $\sigma_\xi > 0$ и $\sigma_\eta > 0$. Тогда $|r(\xi, \eta)| = 1$ в том и только том случае, когда существуют числа $b \neq 0$ и c, при которых $\eta = b\xi + c$ почти наверное. При этом

$$|b| = \frac{\sigma_\eta}{\sigma_\xi}, \qquad \operatorname{sign} b = \operatorname{sign} r(\xi, \eta).$$

Теорема 8 (критерий $|r| = 1$)

Пусть $\sigma_\xi > 0$ и $\sigma_\eta > 0$. Тогда $|r(\xi, \eta)| = 1$ в том и только том случае, когда существуют числа $b \neq 0$ и c, при которых $\eta = b\xi + c$ почти наверное. При этом

$$|b| = \frac{\sigma_\eta}{\sigma_\xi}, \qquad \operatorname{sign} b = \operatorname{sign} r(\xi, \eta).$$

Итого: r лежит в $[-1, 1]$, и крайние значения достигаются ровно на почти наверное **линейной** зависимости. Про нелинейную связь коэффициент корреляции не утверждает ничего.

Чего r не видит

Пример 9 (квадрат симметричной величины)

Пусть ξ равномерна на $[-1, 1]$ и $\eta = \xi^2$. Тогда

$$\mathsf{E}\xi = 0, \quad \mathsf{E}\xi^3 = 0, \quad \operatorname{cov}(\xi, \eta) = \mathsf{E}\xi^3 - \mathsf{E}\xi\,\mathsf{E}\xi^2 = 0,$$

то есть $r(\xi, \eta) = 0$: величины некоррелированы. При этом η есть функция от ξ, и прогноз по ξ восстанавливает η точно.

Чего r не видит

Пример 9 (квадрат симметричной величины)

Пусть ξ равномерна на $[-1, 1]$ и $\eta = \xi^2$. Тогда

$$\mathsf{E}\xi = 0, \quad \mathsf{E}\xi^3 = 0, \quad \operatorname{cov}(\xi, \eta) = \mathsf{E}\xi^3 - \mathsf{E}\xi\,\mathsf{E}\xi^2 = 0,$$

то есть $r(\xi, \eta) = 0$: величины некоррелированы. При этом η есть функция от ξ, и прогноз по ξ восстанавливает η точно.

Наилучший линейный прогноз снимает $r^2 = 0$ дисперсии, наилучший прогноз вообще — всю. Измерено: выборочный $r = 3{,}1 \cdot 10^{-4}$, и линейный прогноз снимает $9{,}4 \cdot 10^{-8}$ дисперсии — ровно r^2, до седьмого знака. Наилучший же прогноз, оценённый условными средними по 200 бинам, оставляет $1{,}1 \cdot 10^{-5}$, то есть снимает $99{,}99\,\%$.

Независимость влечёт некоррелированность; обратное неверно.

Ковариационная матрица

Как преобразуется ковариационная матрица

Теорема 10 (преобразование при аффинном отображении)

Пусть у вектора $\xi \in \mathbb{R}^n$ конечны вторые моменты компонент, A — постоянная матрица с n столбцами, b — постоянный вектор той же высоты, что у $A\xi$. Тогда

$$\mathsf{E}(A\xi + b) = A\,\mathsf{E}\xi + b, \qquad \Gamma_{A\xi+b} = A\,\Gamma_{\xi} A^{\mathsf{T}}.$$

Для второго вектора $\eta \in \mathbb{R}^m$ и постоянной матрицы B с m столбцами выполнено $\Gamma_{A\xi,\,B\eta} = A\,\Gamma_{\xi\eta} B^{\mathsf{T}}$.

Ковариационная матрица — характеристика разброса, а не положения: сдвиг её не меняет.

Дисперсия линейной комбинации

Теорема 11 (дисперсия линейной комбинации)

Для любого $u \in \mathbb{R}^n$

$$\mathsf{D}\,\langle u, \xi \rangle = u^{\mathsf{T}} \Gamma_\xi u = \sum_{k,j=1}^{n} u_k u_j \operatorname{cov}(\xi_k, \xi_j).$$

Отсюда дисперсия суммы: сумма дисперсий плюс удвоенная сумма попарных ковариаций.

Аддитивность требует только **попарной некоррелированности**.

Какие матрицы бывают ковариационными

Теорема 12 (какие матрицы бывают ковариационными)

1. *Ковариационная матрица всякого случайного вектора симметрична и неотрицательно определена.*
2. *Обратно, для всякой симметричной неотрицательно определённой матрицы* Γ *размера* $n \times n$ *и всякого* $a \in \mathbb{R}^n$ *существует случайный вектор* ξ *с* $\mathsf{E}\xi = a$ *и* $\Gamma_\xi = \Gamma$.

Какие матрицы бывают ковариационными

Теорема 12 (какие матрицы бывают ковариационными)

1. *Ковариационная матрица всякого случайного вектора симметрична и неотрицательно определена.*
2. *Обратно, для всякой симметричной неотрицательно определённой матрицы Γ размера $n \times n$ и всякого $a \in \mathbb{R}^n$ существует случайный вектор ξ с* $\mathsf{E}\xi = a$ *и* $\Gamma_\xi = \Gamma$.

Схема. Первое: $u^{\mathsf{T}}\Gamma u = \mathsf{D}\,\langle u, \xi\rangle \geq 0$. Второе: взять $\Omega = \{-1, 1\}^n$ с равномерной мерой, $\zeta_k(\omega) = \omega_k$ — тогда $\Gamma_\zeta = I$, и положить $\xi = \Gamma^{1/2}\zeta + a$.

Смысл: корреляционная теория не накладывает на пару (a, Γ) **никаких** других условий.

Как проверить матрицу на допустимость

Верный критерий: неотрицательно определена тогда и только тогда, когда неотрицательны **все главные** миноры. На практике проще считать собственные значения.

Как проверить матрицу на допустимость

Верный критерий: неотрицательно определена тогда и только тогда, когда неотрицательны **все главные** миноры. На практике проще считать собственные значения.

Разложение Холецкого отвечает на соседний вопрос — о **положительной** определённости, то есть, для уже допустимой матрицы, об её обратимости в формулах прогноза: алгоритм без выбора ведущего элемента обрывается на вырожденной, а вырожденная ковариационная матрица допустима.

Как проверить матрицу на допустимость

Верный критерий: неотрицательно определена тогда и только тогда, когда неотрицательны **все главные** миноры. На практике проще считать собственные значения.

Разложение Холецкого отвечает на соседний вопрос — о **положительной** определённости, то есть, для уже допустимой матрицы, об её обратимости в формулах прогноза: алгоритм без выбора ведущего элемента обрывается на вырожденной, а вырожденная ковариационная матрица допустима.

Привычная формулировка критерия Сильвестра — про **угловые** миноры — проверяет *положительную* определённость, и на неотрицательную не переносится:

$$\Gamma = \begin{pmatrix} 0 & 0 \\ 0 & -1 \end{pmatrix},$$

угловые миноры равны 0 и 0, а $u^{\mathsf{T}}\Gamma u = -u_2^2 < 0$ при $u = (0, 1)^{\mathsf{T}}$.

Вырожденность — это точная линейная связь

Теорема 13 (вырожденность и размерность носителя)

Пусть $a = \mathsf{E}\xi$, $\Gamma = \Gamma_\xi$. *Тогда*

1. *для* $u \in \mathbb{R}^n$ *равенство* $u^\mathsf{T}\Gamma u = 0$ *равносильно* $\langle u, \xi - a\rangle = 0$ *почти наверное;*
2. *если* $\operatorname{rank}\Gamma = k$, *то почти наверное* $\xi \in a + \mathcal{L}$, *где* $\mathcal{L} = \operatorname{Im}\Gamma$ *– линейное подпространство размерности* k.

Вырожденность — это точная линейная связь

Теорема 13 (вырожденность и размерность носителя)

Пусть $a = \mathsf{E}\xi$, $\Gamma = \Gamma_\xi$. *Тогда*

1. *для* $u \in \mathbb{R}^n$ *равенство* $u^\mathsf{T}\Gamma u = 0$ *равносильно* $\langle u, \xi - a\rangle = 0$ *почти наверное;*
2. *если* $\operatorname{rank}\Gamma = k$, *то почти наверное* $\xi \in a + \mathcal{L}$, *где* $\mathcal{L} = \operatorname{Im}\Gamma$ *— линейное подпространство размерности* k.

Схема. Первое: $u^\mathsf{T}\Gamma u = \mathsf{E}\,\langle u, \xi - a\rangle^2$, и нулевое математическое ожидание неотрицательной величины означает нуль почти наверное. Второе: $\ker\Gamma = (\operatorname{Im}\Gamma)^\perp$, и пересечение конечного числа событий вероятности 1 имеет вероятность 1.

Вырожденность — не «плохая обусловленность», а точное линейное соотношение.

Главные оси

Теорема 14 (главные оси рассеяния)

Пусть $\Gamma = \Gamma_\xi$, $\Gamma = Q\Lambda Q^\mathsf{T}$ *– её спектральное разложение,* $Q = [q_1, \dots, q_n]$ *ортогональна,* $\Lambda = \operatorname{diag}(\lambda_1, \dots, \lambda_n)$, $\lambda_1 \geq \dots \geq \lambda_n \geq 0$. *Тогда*

1. *компоненты вектора* $\zeta = Q^\mathsf{T}(\xi - a)$ *попарно некоррелированы и* $\mathsf{D}\zeta_k = \lambda_k$;
2. $\max\limits_{\|u\|=1} \mathsf{D}\langle u, \xi\rangle = \lambda_1$, *и максимум достигается при* $u = q_1$;
3. $\min\limits_{\|u\|=1} \mathsf{D}\langle u, \xi\rangle = \lambda_n$, *и минимум достигается при* $u = q_n$;
4. $\operatorname{tr}\Gamma = \sum_{k=1}^n \lambda_k = \sum_{k=1}^n \mathsf{D}\xi_k$.

Главные оси

Теорема 14 (главные оси рассеяния)

Пусть $\Gamma = \Gamma_\xi$, $\Gamma = Q\Lambda Q^\mathsf{T}$ *– её спектральное разложение,* $Q = [q_1, \dots, q_n]$ *ортогональна,* $\Lambda = \operatorname{diag}(\lambda_1, \dots, \lambda_n)$, $\lambda_1 \geq \dots \geq \lambda_n \geq 0$. *Тогда*

1. *компоненты вектора* $\zeta = Q^\mathsf{T}(\xi - a)$ *попарно некоррелированы и* $\mathsf{D}\zeta_k = \lambda_k$;
2. $\max\limits_{\|u\|=1} \mathsf{D}\langle u, \xi\rangle = \lambda_1$, *и максимум достигается при* $u = q_1$;
3. $\min\limits_{\|u\|=1} \mathsf{D}\langle u, \xi\rangle = \lambda_n$, *и минимум достигается при* $u = q_n$;
4. $\operatorname{tr}\Gamma = \sum_{k=1}^n \lambda_k = \sum_{k=1}^n \mathsf{D}\xi_k$.

Поворот превращает коррелированные координаты в некоррелированные; дисперсии в новых осях — собственные значения. Это и есть метод главных компонент (англ. *principal component analysis*, PCA), применённый к выборочной матрице. Величина $\operatorname{tr}\Gamma$ — полная дисперсия, знаменатель доли объяснённой.

Эллипсоид рассеяния — геометрия разброса, построенная из одних вторых моментов.

Определение 15 (эллипсоид рассеяния)

Пусть Γ невырождена. **Эллипсоидом рассеяния** уровня $c > 0$ называется множество

$$E_c = \{x \in \mathbb{R}^n : (x-a)^{\mathsf{T}}\Gamma^{-1}(x-a) \le c\}.$$

Его главные полуоси направлены по q_k и равны $\sqrt{c\lambda_k}$; объём равен $c^{n/2}V_n\sqrt{\det\Gamma}$, где V_n — объём единичного шара в $\mathbb{R}^n$.

Величина $\det\Gamma$ — **обобщённая дисперсия**: она меряет объём рассеяния и обращается в нуль ровно при вырожденности.

Оценка уклонения через эллипсоид

Теорема 16 (многомерное неравенство Чебышёва)

Пусть Γ невырождена и $c > 0$. Тогда

$$\mathsf{P}\bigl\{(\xi - a)^{\mathsf{T}}\Gamma^{-1}(\xi - a) \geq c\bigr\} \leq \frac{n}{c},$$

то есть вероятность выйти за эллипсоид рассеяния уровня c не превосходит n/c.

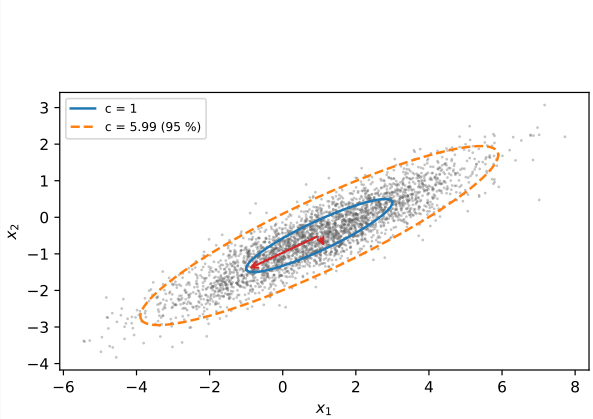
Схема: неравенство Маркова, применённое к квадратичной форме, плюс $\mathsf{E}(\xi - a)^{\mathsf{T}}\Gamma^{-1}(\xi - a) = \operatorname{tr}(\Gamma^{-1}\Gamma) = n$.

Геометрия: главные оси и эллипсы

Двумерный нормальный закон, $\mathrm{D}\xi_1 = 4$, $\mathrm{D}\xi_2 = 1$, $\mathrm{cov} = 1{,}8$, то есть $r = 0{,}9$.

- собственные значения $4{,}843$ и $0{,}157$;
- разброс вдоль первой оси шире в $\sqrt{\lambda_1/\lambda_2} = 5{,}56$ раза;
- внутри эллипса $c = 5{,}99$ оказалось $94{,}98\,\%$ выборки при точном значении $95\,\%$.

Поворот в главные оси обнулил выборочную ковариацию: $1{,}8047$ до поворота, $1{,}6 \cdot 10^{-3}$ после.



Насколько груба оценка Чебышёва

c	доля вне эллипса	точно $e^{-c/2}$	Чебышёв $2/c$
1	0,6068	0,6065	2,0
2	0,3683	0,3679	1,0
5	0,0821	0,0821	0,4
10	0,00686	0,00674	0,2

Выборка $4 \cdot 10^5$ точек. При $c = 10$ уклонение измеренной доли от точного значения равно $1{,}2 \cdot 10^{-4}$ при стандартном уклонении доли $1{,}3 \cdot 10^{-4}$ — одна сигма.

Насколько груба оценка Чебышёва

c	доля вне эллипса	точно $e^{-c/2}$	Чебышёв $2/c$
1	$0{,}6068$	$0{,}6065$	$2{,}0$
2	$0{,}3683$	$0{,}3679$	$1{,}0$
5	$0{,}0821$	$0{,}0821$	$0{,}4$
10	$0{,}00686$	$0{,}00674$	$0{,}2$

Выборка $4 \cdot 10^5$ точек. При $c = 10$ уклонение измеренной доли от точного значения равно $1{,}2 \cdot 10^{-4}$ при стандартном уклонении доли $1{,}3 \cdot 10^{-4}$ — одна сигма.

Оценка Чебышёва при том же c завышает вероятность в $29{,}7$ раза. Цена её универсальности: она верна при любом распределении.

Наилучший прогноз

Теорема 17 (наилучший линейный прогноз)

Пусть $\mathsf{E}\xi^2 < \infty$, $\mathsf{E}\eta^2 < \infty$ *и* $\mathsf{D}\xi > 0$. *Тогда*

$$\min_{b,c\in\mathbb{R}} \mathsf{E}(\eta - b\xi - c)^2 = \mathsf{D}\eta\,(1 - r^2), \qquad r = r(\xi,\eta),$$

минимум достигается в единственной точке

$$b^* = \frac{\operatorname{cov}(\xi,\eta)}{\mathsf{D}\xi} = r\,\frac{\sigma_\eta}{\sigma_\xi}, \qquad c^* = \mathsf{E}\eta - b^*\,\mathsf{E}\xi.$$

Теорема 17 (наилучший линейный прогноз)

Пусть $\mathsf{E}\xi^2 < \infty$, $\mathsf{E}\eta^2 < \infty$ *и* $\mathsf{D}\xi > 0$. *Тогда*

$$\min_{b,c\in\mathbb{R}} \mathsf{E}(\eta - b\xi - c)^2 = \mathsf{D}\eta\,(1 - r^2), \qquad r = r(\xi,\eta),$$

минимум достигается в единственной точке

$$b^* = \frac{\operatorname{cov}(\xi,\eta)}{\mathsf{D}\xi} = r\,\frac{\sigma_\eta}{\sigma_\xi}, \qquad c^* = \mathsf{E}\eta - b^*\,\mathsf{E}\xi.$$

Схема: выделить $\gamma = \mathsf{E}\eta - b\,\mathsf{E}\xi - c$, заметив, что $\mathsf{E}(\eta - b\xi - c)^2 = \mathsf{E}(\eta^\circ - b\xi^\circ)^2 + \gamma^2$; остаётся минимум квадратного трёхчлена по b.

Смысл r^2: **доля дисперсии, снимаемая наилучшим линейным прогнозом.**

Две прямые регрессии

Прямая регрессии η на ξ в стандартизованной записи:

$$\frac{y - \mathsf{E}\eta}{\sigma_\eta} = r\,\frac{x - \mathsf{E}\xi}{\sigma_\xi}.$$

Две прямые регрессии

Прямая регрессии η на ξ в стандартизованной записи:

$$\frac{y - \mathsf{E}\eta}{\sigma_\eta} = r\,\frac{x - \mathsf{E}\xi}{\sigma_\xi}.$$

Поменяв роли величин, получим вторую прямую. Их угловые коэффициенты относятся как r^2, поэтому прямые совпадают ровно при $r^2 = 1$ — то есть при почти наверное линейной связи.

Две прямые регрессии

Прямая регрессии η на ξ в стандартизованной записи:

$$\frac{y - \mathsf{E}\eta}{\sigma_\eta} = r\,\frac{x - \mathsf{E}\xi}{\sigma_\xi}.$$

Поменяв роли величин, получим вторую прямую. Их угловые коэффициенты относятся как r^2, поэтому прямые совпадают ровно при $r^2 = 1$ — то есть при почти наверное линейной связи.

При $|r| < 1$ прогноз «притянут» к среднему сильнее самой величины: $|b^*| = |r|\ \sigma_\eta/\sigma_\xi < \sigma_\eta/\sigma_\xi$. Это и есть регрессия к среднему — явление, которое Гальтон назвал так и от которого метод получил имя.

Теорема 18 (наилучшая линейная оценка)

Пусть $\xi \in \mathbb{R}^n$ и $\eta \in \mathbb{R}^m$ – случайные векторы с конечными вторыми моментами компонент и невырожденной Γ_η. Среди всех оценок вида $\widehat{\xi} = B\eta + c$ (B – матрица $n \times m$, $c \in \mathbb{R}^n$) матрица вторых моментов ошибки $\mathsf{E}(\xi - \widehat{\xi})(\xi - \widehat{\xi})^\mathsf{T}$ минимальна в смысле порядка $\succeq$ при

$$B^* = \Gamma_{\xi\eta}\Gamma_\eta^{-1}, \qquad c^* = \mathsf{E}\xi - B^*\mathsf{E}\eta,$$

и минимум равен

$$\Gamma_{\text{err}} = \Gamma_\xi - \Gamma_{\xi\eta}\Gamma_\eta^{-1}\Gamma_{\eta\xi}.$$

Точка минимума единственна.

Теорема 18 (наилучшая линейная оценка)

Пусть $\xi \in \mathbb{R}^n$ и $\eta \in \mathbb{R}^m$ – случайные векторы с конечными вторыми моментами компонент и невырожденной Γ_η. Среди всех оценок вида $\widehat{\xi} = B\eta + c$ (B – матрица $n \times m$, $c \in \mathbb{R}^n$) матрица вторых моментов ошибки $\mathsf{E}(\xi - \widehat{\xi})(\xi - \widehat{\xi})^\mathsf{T}$ минимальна в смысле порядка $\succeq$ при

$$B^* = \Gamma_{\xi\eta}\Gamma_\eta^{-1}, \qquad c^* = \mathsf{E}\xi - B^*\mathsf{E}\eta,$$

и минимум равен

$$\Gamma_{\text{err}} = \Gamma_\xi - \Gamma_{\xi\eta}\Gamma_\eta^{-1}\Gamma_{\eta\xi}.$$

Точка минимума единственна.

Схема: ошибка e^* не коррелирует с данными ($\mathsf{E}e^*(\eta^\circ)^\mathsf{T} = 0$), поэтому для любого B

$$\mathsf{E}ee^\mathsf{T} = \mathsf{E}e^*(e^*)^\mathsf{T} + (B - B^*)\Gamma_\eta(B - B^*)^\mathsf{T}.$$

Почему «в матричном смысле»

Минимальность в смысле порядка $\succeq$ сильнее минимальности следа или определителя: малой оказывается дисперсия **любой** линейной комбинации компонент ошибки, а не только их сумма.

Почему «в матричном смысле»

Минимальность в смысле порядка $\succeq$ сильнее минимальности следа или определителя: малой оказывается дисперсия **любой** линейной комбинации компонент ошибки, а не только их сумма.

Побочно получается чисто алгебраический факт: дополнение Шура $\Gamma_\xi - \Gamma_{\xi\eta}\Gamma_\eta^{-1}\Gamma_{\eta\xi}$ блочной ковариационной матрицы неотрицательно определено — потому что это ковариационная матрица ошибки.

Шаг фильтра Калмана

Пусть $\eta = H\xi + \varepsilon$, где ε имеет нулевое среднее, ковариационную матрицу Γ_ε и не коррелирована с ξ; $P = \Gamma_\xi$.

Шаг фильтра Калмана

Пусть $\eta = H\xi + \varepsilon$, где ε имеет нулевое среднее, ковариационную матрицу Γ_ε и не коррелирована с ξ; $P = \Gamma_\xi$.

Тогда $\Gamma_{\xi\eta} = PH^\mathsf{T}$, $\Gamma_\eta = HPH^\mathsf{T} + \Gamma_\varepsilon$, и предыдущая теорема даёт

$$\hat{\xi} = \mathsf{E}\xi + K(\eta - H\,\mathsf{E}\xi), \qquad K = PH^\mathsf{T}(HPH^\mathsf{T} + \Gamma_\varepsilon)^{-1},$$

с ковариацией ошибки $(I - KH)P$. В литературе по фильтрации ковариацию шума обозначают R; здесь эта буква занята корреляционной матрицей.

Шаг фильтра Калмана

Пусть $\eta = H\xi + \varepsilon$, где ε имеет нулевое среднее, ковариационную матрицу Γ_ε и не коррелирована с ξ; $P = \Gamma_\xi$.

Тогда $\Gamma_{\xi\eta} = PH^\mathsf{T}$, $\Gamma_\eta = HPH^\mathsf{T} + \Gamma_\varepsilon$, и предыдущая теорема даёт

$$\hat{\xi} = \mathsf{E}\xi + K(\eta - H\,\mathsf{E}\xi), \qquad K = PH^\mathsf{T}(HPH^\mathsf{T} + \Gamma_\varepsilon)^{-1},$$

с ковариацией ошибки $(I - KH)P$. В литературе по фильтрации ковариацию шума обозначают R; здесь эта буква занята корреляционной матрицей.

Это корректирующий шаг фильтра Калмана, и важно, **чего в выводе не было**: ни одного предположения о виде распределений. Только два момента.

Теорема 19 (условное математическое ожидание как наилучший прогноз)

Пусть $\mathsf{E}\xi^2 < \infty$, $\mathcal{G} \subset \mathcal{F}$ *– под-*σ*-алгебра,* $\mathcal{A}_{\mathcal{G}}$ *– множество* $\mathcal{G}$*-измеримых случайных величин с конечным вторым моментом. Тогда*

$$\mathsf{E}\big(\xi - \mathsf{E}(\xi \mid \mathcal{G})\big)^2 = \min_{\zeta \in \mathcal{A}_{\mathcal{G}}} \mathsf{E}(\xi - \zeta)^2,$$

и минимум достигается только на $\zeta = \mathsf{E}(\xi \mid \mathcal{G})$ *(с точностью до равенства почти наверное).*

Теорема 19 (условное математическое ожидание как наилучший прогноз)

Пусть $\mathsf{E}\xi^2 < \infty$, $\mathcal{G} \subset \mathcal{F}$ *— под-σ-алгебра,* $\mathcal{A}_{\mathcal{G}}$ *— множество* $\mathcal{G}$*-измеримых случайных величин с конечным вторым моментом. Тогда*

$$\mathsf{E}\big(\xi - \mathsf{E}(\xi \mid \mathcal{G})\big)^2 = \min_{\zeta \in \mathcal{A}_{\mathcal{G}}} \mathsf{E}(\xi - \zeta)^2,$$

и минимум достигается только на $\zeta = \mathsf{E}(\xi \mid \mathcal{G})$ *(с точностью до равенства почти наверное).*

Схема — теорема Пифагора. Разность $\xi - \mathsf{E}(\xi \mid \mathcal{G})$ ортогональна всему $\mathcal{A}_{\mathcal{G}}$ в L_2 со скалярным произведением $\mathsf{E}\xi\eta$; значит условное математическое ожидание — ортогональная проекция.

Закон полной дисперсии

Следствие 20 (закон полной дисперсии)

Пусть $\mathsf{E}\xi^2 < \infty$ *и* $\mathsf{D}(\xi \mid \mathcal{G}) = \mathsf{E}(\xi^2 \mid \mathcal{G}) - \big(\mathsf{E}(\xi \mid \mathcal{G})\big)^2$. *Тогда*

$$\mathsf{D}\xi = \mathsf{E}\,\mathsf{D}(\xi \mid \mathcal{G}) + \mathsf{D}\,\mathsf{E}(\xi \mid \mathcal{G}).$$

Та же ортогональность: дисперсия распадается на «разброс внутри» и «разброс между». Отсюда и следующий кадр.

Определение 21 (корреляционное отношение)

Пусть $\mathsf{D}\eta > 0$. **Корреляционным отношением** (англ. *correlation ratio*) величины η по ξ называется

$$\nu^2(\eta \mid \xi) = \frac{\mathsf{D}\,\mathsf{E}(\eta \mid \xi)}{\mathsf{D}\eta}.$$

Определение 21 (корреляционное отношение)

Пусть $\mathsf{D}\eta > 0$. **Корреляционным отношением** (англ. *correlation ratio*) величины η по ξ называется

$$\nu^2(\eta \mid \xi) = \frac{\mathsf{D}\,\mathsf{E}(\eta \mid \xi)}{\mathsf{D}\eta}.$$

Предложение 1 (корреляционное отношение не меньше квадрата корреляции)

При $\mathsf{D}\xi > 0, \mathsf{D}\eta > 0$

$$r^2(\xi, \eta) \leq \nu^2(\eta \mid \xi) \leq 1,$$

причём $\nu^2(\eta \mid \xi) = 0$ *равносильно тому, что* $\mathsf{E}(\eta \mid \xi)$ *постоянно почти наверное, а* $\nu^2(\eta \mid \xi) = 1$ *— тому, что* η *есть функция от* ξ *почти наверное.*

Что теряет корреляционная теория

Определение 21 (корреляционное отношение)

Пусть $\mathsf{D}\eta > 0$. **Корреляционным отношением** (англ. *correlation ratio*) величины η по ξ называется

$$\nu^2(\eta \mid \xi) = \frac{\mathsf{D}\,\mathsf{E}(\eta \mid \xi)}{\mathsf{D}\eta}.$$

Предложение 1 (корреляционное отношение не меньше квадрата корреляции)

При $\mathsf{D}\xi > 0, \mathsf{D}\eta > 0$

$$r^2(\xi, \eta) \le \nu^2(\eta \mid \xi) \le 1,$$

причём $\nu^2(\eta \mid \xi) = 0$ *равносильно тому, что* $\mathsf{E}(\eta \mid \xi)$ *постоянно почти наверное, а* $\nu^2(\eta \mid \xi) = 1$ *— тому, что* η *есть функция от* ξ *почти наверное.*

r^2 — доля, снимаемая **линейным** прогнозом; ν^2 — наилучшим вообще; разность — ровно то, чего два момента не видят. В примере с $\eta = \xi^2$ она равна единице.

Гауссовский случай

Гауссовский вектор

Определение 22 (гауссовский вектор)

Случайный вектор $\zeta \in \mathbb{R}^k$ называется **стандартным гауссовским**, если его компоненты независимы в совокупности и каждая имеет распределение $\mathcal{N}(0,1)$ с плотностью $(2\pi)^{-1/2}e^{-x^2/2}$. Вектор $\xi \in \mathbb{R}^n$ называется **гауссовским** (англ. *Gaussian vector*; он же нормальный), если он представим в виде

$$\xi = A\zeta + a$$

со стандартным гауссовским $\zeta \in \mathbb{R}^k$, постоянной матрицей A размера $n \times k$ и постоянным $a \in \mathbb{R}^n$. Пишут $\xi \sim \mathcal{N}(a, \Gamma)$, где $\Gamma = AA^{\mathsf{T}}$.

Гауссовский вектор

Определение 22 (гауссовский вектор)

Случайный вектор $\zeta \in \mathbb{R}^k$ называется **стандартным гауссовским**, если его компоненты независимы в совокупности и каждая имеет распределение $\mathcal{N}(0,1)$ с плотностью $(2\pi)^{-1/2}e^{-x^2/2}$. Вектор $\xi \in \mathbb{R}^n$ называется **гауссовским** (англ. *Gaussian vector*; он же нормальный), если он представим в виде

$$\xi = A\zeta + a$$

со стандартным гауссовским $\zeta \in \mathbb{R}^k$, постоянной матрицей A размера $n \times k$ и постоянным $a \in \mathbb{R}^n$. Пишут $\xi \sim \mathcal{N}(a, \Gamma)$, где $\Gamma = AA^{\mathsf{T}}$.

Определение через линейный образ, а не через плотность, работает и в вырожденном случае, где плотности нет, и сразу даёт замкнутость класса относительно линейных преобразований.

Теорема 23 (характеристическая функция гауссовского вектора)

Если $\xi \sim \mathcal{N}(a, \Gamma)$, *то при всех* $t \in \mathbb{R}^n$

$$\varphi_\xi(t) = \mathsf{E} e^{i\langle t, \xi \rangle} = \exp\left\{ i \langle t, a \rangle - \tfrac{1}{2} \langle \Gamma t, t \rangle \right\}.$$

Следовательно, распределение гауссовского вектора однозначно определяется парой (a, Γ).

Теорема 23 (характеристическая функция гауссовского вектора)

Если $\xi \sim \mathcal{N}(a, \Gamma)$, *то при всех* $t \in \mathbb{R}^n$

$$\varphi_\xi(t) = \mathsf{E} e^{i\langle t, \xi\rangle} = \exp\Big\{ i\,\langle t, a\rangle - \tfrac{1}{2}\,\langle \Gamma t, t\rangle \Big\}.$$

Следовательно, распределение гауссовского вектора однозначно определяется парой (a, Γ).

Два момента — полное описание: по ним восстанавливается распределение целиком.

Некоррелированность равносильна независимости

Теорема 24 (некоррелированность равносильна независимости)

Пусть вектор (ξ, η) размерности $n + m$ гауссовский и $\Gamma_{\xi\eta} = 0$. Тогда ξ и η независимы. В частности, попарно некоррелированные компоненты гауссовского вектора независимы в совокупности.

Некоррелированность равносильна независимости

Теорема 24 (некоррелированность равносильна независимости)

Пусть вектор (ξ, η) размерности $n + m$ гауссовский и $\Gamma_{\xi\eta} = 0$. Тогда ξ и η независимы. В частности, попарно некоррелированные компоненты гауссовского вектора независимы в совокупности.

Схема: при блочно-диагональной Γ характеристическая функция распадается в произведение, а произведение характеристических функций есть характеристическая функция произведения мер; дальше теорема единственности.

Теорема 25 (условное распределение гауссовского вектора)

Пусть вектор (ξ, η), $\xi \in \mathbb{R}^n$, $\eta \in \mathbb{R}^m$, гауссовский и Γ_η невырождена. Тогда условное распределение ξ при $\eta = y$ гауссовское с параметрами

$$\mathsf{E}\xi + \Gamma_{\xi\eta}\Gamma_\eta^{-1}(y - \mathsf{E}\eta), \qquad \Gamma_\xi - \Gamma_{\xi\eta}\Gamma_\eta^{-1}\Gamma_{\eta\xi}.$$

В частности,

$$\mathsf{E}(\xi \mid \eta) = \mathsf{E}\xi + \Gamma_{\xi\eta}\Gamma_\eta^{-1}(\eta - \mathsf{E}\eta),$$

то есть условное математическое ожидание линейно и совпадает с наилучшей линейной оценкой.

Теорема 25 (условное распределение гауссовского вектора)

Пусть вектор (ξ, η), $\xi \in \mathbb{R}^n$, $\eta \in \mathbb{R}^m$, гауссовский и Γ_η невырождена. Тогда условное распределение ξ при $\eta = y$ гауссовское с параметрами

$$\mathsf{E}\xi + \Gamma_{\xi\eta}\Gamma_\eta^{-1}(y - \mathsf{E}\eta), \qquad \Gamma_\xi - \Gamma_{\xi\eta}\Gamma_\eta^{-1}\Gamma_{\eta\xi}.$$

В частности,

$$\mathsf{E}(\xi \mid \eta) = \mathsf{E}\xi + \Gamma_{\xi\eta}\Gamma_\eta^{-1}(\eta - \mathsf{E}\eta),$$

то есть условное математическое ожидание линейно и совпадает с наилучшей линейной оценкой.

Схема: вектор (e, η) с $e = \xi - \mathsf{E}\xi - B^*(\eta - \mathsf{E}\eta)$ гауссовский, $\Gamma_{e\eta} = 0$, значит e и η независимы; остаётся подставить $\xi = \mathsf{E}\xi + B^*(\eta - \mathsf{E}\eta) + e$.

Кульминация: в гауссовском случае $\mathsf{E}(\xi \mid \eta)$ линейно, то есть корреляционная теория исчерпывающая. Вне его она даёт точный ответ внутри класса линейных процедур.

Где нужна совместная гауссовость

Пример 26 (гауссовская пара со случайным знаком)

Пусть $\xi \sim \mathcal{N}(0,1)$, а s принимает значения ± 1 с вероятностью $1/2$ каждое и независима от ξ. Положим $\eta = s\xi$. Тогда

1. $\eta \sim \mathcal{N}(0,1)$;
2. $\operatorname{cov}(\xi, \eta) = 0$;
3. ξ и η зависимы, ибо $|\xi| = |\eta|$ почти наверное;
4. вектор (ξ, η) **не** гауссовский.

Где нужна совместная гауссовость

Пример 26 (гауссовская пара со случайным знаком)

Пусть $\xi \sim \mathcal{N}(0,1)$, а s принимает значения ± 1 с вероятностью $1/2$ каждое и независима от ξ. Положим $\eta = s\xi$. Тогда

1. $\eta \sim \mathcal{N}(0,1)$;
2. $\operatorname{cov}(\xi, \eta) = 0$;
3. ξ и η зависимы, ибо $|\xi| = |\eta|$ почти наверное;
4. вектор (ξ, η) **не** гауссовский.

Последний пункт — следствие второго и третьего: будь вектор гауссовским, из нулевой корреляции следовала бы независимость. Нормальности каждой компоненты для теоремы о равносильности недостаточно.

Измерено: $r(\xi, \eta) = 3{,}1 \cdot 10^{-3}$, а $r(\xi^2, \eta^2) = 1$ ровно.

Сквозной пример и численные проверки

Два датчика: оптимальный вес

Предложение 2 (оптимальный вес и достижимая точность)

Пусть $\sigma_1, \sigma_2 > 0$ *и* $\sigma_1^2 + \sigma_2^2 - 2r\sigma_1\sigma_2 > 0$. *Тогда дисперсия* $V(w) = \mathsf{D}(w\eta_1 + (1-w)\eta_2)$ *достигает наименьшего значения в единственной точке*

$$w^* = \frac{\sigma_2^2 - r\sigma_1\sigma_2}{\sigma_1^2 + \sigma_2^2 - 2r\sigma_1\sigma_2}$$

и это наименьшее значение равно

$$V^* = \frac{\sigma_1^2\sigma_2^2\,(1-r^2)}{\sigma_1^2 + \sigma_2^2 - 2r\sigma_1\sigma_2}.$$

При этом $w^* < 0$ *тогда и только тогда, когда* $r > \sigma_2/\sigma_1$, *и* $w^* > 1$ *тогда и только тогда, когда* $r > \sigma_1/\sigma_2$.

Схема: V — квадратный трёхчлен по w с положительным старшим коэффициентом $\mathsf{D}(\varepsilon_1 - \varepsilon_2)$; приравнять производную нулю.

Два датчика: три режима

- $r = 0$: веса обратно пропорциональны дисперсиям — привычный ответ.
- $\sigma_1 = \sigma_2$: вес равен $1/2$ при любом r, $V^* = \sigma^2(1 + r)/2$; при $r \to 1$ второй прибор не даёт ничего.
- $\sigma_1 \neq \sigma_2, r \to 1$: $V^* \to 0$ — шум **вычитается**.

Два датчика: картинка

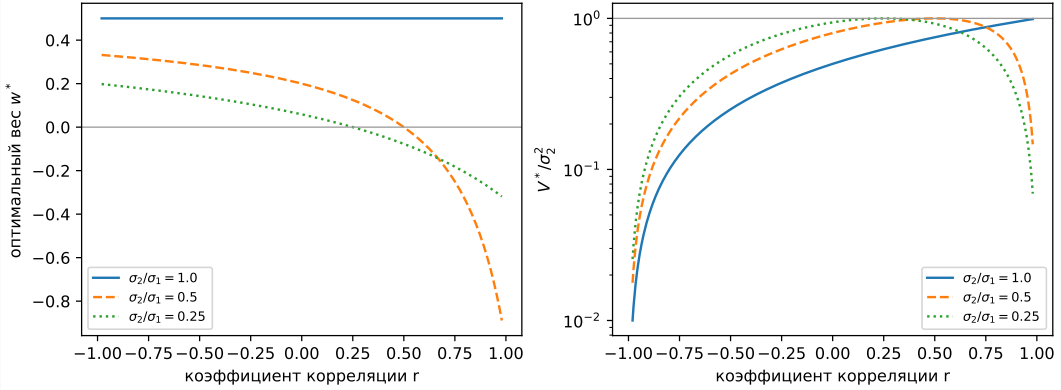


Рис. 1: Оптимальный вес (слева) и дисперсия оптимальной комбинации, отнесённая к дисперсии лучшего прибора (справа), при трёх отношениях σ_2/σ_1.

При $\sigma_2 < \sigma_1$ вес уходит в отрицательную область, как только r превосходит σ_2/σ_1.

Устойчивость счёта

Формула $\operatorname{cov} = \mathsf{E}\xi\eta - \mathsf{E}\xi\,\mathsf{E}\eta$ считается в один проход — и теряет все верные цифры на сдвинутых данных: оба слагаемых имеют порядок c^2, а разность — порядок дисперсии.

Устойчивость счёта

Формула $\operatorname{cov} = \mathsf{E}\xi\eta - \mathsf{E}\xi\,\mathsf{E}\eta$ считается в один проход — и теряет все верные цифры на сдвинутых данных: оба слагаемых имеют порядок c^2, а разность — порядок дисперсии.

сдвиг	наивная	двухпроходная	Уэлфорд
0	$1{,}00016928$	$1{,}00016928$	$1{,}00016928$
10^4	$1{,}00016929$	$1{,}00016928$	$1{,}00016928$
10^8	$2{,}00000000$	$1{,}00016928$	$1{,}00016928$
10^9	$0{,}00000000$	$1{,}00016928$	$1{,}00016925$

Выборка $2 \cdot 10^5$ стандартных нормальных величин. В одинарной точности наивная формула даёт **отрицательную** дисперсию уже при сдвиге 10^4: при сдвигах 10^4, 10^5, 10^6 напечатаны -8, -1024 и -131072.

Разобранные задачи

Допустим ли такой набор корреляций

Задача. Три величины попарно коррелированы: $r_{12} = r_{23} = 0{,}8$, $r_{13} = 0$. Возможно ли это?

Допустим ли такой набор корреляций

Задача. Три величины попарно коррелированы: $r_{12} = r_{23} = 0{,}8$, $r_{13} = 0$. Возможно ли это?

Корреляционная матрица обязана быть неотрицательно определённой, значит её определитель неотрицателен. Считаем:

$$\det R = 1 \cdot (1 - 0{,}64) - 0{,}8\,(0{,}8 - 0) + 0 = 0{,}36 - 0{,}64 = -0{,}28 < 0.$$

Невозможно.

Допустим ли такой набор корреляций

Задача. Три величины попарно коррелированы: $r_{12} = r_{23} = 0{,}8$, $r_{13} = 0$. Возможно ли это?

Корреляционная матрица обязана быть неотрицательно определённой, значит её определитель неотрицателен. Считаем:

$$\det R = 1 \cdot (1 - 0{,}64) - 0{,}8\,(0{,}8 - 0) + 0 = 0{,}36 - 0{,}64 = -0{,}28 < 0.$$

Невозможно.

Общее ограничение: при $r_{12} = r_{23} = \rho$ выполнено $r_{13} \geq 2\rho^2 - 1$ (корни трёхчлена $x^2 - 2\rho^2 x + 2\rho^2 - 1$ равны $2\rho^2 - 1$ и 1). При $\rho = 0{,}8$ получаем $r_{13} \geq 0{,}28$. Корреляция частично транзитивна.

Два датчика с числами

Задача. $\sigma_1 = 2, \sigma_2 = 1$. Найти w^* и V^* при $r = 0, 0{,}5$ и $0{,}9$.

Два датчика с числами

Задача. $\sigma_1 = 2$, $\sigma_2 = 1$. Найти w^* и V^* при $r = 0,\,0{,}5$ и $0{,}9$.

Знаменатель $D = 5 - 4r$, числитель веса $1 - 2r$:

$$w^* = \frac{1-2r}{5-4r}, \qquad V^* = \frac{4(1-r^2)}{5-4r}.$$

r	w^*	V^*
0	$+0{,}200$	$0{,}800$
$0{,}5$	$0{,}000$	$1{,}000$
$0{,}9$	$-0{,}571$	$0{,}543$

При $r = 0{,}9$ вес худшего прибора отрицателен, а точность **лучше**, чем у лучшего прибора в одиночку ($\sigma_2^2 = 1$).

Итог

Что стоит помнить

Инструмент. Пара (a, Γ); Γ — ровно симметричная неотрицательно определённая, и никаких других условий.

Что стоит помнить

Инструмент. Пара (a, Γ); Γ — ровно симметричная неотрицательно определённая, и никаких других условий.

Что им делается. Дисперсия линейной комбинации $u^\intercal \Gamma u$; наилучший линейный прогноз с остаточной дисперсией $\mathrm{D}\eta(1 - r^2)$ и его векторный вариант — шаг фильтра Калмана; главные оси и доля объяснённой дисперсии; оценка уклонения через эллипсоид рассеяния.

Что стоит помнить

Инструмент. Пара (a, Γ); Γ — ровно симметричная неотрицательно определённая, и никаких других условий.

Что им делается. Дисперсия линейной комбинации $u^{\mathsf{T}}\Gamma u$; наилучший линейный прогноз с остаточной дисперсией $\mathrm{D}\eta(1 - r^2)$ и его векторный вариант — шаг фильтра Калмана; главные оси и доля объяснённой дисперсии; оценка уклонения через эллипсоид рассеяния.

Граница. Вне гауссовского случая корреляционная теория точна только внутри класса линейных процедур; разрыв между r^2 и ν^2 и есть её слепое пятно. В гауссовском случае слепого пятна нет.

Вопросы, которые стоит ожидать

- Какие матрицы бывают ковариационными? Следует ли из некоррелированности независимость? Что означает $r = 0$ и что $|r| = 1$?
- Зачем нужен коэффициент корреляции, если есть ковариация?
- В чём смысл неотрицательной определённости? Что даёт спектральное разложение?
- Как строится наилучший линейный прогноз и чему равна его ошибка? Почему условное математическое ожидание — наилучший прогноз? Когда он линеен?
- Чему равна дисперсия суммы зависимых величин?
- Может ли выборочная ковариационная матрица быть вырожденной?

Запасные кадры

Выборочная ковариационная матрица

$$\overline{\xi} = \frac{1}{N}\sum_{i=1}^{N}\xi^{(i)}, \qquad \hat{\Gamma} = \frac{1}{N-1}\sum_{i=1}^{N}(\xi^{(i)} - \overline{\xi})(\xi^{(i)} - \overline{\xi})^{\intercal}.$$

- несмещена: $\mathsf{E}\hat{\Gamma} = \Gamma$ при $N \geq 2$;
- всегда неотрицательно определена — проверять не нужно;
- при $N \leq n$ **обязана** быть вырожденной: $\operatorname{rank}\hat{\Gamma} \leq N - 1$.

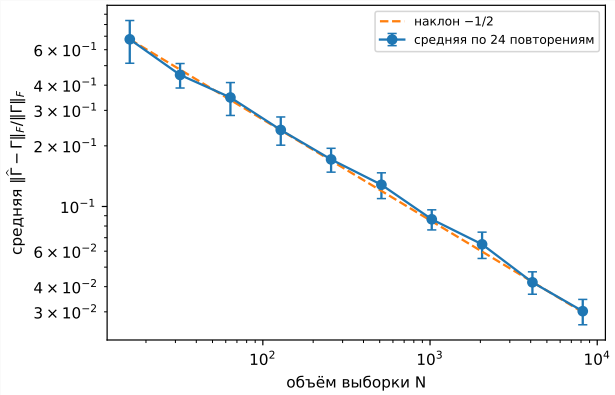
Выборочная ковариационная матрица

$$\overline{\xi} = \frac{1}{N}\sum_{i=1}^{N} \xi^{(i)}, \qquad \hat{\Gamma} = \frac{1}{N-1}\sum_{i=1}^{N} (\xi^{(i)} - \overline{\xi})(\xi^{(i)} - \overline{\xi})^{\mathsf{T}}.$$

- несмещена: $\mathsf{E}\hat{\Gamma} = \Gamma$ при $N \geq 2$;
- всегда неотрицательно определена — проверять не нужно;
- при $N \leq n$ **обязана** быть вырожденной: $\operatorname{rank} \hat{\Gamma} \leq N - 1$.

Последнее — практическая граница: при числе наблюдений, не превосходящем размерности, формулы наилучшей линейной оценки неприменимы буквально, и нужна либо регуляризация, либо понижение размерности.

Сходимость выборочной ковариационной матрицы



Относительная ошибка $\left\|\hat{\Gamma} - \Gamma\right\|_F / \|\Gamma\|_F$ в норме Фробениуса, логарифмические оси; $n = 8$, усреднение по 24 повторениям, усы — разброс по повторениям.

Измеренный наклон $-0{,}4923$ против предсказанного центральной предельной теоремой $-1/2$.

При $N = 4$ ранг равен 3, при $N = 8$ равен 7 — ровно $N - 1$.

Предложение 3 (оптимальность первых главных компонент)

Пусть $\Gamma = Q\Lambda Q^{\mathsf{T}}$ *– спектральное разложение ковариационной матрицы,* $\lambda_1 \geq \ldots \geq \lambda_n \geq 0$*, и пусть* $\mathcal{L}$ *– линейное подпространство* $\mathbb{R}^n$ *размерности* k*,* $\Pi_{\mathcal{L}}$ *– ортогональный проектор на него. Тогда*

$$\max_{\dim \mathcal{L}=k} \mathsf{E}\left\|\Pi_{\mathcal{L}}(\xi - a)\right\|^2 = \lambda_1 + \cdots + \lambda_k,$$

и максимум достигается на $\mathcal{L} = \operatorname{span}(q_1, \ldots, q_k)$.

Предложение 3 (оптимальность первых главных компонент)

Пусть $\Gamma = Q\Lambda Q^{\mathsf{T}}$ – спектральное разложение ковариационной матрицы, $\lambda_1 \geq \ldots \geq \lambda_n \geq 0$, и пусть $\mathcal{L}$ – линейное подпространство $\mathbb{R}^n$ размерности k, $\Pi_{\mathcal{L}}$ – ортогональный проектор на него. Тогда

$$\max_{\dim \mathcal{L}=k} \mathsf{E} \left\|\Pi_{\mathcal{L}}(\xi - a)\right\|^2 = \lambda_1 + \cdots + \lambda_k,$$

и максимум достигается на $\mathcal{L} = \operatorname{span}(q_1, \ldots, q_k)$.

Схема: $\mathsf{E} \left\|\Pi_L(\xi - a)\right\|^2 = \operatorname{tr}(U^{\mathsf{T}}\Gamma U) = \sum_j \lambda_j \beta_j$, где $\beta_j \in [0,1]$ и $\sum_j \beta_j = k$; среднее взвешенное максимально, когда масса на первых k номерах.

Метод даёт **некоррелированность**, а не независимость. Поиск независимых компонент требует моментов выше второго — и потому нетривиален только вне гауссовского случая.

Корреляционная функция (англ. *autocovariance*) и стационарность в широком смысле.

Определение 27 (характеристики случайного процесса)

Пусть $\{X(t),\ t \in T\}$ — семейство случайных величин с $\mathsf{E}X^2(t) < \infty$. **Математическим ожиданием** процесса называется функция $m_X(t) = \mathsf{E}X(t)$, **корреляционной функцией** (англ. *autocovariance*) — функция двух переменных

$$K_X(t_1, t_2) = \operatorname{cov}(X(t_1), X(t_2)) = \mathsf{E}\big(X(t_1) - m_X(t_1)\big)\big(X(t_2) - m_X(t_2)\big).$$

Процесс называется **стационарным в широком смысле**, если $m_X(t)$ постоянно, а $K_X(t_1, t_2)$ зависит только от разности $\tau = t_2 - t_1$; тогда пишут $K_X(\tau)$.

У части авторов буквой K_X обозначена **не**центрированная $\mathsf{E}X(t_1)X(t_2)$, а центрированная названа R_X: смотреть надо на формулу.

Та же теорема, применённая ко всем сечениям сразу

Предложение 4 (неотрицательная определённость корреляционной функции)

Для любого $l \in \mathbb{N}$, *любых* $t_1, \dots, t_l \in T$ *и любых* $c_1, \dots, c_l \in \mathbb{R}$

$$\sum_{k,j=1}^{l} c_k c_j \, K_X(t_k, t_j) \geq 0.$$

Это неотрицательная определённость ковариационной матрицы вектора $(X(t_1), \dots, X(t_l))$ — та же теорема.

Та же теорема, применённая ко всем сечениям сразу

Предложение 4 (неотрицательная определённость корреляционной функции)

Для любого $l \in \mathbb{N}$, *любых* $t_1, \dots, t_l \in T$ *и любых* $c_1, \dots, c_l \in \mathbb{R}$

$$\sum_{k,j=1}^{l} c_k c_j \, K_X(t_k, t_j) \geq 0.$$

Это неотрицательная определённость ковариационной матрицы вектора $(X(t_1), \dots, X(t_l))$ — та же теорема.

Дальше — **теорема Хинчина** (она же Бохнера — Хинчина): непрерывная корреляционная функция стационарного процесса есть преобразование Фурье конечной меры; если у меры есть плотность, её называют спектральной. Белый шум под теорему не подпадает: постоянная спектральная плотность отвечает бесконечной мере.

Предельный переход к двум датчикам

Формулы для двух датчиков — частный случай калмановской поправки при $n = 1$, $H = (1, 1)^\mathsf{T}$ и $P \to \infty$ (о величине заранее ничего не известно).

Предельный переход к двум датчикам

Формулы для двух датчиков — частный случай калмановской поправки при $n = 1$, $H = (1, 1)^{\mathsf{T}}$ и $P \to \infty$ (о величине заранее ничего не известно).

С $D = \sigma_1^2 + \sigma_2^2 - 2r\sigma_1\sigma_2$ и $C = \sigma_1^2\sigma_2^2(1 - r^2)$:

$$\det(PJ + \Gamma_\varepsilon) = PD + C, \qquad K = \frac{P}{PD + C}(\sigma_2^2 - r\sigma_1\sigma_2,\ \sigma_1^2 - r\sigma_1\sigma_2),$$

где $J = HH^{\mathsf{T}}$ — матрица 2×2 из одних единиц.

Предельный переход к двум датчикам

Формулы для двух датчиков — частный случай калмановской поправки при $n = 1$, $H = (1, 1)^{\mathsf{T}}$ и $P \to \infty$ (о величине заранее ничего не известно).

С $D = \sigma_1^2 + \sigma_2^2 - 2r\sigma_1\sigma_2$ и $C = \sigma_1^2\sigma_2^2(1 - r^2)$:

$$\det(PJ + \Gamma_\varepsilon) = PD + C, \qquad K = \frac{P}{PD + C}(\sigma_2^2 - r\sigma_1\sigma_2,\ \sigma_1^2 - r\sigma_1\sigma_2),$$

где $J = HH^{\mathsf{T}}$ — матрица 2×2 из одних единиц.

При $P \to \infty$ первая компонента стремится к w^*, сумма компонент — к единице, а дисперсия ошибки $(1 - KH)P = PC/(PD + C)$ — к $C/D = V^*$. Два вывода сошлись.

Зачем нужны конечные вторые моменты

Посылка $\mathrm{E}\xi^2 < \infty$ стоит в каждой теореме вопроса. Без неё ковариация и коэффициент корреляции **не существуют** — не «равны чему-то неудобному».

Зачем нужны конечные вторые моменты

Посылка $\mathrm{E}\xi^2 < \infty$ стоит в каждой теореме вопроса. Без неё ковариация и коэффициент корреляции **не существуют** — не «равны чему-то неудобному».

Опасность практическая: формула выборочной дисперсии считается по любым числам и всегда выдаёт число. Измерено на пяти объёмах выборки от 10^3 до $2 \cdot 10^6$: отношение наибольшей выборочной дисперсии к наименьшей равно $1{,}039$ для нормального закона и $5{,}2 \cdot 10^3$ для закона Коши, причём у второго значения не сглаживаются с ростом N, а прыгают.

Где корреляционная теория работает

Задача	Что берётся	Чего не даёт
объединение приборов	оптимальные веса и точность	оптимальность вне линейного класса
фильтрация состояния	корректирующий шаг без вида распределений	при негауссовском шуме есть оценки точнее
понижение размерности	главные оси и доля дисперсии	независимость: выходит лишь некоррелированность
регрессия	наилучший линейный прогноз и смысл r^2	причинную связь и нелинейную зависимость
оценка риска суммы	дисперсия линейной комбинации	хвосты: вторые моменты о редких событиях молчат

Ограничения, снимаемые за рамками вопроса

Ранговые коэффициенты Спирмена и Кендалла инвариантны относительно любого строго возрастающего преобразования каждой величины и равны ± 1 на любой монотонной зависимости. Цена — теряется связь с дисперсией прогноза.

Ограничения, снимаемые за рамками вопроса

Ранговые коэффициенты Спирмена и Кендалла инвариантны относительно любого строго возрастающего преобразования каждой величины и равны ± 1 на любой монотонной зависимости. Цена — теряется связь с дисперсией прогноза.

Копулы. По теореме Скляра совместная функция распределения представима как $C(F_\xi(x), F_\eta(y))$. Корреляционная теория описывает связь одним числом, копула — функцией, и потому различает поведение в хвостах.

Ограничения, снимаемые за рамками вопроса

Ранговые коэффициенты Спирмена и Кендалла инвариантны относительно любого строго возрастающего преобразования каждой величины и равны ± 1 на любой монотонной зависимости. Цена — теряется связь с дисперсией прогноза.

Копулы. По теореме Скляра совместная функция распределения представима как $C(F_\xi(x), F_\eta(y))$. Корреляционная теория описывает связь одним числом, копула — функцией, и потому различает поведение в хвостах.

Хвосты. Два момента дают о редких больших уклонениях только неравенство Чебышёва, то есть оценку порядка $1/c$; у лёгких хвостов настоящая вероятность экспоненциально мала. Это граница применимости в задачах о риске.

Источники

- [06] Турчин В. Н. Теория вероятностей и математическая статистика. — Днепр: Лира, 2018. §21.1 «Многомерное нормальное распределение», с. 517–526; ковариация и коэффициент корреляции — с. 109–110.
- [24] Гмурман В. Е. Теория вероятностей и математическая статистика: учеб. пособие для вузов. — 10-е изд., стер. — М.: Высш. шк., 2004. Гл. 14 §17–18 (корреляционный момент); гл. 23 §3, с. 388–389 — определение корреляционной теории.
- [07] Шабанов Д. А. Математическая статистика: конспект лекций мехмата МГУ. Теорема 10.4 о наилучшем квадратичном прогнозе, с. 98–99.
- [44] Гасников А. В. (ред.) и др. Лекции по случайным процессам. — М.: МФТИ, 2019. Определения 1.8–1.9, 4.4–4.5; теорема 4.5 (Бохнера — Хинчина).
- [62] Богачев В. И. Гауссовские меры. — М.: Наука, Физматлит, 1997. §1.2, с. 12–16.