

Вопрос 08. Случайные величины и векторы. Элементы корреляционной теории случайных величин

Конспект теории с полными доказательствами

Крохалев Е. М.

2026

Содержание

I. Основная часть	2
1. Постановка и мотивация	2
1.1. Сквозной пример: два датчика с коррелированными шумами	3
1.2. Место вопроса среди остальных	3
2. Что берётся готовым	3
3. Определения и обозначения	4
3.1. Случайная величина, случайный вектор, распределение	4
3.2. Моменты, ковариация, коэффициент корреляции	6
4. Коэффициент корреляции: что именно он измеряет	7
5. Ковариационная матрица	9
5.1. Как она преобразуется и что описывает	9
5.2. Описание класса ковариационных матриц	10
5.3. Главные оси	11
6. Наилучший прогноз	13
6.1. Наилучший линейный прогноз: скалярный случай	13
6.2. Наилучшая линейная оценка вектора по вектору	14
6.3. Прогноз без ограничения на класс	15
7. Гауссовский вектор: когда двух моментов хватает	17
8. Посылки: что ломается и как	20
8.1. Конечность вторых моментов	20
8.2. Некоррелированность не влечёт независимости	20
8.3. Невырожденность	21
8.4. Что именно утверждает коэффициент корреляции	21
9. Приложение 1: оптимальная обработка измерений и шаг фильтра Калмана	21
9.1. Два датчика	21
9.2. Общий случай: корректирующий шаг фильтра Калмана	22
10. Приложение 2: главные компоненты	23
11. Приложение 3: корреляционная теория случайных процессов	24

12. Вычислительная сторона	25
12.1 Выборочные оценки	25
12.2 Устойчивость счёта	26
12.3 Обращение ковариационной матрицы	26
13. Где корреляционная теория работает	27
14. Разобранные задачи	27
 II. Расширенная часть	 29
15. Предельный переход от калмановской поправки к двум датчикам	29
16. Сводка контрпримеров	30
17. Что дальше	30
18. Вопросы, которые стоит ожидать	31
19. Источники	32

Часть I.

Основная часть

1. Постановка и мотивация

Полное описание случайного вектора — это его распределение: мера на борелевских множествах $\mathbb{R}^n$. Пользоваться им напрямую почти никогда не удаётся. Распределение двумерного вектора задаётся функцией двух переменных, n -мерного — функцией n переменных; оценить такую функцию по данным нельзя уже при $n = 5$, а выписать её в модели можно лишь в немногих специальных случаях.

Поэтому в прикладной работе распределение заменяют **несколькими числами** — моментами, и почти всегда останавливаются на моментах первых двух порядков: векторе средних и ковариационной матрице. Теория, построенная на этой замене, называется **корреляционной**. Определение так и звучит: корреляционной называют теорию, основанную на изучении моментов первого и второго порядка ([24], гл. 23 §3); у Гмурмана оно дано для случайных функций, но рамка от этого не меняется.

Замена на два момента — сделка, и конспект отвечает на три вопроса о том, что именно в ней покупается и чем платится.

Первый: какие пары «вектор — матрица» бывают ковариационными? Вопрос не праздный: если в модель подставлена произвольная матрица, надо знать, бывает ли такая. Ответ полный — ровно симметричные неотрицательно определённые матрицы, и никаких других условий нет (теорема 5.5). Отсюда же получается практический критерий проверки и типичная ошибка при нём (замечание 5.6).

Второй: что по двум моментам можно посчитать, не зная распределения? Ответ: дисперсию любой линейной комбинации (теорема 5.3), наилучший линейный прогноз и его точность (теоремы 6.1 и 6.4), главные оси рассеяния (теорема 5.8), оценку вероятности большого отклонения (теорема 5.10). Этого хватает, чтобы построить оптимальную обработку измерений нескольких приборов и корректирующий шаг фильтра Калмана — и то и другое выводится здесь из одной теоремы.

Третий: когда двух моментов хватает полностью? Ответ точный: ровно в гауссовском случае. Там распределение определяется парой (a, Γ) , некоррелированность равносильна

независимости, а условное математическое ожидание линейно — то есть наилучший прогноз совпадает с наилучшим линейным (раздел 7). Вне гауссовского случая разрыв между ними может быть каким угодно, вплоть до полного: раздел 8 показывает пару, у которой коэффициент корреляции равен нулю, а одна величина есть функция другой.

Так устроен вопрос: **сперва описывается инструмент (ковариационная матрица), потом то, что им делается (прогноз и главные оси), потом граница его применимости (гауссовский случай против общего).**

1.1. Сквозной пример: два датчика с коррелированными шумами

Через весь конспект проходит один пример. Две измерительные системы дают оценки η_1 и η_2 одной и той же величины μ :

$$\eta_1 = \mu + \varepsilon_1, \quad \eta_2 = \mu + \varepsilon_2, \quad (1)$$

погрешности $\varepsilon_1, \varepsilon_2$ имеют нулевые средние, дисперсии σ_1^2 и σ_2^2 и коэффициент корреляции r . Корреляция здесь не надуманная: приборы стоят в одном помещении и общий дрейф температуры входит в обе погрешности.

Спрашивается, как объединить два показания в одно, и что даёт корреляция. Ответ — в разделе 9, и он содержательнее, чем можно ожидать: при $\sigma_1 \neq \sigma_2$ и $r \rightarrow 1$ дисперсия наилучшей линейной комбинации стремится к **нулю**. Полностью коррелированный шум вычитается: одно измерение служит мерой погрешности другого. То есть **корреляция — это информация, а не только помеха**, и корреляционная теория как раз и есть аппарат, позволяющий эту информацию извлечь.

Второе, что видно на этом примере: при $\sigma_1 \neq \sigma_2$ и достаточно большом r оптимальный вес у **худшего** прибора отрицателен. Правило «усреднить показания», взятое без корреляционной теории, в этом случае даёт заведомо не лучший ответ.

1.2. Место вопроса среди остальных

Вопрос не требует от программы ничего: все нужные понятия вводятся здесь. Внешний аппарат — теория меры и интеграла и спектральная теорема для симметричной матрицы; и то и другое выписано в разделе 2.

Продолжений у вопроса четыре, и каждое берёт отсюда своё.

Вопрос о законе больших чисел и центральной предельной теореме берёт отсюда только определения и неравенство Чебышёва — и выписывает их у себя сам, потому что каждый конспект самодостаточен. Вопрос о принятии решения берёт квадратичную функцию потерь и то, что байесовская оценка при ней есть условное математическое ожидание (теорема 6.6). Вопрос о методе главных компонент — прямое продолжение теоремы о главных осях (теорема 5.8). Вопрос о линейной регрессии стоит на теореме о наилучшем линейном прогнозе (теорема 6.1): метод наименьших квадратов есть её выборочный вариант.

Есть и обратная связка, важная для ответа: условное математическое ожидание — ортогональная проекция в пространстве L_2 , и существование её даёт теорема о проекции из вопроса о гильбертовых пространствах. В этом конспекте условное математическое ожидание берётся готовым вместе со списком свойств (раздел 2), а то, что оно минимизирует средний квадрат, доказывается.

2. Что берётся готовым

Всё вероятностное, относящееся к моментам первых двух порядков, здесь доказывается. Готовыми берутся факты трёх сортов.

Теория меры и интеграла. Линейность и монотонность интеграла Лебега; непрерывность меры по монотонным последовательностям множеств; теорема о единственности

продолжения меры с π -системы, порождающей σ -алгебру; теорема Фубини — Тонелли для произведения конечных мер; интеграл по образу меры (он же формула $Eg(\xi) = \int g dF_\xi$); формула замены переменных в кратном интеграле; дифференцирование под знаком интеграла при мажорируемой производной; теорема о мажорируемой сходимости. Отдельно — значение интеграла Пуассона $\int_{\mathbb{R}} e^{-u^2/2} du = \sqrt{2\pi}$.

Условное математическое ожидание. Для ξ с $E|\xi| < \infty$ и под- σ -алгебры $\mathcal{G} \subset \mathcal{F}$ существует и единственна с точностью до равенства почти наверное $\mathcal{G}$ -измеримая величина $E(\xi | \mathcal{G})$ с $E(E(\xi | \mathcal{G})\mathbb{1}_A) = E(\xi\mathbb{1}_A)$ при всех $A \in \mathcal{G}$. Берутся её линейность, равенство $E(E(\xi | \mathcal{G})) = E\xi$ и вынесение измеримого множителя: если ζ $\mathcal{G}$ -измерима и $E|\zeta\xi| < \infty$, то $E(\zeta\xi | \mathcal{G}) = \zeta E(\xi | \mathcal{G})$. Запись $E(\xi | \eta)$ означает $E(\xi | \sigma(\eta))$, где $\sigma(\eta)$ — σ -алгебра, порождённая случайным вектором η .

Линейная алгебра. Спектральная теорема: у вещественной симметричной матрицы Γ существует ортогональная Q с $Q^T \Gamma Q = \Lambda = \text{diag}(\lambda_1, \dots, \lambda_n)$, λ_k вещественны ([01] §30.1, с. 105; свёрка — [02], теорема 8.1.1, с. 369, «симметричное вещественное разложение Шура»). Инвариантность следа относительно подобия. Отсюда получается матричный корень: для неотрицательно определённой Γ полагаем $\Gamma^{1/2} = Q\Lambda^{1/2}Q^T$, где $\Lambda^{1/2} = \text{diag}(\sqrt{\lambda_1}, \dots, \sqrt{\lambda_n})$; он симметричен, неотрицательно определён и $(\Gamma^{1/2})^2 = \Gamma$.

Теорема единственности для характеристических функций на $\mathbb{R}^n$: различным распределениям отвечают различные характеристические функции ([06], теорема 21.1.2). Она нужна только в разделе 7.

Свёрка [01] с [02] — не формальность: авторы [01] предупреждают, что начиная с девятнадцатой лекции возможны ошибки, а спектральная теорема стоит в тридцатой.

3. Определения и обозначения

Обозначения. $(\Omega, \mathcal{F}, P)$ — вероятностное пространство: Ω — множество исходов, $\mathcal{F}$ — σ -алгебра событий, P — вероятностная мера. $\mathcal{B}(\mathbb{R}^n)$ — борелевская σ -алгебра на $\mathbb{R}^n$; при $n = 1$ пишем $\mathcal{B}$.

Векторы — столбцы; $u^T v = \langle u, v \rangle$ — скалярное произведение, $\|u\|$ — евклидова норма. Для матриц $A \succeq B$ означает, что $A - B$ симметрична и неотрицательно определена; $A \succ B$ — что положительно определена. Запись $\Lambda = \text{diag}(\lambda_1, \dots, \lambda_n)$ — диагональная матрица, I — единичная.

Буква n — размерность случайного вектора, m — число измерений, N — объём выборки. Буква r обозначает коэффициент корреляции (как у [06] и [24]), Γ — ковариационную матрицу (как у [06]), a — вектор средних. Верхний кружок $\xi^\circ = \xi - E\xi$ обозначает центрирование.

3.1. Случайная величина, случайный вектор, распределение

Определение 3.1 (случайный вектор). **Случайным вектором** (англ. *random vector*) размерности n называется измеримое отображение $\xi: \Omega \rightarrow \mathbb{R}^n$, то есть такое, что $\xi^{-1}(B) \in \mathcal{F}$ при всех $B \in \mathcal{B}(\mathbb{R}^n)$. При $n = 1$ он называется **случайной величиной** (англ. *random variable*). **Распределением** вектора ξ называется мера $F_\xi(B) = P\{\xi \in B\}$ на $\mathcal{B}(\mathbb{R}^n)$, **функцией распределения** — функция

$$F_\xi(x_1, \dots, x_n) = P\{\xi_1 \leq x_1, \dots, \xi_n \leq x_n\}.$$

Мера F_ξ и функция F_ξ обозначены одной буквой, как принято: их различает вид аргумента.

Теорема 3.2 (критерий измеримости по компонентам). *Отображение $\xi = (\xi_1, \dots, \xi_n)^T: \Omega \rightarrow \mathbb{R}^n$ является случайным вектором тогда и только тогда, когда каждая его компонента ξ_k является случайной величиной.*

Доказательство. Необходимость. Проекция $\pi_k: \mathbb{R}^n \rightarrow \mathbb{R}$ непрерывна, значит борелевски измерима, а композиция измеримых отображений измерима: для $B \in \mathcal{B}$ имеем $\xi_k^{-1}(B) = \xi^{-1}(\pi_k^{-1}(B)) \in \mathcal{F}$, поскольку $\pi_k^{-1}(B) \in \mathcal{B}(\mathbb{R}^n)$.

Достаточность. Пусть все ξ_k измеримы. Рассмотрим класс

$$\mathcal{D} = \{B \subset \mathbb{R}^n: \xi^{-1}(B) \in \mathcal{F}\}.$$

Прообраз перестановочен с дополнением и со счётным объединением, поэтому $\mathcal{D}$ — σ -алгебра. Для параллелепипеда $P = (-\infty, x_1] \times \dots \times (-\infty, x_n]$ имеем

$$\xi^{-1}(P) = \bigcap_{k=1}^n \{\xi_k \leq x_k\} \in \mathcal{F},$$

то есть $\mathcal{D}$ содержит все такие параллелепипеды. Они порождают $\mathcal{B}(\mathbb{R}^n)$: всякое открытое множество в $\mathbb{R}^n$ есть счётное объединение открытых параллелепипедов с рациональными вершинами, открытый параллелепипед есть счётное возрастающее объединение полузамкнутых $\prod_k (\alpha_k, \beta_k]$, а каждый такой получается из четырёх параллелепипедов вида P конечным числом теоретико-множественных операций. Значит $\mathcal{D} \supset \mathcal{B}(\mathbb{R}^n)$, что и требовалось. $\square$

Теорема 3.2 говорит, что работа с вектором не требует новой проверки измеримости: если компоненты — случайные величины, вектор из них автоматически случайный. Это и позволяет дальше не возвращаться к вопросу об измеримости.

Следующая теорема отвечает на вопрос, какие функции бывают функциями распределения. Ответ нужен по двум причинам: он показывает, что распределение можно задавать функцией распределения (а не мерой), и попутно даёт способ моделировать случайную величину с заданным законом.

Теорема 3.3 (свойства функции распределения и обратная теорема). *Пусть ξ — случайная величина. Тогда её функция распределения $F = F_\xi$*

1. *не убывает;*
2. *удовлетворяет $\lim_{x \rightarrow -\infty} F(x) = 0$ и $\lim_{x \rightarrow +\infty} F(x) = 1$;*
3. *непрерывна справа в каждой точке.*

Обратно, всякая функция $F: \mathbb{R} \rightarrow [0, 1]$ со свойствами 1-3 является функцией распределения некоторой случайной величины, заданной на отрезке $(0, 1)$ с мерой Лебега.

Доказательство. Прямая часть. При $x \leq y$ событие $\{\xi \leq x\}$ содержится в $\{\xi \leq y\}$, откуда монотонность. Далее, события $\{\xi \leq x\}$ при $x \uparrow +\infty$ по целым x возрастают к Ω , а при $x \downarrow -\infty$ убывают к пустому множеству; по непрерывности меры пределы равны 1 и 0, а монотонность F превращает предел по целой последовательности в предел по непрерывному аргументу. Непрерывность справа: при $x_j \downarrow x$ события $\{\xi \leq x_j\}$ убывают, и их пересечение равно $\{\xi \leq x\}$, откуда $F(x_j) \rightarrow F(x)$.

Обратная часть. Возьмём $\Omega = (0, 1)$, $\mathcal{F} = \mathcal{B} \cap (0, 1)$, $\mathbf{P}$ — меру Лебега, и положим

$$\xi(u) = F^-(u) = \inf\{x \in \mathbb{R}: F(x) \geq u\}, \quad u \in (0, 1). \quad (2)$$

Множество $A_u = \{x: F(x) \geq u\}$ непусто (иначе $F(x) < u < 1$ при всех x , что противоречит свойству 2) и ограничено снизу (иначе $F(x) \geq u > 0$ при сколь угодно малых x), так что нижняя грань конечна.

Проверим ключевое равносильное соотношение

$$F^-(u) \leq x \iff u \leq F(x). \quad (3)$$

Если $u \leq F(x)$, то $x \in A_u$ и потому $F^-(u) \leq x$. Обратно, пусть $F^-(u) \leq x$. Множество A_u вместе с точкой содержит луч вправо (свойство 1) и содержит свою нижнюю грань $c = F^-(u)$: беря $x_j \downarrow c$ с $x_j \in A_u$, получаем $F(c) = \lim F(x_j) \geq u$ по непрерывности справа. Значит $F(c) \geq u$, а из $c \leq x$ и монотонности $F(x) \geq F(c) \geq u$.

Из (3) следует

$$\mathbf{P}\{\xi \leq x\} = \mathbf{P}\{u \in (0, 1) : u \leq F(x)\} = F(x),$$

поскольку мера Лебега интервала $(0, F(x)] \cap (0, 1)$ равна $F(x)$. Измеримость ξ вытекает из того же соотношения: прообраз луча $(-\infty, x]$ есть промежуток. Итак, F — функция распределения величины ξ . $\square$

Замечание 3.4 (метод обратной функции). Равенство (2) — это и есть рецепт моделирования: если u разыграно равномерно на $(0, 1)$, то $F^-(u)$ имеет заданное распределение F . Доказательство обратной части теоремы 3.3 и есть обоснование метода обратной функции, на котором стоит вся техника разыгрывания распределений в методе Монте-Карло. Особо отметим, что непрерывность и строгая монотонность F не нужны: определение через нижнюю грань работает и для дискретных законов, где обычная обратная функция не существует.

Определение 3.5 (плотность, маргинальные распределения, независимость). **Плотностью** распределения вектора ξ называется такая борелевская $p \geq 0$, что $F_\xi(B) = \int_B p(x) dx$ при всех $B \in \mathcal{B}(\mathbb{R}^n)$; тогда $Eg(\xi) = \int_{\mathbb{R}^n} g(x)p(x) dx$ для всякой борелевской $g \geq 0$ и всякой g с $E|g(\xi)| < \infty$.

Маргинальным (частным) распределением компоненты ξ_k называется её собственное распределение; оно получается из совместного предельным переходом $F_{\xi_k}(x_k) = \lim F_\xi(x_1, \dots, x_n)$ при $x_j \rightarrow +\infty, j \neq k$.

Случайные векторы $\xi \in \mathbb{R}^n$ и $\eta \in \mathbb{R}^m$ **независимы**, если их совместное распределение есть произведение распределений: $F_{(\xi, \eta)} = F_\xi \otimes F_\eta$. Набор $\xi_1, \dots, \xi_n$ **независим в совокупности**, если совместное распределение есть произведение всех n распределений.

Произведение мер однозначно определяется своими значениями на прямоугольниках, а те образуют π -систему, порождающую $\mathcal{B}(\mathbb{R}^{n+m})$; поэтому независимость равносильна равенству $F_{(\xi, \eta)}(x, y) = F_\xi(x)F_\eta(y)$ для функций распределения — проверять достаточно его.

3.2. Моменты, ковариация, коэффициент корреляции

Определение 3.6 (моменты). $E\xi = \int_{\Omega} \xi dP$ — **математическое ожидание** (определено при $E|\xi| < \infty$); $D\xi = E(\xi - E\xi)^2$ — **дисперсия**, $\sigma_\xi = \sqrt{D\xi}$ — **стандартное уклонение**. Для случайной матрицы $V = [v_{kj}]$ полагаем $EV = [Ev_{kj}]$; в частности, $E\xi = (E\xi_1, \dots, E\xi_n)^T$ для вектора.

Определение 3.7 (ковариация и коэффициент корреляции). Пусть $E\xi^2 < \infty$ и $E\eta^2 < \infty$. **Ковариацией** (англ. *covariance*; в русской традиции также *корреляционный момент* — [24], гл. 14 §17) называется число

$$\text{cov}(\xi, \eta) = E(\xi - E\xi)(\eta - E\eta) = E\xi\eta - E\xi E\eta.$$

Если $\sigma_\xi > 0$ и $\sigma_\eta > 0$, **коэффициентом корреляции** (англ. *correlation coefficient*) называется

$$r(\xi, \eta) = \frac{\text{cov}(\xi, \eta)}{\sigma_\xi \sigma_\eta}.$$

Величины с $\text{cov}(\xi, \eta) = 0$ называются **некоррелированными**.

Определение корректно: из $|\xi\eta| \leq \frac{1}{2}(\xi^2 + \eta^2)$ и $|\xi| \leq \frac{1}{2}(\xi^2 + 1)$ следует, что конечность вторых моментов влечёт конечность $E|\xi\eta|$, $E|\xi|$ и $E|\eta|$, так что все три слагаемые в определении существуют ([06], с. 109). Второе выражение для ковариации получается раскрытием скобок и линейностью.

Замечание 3.8 (два имени и разные единицы). Слово «корреляционный момент» у [24] означает ровно ковариацию, и стоит помнить оба имени: экзаменатор пользуется тем, к которому привык. У Гмурмана же взято и наблюдение, объясняющее, зачем вообще нужен коэффициент корреляции: ковариация имеет размерность произведения величин, и потому при переходе от сантиметров к миллиметрам значение 2 превращается в 200, тогда как коэффициент корреляции безразмерен и от выбора единиц не зависит.

Определение 3.9 (вектор средних и ковариационная матрица). Пусть у всех компонент вектора $\xi \in \mathbb{R}^n$ конечны вторые моменты. Его **вектор средних** — $a = E\xi$, **ковариационная матрица** (англ. *covariance matrix*) —

$$\Gamma_\xi = E(\xi - a)(\xi - a)^\top, \quad (\Gamma_\xi)_{kj} = \text{cov}(\xi_k, \xi_j).$$

Для пары векторов $\xi \in \mathbb{R}^n$, $\eta \in \mathbb{R}^m$ **взаимной ковариационной матрицей** называется прямоугольная матрица $\Gamma_{\xi\eta} = E(\xi - E\xi)(\eta - E\eta)^\top$ размера $n \times m$; очевидно $\Gamma_{\eta\xi} = \Gamma_{\xi\eta}^\top$. **Корреляционной матрицей** называется матрица $R_\xi = [r(\xi_k, \xi_j)]$ (определена при всех $\sigma_{\xi_k} > 0$); она получается из Γ_ξ нормировкой: $R_\xi = S^{-1}\Gamma_\xi S^{-1}$, где $S = \text{diag}(\sigma_{\xi_1}, \dots, \sigma_{\xi_n})$.

Диагональ ковариационной матрицы — дисперсии компонент: $(\Gamma_\xi)_{kk} = D\xi_k$; диагональ корреляционной состоит из единиц.

Замечание 3.10 (ловушка имён). В части прикладной литературы «корреляционной матрицей» называют то, что здесь названо ковариационной. Различие содержательное — нормированная и ненормированная матрицы не совпадают, если дисперсии компонент не равны единице, — поэтому при чтении надо смотреть на формулу, а не на имя. Мы держим имена раздельно: *ковариационная* — из вторых центральных моментов, *корреляционная* — из коэффициентов корреляции.

Предложение 3.11 (линейность математического ожидания матрицы). Для случайных матриц V, W размера $n \times m$ с конечными математическими ожиданиями и постоянных матриц A размера $p \times n$, B размера $m \times q$

$$E(V + W) = EV + EW, \quad E(AB) = A(EV)B.$$

Доказательство. Оба равенства проверяются поэлементно: элемент матрицы AB есть $\sum_{k,l} A_{ik} v_{kl} B_{lj}$ — конечная линейная комбинация элементов V с постоянными коэффициентами, и остаётся сослаться на линейность математического ожидания скалярных величин ([06], с. 517). $\square$

Определение 3.12 (корреляционная теория). **Корреляционной теорией** (англ. *second-order theory*) называется теория, основанная на изучении моментов первого и второго порядка ([24], гл. 23 §3, с. 388–389). Для случайного вектора это означает работу с парой (a, Γ_ξ) вместо распределения.

4. Коэффициент корреляции: что именно он измеряет

Теорема 4.1 (неравенство Коши — Буняковского для моментов). Пусть $E\xi^2 < \infty$ и $E\eta^2 < \infty$. Тогда $E|\xi\eta| < \infty$ и

$$(E\xi\eta)^2 \leq E\xi^2 \cdot E\eta^2. \quad (4)$$

Равенство достигается тогда и только тогда, когда найдётся пара чисел $(\alpha, \beta) \neq (0, 0)$, при которой $\alpha\xi + \beta\eta = 0$ почти наверное.

Доказательство. Конечность $E|\xi\eta|$ уже отмечена после определения 3.7.

Пусть сперва $E\xi^2 > 0$. Для всякого $\lambda \in \mathbb{R}$

$$q(\lambda) = E(\lambda\xi + \eta)^2 = \lambda^2 E\xi^2 + 2\lambda E\xi\eta + E\eta^2 \geq 0,$$

поскольку под знаком математического ожидания стоит неотрицательная величина. Квадратный трёхчлен с положительным старшим коэффициентом неотрицателен при всех λ тогда и только тогда, когда его дискриминант неположителен:

$$4(E\xi\eta)^2 - 4E\xi^2 E\eta^2 \leq 0,$$

что и есть (4).

Если же $E\xi^2 = 0$, то $\xi = 0$ почти наверное, а тогда $E\xi\eta = 0$ и обе части (4) равны нулю: неравенство обращается в равенство, и требуемое соотношение $1 \cdot \xi + 0 \cdot \eta = 0$ почти наверное выполнено.

Условие равенства. Пусть $E\xi^2 > 0$ и в (4) равенство. Тогда дискриминант равен нулю, значит существует λ_0 с $q(\lambda_0) = 0$, то есть $E(\lambda_0\xi + \eta)^2 = 0$. Математическое ожидание неотрицательной величины равно нулю лишь тогда, когда величина равна нулю почти наверное, откуда $\lambda_0\xi + \eta = 0$ почти наверное; пара $(\lambda_0, 1)$ ненулевая. Случай $E\xi^2 = 0$ разобран выше.

Обратно, пусть $\alpha\xi + \beta\eta = 0$ почти наверное при $(\alpha, \beta) \neq (0, 0)$. Если $\beta \neq 0$, то $\eta = -(\alpha/\beta)\xi$ почти наверное; обозначив $c = -\alpha/\beta$, получаем $(E\xi\eta)^2 = c^2(E\xi^2)^2$ и $E\xi^2 E\eta^2 = E\xi^2 \cdot c^2 E\xi^2 = c^2(E\xi^2)^2$ — равенство. Если же $\beta = 0$, то $\alpha \neq 0$ и $\xi = 0$ почти наверное, и обе части нули. $\square$

Следствие 4.2 (границы ковариации и коэффициента корреляции). Для величин с конечными вторыми моментами

$$|\text{cov}(\xi, \eta)| \leq \sigma_\xi \sigma_\eta,$$

а при $\sigma_\xi > 0, \sigma_\eta > 0$ выполнено $|r(\xi, \eta)| \leq 1$.

Доказательство. Применяем теорему 4.1 к центрированным величинам ξ° и η° : там $E\xi^\circ\eta^\circ = \text{cov}(\xi, \eta)$, $E(\xi^\circ)^2 = D\xi$, $E(\eta^\circ)^2 = D\eta$. Деление на $\sigma_\xi\sigma_\eta > 0$ даёт вторую оценку. $\square$

Теорема 4.3 (критерий $|r| = 1$). Пусть $\sigma_\xi > 0$ и $\sigma_\eta > 0$. Тогда $|r(\xi, \eta)| = 1$ в том и только том случае, когда существуют числа $a \neq 0$ и b , при которых $\eta = a\xi + b$ почти наверное. При этом

$$|a| = \frac{\sigma_\eta}{\sigma_\xi}, \quad \text{sign } a = \text{sign } r(\xi, \eta).$$

Доказательство. Необходимость. Равенство $|r| = 1$ означает равенство в (4) для центрированных величин, то есть $\alpha\xi^\circ + \beta\eta^\circ = 0$ почти наверное при некоторой ненулевой паре (α, β) . Здесь $\beta \neq 0$: иначе $\alpha \neq 0$ и $\xi^\circ = 0$ почти наверное, что противоречит $\sigma_\xi > 0$. Значит $\eta^\circ = a\xi^\circ$ почти наверное с $a = -\alpha/\beta$, и тогда $\eta = a\xi + b$ с $b = E\eta - aE\xi$. Величина a не равна нулю: при $a = 0$ получилось бы $\sigma_\eta = 0$.

Достаточность и вычисление a . Пусть $\eta = a\xi + b$ почти наверное, $a \neq 0$. Тогда $\eta^\circ = a\xi^\circ$, откуда $D\eta = a^2 D\xi$, то есть $\sigma_\eta = |a| \sigma_\xi$, и $\text{cov}(\xi, \eta) = Ea(\xi^\circ)^2 = aD\xi$. Следовательно

$$r(\xi, \eta) = \frac{a \sigma_\xi^2}{\sigma_\xi \cdot |a| \sigma_\xi} = \frac{a}{|a|} = \text{sign } a,$$

что даёт и $|r| = 1$, и оба заявленных равенства. $\square$

Теоремы 4.1 и 4.3 вместе отвечают на вопрос, что измеряет коэффициент корреляции: он лежит в $[-1, 1]$, и крайние значения достигаются ровно на почти наверное линейной зависимости. Отсюда и его имя в русской литературе — мера **линейной** связи; про нелинейную он не утверждает ничего, и раздел 8 показывает, насколько «ничего» здесь буквально.

Предложение 4.4 (независимость влечёт некоррелированность). Если ξ и η независимы и имеют конечные вторые моменты, то $\text{cov}(\xi, \eta) = 0$.

Доказательство. При независимости совместное распределение есть произведение, поэтому по теореме Фубини $E\xi\eta = \int xy F_\xi(dx)F_\eta(dy) = E\xi E\eta$; применимость Фубини обеспечена конечностью $E|\xi\eta|$, которая, в свою очередь, получается той же выкладкой для модулей (это половина Тонелли, предположения интегрируемости не требующая). Остаётся вычесть. $\square$

Обратное неверно, и это главное ограничение всей корреляционной теории; контрпримеры — в разделе 8.

5. Ковариационная матрица

5.1. Как она преобразуется и что описывает

Теорема 5.1 (преобразование при аффинном отображении). Пусть u вектора $\xi \in \mathbb{R}^n$ конечны вторые моменты компонент, A — постоянная матрица размера $p \times n$, $b \in \mathbb{R}^p$. Тогда

$$E(A\xi + b) = AE\xi + b, \quad \Gamma_{A\xi+b} = A\Gamma_\xi A^T.$$

Для второго вектора $\eta \in \mathbb{R}^m$ и постоянной B размера $q \times m$ выполнено $\Gamma_{A\xi, B\eta} = A\Gamma_{\xi\eta}B^T$.

Доказательство. Первое равенство — линейность (предложение 3.11). Далее, $(A\xi + b) - E(A\xi + b) = A(\xi - E\xi)$, поэтому

$$\Gamma_{A\xi+b} = E(A(\xi - E\xi))(A(\xi - E\xi))^T = E\left(A(\xi - E\xi)(\xi - E\xi)^T A^T\right) = A\Gamma_\xi A^T,$$

где последний переход — снова предложение 3.11 с постоянными множителями слева и справа. Смешанный случай разбирается дословно так же ([06], лемма 21.1.1). $\square$

Следствие 5.2 (сдвиг не меняет ковариаций). $\Gamma_{\xi+b} = \Gamma_\xi$ при любом постоянном b : ковариационная матрица — характеристика разброса, а не положения.

Теорема 5.3 (дисперсия линейной комбинации). Для любого $u \in \mathbb{R}^n$

$$D\langle u, \xi \rangle = u^T \Gamma_\xi u = \sum_{k,j=1}^n u_k u_j \text{cov}(\xi_k, \xi_j). \quad (5)$$

Доказательство. Это теорема 5.1 при $A = u^T$, $b = 0$: ковариационная матрица одномерного вектора $\langle u, \xi \rangle$ есть его дисперсия. $\square$

Следствие 5.4 (дисперсия суммы).

$$D\left(\sum_{k=1}^n \xi_k\right) = \sum_{k=1}^n D\xi_k + 2 \sum_{k<j} \text{cov}(\xi_k, \xi_j).$$

В частности, если величины попарно некоррелированы, дисперсия суммы равна сумме дисперсий.

Доказательство. Формула (5) при $u = (1, \dots, 1)^T$; диагональные слагаемые дают дисперсии, внедиагональные попарно совпадают по симметрии ковариации. $\square$

Следствие 5.4 — это ровно то место, где корреляционная теория входит в закон больших чисел: там нужна аддитивность дисперсии, и нужна она только для попарно некоррелированных слагаемых, а независимость оказывается избыточным требованием.

5.2. Описание класса ковариационных матриц

Теорема 5.5 (какие матрицы бывают ковариационными). 1. Ковариационная матрица всякого случайного вектора симметрична и неотрицательно определена.

2. Обратно, для всякой симметричной неотрицательно определённой матрицы Γ размера $n \times n$ и всякого $a \in \mathbb{R}^n$ существует случайный вектор ξ с $E\xi = a$ и $\Gamma_\xi = \Gamma$.

Доказательство. Пункт 1. Симметричность очевидна из $\text{cov}(\xi_k, \xi_j) = \text{cov}(\xi_j, \xi_k)$. Неотрицательная определённость — прямое следствие теоремы 5.3: при любом u

$$u^T \Gamma_\xi u = D \langle u, \xi \rangle = E \langle u, \xi - a \rangle^2 \geq 0$$

как математическое ожидание неотрицательной величины.

Пункт 2. Построим вероятностное пространство явно, чтобы не опираться на существование нормального закона. Возьмём $\Omega = \{-1, 1\}^n$ с равномерной мерой (все 2^n исходов равновероятны) и положим $\zeta_k(\omega) = \omega_k$. Компоненты $\zeta = (\zeta_1, \dots, \zeta_n)^T$ независимы в совокупности, $E\zeta_k = 0$, $D\zeta_k = E\zeta_k^2 = 1$, и потому $\Gamma_\zeta = I$ (внедиагональные элементы равны нулю по предложению 4.4).

Матрица Γ симметрична и неотрицательно определена, значит определён её корень $\Gamma^{1/2}$ (раздел 2). Положим $\xi = \Gamma^{1/2}\zeta + a$. По теореме 5.1

$$E\xi = a, \quad \Gamma_\xi = \Gamma^{1/2} I (\Gamma^{1/2})^T = \Gamma^{1/2} \Gamma^{1/2} = \Gamma,$$

поскольку $\Gamma^{1/2}$ симметричен. □

Пункт 2 — не техническая подробность, а содержательное утверждение: **корреляционная теория не накладывает на пару (a, Γ) никаких условий, кроме симметрии и неотрицательной определённости**. Поэтому вопрос «бывает ли такая ковариационная матрица» сводится к проверке неотрицательной определённости — и нигде больше не требует знания распределения.

Замечание 5.6 (угловых миноров недостаточно). Критерий Сильвестра в ходовой формулировке — «все угловые миноры положительны» — проверяет *положительную* определённость. Для *неотрицательной* определённости условие «все угловые миноры неотрицательны» ложно. Контрпример на матрице 2×2 :

$$\Gamma = \begin{pmatrix} 0 & 0 \\ 0 & -1 \end{pmatrix},$$

угловые миноры равны 0 и 0, оба неотрицательны, а $u^T \Gamma u = -u_2^2 < 0$ при $u = (0, 1)^T$. Верный критерий требует неотрицательности *всех* главных миноров, а не только угловых; на практике проще считать собственные значения или пытаться построить разложение Холецкого.

Теорема 5.7 (вырожденность и размерность носителя). Пусть $a = E\xi$, $\Gamma = \Gamma_\xi$. Тогда

1. для $u \in \mathbb{R}^n$ равенство $u^T \Gamma u = 0$ равносильно $\langle u, \xi - a \rangle = 0$ почти наверное;
2. если $\text{rank } \Gamma = k$, то почти наверное $\xi \in a + \mathcal{L}$, где $\mathcal{L} = \text{Im } \Gamma$ — линейное подпространство размерности k .

Доказательство. Пункт 1. По теореме 5.3 $u^T \Gamma u = E \langle u, \xi - a \rangle^2$. Математическое ожидание неотрицательной величины равно нулю тогда и только тогда, когда величина равна нулю почти наверное.

Пункт 2. Матрица Γ симметрична, поэтому $\ker \Gamma = (\operatorname{Im} \Gamma)^\perp$ и $\dim \ker \Gamma = n - k$. Заметим, что $u \in \ker \Gamma$ влечёт $u^T \Gamma u = 0$. Возьмём базис $u_1, \dots, u_{n-k}$ ядра; по пункту 1 каждое событие $\{\langle u_i, \xi - a \rangle = 0\}$ имеет вероятность 1, а пересечение конечного числа событий вероятности 1 имеет вероятность 1. Значит почти наверное $\xi - a$ ортогонален всему $\ker \Gamma$, то есть $\xi - a \in (\ker \Gamma)^\perp = \operatorname{Im} \Gamma$. $\square$

Теорема 5.7 объясняет, что означает вырожденность ковариационной матрицы: не «плохую обусловленность», а точную линейную связь между компонентами, выполненную почти наверное. В сквозном примере (1) это случай $|r| = 1$: показания двух приборов связаны точным линейным соотношением, и одно из них лишнее — либо, наоборот, позволяет полностью вычесть шум другого (раздел 9).

5.3. Главные оси

Теорема 5.8 (главные оси рассеяния). Пусть $\Gamma = \Gamma_\xi$, $\Gamma = Q\Lambda Q^T$ — её спектральное разложение, $Q = [q_1, \dots, q_n]$ ортогональна, $\Lambda = \operatorname{diag}(\lambda_1, \dots, \lambda_n)$, $\lambda_1 \geq \dots \geq \lambda_n \geq 0$. Тогда

1. компоненты вектора $\zeta = Q^T(\xi - a)$ попарно некоррелированы и $D\zeta_k = \lambda_k$;
2. $\max_{\|u\|=1} D \langle u, \xi \rangle = \lambda_1$, и максимум достигается при $u = q_1$; аналогично минимум равен λ_n и достигается при $u = q_n$;
3. $\operatorname{tr} \Gamma = \sum_{k=1}^n \lambda_k = \sum_{k=1}^n D\xi_k$.

Доказательство. Пункт 1. По теореме 5.1 $\Gamma_\zeta = Q^T \Gamma Q = \Lambda$; внедиагональные элементы диагональной матрицы равны нулю, диагональные равны λ_k .

Пункт 2. Разложим единичный вектор u по ортонормированному базису: $u = \sum_k c_k q_k$, $\sum_k c_k^2 = 1$. Тогда

$$u^T \Gamma u = \sum_k \lambda_k c_k^2 \leq \lambda_1 \sum_k c_k^2 = \lambda_1,$$

и при $u = q_1$ достигается равенство. Оценка снизу — то же рассуждение с λ_n .

Пункт 3. След инвариантен относительно подобия, поэтому $\operatorname{tr} \Gamma = \operatorname{tr}(Q\Lambda Q^T) = \operatorname{tr} \Lambda = \sum \lambda_k$; с другой стороны, след равен сумме диагональных элементов Γ , то есть сумме дисперсий компонент. $\square$

Пункты 1 и 2 — вся геометрическая часть корреляционной теории. Ортогональный поворот Q^T превращает произвольный набор коррелированных компонент в некоррелированный, а дисперсии в новых осях суть собственные значения Γ ; направление наибольшего разброса — собственный вектор наибольшего собственного значения. Метод главных компонент — это в точности данная теорема, применённая к выборочной ковариационной матрице (раздел 10).

Пункт 3 даёт сохраняющуюся при повороте величину — **полную дисперсию** $\operatorname{tr} \Gamma$. Она и служит знаменателем в доле объяснённой дисперсии, на которой основан отбор числа главных компонент.

Определение 5.9 (эллипсоид рассеяния). Пусть Γ невырождена. **Эллипсоидом рассеяния** уровня $c > 0$ называется множество

$$E_c = \{x \in \mathbb{R}^n : (x - a)^T \Gamma^{-1} (x - a) \leq c\}.$$

Его главные полуоси направлены по q_k и равны $\sqrt{c\lambda_k}$; объём равен $c^{n/2}V_n\sqrt{\det\Gamma}$, где V_n — объём единичного шара в $\mathbb{R}^n$.

Утверждение о полуосях получается подстановкой $x - a = Qu$: неравенство превращается в $\sum_k u_k^2/\lambda_k \leq c$. Объём — формула замены переменных с якобианом $\det\Gamma^{1/2} = \sqrt{\det\Gamma}$. Отсюда имя $\det\Gamma$ — **обобщённая дисперсия**: она меряет объём рассеяния и обращается в нуль ровно при вырожденности, то есть в случае теоремы 5.7.




Рис. 1: Выборка из двумерного нормального закона с $D\xi_1 = 4$, $D\xi_2 = 1$ и $\text{cov}(\xi_1, \xi_2) = 1,8$, то есть с $r = 0,9$. Стрелки — главные оси длиной $\sqrt{\lambda_k}$, $\lambda_1 = 4,843$, $\lambda_2 = 0,157$; кривые — эллипсы рассеяния уровней $c = 1$ и $c = 5,99$ (последний содержит 95 % массы). Видно, чего стоит корреляция: разброс вдоль первой главной оси в $\sqrt{\lambda_1/\lambda_2} = 5,56$ раза шире, чем поперёк. Построено в `examples.ipynb`, пример 3.

Теорема 5.10 (многомерное неравенство Чебышёва). Пусть Γ невырождена и $c > 0$. Тогда

$$\mathbb{P}\{(\xi - a)^T \Gamma^{-1}(\xi - a) \geq c\} \leq \frac{n}{c},$$

то есть вероятность выйти за эллипсоид рассеяния уровня c не превосходит n/c .

Доказательство. Сперва неравенство Маркова: для неотрицательной величины ϱ с конечным математическим ожиданием и $c > 0$

$$\mathbb{E}\varrho \geq \mathbb{E}(\varrho \mathbb{1}\{\varrho \geq c\}) \geq c \mathbb{P}\{\varrho \geq c\}.$$

Применим его к $\varrho = (\xi - a)^T \Gamma^{-1}(\xi - a)$. Эта величина неотрицательна, поскольку Γ^{-1} неотрицательно определена вместе с Γ . Её математическое ожидание вычисляется через след: число равно следу матрицы 1×1 , а след перестановочен с циклической перестановкой сомножителей, поэтому

$$\varrho = \text{tr}(\Gamma^{-1}(\xi - a)(\xi - a)^T),$$

и по линейности (предложение 3.11) и перестановочности следа с математическим ожиданием

$$\mathbb{E}\varrho = \text{tr}(\Gamma^{-1}\mathbb{E}(\xi - a)(\xi - a)^T) = \text{tr}(\Gamma^{-1}\Gamma) = \text{tr} I = n.$$

Подстановка в неравенство Маркова даёт требуемое. $\square$

Замечание 5.11 (что даёт и чего не даёт эта оценка). При $n = 1$ теорема 5.10 превращается в классическое неравенство Чебышёва $P\{|\xi - a| \geq \sigma\sqrt{c}\} \leq 1/c$. Достоинство её в том, что она не требует ничего, кроме конечности вторых моментов, и потому работает при любом распределении. Цена — грубость: для двумерного нормального закона точная вероятность выйти за эллипс уровня c равна $e^{-c/2}$ (распределение квадратичной формы есть χ^2 с двумя степенями свободы), тогда как оценка даёт $2/c$. При $c = 10$ это 0,0067 против 0,2 — оценка завышает вероятность в 29,7 раза; измерение обоих чисел на выборке — в примере 3 ноутбука.

6. Наилучший прогноз

Раздел отвечает на главный прикладной вопрос корреляционной теории: как по наблюдаемой величине предсказать ненаблюдаемую и насколько точно это удаётся. Порядок такой: сперва скалярный линейный прогноз, потом векторный, потом прогноз без ограничения на класс — и сравнение двух последних показывает, что именно теряет корреляционная теория.

6.1. Наилучший линейный прогноз: скалярный случай

Теорема 6.1 (наилучший линейный прогноз). Пусть $E\xi^2 < \infty$, $E\eta^2 < \infty$ и $D\xi > 0$. Тогда

$$\min_{a, b \in \mathbb{R}} E(\eta - a - b\xi)^2 = D\eta(1 - r^2), \quad r = r(\xi, \eta),$$

минимум достигается в единственной точке

$$b^* = \frac{\text{cov}(\xi, \eta)}{D\xi} = r \frac{\sigma_\eta}{\sigma_\xi}, \quad a^* = E\eta - b^* E\xi.$$

Доказательство. Обозначим $\xi^\circ = \xi - E\xi$, $\eta^\circ = \eta - E\eta$ и $c = E\eta - a - bE\xi$. Тогда $\eta - a - b\xi = (\eta^\circ - b\xi^\circ) + c$, а величина $\eta^\circ - b\xi^\circ$ имеет нулевое математическое ожидание, поэтому удвоенное произведение при раскрытии квадрата исчезает:

$$E(\eta - a - b\xi)^2 = E(\eta^\circ - b\xi^\circ)^2 + c^2.$$

Второе слагаемое зависит только от a (при фиксированном b) и обращается в нуль ровно при $a = E\eta - bE\xi$; при этом первое слагаемое не меняется. Значит минимум по a берётся именно там, и остаётся минимизировать

$$g(b) = E(\eta^\circ - b\xi^\circ)^2 = D\eta - 2b \text{cov}(\xi, \eta) + b^2 D\xi.$$

Это квадратный трёхчлен с положительным старшим коэффициентом $D\xi > 0$; он имеет единственный минимум при $b^* = \text{cov}(\xi, \eta)/D\xi$, и

$$g(b^*) = D\eta - \frac{\text{cov}^2(\xi, \eta)}{D\xi} = D\eta \left(1 - \frac{\text{cov}^2(\xi, \eta)}{D\xi D\eta} \right) = D\eta(1 - r^2).$$

Единственность точки минимума по паре (a, b) следует из строгой выпуклости по b и из того, что a определяется по b однозначно. $\square$

Следствие 6.2 (смысл r^2). Доля дисперсии η , снимаемая наилучшим линейным прогнозом по ξ , равна r^2 :

$$\frac{D\eta - \min_{a, b} E(\eta - a - b\xi)^2}{D\eta} = r^2.$$

Прямая $y = a^* + b^*x$ называется **прямой среднеквадратичной регрессии** η на ξ ; в стандартизованной записи она выглядит так:

$$\frac{y - E\eta}{\sigma_\eta} = r \frac{x - E\xi}{\sigma_\xi}. \quad (6)$$

Замечание 6.3 (две прямые регрессии и почему их две). Поменяв роли величин, получим прямую регрессии ξ на η : $\frac{x - E\xi}{\sigma_\xi} = r \frac{y - E\eta}{\sigma_\eta}$, то есть в координатах (x, y) — прямую с угловым коэффициентом $\sigma_\eta/(r\sigma_\xi)$ при $r \neq 0$. Угловые коэффициенты двух прямых относятся как r^2 , поэтому прямые совпадают тогда и только тогда, когда $r^2 = 1$, то есть ровно в случае почти линейной связи (теорема 4.3). При $r \rightarrow 0$ они расходятся к горизонтали и вертикали.

Смысл этого прост, и его стоит проговорить на экзамене: прогноз несимметричен. Величина $b^* = r\sigma_\eta/\sigma_\xi$ по модулю меньше, чем σ_η/σ_ξ , — наилучший прогноз всегда «притянут» к среднему сильнее, чем сама величина. Это и есть явление, которое Гальтон назвал регрессией к среднему и от которого метод получил своё имя.

6.2. Наилучшая линейная оценка вектора по вектору

Теорема 6.4 (наилучшая линейная оценка). Пусть $\xi \in \mathbb{R}^n$ и $\eta \in \mathbb{R}^m$ — случайные векторы с конечными вторыми моментами компонент и невырожденной Γ_η . Среди всех оценок вида $\hat{\xi} = B\eta + c$ (B — матрица $n \times m$, $c \in \mathbb{R}^n$) матрица вторых моментов ошибки $E(\xi - \hat{\xi})(\xi - \hat{\xi})^\top$ минимальна в смысле порядка $\succeq$ при

$$B^* = \Gamma_{\xi\eta}\Gamma_\eta^{-1}, \quad c^* = E\xi - B^*E\eta,$$

и минимум равен

$$\Gamma_{\text{err}} = \Gamma_\xi - \Gamma_{\xi\eta}\Gamma_\eta^{-1}\Gamma_{\eta\xi}. \quad (7)$$

Точка минимума единственна.

Доказательство. Обозначим $\xi^\circ = \xi - E\xi$, $\eta^\circ = \eta - E\eta$. Для произвольных B, c ошибка записывается как

$$e = \xi - B\eta - c = (\xi^\circ - B\eta^\circ) + d, \quad d = E\xi - B E\eta - c,$$

причём $E(\xi^\circ - B\eta^\circ) = 0$, поэтому перекрёстные слагаемые исчезают:

$$Eee^\top = E(\xi^\circ - B\eta^\circ)(\xi^\circ - B\eta^\circ)^\top + dd^\top.$$

Матрица $dd^\top$ неотрицательно определена и равна нулю ровно при $d = 0$, то есть при $c = E\xi - B E\eta$; значит минимум берётся при этом c , каково бы ни было B .

Положим $e^* = \xi^\circ - B^*\eta^\circ$. Ключевое свойство — ошибка не коррелирует с данными:

$$Ee^*(\eta^\circ)^\top = \Gamma_{\xi\eta} - B^*\Gamma_\eta = \Gamma_{\xi\eta} - \Gamma_{\xi\eta}\Gamma_\eta^{-1}\Gamma_\eta = 0.$$

Для произвольного B имеем $\xi^\circ - B\eta^\circ = e^* - (B - B^*)\eta^\circ$, и в силу выписанной ортогональности

$$E(\xi^\circ - B\eta^\circ)(\xi^\circ - B\eta^\circ)^\top = Ee^*(e^*)^\top + (B - B^*)\Gamma_\eta(B - B^*)^\top.$$

Второе слагаемое неотрицательно определено, поэтому $Eee^\top \succeq Ee^*(e^*)^\top$; равенство достигается лишь при $(B - B^*)\Gamma_\eta(B - B^*)^\top = 0$, что при невырожденной Γ_η даёт $B = B^*$ (иначе нашлась бы строка $v^\top$ матрицы $B - B^*$ с $v^\top\Gamma_\eta v > 0$). Наконец,

$$Ee^*(e^*)^\top = \Gamma_\xi - B^*\Gamma_{\eta\xi} - \Gamma_{\xi\eta}(B^*)^\top + B^*\Gamma_\eta(B^*)^\top = \Gamma_\xi - \Gamma_{\xi\eta}\Gamma_\eta^{-1}\Gamma_{\eta\xi},$$

поскольку два последних слагаемых взаимно уничтожаются. $\square$

Утверждение о минимальности в смысле $\succeq$ сильнее, чем минимальность следа или определителя: из $\Gamma_{\text{err}} \preceq \Gamma$ следует и $\text{tr } \Gamma_{\text{err}} \leq \text{tr } \Gamma$, и $\det \Gamma_{\text{err}} \leq \det \Gamma$, и малость дисперсии **любой** линейной комбинации компонент ошибки. Обратное неверно, поэтому именно в такой форме теорему и стоит формулировать.

Следствие 6.5 (неотрицательность дополнения Шура). *Если блочная матрица $\begin{pmatrix} \Gamma_\xi & \Gamma_{\xi\eta} \\ \Gamma_{\eta\xi} & \Gamma_\eta \end{pmatrix}$ является ковариационной матрицей объединённого вектора (ξ, η) и Γ_η невырождена, то её дополнение Шура (7) неотрицательно определено.*

Доказательство. По теореме 6.4 эта матрица есть матрица вторых моментов случайного вектора e^* , то есть его ковариационная матрица (среднее e^* равно нулю); остаётся сослаться на пункт 1 теоремы 5.5. $\square$

Следствие 6.5 — пример того, как вероятностный язык доказывает чисто алгебраический факт: неотрицательность дополнения Шура получена без единой матричной выкладки, из того лишь, что дисперсия неотрицательна.

6.3. Прогноз без ограничения на класс

Теорема 6.6 (условное математическое ожидание как наилучший прогноз). *Пусть $E\xi^2 < \infty$, $\mathcal{G} \subset \mathcal{F}$ — под- σ -алгебра, $\mathcal{A}_\mathcal{G}$ — множество $\mathcal{G}$ -измеримых случайных величин с конечным вторым моментом. Тогда*

$$E(\xi - E(\xi | \mathcal{G}))^2 = \min_{\zeta \in \mathcal{A}_\mathcal{G}} E(\xi - \zeta)^2,$$

и минимум достигается только на $\zeta = E(\xi | \mathcal{G})$ (с точностью до равенства почти наверное).

Доказательство. Обозначим $\hat{\xi} = E(\xi | \mathcal{G})$; она принадлежит $\mathcal{A}_\mathcal{G}$, поскольку по неравенству Йенсена для условного математического ожидания (или прямо по доказываемой ниже оценке при $\zeta = 0$) её второй момент конечен. Для $\zeta \in \mathcal{A}_\mathcal{G}$ запишем

$$E(\xi - \zeta)^2 = E(\xi - \hat{\xi})^2 + E(\hat{\xi} - \zeta)^2 + 2E[(\xi - \hat{\xi})(\hat{\xi} - \zeta)].$$

Покажем, что третье слагаемое равно нулю. Разность $\hat{\xi} - \zeta$ $\mathcal{G}$ -измерима, и $E|(\hat{\xi} - \zeta)(\xi - \hat{\xi})| < \infty$ по неравенству Коши — Буняковского (теорема 4.1), так что множитель можно вынести:

$$E[(\hat{\xi} - \zeta)(\xi - \hat{\xi})] = E[E((\hat{\xi} - \zeta)(\xi - \hat{\xi}) | \mathcal{G})] = E[(\hat{\xi} - \zeta)E(\xi - \hat{\xi} | \mathcal{G})] = 0,$$

поскольку $E(\xi | \mathcal{G}) = \hat{\xi}$ и $\hat{\xi}$ $\mathcal{G}$ -измерима, откуда $E(\xi - \hat{\xi} | \mathcal{G}) = 0$. Итак,

$$E(\xi - \zeta)^2 = E(\xi - \hat{\xi})^2 + E(\hat{\xi} - \zeta)^2 \geq E(\xi - \hat{\xi})^2,$$

и равенство достигается тогда и только тогда, когда $E(\hat{\xi} - \zeta)^2 = 0$, то есть $\zeta = \hat{\xi}$ почти наверное ([07], теорема 10.4, с. 98–99). $\square$

Выкладка доказательства — это теорема Пифагора: разность $\xi - \hat{\xi}$ ортогональна всему подпространству $\mathcal{A}_\mathcal{G}$ в пространстве $L_2(\Omega, \mathcal{F}, \mathbb{P})$ со скалярным произведением $\langle \xi, \eta \rangle = E\xi\eta$, и $\hat{\xi}$ — ортогональная проекция ξ на это подпространство. Существование проекции даёт теорема о проекции из вопроса о гильбертовых пространствах; здесь же условное математическое ожидание взято готовым, а доказана именно минимальность.

Следствие 6.7 (закон полной дисперсии). Пусть $E\xi^2 < \infty$ и $D(\xi | \mathcal{G}) = E(\xi^2 | \mathcal{G}) - (E(\xi | \mathcal{G}))^2$. Тогда

$$D\xi = ED(\xi | \mathcal{G}) + DE(\xi | \mathcal{G}).$$

Доказательство. Пишем $\xi - E\xi = (\xi - \hat{\xi}) + (\hat{\xi} - E\xi)$, где $\hat{\xi} = E(\xi | \mathcal{G})$. Второе слагаемое $\mathcal{G}$ -измеримо, и по доказанной в теореме 6.6 ортогональности перекрёстное слагаемое обращается в нуль:

$$D\xi = E(\xi - \hat{\xi})^2 + E(\hat{\xi} - E\xi)^2.$$

Второе слагаемое есть $D\hat{\xi}$, поскольку $E\hat{\xi} = E\xi$. Первое преобразуем, вставив условное математическое ожидание:

$$E(\xi - \hat{\xi})^2 = E\left[E((\xi - \hat{\xi})^2 | \mathcal{G})\right] = E\left[E(\xi^2 | \mathcal{G}) - 2\hat{\xi}E(\xi | \mathcal{G}) + \hat{\xi}^2\right] = ED(\xi | \mathcal{G}),$$

где снова использовано вынесение $\mathcal{G}$ -измеримого множителя. $\square$

Определение 6.8 (корреляционное отношение). Пусть $D\eta > 0$. **Корреляционным отношением** (англ. *correlation ratio*) величины η по ξ называется

$$\nu^2(\eta | \xi) = \frac{DE(\eta | \xi)}{D\eta}.$$

Традиционное обозначение этой величины — η^2 , и оно здесь непригодно: буква η занята случайной величиной. Буква ν во всех двадцати вопросах свободна и занята здесь; выборочный вариант величины изложен у [24], гл. 18 §11–13.

Предложение 6.9 (корреляционное отношение не меньше квадрата корреляции). При $D\xi > 0$, $D\eta > 0$

$$r^2(\xi, \eta) \leq \nu^2(\eta | \xi) \leq 1,$$

причём $\nu^2(\eta | \xi) = 0$ равносильно тому, что $E(\eta | \xi)$ постоянно почти наверное, а $\nu^2(\eta | \xi) = 1$ — тому, что η есть функция от ξ почти наверное.

Доказательство. По закону полной дисперсии (следствие 6.7) с $\mathcal{G} = \sigma(\xi)$

$$E(\eta - E(\eta | \xi))^2 = ED(\eta | \xi) = D\eta - DE(\eta | \xi) = D\eta(1 - \nu^2).$$

С другой стороны, всякая линейная функция $a + b\xi$ является $\sigma(\xi)$ -измеримой величиной с конечным вторым моментом, поэтому по теореме 6.6 минимум по всем таким величинам не превосходит минимума по линейным, вычисленного в теореме 6.1:

$$D\eta(1 - \nu^2) \leq D\eta(1 - r^2),$$

откуда $\nu^2 \geq r^2$. Неравенство $\nu^2 \leq 1$ следует из неотрицательности левой части. Случай $\nu^2 = 1$ означает $E(\eta - E(\eta | \xi))^2 = 0$, то есть $\eta = E(\eta | \xi)$ почти наверное, а $E(\eta | \xi)$ есть борелевская функция от ξ ; случай $\nu^2 = 0$ означает $DE(\eta | \xi) = 0$. $\square$

Предложение 6.9 и есть точная мера того, что теряет корреляционная теория. Величина r^2 — доля дисперсии, снимаемая линейным прогнозом; ν^2 — доля, снимаемая наилучшим прогнозом вообще; разность $\nu^2 - r^2$ — то, чего два момента не видят. Раздел 8 даёт пример, в котором эта разность равна единице: $r = 0$ при $\nu^2 = 1$.

7. Гауссовский вектор: когда двух моментов хватает

Определение 7.1 (гауссовский вектор). Случайный вектор $\zeta \in \mathbb{R}^n$ называется **стандартным гауссовским**, если его компоненты независимы в совокупности и каждая имеет распределение $\mathcal{N}(0, 1)$ с плотностью $(2\pi)^{-1/2}e^{-x^2/2}$. Вектор $\xi \in \mathbb{R}^p$ называется **гауссовским** (англ. *Gaussian vector*; он же нормальный), если он представим в виде

$$\xi = A\zeta + a$$

со стандартным гауссовским ζ , постоянной матрицей A размера $p \times n$ и постоянным $a \in \mathbb{R}^p$. Пишут $\xi \sim \mathcal{N}(a, \Gamma)$, где $\Gamma = AA^\top$.

Обозначение согласовано: по теореме 5.1 у вектора $A\zeta + a$ действительно $E\xi = a$ и $\Gamma_\xi = A I A^\top = AA^\top$. Определение через линейный образ, а не через плотность, взято у [06] (§21.1) сознательно: оно работает и в вырожденном случае, когда плотности нет, и сразу даёт замкнутость класса относительно линейных преобразований.

Предложение 7.2 (линейный образ гауссовского вектора гауссовский). Если ξ гауссовский, то и $B\xi + b$ гауссовский при любых постоянных B, b .

Доказательство. $B(A\zeta + a) + b = (BA)\zeta + (Ba + b)$ — снова линейный образ стандартного гауссовского вектора ([06], теорема 21.1.1). $\square$

Лемма 7.3 (характеристическая функция стандартного нормального закона). Если $\zeta_1 \sim \mathcal{N}(0, 1)$, то $Ee^{it\zeta_1} = e^{-t^2/2}$ при всех $t \in \mathbb{R}$.

Доказательство. Положим $\varphi(t) = Ee^{it\zeta_1} = \frac{1}{\sqrt{2\pi}} \int_{\mathbb{R}} e^{itx} e^{-x^2/2} dx$. Подынтегральная функция по t дифференцируема, её производная по модулю не превосходит $|x| e^{-x^2/2}$ — интегрируемой мажоранты, не зависящей от t , — поэтому дифференцирование под знаком интеграла законно:

$$\varphi'(t) = \frac{1}{\sqrt{2\pi}} \int_{\mathbb{R}} ix e^{itx} e^{-x^2/2} dx.$$

Заметив, что $xe^{-x^2/2} = -(e^{-x^2/2})'$, интегрируем по частям (внеинтегральный член исчезает, так как $e^{-x^2/2} \rightarrow 0$ на бесконечности):

$$\varphi'(t) = \frac{i}{\sqrt{2\pi}} \int_{\mathbb{R}} e^{itx} d(-e^{-x^2/2}) = \frac{i}{\sqrt{2\pi}} \int_{\mathbb{R}} it e^{itx} e^{-x^2/2} dx = -t \varphi(t).$$

Значит $(\varphi(t)e^{t^2/2})' = e^{t^2/2}(\varphi'(t) + t\varphi(t)) = 0$, то есть $\varphi(t)e^{t^2/2}$ постоянно и равно своему значению в нуле: $\varphi(0) = 1$ ввиду $\int_{\mathbb{R}} e^{-x^2/2} dx = \sqrt{2\pi}$. Отсюда $\varphi(t) = e^{-t^2/2}$. $\square$

Теорема 7.4 (характеристическая функция гауссовского вектора). Если $\xi \sim \mathcal{N}(a, \Gamma)$, то при всех $t \in \mathbb{R}^p$

$$\varphi_\xi(t) = Ee^{i\langle t, \xi \rangle} = \exp\left\{i\langle t, a \rangle - \frac{1}{2}\langle \Gamma t, t \rangle\right\}. \quad (8)$$

Следовательно, распределение гауссовского вектора однозначно определяется парой (a, Γ) .

Доказательство. Пусть $\xi = A\zeta + a$. Сперва вычислим характеристическую функцию стандартного вектора $\zeta \in \mathbb{R}^n$: по независимости компонент и мультипликативности математического ожидания (предложение 4.4 в его версии для комплекснозначных функций от независимых величин, получаемой той же теоремой Фубини)

$$Ee^{i\langle s, \zeta \rangle} = E \prod_{j=1}^n e^{is_j \zeta_j} = \prod_{j=1}^n Ee^{is_j \zeta_j} = \prod_{j=1}^n e^{-s_j^2/2} = e^{-\langle s, s \rangle/2},$$

где использована лемма 7.3. Теперь

$$\varphi_\xi(t) = \mathbb{E} e^{i\langle t, A\xi + a \rangle} = e^{i\langle t, a \rangle} \mathbb{E} e^{i\langle A^\top t, \xi \rangle} = e^{i\langle t, a \rangle} \exp\left\{-\frac{1}{2} \langle A^\top t, A^\top t \rangle\right\} = e^{i\langle t, a \rangle} \exp\left\{-\frac{1}{2} \langle AA^\top t, t \rangle\right\},$$

что и есть (8) ввиду $\Gamma = AA^\top$. Последнее утверждение — теорема единственности для характеристических функций на $\mathbb{R}^p$ (раздел 2; [06], теорема 21.1.2 и следствие после теоремы 21.1.4). $\square$

Теорема 7.5 (некоррелированность равносильна независимости). Пусть вектор (ξ, η) размерности $n + m$ гауссовский и $\Gamma_{\xi\eta} = 0$. Тогда ξ и η независимы. В частности, попарно некоррелированные компоненты гауссовского вектора независимы в совокупности.

Доказательство. Обозначим через Γ ковариационную матрицу объединённого вектора; при $\Gamma_{\xi\eta} = 0$ она блочно-диагональна, $\Gamma = \text{diag}(\Gamma_\xi, \Gamma_\eta)$ в блочном смысле. Для $t = (t_1, t_2)$, $t_1 \in \mathbb{R}^n$, $t_2 \in \mathbb{R}^m$, по теореме 7.4

$$\varphi_{(\xi, \eta)}(t_1, t_2) = \exp\left\{i\langle t_1, \mathbb{E}\xi \rangle + i\langle t_2, \mathbb{E}\eta \rangle - \frac{1}{2} \langle \Gamma_\xi t_1, t_1 \rangle - \frac{1}{2} \langle \Gamma_\eta t_2, t_2 \rangle\right\} = \varphi_\xi(t_1) \varphi_\eta(t_2),$$

причём φ_ξ и φ_η — характеристические функции самих ξ и η (они получаются из формулы при $t_2 = 0$ и $t_1 = 0$ соответственно; заодно видно, что ξ и η сами гауссовские). С другой стороны, произведение $\varphi_\xi(t_1) \varphi_\eta(t_2)$ есть, по теореме Фубини, характеристическая функция произведения мер $F_\xi \otimes F_\eta$. Итак, у распределения $F_{(\xi, \eta)}$ и у меры $F_\xi \otimes F_\eta$ характеристические функции совпадают; по теореме единственности совпадают и сами меры, а это и есть независимость. Случай попарно некоррелированных компонент разбирается так же: там Γ диагональна и характеристическая функция распадается в произведение n сомножителей ([06], теорема 21.1.6). $\square$

Теорема 7.6 (плотность гауссовского вектора). Если $\xi \sim \mathcal{N}(a, \Gamma)$ и Γ невырождена, то ξ имеет плотность

$$p(x) = \frac{1}{(2\pi)^{n/2} \sqrt{\det \Gamma}} \exp\left\{-\frac{1}{2}(x - a)^\top \Gamma^{-1}(x - a)\right\}. \quad (9)$$

При вырожденной Γ плотности нет: по теореме 5.7 вектор почти наверное лежит в аффинной плоскости меньшей размерности, а у такой плоскости мера Лебега нулевая.

Доказательство. Представим $\xi = \Gamma^{1/2}\zeta + a$ (такое представление годится: по теореме 7.4 характеристическая функция зависит только от (a, Γ) , а у $\Gamma^{1/2}\zeta + a$ ровно эти параметры). Матрица $\Gamma^{1/2}$ невырождена вместе с Γ , значит замена $x = \Gamma^{1/2}z + a$ — диффеоморфизм $\mathbb{R}^n$ на себя с якобианом $\det \Gamma^{1/2} = \sqrt{\det \Gamma}$. Плотность стандартного вектора есть $(2\pi)^{-n/2} e^{-\langle z, z \rangle/2}$ (произведение одномерных плотностей), поэтому для борелевского B

$$\mathbb{P}\{\xi \in B\} = \mathbb{P}\{\zeta \in \Gamma^{-1/2}(B - a)\} = \int_{\Gamma^{-1/2}(B - a)} \frac{e^{-\langle z, z \rangle/2}}{(2\pi)^{n/2}} dz.$$

Подстановка $z = \Gamma^{-1/2}(x - a)$ даёт $dz = dx / \sqrt{\det \Gamma}$ и

$$\langle z, z \rangle = (x - a)^\top \Gamma^{-1/2} \Gamma^{-1/2} (x - a) = (x - a)^\top \Gamma^{-1} (x - a),$$

откуда и получается (9). $\square$

Форма показателя в (9) — это квадратичная форма из определения 5.9. Значит **линии уровня плотности гауссовского вектора суть эллипсоиды рассеяния**, и геометрия, построенная в разделе 5.3 из одних вторых моментов, в гауссовском случае оказывается геометрией самого распределения.

Теорема 7.7 (условное распределение гауссовского вектора). Пусть вектор (ξ, η) , $\xi \in \mathbb{R}^n$, $\eta \in \mathbb{R}^m$, гауссовский и Γ_η невырождена. Тогда условное распределение ξ при $\eta = y$ гауссовское с параметрами

$$E\xi + \Gamma_{\xi\eta}\Gamma_\eta^{-1}(y - E\eta), \quad \Gamma_\xi - \Gamma_{\xi\eta}\Gamma_\eta^{-1}\Gamma_{\eta\xi}.$$

В частности,

$$E(\xi \mid \eta) = E\xi + \Gamma_{\xi\eta}\Gamma_\eta^{-1}(\eta - E\eta),$$

то есть условное математическое ожидание линейно и совпадает с наилучшей линейной оценкой.

Доказательство. Положим $B^* = \Gamma_{\xi\eta}\Gamma_\eta^{-1}$ и $e = \xi - E\xi - B^*(\eta - E\eta)$. Объединённый вектор (e, η) получается из (ξ, η) линейным преобразованием, значит гауссовский (предложение 7.2). В доказательстве теоремы 6.4 установлено $\Gamma_{e\eta} = Ee(\eta - E\eta)^T = 0$, поэтому по теореме 7.5 векторы e и η независимы; при этом e гауссовский со средним нуль и ковариационной матрицей $\Gamma_{\text{err}} = \Gamma_\xi - \Gamma_{\xi\eta}\Gamma_\eta^{-1}\Gamma_{\eta\xi}$.

Теперь $\xi = E\xi + B^*(\eta - E\eta) + e$, где первое и второе слагаемые $\sigma(\eta)$ -измеримы, а e от η не зависит. Для борелевского $C \subset \mathbb{R}^n$ и борелевского $D \subset \mathbb{R}^m$

$$P\{\xi \in C, \eta \in D\} = \int_D P\{e \in C - E\xi - B^*(y - E\eta)\} F_\eta(dy),$$

что и означает, что условное распределение ξ при $\eta = y$ есть сдвиг распределения e на вектор $E\xi + B^*(y - E\eta)$, то есть гауссовское с заявленными параметрами. Равенство для условного математического ожидания получается интегрированием: $E(\xi \mid \eta) = E\xi + B^*(\eta - E\eta) + E(e \mid \eta)$, а $E(e \mid \eta) = Ee = 0$ по независимости. $\square$

Следствие 7.8 (в гауссовском случае корреляционная теория исчерпывающая). Пусть вектор (ξ, η) гауссовский и Γ_η невырождена. Тогда минимум $E\|\xi - g(\eta)\|^2$ по всем борелевским $g: \mathbb{R}^m \rightarrow \mathbb{R}^n$ с конечным вторым моментом достигается на линейной функции из теоремы 6.4, и потому наилучший прогноз совпадает с наилучшим линейным. Для каждой компоненты это означает $\nu^2(\xi_k \mid \eta) = r_k^2$, где r_k — коэффициент корреляции ξ_k с её наилучшим линейным прогнозом.

Доказательство. По теореме 6.6, применённой покомпонентно с $\mathcal{G} = \sigma(\eta)$, минимум достигается на $E(\xi \mid \eta)$; по теореме 7.7 эта величина линейна по η и совпадает с $\hat{\xi} = E\xi + B^*(\eta - E\eta)$.

Равенство $\nu^2(\xi_k \mid \eta) = r_k^2$ проверяется счётом. Обозначим $e = \xi - \hat{\xi}$; в доказательстве теоремы 6.4 установлено $Ee(\eta - E\eta)^T = 0$, а $\hat{\xi}_k - E\xi_k$ есть линейная функция от $\eta - E\eta$, поэтому $\text{cov}(e_k, \hat{\xi}_k) = 0$. Отсюда

$$\text{cov}(\xi_k, \hat{\xi}_k) = \text{cov}(\hat{\xi}_k + e_k, \hat{\xi}_k) = D\hat{\xi}_k,$$

и (при $D\hat{\xi}_k > 0$)

$$r_k = \frac{\text{cov}(\xi_k, \hat{\xi}_k)}{\sigma_{\xi_k} \sigma_{\hat{\xi}_k}} = \frac{\sigma_{\hat{\xi}_k}}{\sigma_{\xi_k}}, \quad r_k^2 = \frac{D\hat{\xi}_k}{D\xi_k} = \frac{DE(\xi_k \mid \eta)}{D\xi_k} = \nu^2(\xi_k \mid \eta).$$

При $D\hat{\xi}_k = 0$ обе величины равны нулю. $\square$

Это и есть оправдание корреляционной теории. В гауссовской модели пара (a, Γ) — полное описание: по ней восстанавливается распределение (теорема 7.4), независимость сводится к некоррелированности (теорема 7.5), а оптимальная обработка данных линейна (теорема

7.7). Вне гауссовской модели остаётся более слабое, но тоже полезное утверждение: корреляционная теория даёт **точный** ответ внутри класса линейных процедур, каким бы ни было распределение (теорема 6.4).

Отдельного внимания стоит то, что условная ковариация в теореме 7.7 от y не зависит. В негауссовском случае это неверно: точность прогноза может зависеть от того, что именно наблюдается, и корреляционная теория такой зависимости не видит в принципе — у неё нет для неё места.

8. Посылки: что ломается и как

8.1. Конечность вторых моментов

Вся корреляционная теория стоит на предположении $E\xi_k^2 < \infty$. Оно не безобидно: у распределения Коши с плотностью $\frac{1}{\pi(1+x^2)}$ не существует даже математического ожидания, потому что $\int |x| \frac{dx}{\pi(1+x^2)}$ расходится логарифмически. Ковариация и коэффициент корреляции для такой пары **не определены** — не «равны чему-то неудобному», а не существуют.

Опасность здесь практическая. Выборочный коэффициент корреляции считается по любым числам: формула не спрашивает о существовании моментов и выдаёт значение из $[-1, 1]$. Но утверждать про это значение нечего: закон больших чисел к нему неприменим, и при росте объёма выборки оно не сходится ни к чему. Приznak беды — неустойчивость выборочной величины при добавлении наблюдений; в примере 5 ноутбука та же неустойчивость видна на выборочной ковариационной матрице.

8.2. Некоррелированность не влечёт независимости

Пример 8.1 (квадрат симметричной величины). Пусть ξ равномерна на $[-1, 1]$ и $\eta = \xi^2$. Тогда

$$E\xi = 0, \quad E\xi^3 = 0, \quad \text{cov}(\xi, \eta) = E\xi^3 - E\xi E\xi^2 = 0,$$

то есть $r(\xi, \eta) = 0$: величины некоррелированы. При этом η есть функция от ξ , и прогноз по ξ восстанавливает η точно.

Посчитаем обе доли объяснённой дисперсии. По следствию 6.2 наилучший линейный прогноз снимает $r^2 = 0$ дисперсии — то есть не снимает ничего. По предложению 6.9 корреляционное отношение равно $\nu^2(\eta | \xi) = 1$, поскольку $E(\eta | \xi) = \xi^2 = \eta$ почти наверное. Разрыв максимален: корреляционная теория не видит здесь ровно ничего, тогда как связь функциональная. Числа проверены в примере 2 ноутбука.

Пример 8.2 (гауссовская пара со случайным знаком). Пусть $\xi \sim \mathcal{N}(0, 1)$, а s принимает значения ± 1 с вероятностью $1/2$ каждое и независима от ξ . Положим $\eta = s\xi$. Тогда

1. $\eta \sim \mathcal{N}(0, 1)$;
2. $\text{cov}(\xi, \eta) = 0$;
3. ξ и η зависимы, ибо $|\xi| = |\eta|$ почти наверное;
4. вектор (ξ, η) **не** гауссовский.

Доказательство. Пункт 1: по формуле полной вероятности и симметрии нормального закона

$$P\{s\xi \leq x\} = \frac{1}{2}P\{\xi \leq x\} + \frac{1}{2}P\{-\xi \leq x\} = \Phi(x).$$

Пункт 2: $\text{cov}(\xi, \eta) = E(s\xi^2) = Es \cdot E\xi^2 = 0$ по независимости s и ξ и ввиду $Es = 0$. Пункт 3: событие $\{|\xi| = |\eta|\}$ имеет вероятность 1, а у независимых величин с непрерывными распределениями его вероятность была бы нулевой (по теореме Фубини мера множества $\{|x| = |y|\}$ относительно произведения непрерывных распределений равна нулю). Пункт 4:

если бы вектор был гауссовским, то из пункта 2 по теореме 7.5 следовала бы независимость, противоречащая пункту 3. $\square$

Пример 8.2 закрывает частый и естественный вопрос: **нормальность каждой компоненты не делает вектор гауссовским**, и потому эквивалентность «некоррелированность равносильна независимости» требует совместной гауссовости, а не покомпонентной. Другой пример того же — [62], пример 1.2.6: там берётся плотность, равная удвоенной стандартной гауссовской в первом и третьем квадрантах и нулю в остальных; обе её маргинальные плотности стандартные нормальные, а сама она гауссовской не является.

8.3. Невырожденность

Теоремы 6.4, 7.6, 7.7 и 5.10 требуют невырожденности Γ_η (или Γ). Это не техническая оговорка, а указание на то, что данные содержат точную линейную зависимость (теорема 5.7). Лечится это не регуляризацией, а исключением лишней координаты: работать надо в подпространстве $\text{Im } \Gamma_\eta$, где матрица уже невырождена. Формально удобно заменить Γ_η^{-1} псевдообратной Γ_η^+ — все формулы раздела 6 сохраняются, а доказательство повторяется дословно, если в нём ограничиться векторами из $\text{Im } \Gamma_\eta$.

8.4. Что именно утверждает коэффициент корреляции

Коэффициент корреляции утверждает ровно одно: насколько хорошо одна величина приближается **линейной** функцией другой в среднеквадратичном смысле (следствие 6.2). Из него не следует ни причинной связи, ни даже зависимости в обе стороны в каком-либо содержательном смысле: две величины могут быть сильно коррелированы, будучи следствиями общей третьей. Внутри корреляционной теории отличить эти случаи нельзя в принципе — у неё нет понятия вмешательства в систему, а есть только совместное распределение. Практический вывод для моделирования: корреляция задаёт структуру ошибок измерения и потому годится для оценивания, но не годится как самостоятельное обоснование модели.

9. Приложение 1: оптимальная обработка измерений и шаг фильтра Калмана

9.1. Два датчика

Вернёмся к сквозному примеру (1). Ищем оценку вида $\hat{\mu} = w\eta_1 + (1 - w)\eta_2$: требование $E\hat{\mu} = \mu$ при любом μ вынуждает сумму весов равняться единице. По теореме 5.3

$$V(w) = D\hat{\mu} = w^2\sigma_1^2 + (1 - w)^2\sigma_2^2 + 2w(1 - w)r\sigma_1\sigma_2. \quad (10)$$

Предложение 9.1 (оптимальный вес и достижимая точность). Пусть $\sigma_1, \sigma_2 > 0$ и $\sigma_1^2 + \sigma_2^2 - 2r\sigma_1\sigma_2 > 0$. Тогда дисперсия $V(w) = D(w\eta_1 + (1 - w)\eta_2)$ достигает наименьшего значения в единственной точке

$$w^* = \frac{\sigma_2^2 - r\sigma_1\sigma_2}{\sigma_1^2 + \sigma_2^2 - 2r\sigma_1\sigma_2} \quad (11)$$

и это наименьшее значение равно

$$V^* = \frac{\sigma_1^2\sigma_2^2(1 - r^2)}{\sigma_1^2 + \sigma_2^2 - 2r\sigma_1\sigma_2}. \quad (12)$$

При этом $w^* < 0$ тогда и только тогда, когда $r > \sigma_2/\sigma_1$, и $w^* > 1$ тогда и только тогда, когда $r > \sigma_1/\sigma_2$.

Доказательство. Функция V — квадратный трёхчлен от w со старшим коэффициентом $\sigma_1^2 + \sigma_2^2 - 2r\sigma_1\sigma_2$, положительным по условию (он равен $D(\varepsilon_1 - \varepsilon_2)$, то есть положителен всюду, кроме случая $|r| = 1$ при $\sigma_1 = \sigma_2$). Производная

$$V'(w) = 2w\sigma_1^2 - 2(1-w)\sigma_2^2 + 2(1-2w)r\sigma_1\sigma_2$$

обращается в нуль ровно при $w = w^*$ из (11). Подстановка и приведение подобных дают (12); выкладка короче, если заметить, что

$$V^* = \sigma_2^2 - \frac{(\sigma_2^2 - r\sigma_1\sigma_2)^2}{\sigma_1^2 + \sigma_2^2 - 2r\sigma_1\sigma_2},$$

и привести к общему знаменателю: числитель равен $\sigma_2^2(\sigma_1^2 + \sigma_2^2 - 2r\sigma_1\sigma_2) - \sigma_2^2(\sigma_2 - r\sigma_1)^2 = \sigma_1^2\sigma_2^2(1-r^2)$. Знаки: знаменатель в (11) положителен, поэтому знак w^* есть знак $\sigma_2(\sigma_2 - r\sigma_1)$, а $w^* - 1$ имеет знак $\sigma_1(\sigma_1 - r\sigma_2)$ с обратным знаком, то есть $\sigma_1(r\sigma_2 - \sigma_1)$. $\square$

Из (12) читаются три содержательных вывода.

При $r = 0$ получаем $V^* = \sigma_1^2\sigma_2^2/(\sigma_1^2 + \sigma_2^2)$ — среднее гармоническое дисперсий, делённое пополам; веса обратно пропорциональны дисперсиям. Это привычный ответ, и именно он обычно и применяется.

При $\sigma_1 = \sigma_2 = \sigma$ вес равен $1/2$ при любом r , а $V^* = \sigma^2(1+r)/2$. Корреляция здесь только мешает: при $r \rightarrow 1$ выигрыш от второго прибора исчезает вовсе, при $r \rightarrow -1$ дисперсия стремится к нулю.

При $\sigma_1 \neq \sigma_2$ и $r \rightarrow 1$ знаменатель стремится к $(\sigma_1 - \sigma_2)^2 > 0$, а числитель к нулю, поэтому $V^* \rightarrow 0$: полностью коррелированный шум **вычитается**. Формально это случай теоремы 5.7: при $r = 1$ ковариационная матрица вырождена, погрешности связаны точным соотношением $\varepsilon_1/\sigma_1 = \varepsilon_2/\sigma_2$, и линейная комбинация $(\sigma_2\eta_1 - \sigma_1\eta_2)/(\sigma_2 - \sigma_1)$ равна μ тождественно. Именно на этом стоит дифференциальное измерение: второй прибор ставят не ради усреднения, а ради того, чтобы измерить общую помеху.

Наконец, знаковое условие $r > \sigma_2/\sigma_1$ означает, что при сильной корреляции оптимальный вес худшего прибора отрицателен: его показание входит в оценку **со знаком минус**. Правило «усреднить показания приборов», взятое без корреляционной теории, в этом режиме заведомо не оптимально. Числа — в примере 1 ноутбука.

9.2. Общий случай: корректирующий шаг фильтра Калмана

Пусть теперь оценивается вектор $\xi \in \mathbb{R}^n$ (состояние), а наблюдается

$$\eta = H\xi + \varepsilon, \quad (13)$$

где H — постоянная матрица $m \times n$, погрешность ε имеет нулевое среднее, ковариационную матрицу Γ_ε и не коррелирована с ξ . Обозначим $P = \Gamma_\xi$. (В литературе по фильтрации ковариацию шума обозначают R ; здесь эта буква занята корреляционной матрицей.)

Предложение 9.2 (калмановская поправка). В обозначениях (13) при невырожденной $HPH^\top + \Gamma_\varepsilon$ наилучшая линейная оценка ξ по η есть

$$\hat{\xi} = E\xi + K(\eta - HE\xi), \quad K = PH^\top(HPH^\top + \Gamma_\varepsilon)^{-1},$$

а ковариационная матрица её ошибки равна $(I - KH)P$.




Рис. 2: Оптимальный вес w^* (слева) и дисперсия оптимальной комбинации, отнесённая к дисперсии лучшего прибора (справа), как функции коэффициента корреляции при трёх отношениях σ_2/σ_1 . При равных дисперсиях (сплошная линия) вес не зависит от r , а выигрыш от второго прибора исчезает при $r \rightarrow 1$; при различных дисперсиях вес уходит в отрицательную область, а V^* падает к нулю. Построено в `examples.ipynb`, пример 1.

Доказательство. По теореме 5.1 и некоррелированности ε с ξ

$$\Gamma_{\xi\eta} = E(\xi - E\xi)(H(\xi - E\xi) + \varepsilon - E\varepsilon)^T = PH^T,$$

$$\Gamma_\eta = E(H(\xi - E\xi) + \varepsilon)(\dots)^T = HPH^T + \Gamma_\varepsilon.$$

Подстановка в теорему 6.4 даёт $B^* = PH^T(HPH^T + \Gamma_\varepsilon)^{-1} = K$ и

$$\Gamma_{\text{err}} = P - PH^T(HPH^T + \Gamma_\varepsilon)^{-1}HP = P - KHP = (I - KH)P.$$

□

Это в точности корректирующий шаг фильтра Калмана, и важно, **чего в выводе не было**: ни одного предположения о виде распределений. Использованы только два момента. Поэтому фильтр Калмана есть объект корреляционной теории, и утверждение о нём такое: среди линейных оценок он оптимален всегда, а среди всех оценок — в гауссовском случае, по теореме 7.7.

Два датчика из раздела 9.1 — частный случай: там $n = 1$, $m = 2$, $H = (1, 1)^T$, а $P \rightarrow \infty$ (о μ заранее ничего не известно). Предельный переход при $P \rightarrow \infty$ в формуле поправки и даёт (11) — этот счёт вынесен в раздел 15.

10. Приложение 2: главные компоненты

Теорема 5.8 — готовая постановка метода главных компонент (англ. *principal component analysis*). Задача: заменить n коррелированных координат меньшим числом некоррелированных так, чтобы потерять как можно меньше суммарной дисперсии.

Предложение 10.1 (оптимальность первых главных компонент). Пусть $\Gamma = Q\Lambda Q^T$ — спектральное разложение ковариационной матрицы, $\lambda_1 \geq \dots \geq \lambda_n \geq 0$, и пусть L — линейное подпространство $\mathbb{R}^n$ размерности k , Π_L — ортогональный проектор на него. Тогда

$$\max_{\dim L=k} E \|\Pi_L(\xi - a)\|^2 = \lambda_1 + \dots + \lambda_k,$$

и максимум достигается на $L = \text{span}(q_1, \dots, q_k)$.

Доказательство. Пусть $u_1, \dots, u_k$ — ортонормированный базис L . Тогда $\|\Pi_L(\xi - a)\|^2 = \sum_{i=1}^k \langle u_i, \xi - a \rangle^2$, и по теореме 5.3

$$\mathbb{E} \|\Pi_L(\xi - a)\|^2 = \sum_{i=1}^k u_i^T \Gamma u_i = \text{tr}(U^T \Gamma U),$$

где $U = [u_1, \dots, u_k]$ — матрица с ортонормированными столбцами. Разложим $u_i = \sum_j c_{ij} q_j$; тогда $\text{tr}(U^T \Gamma U) = \sum_j \lambda_j \beta_j$, где $\beta_j = \sum_{i=1}^k c_{ij}^2$. Числа β_j удовлетворяют $0 \leq \beta_j \leq 1$ (это квадрат нормы проекции q_j на L) и $\sum_j \beta_j = k$ (сумма квадратов норм столбцов U в базисе Q). Значит $\sum_j \lambda_j \beta_j$ — среднее взвешенное, и при $\lambda_1 \geq \dots \geq \lambda_n$ максимум достигается, когда вся «масса» сосредоточена на первых k номерах: $\beta_1 = \dots = \beta_k = 1$, остальные нули. Это и есть $L = \text{span}(q_1, \dots, q_k)$, максимум равен $\lambda_1 + \dots + \lambda_k$. $\square$

Величина $(\lambda_1 + \dots + \lambda_k) / \text{tr} \Gamma$ называется долей объяснённой дисперсии; она и служит правилом выбора k . Существенно, что весь вывод опирается только на два момента: метод главных компонент — процедура корреляционной теории.

Не менее существенно, чего метод не даёт. Он делает компоненты **некоррелированными**, а не независимыми, и по примеру 8.1 это разные вещи. Поиск действительно независимых компонент — другая задача (метод независимых компонент), и в ней двух моментов уже не хватает: по теореме 7.5 в гауссовском случае некоррелированность и есть независимость, поэтому нетривиальной задача становится только в негауссовском случае, где работают моменты выше второго.

11. Приложение 3: корреляционная теория случайных процессов

Термин «корреляционная теория» чаще всего встречается именно в теории случайных процессов, и стоит увидеть, что это та же теория и те же теоремы.

Определение 11.1 (характеристики случайного процесса). Пусть $\{X(t), t \in T\}$ — семейство случайных величин с $\mathbb{E} X^2(t) < \infty$. **Математическим ожиданием** процесса называется функция $m_X(t) = \mathbb{E} X(t)$, **корреляционной функцией** — функция двух переменных

$$K_X(t_1, t_2) = \text{cov}(X(t_1), X(t_2)) = \mathbb{E}(X(t_1) - m_X(t_1))(X(t_2) - m_X(t_2)).$$

Процесс называется **стационарным в широком смысле**, если $m_X(t)$ постоянно, а $K_X(t_1, t_2)$ зависит только от разности $\tau = t_2 - t_1$; тогда пишут $K_X(\tau)$.

При $t_1 = t_2$ корреляционная функция даёт дисперсию сечения: $K_X(t, t) = \text{D}X(t)$ ([24], гл. 23 §9).

Предложение 11.2 (неотрицательная определённости корреляционной функции). Для любых $t_1, \dots, t_N \in T$ и любых $c_1, \dots, c_N \in \mathbb{R}$

$$\sum_{k,j=1}^N c_k c_j K_X(t_k, t_j) \geq 0.$$

Доказательство. Рассмотрим случайный вектор $(X(t_1), \dots, X(t_N))$: его ковариационная матрица есть $[K_X(t_k, t_j)]$, и утверждение — это пункт 1 теоремы 5.5, то есть неотрицательная определённости ковариационной матрицы. $\square$

Предложение 11.2 показывает, что корреляционная теория процессов есть корреляционная теория векторов, применённая ко всем конечным наборам сечений сразу. Верно и обратное: по теореме 5.5 всякая симметричная неотрицательно определённая функция двух переменных является корреляционной функцией некоторого процесса.

Для стационарных в широком смысле процессов неотрицательная определённость $K_X(\tau)$ получает спектральное описание: **теорема Хинчина** утверждает, что непрерывная корреляционная функция стационарного процесса представима как преобразование Фурье конечной меры на прямой, а если эта мера имеет плотность, то плотность называется спектральной ([44], раздел о спектральном представлении). Это выводит корреляционную теорию в гармонический анализ и делает белый шум (процесс с $K_X(\tau) = \sigma^2 \delta(\tau)$, то есть с постоянной спектральной плотностью) определением, а не метафорой. Здесь мы ограничимся формулировкой: предмет относится к отдельному разделу программы.

Замечание 11.3 (имена корреляционной и ковариационной функций расходятся). Терминология здесь разнородная, и расхождение стоит знать заранее. У [24] корреляционной функцией названа *центрированная* величина и обозначена буквой K_X — так же, как выше. У [44] центрированная величина названа корреляционной функцией и обозначена R_X , а буквой K_X обозначена *нецентрированная* $EX(t_1)X(t_2)$ под именем ковариационной функции; там же оговорено, что часть авторов зовёт ковариационной как раз центрированную. То есть одна и та же буква K означает у двух источников разные вещи, а разница между ними — слагаемое $m_X(t_1)m_X(t_2)$, исчезающее только у центрированных процессов. При чтении надо смотреть на формулу.

12. Вычислительная сторона

12.1. Выборочные оценки

По выборке $\xi^{(1)}, \dots, \xi^{(N)}$ независимых одинаково распределённых векторов строят

$$\bar{\xi} = \frac{1}{N} \sum_{i=1}^N \xi^{(i)}, \quad \hat{\Gamma} = \frac{1}{N-1} \sum_{i=1}^N (\xi^{(i)} - \bar{\xi})(\xi^{(i)} - \bar{\xi})^\top. \quad (14)$$

Предложение 12.1 (несмещённость). При $N \geq 2$ и конечных вторых моментах $E\hat{\Gamma} = \Gamma$.

Доказательство. Не ограничивая общности, $E\xi = 0$ (сдвиг не меняет ни $\hat{\Gamma}$, ни Γ). Тогда

$$\sum_i (\xi^{(i)} - \bar{\xi})(\xi^{(i)} - \bar{\xi})^\top = \sum_i \xi^{(i)}(\xi^{(i)})^\top - N \bar{\xi} \bar{\xi}^\top.$$

Математическое ожидание первой суммы равно $N\Gamma$. Для второго слагаемого

$$E \bar{\xi} \bar{\xi}^\top = \frac{1}{N^2} \sum_{i,j} E \xi^{(i)}(\xi^{(j)})^\top = \frac{1}{N^2} \cdot N\Gamma = \frac{\Gamma}{N},$$

поскольку при $i \neq j$ векторы независимы и имеют нулевые средние, так что $E \xi^{(i)}(\xi^{(j)})^\top = 0$. Итого математическое ожидание суммы равно $N\Gamma - \Gamma = (N-1)\Gamma$, и деление на $N-1$ даёт требуемое. $\square$

Два свойства выборочной матрицы стоит помнить.

Она всегда неотрицательно определена: по построению $u^\top \hat{\Gamma} u = \frac{1}{N-1} \sum_i \langle u, \xi^{(i)} - \bar{\xi} \rangle^2 \geq 0$. То есть проверять её на допустимость не нужно, она допустима автоматически.

При $N \leq n$ она обязательно вырождена: сумма (14) есть сумма N матриц ранга 1, причём слагаемые связаны одним линейным соотношением ($\sum_i (\xi^{(i)} - \bar{\xi}) = 0$), поэтому

$\text{rank } \hat{\Gamma} \leq N - 1$. Практический вывод: при числе наблюдений, не превосходящем размерности, формулы раздела 6 неприменимы буквально — нужна либо регуляризация (сдвиг диагонали, он же гребневая поправка), либо понижение размерности. Это и есть то место, где корреляционная теория смыкается с регуляризацией некорректных задач.




Рис. 3: Сходимость выборочной ковариационной матрицы к истинной при $n = 8$: относительная ошибка в норме Фробениуса, усреднённая по 24 повторениям. Измеренный наклон в логарифмических осях равен $-0,4923$ против предсказанного центральной предельной теоремой $-1/2$. Построено в `examples.ipynb`, пример 5.

12.2. Устойчивость счёта

Формула $\text{cov}(\xi, \eta) = E\xi\eta - E\xi E\eta$ удобна тем, что позволяет считать в один проход, накапливая суммы $\sum x_i$, $\sum y_i$, $\sum x_i y_i$. В арифметике с плавающей точкой она опасна: если данные сдвинуты на большую величину c , оба слагаемых имеют порядок c^2 , а их разность — порядок дисперсии, и при c^2 , сравнимом с $\varepsilon_{\text{маш}}^{-1}$, от результата не остаётся ни одной верной цифры. Вычисленная так дисперсия может оказаться **отрицательной**: в одинарной точности это происходит уже при сдвиге 10^4 , и пример 4 ноутбука печатает значения -8 , -1024 и -131072 . В двойной точности при сдвиге 10^8 та же формула на выборке из $2 \cdot 10^5$ стандартных нормальных величин даёт ровно 2,0 вместо 1,0002, а при сдвиге 10^9 — ровно нуль.

Правильных путей два: двухпроходный счёт (сперва среднее, потом сумма квадратов отклонений) и однопроходная формула Уэлфорда, обновляющая среднее и сумму квадратов отклонений по одному наблюдению:

$$\bar{x}_i = \bar{x}_{i-1} + \frac{x_i - \bar{x}_{i-1}}{i}, \quad M_i = M_{i-1} + (x_i - \bar{x}_{i-1})(x_i - \bar{x}_i).$$

Обе устойчивы, потому что работают с отклонениями, а не с самими числами. Измерение потери точности — в примере 4 ноутбука.

12.3. Обращение ковариационной матрицы

Формулы раздела 6 содержат Γ_η^{-1} , но обращать матрицу явно не следует. Матрица симметрична и (при невырожденности) положительно определена, поэтому у неё есть разложение Холецкого $\Gamma_\eta = LL^\top$, и решение системы $\Gamma_\eta z = v$ сводится к двум треугольным подстановкам. Это вдвое дешевле общего метода Гаусса, устойчиво без выбора ведущего элемента и заодно служит проверкой: разложение Холецкого существует тогда и только тогда, когда

матрица положительно определена, — то есть попытка его построить и есть практический критерий из замечания 5.6.

Число обусловленности λ_1/λ_n говорит, насколько результат чувствителен к погрешности в Γ_η . Оно велико именно тогда, когда между наблюдениями есть почти линейная зависимость (теорема 5.7 в приближённой форме), и это же — признак избыточности измерений.

13. Где корреляционная теория работает

Задача	Что берётся из корреляционной теории	Чего она не даёт
объединение показаний нескольких приборов	оптимальные веса и достижимая точность (предложение 9.1)	оптимальность вне линейного класса при негауссовском шуме
фильтрация состояний динамической системы	корректирующий шаг (предложение 9.2), не требующий вида распределений	при негауссовском шуме существуют нелинейные оценки точнее
понижение размерности данных	главные оси и доля объяснённой дисперсии (теорема 5.8, предложение 10.1)	независимость компонент: получается только некоррелированность
регрессия по методу наименьших квадратов	наилучший линейный прогноз и смысл r^2 (теорема 6.1)	причинную связь; нелинейную зависимость
планирование эксперимента	обобщённая дисперсия $\det \Gamma$ как мера неопределённости (определение 5.9)	выбор критерия: $\det$, tr и $\lambda_{\max}$ дают разные планы
оценка риска суммы	дисперсия линейной комбинации (теорема 5.3) и роль ковариаций	поведение хвостов: вторые моменты о редких событиях молчат

Строка про хвосты — самая важная, и её стоит проговорить отдельно. Два момента описывают разброс «в среднем»; про вероятность редкого большого отклонения они дают только неравенство Чебышёва (теорема 5.10), то есть оценку сверху порядка $1/c$, тогда как у лёгких хвостов настоящая вероятность экспоненциально мала. Разрыв между этими двумя ответами и есть граница применимости корреляционной теории в задачах о риске.

14. Разобранные задачи

Задача 14.1 (ковариационная матрица линейного образа). Случайный вектор $\xi = (\xi_1, \xi_2)^T$ имеет $D\xi_1 = 4$, $D\xi_2 = 9$, $r(\xi_1, \xi_2) = -1/3$. Найти дисперсию величины $\zeta = 2\xi_1 - \xi_2$ и ковариационную матрицу вектора $(\xi_1 + \xi_2, \xi_1 - \xi_2)^T$.

Решение. Ковариация равна $r\sigma_1\sigma_2 = -\frac{1}{3} \cdot 2 \cdot 3 = -2$, так что

$$\Gamma_\xi = \begin{pmatrix} 4 & -2 \\ -2 & 9 \end{pmatrix}.$$

По теореме 5.3 с $u = (2, -1)^T$

$$D\zeta = u^T \Gamma_\xi u = 4 \cdot 4 + 1 \cdot 9 - 2 \cdot 2 \cdot 1 \cdot (-2) = 16 + 9 + 8 = 33.$$

Для второго вопроса берём $A = \begin{pmatrix} 1 & 1 \\ 1 & -1 \end{pmatrix}$ и по теореме 5.1

$$A\Gamma_\xi A^T = \begin{pmatrix} 1 & 1 \\ 1 & -1 \end{pmatrix} \begin{pmatrix} 4 & -2 \\ -2 & 9 \end{pmatrix} \begin{pmatrix} 1 & 1 \\ 1 & -1 \end{pmatrix} = \begin{pmatrix} 9 & -5 \\ -5 & 17 \end{pmatrix}.$$

Элементы читаются и без умножения матриц: $D(\xi_1 + \xi_2) = 4 + 9 - 4 = 9$, $D(\xi_1 - \xi_2) = 4 + 9 + 4 = 17$, а $\text{cov}(\xi_1 + \xi_2, \xi_1 - \xi_2) = D\xi_1 - D\xi_2 = -5$.

Две проверки. След: $A^T A = 2I$, то есть $A/\sqrt{2}$ ортогональна, и потому $\text{tr}(A\Gamma_\xi A^T) = 2 \text{tr} \Gamma_\xi$; действительно $9 + 17 = 26 = 2 \cdot 13$. Определитель: $\det(A\Gamma_\xi A^T) = (\det A)^2 \det \Gamma_\xi = 4 \cdot 32 = 128$, и прямой счёт даёт $9 \cdot 17 - 25 = 128$.

Задача 14.2 (бывает ли такая матрица корреляционной). Три величины попарно коррелированы так: $r_{12} = r_{23} = 0,8$, $r_{13} = 0$. Возможно ли это?

Решение. Корреляционная матрица

$$R = \begin{pmatrix} 1 & 0,8 & 0 \\ 0,8 & 1 & 0,8 \\ 0 & 0,8 & 1 \end{pmatrix}$$

обязана быть неотрицательно определённой (теорема 5.5). Считаем определитель:

$$\det R = 1 \cdot (1 - 0,64) - 0,8(0,8 - 0) + 0 = 0,36 - 0,64 = -0,28 < 0.$$

Определитель неотрицательно определённой матрицы неотрицателен (он равен произведению собственных значений), значит такой набор корреляций невозможен.

Это частный случай общего ограничения, которое полезно знать: если $r_{12} = r_{23} = \rho$, то

$$r_{13} \geq 2\rho^2 - 1. \quad (15)$$

Вывод: определитель корреляционной матрицы 3×3 с элементами $r_{12} = r_{23} = \rho$, $r_{13} = x$ равен

$$1 - 2\rho^2 - x^2 + 2\rho^2 x,$$

и требование его неотрицательности даёт $x^2 - 2\rho^2 x + 2\rho^2 - 1 \leq 0$. Корни квадратного трёхчлена равны $\rho^2 \pm \sqrt{\rho^4 - 2\rho^2 + 1} = \rho^2 \pm (1 - \rho^2)$, то есть $2\rho^2 - 1$ и 1 ; отсюда (15). При $\rho = 0,8$ получаем $r_{13} \geq 0,28$, так что нулевая корреляция первой и третьей величин действительно исключена. Содержательно: корреляция «частично транзитивна» — два сильных попарных сцепления вынуждают третье.

Задача 14.3 (наилучший линейный прогноз). Рост и вес в некоторой совокупности имеют $\sigma_\xi = 7$ см, $\sigma_\eta = 9$ кг и $r = 0,6$. Построить наилучший линейный прогноз веса по росту, указать остаточное стандартное отклонение и сравнить его с безусловным.

Решение. По теореме 6.1 $b^* = r\sigma_\eta/\sigma_\xi = 0,6 \cdot 9/7 = 0,771$ кг на сантиметр, и прогноз в стандартизованной форме (6):

$$\frac{y - E\eta}{9} = 0,6 \cdot \frac{x - E\xi}{7}.$$

Остаточная дисперсия равна $D\eta(1 - r^2) = 81 \cdot 0,64 = 51,84$, то есть остаточное стандартное отклонение 7,2 кг против безусловного 9 кг. Выигрыш скромный: при $r = 0,6$ снимается $r^2 = 36\%$ дисперсии, а стандартное отклонение уменьшается лишь в $\sqrt{1 - r^2} = 0,8$ раза. Это общий эффект, который стоит помнить: **чтобы вдвое уменьшить ошибку прогноза, нужно $|r| \geq \sqrt{3}/2 \approx 0,87$.**

Обратная прямая (прогноз роста по весу) имеет в координатах (x, y) угловой коэффициент $\sigma_\eta/(r\sigma_\xi) = 9/(0,6 \cdot 7) = 2,14$ против 0,771 у прямой регрессии веса на рост — отношение равно $r^2 = 0,36$, как и сказано в замечании 6.3.

Задача 14.4 (два датчика с числами). Два прибора измеряют одну величину с $\sigma_1 = 2$, $\sigma_2 = 1$ (в единицах измеряемой величины) и корреляцией погрешностей r . Найти оптимальный вес и достижимую дисперсию при $r = 0$, $r = 0,5$ и $r = 0,9$.

Решение. По формулам (11) и (12) с $\sigma_1 = 2$, $\sigma_2 = 1$: знаменатель $D = 5 - 4r$, числитель веса $1 - 2r$,

$$w^* = \frac{1 - 2r}{5 - 4r}, \quad V^* = \frac{4(1 - r^2)}{5 - 4r}.$$

При $r = 0$: $w^* = 0,2$, $V^* = 0,8$ — знакомое правило обратных дисперсий ($\sigma_2^2/(\sigma_1^2 + \sigma_2^2) = 1/5$). При $r = 0,5$: $w^* = 0$, $V^* = 1$ — худший прибор в оценку не входит вовсе, поскольку $r = \sigma_2/\sigma_1$ ровно на границе из предложения 9.1. При $r = 0,9$: $w^* = -0,8/1,4 = -0,571$, $V^* = 4 \cdot 0,19/1,4 = 0,543$ — вес отрицателен, а точность **лучше**, чем у лучшего прибора в одиночку ($\sigma_2^2 = 1$). Последнее и есть главный вывод раздела 9: сильная корреляция превращает худший прибор в измеритель общей помехи. Числа проверены в примере 1 ноутбука.

Часть II.

Расширенная часть

15. Предельный переход от калмановской поправки к двум датчикам

Проверим обещанное в разделе 9.2: формулы (11) и (12) получаются из предложения 9.2 предельным переходом при неограниченной априорной неопределённости.

Берём $n = 1$ (оцениваем скаляр μ), $m = 2$, $H = (1, 1)^\top$, $P > 0$ — априорная дисперсия μ , и

$$\Gamma_\varepsilon = \begin{pmatrix} \sigma_1^2 & r\sigma_1\sigma_2 \\ r\sigma_1\sigma_2 & \sigma_2^2 \end{pmatrix}.$$

Тогда $HPH^\top + \Gamma_\varepsilon = PJ + \Gamma_\varepsilon$, где J — матрица из одних единиц, то есть

$$M = \begin{pmatrix} P + \sigma_1^2 & P + r\sigma_1\sigma_2 \\ P + r\sigma_1\sigma_2 & P + \sigma_2^2 \end{pmatrix}.$$

Обозначим, как в предложении 9.1, $D = \sigma_1^2 + \sigma_2^2 - 2r\sigma_1\sigma_2$ и $C = \sigma_1^2\sigma_2^2(1 - r^2)$. Раскрывая определитель, получаем

$$\det M = (P + \sigma_1^2)(P + \sigma_2^2) - (P + r\sigma_1\sigma_2)^2 = PD + C,$$

поскольку слагаемые с P^2 взаимно уничтожаются.

Присоединённая матрица M есть $\begin{pmatrix} P + \sigma_2^2 & -(P + r\sigma_1\sigma_2) \\ -(P + r\sigma_1\sigma_2) & P + \sigma_1^2 \end{pmatrix}$, поэтому строка $H^\top M^{-1} = (1, 1)M^{-1}$ равна

$$\frac{1}{PD + C}(\sigma_2^2 - r\sigma_1\sigma_2, \sigma_1^2 - r\sigma_1\sigma_2),$$

и коэффициент усиления из предложения 9.2 $K = PH^\top M^{-1}$ есть та же строка, умноженная на P . Сумма её компонент равна $PD/(PD + C)$, то есть стремится к единице при $P \rightarrow \infty$, и в пределе

$$K \rightarrow \frac{1}{D}(\sigma_2^2 - r\sigma_1\sigma_2, \sigma_1^2 - r\sigma_1\sigma_2).$$

Первая компонента — это ровно w^* из (11), вторая равна $1 - w^*$. Дисперсия ошибки:

$$(1 - KH)P = P \left(1 - \frac{PD}{PD + C}\right) = \frac{PC}{PD + C} \xrightarrow{P \rightarrow \infty} \frac{C}{D},$$

и C/D — это V^* из (12).

Переход имеет и содержательный смысл: $P \rightarrow \infty$ означает отсутствие априорных сведений о величине, и тогда единственное, что остаётся, — требование несмещённости $E\hat{\mu} = \mu$, из которого и выведено условие $w + (1 - w) = 1$ в разделе 9.1. Два вывода сошлись, и это проверка обоих.

16. Сводка контрпримеров

Утверждение, которое хочется сказать	Контрпример	Что на самом деле
«некоррелированные величины независимы»	ξ равномерна на $[-1, 1]$, $\eta = \xi^2$ (пример 8.1)	независимость влечёт некоррелированность, обратное неверно (предложение 4.4)
«у вектора с нормальными компонентами некоррелированность равносильна независимости»	$\xi \sim \mathcal{N}(0, 1)$, $\eta = s\xi$ со случайным знаком (пример 8.2)	нужна совместная гауссовость вектора, а не покомпонентная (теорема 7.5)
«неотрицательность угловых миноров означает неотрицательную определённость»	$\text{diag}(0, -1)$ (замечание 5.6)	нужны все главные миноры, а не только угловые
«любые попарные корреляции совместимы»	$r_{12} = r_{23} = 0,8$, $r_{13} = 0$ (задача 14.2)	матрица обязана быть неотрицательно определённой: $r_{13} \geq 2\rho^2 - 1$
«коэффициент корреляции всегда определён»	пара величин с распределением Коши (раздел 8.1)	нужны конечные вторые моменты
«оптимальные веса при объединении измерений лежат между нулём и единицей»	$\sigma_1 = 2$, $\sigma_2 = 1$, $r = 0,9$ (задача 14.4)	при $r > \sigma_2/\sigma_1$ вес худшего прибора отрицателен
«неравенство Чебышёва даёт разумную оценку вероятности»	двумерный нормальный закон, $c = 10$ (замечание 5.11)	0,2 против точного $e^{-5} \approx 0,0067$

17. Что дальше

Три продолжения, каждое из которых снимает одно из ограничений корреляционной теории.

Ранговые коэффициенты связи. Коэффициент корреляции не инвариантен относительно нелинейных преобразований: у пары (ξ, ξ^3) связь функциональная, а r меньше единицы и зависит от распределения ξ . Коэффициенты Спирмена и Кендалла строятся по рангам наблюдений и потому не меняются при любом строго возрастающем преобразовании каждой из величин; они равны ± 1 на любой монотонной зависимости, а не только на линейной. Цена — они уже не связаны напрямую с дисперсией прогноза, то есть теряют интерпретацию следствия 6.2.

Копулы. Совместное распределение пары распадается на две части: маргинальные распределения и функцию связи между ними. Формально это теорема Склера: всякая совместная функция распределения представима как $C(F_\xi(x), F_\eta(y))$ с функцией C на квадрате, имеющей равномерные маргинальные распределения. Корреляционная теория описывает связь одним числом; копула описывает её функцией, и потому различает случаи, неразличимые по r , — в частности, поведение в хвостах, о котором вторые моменты молчат (последняя строка таблицы раздела 13).

Корреляционная теория случайных процессов. Приложение 3 — только вход. Дальше идут: спектральное представление стационарного процесса, теорема Хинчина о представлении корреляционной функции преобразованием Фурье, эргодические теоремы (когда среднее по одной траектории заменяет среднее по ансамблю), среднеквадратичное

дифференцирование и интегрирование процессов. Весь этот аппарат строится из тех же двух моментов и потому целиком принадлежит корреляционной теории.

18. Вопросы, которые стоит ожидать

Какие матрицы бывают ковариационными? Ровно симметричные неотрицательно определённые, и никаких других условий нет (теорема 5.5). Вторая половина утверждения — конструктивная: $\xi = \Gamma^{1/2}\zeta + a$.

Следует ли из некоррелированности независимость? Нет; следствие идёт в другую сторону (предложение 4.4). Контрпример — пример 8.1. Равносильность верна для *совместно* гауссовского вектора (теорема 7.5), и пример 8.2 показывает, что нормальности каждой компоненты для этого мало.

Что означает $r = 0$? Только то, что наилучший линейный прогноз тривиален: он равен $E\eta$ и не снимает ни доли дисперсии (следствие 6.2). Про нелинейную связь это не говорит ничего.

Что означает $|r| = 1$? Почти наверное линейную зависимость (теорема 4.3), то есть вырожденность ковариационной матрицы и попадание вектора в прямую (теорема 5.7).

Зачем нужен коэффициент корреляции, если есть ковариация? Ковариация зависит от единиц измерения, коэффициент корреляции — нет (замечание 3.8), и только он допускает интерпретацию доли снятой дисперсии.

В чём смысл неотрицательной определённости? В том, что дисперсия любой линейной комбинации неотрицательна (теорема 5.3); нарушение означало бы величину с отрицательной дисперсией.

Что даёт спектральное разложение ковариационной матрицы? Поворот, после которого компоненты некоррелированы, дисперсии в новых осях равны собственным значениям, и направление наибольшего разброса — первый собственный вектор (теорема 5.8). Это и есть метод главных компонент.

Как строится наилучший линейный прогноз и чему равна его ошибка? Теорема 6.1: $b^* = \text{cov}/D\xi$, остаточная дисперсия $D\eta(1 - r^2)$. Векторный вариант — теорема 6.4, и он же корректирующий шаг фильтра Калмана.

Почему условное математическое ожидание — наилучший прогноз? Потому что оно есть ортогональная проекция в L_2 на подпространство измеримых функций от наблюдения (теорема 6.6); минимальность получается теоремой Пифагора.

Когда наилучший прогноз линеен? В гауссовском случае (теорема 7.7); там же условная ковариация не зависит от наблюдаемого значения.

Чему равна дисперсия суммы зависимых величин? Сумме дисперсий плюс удвоенная сумма попарных ковариаций (следствие 5.4); аддитивность требует только попарной некоррелированности, не независимости.

Что такое эллипсоид рассеяния и что про него известно без предположений о распределении? Определение 5.9; оценка вероятности выхода — теорема 5.10, и она груба (замечание 5.11).

Может ли выборочная ковариационная матрица быть вырожденной? Обязана при $N \leq n$ (раздел 12.1); она же всегда неотрицательно определена.

19. Источники

Основной. [06] (Турчин), §21.1 «Многомерное нормальное распределение», с. 517–526: математическое ожидание случайного вектора и случайной матрицы, ковариационная матрица, лемма 21.1.1 о линейном преобразовании, теорема о симметричности и положительной полуопределённости (с. 518–519), гауссовские векторы, теоремы 21.1.1–21.1.6. Ковариация и коэффициент корреляции — там же, с. 109–110.

Второй русскоязычный. [24] (Гмурман), гл. 14 §17–18 (корреляционный момент, коэффициент корреляции, коррелированность и зависимость) и гл. 23 §3, с. 388–389 (определение корреляционной теории), §9 (корреляционная функция).

Условное математическое ожидание. [07] (Шабанов), теорема 10.4 о наилучшем квадратичном прогнозе, с. 98–99.

Дополнение на языке теории меры. [62] (Богачев), §1.2, с. 12–16: предложение 1.2.2, следствие 1.2.3 (ковариационный оператор), эллипсоид рассеяния, лемма 1.2.5, пример 1.2.6.

Случайные процессы. [44] (Гасников и др.), определения 1.8, 4.4 и 4.5; теорема Хинчина о спектральном представлении корреляционной функции.

Линейная алгебра. [01] (Бобень, Сиренева), §30.1 и §30.3, с. 105; свёрка — [02] (Голуб, Ван Лоун), теорема 8.1.1, с. 369, и теорема 8.1.2 (Куранта — Фишера).