Вопрос 08. Случайные величины и векторы. Элементы корреляционной теории случайных величин

Конспект теории с полными доказательствами

Крохалев Е. М.

2026

Содержание

I. Основная часть **2**

1. Постановка и мотивация **2**
1.1. Сквозной пример: два датчика с коррелированными шумами 3
1.2. Место вопроса среди остальных 3

2. Что берётся готовым **4**

3. Определения и обозначения **5**
3.1. Случайная величина, случайный вектор, распределение 5
3.2. Моменты, ковариация, коэффициент корреляции 6

4. Коэффициент корреляции: что именно он измеряет **7**

5. Ковариационная матрица **9**
5.1. Как она преобразуется и что описывает 9
5.2. Описание класса ковариационных матриц 10
5.3. Главные оси 11

6. Наилучший прогноз **13**
6.1. Наилучший линейный прогноз: скалярный случай 13
6.2. Наилучшая линейная оценка вектора по вектору 14
6.3. Прогноз без ограничения на класс 16

7. Гауссовский вектор: когда двух моментов хватает **17**

8. Посылки: что ломается и как **19**
8.1. Конечность вторых моментов 19
8.2. Некоррелированность не влечёт независимости 19

9. Приложение: оптимальная обработка измерений и шаг фильтра Калмана **20**
9.1. Два датчика 20
9.2. Общий случай: корректирующий шаг фильтра Калмана 21

10. Где корреляционная теория работает **21**

11. Разобранная задача: сквозной пример в числах **22**

II. Расширенная часть **22**

12. Доказательства, вынесенные из основной части **23**
12.1 Критерий измеримости по компонентам . . . 23
12.2 Обратная теорема о функции распределения . . . 23
12.3 Мультипликативность математического ожидания . . . 24
12.4 Многомерное неравенство Чебышёва . . . 24
12.5 Точное значение вероятности выхода за эллипсоид . . . 24
12.6 Характеристическая функция нормального закона . . . 25
12.7 Характеристическая функция гауссовского вектора . . . 25
12.8 Закон полной дисперсии . . . 25
12.9 Плотность гауссовского вектора . . . 26
12.10 В гауссовском случае корреляционная теория исчерпывающая . . . 26
12.11 Оптимальный вес при двух датчиках . . . 27
12.12 Некоррелированность и независимость в гауссовском случае . . . 27
12.13 Гауссовская пара со случайным знаком . . . 27
12.14 Условное распределение гауссовского вектора . . . 28
12.15 Калмановская поправка . . . 28

13. Корреляционное отношение: оценка сверху и снизу **28**

14. Приложение: главные компоненты **29**

15. Приложение: корреляционная теория случайных процессов **30**

16. Вычислительная сторона **31**
16.1 Выборочные оценки . . . 31
16.2 Устойчивость счёта . . . 32
16.3 Обращение ковариационной матрицы . . . 32

17. Посылки: невырожденность и смысл коэффициента корреляции **33**
17.1 Невырожденность . . . 33
17.2 Что именно утверждает коэффициент корреляции . . . 33

18. Ещё разобранные задачи **33**

19. Предельный переход от калмановской поправки к двум датчикам **35**

20. Сводка контрпримеров **36**

21. Что дальше **36**

22. Вопросы, которые стоит ожидать **37**

23. Источники **38**

Часть I.
Основная часть

1. Постановка и мотивация

Полное описание случайного вектора — это его распределение: мера на борелевских множествах $\mathbb{R}^n$. Пользоваться им напрямую почти никогда не удаётся. Распределение двумерного вектора задаётся функцией двух переменных, n-мерного — функцией n переменных; оценить такую функцию по данным нельзя уже при $n = 5$, а выписать её в модели можно лишь в немногих специальных случаях.

Поэтому в прикладной работе распределение заменяют **несколькими числами** — моментами, и почти всегда останавливаются на моментах первых двух порядков: векторе средних и ковариационной матрице. Теория, построенная на этой замене, называется **корреляционной**. Определение так и звучит: корреляционной называют теорию, основанную на изучении моментов первого и второго порядка ([24], гл. 23 §3); у Гмурмана оно дано для случайных функций, но рамка от этого не меняется.

Замена на два момента — сделка, и конспект отвечает на три вопроса о том, что именно в ней покупается и чем платится.

Первый: какие пары «вектор — матрица» бывают ковариационными? Вопрос не праздный: если в модель подставлена произвольная матрица, надо знать, бывает ли такая. Ответ полный — ровно симметричные неотрицательно определённые матрицы, и никаких других условий нет (теорема 5.5). Отсюда же получается практический критерий проверки и типичная ошибка при нём (замечание 5.6).

Второй: что по двум моментам можно посчитать, не зная распределения? Ответ: дисперсию любой линейной комбинации (теорема 5.3), наилучший линейный прогноз и его точность (теоремы 6.1 и 6.4), главные оси рассеяния (теорема 5.8), оценку вероятности большого уклонения (теорема 5.10). Этого хватает, чтобы построить оптимальную обработку измерений нескольких приборов и корректирующий шаг фильтра Калмана — и то и другое выводится здесь из одной теоремы.

Третий: когда двух моментов хватает полностью? Ответ точный: ровно в гауссовском случае. Там распределение определяется парой (a, Γ), некоррелированность равносильна независимости, а условное математическое ожидание линейно — то есть наилучший прогноз совпадает с наилучшим линейным (раздел 7). Вне гауссовского случая разрыв между ними может быть каким угодно, вплоть до полного: раздел 8 показывает пару, у которой коэффициент корреляции равен нулю, а одна величина есть функция другой.

Так устроен вопрос: **сперва описывается инструмент (ковариационная матрица), потом то, что им делается (прогноз и главные оси), потом граница его применимости (гауссовский случай против общего).**

1.1. Сквозной пример: два датчика с коррелированными шумами

Через весь конспект проходит один пример. Две измерительные системы дают оценки η_1 и η_2 одной и той же величины μ:

$$\eta_1 = \mu + \varepsilon_1, \qquad \eta_2 = \mu + \varepsilon_2, \tag{1}$$

погрешности $\varepsilon_1, \varepsilon_2$ имеют нулевые средние, дисперсии σ_1^2 и σ_2^2 и коэффициент корреляции r. Корреляция здесь не надуманная: приборы стоят в одном помещении и общий дрейф температуры входит в обе погрешности.

Спрашивается, как объединить два показания в одно, и что даёт корреляция. Ответ — в разделе 9, и он содержательнее, чем можно ожидать: при $\sigma_1 \neq \sigma_2$ и $r \to 1$ дисперсия наилучшей линейной комбинации стремится к **нулю**. Полностью коррелированный шум вычитается: одно измерение служит мерой погрешности другого. То есть **корреляция — это информация, а не только помеха**, и корреляционная теория как раз и есть аппарат, позволяющий эту информацию извлечь.

Второе, что видно на этом примере: при $\sigma_1 \neq \sigma_2$ и достаточно большом r оптимальный вес у **худшего** прибора отрицателен. Правило «усреднить показания», взятое без корреляционной теории, в этом случае даёт заведомо не лучший ответ.

1.2. Место вопроса среди остальных

Вопрос не требует от программы ничего: все нужные понятия вводятся здесь. Внешний аппарат — теория меры и интеграла, условное математическое ожидание, спектральная теорема для симметричной матрицы и теорема единственности для характеристических функций; всё выписано в разделе 2.

Продолжений у вопроса четыре, и каждое берёт отсюда своё.

Вопрос о законе больших чисел и центральной предельной теореме берёт отсюда только определения и неравенство Чебышёва — и выписывает их у себя сам, потому что каждый конспект самодостаточен. Вопрос о принятии решения берёт квадратичную функцию потерь и то, что байесовская оценка при ней есть условное математическое ожидание (теорема 6.6). Вопрос о методе главных компонент — прямое продолжение теоремы о главных осях (теорема 5.8). Вопрос о линейной регрессии стоит на теореме о наилучшем линейном прогнозе (теорема 6.1): метод наименьших квадратов есть её выборочный вариант.

Есть и обратная связка, важная для ответа: условное математическое ожидание — ортогональная проекция в пространстве L_2, и существование её даёт теорема о проекции из вопроса о гильбертовых пространствах. В этом конспекте условное математическое ожидание берётся готовым вместе со списком свойств (раздел 2), а то, что оно минимизирует средний квадрат, доказывается.

2. Что берётся готовым

Всё, что относится к ковариации и моментам второго порядка и нужно для ответа на вопрос, здесь доказывается. Что берётся готовым — перечислено ниже; сверх того в расширенной части используются, с оговоркой на месте, теорема Колмогорова о продолжении, представление Бохнера — Хинчина и скорость $N^{-1/2}$ из центральной предельной теоремы. Готовыми берутся факты четырёх сортов.

Теория меры и интеграла. Линейность и монотонность интеграла Лебега; непрерывность меры по монотонным последовательностям множеств; теорема о единственности продолжения меры с π-системы, порождающей σ-алгебру; теорема Фубини — Тонелли для произведения конечных мер; интеграл по образу меры (он же формула $\mathsf{E} g(\xi) = \int g\, dF_\xi$); формула замены переменных в кратном интеграле; дифференцирование под знаком интеграла при мажорируемой производной. Отдельно — значение интеграла Пуассона $\int_{\mathbb{R}} e^{-u^2/2}\, du = \sqrt{2\pi}$.

Условное математическое ожидание. Для ξ с $\mathsf{E}\,|\xi| < \infty$ и под-σ-алгебры $\mathcal{G} \subset \mathcal{F}$ существует и единственна с точностью до равенства почти наверное $\mathcal{G}$-измеримая величина $\mathsf{E}(\xi \mid \mathcal{G})$ с $\mathsf{E}\big(\mathsf{E}(\xi \mid \mathcal{G})\mathbb{1}_A\big) = \mathsf{E}(\xi \mathbb{1}_A)$ при всех $A \in \mathcal{G}$. Берутся её линейность, равенство $\mathsf{E}\big(\mathsf{E}(\xi \mid \mathcal{G})\big) = \mathsf{E}\xi$ и вынесение измеримого множителя: если ζ $\mathcal{G}$-измерима и $\mathsf{E}\,|\zeta\xi| < \infty$, то $\mathsf{E}(\zeta\xi \mid \mathcal{G}) = \zeta\, \mathsf{E}(\xi \mid \mathcal{G})$. Запись $\mathsf{E}(\xi \mid \eta)$ означает $\mathsf{E}(\xi \mid \sigma(\eta))$, где $\sigma(\eta)$ — σ-алгебра, порождённая случайным вектором η.

Берутся готовыми ещё три свойства, каждое из которых в конспекте работает. *Условное неравенство Йенсена:* для выпуклой ψ с $\mathsf{E}\,|\xi| < \infty$ и $\mathsf{E}\,|\psi(\xi)| < \infty$ выполнено $\psi(\mathsf{E}(\xi \mid \mathcal{G})) \le \mathsf{E}(\psi(\xi) \mid \mathcal{G})$ почти наверное ([07], лекция 9, свойство 10); при $\psi(x) = x^2$ отсюда $\mathsf{E}\big(\mathsf{E}(\xi \mid \mathcal{G})\big)^2 \le \mathsf{E}\xi^2$, то есть условное математическое ожидание величины из L_2 само лежит в L_2. *Лемма Дуба — Дынкина:* всякая $\sigma(\eta)$-измеримая случайная величина есть борелевская функция от η. *Независимость:* если ζ не зависит от η и $\mathsf{E}\,|\zeta| < \infty$, то $\mathsf{E}(\zeta \mid \eta) = \mathsf{E}\zeta$ почти наверное (проверяется прямо по определению: для $D \in \mathcal{B}(\mathbb{R}^m)$ имеем $\mathsf{E}(\zeta \mathbb{1}\{\eta \in D\}) = \mathsf{E}\zeta \cdot \mathsf{P}\{\eta \in D\}$ по мультипликативности математического ожидания на независимых сомножителях).

Условное распределение. **Условным распределением** вектора ξ при $\eta = y$ называется такое семейство вероятностных мер $\mu(\cdot \mid y)$ на $\mathcal{B}(\mathbb{R}^n)$, измеримо зависящее от y, что

$$\mathsf{P}\{\xi \in B,\ \eta \in D\} = \int_D \mu(B \mid y)\, F_\eta(dy)$$

при всех $B \in \mathcal{B}(\mathbb{R}^n)$ и $D \in \mathcal{B}(\mathbb{R}^m)$. Его существование для случайных векторов берётся готовым; именно выписанное равенство и проверяется в доказательстве теоремы об условном распределении гауссовского вектора.

Линейная алгебра. Спектральная теорема: у вещественной симметричной матрицы Γ существует ортогональная Q с $Q^{\mathsf{T}}\Gamma Q = \Lambda = \operatorname{diag}(\lambda_1, \dots, \lambda_n)$, λ_k вещественны ([01] §30.1, с. 105; сверка — [02], теорема 8.1.1, с. 369, «симметричное вещественное разложение Шура»). Перестановочность следа с циклической перестановкой сомножителей. Отсюда получается матричный корень: для неотрицательно определённой Γ полагаем $\Gamma^{1/2} = Q\Lambda^{1/2}Q^{\mathsf{T}}$, где $\Lambda^{1/2} = \operatorname{diag}(\sqrt{\lambda_1}, \dots, \sqrt{\lambda_n})$; он симметричен, неотрицательно определён и $(\Gamma^{1/2})^2 = \Gamma$. Разложение Холецкого $\Gamma = LL^{\mathsf{T}}$ с положительной диагональю L существует ровно у положительно определённых матриц.

Теорема единственности для характеристических функций на $\mathbb{R}^n$: различным распределениям отвечают различные характеристические функции ([06], теорема 21.1.2); и связь моментов с производными: если $\mathsf{E}\,|\xi|^n < \infty$, то $\mathsf{E}\xi^n = (-i)^n \varphi^{(n)}(0)$. Она нужна в разделе 7 и в вынесенных из него доказательствах (разделы 12.7, 12.12).

Сверка [01] с [02] — не формальность: авторы [01] предупреждают, что начиная с девятнадцатой лекции возможны ошибки, а спектральная теорема стоит в тридцатой.

3. Определения и обозначения

Обозначения. $(\Omega, \mathcal{F}, \mathsf{P})$ — вероятностное пространство: Ω — множество исходов, $\mathcal{F}$ — σ-алгебра событий, P — вероятностная мера. $\mathcal{B}(\mathbb{R}^n)$ — борелевская σ-алгебра на $\mathbb{R}^n$; при $n = 1$ пишем $\mathcal{B}$.

Векторы — столбцы; $u^{\mathsf{T}}v = \langle u, v\rangle$ — скалярное произведение, $\|u\|$ — евклидова норма. Для матриц $A \succeq B$ означает, что $A - B$ симметрична и неотрицательно определена; $A \succ B$ — что положительно определена. Запись $\Lambda = \operatorname{diag}(\lambda_1, \dots, \lambda_n)$ — диагональная матрица, I — единичная.

Буква n — размерность случайного вектора, m — число измерений, N — объём выборки. Буква r обозначает коэффициент корреляции (как у [06] и [24]), Γ — ковариационную матрицу (как у [06]), a — вектор средних. Верхний кружок $\xi^\circ = \xi - \mathsf{E}\xi$ обозначает центрирование.

3.1. Случайная величина, случайный вектор, распределение

Определение 3.1 (случайный вектор)**. Случайным вектором** (англ. *random vector*) размерности n называется измеримое отображение $\xi\colon \Omega \to \mathbb{R}^n$, то есть такое, что $\xi^{-1}(B) \in \mathcal{F}$ при всех $B \in \mathcal{B}(\mathbb{R}^n)$. При $n = 1$ он называется **случайной величиной** (англ. *random variable*). **Распределением** вектора ξ называется мера $F_\xi(B) = \mathsf{P}\{\xi \in B\}$ на $\mathcal{B}(\mathbb{R}^n)$, **функцией распределения** — функция

$$F_\xi(x_1, \dots, x_n) = \mathsf{P}\{\xi_1 \le x_1, \dots, \xi_n \le x_n\}.$$

Мера F_ξ и функция F_ξ обозначены одной буквой, как принято: их различает вид аргумента.

Теорема 3.2 (критерий измеримости по компонентам)**.** *Отображение $\xi = (\xi_1, \dots, \xi_n)^{\mathsf{T}}$ из Ω в $\mathbb{R}^n$ является случайным вектором тогда и только тогда, когда каждая его компонента ξ_k является случайной величиной.*

Идея. В одну сторону — композиция измеримых отображений; в другую — класс множеств с измеримым прообразом есть σ-алгебра, он содержит параллелепипеды $\prod_k (-\infty, x_k]$, а те порождают $\mathcal{B}(\mathbb{R}^n)$. Выкладка — в разделе 12.1.

Теорема 3.2 говорит, что работа с вектором не требует новой проверки измеримости: если компоненты — случайные величины, вектор из них автоматически случайный. Это и позволяет дальше не возвращаться к вопросу об измеримости.

Следующая теорема отвечает на вопрос, какие функции бывают функциями распределения. Ответ нужен по двум причинам: он показывает, что распределение можно задавать функцией распределения (а не мерой), и попутно даёт способ моделировать случайную величину с заданным законом.

Теорема 3.3 (свойства функции распределения и обратная теорема)**.** *Пусть ξ — случайная величина. Тогда её функция распределения $F = F_\xi$*

1. *не убывает;*
2. *удовлетворяет $\lim_{x\to-\infty} F(x) = 0$ и $\lim_{x\to+\infty} F(x) = 1$;*
3. *непрерывна справа в каждой точке.*

Обратно, всякая функция $F\colon \mathbb{R} \to [0,1]$ со свойствами 1–3 является функцией распределения некоторой случайной величины, заданной на интервале $(0,1)$ с мерой Лебега.

Идея. Прямая часть — монотонность вложенных событий и непрерывность меры. Обратная — построение: на интервале $(0,1)$ с мерой Лебега положить $\xi(u) = \inf\{x\colon F(x) \ge u\}$ и проверить равносильность $\xi(u) \le x \iff u \le F(x)$. Выкладка и вытекающий из неё метод обратной функции — в разделе 12.2.

Определение 3.4 (плотность, маргинальные распределения, независимость)**. Плотностью** распределения вектора ξ называется такая борелевская $p \ge 0$, что $F_\xi(B) = \int_B p(x)\,dx$ при всех $B \in \mathcal{B}(\mathbb{R}^n)$; тогда $\mathsf{E} g(\xi) = \int_{\mathbb{R}^n} g(x)p(x)\,dx$ для всякой борелевской $g \ge 0$ и всякой g с $\mathsf{E}\,|g(\xi)| < \infty$.

Маргинальным (частным) распределением компоненты ξ_k называется её собственное распределение; оно получается из совместного предельным переходом $F_{\xi_k}(x_k) = \lim F_\xi(x_1,\dots,x_n)$ при $x_j \to +\infty$, $j \ne k$.

Случайные векторы $\xi \in \mathbb{R}^n$ и $\eta \in \mathbb{R}^m$ **независимы**, если их совместное распределение есть произведение распределений: $F_{(\xi,\eta)} = F_\xi \otimes F_\eta$. Набор $\xi_1,\dots,\xi_n$ независим **в совокупности**, если совместное распределение есть произведение всех n распределений.

Произведение мер однозначно определяется своими значениями на прямоугольниках, а те образуют π-систему, порождающую $\mathcal{B}(\mathbb{R}^{n+m})$; поэтому независимость равносильна равенству $F_{(\xi,\eta)}(x,y) = F_\xi(x)F_\eta(y)$ для функций распределения — проверять достаточно его.

3.2. Моменты, ковариация, коэффициент корреляции

Определение 3.5 (моменты)**.** $\mathsf{E}\xi = \int_\Omega \xi\,d\mathsf{P}$ — **математическое ожидание** (определено при $\mathsf{E}\,|\xi| < \infty$); $\mathsf{D}\xi = \mathsf{E}(\xi - \mathsf{E}\xi)^2$ — **дисперсия**, $\sigma_\xi = \sqrt{\mathsf{D}\xi}$ — **стандартное уклонение**. Для случайной матрицы $V = [v_{kj}]$ полагаем $\mathsf{E}V = [\mathsf{E}v_{kj}]$; в частности, $\mathsf{E}\xi = (\mathsf{E}\xi_1,\dots,\mathsf{E}\xi_n)^{\mathsf{T}}$ для вектора.

Определение 3.6 (ковариация и коэффициент корреляции)**.** Пусть $\mathsf{E}\xi^2 < \infty$ и $\mathsf{E}\eta^2 < \infty$. **Ковариацией** (англ. *covariance*; в русской традиции также *корреляционный момент* — [24], гл. 14 §17) называется число

$$\operatorname{cov}(\xi,\eta) = \mathsf{E}(\xi - \mathsf{E}\xi)(\eta - \mathsf{E}\eta) = \mathsf{E}\xi\eta - \mathsf{E}\xi\,\mathsf{E}\eta.$$

Если $\sigma_\xi > 0$ и $\sigma_\eta > 0$, **коэффициентом корреляции** (англ. *correlation coefficient*) называется

$$r(\xi,\eta) = \frac{\operatorname{cov}(\xi,\eta)}{\sigma_\xi \sigma_\eta}.$$

Величины с $\operatorname{cov}(\xi,\eta) = 0$ называются **некоррелированными**.

Определение корректно: из $|\xi\eta| \le \frac{1}{2}(\xi^2+\eta^2)$ и $|\xi| \le \frac{1}{2}(\xi^2+1)$ следует, что конечность вторых моментов влечёт конечность $\mathsf{E}\,|\xi\eta|$, $\mathsf{E}\,|\xi|$ и $\mathsf{E}\,|\eta|$, так что все три слагаемые в определении существуют ([06], с. 109). Второе выражение для ковариации получается раскрытием скобок и линейностью.

Замечание 3.7 (два имени и разные единицы). Слово «корреляционный момент» у [24] означает ровно ковариацию, и стоит помнить оба имени: экзаменатор пользуется тем, к которому привык. У Гмурмана же взято и наблюдение, объясняющее, зачем вообще нужен коэффициент корреляции: ковариация имеет размерность произведения величин, и потому при переходе от сантиметров к миллиметрам значение 2 превращается в 200, тогда как коэффициент корреляции безразмерен и от выбора единиц не зависит.

Определение 3.8 (вектор средних и ковариационная матрица)**.** Пусть у всех компонент вектора $\xi \in \mathbb{R}^n$ конечны вторые моменты. Его **вектор средних** — $a = \mathsf{E}\xi$, **ковариационная матрица** (англ. *covariance matrix*) —

$$\Gamma_\xi = \mathsf{E}(\xi - a)(\xi - a)^{\mathsf{T}}, \qquad (\Gamma_\xi)_{kj} = \operatorname{cov}(\xi_k, \xi_j).$$

Для пары векторов $\xi \in \mathbb{R}^n$, $\eta \in \mathbb{R}^m$ **взаимной ковариационной матрицей** называется прямоугольная матрица $\Gamma_{\xi\eta} = \mathsf{E}(\xi - \mathsf{E}\xi)(\eta - \mathsf{E}\eta)^{\mathsf{T}}$ размера $n \times m$; транспонирование переставляет сомножители, поэтому $\Gamma_{\eta\xi} = \Gamma_{\xi\eta}^{\mathsf{T}}$. **Корреляционной матрицей** называется матрица $R_\xi = [r(\xi_k, \xi_j)]$ (определена при всех $\sigma_{\xi_k} > 0$); она получается из Γ_ξ нормировкой: $R_\xi = S^{-1}\Gamma_\xi S^{-1}$, где $S = \operatorname{diag}(\sigma_{\xi_1}, \dots, \sigma_{\xi_n})$.

Диагональ ковариационной матрицы — дисперсии компонент: $(\Gamma_\xi)_{kk} = \mathsf{D}\xi_k$; диагональ корреляционной состоит из единиц. То же построение для семейства сечений случайного процесса даёт корреляционную функцию (раздел 15).

Замечание 3.9 (ловушка имён). В части прикладной литературы «корреляционной матрицей» называют то, что здесь названо ковариационной. Различие содержательное — нормированная и ненормированная матрицы не совпадают, если дисперсии компонент не равны единице, — поэтому при чтении надо смотреть на формулу, а не на имя. Мы держим имена раздельно: *ковариационная* — из вторых центральных моментов, *корреляционная* — из коэффициентов корреляции.

Предложение 3.10 (линейность математического ожидания матрицы)**.** *Пусть V и W — случайные матрицы одинакового размера с конечными математическими ожиданиями, а A и B — постоянные матрицы таких размеров, что произведение AVB определено. Тогда*

$$\mathsf{E}(V + W) = \mathsf{E}V + \mathsf{E}W, \qquad \mathsf{E}(AVB) = A(\mathsf{E}V)B.$$

Доказательство. Оба равенства проверяются поэлементно: элемент матрицы AVB есть $\sum_{s,t} A_{is} v_{st} B_{tj}$ — конечная линейная комбинация элементов V с постоянными коэффициентами, и остаётся сослаться на линейность математического ожидания скалярных величин ([06], с. 517). □

Определение 3.11 (корреляционная теория)**. Корреляционной теорией** (англ. *second-order theory*) называется теория, основанная на изучении моментов первого и второго порядка ([24], гл. 23 §3, с. 388–389). Для случайного вектора это означает работу с парой (a, Γ_ξ) вместо распределения.

4. Коэффициент корреляции: что именно он измеряет

Теорема 4.1 (неравенство Коши — Буняковского для моментов)**.** *(В переводной литературе то же неравенство зовут* неравенством Шварца*, в части курсов — неравенством Коши — Буняковского — Шварца.) Пусть $\mathsf{E}\xi^2 < \infty$ и $\mathsf{E}\eta^2 < \infty$. Тогда $\mathsf{E}\,|\xi\eta| < \infty$ и*

$$(\mathsf{E}\xi\eta)^2 \le \mathsf{E}\xi^2 \cdot \mathsf{E}\eta^2. \tag{2}$$

Равенство достигается тогда и только тогда, когда найдётся пара чисел $(\alpha, \beta) \neq (0,0)$, при которой $\alpha\xi + \beta\eta = 0$ почти наверное.

Доказательство. Конечность $\mathsf{E}\,|\xi\eta|$ уже отмечена после определения 3.6.

Пусть сперва $\mathsf{E}\xi^2 > 0$. Для всякого $t \in \mathbb{R}$

$$q(t) = \mathsf{E}(t\xi + \eta)^2 = t^2\,\mathsf{E}\xi^2 + 2t\,\mathsf{E}\xi\eta + \mathsf{E}\eta^2 \geq 0,$$

поскольку под знаком математического ожидания стоит неотрицательная величина. Квадратный трёхчлен с положительным старшим коэффициентом неотрицателен при всех t тогда и только тогда, когда его дискриминант неположителен:

$$4(\mathsf{E}\xi\eta)^2 - 4\,\mathsf{E}\xi^2\,\mathsf{E}\eta^2 \leq 0,$$

что и есть (2).

Если же $\mathsf{E}\xi^2 = 0$, то $\xi = 0$ почти наверное, а тогда $\mathsf{E}\xi\eta = 0$ и обе части (2) равны нулю: неравенство обращается в равенство, и требуемое соотношение $1 \cdot \xi + 0 \cdot \eta = 0$ почти наверное выполнено.

Условие равенства. Пусть $\mathsf{E}\xi^2 > 0$ и в (2) равенство. Тогда дискриминант равен нулю, значит существует t_0 с $q(t_0) = 0$, то есть $\mathsf{E}(t_0\xi + \eta)^2 = 0$. Математическое ожидание неотрицательной величины равно нулю лишь тогда, когда величина равна нулю почти наверное, откуда $t_0\xi + \eta = 0$ почти наверное; пара $(t_0, 1)$ ненулевая. Случай $\mathsf{E}\xi^2 = 0$ разобран выше.

Обратно, пусть $\alpha\xi + \beta\eta = 0$ почти наверное при $(\alpha, \beta) \neq (0,0)$. Если $\beta \neq 0$, то $\eta = -(\alpha/\beta)\xi$ почти наверное; обозначив $b = -\alpha/\beta$, получаем $(\mathsf{E}\xi\eta)^2 = b^2(\mathsf{E}\xi^2)^2$ и $\mathsf{E}\xi^2\,\mathsf{E}\eta^2 = \mathsf{E}\xi^2 \cdot b^2\,\mathsf{E}\xi^2 = b^2(\mathsf{E}\xi^2)^2$ — равенство. Если же $\beta = 0$, то $\alpha \neq 0$ и $\xi = 0$ почти наверное, и обе части нули. □

Следствие 4.2 (границы ковариации и коэффициента корреляции)**.** *Для величин с конечными вторыми моментами*

$$|\operatorname{cov}(\xi, \eta)| \leq \sigma_\xi \sigma_\eta,$$

а при $\sigma_\xi > 0$, $\sigma_\eta > 0$ выполнено $|r(\xi, \eta)| \leq 1$.

Доказательство. Применяем теорему 4.1 к центрированным величинам ξ° и η°: там $\mathsf{E}\xi^\circ\eta^\circ = \operatorname{cov}(\xi, \eta)$, $\mathsf{E}(\xi^\circ)^2 = \mathsf{D}\xi$, $\mathsf{E}(\eta^\circ)^2 = \mathsf{D}\eta$. Деление на $\sigma_\xi\sigma_\eta > 0$ даёт вторую оценку. □

Теорема 4.3 (критерий $|r| = 1$)**.** *Пусть $\sigma_\xi > 0$ и $\sigma_\eta > 0$. Тогда $|r(\xi, \eta)| = 1$ в том и только том случае, когда существуют числа $b \neq 0$ и c, при которых $\eta = b\xi + c$ почти наверное. При этом*

$$|b| = \frac{\sigma_\eta}{\sigma_\xi}, \qquad \operatorname{sign} b = \operatorname{sign} r(\xi, \eta).$$

Доказательство. Необходимость. Равенство $|r| = 1$ означает равенство в (2) для центрированных величин, то есть $\alpha\xi^\circ + \beta\eta^\circ = 0$ почти наверное при некоторой ненулевой паре (α, β). Здесь $\beta \neq 0$: иначе $\alpha \neq 0$ и $\xi^\circ = 0$ почти наверное, что противоречит $\sigma_\xi > 0$. Значит $\eta^\circ = b\xi^\circ$ почти наверное с $b = -\alpha/\beta$, и тогда $\eta = b\xi + c$ с $c = \mathsf{E}\eta - b\,\mathsf{E}\xi$. Величина b не равна нулю: при $b = 0$ получилось бы $\sigma_\eta = 0$.

Достаточность и вычисление b. Пусть $\eta = b\xi + c$ почти наверное, $b \neq 0$. Тогда $\eta^\circ = b\xi^\circ$, откуда $\mathsf{D}\eta = b^2\mathsf{D}\xi$, то есть $\sigma_\eta = |b|\ \sigma_\xi$, и $\operatorname{cov}(\xi, \eta) = \mathsf{E}b(\xi^\circ)^2 = b\mathsf{D}\xi$. Следовательно

$$r(\xi, \eta) = \frac{b\,\sigma_\xi^2}{\sigma_\xi \cdot |b|\ \sigma_\xi} = \frac{b}{|b|} = \operatorname{sign} b,$$

что даёт и $|r| = 1$, и оба заявленных равенства. □

Теоремы 4.1 и 4.3 вместе отвечают на вопрос, что измеряет коэффициент корреляции: он лежит в $[-1,1]$, и крайние значения достигаются ровно на почти наверное линейной зависимости. Отсюда и его имя в русской литературе — мера **линейной** связи; про нелинейную он не утверждает ничего, и раздел 8 показывает, насколько «ничего» здесь буквально.

Предложение 4.4 (мультипликативность и некоррелированность)**.** *Пусть $\xi_1,\dots,\xi_k$ независимы в совокупности, а $u_1,\dots,u_k$ — борелевские функции, вещественно- или комплекснозначные, с $\mathsf{E}\left|u_j(\xi_j)\right|<\infty$. Тогда*

$$\mathsf{E}\prod_{j=1}^{k} u_j(\xi_j)=\prod_{j=1}^{k}\mathsf{E}u_j(\xi_j).$$

В частности, если ξ и η независимы и имеют конечные вторые моменты, то $\operatorname{cov}(\xi,\eta)=0$.

Идея. Совместное распределение независимых величин есть произведение, поэтому конечность $\mathsf{E}\prod_j\left|u_j(\xi_j)\right|$ даёт половина Тонелли, а снять модули позволяет половина Фубини; комплексный случай разбирается почленно. Выкладка — в разделе 12.3.

Обратное неверно, и это главное ограничение всей корреляционной теории; контрпримеры — в разделе 8.

5. Ковариационная матрица

5.1. Как она преобразуется и что описывает

Теорема 5.1 (преобразование при аффинном отображении)**.** *Пусть у вектора $\xi\in\mathbb{R}^n$ конечны вторые моменты компонент, A — постоянная матрица с n столбцами, b — постоянный вектор той же высоты, что у $A\xi$. Тогда*

$$\mathsf{E}(A\xi+b)=A\,\mathsf{E}\xi+b,\qquad \Gamma_{A\xi+b}=A\,\Gamma_\xi A^{\mathsf{T}}.$$

Для второго вектора $\eta\in\mathbb{R}^m$ и постоянной матрицы B с m столбцами выполнено $\Gamma_{A\xi,\,B\eta}=A\,\Gamma_{\xi\eta}B^{\mathsf{T}}$.

Доказательство. Первое равенство — линейность (предложение 3.10). Далее, $(A\xi+b)-\mathsf{E}(A\xi+b)=A(\xi-\mathsf{E}\xi)$, поэтому

$$\Gamma_{A\xi+b}=\mathsf{E}\big(A(\xi-\mathsf{E}\xi)\big)\big(A(\xi-\mathsf{E}\xi)\big)^{\mathsf{T}}=\mathsf{E}\Big(A(\xi-\mathsf{E}\xi)(\xi-\mathsf{E}\xi)^{\mathsf{T}}A^{\mathsf{T}}\Big)=A\,\Gamma_\xi A^{\mathsf{T}},$$

где последний переход — снова предложение 3.10 с постоянными множителями слева и справа; несмешанное равенство есть лемма 21.1.1 у [06]. Смешанный случай выписывается в одну строку тем же предложением:

$$\Gamma_{A\xi,\,B\eta}=\mathsf{E}\big(A(\xi-\mathsf{E}\xi)\big)\big(B(\eta-\mathsf{E}\eta)\big)^{\mathsf{T}}=\mathsf{E}\Big(A(\xi-\mathsf{E}\xi)(\eta-\mathsf{E}\eta)^{\mathsf{T}}B^{\mathsf{T}}\Big)=A\,\Gamma_{\xi\eta}B^{\mathsf{T}}.$$

□

Следствие 5.2 (сдвиг не меняет ковариаций)**.** $\Gamma_{\xi+b}=\Gamma_\xi$ *при любом постоянном b: ковариационная матрица — характеристика разброса, а не положения.*

Теорема 5.3 (дисперсия линейной комбинации)**.** *Для любого $u\in\mathbb{R}^n$*

$$\mathsf{D}\,\langle u,\xi\rangle=u^{\mathsf{T}}\Gamma_\xi u=\sum_{k,j=1}^{n}u_k u_j\operatorname{cov}(\xi_k,\xi_j).\tag{3}$$

Доказательство. Это теорема 5.1 при $A = u^{\mathsf{T}}$, $b = 0$: ковариационная матрица одномерного вектора $\langle u, \xi \rangle$ есть его дисперсия. □

Следствие 5.4 (дисперсия суммы)**.**

$$\mathsf{D}\Big(\sum_{k=1}^{n} \xi_k\Big) = \sum_{k=1}^{n} \mathsf{D}\xi_k + 2\sum_{k<j} \operatorname{cov}(\xi_k, \xi_j).$$

В частности, если величины попарно некоррелированы, дисперсия суммы равна сумме дисперсий.

Доказательство. Формула (3) при $u = (1, \dots, 1)^{\mathsf{T}}$; диагональные слагаемые дают дисперсии, внедиагональные попарно совпадают по симметрии ковариации. □

Следствие 5.4 — это ровно то место, где корреляционная теория входит в закон больших чисел: там нужна аддитивность дисперсии, и нужна она только для попарно некоррелированных слагаемых, а независимость оказывается избыточным требованием.

5.2. Описание класса ковариационных матриц

Теорема 5.5 (какие матрицы бывают ковариационными)**.** *1. Ковариационная матрица всякого случайного вектора симметрична и неотрицательно определена.*

2. *Обратно, для всякой симметричной неотрицательно определённой матрицы Γ размера $n \times n$ и всякого $a \in \mathbb{R}^n$ существует случайный вектор ξ с $\mathsf{E}\xi = a$ и $\Gamma_\xi = \Gamma$.*

Доказательство. Пункт 1. Симметричность: ковариация симметрична по определению 3.6, поскольку произведение центрированных величин от порядка сомножителей не зависит, то есть $\operatorname{cov}(\xi_k, \xi_j) = \operatorname{cov}(\xi_j, \xi_k)$. Неотрицательная определённость — прямое следствие теоремы 5.3: при любом u

$$u^{\mathsf{T}}\Gamma_\xi u = \mathsf{D}\,\langle u, \xi \rangle = \mathsf{E}\,\langle u, \xi - a \rangle^2 \geq 0$$

как математическое ожидание неотрицательной величины.

Пункт 2. Построим вероятностное пространство явно, чтобы не опираться на существование нормального закона. Возьмём $\Omega = \{-1, 1\}^n$ с равномерной мерой (все 2^n исходов равновероятны) и положим $\zeta_k(\omega) = \omega_k$. Компоненты $\zeta = (\zeta_1, \dots, \zeta_n)^{\mathsf{T}}$ независимы в совокупности, $\mathsf{E}\zeta_k = 0$, $\mathsf{D}\zeta_k = \mathsf{E}\zeta_k^2 = 1$, и потому $\Gamma_\zeta = I$ (внедиагональные элементы равны нулю по предложению 4.4).

Матрица Γ симметрична и неотрицательно определена, значит определён её корень $\Gamma^{1/2}$ (раздел 2). Положим $\xi = \Gamma^{1/2}\zeta + a$. По теореме 5.1

$$\mathsf{E}\xi = a, \qquad \Gamma_\xi = \Gamma^{1/2}\, I\, (\Gamma^{1/2})^{\mathsf{T}} = \Gamma^{1/2}\Gamma^{1/2} = \Gamma,$$

поскольку $\Gamma^{1/2}$ симметричен. □

Пункт 2 — не техническая подробность, а содержательное утверждение: **корреляционная теория не накладывает на пару (a, Γ) никаких условий, кроме симметрии и неотрицательной определённости.** Поэтому вопрос «бывает ли такая ковариационная матрица» сводится к проверке неотрицательной определённости — и нигде больше не требует знания распределения.

Замечание 5.6 (угловых миноров недостаточно). Критерий Сильвестра в ходовой формулировке — «все угловые миноры положительны» — проверяет *положительную* определённость. Для *неотрицательной* определённости условие «все угловые миноры неотрицательны» ложно. Контрпример на матрице 2×2:

$$\Gamma = \begin{pmatrix} 0 & 0 \\ 0 & -1 \end{pmatrix},$$

угловые миноры равны 0 и 0, оба неотрицательны, а $u^{\mathsf{T}}\Gamma u = -u_2^2 < 0$ при $u = (0,1)^{\mathsf{T}}$. Верный критерий даёт спектральная теорема: в записи $\Gamma = Q\Lambda Q^{\mathsf{T}}$ неотрицательная определённость равносильна неотрицательности всех λ_k, — их и считают на практике. Разложение Холецкого для этой проверки не годится: разложение $\Gamma = LL^{\mathsf{T}}$ с *положительной* диагональю L существует ровно у *положительно* определённых матриц, а вырожденная ковариационная матрица допустима (пункт 2 теоремы 5.5) и такого разложения не имеет: у $\operatorname{diag}(0,1)$ разложение LL^{T} есть, но диагональ L положительной быть не может. Само по себе существование вещественного L с $\Gamma = LL^{\mathsf{T}}$ равносильно как раз неотрицательной определённости — в одну сторону потому, что $u^{\mathsf{T}}LL^{\mathsf{T}}u = \|L^{\mathsf{T}}u\|^2 \geq 0$, а в другую потому, что годится $L = \Gamma^{1/2}$ (раздел 2), — то есть в точной арифметике критерием оно было бы. Не годится оно по другой причине: стандартный алгоритм требует строго положительного ведущего элемента на каждом шаге и на вырожденной матрице останавливается — то есть по факту обрыва вырожденную от недопустимой не отличить. Счёт и обращение по выборке — раздел 16.

Теорема 5.7 (вырожденность и размерность носителя)**.** *Пусть* $a = \mathsf{E}\xi$, $\Gamma = \Gamma_\xi$. *Тогда*

1. *для* $u \in \mathbb{R}^n$ *равенство* $u^{\mathsf{T}}\Gamma u = 0$ *равносильно* $\langle u, \xi - a\rangle = 0$ *почти наверное;*
2. *если* $\operatorname{rank}\Gamma = k$, *то почти наверное* $\xi \in a + \mathcal{L}$, *где* $\mathcal{L} = \operatorname{Im}\Gamma$ *— линейное подпространство размерности* k.

Доказательство. Пункт 1. По теореме 5.3 $u^{\mathsf{T}}\Gamma u = \mathsf{E}\langle u, \xi - a\rangle^2$. Математическое ожидание неотрицательной величины равно нулю тогда и только тогда, когда величина равна нулю почти наверное.

Пункт 2. Матрица Γ симметрична, поэтому $\ker\Gamma = (\operatorname{Im}\Gamma)^\perp$ и $\dim\ker\Gamma = n - k$. Заметим, что $u \in \ker\Gamma$ влечёт $u^{\mathsf{T}}\Gamma u = 0$. Возьмём базис $u_1, \ldots, u_{n-k}$ ядра; по пункту 1 каждое событие $\{\langle u_i, \xi - a\rangle = 0\}$ имеет вероятность 1, а пересечение конечного числа событий вероятности 1 имеет вероятность 1. Значит почти наверное $\xi - a$ ортогонален всему $\ker\Gamma$, то есть $\xi - a \in (\ker\Gamma)^\perp = \operatorname{Im}\Gamma$. □

Теорема 5.7 объясняет, что означает вырожденность ковариационной матрицы: не «плохую обусловленность», а точную линейную связь между компонентами, выполненную почти наверное. В сквозном примере (1) это случай $|r| = 1$: показания двух приборов связаны точным линейным соотношением, и одно из них лишнее — либо, наоборот, позволяет полностью вычесть шум другого (раздел 9).

5.3. Главные оси

Теорема 5.8 (главные оси рассеяния)**.** *Пусть* $\Gamma = \Gamma_\xi$, $\Gamma = Q\Lambda Q^{\mathsf{T}}$ *— её спектральное разложение,* $Q = [q_1, \ldots, q_n]$ *ортогональна,* $\Lambda = \operatorname{diag}(\lambda_1, \ldots, \lambda_n)$, $\lambda_1 \geq \ldots \geq \lambda_n \geq 0$. *Тогда*

1. *компоненты вектора* $\zeta = Q^{\mathsf{T}}(\xi - a)$ *попарно некоррелированы и* $\mathsf{D}\zeta_k = \lambda_k$;
2. $\max\limits_{\|u\|=1} \mathsf{D}\langle u, \xi\rangle = \lambda_1$, *и максимум достигается при* $u = q_1$;
3. $\min\limits_{\|u\|=1} \mathsf{D}\langle u, \xi\rangle = \lambda_n$, *и минимум достигается при* $u = q_n$;
4. $\operatorname{tr}\Gamma = \sum_{k=1}^n \lambda_k = \sum_{k=1}^n \mathsf{D}\xi_k$.

Доказательство. Пункт 1. По теореме 5.1 $\Gamma_\zeta = Q^{\mathsf T}\Gamma Q = \Lambda$; внедиагональные элементы диагональной матрицы равны нулю, диагональные равны λ_k.

Пункт 2. Разложим единичный вектор u по ортонормированному базису: $u = \sum_k c_k q_k$, $\sum_k c_k^2 = 1$. Тогда

$$u^{\mathsf T}\Gamma u = \sum_k \lambda_k c_k^2 \le \lambda_1 \sum_k c_k^2 = \lambda_1,$$

и при $u = q_1$ достигается равенство.

Пункт 3. В тех же обозначениях

$$u^{\mathsf T}\Gamma u = \sum_k \lambda_k c_k^2 \ge \lambda_n \sum_k c_k^2 = \lambda_n,$$

поскольку все $\lambda_k \ge \lambda_n$, а $c_k^2 \ge 0$; при $u = q_n$ достигается равенство.

Пункт 4. След инвариантен относительно подобия, поэтому $\operatorname{tr}\Gamma = \operatorname{tr}(Q\Lambda Q^{\mathsf T}) = \operatorname{tr}\Lambda = \sum \lambda_k$; с другой стороны, след равен сумме диагональных элементов Γ, то есть сумме дисперсий компонент. □

Утверждения о некоррелированности и о крайних значениях — вся геометрическая часть корреляционной теории. Ортогональный поворот $Q^{\mathsf T}$ превращает произвольный набор коррелированных компонент в некоррелированный, а дисперсии в новых осях суть собственные значения Γ; направление наибольшего разброса — собственный вектор наибольшего собственного значения, наименьшего — собственный вектор наименьшего. Второе не менее полезно первого: направление q_n — то, вдоль которого данные почти не меняются, то есть кандидат на линейную связь между компонентами (при $\lambda_n = 0$ связь точная, теорема 5.7). Метод главных компонент (англ. *principal component analysis*, PCA) — это в точности данная теорема, применённая к выборочной ковариационной матрице (раздел 14).

Утверждение о следе даёт сохраняющуюся при повороте величину — **полную дисперсию** $\operatorname{tr}\Gamma$. Она и служит знаменателем в доле объяснённой дисперсии, на которой основан отбор числа главных компонент.

Определение 5.9 (эллипсоид рассеяния)**.** Пусть Γ невырождена. **Эллипсоидом рассеяния** уровня $c > 0$ называется множество

$$E_c = \{x \in \mathbb{R}^n : (x-a)^{\mathsf T}\Gamma^{-1}(x-a) \le c\}.$$

Его главные полуоси направлены по q_k и равны $\sqrt{c\lambda_k}$; объём равен $c^{n/2} V_n \sqrt{\det\Gamma}$, где V_n — объём единичного шара в $\mathbb{R}^n$.

Утверждение о полуосях получается подстановкой $x - a = Qy$: неравенство превращается в $\sum_k y_k^2/\lambda_k \le c$. Объём — формула замены переменных с якобианом $\det\Gamma^{1/2} = \sqrt{\det\Gamma}$. Отсюда имя $\det\Gamma$ — **обобщённая дисперсия**: она меряет объём рассеяния и обращается в нуль ровно при вырожденности, то есть в случае теоремы 5.7.

Теорема 5.10 (многомерное неравенство Чебышёва)**.** *Пусть Γ невырождена и $c > 0$. Тогда*

$$\mathsf P\{(\xi-a)^{\mathsf T}\Gamma^{-1}(\xi-a) \ge c\} \le \frac{n}{c},$$

то есть вероятность выйти за эллипсоид рассеяния уровня c не превосходит n/c.

Идея. Неравенство Маркова, применённое к квадратичной форме $\varrho = (\xi-a)^{\mathsf T}\Gamma^{-1}(\xi-a)$, вместе с равенством $\mathsf E\varrho = n$, которое получается из $\varrho = \operatorname{tr}\bigl(\Gamma^{-1}(\xi-a)(\xi-a)^{\mathsf T}\bigr)$ перестановочностью следа с математическим ожиданием. Выкладка — в разделе 12.4.

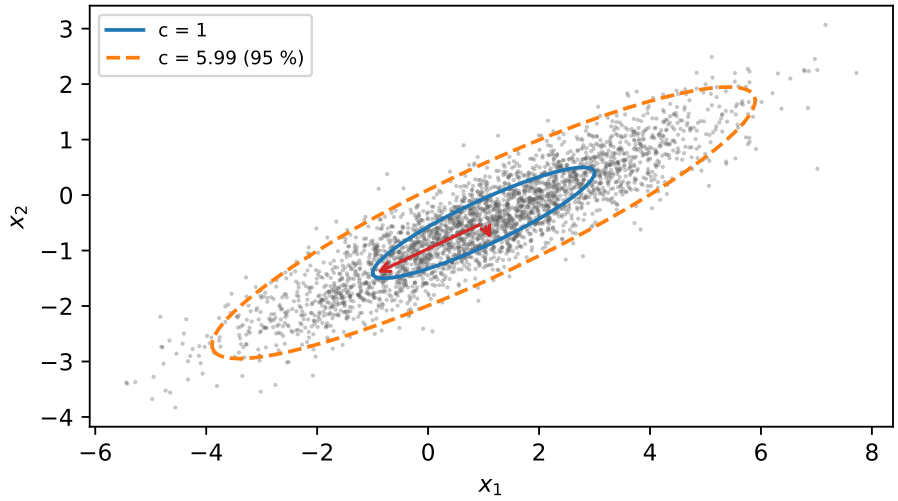


Рис. 1: Выборка из двумерного нормального закона с $\mathsf{D}\xi_1 = 4$, $\mathsf{D}\xi_2 = 1$ и $\operatorname{cov}(\xi_1, \xi_2) = 1{,}8$, то есть с $r = 0{,}9$. Стрелки — главные оси длиной $\sqrt{\lambda_k}$, $\lambda_1 = 4{,}843$, $\lambda_2 = 0{,}157$; кривые — эллипсы рассеяния уровней $c = 1$ и $c = 5{,}99$ (внутри последнего оказалось $94{,}98\,\%$ выборки при точном значении $95\,\%$). Видно, чего стоит корреляция: разброс вдоль первой главной оси в $\sqrt{\lambda_1/\lambda_2} = 5{,}56$ раза шире, чем поперёк. Построено в `examples.ipynb`, пример 3.

Замечание 5.11 (что даёт и чего не даёт эта оценка). При $n = 1$ теорема 5.10 превращается в классическое неравенство Чебышёва $\mathsf{P}\{|\xi - a| \geq \sigma\sqrt{c}\} \leq 1/c$. Достоинство её в том, что она не требует ничего, кроме конечности вторых моментов и невырожденности Γ, и потому работает при любом распределении. Цена — грубость. Для двумерного нормального закона точная вероятность выйти за эллипс уровня c равна $e^{-c/2}$; вывод занимает две строки и приведён в разделе 12.5. Оценка теоремы 5.10 даёт при том же c величину $2/c$. При $c = 10$ это $0{,}2$ против $e^{-5} \approx 0{,}0067$ — завышение в $29{,}7$ раза; доля точек вне эллипса измерена на выборке, а отношение оценки к точному значению напечатано — пример 3 ноутбука.

6. Наилучший прогноз

Раздел отвечает на главный прикладной вопрос корреляционной теории: как по наблюдённой величине предсказать ненаблюдённую и насколько точно это удаётся. Порядок такой: сперва скалярный линейный прогноз, потом векторный, потом прогноз без ограничения на класс — и сравнение двух последних показывает, что именно теряет корреляционная теория.

6.1. Наилучший линейный прогноз: скалярный случай

Теорема 6.1 (наилучший линейный прогноз)**.** *Пусть* $\mathsf{E}\xi^2 < \infty$, $\mathsf{E}\eta^2 < \infty$ *и* $\mathsf{D}\xi > 0$. *Тогда*

$$\min_{b,c\in\mathbb{R}} \mathsf{E}(\eta - b\xi - c)^2 = \mathsf{D}\eta\,(1 - r^2), \qquad r = r(\xi, \eta),$$

минимум достигается в единственной точке

$$b^* = \frac{\operatorname{cov}(\xi,\eta)}{\mathsf{D}\xi} = r\,\frac{\sigma_\eta}{\sigma_\xi}, \qquad c^* = \mathsf{E}\eta - b^*\,\mathsf{E}\xi.$$

Доказательство. Обозначим $\xi^\circ = \xi - \mathsf{E}\xi$, $\eta^\circ = \eta - \mathsf{E}\eta$ и $\gamma = \mathsf{E}\eta - b\,\mathsf{E}\xi - c$. Тогда $\eta - b\xi - c = (\eta^\circ - b\xi^\circ) + \gamma$, а величина $\eta^\circ - b\xi^\circ$ имеет нулевое математическое ожидание, поэтому удвоенное произведение при раскрытии квадрата исчезает:

$$\mathsf{E}(\eta - b\xi - c)^2 = \mathsf{E}(\eta^\circ - b\xi^\circ)^2 + \gamma^2.$$

Второе слагаемое зависит только от c (при фиксированном b) и обращается в нуль ровно при $c = \mathsf{E}\eta - b\,\mathsf{E}\xi$; при этом первое слагаемое не меняется. Значит минимум по c берётся именно там, и остаётся минимизировать

$$g(b) = \mathsf{E}(\eta^\circ - b\xi^\circ)^2 = \mathsf{D}\eta - 2b\,\operatorname{cov}(\xi,\eta) + b^2\mathsf{D}\xi.$$

Это квадратный трёхчлен с положительным старшим коэффициентом $\mathsf{D}\xi > 0$; он имеет единственный минимум при $b^* = \operatorname{cov}(\xi,\eta)/\mathsf{D}\xi$, и

$$g(b^*) = \mathsf{D}\eta - \frac{\operatorname{cov}^2(\xi,\eta)}{\mathsf{D}\xi} = \mathsf{D}\eta\left(1 - \frac{\operatorname{cov}^2(\xi,\eta)}{\mathsf{D}\xi\,\mathsf{D}\eta}\right) = \mathsf{D}\eta\,(1 - r^2).$$

Единственность точки минимума по паре (b,c) следует из строгой выпуклости по b и из того, что c определяется по b однозначно. □

Следствие 6.2 (смысл r^2)**.** *Доля дисперсии η, снимаемая наилучшим линейным прогнозом по ξ, равна r^2:*

$$\frac{\mathsf{D}\eta - \min_{b,c}\mathsf{E}(\eta - b\xi - c)^2}{\mathsf{D}\eta} = r^2.$$

Прямая $y = b^*x + c^*$ называется **прямой среднеквадратичной регрессии** η на ξ; в стандартизованной записи она выглядит так:

$$\frac{y - \mathsf{E}\eta}{\sigma_\eta} = r\,\frac{x - \mathsf{E}\xi}{\sigma_\xi}. \tag{4}$$

Замечание 6.3 (две прямые регрессии и почему их две)*.* Поменяв роли величин, получим прямую регрессии ξ на η: $\frac{x-\mathsf{E}\xi}{\sigma_\xi} = r\frac{y-\mathsf{E}\eta}{\sigma_\eta}$, то есть в координатах (x,y) — прямую с угловым коэффициентом $\sigma_\eta/(r\sigma_\xi)$ при $r \neq 0$. Угловые коэффициенты двух прямых относятся как r^2, поэтому прямые совпадают тогда и только тогда, когда $r^2 = 1$, то есть ровно в случае почти наверное линейной связи (теорема 4.3). При $r \to 0$ они расходятся к горизонтали и вертикали.

Смысл этого прост, и его стоит проговорить на экзамене: прогноз несимметричен. Величина $b^* = r\sigma_\eta/\sigma_\xi$ по модулю меньше, чем σ_η/σ_ξ, — наилучший прогноз всегда «притянут» к среднему сильнее, чем сама величина. Это и есть явление, которое Гальтон назвал регрессией к среднему и от которого метод получил своё имя.

6.2. Наилучшая линейная оценка вектора по вектору

Теорема 6.4 (наилучшая линейная оценка)**.** *Пусть $\xi \in \mathbb{R}^n$ и $\eta \in \mathbb{R}^m$ — случайные векторы с конечными вторыми моментами компонент и невырожденной Γ_η. Среди всех оценок*

вида $\hat{\xi} = B\eta + c$ *(*B *— матрица* $n \times m$*,* $c \in \mathbb{R}^n$*) матрица вторых моментов ошибки* $\mathsf{E}(\xi - \hat{\xi})(\xi - \hat{\xi})^\mathsf{T}$ *минимальна в смысле порядка* $\succeq$ *при*

$$B^* = \Gamma_{\xi\eta}\Gamma_\eta^{-1}, \qquad c^* = \mathsf{E}\xi - B^*\mathsf{E}\eta,$$

и минимум равен

$$\Gamma_{\text{err}} = \Gamma_\xi - \Gamma_{\xi\eta}\Gamma_\eta^{-1}\Gamma_{\eta\xi}. \tag{5}$$

Точка минимума единственна.

Доказательство. Обозначим $\xi^\circ = \xi - \mathsf{E}\xi$, $\eta^\circ = \eta - \mathsf{E}\eta$. Для произвольных B, c ошибка записывается как

$$e = \xi - B\eta - c = (\xi^\circ - B\eta^\circ) + d, \qquad d = \mathsf{E}\xi - B\,\mathsf{E}\eta - c,$$

причём $\mathsf{E}(\xi^\circ - B\eta^\circ) = 0$, поэтому перекрёстные слагаемые исчезают:

$$\mathsf{E}ee^\mathsf{T} = \mathsf{E}(\xi^\circ - B\eta^\circ)(\xi^\circ - B\eta^\circ)^\mathsf{T} + dd^\mathsf{T}.$$

Матрица dd^T неотрицательно определена и равна нулю ровно при $d = 0$, то есть при $c = \mathsf{E}\xi - B\,\mathsf{E}\eta$; значит минимум берётся при этом c, каково бы ни было B.

Положим $e^* = \xi^\circ - B^*\eta^\circ$. Ключевое свойство — ошибка не коррелирует с данными:

$$\mathsf{E}e^*(\eta^\circ)^\mathsf{T} = \Gamma_{\xi\eta} - B^*\Gamma_\eta = \Gamma_{\xi\eta} - \Gamma_{\xi\eta}\Gamma_\eta^{-1}\Gamma_\eta = 0.$$

Для произвольного B имеем $\xi^\circ - B\eta^\circ = e^* - (B - B^*)\eta^\circ$, и в силу выписанной ортогональности

$$\mathsf{E}(\xi^\circ - B\eta^\circ)(\xi^\circ - B\eta^\circ)^\mathsf{T} = \mathsf{E}e^*(e^*)^\mathsf{T} + (B - B^*)\Gamma_\eta(B - B^*)^\mathsf{T}.$$

Второе слагаемое неотрицательно определено, поэтому $\mathsf{E}ee^\mathsf{T} \succeq \mathsf{E}e^*(e^*)^\mathsf{T}$; равенство достигается лишь при $(B - B^*)\Gamma_\eta(B - B^*)^\mathsf{T} = 0$, что при невырожденной Γ_η даёт $B = B^*$ (иначе нашлась бы строка v^T матрицы $B - B^*$ с $v^\mathsf{T}\Gamma_\eta v > 0$). Наконец,

$$\mathsf{E}e^*(e^*)^\mathsf{T} = \Gamma_\xi - B^*\Gamma_{\eta\xi} - \Gamma_{\xi\eta}(B^*)^\mathsf{T} + B^*\Gamma_\eta(B^*)^\mathsf{T} = \Gamma_\xi - \Gamma_{\xi\eta}\Gamma_\eta^{-1}\Gamma_{\eta\xi},$$

поскольку два последних слагаемых взаимно уничтожаются. □

Утверждение о минимальности в смысле $\succeq$ сильнее, чем минимальность следа или определителя: из $\Gamma_{\text{err}} \preceq \Gamma$ следует и $\operatorname{tr}\Gamma_{\text{err}} \le \operatorname{tr}\Gamma$, и $\det\Gamma_{\text{err}} \le \det\Gamma$, и малость дисперсии **любой** линейной комбинации компонент ошибки. Обратное неверно, поэтому именно в такой форме теорему и стоит формулировать.

Следствие 6.5 (неотрицательность дополнения Шура)**.** *Если блочная матрица* $\begin{pmatrix}\Gamma_\xi & \Gamma_{\xi\eta}\\ \Gamma_{\eta\xi} & \Gamma_\eta\end{pmatrix}$ *является ковариационной матрицей объединённого вектора* (ξ, η) *и* Γ_η *невырождена, то её дополнение Шура* (5) *неотрицательно определено.*

Доказательство. По теореме 6.4 дополнение Шура (5) есть матрица вторых моментов случайного вектора e^*, то есть его ковариационная матрица (среднее e^* равно нулю); остаётся сослаться на пункт 1 теоремы 5.5. □

Следствие 6.5 — пример того, как вероятностный язык доказывает чисто алгебраический факт: неотрицательность дополнения Шура получена без единой матричной выкладки, из того лишь, что дисперсия неотрицательна.

6.3. Прогноз без ограничения на класс

Теорема 6.6 (условное математическое ожидание как наилучший прогноз)**.** *Пусть* $\mathsf{E}\xi^2 < \infty$, $\mathcal{G} \subset \mathcal{F}$ *— под-σ-алгебра,* $\mathcal{A}_{\mathcal{G}}$ *— множество* $\mathcal{G}$*-измеримых случайных величин с конечным вторым моментом. Тогда*

$$\mathsf{E}\bigl(\xi - \mathsf{E}(\xi \mid \mathcal{G})\bigr)^2 = \min_{\zeta \in \mathcal{A}_{\mathcal{G}}} \mathsf{E}(\xi - \zeta)^2,$$

и минимум достигается только на $\zeta = \mathsf{E}(\xi \mid \mathcal{G})$ *(с точностью до равенства почти наверное).*

Доказательство. Обозначим $\hat{\xi} = \mathsf{E}(\xi \mid \mathcal{G})$; она принадлежит $\mathcal{A}_{\mathcal{G}}$, поскольку по условному неравенству Йенсена с $\psi(x) = x^2$ (раздел 2) выполнено $\mathsf{E}\hat{\xi}^2 \le \mathsf{E}\xi^2 < \infty$. Для $\zeta \in \mathcal{A}_{\mathcal{G}}$ запишем

$$\mathsf{E}(\xi - \zeta)^2 = \mathsf{E}(\xi - \hat{\xi})^2 + \mathsf{E}(\hat{\xi} - \zeta)^2 + 2\,\mathsf{E}\bigl[(\xi - \hat{\xi})(\hat{\xi} - \zeta)\bigr].$$

Покажем, что третье слагаемое равно нулю. Разность $\hat{\xi} - \zeta$ $\mathcal{G}$-измерима, и $\mathsf{E}\bigl|(\hat{\xi} - \zeta)(\xi - \hat{\xi})\bigr| < \infty$ по неравенству Коши — Буняковского (теорема 4.1), так что множитель можно вынести:

$$\mathsf{E}\bigl[(\hat{\xi} - \zeta)(\xi - \hat{\xi})\bigr] = \mathsf{E}\Bigl[\mathsf{E}\bigl((\hat{\xi} - \zeta)(\xi - \hat{\xi}) \mid \mathcal{G}\bigr)\Bigr] = \mathsf{E}\Bigl[(\hat{\xi} - \zeta)\,\mathsf{E}(\xi - \hat{\xi} \mid \mathcal{G})\Bigr] = 0,$$

поскольку $\mathsf{E}(\xi \mid \mathcal{G}) = \hat{\xi}$ и $\hat{\xi}$ $\mathcal{G}$-измерима, откуда $\mathsf{E}(\xi - \hat{\xi} \mid \mathcal{G}) = 0$. Итак,

$$\mathsf{E}(\xi - \zeta)^2 = \mathsf{E}(\xi - \hat{\xi})^2 + \mathsf{E}(\hat{\xi} - \zeta)^2 \ge \mathsf{E}(\xi - \hat{\xi})^2,$$

и равенство достигается тогда и только тогда, когда $\mathsf{E}(\hat{\xi} - \zeta)^2 = 0$, то есть $\zeta = \hat{\xi}$ почти наверное ([07], теорема 10.4, с. 98–99). □

Выкладка доказательства — это теорема Пифагора: разность $\xi - \hat{\xi}$ ортогональна всему подпространству $\mathcal{A}_{\mathcal{G}}$ в пространстве $L_2(\Omega, \mathcal{F}, \mathsf{P})$ со скалярным произведением $\langle \xi, \eta \rangle = \mathsf{E}\xi\eta$, и $\hat{\xi}$ — ортогональная проекция ξ на это подпространство. Существование проекции даёт теорема о проекции из вопроса о гильбертовых пространствах; здесь же условное математическое ожидание взято готовым, а доказана именно минимальность.

Следствие 6.7 (закон полной дисперсии)**.** *Пусть* $\mathsf{E}\xi^2 < \infty$ *и* $\mathsf{D}(\xi \mid \mathcal{G}) = \mathsf{E}(\xi^2 \mid \mathcal{G}) - \bigl(\mathsf{E}(\xi \mid \mathcal{G})\bigr)^2$*. Тогда*

$$\mathsf{D}\xi = \mathsf{E}\,\mathsf{D}(\xi \mid \mathcal{G}) + \mathsf{D}\,\mathsf{E}(\xi \mid \mathcal{G}).$$

Идея. Та же ортогональность: разложить $\xi - \mathsf{E}\xi$ на $(\xi - \hat{\xi})$ и $(\hat{\xi} - \mathsf{E}\xi)$, перекрёстное слагаемое обнуляется, первое даёт $\mathsf{E}\mathsf{D}(\xi \mid \mathcal{G})$, второе — $\mathsf{D}\hat{\xi}$. Выкладка — в разделе 12.8.

Определение 6.8 (корреляционное отношение)**.** Пусть $\mathsf{D}\eta > 0$. **Корреляционным отношением** (англ. *correlation ratio*) величины η по ξ называется

$$\nu^2(\eta \mid \xi) = \frac{\mathsf{D}\,\mathsf{E}(\eta \mid \xi)}{\mathsf{D}\eta}.$$

Традиционное обозначение этой величины — η^2, и оно здесь непригодно: буква η занята случайной величиной; поэтому пишем ν^2. Выборочный вариант величины изложен у [24], гл. 18 §11–13.

Величина ν^2 — доля дисперсии, снимаемая **наилучшим** прогнозом, тогда как r^2 — доля, снимаемая наилучшим *линейным* (следствие 6.2). Их разность и есть точная мера того, что теряет корреляционная теория: всегда $r^2 \le \nu^2 \le 1$, причём $\nu^2 = 1$ равносильно тому, что η есть функция от ξ почти наверное. Это предложение 13.1; оно вместе с доказательством

вынесено в раздел 13, а раздел 8 даёт пример, в котором разность равна единице: $r = 0$ при $\nu^2 = 1$.

7. Гауссовский вектор: когда двух моментов хватает

Определение 7.1 (гауссовский вектор)**.** Случайный вектор $\zeta \in \mathbb{R}^k$ называется **стандартным гауссовским**, если его компоненты независимы в совокупности и каждая имеет распределение $\mathcal{N}(0,1)$ с плотностью $(2\pi)^{-1/2} e^{-x^2/2}$. Вектор $\xi \in \mathbb{R}^n$ называется **гауссовским** (англ. *Gaussian vector*; он же нормальный), если он представим в виде

$$\xi = A\zeta + a$$

со стандартным гауссовским $\zeta \in \mathbb{R}^k$, постоянной матрицей A размера $n \times k$ и постоянным $a \in \mathbb{R}^n$. Пишут $\xi \sim \mathcal{N}(a, \Gamma)$, где $\Gamma = AA^{\mathsf{T}}$.

Обозначение согласовано: по теореме 5.1 у вектора $A\zeta + a$ действительно $\mathsf{E}\xi = a$ и $\Gamma_\xi = A\,I\,A^{\mathsf{T}} = AA^{\mathsf{T}}$. Определение через линейный образ, а не через плотность, взято у [06] (§21.1) сознательно: оно работает и в вырожденном случае, когда плотности нет, и сразу даёт замкнутость класса относительно линейных преобразований.

Предложение 7.2 (линейный образ гауссовского вектора гауссовский)**.** *Если ξ гауссовский, то и $B\xi + b$ гауссовский при любых постоянных B, b.*

Доказательство. $B(A\zeta + a) + b = (BA)\zeta + (Ba + b)$ — снова линейный образ стандартного гауссовского вектора ([06], теорема 21.1.1). □

Лемма 7.3 (характеристическая функция стандартного нормального закона)**.** *Если $\zeta_1 \sim \mathcal{N}(0,1)$, то $\mathsf{E}e^{it\zeta_1} = e^{-t^2/2}$ при всех $t \in \mathbb{R}$.*

Идея. Дифференцирование под знаком интеграла и интегрирование по частям дают $\varphi' = -t\varphi$, откуда $(\varphi e^{t^2/2})' = 0$. Выкладка — в разделе 12.6.

Теорема 7.4 (характеристическая функция гауссовского вектора)**.** *Если $\xi \sim \mathcal{N}(a, \Gamma)$, то при всех $t \in \mathbb{R}^n$*

$$\varphi_\xi(t) = \mathsf{E}e^{i\langle t, \xi\rangle} = \exp\Big\{ i\,\langle t, a\rangle - \tfrac{1}{2}\,\langle \Gamma t, t\rangle \Big\}. \tag{6}$$

Следовательно, распределение гауссовского вектора однозначно определяется парой (a, Γ).

Идея. У стандартного вектора характеристическая функция распадается в произведение одномерных (независимость компонент) и равна $e^{-\langle s,s\rangle/2}$ по лемме 7.3; подстановка $\xi = A\zeta + a$ переносит A^{T} на аргумент. Единственность распределения — теорема единственности из раздела 2. Выкладка — в разделе 12.7.

Теорема 7.5 (некоррелированность равносильна независимости)**.** *Пусть вектор (ξ, η) размерности $n + m$ гауссовский и $\Gamma_{\xi\eta} = 0$. Тогда ξ и η независимы. В частности, попарно некоррелированные компоненты гауссовского вектора независимы в совокупности.*

Идея. При $\Gamma_{\xi\eta} = 0$ характеристическая функция объединённого вектора распадается в произведение характеристических функций сомножителей, а то же произведение по теореме Фубини есть характеристическая функция произведения мер; дальше теорема единственности. Выкладка — в разделе 12.12.

Теорема 7.6 (плотность гауссовского вектора)**.** *Если $\xi \sim \mathcal{N}(a, \Gamma)$ и Γ невырождена, то ξ имеет плотность*

$$p(x) = \frac{1}{(2\pi)^{n/2}\sqrt{\det \Gamma}} \exp\Big\{-\tfrac{1}{2}(x-a)^{\intercal}\Gamma^{-1}(x-a)\Big\}. \tag{7}$$

При вырожденной Γ плотности нет: по теореме 5.7 вектор почти наверное лежит в аффинной плоскости меньшей размерности, а у такой плоскости мера Лебега нулевая.

Идея. Замена $x = \Gamma^{1/2}z + a$ в плотности стандартного вектора; якобиан равен $\sqrt{\det \Gamma}$. Выкладка — в разделе 12.9.

Форма показателя в (7) — это квадратичная форма из определения 5.9. Значит **линии уровня плотности гауссовского вектора суть эллипсоиды рассеяния**, и геометрия, построенная в разделе 5.3 из одних вторых моментов, в гауссовском случае оказывается геометрией самого распределения.

Теорема 7.7 (условное распределение гауссовского вектора)**.** *Пусть вектор (ξ, η), $\xi \in \mathbb{R}^n$, $\eta \in \mathbb{R}^m$, гауссовский и Γ_η невырождена. Тогда условное распределение ξ при $\eta = y$ гауссовское с параметрами*

$$\mathsf{E}\xi + \Gamma_{\xi\eta}\Gamma_\eta^{-1}(y - \mathsf{E}\eta), \qquad \Gamma_\xi - \Gamma_{\xi\eta}\Gamma_\eta^{-1}\Gamma_{\eta\xi}.$$

В частности,

$$\mathsf{E}(\xi \mid \eta) = \mathsf{E}\xi + \Gamma_{\xi\eta}\Gamma_\eta^{-1}(\eta - \mathsf{E}\eta),$$

то есть условное математическое ожидание линейно и совпадает с наилучшей линейной оценкой.

Идея. Подобрать матрицу B так, чтобы $\xi - B\eta$ не коррелировала с η; для гауссовской пары некоррелированность даёт независимость, и условное распределение ξ при η совпадает с безусловным у $\xi - B\eta$. Выкладка — в разделе 12.14.

Следствие 7.8 (в гауссовском случае корреляционная теория исчерпывающая)**.** *Пусть вектор (ξ, η) гауссовский и Γ_η невырождена. Тогда минимум $\mathsf{E}\,\|\xi - g(\eta)\|^2$ по всем борелевским $g\colon \mathbb{R}^m \to \mathbb{R}^n$ с конечным вторым моментом достигается на линейной функции из теоремы 6.4, и потому наилучший прогноз совпадает с наилучшим линейным. Для каждой компоненты это означает $\nu^2(\xi_k \mid \eta) = r_k^2$, где r_k — коэффициент корреляции ξ_k с её наилучшим линейным прогнозом.*

Идея. Минимум по всем борелевским функциям даёт условное математическое ожидание, а оно в гауссовском случае линейно; равенство $\nu^2 = r_k^2$ — прямой счёт через некоррелированность ошибки с данными. Выкладка — в разделе 12.10.

Это и есть оправдание корреляционной теории. В гауссовской модели пара (a, Γ) — полное описание: по ней восстанавливается распределение (теорема 7.4), независимость сводится к некоррелированности (теорема 7.5), а оптимальная обработка данных линейна (теорема 7.7). Вне гауссовской модели остаётся более слабое, но тоже полезное утверждение: корреляционная теория даёт **точный** ответ внутри класса линейных процедур, каким бы ни было распределение (теорема 6.4).

Отдельного внимания стоит то, что условная ковариация в теореме 7.7 от y не зависит. В негауссовском случае это неверно: точность прогноза может зависеть от того, что именно наблюдено, и корреляционная теория такой зависимости не видит в принципе — у неё нет для неё места.

8. Посылки: что ломается и как

8.1. Конечность вторых моментов

Вся корреляционная теория стоит на предположении $\mathsf{E}\xi_k^2 < \infty$. Оно не безобидно: у распределения Коши с плотностью $\frac{1}{\pi(1+x^2)}$ не существует даже математического ожидания, потому что $\int |x| \, \frac{dx}{\pi(1+x^2)}$ расходится логарифмически. Ковариация и коэффициент корреляции для такой пары **не определены** — не «равны чему-то неудобному», а не существуют.

Опасность здесь практическая. Выборочные формулы считаются по любым числам: они не спрашивают о существовании моментов и выдают числа. Но утверждать про эти числа нечего — закон больших чисел к ним неприменим, и сходиться им не к чему. Признак беды — неустойчивость при добавлении наблюдений, и мерить её надо на той величине, у которой момента нет: на **выборочной дисперсии**. Пример 2 ноутбука делает это прямо: отношение наибольшей выборочной дисперсии к наименьшей по пяти объёмам выборки от 10^3 до $2 \cdot 10^6$ равно $1{,}039$ для нормального закона и $5{,}2 \cdot 10^3$ для закона Коши, причём у второго значения не сглаживаются с ростом N, а прыгают.

Выборочный коэффициент корреляции этой неустойчивости не показывает, и это поучительно: он нормирован на выборочные уклонения, то есть студентизирован, и у независимых компонент прижимается к нулю даже при бесконечной дисперсии. Величина, которой мерят отсутствие момента, не должна сама от этого момента не зависеть.

8.2. Некоррелированность не влечёт независимости

Пример 8.1 (квадрат симметричной величины)**.** Пусть ξ равномерна на $[-1, 1]$ и $\eta = \xi^2$. Тогда

$$\mathsf{E}\xi = 0, \quad \mathsf{E}\xi^3 = 0, \quad \operatorname{cov}(\xi, \eta) = \mathsf{E}\xi^3 - \mathsf{E}\xi \, \mathsf{E}\xi^2 = 0,$$

то есть $r(\xi, \eta) = 0$: величины некоррелированы. При этом η есть функция от ξ, и прогноз по ξ восстанавливает η точно.

Посчитаем обе доли объяснённой дисперсии. По следствию 6.2 наилучший линейный прогноз снимает $r^2 = 0$ дисперсии — то есть не снимает ничего. По предложению 13.1 корреляционное отношение равно $\nu^2(\eta \mid \xi) = 1$, поскольку $\mathsf{E}(\eta \mid \xi) = \xi^2 = \eta$ почти наверное. Разрыв максимален: корреляционная теория не видит здесь ровно ничего, тогда как связь функциональная. Числа проверены в примере 2 ноутбука.

Пример 8.2 (гауссовская пара со случайным знаком)**.** Пусть $\xi \sim \mathcal{N}(0, 1)$, а s принимает значения ± 1 с вероятностью $1/2$ каждое и независима от ξ. Положим $\eta = s\xi$. Тогда

1. $\eta \sim \mathcal{N}(0, 1)$;
2. $\operatorname{cov}(\xi, \eta) = 0$;
3. ξ и η зависимы, ибо $|\xi| = |\eta|$ почти наверное;
4. вектор (ξ, η) **не** гауссовский.

Идея. Первый пункт — симметрия нормального закона, второй — независимость s и ξ при $\mathsf{E}s = 0$, третий — событие $\{|\xi| = |\eta|\}$ имеет у независимых непрерывных величин нулевую вероятность, четвёртый — следствие второго и третьего вместе с теоремой 7.5. Проверка — в разделе 12.13.

Пример 8.2 закрывает частый и естественный вопрос: **нормальность каждой компоненты не делает вектор гауссовским**, и потому эквивалентность «некоррелированность равносильна независимости» требует совместной гауссовости, а не покомпонентной. Другой пример того же — [62], пример 1.2.6: там берётся плотность, равная удвоенной стандартной гауссовской в первом и третьем квадрантах и нулю в остальных; обе её маргинальные плотности стандартные нормальные, а сама она гауссовской не является.

Ещё две посылки разобраны в разделе 17: невырожденность ковариационной матрицы, которую требуют теоремы 6.4, 7.6, 7.7 и 5.10, и то, что именно утверждает коэффициент корреляции — в частности, почему из него не следует причинная связь.

9. Приложение: оптимальная обработка измерений и шаг фильтра Калмана

9.1. Два датчика

Вернёмся к сквозному примеру (1). Ищем оценку вида $\widehat{\mu} = w\eta_1 + (1-w)\eta_2$: требование $\mathsf{E}\widehat{\mu} = \mu$ при любом μ вынуждает сумму весов равняться единице. По теореме 5.3

$$V(w) = \mathsf{D}\widehat{\mu} = w^2\sigma_1^2 + (1-w)^2\sigma_2^2 + 2w(1-w)\,r\,\sigma_1\sigma_2. \tag{8}$$

Предложение 9.1 (оптимальный вес и достижимая точность)**.** *Пусть $\sigma_1, \sigma_2 > 0$ и $\sigma_1^2 + \sigma_2^2 - 2r\sigma_1\sigma_2 > 0$. Тогда дисперсия $V(w) = \mathsf{D}(w\eta_1 + (1-w)\eta_2)$ достигает наименьшего значения в единственной точке*

$$w^* = \frac{\sigma_2^2 - r\sigma_1\sigma_2}{\sigma_1^2 + \sigma_2^2 - 2r\sigma_1\sigma_2} \tag{9}$$

и это наименьшее значение равно

$$V^* = \frac{\sigma_1^2\sigma_2^2\,(1-r^2)}{\sigma_1^2 + \sigma_2^2 - 2r\sigma_1\sigma_2}. \tag{10}$$

При этом $w^* < 0$ тогда и только тогда, когда $r > \sigma_2/\sigma_1$, и $w^* > 1$ тогда и только тогда, когда $r > \sigma_1/\sigma_2$.

Идея. V — квадратный трёхчлен по w с положительным старшим коэффициентом $\mathsf{D}(\varepsilon_1 - \varepsilon_2)$; приравнять производную нулю и подставить. Выкладка, включая проверку того, когда старший коэффициент обращается в нуль, — в разделе 12.11.

Из (10) читаются три содержательных вывода.

При $r = 0$ получаем $V^* = \sigma_1^2\sigma_2^2/(\sigma_1^2 + \sigma_2^2)$ — среднее гармоническое дисперсий, делённое пополам; веса обратно пропорциональны дисперсиям. Это привычный ответ, и именно он обычно и применяется.

При $\sigma_1 = \sigma_2 = \sigma$ вес равен $1/2$ при любом r, а $V^* = \sigma^2(1+r)/2$. Корреляция здесь только мешает: при $r \to 1$ выигрыш от второго прибора исчезает вовсе, при $r \to -1$ дисперсия стремится к нулю.

При $\sigma_1 \neq \sigma_2$ **и** $r \to 1$ знаменатель стремится к $(\sigma_1 - \sigma_2)^2 > 0$, а числитель к нулю, поэтому $V^* \to 0$: полностью коррелированный шум **вычитается**. Формально это случай теоремы 5.7: при $r = 1$ ковариационная матрица вырождена, погрешности связаны точным соотношением $\varepsilon_1/\sigma_1 = \varepsilon_2/\sigma_2$, и линейная комбинация $(\sigma_2\eta_1 - \sigma_1\eta_2)/(\sigma_2 - \sigma_1)$ равна μ тождественно. Именно на этом стоит дифференциальное измерение: второй прибор ставят не ради усреднения, а ради того, чтобы измерить общую помеху.

Наконец, знаковое условие $r > \sigma_2/\sigma_1$ означает, что при сильной корреляции оптимальный вес худшего прибора отрицателен: его показание входит в оценку **со знаком минус**. Правило «усреднить показания приборов», взятое без корреляционной теории, в этом режиме заведомо не оптимально. Числа — в примере 1 ноутбука.

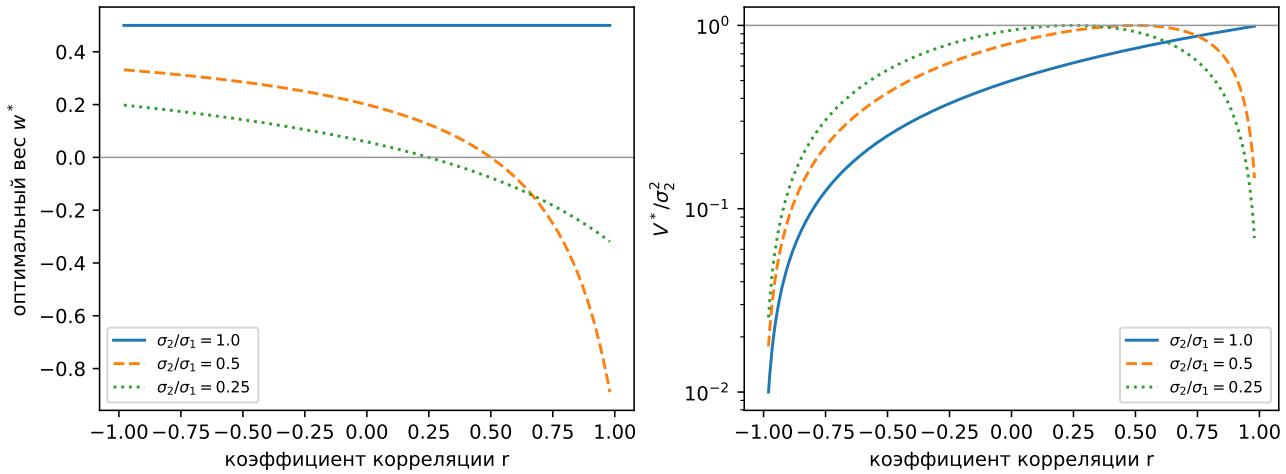


Рис. 2: Оптимальный вес w^* (слева) и дисперсия оптимальной комбинации, отнесённая к дисперсии лучшего прибора (справа), как функции коэффициента корреляции при трёх отношениях σ_2/σ_1. При равных дисперсиях (сплошная линия) вес не зависит от r, а выигрыш от второго прибора исчезает при $r \to 1$; при различных дисперсиях вес уходит в отрицательную область, а V^* падает к нулю. Построено в `examples.ipynb`, пример 1.

9.2. Общий случай: корректирующий шаг фильтра Калмана

Пусть теперь оценивается вектор $\xi \in \mathbb{R}^n$ (состояние), а наблюдается

$$\eta = H\xi + \varepsilon, \tag{11}$$

где H — постоянная матрица $m \times n$, погрешность ε имеет нулевое среднее, ковариационную матрицу Γ_ε и не коррелирована с ξ. Обозначим $P = \Gamma_\xi$. (В литературе по фильтрации ковариацию шума обозначают R; здесь эта буква занята корреляционной матрицей.)

Предложение 9.2 (калмановская поправка)**.** *В обозначениях* (11) *при невырожденной* $HPH^{\mathsf T} + \Gamma_\varepsilon$ *наилучшая линейная оценка* ξ *по* η *есть*

$$\hat\xi = \mathsf E\xi + K(\eta - H\,\mathsf E\xi), \qquad K = PH^{\mathsf T}\bigl(HPH^{\mathsf T} + \Gamma_\varepsilon\bigr)^{-1},$$

а ковариационная матрица её ошибки равна $(I - KH)P$.

Идея. Подставить $\Gamma_{\xi\eta} = PH^{\mathsf T}$ и $\Gamma_\eta = HPH^{\mathsf T} + \Gamma_\varepsilon$ в теорему 6.4. Выкладка — в разделе 12.15.

Это в точности корректирующий шаг фильтра Калмана, и важно, **чего в выводе не было**: ни одного предположения о виде распределений. Использованы только два момента. Поэтому фильтр Калмана есть объект корреляционной теории, и утверждение о нём такое: среди линейных оценок он оптимален всегда, а среди всех оценок — в гауссовском случае, по теореме 7.7.

Два датчика из раздела 9.1 — частный случай: там $n = 1$, $m = 2$, $H = (1,1)^{\mathsf T}$, а $P \to \infty$ (о μ заранее ничего не известно). Предельный переход при $P \to \infty$ в формуле поправки и даёт (9) — этот счёт вынесен в раздел 19.

10. Где корреляционная теория работает

Шесть задач, в каждой — что берётся из двух моментов и чего они не дают.

Объединение показаний нескольких приборов. Берутся оптимальные веса и достижимая точность (предложение 9.1); не даётся оптимальность вне линейного класса при негауссовском шуме.

Фильтрация состояния динамической системы. Берётся корректирующий шаг (предложение 9.2), не требующий вида распределений; не даётся то, что при негауссовском шуме существуют нелинейные оценки точнее.

Понижение размерности данных. Берутся главные оси и доля объяснённой дисперсии (теорема 5.8, предложение 14.1); не даётся независимость компонент — получается только некоррелированность.

Регрессия по методу наименьших квадратов. Берутся наилучший линейный прогноз и смысл r^2 (теорема 6.1); не даётся ни причинная связь, ни нелинейная зависимость.

Планирование эксперимента. Берётся обобщённая дисперсия $\det\Gamma$ как мера неопределённости (определение 5.9); не даётся выбор критерия — det, tr и $\lambda_{\max}$ дают разные планы.

Оценка риска суммы. Берутся дисперсия линейной комбинации (теорема 5.3) и роль ковариаций; не даётся поведение хвостов.

Последнее — самое важное, и его стоит проговорить отдельно. Два момента описывают разброс «в среднем»; про вероятность редкого большого уклонения они дают только неравенство Чебышёва (теорема 5.10), то есть оценку сверху порядка $1/c$, тогда как у лёгких хвостов настоящая вероятность экспоненциально мала. Разрыв между этими двумя ответами и есть граница применимости корреляционной теории в задачах о риске.

11. Разобранная задача: сквозной пример в числах

Ещё три задачи — на ковариационную матрицу линейного образа, на допустимость набора корреляций и на наилучший линейный прогноз — разобраны в разделе 18.

Задача 11.1 (два датчика с числами)**.** Два прибора измеряют одну величину с $\sigma_1 = 2$, $\sigma_2 = 1$ (в единицах измеряемой величины) и корреляцией погрешностей r. Найти оптимальный вес и достижимую дисперсию при $r = 0$, $r = 0{,}5$ и $r = 0{,}9$.

Решение. По формулам (9) и (10) с $\sigma_1 = 2$, $\sigma_2 = 1$: знаменатель $D = 5 - 4r$, числитель веса $1 - 2r$,

$$w^* = \frac{1 - 2r}{5 - 4r}, \qquad V^* = \frac{4(1 - r^2)}{5 - 4r}.$$

При $r = 0$: $w^* = 0{,}2$, $V^* = 0{,}8$ — знакомое правило обратных дисперсий ($\sigma_2^2/(\sigma_1^2+\sigma_2^2) = 1/5$). При $r = 0{,}5$: $w^* = 0$, $V^* = 1$ — худший прибор в оценку не входит вовсе, поскольку $r = \sigma_2/\sigma_1$ ровно на границе из предложения 9.1. При $r = 0{,}9$: $w^* = -0{,}8/1{,}4 = -0{,}571$, $V^* = 4 \cdot 0{,}19/1{,}4 = 0{,}543$ — вес отрицателен, а точность **лучше**, чем у лучшего прибора в одиночку ($\sigma_2^2 = 1$). Последнее и есть главный вывод раздела 9: сильная корреляция превращает худший прибор в измеритель общей помехи. Числа проверены в примере 1 ноутбука.

Часть II.
Расширенная часть

Сюда вынесено то, что в устный ответ не помещается: доказательства аппарата, приложения, стоящие не на главном утверждении вопроса, и вычислительная сторона. У каждого вынесенного доказательства в основной части осталась формулировка и абзац «идея», так что основная часть читается подряд.

12. Доказательства, вынесенные из основной части

12.1. Критерий измеримости по компонентам

Доказательство теоремы 3.2.

Доказательство. Необходимость. Проекция $\pi_k\colon \mathbb{R}^n \to \mathbb{R}$ непрерывна, значит борелевски измерима, а композиция измеримых отображений измерима: для $B \in \mathcal{B}$ имеем $\xi_k^{-1}(B) = \xi^{-1}(\pi_k^{-1}(B)) \in \mathcal{F}$, поскольку $\pi_k^{-1}(B) \in \mathcal{B}(\mathbb{R}^n)$.

Достаточность. Пусть все ξ_k измеримы. Рассмотрим класс

$$\mathcal{D} = \{B \subset \mathbb{R}^n \colon \xi^{-1}(B) \in \mathcal{F}\}.$$

Прообраз перестановочен с дополнением и со счётным объединением, поэтому $\mathcal{D}$ — σ-алгебра. Для параллелепипеда $\Pi = (-\infty, x_1] \times \dots \times (-\infty, x_n]$ имеем

$$\xi^{-1}(\Pi) = \bigcap_{k=1}^{n} \{\xi_k \le x_k\} \in \mathcal{F},$$

то есть $\mathcal{D}$ содержит все параллелепипеды вида Π. Они порождают $\mathcal{B}(\mathbb{R}^n)$: всякое открытое множество в $\mathbb{R}^n$ есть счётное объединение открытых параллелепипедов с рациональными вершинами, открытый параллелепипед есть счётное возрастающее объединение полузамкнутых $\prod_k (\alpha_k, \beta_k]$, а каждый такой выражается через 2^n параллелепипедов вида Π по формуле включений-исключений: его индикатор равен $\sum_{\tau \in \{0,1\}^n} (-1)^{|\tau|} \mathbb{1}_{\Pi(\tau)}$, где $\Pi(\tau)$ — параллелепипед вида Π с k-й границей β_k при $\tau_k = 0$ и α_k при $\tau_k = 1$, а $|\tau| = \sum_k \tau_k$. При $n = 1$ это привычная разность двух лучей. Значит $\mathcal{D} \supset \mathcal{B}(\mathbb{R}^n)$, что и требовалось. $\square$

12.2. Обратная теорема о функции распределения

Доказательство теоремы 3.3.

Доказательство. Прямая часть. При $x \le y$ событие $\{\xi \le x\}$ содержится в $\{\xi \le y\}$, откуда монотонность. Далее, события $\{\xi \le x\}$ при $x \uparrow +\infty$ по целым x возрастают к Ω, а при $x \downarrow -\infty$ убывают к пустому множеству; по непрерывности меры пределы равны 1 и 0, а монотонность F превращает предел по целой последовательности в предел по непрерывному аргументу. Непрерывность справа: при $x_j \downarrow x$ события $\{\xi \le x_j\}$ убывают, и их пересечение равно $\{\xi \le x\}$, откуда $F(x_j) \to F(x)$.

Обратная часть. Возьмём $\Omega = (0,1)$, $\mathcal{F} = \mathcal{B} \cap (0,1)$, P — меру Лебега, и положим

$$\xi(u) = F^{-}(u) = \inf\{x \in \mathbb{R} \colon F(x) \ge u\}, \qquad u \in (0,1). \tag{12}$$

Множество $A_u = \{x \colon F(x) \ge u\}$ непусто (иначе $F(x) < u < 1$ при всех x, что противоречит свойству 2) и ограничено снизу (иначе $F(x) \ge u > 0$ при сколь угодно малых x), так что нижняя грань конечна.

Проверим ключевое равносильное соотношение

$$F^{-}(u) \le x \iff u \le F(x). \tag{13}$$

Если $u \le F(x)$, то $x \in A_u$ и потому $F^{-}(u) \le x$. Обратно, пусть $F^{-}(u) \le x$. Множество A_u вместе с точкой содержит луч вправо (свойство 1) и содержит свою нижнюю грань $c = F^{-}(u)$: беря $x_j \downarrow c$ с $x_j \in A_u$, получаем $F(c) = \lim F(x_j) \ge u$ по непрерывности справа. Значит $F(c) \ge u$, а из $c \le x$ и монотонности $F(x) \ge F(c) \ge u$.

Из (13) следует

$$\mathsf{P}\{\xi \le x\} = \mathsf{P}\{u \in (0,1) \colon u \le F(x)\} = F(x),$$

поскольку мера Лебега интервала $(0, F(x)] \cap (0,1)$ равна $F(x)$. Измеримость ξ вытекает из того же соотношения: прообраз луча $(-\infty, x]$ есть промежуток. Итак, F — функция распределения величины ξ. □

Замечание 12.1 (метод обратной функции). Равенство (12) — это и есть рецепт моделирования: если u разыграно равномерно на $(0,1)$, то $F^-(u)$ имеет заданное распределение F. Доказательство обратной части теоремы 3.3 и есть обоснование метода обратной функции, на котором стоит вся техника разыгрывания распределений в методе Монте-Карло. Особо отметим, что непрерывность и строгая монотонность F не нужны: определение через нижнюю грань работает и для дискретных законов, где обычная обратная функция не существует.

12.3. Мультипликативность математического ожидания

Доказательство предложения 4.4.

Доказательство. Совместное распределение независимых величин есть произведение распределений, поэтому для неотрицательных борелевских функций $\mathsf{E}\prod_j |u_j(\xi_j)| = \prod_j \mathsf{E}\,|u_j(\xi_j)| < \infty$ — это половина Тонелли, предположения интегрируемости не требующая, и она как раз интегрируемость и устанавливает. Теперь, когда интеграл от модуля конечен, половина Фубини позволяет в той же выкладке убрать модули. Для комплекснозначных u_j рассуждение применяется почленно к произведениям вещественных и мнимых частей: их конечное число, и каждое подпадает под вещественный случай.

Второе утверждение — частный случай при $k = 2$, $u_1(x) = x$, $u_2(y) = y$: конечность $\mathsf{E}\,|\xi\eta|$ отмечена после определения 3.6, $\mathsf{E}\xi\eta = \mathsf{E}\xi\,\mathsf{E}\eta$, остаётся вычесть. □

12.4. Многомерное неравенство Чебышёва

Доказательство теоремы 5.10.

Доказательство. Сперва неравенство Маркова: для неотрицательной величины ϱ с конечным математическим ожиданием и $c > 0$

$$\mathsf{E}\varrho \geq \mathsf{E}\bigl(\varrho\,\mathbb{1}\{\varrho \geq c\}\bigr) \geq c\,\mathsf{P}\{\varrho \geq c\}.$$

Применим его к $\varrho = (\xi - a)^{\mathsf{T}}\Gamma^{-1}(\xi - a)$. Эта величина неотрицательна, поскольку Γ^{-1} неотрицательно определена вместе с Γ. Её математическое ожидание вычисляется через след: число равно следу матрицы 1×1, а след перестановочен с циклической перестановкой сомножителей, поэтому

$$\varrho = \operatorname{tr}\bigl(\Gamma^{-1}(\xi - a)(\xi - a)^{\mathsf{T}}\bigr),$$

и по линейности (предложение 3.10) и перестановочности следа с математическим ожиданием

$$\mathsf{E}\varrho = \operatorname{tr}\bigl(\Gamma^{-1}\mathsf{E}(\xi - a)(\xi - a)^{\mathsf{T}}\bigr) = \operatorname{tr}(\Gamma^{-1}\Gamma) = \operatorname{tr} I = n.$$

Подстановка в неравенство Маркова даёт требуемое. □

12.5. Точное значение вероятности выхода за эллипсоид

Здесь выведено число, на котором стоит замечание 5.11: для двумерного нормального закона вероятность выйти за эллипс уровня c равна $e^{-c/2}$.

По теореме 7.4 распределение гауссовского вектора определяется парой (a, Γ), поэтому можно взять $\xi = \Gamma^{1/2}\zeta + a$ со стандартным гауссовским ζ; тогда

$$\varrho = (\xi - a)^{\mathsf{T}}\Gamma^{-1}(\xi - a) = \zeta^{\mathsf{T}}\Gamma^{1/2}\Gamma^{-1}\Gamma^{1/2}\zeta = \zeta_1^2 + \zeta_2^2,$$

а переход к полярным координатам в плотности стандартного вектора даёт

$$\mathsf{P}\{\varrho \geq c\} = \frac{1}{2\pi} \iint_{z_1^2+z_2^2 \geq c} e^{-(z_1^2+z_2^2)/2}\, dz = \int_{\sqrt{c}}^{\infty} v\, e^{-v^2/2}\, dv = e^{-c/2},$$

где v — полярный радиус.

12.6. Характеристическая функция нормального закона

Доказательство леммы 7.3.

Доказательство. Положим $\varphi(t) = \mathsf{E}e^{it\zeta_1} = \frac{1}{\sqrt{2\pi}} \int_{\mathbb{R}} e^{itx} e^{-x^2/2}\, dx$. Подынтегральная функция по t дифференцируема, её производная по модулю не превосходит $|x|\, e^{-x^2/2}$ — интегрируемой мажоранты, не зависящей от t, — поэтому дифференцирование под знаком интеграла законно:

$$\varphi'(t) = \frac{1}{\sqrt{2\pi}} \int_{\mathbb{R}} ix\, e^{itx} e^{-x^2/2}\, dx.$$

Заметив, что $xe^{-x^2/2} = -\bigl(e^{-x^2/2}\bigr)'$, интегрируем по частям (внеинтегральный член исчезает, так как $e^{-x^2/2} \to 0$ на бесконечности):

$$\varphi'(t) = \frac{i}{\sqrt{2\pi}} \int_{\mathbb{R}} e^{itx}\, d\bigl(-e^{-x^2/2}\bigr) = \frac{i}{\sqrt{2\pi}} \int_{\mathbb{R}} it\, e^{itx} e^{-x^2/2}\, dx = -t\, \varphi(t).$$

Значит $\bigl(\varphi(t)e^{t^2/2}\bigr)' = e^{t^2/2}(\varphi'(t) + t\varphi(t)) = 0$, то есть $\varphi(t)e^{t^2/2}$ постоянно и равно своему значению в нуле: $\varphi(0) = 1$ ввиду $\int_{\mathbb{R}} e^{-x^2/2}\, dx = \sqrt{2\pi}$. Отсюда $\varphi(t) = e^{-t^2/2}$. □

12.7. Характеристическая функция гауссовского вектора

Доказательство теоремы 7.4.

Доказательство. Пусть $\xi = A\zeta + a$. Сперва вычислим характеристическую функцию стандартного вектора $\zeta \in \mathbb{R}^k$: по независимости компонент и мультипликативности математического ожидания (предложение 4.4 в его версии для комплекснозначных функций от независимых величин, получаемой той же теоремой Фубини)

$$\mathsf{E}e^{i\langle s,\zeta\rangle} = \mathsf{E}\prod_{j=1}^{k} e^{is_j\zeta_j} = \prod_{j=1}^{k} \mathsf{E}e^{is_j\zeta_j} = \prod_{j=1}^{k} e^{-s_j^2/2} = e^{-\langle s,s\rangle/2},$$

где использована лемма 7.3. Теперь

$$\varphi_\xi(t) = \mathsf{E}e^{i\langle t, A\zeta+a\rangle} = e^{i\langle t,a\rangle}\, \mathsf{E}e^{i\langle A^{\mathsf{T}}t,\zeta\rangle} = e^{i\langle t,a\rangle} \exp\Bigl\{-\tfrac{1}{2}\,\langle A^{\mathsf{T}}t, A^{\mathsf{T}}t\rangle\Bigr\} = e^{i\langle t,a\rangle} \exp\Bigl\{-\tfrac{1}{2}\,\langle AA^{\mathsf{T}}t, t\rangle\Bigr\},$$

что и есть (6) ввиду $\Gamma = AA^{\mathsf{T}}$. Последнее утверждение — теорема единственности для характеристических функций на $\mathbb{R}^n$ (раздел 2; [06], теорема 21.1.2 и следствие после теоремы 21.1.4). □

12.8. Закон полной дисперсии

Доказательство следствия 6.7.

Доказательство. Пишем $\xi - \mathsf{E}\xi = (\xi - \widehat{\xi}) + (\widehat{\xi} - \mathsf{E}\xi)$, где $\widehat{\xi} = \mathsf{E}(\xi \mid \mathcal{G})$. Второе слагаемое $\mathcal{G}$-измеримо, и по доказанной в теореме 6.6 ортогональности перекрёстное слагаемое обращается в нуль:

$$\mathsf{D}\xi = \mathsf{E}(\xi - \widehat{\xi})^2 + \mathsf{E}(\widehat{\xi} - \mathsf{E}\xi)^2.$$

Второе слагаемое есть $\mathsf{D}\widehat{\xi}$, поскольку $\mathsf{E}\widehat{\xi} = \mathsf{E}\xi$. Первое преобразуем, вставив условное математическое ожидание:

$$\mathsf{E}(\xi - \widehat{\xi})^2 = \mathsf{E}\Big[\mathsf{E}((\xi - \widehat{\xi})^2 \mid \mathcal{G})\Big] = \mathsf{E}\Big[\mathsf{E}(\xi^2 \mid \mathcal{G}) - 2\widehat{\xi}\,\mathsf{E}(\xi \mid \mathcal{G}) + \widehat{\xi}^{\,2}\Big] = \mathsf{E}\,\mathsf{D}(\xi \mid \mathcal{G}),$$

где снова использовано вынесение $\mathcal{G}$-измеримого множителя. □

12.9. Плотность гауссовского вектора

Доказательство теоремы 7.6.

Доказательство. Представим $\xi = \Gamma^{1/2}\zeta + a$ (такое представление годится: по теореме 7.4 характеристическая функция зависит только от (a, Γ), а у $\Gamma^{1/2}\zeta + a$ ровно эти параметры). Матрица $\Gamma^{1/2}$ невырождена вместе с Γ, значит замена $x = \Gamma^{1/2}z + a$ — диффеоморфизм $\mathbb{R}^n$ на себя с якобианом $\det \Gamma^{1/2} = \sqrt{\det \Gamma}$. Плотность стандартного вектора есть $(2\pi)^{-n/2}e^{-\langle z,z\rangle/2}$ (произведение одномерных плотностей), поэтому для борелевского B

$$\mathsf{P}\{\xi \in B\} = \mathsf{P}\{\zeta \in \Gamma^{-1/2}(B - a)\} = \int_{\Gamma^{-1/2}(B-a)} \frac{e^{-\langle z,z\rangle/2}}{(2\pi)^{n/2}}\, dz.$$

Подстановка $z = \Gamma^{-1/2}(x - a)$ даёт $dz = dx/\sqrt{\det \Gamma}$ и

$$\langle z, z\rangle = (x-a)^{\mathsf{T}}\Gamma^{-1/2}\Gamma^{-1/2}(x-a) = (x-a)^{\mathsf{T}}\Gamma^{-1}(x-a),$$

откуда и получается (7). □

12.10. В гауссовском случае корреляционная теория исчерпывающая

Доказательство следствия 7.8.

Доказательство. По теореме 6.6, применённой покомпонентно с $\mathcal{G} = \sigma(\eta)$, минимум по $\sigma(\eta)$-измеримым величинам достигается на $\mathsf{E}(\xi \mid \eta)$; по лемме Дуба — Дынкина (раздел 2) эта величина сама есть борелевская функция от η, так что и минимум по борелевским g достигается на ней. По теореме 7.7 она линейна по η и совпадает с $\widehat{\xi} = \mathsf{E}\xi + B^*(\eta - \mathsf{E}\eta)$.

Равенство $\nu^2(\xi_k \mid \eta) = r_k^2$ проверяется счётом. Обозначим $e = \xi - \widehat{\xi}$; в доказательстве теоремы 6.4 установлено $\mathsf{E}e(\eta - \mathsf{E}\eta)^{\mathsf{T}} = 0$, а $\widehat{\xi}_k - \mathsf{E}\xi_k$ есть линейная функция от $\eta - \mathsf{E}\eta$, поэтому $\operatorname{cov}(e_k, \widehat{\xi}_k) = 0$. Отсюда

$$\operatorname{cov}(\xi_k, \widehat{\xi}_k) = \operatorname{cov}(\widehat{\xi}_k + e_k, \widehat{\xi}_k) = \mathsf{D}\widehat{\xi}_k,$$

и (при $\mathsf{D}\widehat{\xi}_k > 0$)

$$r_k = \frac{\operatorname{cov}(\xi_k, \widehat{\xi}_k)}{\sigma_{\xi_k}\sigma_{\widehat{\xi}_k}} = \frac{\sigma_{\widehat{\xi}_k}}{\sigma_{\xi_k}}, \qquad r_k^2 = \frac{\mathsf{D}\widehat{\xi}_k}{\mathsf{D}\xi_k} = \frac{\mathsf{D}\mathsf{E}(\xi_k \mid \eta)}{\mathsf{D}\xi_k} = \nu^2(\xi_k \mid \eta).$$

При $\mathsf{D}\widehat{\xi}_k = 0$ прогноз тривиален: $\nu^2(\xi_k \mid \eta) = 0$, а r_k не определён — как и в определении 3.6, требующем положительных уклонений. □

12.11. Оптимальный вес при двух датчиках

Доказательство предложения 9.1.

Доказательство. Функция V — квадратный трёхчлен от w со старшим коэффициентом $\sigma_1^2 + \sigma_2^2 - 2r\sigma_1\sigma_2$, положительным по условию. Он равен $\mathsf{D}(\varepsilon_1 - \varepsilon_2)$ и обращается в нуль ровно при $r = 1$ и $\sigma_1 = \sigma_2$. Действительно,

$$\sigma_1^2 + \sigma_2^2 - 2r\sigma_1\sigma_2 = (\sigma_1 - \sigma_2)^2 + 2(1 - r)\sigma_1\sigma_2,$$

и оба слагаемых неотрицательны при $|r| \le 1$, так что сумма равна нулю только когда $\sigma_1 = \sigma_2$ и $r = 1$ одновременно. Производная

$$V'(w) = 2w\sigma_1^2 - 2(1 - w)\sigma_2^2 + 2(1 - 2w)\, r\sigma_1\sigma_2$$

обращается в нуль ровно при $w = w^*$ из (9). Подстановка и приведение подобных дают (10); выкладка короче, если заметить, что

$$V^* = \sigma_2^2 - \frac{(\sigma_2^2 - r\sigma_1\sigma_2)^2}{\sigma_1^2 + \sigma_2^2 - 2r\sigma_1\sigma_2},$$

и привести к общему знаменателю: числитель равен $\sigma_2^2(\sigma_1^2 + \sigma_2^2 - 2r\sigma_1\sigma_2) - \sigma_2^2(\sigma_2 - r\sigma_1)^2 = \sigma_1^2\sigma_2^2(1 - r^2)$. Знаки: знаменатель в (9) положителен, поэтому знак w^* есть знак $\sigma_2(\sigma_2 - r\sigma_1)$, а $w^* - 1$ имеет знак $\sigma_1(\sigma_1 - r\sigma_2)$ с обратным знаком, то есть $\sigma_1(r\sigma_2 - \sigma_1)$. $\square$

12.12. Некоррелированность и независимость в гауссовском случае

Доказательство теоремы 7.5.

Доказательство. Обозначим через Γ ковариационную матрицу объединённого вектора; при $\Gamma_{\xi\eta} = 0$ она блочно-диагональна, $\Gamma = \operatorname{diag}(\Gamma_\xi, \Gamma_\eta)$ в блочном смысле. Для $t = (t_1, t_2)$, $t_1 \in \mathbb{R}^n$, $t_2 \in \mathbb{R}^m$, по теореме 7.4

$$\varphi_{(\xi,\eta)}(t_1, t_2) = \exp\Big\{ i\,\langle t_1, \mathsf{E}\xi\rangle + i\,\langle t_2, \mathsf{E}\eta\rangle - \tfrac12\,\langle \Gamma_\xi t_1, t_1\rangle - \tfrac12\,\langle \Gamma_\eta t_2, t_2\rangle \Big\} = \varphi_\xi(t_1)\,\varphi_\eta(t_2),$$

причём φ_ξ и φ_η — характеристические функции самих ξ и η (они получаются из формулы при $t_2 = 0$ и $t_1 = 0$ соответственно; заодно видно, что ξ и η сами гауссовские). С другой стороны, произведение $\varphi_\xi(t_1)\varphi_\eta(t_2)$ есть, по теореме Фубини, характеристическая функция произведения мер $F_\xi \otimes F_\eta$. Итак, у распределения $F_{(\xi,\eta)}$ и у меры $F_\xi \otimes F_\eta$ характеристические функции совпадают; по теореме единственности совпадают и сами меры, а это и есть независимость. Случай попарно некоррелированных компонент разбирается так же: там Γ диагональна и характеристическая функция распадается в произведение n сомножителей ([06], теорема 21.1.6). $\square$

12.13. Гауссовская пара со случайным знаком

Проверка четырёх пунктов примера 8.2.

Доказательство. Пункт 1: по формуле полной вероятности и симметрии нормального закона (из $\mathsf{P}\{-\xi \le x\} = \mathsf{P}\{\xi \ge -x\} = \mathsf{P}\{\xi \le x\}$)

$$\mathsf{P}\{s\xi \le x\} = \tfrac12\mathsf{P}\{\xi \le x\} + \tfrac12\mathsf{P}\{-\xi \le x\} = \mathsf{P}\{\xi \le x\}.$$

Пункт 2: $\operatorname{cov}(\xi, \eta) = \mathsf{E}(s\xi^2) = \mathsf{E}s \cdot \mathsf{E}\xi^2 = 0$ по независимости s и ξ и ввиду $\mathsf{E}s = 0$. Пункт 3: событие $\{|\xi| = |\eta|\}$ имеет вероятность 1, а у независимых величин с непрерывными распределениями его вероятность была бы нулевой (по теореме Фубини мера множества

$\{|x| = |y|\}$ относительно произведения непрерывных распределений равна нулю). Пункт 4: если бы вектор был гауссовским, то из пункта 2 по теореме 7.5 следовала бы независимость, противоречащая пункту 3. □

12.14. Условное распределение гауссовского вектора

Доказательство теоремы 7.7.

Доказательство. Положим $B^* = \Gamma_{\xi\eta}\Gamma_\eta^{-1}$ и $e = \xi - \mathsf{E}\xi - B^*(\eta - \mathsf{E}\eta)$. Объединённый вектор (e, η) получается из (ξ, η) линейным преобразованием, значит гауссовский (предложение 7.2). В доказательстве теоремы 6.4 установлено $\Gamma_{e\eta} = \mathsf{E}e(\eta - \mathsf{E}\eta)^{\mathsf{T}} = 0$, поэтому по теореме 7.5 векторы e и η независимы; при этом e гауссовский со средним нуль и ковариационной матрицей $\Gamma_{\text{err}} = \Gamma_\xi - \Gamma_{\xi\eta}\Gamma_\eta^{-1}\Gamma_{\eta\xi}$.

Теперь $\xi = \mathsf{E}\xi + B^*(\eta - \mathsf{E}\eta) + e$, где первое и второе слагаемые $\sigma(\eta)$-измеримы, а e от η не зависит. Для борелевского $C \subset \mathbb{R}^n$ и борелевского $D \subset \mathbb{R}^m$

$$\mathsf{P}\{\xi \in C,\ \eta \in D\} = \int_D \mathsf{P}\bigl\{e \in C - \mathsf{E}\xi - B^*(y - \mathsf{E}\eta)\bigr\}\, F_\eta(dy),$$

что и означает, что условное распределение ξ при $\eta = y$ есть сдвиг распределения e на вектор $\mathsf{E}\xi + B^*(y - \mathsf{E}\eta)$, то есть гауссовское с заявленными параметрами. Равенство для условного математического ожидания получается интегрированием: $\mathsf{E}(\xi \mid \eta) = \mathsf{E}\xi + B^*(\eta - \mathsf{E}\eta) + \mathsf{E}(e \mid \eta)$, а $\mathsf{E}(e \mid \eta) = \mathsf{E}e = 0$ по независимости. □

12.15. Калмановская поправка

Доказательство предложения 9.2.

Доказательство. По теореме 5.1 и некоррелированности ε с ξ

$$\Gamma_{\xi\eta} = \mathsf{E}(\xi - \mathsf{E}\xi)(H(\xi - \mathsf{E}\xi) + \varepsilon - \mathsf{E}\varepsilon)^{\mathsf{T}} = PH^{\mathsf{T}},$$

$$\Gamma_\eta = \mathsf{E}\bigl(H(\xi - \mathsf{E}\xi) + \varepsilon^\circ\bigr)(\cdots)^{\mathsf{T}} = HPH^{\mathsf{T}} + \Gamma_\varepsilon.$$

Подстановка в теорему 6.4 даёт $B^* = PH^{\mathsf{T}}(HPH^{\mathsf{T}} + \Gamma_\varepsilon)^{-1} = K$ и

$$\Gamma_{\text{err}} = P - PH^{\mathsf{T}}(HPH^{\mathsf{T}} + \Gamma_\varepsilon)^{-1}HP = P - KHP = (I - KH)P.$$

□

13. Корреляционное отношение: оценка сверху и снизу

Определение 6.8 дано в основной части; здесь доказано, что корреляционное отношение зажато между r^2 и единицей, и разобраны оба крайних значения. На это опирается разбор примера 8.1 в разделе 8.2.

Предложение 13.1 (корреляционное отношение не меньше квадрата корреляции)**.** *При* $\mathsf{D}\xi > 0$, $\mathsf{D}\eta > 0$

$$r^2(\xi, \eta) \le \nu^2(\eta \mid \xi) \le 1,$$

причём $\nu^2(\eta \mid \xi) = 0$ *равносильно тому, что* $\mathsf{E}(\eta \mid \xi)$ *постоянно почти наверное, а* $\nu^2(\eta \mid \xi) = 1$ *— тому, что* η *есть функция от* ξ *почти наверное.*

Доказательство. По закону полной дисперсии (следствие 6.7) с $\mathcal{G} = \sigma(\xi)$

$$\mathsf{E}\big(\eta - \mathsf{E}(\eta \mid \xi)\big)^2 = \mathsf{E}\,\mathsf{D}(\eta \mid \xi) = \mathsf{D}\eta - \mathsf{D}\,\mathsf{E}(\eta \mid \xi) = \mathsf{D}\eta\,(1 - \nu^2).$$

С другой стороны, всякая линейная функция $b\xi + c$ является $\sigma(\xi)$-измеримой величиной с конечным вторым моментом, поэтому по теореме 6.6 минимум по всем таким величинам не превосходит минимума по линейным, вычисленного в теореме 6.1:

$$\mathsf{D}\eta\,(1 - \nu^2) \le \mathsf{D}\eta\,(1 - r^2),$$

откуда $\nu^2 \ge r^2$. Неравенство $\nu^2 \le 1$ следует из неотрицательности левой части. Разберём крайние значения. Равенство $\nu^2 = 1$ означает $\mathsf{E}(\eta - \mathsf{E}(\eta \mid \xi))^2 = 0$, то есть $\eta = \mathsf{E}(\eta \mid \xi)$ почти наверное; величина $\mathsf{E}(\eta \mid \xi)$ $\sigma(\xi)$-измерима и потому по лемме Дуба — Дынкина (раздел 2) есть борелевская функция от ξ. Обратно, пусть $\eta = f(\xi)$ почти наверное при борелевской f и $\mathsf{E}\eta^2 < \infty$. Тогда η сама $\sigma(\xi)$-измерима, а условное математическое ожидание $\sigma(\xi)$-измеримой величины равно ей самой (она удовлетворяет определяющему равенству), поэтому $\mathsf{E}(\eta \mid \xi) = \eta$ почти наверное, $\mathsf{DE}(\eta \mid \xi) = \mathsf{D}\eta$ и $\nu^2 = 1$. Наконец, $\nu^2 = 0$ означает $\mathsf{DE}(\eta \mid \xi) = 0$, то есть постоянство $\mathsf{E}(\eta \mid \xi)$ почти наверное. □

Крайние значения и стоит запомнить: $\nu^2 = 0$ означает, что наблюдение ξ не меняет прогноза вовсе, а $\nu^2 = 1$ — что η восстанавливается по ξ точно. Второе и отличает корреляционное отношение от r^2: единицы оно достигает на любой функциональной зависимости, а не только на линейной.

14. Приложение: главные компоненты

Теорема 5.8 — готовая постановка метода главных компонент. Задача: заменить n коррелированных координат меньшим числом некоррелированных так, чтобы потерять как можно меньше суммарной дисперсии.

Предложение 14.1 (оптимальность первых главных компонент)**.** *Пусть $\Gamma = Q\Lambda Q^{\mathsf{T}}$ — спектральное разложение ковариационной матрицы, $\lambda_1 \ge \ldots \ge \lambda_n \ge 0$, и пусть $\mathcal{L}$ — линейное подпространство $\mathbb{R}^n$ размерности k, $\Pi_{\mathcal{L}}$ — ортогональный проектор на него. Тогда*

$$\max_{\dim \mathcal{L} = k} \mathsf{E}\,\big\|\Pi_{\mathcal{L}}(\xi - a)\big\|^2 = \lambda_1 + \cdots + \lambda_k,$$

и максимум достигается на $\mathcal{L} = \operatorname{span}(q_1, \ldots, q_k)$.

Доказательство. Пусть $u_1, \ldots, u_k$ — ортонормированный базис $\mathcal{L}$. Тогда $\big\|\Pi_{\mathcal{L}}(\xi - a)\big\|^2 = \sum_{i=1}^k \langle u_i, \xi - a\rangle^2$, и по теореме 5.3

$$\mathsf{E}\,\big\|\Pi_{\mathcal{L}}(\xi - a)\big\|^2 = \sum_{i=1}^k u_i^{\mathsf{T}}\Gamma u_i = \operatorname{tr}(U^{\mathsf{T}}\Gamma U),$$

где $U = [u_1, \ldots, u_k]$ — матрица с ортонормированными столбцами. Разложим $u_i = \sum_j c_{ij} q_j$; тогда $\operatorname{tr}(U^{\mathsf{T}}\Gamma U) = \sum_j \lambda_j \beta_j$, где $\beta_j = \sum_{i=1}^k c_{ij}^2$. Числа β_j удовлетворяют $0 \le \beta_j \le 1$ (это квадрат нормы проекции q_j на $\mathcal{L}$) и $\sum_j \beta_j = k$ (сумма квадратов норм столбцов U в базисе Q). Отсюда

$$\sum_{j=1}^n \lambda_j\beta_j - \sum_{j\le k}\lambda_j = \sum_{j\le k}\lambda_j(\beta_j - 1) + \sum_{j>k}\lambda_j\beta_j \le \lambda_k \sum_{j\le k}(\beta_j - 1) + \lambda_k \sum_{j>k}\beta_j = \lambda_k\Big(\sum_j \beta_j - k\Big) = 0,$$

где первое неравенство использует $\lambda_j \geq \lambda_k$ при $j \leq k$ вместе с $\beta_j - 1 \leq 0$ и $\lambda_j \leq \lambda_k$ при $j > k$ вместе с $\beta_j \geq 0$. Значит $\sum_j \lambda_j \beta_j \leq \lambda_1 + \dots + \lambda_k$, и равенство достигается при $\beta_1 = \dots = \beta_k = 1$, остальные нули. Это и есть $\mathcal{L} = \operatorname{span}(q_1, \dots, q_k)$, максимум равен $\lambda_1 + \dots + \lambda_k$. $\square$

Величина $(\lambda_1 + \dots + \lambda_k)/\operatorname{tr}\Gamma$ называется долей объяснённой дисперсии; она и служит правилом выбора k. Существенно, что весь вывод опирается только на два момента: метод главных компонент — процедура корреляционной теории.

Не менее существенно, чего метод не даёт. Он делает компоненты **некоррелированными**, а не независимыми, и по примеру 8.1 это разные вещи. Поиск действительно независимых компонент — другая задача (метод независимых компонент), и в ней двух моментов уже не хватает: по теореме 7.5 в гауссовском случае некоррелированность и есть независимость, поэтому нетривиальной задача становится только в негауссовском случае, где работают моменты выше второго.

15. Приложение: корреляционная теория случайных процессов

Термин «корреляционная теория» чаще всего встречается именно в теории случайных процессов, и стоит увидеть, что это та же теория и те же теоремы.

Определение 15.1 (характеристики случайного процесса)**.** Пусть $\{X(t),\ t \in T\}$ — семейство случайных величин с $\mathsf{E}X^2(t) < \infty$. **Математическим ожиданием** процесса называется функция $m_X(t) = \mathsf{E}X(t)$, **корреляционной функцией** (англ. *autocovariance*) — функция двух переменных

$$K_X(t_1, t_2) = \operatorname{cov}(X(t_1), X(t_2)) = \mathsf{E}\big(X(t_1) - m_X(t_1)\big)\big(X(t_2) - m_X(t_2)\big).$$

Процесс называется **стационарным в широком смысле**, если $m_X(t)$ постоянно, а $K_X(t_1, t_2)$ зависит только от разности $\tau = t_2 - t_1$; тогда пишут $K_X(\tau)$.

При $t_1 = t_2$ корреляционная функция даёт дисперсию сечения: $K_X(t, t) = \mathsf{D}X(t)$ ([24], гл. 23 §9).

Предложение 15.2 (неотрицательная определённость корреляционной функции)**.** *Для любого $l \in \mathbb{N}$, любых $t_1, \dots, t_l \in T$ и любых $c_1, \dots, c_l \in \mathbb{R}$*

$$\sum_{k,j=1}^{l} c_k c_j \, K_X(t_k, t_j) \geq 0.$$

Доказательство. Рассмотрим случайный вектор $\big(X(t_1), \dots, X(t_l)\big)$: его ковариационная матрица есть $[K_X(t_k, t_j)]$, и утверждение — это пункт 1 теоремы 5.5, то есть неотрицательная определённость ковариационной матрицы. $\square$

Предложение 15.2 показывает, что корреляционная теория процессов есть корреляционная теория векторов, применённая ко всем конечным наборам сечений сразу. Обратное утверждение — что всякая симметричная неотрицательно определённая функция двух переменных является корреляционной функцией некоторого процесса — из теоремы 5.5 получается только для **конечного** множества T: там вектор строится прямо по ней. Для бесконечного T теорема даёт лишь согласованное семейство конечномерных распределений, а склеивание его в один процесс на общем вероятностном пространстве — содержание теоремы Колмогорова о продолжении, которая в этом конспекте не доказывается и в раздел 2 не внесена: она нужна только здесь, в приложении, стоящем за рамками вопроса.

Для стационарных в широком смысле процессов неотрицательная определённость $K_X(\tau)$ получает спектральное описание: **теорема Хинчина** (у ряда авторов — **теорема Бохнера — Хинчина**) утверждает, что непрерывная корреляционная функция стационарного процесса представима как преобразование Фурье конечной меры на прямой, а если эта мера

имеет плотность, то плотность называется спектральной ([44], теорема 4.5). Это выводит корреляционную теорию в гармонический анализ. Здесь мы ограничиваемся формулировкой: предмет относится к отдельному разделу программы.

Оговорка, без которой формулировка вводит в заблуждение: теорема говорит о процессах, непрерывных в среднем квадратичном, и потому **белый шум под неё не подпадает**. Постоянная спектральная плотность отвечает бесконечной мере на прямой, а не конечной, и «корреляционная функция» $\sigma^2\delta(\tau)$ — не функция. Белый шум определяется на языке обобщённых случайных процессов, и это отдельная конструкция, а не следствие теоремы Хинчина; сам источник оговаривает ограничение прямо ([44], замечание после теоремы 4.5).

Замечание 15.3 (имена корреляционной и ковариационной функций расходятся). Терминология здесь разнобойная, и расхождение стоит знать заранее. У [24] корреляционной функцией названа *центрированная* величина и обозначена буквой K_X — так же, как выше. У [44] центрированная величина названа корреляционной функцией и обозначена R_X, а буквой K_X обозначена *нецентрированная* $\mathsf{E}X(t_1)X(t_2)$ под именем ковариационной функции; там же оговорено, что часть авторов зовёт ковариационной как раз центрированную. То есть одна и та же буква K означает у двух источников разные вещи, а разница между ними — слагаемое $m_X(t_1)m_X(t_2)$, исчезающее только у центрированных процессов. При чтении надо смотреть на формулу.

16. Вычислительная сторона

16.1. Выборочные оценки

По выборке $\xi^{(1)}, \dots, \xi^{(N)}$ независимых одинаково распределённых векторов строят

$$\overline{\xi} = \frac{1}{N}\sum_{i=1}^{N} \xi^{(i)}, \qquad \hat{\Gamma} = \frac{1}{N-1}\sum_{i=1}^{N} (\xi^{(i)} - \overline{\xi})(\xi^{(i)} - \overline{\xi})^{\mathsf{T}}. \tag{14}$$

Предложение 16.1 (несмещённость)**.** *При $N \geq 2$ и конечных вторых моментах $\mathsf{E}\hat{\Gamma} = \Gamma$.*

Доказательство. Не ограничивая общности, $\mathsf{E}\xi = 0$ (сдвиг не меняет ни $\hat{\Gamma}$, ни Γ). Тогда

$$\sum_{i} (\xi^{(i)} - \overline{\xi})(\xi^{(i)} - \overline{\xi})^{\mathsf{T}} = \sum_{i} \xi^{(i)}(\xi^{(i)})^{\mathsf{T}} - N\,\overline{\xi}\,\overline{\xi}^{\mathsf{T}}.$$

Математическое ожидание первой суммы равно $N\Gamma$. Для второго слагаемого

$$\mathsf{E}\,\overline{\xi}\,\overline{\xi}^{\mathsf{T}} = \frac{1}{N^2}\sum_{i,j} \mathsf{E}\xi^{(i)}(\xi^{(j)})^{\mathsf{T}} = \frac{1}{N^2}\cdot N\Gamma = \frac{\Gamma}{N},$$

поскольку при $i \neq j$ векторы независимы и имеют нулевые средние, так что $\mathsf{E}\xi^{(i)}(\xi^{(j)})^{\mathsf{T}} = 0$. Итого математическое ожидание суммы равно $N\Gamma - \Gamma = (N-1)\Gamma$, и деление на $N-1$ даёт требуемое. $\square$

Два свойства выборочной матрицы стоит помнить.

Она всегда неотрицательно определена: по построению $u^{\mathsf{T}}\hat{\Gamma}u = \frac{1}{N-1}\sum_i \langle u, \xi^{(i)} - \overline{\xi}\rangle^2 \geq 0$. То есть проверять её на допустимость не нужно, она допустима автоматически.

При $N \leq n$ она обязательно вырождена: сумма (14) есть сумма N матриц ранга 1, причём слагаемые связаны одним линейным соотношением ($\sum_i (\xi^{(i)} - \overline{\xi}) = 0$), поэтому $\operatorname{rank}\hat{\Gamma} \leq N - 1$. Практический вывод: при числе наблюдений, не превосходящем размерности, формулы раздела 6 неприменимы буквально — нужна либо регуляризация (сдвиг

диагонали, он же гребневая поправка), либо понижение размерности. Это и есть то место, где корреляционная теория смыкается с регуляризацией некорректных задач.

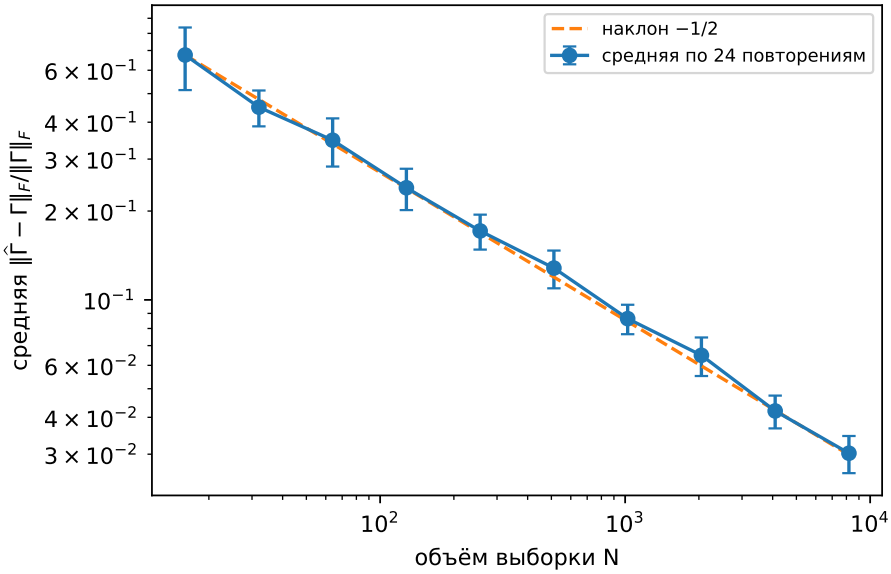


Рис. 3: Сходимость выборочной ковариационной матрицы к истинной при $n = 8$: относительная ошибка в норме Фробениуса, усреднённая по 24 повторениям. Измеренный наклон в логарифмических осях равен $-0{,}4923$ против предсказанного центральной предельной теоремой $-1/2$. Построено в `examples.ipynb`, пример 5.

16.2. Устойчивость счёта

Формула $\operatorname{cov}(\xi,\eta) = \mathsf{E}\xi\eta - \mathsf{E}\xi\,\mathsf{E}\eta$ удобна тем, что позволяет считать в один проход, накапливая суммы $\sum x_i$, $\sum y_i$, $\sum x_i y_i$. В арифметике с плавающей точкой она опасна: если данные сдвинуты на большую величину c, оба слагаемых имеют порядок c^2, а их разность — порядок дисперсии, и при c^2, сравнимом с обратной величиной машинной точности, от результата не остаётся ни одной верной цифры. Вычисленная так дисперсия может оказаться **отрицательной**: в одинарной точности это происходит уже при сдвиге 10^4, и пример 4 ноутбука печатает значения -8, -1024 и -131072. В двойной точности при сдвиге 10^8 та же формула на выборке из $2\cdot10^5$ стандартных нормальных величин даёт ровно $2{,}0$ вместо $1{,}0002$, а при сдвиге 10^9 — ровно нуль.

Правильных путей два: двухпроходный счёт (сперва среднее, потом сумма квадратов отклонений) и однопроходная формула Уэлфорда, обновляющая среднее и сумму квадратов отклонений по одному наблюдению:

$$\overline{x}_i = \overline{x}_{i-1} + \frac{x_i - \overline{x}_{i-1}}{i}, \qquad M_i = M_{i-1} + (x_i - \overline{x}_{i-1})(x_i - \overline{x}_i).$$

Обе устойчивы, потому что работают с отклонениями, а не с самими числами. Измерение потери точности — в примере 4 ноутбука.

16.3. Обращение ковариационной матрицы

Формулы раздела 6 содержат Γ_η^{-1}, но обращать матрицу явно не следует. Матрица симметрична и (при невырожденности) положительно определена, поэтому у неё есть разложение Холецкого $\Gamma_\eta = LL^{\mathsf{T}}$, и решение системы $\Gamma_\eta z = v$ сводится к двум треугольным подстановкам. Это вдвое дешевле общего метода Гаусса, устойчиво без выбора ведущего элемента и заодно служит проверкой: разложение с положительной диагональю существует тогда и только тогда, когда матрица положительно определена, — то есть неудача построения

означает вырожденность, и формулы раздела 6 к такой матрице неприменимы буквально (раздел 17.1). Допустимость матрицы, то есть *не*отрицательную определённость, Холецкий не проверяет — для неё нужны собственные значения (замечание 5.6).

Число обусловленности λ_1/λ_n говорит, насколько результат чувствителен к погрешности в Γ_η. Оно велико именно тогда, когда между наблюдениями есть почти линейная зависимость (теорема 5.7 в приближённой форме), и это же — признак избыточности измерений.

17. Посылки: невырожденность и смысл коэффициента корреляции

17.1. Невырожденность

Теоремы 6.4, 7.6, 7.7 и 5.10 требуют невырожденности Γ_η (или Γ). Это не техническая оговорка, а указание на то, что данные содержат точную линейную зависимость (теорема 5.7). Лечится это не регуляризацией, а исключением лишней координаты: работать надо в подпространстве $\operatorname{Im}\Gamma_\eta$, где матрица уже невырождена. Формально удобно заменить Γ_η^{-1} псевдообратной Γ_η^{+}; сохраняются при этом сама оценка $\hat{\xi}$ и ковариационная матрица ошибки Γ_{err}, а доказательство повторяется дословно, если в нём ограничиться векторами из $\operatorname{Im}\Gamma_\eta$. **Единственность матрицы B^* при этом теряется**, и теряется по существу: матрицы, различающиеся на отображение, обнуляющееся на $\operatorname{Im}\Gamma_\eta$, дают одну и ту же оценку и одну и ту же ошибку. Единственна оценка, а не матрица.

17.2. Что именно утверждает коэффициент корреляции

Коэффициент корреляции утверждает ровно одно: насколько хорошо одна величина приближается л**инейной** функцией другой в среднеквадратичном смысле (следствие 6.2). Из него не следует ни причинной связи, ни даже зависимости в обе стороны в каком-либо содержательном смысле: две величины могут быть сильно коррелированы, будучи следствиями общей третьей. Внутри корреляционной теории отличить эти случаи нельзя в принципе — у неё нет понятия вмешательства в систему, а есть только совместное распределение. Практический вывод для моделирования: корреляция задаёт структуру ошибок измерения и потому годится для оценивания, но не годится как самостоятельное обоснование модели.

18. Ещё разобранные задачи

Задача 18.1 (ковариационная матрица линейного образа)**.** Случайный вектор $\xi = (\xi_1, \xi_2)^{\mathsf{T}}$ имеет $\mathsf{D}\xi_1 = 4$, $\mathsf{D}\xi_2 = 9$, $r(\xi_1, \xi_2) = -1/3$. Найти дисперсию величины $\zeta = 2\xi_1 - \xi_2$ и ковариационную матрицу вектора $(\xi_1 + \xi_2,\ \xi_1 - \xi_2)^{\mathsf{T}}$.

Решение. Ковариация равна $r\sigma_1\sigma_2 = -\frac{1}{3}\cdot 2\cdot 3 = -2$, так что

$$\Gamma_\xi = \begin{pmatrix} 4 & -2 \\ -2 & 9 \end{pmatrix}.$$

По теореме 5.3 с $u = (2, -1)^{\mathsf{T}}$

$$\mathsf{D}\zeta = u^{\mathsf{T}}\Gamma_\xi u = 4\cdot 4 + 1\cdot 9 - 2\cdot 2\cdot 1\cdot(-2) = 16 + 9 + 8 = 33.$$

Для второго вопроса берём $A = \begin{pmatrix} 1 & 1 \\ 1 & -1 \end{pmatrix}$ и по теореме 5.1

$$A\Gamma_\xi A^{\mathsf{T}} = \begin{pmatrix} 1 & 1 \\ 1 & -1 \end{pmatrix} \begin{pmatrix} 4 & -2 \\ -2 & 9 \end{pmatrix} \begin{pmatrix} 1 & 1 \\ 1 & -1 \end{pmatrix} = \begin{pmatrix} 9 & -5 \\ -5 & 17 \end{pmatrix}.$$

Элементы читаются и без умножения матриц: $\mathsf{D}(\xi_1 + \xi_2) = 4 + 9 - 4 = 9$, $\mathsf{D}(\xi_1 - \xi_2) = 4 + 9 + 4 = 17$, а $\operatorname{cov}(\xi_1 + \xi_2, \xi_1 - \xi_2) = \mathsf{D}\xi_1 - \mathsf{D}\xi_2 = -5$.

Две проверки. След: $A^{\mathsf{T}}A = 2I$, то есть $A/\sqrt{2}$ ортогональна, и потому $\operatorname{tr}(A\Gamma_\xi A^{\mathsf{T}}) = 2\operatorname{tr}\Gamma_\xi$; действительно $9 + 17 = 26 = 2 \cdot 13$. Определитель: $\det(A\Gamma_\xi A^{\mathsf{T}}) = (\det A)^2 \det\Gamma_\xi = 4 \cdot 32 = 128$, и прямой счёт даёт $9 \cdot 17 - 25 = 128$.

Задача 18.2 (бывает ли такая матрица корреляционной)**.** Три величины попарно коррелированы так: $r_{12} = r_{23} = 0{,}8$, $r_{13} = 0$. Возможно ли это?

Решение. Корреляционная матрица

$$R = \begin{pmatrix} 1 & 0{,}8 & 0 \\ 0{,}8 & 1 & 0{,}8 \\ 0 & 0{,}8 & 1 \end{pmatrix}$$

обязана быть неотрицательно определённой (теорема 5.5). Считаем определитель:

$$\det R = 1 \cdot (1 - 0{,}64) - 0{,}8\,(0{,}8 - 0) + 0 = 0{,}36 - 0{,}64 = -0{,}28 < 0.$$

Определитель неотрицательно определённой матрицы неотрицателен (он равен произведению собственных значений), значит такой набор корреляций невозможен.

Это частный случай общего ограничения, которое полезно знать: если $r_{12} = r_{23} = \rho$, то

$$r_{13} \geq 2\rho^2 - 1. \tag{15}$$

Вывод: определитель корреляционной матрицы 3×3 с элементами $r_{12} = r_{23} = \rho$, $r_{13} = x$ равен

$$1 - 2\rho^2 - x^2 + 2\rho^2 x,$$

и требование его неотрицательности даёт $x^2 - 2\rho^2 x + 2\rho^2 - 1 \leq 0$. Корни квадратного трёхчлена равны $\rho^2 \pm \sqrt{\rho^4 - 2\rho^2 + 1} = \rho^2 \pm (1 - \rho^2)$, то есть $2\rho^2 - 1$ и 1; отсюда (15). При $\rho = 0{,}8$ получаем $r_{13} \geq 0{,}28$, так что нулевая корреляция первой и третьей величин действительно исключена. Содержательно: корреляция «частично транзитивна» — два сильных попарных сцепления вынуждают третье.

Задача 18.3 (наилучший линейный прогноз)**.** Рост и вес в некоторой совокупности имеют $\sigma_\xi = 7$ см, $\sigma_\eta = 9$ кг и $r = 0{,}6$. Построить наилучший линейный прогноз веса по росту, указать остаточное стандартное уклонение и сравнить его с безусловным.

Решение. По теореме 6.1 $b^* = r\sigma_\eta/\sigma_\xi = 0{,}6 \cdot 9/7 = 0{,}771$ кг на сантиметр, и прогноз в стандартизованной форме (4):

$$\frac{y - \mathsf{E}\eta}{9} = 0{,}6 \cdot \frac{x - \mathsf{E}\xi}{7}.$$

Остаточная дисперсия равна $\mathsf{D}\eta(1 - r^2) = 81 \cdot 0{,}64 = 51{,}84$, то есть остаточное стандартное уклонение $7{,}2$ кг против безусловного 9 кг. Выигрыш скромный: при $r = 0{,}6$ снимается $r^2 = 36\,\%$ дисперсии, а стандартное уклонение уменьшается лишь в $\sqrt{1 - r^2} = 0{,}8$ раза. Это общий эффект, который стоит помнить: **чтобы вдвое уменьшить ошибку прогноза, нужно** $|r| \geq \sqrt{3}/2 \approx 0{,}87$.

Обратная прямая (прогноз роста по весу) имеет в координатах (x, y) угловой коэффициент $\sigma_\eta/(r\sigma_\xi) = 9/(0{,}6 \cdot 7) = 2{,}14$ против $0{,}771$ у прямой регрессии веса на рост — отношение равно $r^2 = 0{,}36$, как и сказано в замечании 6.3.

19. Предельный переход от калмановской поправки к двум датчикам

Проверим обещанное в разделе 9.2: формулы (9) и (10) получаются из предложения 9.2 предельным переходом при неограниченной априорной неопределённости.

Берём $n = 1$ (оцениваем скаляр μ), $m = 2$, $H = (1, 1)^{\mathsf{T}}$, $P > 0$ — априорная дисперсия μ, и

$$\Gamma_{\varepsilon} = \begin{pmatrix} \sigma_1^2 & r\sigma_1\sigma_2 \\ r\sigma_1\sigma_2 & \sigma_2^2 \end{pmatrix}.$$

Тогда $HPH^{\mathsf{T}} + \Gamma_{\varepsilon} = PJ + \Gamma_{\varepsilon}$, где J — матрица из одних единиц, то есть

$$M = \begin{pmatrix} P + \sigma_1^2 & P + r\sigma_1\sigma_2 \\ P + r\sigma_1\sigma_2 & P + \sigma_2^2 \end{pmatrix}.$$

Обозначим $D = \sigma_1^2 + \sigma_2^2 - 2r\sigma_1\sigma_2$ (знаменатель обеих формул предложения 9.1) и $C = \sigma_1^2\sigma_2^2(1 - r^2)$ (числитель второй из них). Раскрывая определитель, получаем

$$\det M = (P + \sigma_1^2)(P + \sigma_2^2) - (P + r\sigma_1\sigma_2)^2 = PD + C,$$

поскольку слагаемые с P^2 взаимно уничтожаются.

Присоединённая матрица M есть $\begin{pmatrix} P + \sigma_2^2 & -(P + r\sigma_1\sigma_2) \\ -(P + r\sigma_1\sigma_2) & P + \sigma_1^2 \end{pmatrix}$, поэтому строка $H^{\mathsf{T}}M^{-1} = (1, 1)M^{-1}$ равна

$$\frac{1}{PD + C}(\sigma_2^2 - r\sigma_1\sigma_2,\ \ \sigma_1^2 - r\sigma_1\sigma_2),$$

и коэффициент усиления из предложения 9.2 $K = PH^{\mathsf{T}}M^{-1}$ есть та же строка, умноженная на P. Сумма её компонент равна $PD/(PD + C)$, то есть стремится к единице при $P \to \infty$, и в пределе

$$K \to \frac{1}{D}(\sigma_2^2 - r\sigma_1\sigma_2,\ \ \sigma_1^2 - r\sigma_1\sigma_2).$$

Первая компонента — это ровно w^* из (9), вторая равна $1 - w^*$. Дисперсия ошибки:

$$(1 - KH)P = P\left(1 - \frac{PD}{PD + C}\right) = \frac{PC}{PD + C} \xrightarrow[P \to \infty]{} \frac{C}{D},$$

и C/D — это V^* из (10).

Переход имеет и содержательный смысл: $P \to \infty$ означает отсутствие априорных сведений о величине, и тогда единственное, что остаётся, — требование несмещённости $\mathsf{E}\hat{\mu} = \mu$, из которого и выведено условие $w + (1 - w) = 1$ в разделе 9.1. Два вывода сошлись, и это проверка обоих.

20. Сводка контрпримеров

Утверждение, которое хочется сказать	Контрпример	Что на самом деле
«некоррелированные величины независимы»	ξ равномерна на $[-1,1]$, $\eta=\xi^2$ (пример 8.1)	независимость влечёт некоррелированность, обратное неверно (предложение 4.4)
«у вектора с нормальными компонентами некоррелированность равносильна независимости»	$\xi\sim\mathcal{N}(0,1)$, $\eta=s\xi$ со случайным знаком (пример 8.2)	нужна совместная гауссовость вектора, а не покомпонентная (теорема 7.5)
«неотрицательность угловых миноров означает неотрицательную определённость»	$\operatorname{diag}(0,-1)$ (замечание 5.6)	нужны все главные миноры, а не только угловые
«любые попарные корреляции совместимы»	$r_{12}=r_{23}=0{,}8$, $r_{13}=0$ (задача 18.2)	матрица обязана быть неотрицательно определённой: $r_{13}\geq 2\rho^2-1$
«коэффициент корреляции всегда определён»	пара величин с распределением Коши (раздел 8.1)	нужны конечные вторые моменты
«оптимальные веса при объединении измерений лежат между нулём и единицей»	$\sigma_1=2$, $\sigma_2=1$, $r=0{,}9$ (задача 11.1)	при $r>\sigma_2/\sigma_1$ вес худшего прибора отрицателен
«неравенство Чебышёва даёт разумную оценку вероятности»	двумерный нормальный закон, $c=10$ (замечание 5.11)	$0{,}2$ против точного $e^{-5}\approx 0{,}0067$

21. Что дальше

Три продолжения, каждое из которых снимает одно из ограничений корреляционной теории.

Ранговые коэффициенты связи. Коэффициент корреляции не инвариантен относительно нелинейных преобразований: у пары (ξ,ξ^3) связь функциональная и монотонная, а r вообще говоря меньше единицы и зависит от распределения ξ. Для $\xi\sim\mathcal{N}(0,1)$ моменты считаются из леммы 7.3. Там выведено $\varphi'(t)=-t\varphi(t)$; дифференцируя это равенство n раз по правилу Лейбница, получаем $\varphi^{(n+1)}(t)=-t\varphi^{(n)}(t)-n\varphi^{(n-1)}(t)$, то есть при $t=0$ выполнено $\varphi^{(n+1)}(0)=-n\,\varphi^{(n-1)}(0)$. Подставляя $\mathsf{E}\xi^n=(-i)^n\varphi^{(n)}(0)$ и учитывая $(-i)^2=-1$, приходим к рекуррентности $\mathsf{E}\xi^{\,n+1}=n\,\mathsf{E}\xi^{\,n-1}$. Отсюда $\mathsf{E}\xi^2=1$, $\mathsf{E}\xi^4=3\cdot1=3$, $\mathsf{E}\xi^6=5\cdot3=15$ (нечётные моменты нулевые по симметрии). Тогда $\operatorname{cov}(\xi,\xi^3)=\mathsf{E}\xi^4=3$, $\mathsf{D}\xi^3=\mathsf{E}\xi^6=15$ и $r(\xi,\xi^3)=3/\sqrt{1\cdot15}=3/\sqrt{15}\approx0{,}775$. (Оговорка «вообще говоря» существенна: на двухточечной $\xi=\pm1$ выполнено $\xi^3=\xi$, и $r=1$.) Коэффициенты Спирмена и Кендалла строятся по рангам наблюдений и потому не меняются при любом строго возрастающем преобразовании каждой из величин; они равны ±1 на любой монотонной зависимости, а не только на линейной. Цена — они уже не связаны напрямую с дисперсией прогноза, то есть теряют интерпретацию следствия 6.2.

Копулы. Совместное распределение пары распадается на две части: маргинальные распределения и функцию связи между ними. Формально это теорема Скляра: всякая совместная функция распределения представима как $C(F_\xi(x),F_\eta(y))$ с функцией C на квадрате, имеющей равномерные маргинальные распределения. Корреляционная теория описывает связь одним числом; копула описывает её функцией, и потому различает случаи, неразличимые по r, — в частности, поведение в хвостах, о котором вторые моменты молчат (последний из шести случаев раздела 10 — оценка риска суммы).

Корреляционная теория случайных процессов. Раздел 15 — только вход. Дальше идут: спектральное представление стационарного процесса, теорема Хинчина о представлении корреляционной функции преобразованием Фурье, эргодические теоремы (когда среднее

по одной траектории заменяет среднее по ансамблю), среднеквадратичное дифференцирование и интегрирование процессов. Весь этот аппарат строится из тех же двух моментов и потому целиком принадлежит корреляционной теории.

22. Вопросы, которые стоит ожидать

Какие матрицы бывают ковариационными? Ровно симметричные неотрицательно определённые, и никаких других условий нет (теорема 5.5). Вторая половина утверждения — конструктивная: $\xi = \Gamma^{1/2}\zeta + a$.

Следует ли из некоррелированности независимость? Нет; следствие идёт в другую сторону (предложение 4.4). Контрпример — пример 8.1. Равносильность верна для *совместно* гауссовского вектора (теорема 7.5), и пример 8.2 показывает, что нормальности каждой компоненты для этого мало.

Что означает $r = 0$? Только то, что наилучший линейный прогноз тривиален: он равен $\mathsf{E}\eta$ и не снимает ни доли дисперсии (следствие 6.2). Про нелинейную связь это не говорит ничего.

Что означает $|r| = 1$? Почти наверное линейную зависимость (теорема 4.3), то есть вырожденность ковариационной матрицы и попадание вектора в прямую (теорема 5.7).

Зачем нужен коэффициент корреляции, если есть ковариация? Ковариация зависит от единиц измерения, коэффициент корреляции — нет (замечание 3.7), и только он допускает интерпретацию доли снятой дисперсии.

В чём смысл неотрицательной определённости? В том, что дисперсия любой линейной комбинации неотрицательна (теорема 5.3); нарушение означало бы величину с отрицательной дисперсией.

Что даёт спектральное разложение ковариационной матрицы? Поворот, после которого компоненты некоррелированы, дисперсии в новых осях равны собственным значениям, и направление наибольшего разброса — первый собственный вектор (теорема 5.8). Это и есть метод главных компонент.

Как строится наилучший линейный прогноз и чему равна его ошибка? Теорема 6.1: $b^* = \operatorname{cov}/\mathsf{D}\xi$, остаточная дисперсия $\mathsf{D}\eta(1 - r^2)$. Векторный вариант — теорема 6.4, и он же корректирующий шаг фильтра Калмана.

Почему условное математическое ожидание — наилучший прогноз? Потому что оно есть ортогональная проекция в L_2 на подпространство измеримых функций от наблюдения (теорема 6.6); минимальность получается теоремой Пифагора.

Когда наилучший прогноз линеен? В гауссовском случае (теорема 7.7); там же условная ковариация не зависит от наблюдённого значения.

Чему равна дисперсия суммы зависимых величин? Сумме дисперсий плюс удвоенная сумма попарных ковариаций (следствие 5.4); аддитивность требует только попарной некоррелированности, не независимости.

Что такое эллипсоид рассеяния и что про него известно без предположений о распределении? Определение 5.9; оценка вероятности выхода — теорема 5.10, и она груба (замечание 5.11).

Может ли выборочная ковариационная матрица быть вырожденной? Обязана при $N \le n$ (раздел 16.1); она же всегда неотрицательно определена.

23. Источники

Основной. [06] (Турчин), §21.1 «Многомерное нормальное распределение», с. 517–526: математическое ожидание случайного вектора и случайной матрицы, ковариационная матрица, лемма 21.1.1 о линейном преобразовании, теорема о симметричности и положительной полуопределённости (с. 518–519), гауссовские векторы, теоремы 21.1.1–21.1.6. Ковариация и коэффициент корреляции — там же, с. 109–110.

Второй русскоязычный. [24] (Гмурман), гл. 14 §17–18 (корреляционный момент, коэффициент корреляции, коррелированность и зависимость) и гл. 23 §3, с. 388–389 (определение корреляционной теории), §9 (корреляционная функция).

Условное математическое ожидание. [07] (Шабанов), теорема 10.4 о наилучшем квадратичном прогнозе, с. 98–99.

Дополнение на языке теории меры. [62] (Богачев), §1.2, с. 12–16: предложение 1.2.2, следствие 1.2.3 (ковариационный оператор), эллипсоид рассеяния, лемма 1.2.5, пример 1.2.6.

Случайные процессы. [44] (Гасников и др.), определения 1.8 (корреляционная функция R_X, центрированная) и 1.9 (ковариационная функция K_X, нецентрированная) — на этой паре стоит замечание о расхождении имён; определения 4.4 и 4.5 (стационарность в узком и широком смысле); теорема 4.5 (Бохнера — Хинчина) о спектральном представлении корреляционной функции.

Линейная алгебра. [01] (Бобень, Сиренева), §30.1 и §30.3, с. 105; сверка — [02] (Голуб, Ван Лоун), теорема 8.1.1, с. 369, и теорема 8.1.2 (Куранта — Фишера).