

# Методы минимизации функций многих переменных

## Вопрос 10

---

Крохалев Е. М.

2026

## Постановка

---

- Оптимальное управление: функционал качества  $\sum (x_k^T Q x_k + u_k^T R u_k)$  — квадратичная функция параметров.
- Машинное обучение: минимизация эмпирического риска по параметрам модели.
- Обратные задачи: минимизация функционала невязки.

Дана  $f: \mathbb{R}^n \rightarrow \mathbb{R}$ . Требуется найти  $x^* \in \arg \min f$  итерационным методом с заданной точностью.

сквозной пример: квадратичная  $\varphi(x) = \frac{1}{2}x^\top Ax - b^\top x$ ,  $\kappa = \mu_{\max}/\mu_{\min} \gg 1$

## Основные результаты

---

## Определение 1

$f$  гладкая с константой  $L$ , если  $\|\nabla f(y) - \nabla f(x)\| \leq L \|y - x\|$ ; эквивалентно  $f(y) \leq f(x) + \langle \nabla f(x), y - x \rangle + \frac{L}{2} \|y - x\|^2$ .

## Определение 2

$f$  сильно выпукла с константой  $\mu$ , если  $f(y) \geq f(x) + \langle \nabla f(x), y - x \rangle + \frac{\mu}{2} \|y - x\|^2$ .

Число обусловленности:  $\kappa = L/\mu$ .

### Теорема 3 (необходимые и достаточные условия экстремума)

Пусть  $f$  дифференцируема в точке  $x^*$ .

(а) Если  $x^*$  — локальный минимум, то  $\nabla f(x^*) = 0$ .

(б) Если  $f$  дважды дифференцируема в  $x^*$  и  $x^*$  — локальный минимум, то  $\nabla^2 f(x^*) \succeq 0$ .

(в) Если  $f$  дважды дифференцируема в окрестности  $x^*$ ,  $\nabla f(x^*) = 0$  и  $\nabla^2 f(x^*) \succ 0$ , то  $x^*$  — строгий локальный минимум.

$$x^{k+1} = x^k - \gamma_k \nabla f(x^k), \quad \gamma_k = \frac{1}{L}$$

### Лемма 4 (спуск)

Пусть  $f$   $L$ -гладка. Тогда  $f(x - \frac{1}{L} \nabla f(x)) \leq f(x) - \frac{1}{2L} \|\nabla f(x)\|^2$ .

### Теорема 5 (сходимость градиентного спуска)

Пусть  $f$   $L$ -гладкая,  $x^{k+1} = x^k - \frac{1}{L} \nabla f(x^k)$ ,  $R = \|x^0 - x^*\|$ .

(а) **Невыпуклый случай.**  $f$  ограничена снизу:  $f \geq f_* > -\infty$ . Тогда

$$\min_{0 \leq k \leq N-1} \|\nabla f(x^k)\| \leq \sqrt{\frac{2L(f(x^0) - f_*)}{N}}.$$

(б) **Выпуклый случай.**  $f$  выпукла. Тогда  $f(\bar{x}^N) - f^* \leq \frac{LR^2}{2N}$ .

(в) **Сильно выпуклый случай.**  $f$   $\mu$ -сильно выпукла. Тогда  $f(x^N) - f^* \leq \frac{LR^2}{2} \min\{\frac{1}{N}, (1 - \frac{\mu}{L})^N\}$ .

### Замечание 1 (существенность посылок)

Каждая посылка существенна: без липшицевости градиента метод расходится ( $\|x\|^{2+\varepsilon}$ ); без ограниченности снизу градиент не обязан стремиться к нулю (линейная  $f$ ); при  $\gamma \geq 2/L$  – расходимость на  $\frac{1}{2} \|x\|^2$ ; без сильной выпуклости скорость может быть сколь угодно малой.

### Теорема 6 (точная оценка для сильно выпуклых гладких функций)

Пусть  $f$  дважды дифференцируема и  $\mu I \preceq \nabla^2 f(x) \preceq LI$  для всех  $x$ . Тогда градиентный спуск с постоянным шагом  $\gamma$  сходится:  $\|x^k - x^*\| \leq \|x^0 - x^*\| q^k$ ,  $q(\gamma) = \max\{|1 - \gamma\mu|, |1 - \gamma L|\}$ ; минимум  $q^* = \frac{\kappa-1}{\kappa+1}$  достигается при  $\gamma^* = \frac{2}{L+\mu}$ . Оценка неулучшаема.

$$N \approx \frac{\kappa}{2} \ln \frac{1}{\varepsilon} \quad \text{итераций} \quad (\kappa = 10^3 : \approx 3\,500)$$

### Теорема 7 (нижние оценки)

(а) Существует  $L$ -гладкая выпуклая  $f$  с  $\|x^0 - x^*\| \leq R$  такая, что для любого метода из span градиентов  $f(x^N) - f^* \geq \frac{3LR^2}{32(N+1)^2}$ .

(б) Для любых  $L \geq \mu > 0$  существует  $L$ -гладкая  $\mu$ -сильно выпуклая  $f$  такая, что  $f(x^N) - f^* \geq \frac{\mu R^2}{2} \left( \frac{\sqrt{n}-1}{\sqrt{n}+1} \right)^{2N}$ .

**Вывод:** градиентный спуск оптимален в классе гладких выпуклых; разрыв  $O(n)$  против  $O(\sqrt{n})$  закрывается ускорением.

## Чебышёвское ускорение

---

$$e^k = p_k(A)e^0, \quad p_k(0) = 1; \quad \min_{\lambda \in [\mu, L]} |p_k(\lambda)| \Rightarrow p_k^* = \frac{T_k(z(\lambda))}{T_k(z(0))}$$

$$\|e^k\| \leq q_k \|e^0\|, \quad q_k = \frac{2\sigma^k}{1 + \sigma^{2k}}, \quad \sigma = \frac{\sqrt{\kappa} - 1}{\sqrt{\kappa} + 1}$$

(аппарат многочленов Чебышёва — вопрос 11)

$$y^{(k+1)} = \omega_{k+1}(y^{(k)} - y^{(k-1)} + \gamma z^{(k)}) + y^{(k-1)}, \quad \omega_{k+1} = 2\mu \frac{T_k(\mu)}{T_{k+1}(\mu)}$$

### Теорема 8 (сходимость чебышёвских полуитераций)

Итерации удовлетворяют  $y^{(k)} - x^* = p_k(A)(y^{(0)} - x^*)$  с чебышёвским  $p_k$ , и  $\|y^{(k)} - x^*\| \leq q_k \|y^{(0)} - x^*\|$ . Для точности  $\varepsilon$  достаточно  $k \geq \frac{\ln(2/\varepsilon)}{2\sqrt{\xi}}$  итераций,  $\xi = \mu_{\min}/\mu_{\max}$ .

**Сравнение:**  $\frac{\kappa}{2} \ln \frac{1}{\varepsilon}$  (стационарный шаг) против  $\frac{\sqrt{\kappa}}{2} \ln \frac{2}{\varepsilon}$  (чебышёв).

$$x^{k+1} = x^k + \gamma_k h^k, \quad h^{k+1} = -\nabla \varphi(x^{k+1}) + \beta_k h^k, \quad \beta_k = \frac{\|\nabla \varphi(x^{k+1})\|^2}{\|\nabla \varphi(x^k)\|^2}$$

### Теорема 9 (конечность сопряжённых градиентов)

Итерации для квадратичной функции с положительно определённой  $A$  находят точный минимум за не более чем  $n$  шагов;  $x^k$  минимизирует  $\varphi$  на крыловском подпространстве.

### Теорема 10 (оценка сходимости CG)

$$\|x^k - x^*\|_A \leq 2\sqrt{L/\mu} q^k \|x^0 - x^*\|_A, \quad q = \frac{\sqrt{n}-1}{\sqrt{n+1}}.$$

CG оптимален среди методов первого порядка и не требует знания спектра.

| Метод                    | Итерации                                | Требует  |
|--------------------------|-----------------------------------------|----------|
| Градиентный $\gamma^*$   | $O(n \ln \frac{1}{\varepsilon})$        | $\mu, L$ |
| Наискорейший спуск       | не лучше стационарного                  | ничего   |
| Чебышёвские полуитерации | $O(\sqrt{n} \ln \frac{2}{\varepsilon})$ | $\mu, L$ |
| Сопряжённые градиенты    | $O(\sqrt{n} \ln \frac{1}{\varepsilon})$ | ничего   |

## Методы второго порядка и ускорение

---

$$x^{k+1} = x^k - \alpha \nabla f(x^k) + \beta(x^k - x^{k-1})$$

### Теорема 11 (локальная сходимость тяжёлого шарика)

Пусть  $\mu I \preceq \nabla^2 f(x^*) \preceq LI$ ,  $0 \leq \beta < 1$ ,  $0 < \alpha < \frac{2(1+\beta)}{\frac{L}{\mu}}$ . Тогда локально

$$\|x^k - x^*\| \leq c(q + \delta)^k; \text{ при } \alpha^* = \frac{4}{(\sqrt{L} + \sqrt{\mu})^2}, \beta^* = \left( \frac{\sqrt{L} - \sqrt{\mu}}{\sqrt{L} + \sqrt{\mu}} \right)^2 \text{ знаменатель } q^* = \frac{\sqrt{\mu} - 1}{\sqrt{\mu} + 1}.$$

$$x^{k+1} = y^k - \frac{1}{L} \nabla f(y^k), \quad y^{k+1} = x^{k+1} + \frac{k}{k+3} (x^{k+1} - x^k)$$

### Теорема 12 (сходимость метода Нестерова)

Для  $L$ -гладкой выпуклой  $f$ :  $f(x^N) - f^* \leq \frac{2LR^2}{(N+1)^2}$ . Для  $\mu$ -сильно выпуклой с постоянным коэффициентом  $\frac{\sqrt{\kappa}-1}{\sqrt{\kappa}+1}$ :  $f(x^N) - f^* \leq \frac{LR^2}{2} \left( \frac{\sqrt{\kappa}-1}{\sqrt{\kappa}+1} \right)^N$ .

**Тяжёлый шарик vs Нестеров:** градиент в  $x^k$  (локально) против градиента в  $y^k$  (глобально по нижним оценкам).

$$x^{k+1} = x^k - [\nabla^2 f(x^k)]^{-1} \nabla f(x^k)$$

## Теорема 13 (локальная квадратичная сходимость)

Пусть  $f$   $\mu$ -сильно выпукла,  $\|\nabla^2 f(x) - \nabla^2 f(y)\| \leq M \|x - y\|$ ,  $q_0 = \frac{M}{2\mu^2} \|\nabla f(x^0)\| < 1$ . Тогда  $\|x^k - x^*\| \leq \frac{2\mu}{M} q_0^{2^k}$ .

### Теорема 14 (Ньютона—Канторовича)

Пусть  $\|\Gamma_0 \nabla f(x^0)\| \leq \eta$ ,  $\|\Gamma_0 \nabla^2 f(x)\| \leq K$  в шаре радиуса  $r$ ,  $\Gamma_0 = [\nabla^2 f(x^0)]^{-1}$ ,  $h = K\eta \leq \frac{1}{2}$ ,  $r \geq r_0 = \frac{1-\sqrt{1-2h}}{h}\eta$ . Тогда в шаре существует решение  $\nabla f(x) = 0$ , к которому сходится метод Ньютона, и  $\|x^k - x^*\| \leq \frac{1}{2^k} (2h)^{2^k} \frac{\eta}{h}$ ; решение единственно при  $r < \frac{1+\sqrt{1-2h}}{h}\eta$ .

## Условная оптимизация

---

$$\text{proj}_Q(y) = \arg \min_{x \in Q} \frac{1}{2} \|x - y\|^2$$

## Теорема 15 (критерий проекции)

$x = \text{proj}_Q(y)$  тогда и только тогда, когда  $\langle y - x, z - x \rangle \leq 0$  для всех  $z \in Q$ ; проекция  
нерасширяющая:  $\|\text{proj}_Q(y) - \text{proj}_Q(y')\| \leq \|y - y'\|$ .

$$x^{k+1} = \text{proj}_Q(x^k - \frac{1}{L} \nabla f(x^k))$$

### Теорема 16 (сходимость PGD)

*$f$  выпукла,  $L$ -гладка на выпуклом замкнутом  $Q \Rightarrow f(x^N) - f^* \leq \frac{LR^2}{2N}$ .*

$$y^k = \arg \min_{y \in Q} \langle \nabla f(x^k), y \rangle, \quad x^{k+1} = x^k + \gamma_k(y^k - x^k), \quad \gamma_k = \frac{2}{k+2}$$

### Теорема 17 (сходимость Франка—Вулфа)

*$f$  выпукла,  $L$ -гладка на выпуклом компакте  $Q$  диаметра  $R \Rightarrow f(x^N) - f^* \leq \frac{2LR^2}{N+2}$ .*


**Оговорка:** оценка  $O(1/k^2)$  для сильно выпуклых функций, встречающаяся в изложениях, неверна — доказательство отбрасывает полезный член с  $\mu$ ; контрпример  $f(x) = \|x\|^2$  на симплексе с tie-breaking «свежая вершина» сходится как  $\Theta(1/k)$  (измерено).

| Постановка          | Что минимизируется               | Метод                                   |
|---------------------|----------------------------------|-----------------------------------------|
| ЛК-регулятор        | $\sum (x^T Q x + u^T R u)$       | CG, Ньютон                              |
| Обратная задача     | $\ Aq - f\ ^2$ (+ регуляризатор) | градиентный через<br>сопряжённую задачу |
| Обучение модели     | эмпирический риск                | SGD + импульс (= тяжёлый шарик)         |
| Задача на симплексе | гладкая выпуклая                 | Франк—Вулф (линейный оракул)            |

## Численная иллюстрация

---

- Квадратичная задача,  $\kappa = 10^3$ : измеренный знаменатель градиентного спуска совпал с  $q^* = (\kappa - 1)/(\kappa + 1)$ .
- Тяжёлый шарик и Нестеров:  $q \approx 0,94$  против 0,998 — выигрыш  $\approx 30$  раз.
- Стресс-тест: трёхчленная чебышёвская форма устойчива, множительная взрывается.
- FW на симплексе:  $\Theta(1/k)$ , наклон  $-1,07$ .





- Лемма спуска  $\Rightarrow$  три режима сходимости градиентного спуска; все оценки точны по порядку.
- Плохая обусловленность — враг:  $O(n)$  итераций; ускорение покупается чебышёвским набором, тяжёлым шариком, Нестеровым или CG —  $O(\sqrt{n})$ .
- Чебышёвская трёхчленная рекуррентность устойчива, множительная форма — нет.
- Ньютон: квадратичная сходимость локально; теорема Канторовича — полулокальная гарантия.
- Условная оптимизация: PGD (проекция) и Франк—Вулф (линейный оракул) — оба  $O(1/k)$ .