

Методы минимизации функций многих переменных

Вопрос 10

Крохалев Е. М.

2026

Постановка

- Оптимальное управление: функционал качества $\sum (x_k^T Q x_k + u_k^T R u_k)$ — квадратичная функция параметров.
- Машинное обучение: минимизация эмпирического риска по параметрам модели.
- Обратные задачи: минимизация функционала невязки.

Дана $f: \mathbb{R}^n \rightarrow \mathbb{R}$. Требуется найти $x^* \in \arg \min f$ итерационным методом с заданной точностью.

сквозной пример: квадратичная $\varphi(x) = \frac{1}{2}x^\top Ax - b^\top x$, $\kappa = \mu_{\max}/\mu_{\min} \gg 1$

Основные результаты

Определение 1

f гладкая с константой L , если $\|\nabla f(y) - \nabla f(x)\| \leq L \|y - x\|$; эквивалентно $f(y) \leq f(x) + \langle \nabla f(x), y - x \rangle + \frac{L}{2} \|y - x\|^2$.

Определение 2

f сильно выпукла с константой μ , если $f(y) \geq f(x) + \langle \nabla f(x), y - x \rangle + \frac{\mu}{2} \|y - x\|^2$.

Число обусловленности: $\kappa = L/\mu$.

Теорема 3 (необходимые и достаточные условия экстремума)

Пусть f дифференцируема в точке x^* .

(а) Если x^* — локальный минимум, то $\nabla f(x^*) = 0$.

(б) Если f дважды дифференцируема в x^* и x^* — локальный минимум, то $\nabla^2 f(x^*) \succeq 0$.

(в) Если f дважды дифференцируема в окрестности x^* , $\nabla f(x^*) = 0$ и $\nabla^2 f(x^*) \succ 0$, то x^* — строгий локальный минимум.

$$x^{k+1} = x^k - \gamma_k \nabla f(x^k), \quad \gamma_k = \frac{1}{L}$$

Лемма 4 (спуск)

Пусть f L -гладка. Тогда $f(x - \frac{1}{L} \nabla f(x)) \leq f(x) - \frac{1}{2L} \|\nabla f(x)\|^2$.

Теорема 5 (сходимость градиентного спуска)

Пусть f L -гладкая, $x^{k+1} = x^k - \frac{1}{L} \nabla f(x^k)$, $R = \|x^0 - x^*\|$.

(а) **Невыпуклый случай.** f ограничена снизу: $f \geq f_* > -\infty$. Тогда

$$\min_{0 \leq k \leq N-1} \|\nabla f(x^k)\| \leq \sqrt{\frac{2L(f(x^0) - f_*)}{N}}.$$

(б) **Выпуклый случай.** f выпукла. Тогда $f(\bar{x}^N) - f^* \leq \frac{LR^2}{2N}$.

(в) **Сильно выпуклый случай.** f μ -сильно выпукла. Тогда $f(x^N) - f^* \leq \frac{LR^2}{2} \min\{\frac{1}{N}, (1 - \frac{\mu}{L})^N\}$.

Замечание 1 (существенность посылок)

Каждая посылка существенна: без липшицевости градиента метод расходится ($\|x\|^{2+\varepsilon}$); без ограниченности снизу градиент не обязан стремиться к нулю (линейная f); при $\gamma \geq 2/L$ – расходимость на $\frac{1}{2} \|x\|^2$; без сильной выпуклости скорость может быть сколь угодно малой.

Теорема 6 (точная оценка для сильно выпуклых гладких функций)

Пусть f дважды дифференцируема и $\mu I \preceq \nabla^2 f(x) \preceq LI$ для всех x . Тогда градиентный спуск с постоянным шагом γ сходится: $\|x^k - x^*\| \leq \|x^0 - x^*\| q^k$, $q(\gamma) = \max\{|1 - \gamma\mu|, |1 - \gamma L|\}$; минимум $q^* = \frac{\kappa-1}{\kappa+1}$ достигается при $\gamma^* = \frac{2}{L+\mu}$. Оценка неулучшаема.

$$N \approx \frac{\kappa}{2} \ln \frac{1}{\varepsilon} \quad \text{итераций} \quad (\kappa = 10^3 : \approx 3\,500)$$

Теорема 7 (нижние оценки)

(а) Существует L -гладкая выпуклая f с $\|x^0 - x^*\| \leq R$ такая, что для любого метода из span градиентов $f(x^N) - f^* \geq \frac{3LR^2}{32(N+1)^2}$.

(б) Для любых $L \geq \mu > 0$ существует L -гладкая μ -сильно выпуклая f такая, что $f(x^N) - f^* \geq \frac{\mu R^2}{2} \left(\frac{\sqrt{n}-1}{\sqrt{n}+1} \right)^{2N}$.

Вывод: градиентный спуск оптимален в классе гладких выпуклых; разрыв $O(n)$ против $O(\sqrt{n})$ закрывается ускорением.

Чебышёвское ускорение

$$e^k = p_k(A)e^0, \quad p_k(0) = 1; \quad \min_{\lambda \in [\mu, L]} |p_k(\lambda)| \Rightarrow p_k^* = \frac{T_k(z(\lambda))}{T_k(z(0))}$$

$$\|e^k\| \leq q_k \|e^0\|, \quad q_k = \frac{2\sigma^k}{1 + \sigma^{2k}}, \quad \sigma = \frac{\sqrt{\kappa} - 1}{\sqrt{\kappa} + 1}$$

(аппарат многочленов Чебышёва — вопрос 11)

$$y^{(k+1)} = \omega_{k+1}(y^{(k)} - y^{(k-1)} + \gamma z^{(k)}) + y^{(k-1)}, \quad \omega_{k+1} = 2\mu \frac{T_k(\mu)}{T_{k+1}(\mu)}$$

Теорема 8 (сходимость чебышёвских полуитераций)

Итерации удовлетворяют $y^{(k)} - x^* = p_k(A)(y^{(0)} - x^*)$ с чебышёвским p_k , и $\|y^{(k)} - x^*\| \leq q_k \|y^{(0)} - x^*\|$. Для точности ε достаточно $k \geq \frac{\ln(2/\varepsilon)}{2\sqrt{\xi}}$ итераций, $\xi = \mu_{\min}/\mu_{\max}$.

Сравнение: $\frac{\kappa}{2} \ln \frac{1}{\varepsilon}$ (стационарный шаг) против $\frac{\sqrt{\kappa}}{2} \ln \frac{2}{\varepsilon}$ (чебышёв).

$$x^{k+1} = x^k + \gamma_k h^k, \quad h^{k+1} = -\nabla \varphi(x^{k+1}) + \beta_k h^k, \quad \beta_k = \frac{\|\nabla \varphi(x^{k+1})\|^2}{\|\nabla \varphi(x^k)\|^2}$$

Теорема 9 (конечность сопряжённых градиентов)

Итерации для квадратичной функции с положительно определённой A находят точный минимум за не более чем n шагов; x^k минимизирует φ на крыловском подпространстве.

Теорема 10 (оценка сходимости CG)

$$\|x^k - x^*\|_A \leq 2\sqrt{L/\mu} q^k \|x^0 - x^*\|_A, \quad q = \frac{\sqrt{n}-1}{\sqrt{n+1}}.$$

CG оптимален среди методов первого порядка и не требует знания спектра.

Метод	Итерации	Требует
Градиентный γ^*	$O(n \ln \frac{1}{\varepsilon})$	μ, L
Наискорейший спуск	не лучше стационарного	ничего
Чебышёвские полуитерации	$O(\sqrt{n} \ln \frac{2}{\varepsilon})$	μ, L
Сопряжённые градиенты	$O(\sqrt{n} \ln \frac{1}{\varepsilon})$	ничего

Методы второго порядка и ускорение

$$x^{k+1} = x^k - \alpha \nabla f(x^k) + \beta(x^k - x^{k-1})$$

Теорема 11 (локальная сходимость тяжёлого шарика)

Пусть $\mu I \preceq \nabla^2 f(x^*) \preceq LI$, $0 \leq \beta < 1$, $0 < \alpha < \frac{2(1+\beta)}{\frac{L}{\mu}}$. Тогда локально

$$\|x^k - x^*\| \leq c(q + \delta)^k; \text{ при } \alpha^* = \frac{4}{(\sqrt{L} + \sqrt{\mu})^2}, \beta^* = \left(\frac{\sqrt{L} - \sqrt{\mu}}{\sqrt{L} + \sqrt{\mu}}\right)^2 \text{ знаменатель } q^* = \frac{\sqrt{\mu} - 1}{\sqrt{\mu} + 1}.$$

$$x^{k+1} = y^k - \frac{1}{L} \nabla f(y^k), \quad y^{k+1} = x^{k+1} + \frac{k}{k+3} (x^{k+1} - x^k)$$

Теорема 12 (сходимость метода Нестерова)

Для L -гладкой выпуклой f : $f(x^N) - f^* \leq \frac{2LR^2}{(N+1)^2}$. Для μ -сильно выпуклой с постоянным коэффициентом $\frac{\sqrt{\kappa}-1}{\sqrt{\kappa}+1}$: $f(x^N) - f^* \leq \frac{LR^2}{2} \left(\frac{\sqrt{\kappa}-1}{\sqrt{\kappa}+1} \right)^N$.

Тяжёлый шарик vs Нестеров: градиент в x^k (локально) против градиента в y^k (глобально по нижним оценкам).

$$x^{k+1} = x^k - [\nabla^2 f(x^k)]^{-1} \nabla f(x^k)$$

Теорема 13 (локальная квадратичная сходимость)

Пусть f μ -сильно выпукла, $\|\nabla^2 f(x) - \nabla^2 f(y)\| \leq M \|x - y\|$, $q_0 = \frac{M}{2\mu^2} \|\nabla f(x^0)\| < 1$. Тогда $\|x^k - x^*\| \leq \frac{2\mu}{M} q_0^{2^k}$.

Теорема 14 (Ньютона—Канторовича)

Пусть $\|\Gamma_0 \nabla f(x^0)\| \leq \eta$, $\|\Gamma_0 \nabla^2 f(x)\| \leq K$ в шаре радиуса r , $\Gamma_0 = [\nabla^2 f(x^0)]^{-1}$, $h = K\eta \leq \frac{1}{2}$, $r \geq r_0 = \frac{1-\sqrt{1-2h}}{h}\eta$. Тогда в шаре существует решение $\nabla f(x) = 0$, к которому сходится метод Ньютона, и $\|x^k - x^*\| \leq \frac{1}{2^k} (2h)^{2^k} \frac{\eta}{h}$; решение единственно при $r < \frac{1+\sqrt{1-2h}}{h}\eta$.

Условная оптимизация

$$\text{proj}_Q(y) = \arg \min_{x \in Q} \frac{1}{2} \|x - y\|^2$$

Теорема 15 (критерий проекции)

$x = \text{proj}_Q(y)$ тогда и только тогда, когда $\langle y - x, z - x \rangle \leq 0$ для всех $z \in Q$; проекция
нерасширяющая: $\|\text{proj}_Q(y) - \text{proj}_Q(y')\| \leq \|y - y'\|$.

$$x^{k+1} = \text{proj}_Q(x^k - \frac{1}{L} \nabla f(x^k))$$

Теорема 16 (сходимость PGD)

f выпукла, L -гладка на выпуклом замкнутом $Q \Rightarrow f(x^N) - f^* \leq \frac{LR^2}{2N}$.

$$y^k = \arg \min_{y \in Q} \langle \nabla f(x^k), y \rangle, \quad x^{k+1} = x^k + \gamma_k(y^k - x^k), \quad \gamma_k = \frac{2}{k+2}$$

Теорема 17 (сходимость Франка—Вулфа)


f выпукла, L -гладка на выпуклом компакте Q диаметра $R \Rightarrow f(x^N) - f^ \leq \frac{2LR^2}{N+2}$.*

Оговорка: оценка $O(1/k^2)$ для сильно выпуклых функций, встречающаяся в изложениях, неверна — доказательство отбрасывает полезный член с μ ; контрпример $f(x) = \|x\|^2$ на симплексе с tie-breaking «свежая вершина» сходится как $\Theta(1/k)$ (измерено).

Постановка	Что минимизируется	Метод
ЛК-регулятор	$\sum (x^T Q x + u^T R u)$	CG, Ньютон
Обратная задача	$\ Aq - f\ ^2$ (+ регуляризатор)	градиентный через сопряжённую задачу
Обучение модели	эмпирический риск	SGD + импульс (= тяжёлый шарик)
Задача на симплексе	гладкая выпуклая	Франк—Вулф (линейный оракул)

Численная иллюстрация

- Квадратичная задача, $\kappa = 10^3$: измеренный знаменатель градиентного спуска совпал с $q^* = (\kappa - 1)/(\kappa + 1)$.
- Тяжёлый шарик и Нестеров: $q \approx 0,94$ против 0,998 — выигрыш ≈ 30 раз.
- Стресс-тест: трёхчленная чебышёвская форма устойчива, множительная взрывается.
- FW на симплексе: $\Theta(1/k)$, наклон $-1,07$.



- Лемма спуска $\Rightarrow$ три режима сходимости градиентного спуска; все оценки точны по порядку.
- Плохая обусловленность — враг: $O(n)$ итераций; ускорение покупается чебышёвским набором, тяжёлым шариком, Нестеровым или CG — $O(\sqrt{n})$.
- Чебышёвская трёхчленная рекуррентность устойчива, множительная форма — нет.
- Ньютон: квадратичная сходимость локально; теорема Канторовича — полулокальная гарантия.
- Условная оптимизация: PGD (проекция) и Франк—Вулф (линейный оракул) — оба $O(1/k)$.