

Методы минимизации функций многих переменных

Вопрос 10

Крохалев Е. М.

2026

Постановка

- Оптимальное управление: функционал качества $\sum (x_k^T Q x_k + u_k^T R u_k)$ — квадратичная функция параметров.
- Машинное обучение: минимизация эмпирического риска по параметрам модели.
- Обратные задачи: минимизация функционала невязки.

Дана $f: \mathbb{R}^n \rightarrow \mathbb{R}$. Требуется найти $x^* \in \arg \min f$ итерационным методом с заданной точностью.

сквозной пример: квадратичная $\varphi(x) = \frac{1}{2}x^\top Ax - b^\top x$, $\mu = \mu_{\min}(A)$, $L = \mu_{\max}(A)$, $\kappa = L/\mu \gg 1$

Основные результаты

Определение 1

f гладкая с константой L , если $\|\nabla f(y) - \nabla f(x)\| \leq L \|y - x\|$; тогда f мажорирована квадратичной формой: $f(y) \leq f(x) + \langle \nabla f(x), y - x \rangle + \frac{L}{2} \|y - x\|^2$ (для выпуклой f — эквивалентность в обе стороны, prop:equiv в theory.md).

Определение 2

f сильно выпукла с константой μ , если $f(y) \geq f(x) + \langle \nabla f(x), y - x \rangle + \frac{\mu}{2} \|y - x\|^2$.

Число обусловленности: $\kappa = L/\mu$.

Теорема 3 (необходимые и достаточные условия экстремума)

Пусть f дифференцируема в точке x^* .

(а) Если x^* — локальный минимум, то $\nabla f(x^*) = 0$.

(б) Если f дважды дифференцируема в x^* и x^* — локальный минимум, то $\nabla^2 f(x^*) \succeq 0$.

(в) Если f дважды дифференцируема в окрестности x^* , $\nabla f(x^*) = 0$ и $\nabla^2 f(x^*) \succ 0$, то x^* — строгий локальный минимум.

$$x^{k+1} = x^k - \gamma_k \nabla f(x^k), \quad \gamma_k = \frac{1}{L}$$

Лемма 4 (спуск)

Пусть f L -гладка. Тогда $f(x - \frac{1}{L} \nabla f(x)) \leq f(x) - \frac{1}{2L} \|\nabla f(x)\|^2$.

Теорема 5 (сходимость градиентного спуска)

Пусть f L -гладкая, $x^{k+1} = x^k - \frac{1}{L} \nabla f(x^k)$, $R = \|x^0 - x^*\|$.

(а) Невыпуклый случай. f ограничена снизу: $f \geq f_* > -\infty$. Тогда

$$\min_{0 \leq k \leq N-1} \|\nabla f(x^k)\| \leq \sqrt{\frac{2L(f(x^0) - f_*)}{N}}.$$

(б) Выпуклый случай. f выпукла. Тогда для усреднённой точки $\bar{x}^N = \frac{1}{N} \sum_{k=1}^N x^k$ верно $f(\bar{x}^N) - f^* \leq \frac{LR^2}{2N}$.

(в) Сильно выпуклый случай. f μ -сильно выпукла. Тогда

$$f(x^N) - f^* \leq \frac{LR^2}{2} \min\left\{\frac{1}{N}, \left(1 - \frac{\mu}{L}\right)^N\right\}, \quad \|x^N - x^*\| \leq R \left(1 - \frac{\mu}{L}\right)^{N/2}.$$

Замечание 1 (существенность посылок)

Каждая посылка существенна: без липшицевости градиента метод расходится ($|x|^{2+\varepsilon}$); без ограниченности снизу градиент не обязан стремиться к нулю (линейная f); при $\gamma > 2/L$ – расходимость на $\frac{1}{2} \|x\|^2$ (при $\gamma = 2/L$ – периодические колебания); без сильной выпуклости скорость может быть сколь угодно малой.

Теорема 6 (точная оценка для сильно выпуклых гладких функций)

Пусть f дважды дифференцируема и $\mu I \preceq \nabla^2 f(x) \preceq LI$ для всех x . Тогда градиентный спуск с постоянным шагом γ сходится: $\|x^k - x^*\| \leq \|x^0 - x^*\| q^k$, $q(\gamma) = \max\{|1 - \gamma\mu|, |1 - \gamma L|\}$; минимум $q^* = \frac{\kappa-1}{\kappa+1}$ достигается при $\gamma^* = \frac{2}{L+\mu}$. Оценка неулучшаема.

$$N \approx \frac{\kappa}{2} \ln \frac{1}{\varepsilon} \quad \text{итераций} \quad (\kappa = 10^3 : \approx 3\,500)$$

Теорема 7 (нижние оценки)

(а) Для любых $L > 0$, $N \geq 1$ существует L -гладкая выпуклая f на $\mathbb{R}^n$ ($2N + 1 \leq n$) с точкой минимума x^* такая, что при $x^0 = 0$ для любого метода, генерирующего точки по правилу $x^k \in x^0 + \text{span}\{\nabla f(x^0), \dots, \nabla f(x^{k-1})\}$,

$$\min_{k=1, \dots, N} f(x^k) - f^* \geq \frac{3L \|x^0 - x^*\|^2}{32(N+1)^2}.$$

(б) Для любых $L \geq \mu > 0$, $N \geq 1$ существует L -гладкая μ -сильно выпуклая f на ℓ_2 с точкой минимума x^* такая, что при $x^0 = 0$ для любого такого метода

$$f(x^N) - f^* \geq \frac{\mu}{2} \left(\frac{\sqrt{\mathfrak{n}} - 1}{\sqrt{\mathfrak{n}} + 1} \right)^{2N} \|x^0 - x^*\|^2.$$

Вывод: градиентный спуск оптимален в классе гладких выпуклых; разрыв $O(\mathfrak{n})$ против $O(\sqrt{\mathfrak{n}})$ закрывается ускорением.

Чебышёвское ускорение

$$e^k = p_k(A)e^0, \quad p_k(0) = 1; \quad \min_{\lambda \in [\mu, L]} \max |p_k(\lambda)| \Rightarrow p_k^* = \frac{T_k(z(\lambda))}{T_k(z(0))}$$

$$\|e^k\| \leq q_k \|e^0\|, \quad q_k = \frac{2q^k}{1 + q^{2k}}, \quad q = \frac{\sqrt{\kappa} - 1}{\sqrt{\kappa} + 1}$$

(аппарат многочленов Чебышёва — предмет отдельного вопроса программы)

$$y^{(k+1)} = \omega_{k+1}(y^{(k)} - y^{(k-1)} + \gamma z^{(k)}) + y^{(k-1)}, \quad \omega_{k+1} = 2\nu \frac{T_k(\nu)}{T_{k+1}(\nu)}, \quad \nu = \frac{\mu_{\max} + \mu_{\min}}{\mu_{\max} - \mu_{\min}}$$

Теорема 8 (сходимость чебышёвских полуитераций)

Итерации удовлетворяют $y^{(k)} - x^* = p_k(A)(y^{(0)} - x^*)$ с чебышёвским p_k , и $\|y^{(k)} - x^*\| \leq q_k \|y^{(0)} - x^*\|$. Для точности ε достаточно $k \geq \frac{\ln(2/\varepsilon)}{2\sqrt{\xi}}$ итераций, $\xi = \mu_{\min}/\mu_{\max}$.

Сравнение: $\frac{\kappa}{2} \ln \frac{1}{\varepsilon}$ (стационарный шаг) против $\frac{\sqrt{\kappa}}{2} \ln \frac{2}{\varepsilon}$ (чебышёв).

$$x^{k+1} = x^k + \gamma_k h^k, \quad h^{k+1} = -\nabla \varphi(x^{k+1}) + \beta_k h^k, \quad \beta_k = \frac{\|\nabla \varphi(x^{k+1})\|^2}{\|\nabla \varphi(x^k)\|^2} \quad (1)$$

Теорема 9 (конечность сопряжённых градиентов)

Итерации (1) для квадратичной функции с положительно определённой A находят точный минимум за не более чем n шагов: если $\nabla \varphi(x^k) \neq 0$ при $k < n$, то $x^n = x^*$; в противном случае процесс останавливается раньше. Кроме того, x^k минимизирует φ на крыловском подпространстве $x^0 + \mathcal{K}_k$, $\mathcal{K}_k = \text{span}\{\nabla \varphi(x^0), A\nabla \varphi(x^0), \dots, A^{k-1}\nabla \varphi(x^0)\}$.

Теорема 10 (оценка сходимости CG)

Для итераций (1)

$$\|x^k - x^*\|_A \leq 2q^k \|x^0 - x^*\|_A, \quad q = \frac{\sqrt{\kappa} - 1}{\sqrt{\kappa} + 1},$$

где $\|u\|_A = \sqrt{\langle Au, u \rangle}$, $\mu = \mu_{\min}(A)$, $L = \mu_{\max}(A)$.

CG оптимален среди методов первого порядка и не требует знания спектра.

Метод	Итерации	Требует
Градиентный γ^*	$O(n \ln \frac{1}{\varepsilon})$	μ, L
Наискорейший спуск	как стационарный	ничего
Чебышёвские полуитерации	$O(\sqrt{n} \ln \frac{2}{\varepsilon})$	μ, L
Сопряжённые градиенты	$O(\sqrt{n} \ln \frac{1}{\varepsilon})$	ничего

Методы второго порядка и ускорение

$$x^{k+1} = x^k - \alpha \nabla f(x^k) + \beta(x^k - x^{k-1})$$

Теорема 11 (локальная сходимость тяжёлого шарика)

Пусть f дважды дифференцируема, x^* — точка минимума с $\mu I \preceq \nabla^2 f(x^*) \preceq LI$, $\mu > 0$, параметры удовлетворяют $0 \leq \beta < 1$, $0 < \alpha < \frac{2(1+\beta)}{L}$, и начальное приближение достаточно близко к x^* . Тогда существуют константа $c > 0$ и знаменатель $q \in (0, 1)$ такие, что $\|x^k - x^*\| \leq c(q + \delta)^k$ для любого наперёд заданного $\delta > 0$; при $\alpha^* = \frac{4}{(\sqrt{L} + \sqrt{\mu})^2}$, $\beta^* = \left(\frac{\sqrt{L} - \sqrt{\mu}}{\sqrt{L} + \sqrt{\mu}}\right)^2$ достигается оптимальный знаменатель $q = \frac{\sqrt{\kappa} - 1}{\sqrt{\kappa} + 1}$.

$$\begin{aligned}x^{k+1} &= y^k - \frac{1}{L} \nabla f(y^k), \\ y^{k+1} &= x^{k+1} + \frac{t_{k+1} - 1}{t_{k+2}} (x^{k+1} - x^k), \quad y^0 = x^0,\end{aligned}\tag{2}$$

$$t_{k+2} = \frac{1 + \sqrt{1 + 4t_{k+1}^2}}{2} \quad (\Leftrightarrow t_{k+2}^2 - t_{k+2} = t_{k+1}^2), \quad t_0 = 0, t_1 = 1.$$

Тяжёлый шарик vs Нестеров: градиент в x^k (локально) против градиента в y^k (глобально по нижним оценкам).

Теорема 12 (сходимость метода Нестерова)

Пусть f L -гладкая и выпукла, $R = \|x^0 - x^*\|$. Тогда итерации (2) удовлетворяют

$$f(x^N) - f^* \leq \frac{2LR^2}{(N+1)^2}.$$

Если дополнительно f μ -сильно выпукла, то перезапуск каждые $m = \lceil 4\sqrt{\kappa} \rceil$ итераций (сброс экстраполяции: $y \leftarrow x$) даёт

$$f(x^N) - f^* \leq 2LR^2 \left(\frac{1}{2}\right)^{2\lfloor N/m \rfloor},$$

то есть точность ε достигается за $N = O(\sqrt{\kappa} \ln \frac{LR^2}{\varepsilon})$ итераций. Обе оценки совпадают с нижними оценками по порядку.

$$x^{k+1} = x^k - [\nabla^2 f(x^k)]^{-1} \nabla f(x^k)$$

Теорема 13 (локальная квадратичная сходимость)

Пусть f μ -сильно выпукла, $\|\nabla^2 f(x) - \nabla^2 f(y)\| \leq M \|x - y\|$, $q_0 = \frac{M}{2\mu^2} \|\nabla f(x^0)\| < 1$. Тогда $\|x^k - x^*\| \leq \frac{2\mu}{M} q_0^{2^k}$.

Теорема 14 (Ньютона—Канторовича)

Пусть f дважды непрерывно дифференцируема в шаре $\Omega = \{x : \|x - x^0\| \leq r\}$, гессиан невырожден в x^0 , $\Gamma_0 = [\nabla^2 f(x^0)]^{-1}$ и

$$\|\Gamma_0 \nabla f(x^0)\| \leq \eta, \quad \|\Gamma_0 (\nabla^2 f(x) - \nabla^2 f(y))\| \leq K \|x - y\| \quad (x, y \in \Omega), \quad h := K\eta \leq \frac{1}{2}.$$

Тогда при $r \geq r_0 = \frac{1-\sqrt{1-2h}}{h} \eta$ (при $h = 1/2$ читается $r_0 = 2\eta$) в Ω существует решение x^* уравнения $\nabla f(x) = 0$, к которому сходится метод Ньютона, причём

$$\|x^k - x^*\| \leq \frac{1}{2^k} (2h)^{2^k} \frac{\eta}{h}.$$

Решение единственно в открытом шаре радиуса $r_1 = \frac{1+\sqrt{1-2h}}{h} \eta$. Для модифицированного процесса (гессиан заморожен: $x^{k+1} = x^k - \Gamma_0 \nabla f(x^k)$) при $h < 1/2$

$$\|x'^k - x^*\| \leq \frac{\eta}{h} (1 - \sqrt{1-2h})^{k+1}.$$

Условная оптимизация

$$\text{proj}_Q(y) = \arg \min_{x \in Q} \frac{1}{2} \|x - y\|^2$$

Теорема 15 (критерий проекции)

Пусть Q выпукло замкнуто. Тогда $x = \text{proj}_Q(y)$ тогда и только тогда, когда $\langle y - x, z - x \rangle \leq 0$ для всех $z \in Q$. В частности, $\|z - \text{proj}_Q(y)\|^2 + \|y - \text{proj}_Q(y)\|^2 \leq \|z - y\|^2$ для всех $z \in Q$.

Следствие (неэкспансивность): $\|\text{proj}_Q(y) - \text{proj}_Q(y')\| \leq \|y - y'\|$.

$$x^{k+1} = \text{proj}_Q(x^k - \frac{1}{L} \nabla f(x^k)) \quad (3)$$

Теорема 16 (сходимость PGD)

Пусть f выпукла и L -гладка на выпуклом замкнутом Q , x^* – минимум f на Q , $R = \|x^0 - x^*\|$. Тогда итерации (3) удовлетворяют

$$f(x^N) - f^* \leq \frac{LR^2}{2N}.$$

$$y^k = \arg \min_{y \in Q} \langle \nabla f(x^k), y \rangle, \quad x^{k+1} = x^k + \gamma_k(y^k - x^k), \quad \gamma_k = \frac{2}{k+2} \quad (4)$$

Теорема 17 (сходимость Франка—Вулфа)

Пусть f выпукла и L -гладкая на выпуклом компакте Q диаметра $R = \max_{x,y \in Q} \|x - y\|$, x^* — минимум. Тогда итерации (4) удовлетворяют


$$f(x^N) - f^* \leq \frac{2LR^2}{N+2}.$$

Оговорка: оценка $O(1/k^2)$ для сильно выпуклых функций, встречающаяся в изложениях, неверна — доказательство отбрасывает полезный член с μ ; контрпример $f(x) = \|x\|^2$ на симплексе с tie-breaking «свежая вершина» сходится как $\Theta(1/k)$ (измерено).

Постановка	Что минимизируется	Метод
Линейно-квадратичный регулятор	$\sum (x^\top Q x + u^\top R u)$	CG, Ньютон
Обратная задача	$\ Aq - f\ ^2$ (+ регуляризатор)	градиентный через сопряжённую задачу
Обучение модели	эмпирический риск	SGD + импульс (= тяжёлый шарик)
Задача на симплексе	гладкая выпуклая	Франк—Вулф (линейный оракул)

Численная иллюстрация

- Квадратичная задача, $\kappa = 10^3$: измеренный знаменатель градиентного спуска совпал с $q^* = (\kappa - 1)/(\kappa + 1)$.
- Тяжёлый шарик: $q \approx 0,94$, Нестеров (постоянный момент): $q \approx 0,97$ — против $q^* \approx 0,998$; выигрыш ≈ 30 раз.
- Стресс-тест: трёхчленная чебышёвская форма устойчива, множительная взрывается.
- FW на симплексе: $\Theta(1/k)$, наклон $-1,07$.



- Лемма спуска $\Rightarrow$ три режима сходимости градиентного спуска; все оценки точны по порядку.
- Плохая обусловленность — враг: $O(n)$ итераций; ускорение покупается чебышёвским набором, тяжёлым шариком, Нестеровым или CG — $O(\sqrt{n})$.
- Чебышёвская трёхчленная рекуррентность устойчива, множительная форма — нет.
- Ньютон: квадратичная сходимость локально; теорема Канторовича — полулокальная гарантия.
- Условная оптимизация: PGD (проекция) и Франк—Вулф (линейный оракул) — оба $O(1/k)$.