

Вопрос 10. Методы минимизации функций многих переменных

Конспект теории с полными доказательствами

Крохалев Е. М.

2026

Содержание

I. Основная часть	2
1. Постановка и мотивация	2
2. Определения и обозначения	3
3. Градиентный спуск	5
4. Точная линейная оценка и оптимальный шаг	8
5. Нижние оценки для методов первого порядка	9
6. Чебышёвское ускорение	10
7. Метод сопряжённых градиентов	12
8. Вычислительная сторона	13
9. Разобранные задачи	14
10. Вопросы, которые стоит ожидать	15
II. Расширенная часть	15
11. Метод тяжёлого шарика	15
12. Ускоренный метод Нестерова	17
13. Метод Ньютона	18
14. Условная оптимизация	20
14.1 Проекция на выпуклое множество	20
14.2 Метод проекции градиента	21
15. Метод Франка—Вулфа (условный градиент)	22
16. Негладкая оптимизация	23
17. Градиент функционала через сопряжённую задачу	23
18. Что почитать ещё: темы за рамками вопроса	24

Часть I.

Основная часть

1. Постановка и мотивация

Большинство задач математического моделирования сводится в конце концов к одной и той же вычислительной процедуре: найти минимум функции многих переменных. Три типовых источника такой постановки.

Оптимальное управление. Для дискретной линейной системы $x_{k+1} = Ax_k + Bu_k$ функционал качества

$$J = \sum_{k=0}^{N-1} (x_k^T Q x_k + u_k^T R u_k)$$

является квадратичной функцией совокупности управлений $u_0, \dots, u_{N-1}$ и начальных условий; задача оптимального управления — это задача о его минимуме. При доминировании одного из слагаемых (малый вес R — дешёвое управление, малый вес Q — слабый штраф за отклонение) гессиан функционала становится плохо обусловленным, и именно здесь методы минимизации начинают различаться по скорости на порядки.

Машинное обучение. Обучение — это минимизация эмпирического риска $\frac{1}{N} \sum_{i=1}^N \ell(h_w(x_i), y_i)$ по параметрам w модели; обучение нейронной сети — минимизация этой функции в пространстве размерности в миллионы. Метод, которым это делается на практике (стохастический градиентный спуск с импульсом), есть пересборка методов, разобранных в этом конспекте, — см. расширенную часть и вопрос 02 (ML и обратные задачи).

Обратные задачи. Восстановление параметров модели по измерениям сводится к минимизации функционала невязки между измеренным и модельным выходом; способ вычислить градиент такого функционала через сопряжённую задачу дан в расширенной части (раздел 17).

Формальная постановка этого вопроса программы: дана функция $f: \mathbb{R}^n \rightarrow \mathbb{R}$; требуется найти

$$x^* \in \arg \min_{x \in \mathbb{R}^n} f(x)$$

и построить итерационный метод, вычисляющий x^* с заданной точностью. Отдельно разбирается условная постановка $\min_{x \in Q} f(x)$ с выпуклым замкнутым Q (раздел 14) — это акцент лекции курса прошлого года.

Сквозной пример. Через весь конспект и через численные примеры ведётся одна задача: минимизация квадратичной функции

$$\varphi(x) = \frac{1}{2} x^T A x - b^T x, \quad \mu_{\min} I \preceq A \preceq \mu_{\max} I, \quad \kappa = \frac{\mu_{\max}}{\mu_{\min}},$$

с плохо обусловленной матрицей A (число обусловленности κ велико). Она — конечномерный образец функционала качества: та же структура $\frac{1}{2}$ (форма) — (линейная часть) и та же плохая обусловленность, что и у дискретного функционала качества управления выше, а главное — на квадратичной функции все оценки сходимости методов первого порядка точны и проверяются расчётом (пример 1 `examples.ipynb`).

Конспект двухчастный. Основная часть — градиентные методы и теория их скорости сходимости: лемма спуска, теорема о сходимости в трёх режимах, точная линейная оценка, нижние оценки, чебышёвское ускорение и метод сопряжённых градиентов. Расширенная

часть — методы второго порядка (Ньютон, Ньютон—Канторович), ускоренные методы (тяжёлый шарик, Нестеров), условная и негладкая оптимизация и приложение к обратным задачам.

2. Определения и обозначения

Все нормы — евклидовы, $\|x\| = \sqrt{\langle x, x \rangle}$; через I обозначен единичный оператор. Функция f называется **выпуклой**, если

$$f(\lambda x + (1 - \lambda)y) \leq \lambda f(x) + (1 - \lambda)f(y) \quad \forall x, y, \forall \lambda \in [0, 1].$$

Определение 2.1. Функция f **гладкая с константой L** (L -гладкая), если она дифференцируема и её градиент липшицев с константой L :

$$\|\nabla f(y) - \nabla f(x)\| \leq L \|y - x\| \quad \forall x, y. \quad (1)$$

Определение 2.2. Функция f **сильно выпукла с константой $\mu > 0$** (μ -сильно выпукла), если

$$f(y) \geq f(x) + \langle \nabla f(x), y - x \rangle + \frac{\mu}{2} \|y - x\|^2 \quad \forall x, y. \quad (2)$$

Обозначения. L — константа Липшица градиента (1); μ — константа сильной выпуклости (2); $\kappa = L/\mu \geq 1$ — число обусловленности задачи (так же, как в вопросе 11 о многочленах Чебышёва); x^* — точка минимума, $f^* = f(x^*)$; γ_k — шаг метода на итерации k . У сильно выпуклой функции минимум единствен (теорема 2.7).

Предложение 2.3 (эквивалентные формы). Для дифференцируемой f :

(а) гладкость (1) эквивалентна мажорированию квадратичной формой с кривизной L :

$$f(y) \leq f(x) + \langle \nabla f(x), y - x \rangle + \frac{L}{2} \|y - x\|^2; \quad (3)$$

(б) для дважды дифференцируемой f условие (1) равносильно $\nabla^2 f(x) \preceq LI$ для всех x ;

(в) сильная выпуклость (2) для дважды дифференцируемой f равносильна $\nabla^2 f(x) \succeq \mu I$ для всех x ;

(г) для гладкой выпуклой f сильная выпуклость (2) равносильна сильной монотонности градиента:

$$\langle \nabla f(y) - \nabla f(x), y - x \rangle \geq \mu \|y - x\|^2. \quad (4)$$

Доказательство. **(а)** Пусть $g(t) = f(x + t(y - x))$, $t \in [0, 1]$. Тогда $g'(t) = \langle \nabla f(x + t(y - x)), y - x \rangle$ и

$$f(y) - f(x) - \langle \nabla f(x), y - x \rangle = \int_0^1 \langle \nabla f(x + t(y - x)) - \nabla f(x), y - x \rangle dt \leq \int_0^1 Lt \|y - x\|^2 dt = \frac{L}{2} \|y - x\|^2$$

Обратно: из (3) для $y = x + h$, $h = td$,

$$f(x + td) - f(x) \leq t \langle \nabla f(x), d \rangle + \frac{Lt^2}{2} \|d\|^2,$$

аналогично снизу с $x \rightarrow x + td$, $y = x$: после перестановки и предельного перехода $t \rightarrow 0$ получаем $\langle \nabla f(x + td) - \nabla f(x), d \rangle \leq Lt \|d\|^2$, что при $d = y - x$ даёт (1).

(б) Если $\nabla^2 f \preceq LI$, то по формуле Тейлора с остатком в интегральной форме

$$\nabla f(y) - \nabla f(x) = \int_0^1 \nabla^2 f(x + t(y-x))(y-x) dt,$$

откуда (1). Обратно: применяя (1) к $y = x + td$ и устремляя $t \rightarrow 0$, получаем $\|\nabla^2 f(x)d\| \leq L\|d\|$ для всех d , то есть $\nabla^2 f(x) \preceq LI$.

(в) Достаточность: формула Тейлора с остатком в интегральной форме и $\nabla^2 f \succeq \mu I$ дают

$$f(y) = f(x) + \langle \nabla f(x), y-x \rangle + \int_0^1 (1-t) \langle \nabla^2 f(x + t(y-x))(y-x), y-x \rangle dt \geq f(x) + \langle \nabla f(x), y-x \rangle + \frac{\mu}{2} \|y-x\|^2$$

Необходимость: вычитая из (2) её же с переставленными x, y и применяя к разности формулу Тейлора, получаем $\langle \nabla^2 f(x)(y-x), y-x \rangle \geq \mu \|y-x\|^2$ в каждой точке x .

(г) Сильная монотонность следует из (2), применённого к паре (y, x) и (x, y) с последующим сложением. Обратно: для гладкой выпуклой f градиентное неравенство $f(x) \geq f(y) + \langle \nabla f(y), x-y \rangle$ (теорема 2.6 при $n = 1$ и линейности) вместе с (4) по цепочке

$$f(y) \geq f(x) + \langle \nabla f(x), y-x \rangle + \langle \nabla f(y) - \nabla f(x), y-x \rangle \geq f(x) + \langle \nabla f(x), y-x \rangle + \frac{\mu}{2} \|y-x\|^2$$

даёт (2). $\square$

Замечание 2.4. Запись обозначений у разных школ различается ровно вдвое по μ : у [12] сильная выпуклость вводится слагаемым $\vartheta \lambda (1-\lambda) \|x^1 - x^2\|^2$ в определении, что соответствует $\mu = 2\vartheta$; у [13] константа сильной выпуклости l совпадает с нашей μ . Формулы источников при цитировании переведены на обозначения определения 2.2.

Теорема 2.5 (необходимые и достаточные условия экстремума). Пусть f дифференцируема в точке x^* .

(а) Если x^* — локальный минимум, то $\nabla f(x^*) = 0$.

(б) Если f дважды дифференцируема в x^* и x^* — локальный минимум, то $\nabla^2 f(x^*) \succeq 0$.

(в) Если f дважды дифференцируема в окрестности x^* , $\nabla f(x^*) = 0$ и $\nabla^2 f(x^*) \succ 0$, то x^* — строгий локальный минимум.

Доказательство. **(а)** Для любого d и малых $t > 0$ по определению дифференцируемости $0 \leq f(x^* + td) - f(x^*) = t \langle \nabla f(x^*), d \rangle + o(t)$; деление на t и предельный переход дают $\langle \nabla f(x^*), d \rangle \geq 0$ для всех d , откуда $\nabla f(x^*) = 0$.

(б) Формула Тейлора с остатком в форме Пеано: $f(x^* + td) - f(x^*) = \frac{t^2}{2} \langle \nabla^2 f(x^*)d, d \rangle + o(t^2) \geq 0$; деление на t^2 и предельный переход дают $\langle \nabla^2 f(x^*)d, d \rangle \geq 0$ для всех d .

(в) Матрица $\nabla^2 f$ непрерывна, поэтому в некотором шаре U вокруг x^* выполнено $\nabla^2 f(x) \succeq \frac{\lambda_{\min}}{2} I$, где $\lambda_{\min} > 0$ — наименьшее собственное значение $\nabla^2 f(x^*)$. По формуле Тейлора с остатком в интегральной форме

$$f(x) - f(x^*) = \int_0^1 (1-t) \langle \nabla^2 f(x^* + t(x-x^*))(x-x^*), x-x^* \rangle dt \geq \frac{\lambda_{\min}}{4} \|x-x^*\|^2 > 0$$

для $x \in U, x \neq x^*$. $\square$

Теорема 2.6 (градиентное неравенство). Дифференцируемая f выпукла тогда и только тогда, когда

$$f(y) \geq f(x) + \langle \nabla f(x), y-x \rangle \quad \forall x, y. \quad (5)$$

Для выпуклой дифференцируемой f точка x^* — точка глобального минимума тогда и только тогда, когда $\nabla f(x^*) = 0$.

Доказательство. Необходимость (5): по определению выпуклости для $\lambda \in (0, 1)$

$$f(x + \lambda(y - x)) \leq f(x) + \lambda(f(y) - f(x)),$$

откуда $\frac{f(x + \lambda(y - x)) - f(x)}{\lambda} \leq f(y) - f(x)$; предельный переход $\lambda \rightarrow 0+$ даёт $\langle \nabla f(x), y - x \rangle \leq f(y) - f(x)$. Достаточность: применим (5) к паре (x, z) и (y, z) с $z = \lambda x + (1 - \lambda)y$ и сложим с весами λ и $1 - \lambda$:

$$\lambda f(x) + (1 - \lambda)f(y) \geq f(z) + (\lambda \nabla f(z) + (1 - \lambda) \nabla f(z))^\top (\lambda(x - z) + (1 - \lambda)(y - z)) = f(z),$$

поскольку $\lambda(x - z) + (1 - \lambda)(y - z) = 0$.

Критерий минимума: если $\nabla f(x^*) = 0$, то (5) с $x = x^*$ даёт $f(y) \geq f(x^*)$ для всех y . Обратно, если x^* — минимум, необходимое условие теоремы 2.5 (а) даёт $\nabla f(x^*) = 0$. $\square$

Теорема 2.7 (существование и единственность минимума). Пусть f непрерывно дифференцируема, μ -сильно выпукла и ограничена снизу. Тогда f имеет единственную точку глобального минимума x^* , причём $\|x - x^*\| \leq \frac{2}{\mu} \|\nabla f(x)\|$ для всех x и лебегово множество $\{x : f(x) \leq f(x^0)\}$ ограничено при любом x^0 .

Доказательство. Из (2) с $y = x$, $x = x^*$ (как только x^* появится) и необходимого условия $\nabla f(x^*) = 0$ (теорема 2.6 ниже) следовала бы оценка; сначала покажем существование. Минимизирующая последовательность $f(x_k) \rightarrow \inf f$ (а $\inf f > -\infty$ по условию) содержится в лебеговом множестве $X_\beta = \{f \leq f(x_0)\}$, $\beta = f(x_0)$. Из (2) для выпуклой дифференцируемой f (лемма о градиентном неравенстве, теорема 2.6) имеем

$$f(x) \geq f(x^0) + \langle \nabla f(x^0), x - x^0 \rangle + \frac{\mu}{2} \|x - x^0\|^2 \geq f(x^0) - \frac{1}{2\mu} \|\nabla f(x^0)\|^2 + \frac{\mu}{4} \|x - x^0\|^2,$$

где второе неравенство — минимизация квадратичной формы по x ; значит X_β ограничено. Замкнуто оно по непрерывности f ; по теореме Вейерштрасса непрерывная f достигает на X_β минимума в точке x^* , которая и есть глобальный минимум. Единственность: для двух минимумов x^*, x^{**} из (2)

$$f(x^{**}) \geq f(x^*) + \frac{\mu}{2} \|x^{**} - x^*\|^2 > f(x^*)$$

при $x^{**} \neq x^*$ — противоречие. Оценка $\|x - x^*\| \leq \frac{2}{\mu} \|\nabla f(x)\|$: из (2) с минимумом по y слева (f^*) и x — произвольной точкой имеем $f^* \geq f(x) + \langle \nabla f(x), x^* - x \rangle + \frac{\mu}{2} \|x^* - x\|^2$; отсюда $\frac{\mu}{2} \|x^* - x\|^2 \leq \|\nabla f(x)\| \|x^* - x\|$ по Коши—Буняковского. $\square$

3. Градиентный спуск

Основной метод этого вопроса. Направление наискорейшего локального убывания f — антиградиент: для единичного d

$$f(x + td) - f(x) = t \langle \nabla f(x), d \rangle + o(t),$$

и минимум $\langle \nabla f(x), d \rangle$ по d , $\|d\| = 1$, равен $-\|\nabla f(x)\|$ и достигается при $d = -\nabla f(x) / \|\nabla f(x)\|$. Метод градиентного спуска (англ. *gradient descent*) строит последовательность

$$x^{k+1} = x^k - \gamma_k \nabla f(x^k), \quad k = 0, 1, \dots \quad (6)$$

Непрерывный образец — градиентный поток $\dot{x} = -\nabla f(x)$, по которому $\frac{d}{dt}f(x(t)) = -\|\nabla f(x(t))\|^2 \leq 0$ и функция монотонно убывает вдоль траектории; метод (6) — дискретизация потока по схеме Эйлера.

Лемма 3.1 (спуск). Пусть f L -гладка. Тогда для любого x и любого $\gamma > 0$

$$f(x - \gamma \nabla f(x)) \leq f(x) - \gamma \left(1 - \frac{L\gamma}{2}\right) \|\nabla f(x)\|^2. \quad (7)$$

В частности, при $\gamma = 1/L$

$$f(x - \frac{1}{L} \nabla f(x)) \leq f(x) - \frac{1}{2L} \|\nabla f(x)\|^2. \quad (8)$$

Доказательство. Подставляем $y = x - \gamma \nabla f(x)$ в неравенство мажорирования (3):

$$f(y) \leq f(x) - \gamma \|\nabla f(x)\|^2 + \frac{L\gamma^2}{2} \|\nabla f(x)\|^2. \quad \square$$

Заметим: коэффициент у $\|\nabla f(x)\|^2$ в (7) максимален при $\gamma = 1/L$; при $\gamma \geq 2/L$ он неположителен и гарантии убывания f нет (метод может расходиться — см. замечание к теореме 3.2).

Теорема 3.2 (сходимость градиентного спуска). Пусть f L -гладка, $x^{k+1} = x^k - \frac{1}{L} \nabla f(x^k)$, $R = \|x^0 - x^*\|$, где x^* — точка минимума.

(а) Невыпуклый случай. f ограничена снизу: $f \geq f_* > -\infty$. Тогда

$$\min_{0 \leq k \leq N-1} \|\nabla f(x^k)\| \leq \sqrt{\frac{2L(f(x^0) - f_*)}{N}}. \quad (9)$$

(б) Выпуклый случай. f выпукла. Тогда для усреднённой точки $\bar{x}^N = \frac{1}{N} \sum_{k=0}^{N-1} x^k$

$$f(\bar{x}^N) - f_* \leq \frac{LR^2}{2N}. \quad (10)$$

(в) Сильно выпуклый случай. f μ -сильно выпукла. Тогда

$$f(x^N) - f_* \leq \frac{LR^2}{2} \min\left\{\frac{1}{N}, \left(1 - \frac{\mu}{L}\right)^N\right\}, \quad \|x^N - x^*\| \leq R \left(1 - \frac{\mu}{L}\right)^{N/2}. \quad (11)$$

Доказательство. По лемме 3.1 последовательность $f(x^k)$ не возрастает:

$$f(x^{k+1}) \leq f(x^k) - \frac{1}{2L} \|\nabla f(x^k)\|^2. \quad (12)$$

(а) Суммируем (12) по $k = 0, \dots, N-1$:

$$\frac{1}{2L} \sum_{k=0}^{N-1} \|\nabla f(x^k)\|^2 \leq f(x^0) - f(x^N) \leq f(x^0) - f_*.$$

Левая часть не меньше $\frac{N}{2L} \min_k \|\nabla f(x^k)\|^2$.

(б) Выпуклость дает $f(x) - f^* \leq \langle \nabla f(x), x - x^* \rangle$ (теорема 2.6), поэтому из (12)

$$f(x^k) - f^* \leq \langle \nabla f(x^k), x^k - x^* \rangle \leq L \langle x^k - x^{k+1}, x^k - x^* \rangle.$$

Используем тождество $2 \langle u, v \rangle = \|u\|^2 + \|v\|^2 - \|u - v\|^2$ с $u = x^k - x^{k+1}$, $v = x^k - x^*$:

$$f(x^k) - f^* \leq \frac{L}{2} \left(\|x^k - x^{k+1}\|^2 + \|x^k - x^*\|^2 - \|x^{k+1} - x^*\|^2 \right).$$

Суммируем по k ; слагаемые $\|x^k - x^*\|^2$ телескопируются:

$$\sum_{k=0}^{N-1} (f(x^k) - f^*) \leq \frac{L}{2} \left(\sum_{k=0}^{N-1} \|x^k - x^{k+1}\|^2 + R^2 \right). \quad (13)$$

С другой стороны, (12) дает $f(x^{k+1}) \geq f(x^k) - \frac{1}{2L} \|\nabla f(x^k)\|^2$; но нам нужна оценка суммы квадратов шагов: из (12) после суммирования

$$\sum_{k=0}^{N-1} \|x^k - x^{k+1}\|^2 = \frac{1}{L^2} \sum_{k=0}^{N-1} \|\nabla f(x^k)\|^2 \leq \frac{2}{L} (f(x^0) - f^*) \leq \frac{2}{L} \cdot \frac{LR^2}{2} = R^2,$$

где $f(x^0) - f^* \leq \frac{LR^2}{2}$ — это (3) с $y = x^*$, $x = x^0$. Подставляем в (13):

$$\sum_{k=0}^{N-1} (f(x^k) - f^*) \leq \frac{LR^2}{2} + \frac{LR^2}{2} = LR^2.$$

По выпуклости $f(\bar{x}^N) \leq \frac{1}{N} \sum_k f(x^k)$, и деление на N даёт (10).

(в) Сначала докажем оценку по аргументу. Сильная выпуклость в точке минимума ($\nabla f(x^*) = 0$) дает (предложение 2.3, г):

$$\langle \nabla f(x), x - x^* \rangle \geq \mu \|x - x^*\|^2.$$

Тогда из (12) и выпуклости ($f(x) - f^* \leq \langle \nabla f(x), x - x^* \rangle$):

$$\|x^{k+1} - x^*\|^2 = \|x^k - x^*\|^2 - \frac{2}{L} \langle \nabla f(x^k), x^k - x^* \rangle + \frac{1}{L^2} \|\nabla f(x^k)\|^2.$$

Оцениваем среднее слагаемое снизу через $\mu \|x^k - x^*\|^2$, а последнее — сверху через (12), откуда $\|\nabla f(x^k)\|^2 \leq 2L(f(x^k) - f(x^{k+1})) \leq 2L(f(x^k) - f^*)$:

$$\|x^{k+1} - x^*\|^2 \leq \left(1 - \frac{2\mu}{L}\right) \|x^k - x^*\|^2 + \frac{2}{L} (f(x^k) - f^*).$$

Другой путь: из сильной выпуклости $f(x^k) - f^* \geq \frac{\mu}{2} \|x^k - x^*\|^2$, и тогда

$$\|x^{k+1} - x^*\|^2 \leq \left(1 - \frac{2\mu}{L} + \frac{\mu}{L}\right) \|x^k - x^*\|^2 = \left(1 - \frac{\mu}{L}\right) \|x^k - x^*\|^2.$$

Итерация логарифма даёт $\|x^N - x^*\|^2 \leq (1 - \mu/L)^N R^2$. Далее, лемма 3.1 в точке x^* с $\gamma = 1/L$ в роли «шага по градиенту от x^* к x^k » не работает напрямую; вместо этого применим (3) с $x = x^*$, $y = x^k$: $f(x^k) - f^* \leq \frac{L}{2} \|x^k - x^*\|^2 \leq \frac{LR^2}{2} (1 - \mu/L)^N$. Оценка $\frac{LR^2}{2N}$ — это (10), усиленная монотонностью $f(x^N) \leq f(\bar{x}^N)$ не верна для произвольной точки, но $f(x^N) - f^* \leq \frac{1}{N} \sum_k (f(x^k) - f^*) \leq \frac{LR^2}{2N}$ следует из монотонности $f(x^N) \leq f(x^k)$ и уже доказанного. $\square$

Замечание 3.3 (существенность посылок). Каждая посылка теоремы 3.2 существенна, и контрпримеры явные [13]. **(1)** Без липшицевости градиента метод может расходиться: $f(x) = |x|^{2+\varepsilon}$ при $\gamma = 1$ уходит на бесконечность для x^0 вне компакта. **(2)** Без ограниченности снизу градиент не обязан стремиться к нулю: для линейной f при любом шаге $\|\nabla f(x^k)\| = \|\nabla f(x^0)\| > 0$. **(3)** Шаг $\gamma \geq 2/L$ разрушает сходимость даже на квадратичной $f(x) = \frac{1}{2}\|x\|^2$: при $\gamma = 2/L$ последовательность периодически колеблется, при $\gamma > 2/L$ расходится. **(4)** В невыпуклом случае сходимость по градиенту — всё, что можно: $f(x) = 1/(1 + \|x\|^2)$ даёт $\nabla f(x^k) \rightarrow 0$ без сходимости x^k ; без сильной выпуклости скорость может быть сколь угодно малой: для $f(x) = 1/x$ на $[1, \infty)$ при $\gamma = 1$ имеем $|f'(x^k)| = O(k^{-2/3})$ [13].

Все три режима теоремы 3.2 точны по порядку: в разделе 5 построены функции, на которых ни один метод, пользующийся только значениями и градиентами f , не сходится быстрее.

4. Точная линейная оценка и оптимальный шаг

Для сильно выпуклых гладких задач оценку (11) можно уточнить: сходимость по аргументу идёт с точным знаменателем прогрессии, зависящим от $\varkappa = L/\mu$.

Теорема 4.1 (точная оценка для сильно выпуклых гладких функций). Пусть f дважды дифференцируема и

$$\mu I \preceq \nabla^2 f(x) \preceq LI \quad \forall x. \quad (14)$$

Тогда градиентный спуск (6) с постоянным шагом γ сходится линейно: $\|x^k - x^*\| \leq \|x^0 - x^*\| q^k$ с

$$q(\gamma) = \max\{|1 - \gamma\mu|, |1 - \gamma L|\}. \quad (15)$$

Минимум знаменателя достигается при

$$\gamma^* = \frac{2}{L + \mu}, \quad q^* = q(\gamma^*) = \frac{L - \mu}{L + \mu} = \frac{\varkappa - 1}{\varkappa + 1}. \quad (16)$$

Оценка неулучшаема: на квадратичной функции с матрицей, спектр которой лежит в $[\mu, L]$, знаменатель прогрессии равен $q(\gamma)$ точно.

Доказательство. По формуле Тейлора с остатком в интегральной форме

$$\nabla f(x) = \int_0^1 \nabla^2 f(x^* + t(x - x^*)) (x - x^*) dt =: B(x) (x - x^*),$$

где $B(x) = \int_0^1 \nabla^2 f(\cdot) dt$ симметрична и по (14) удовлетворяет $\mu I \preceq B(x) \preceq LI$. Тогда

$$x^{k+1} - x^* = (I - \gamma B(x^k))(x^k - x^*),$$

и, так как собственные значения $I - \gamma B$ по модулю не превосходят $\max\{|1 - \gamma\mu|, |1 - \gamma L|\}$, получаем (15). Минимаксная задача $\min_{\gamma} \max\{|1 - \gamma\mu|, |1 - \gamma L|\}$ решается уравнением $1 - \gamma\mu = \gamma L - 1$, откуда (16).

Неулучшаемость: возьмём $f(x) = \frac{1}{2}x^T A x$ с $A = \text{diag}(L, \mu)$, $x^0 = (1, 1)^T$. Тогда $x^k = ((1 - \gamma L)^k, (1 - \gamma\mu)^k)^T$, и покомпонентные сходимости точно $|1 - \gamma L|$ и $|1 - \gamma\mu|$; евклидова норма даёт $q(\gamma)$ асимптотически (при $k \rightarrow \infty$ медленная компонента доминирует). $\square$

Замечание 4.2. Два вывода из формулы $q^* = (\varkappa - 1)/(\varkappa + 1)$. **(1) Число итераций.** Для точности ε по аргументу достаточно $N \approx \frac{\varkappa}{2} \ln \frac{R}{\varepsilon}$ итераций: $q^* = 1 - \frac{2}{\varkappa + 1} \leq e^{-2/(\varkappa + 1)}$, и $(q^*)^N \leq \varepsilon$ при $N \geq \frac{\varkappa + 1}{2} \ln \frac{1}{\varepsilon}$. При $\varkappa = 10^3$ это сотни итераций — против единиц у методов раздела 6.

(2) Овражная структура. При $\kappa \gg 1$ линии уровня f вытянуты вдоль собственных направлений B с малыми собственными значениями; траектория спуска зигзагом пересекает овраг, и каждый шаг продвигает по длине лишь на $O(1/\kappa)$ долю расстояния. Пример 1 `examples.ipynb` измеряет фактический знаменатель на задаче с $\kappa = 10^3$: он совпадает с q^* из (16).

5. Нижние оценки для методов первого порядка

Теорема 3.2 давала оценки сверху. Покажем, что по порядку они точны: ни один метод, использующий только оракулы значения и градиента, не может сходиться быстрее. Формулировки и функций-«подсадки» — из [37], упр. 1.3; доказательство — классическая схема Немировского—Юдина в воспроизведении для этих конкретных семейств.

Теорема 5.1 (нижние оценки). **(а)** Существует L -гладкая выпуклая f с минимумом f^* и точкой минимума x^* , $\|x^0 - x^*\| \leq R$, такая что для любого метода, генерирующего точки x^k по правилу $x^k \in x^0 + \text{span}\{\nabla f(x^0), \dots, \nabla f(x^{k-1})\}$,

$$f(x^N) - f^* \geq \frac{3LR^2}{32(N+1)^2}, \quad N < n. \quad (17)$$

(б) Для любых $L \geq \mu > 0$ существует L -гладкая μ -сильно выпуклая f с $\|x^0 - x^*\| \leq R$ такая, что

$$f(x^N) - f^* \geq \frac{\mu R^2}{2} \left(\frac{\sqrt{\mu} - 1}{\sqrt{\mu} + 1} \right)^{2N}. \quad (18)$$

Доказательство. **(а)** Рассмотрим семейство квадратичных форм на $\mathbb{R}^{2N+2}$, $m = 2N + 2$:

$$f_m(x) = \frac{L}{4} \left(\frac{1}{2}x_1^2 + \frac{1}{2}x_m^2 + \sum_{i=1}^{m-1} (x_i - x_{i+1})^2 - x_1 \right),$$

— «трёхдиагональная» форма (та же матрица, что в сквозном примере раздела 6 с константами по L). Матрица A_m этой формы имеет собственные значения

$$\lambda_i = L \left(1 - \cos \frac{\pi i}{m+1} \right), \quad i = 1, \dots, m,$$

с относящимися к ним собственными векторами $v_i \propto (\sin \frac{\pi i}{m+1}, \dots, \sin \frac{\pi i m}{m+1})$. При $x^0 = 0$ градиент $\nabla f_m(x) = A_m x - \frac{L}{4} e_1$ имеет поддержку в первых $k+1$ координатах, если x поддержан в первых k ; индукцией по k точка x^k любого метода из условия поддержана в первых $k+1$ координатах, и траектория не зависит от m , пока $m \geq 2N + 2$. Взяв $m = 2N + 2$ и оценивая минимум по последней координате (которая равна нулю на траектории длины $N + 1$), после вычисления f^* прямым минимизацией по формуле для обратной трёхдиагональной матрицы получаем (17); вычисление громоздко, но элементарно и воспроизведено в [37], упр. 1.3.

(б) Добавим сильную выпуклость: $f(x) = f_m(x) + \frac{\mu}{2} \|x\|^2$ с тем же A_m и $m = 2N + 2$. Теперь матрица $\mu I + A_m$ имеет собственные значения $\mu + \lambda_i \in [\mu, \mu + 2L]$, и аналогичная поддержка даёт оценку по последней координате, сводящуюся к (18) после подстановки собственных значений и нормировки R . $\square$

Замечание 5.2. Оценка (18) сравнима с верхней (11): по порядку в показателе экспоненты обе дают $O(\kappa \ln(1/\varepsilon))$ итераций градиентного спуска. Разрыв между верхней оценкой $(1 - 1/\kappa)^N$ и нижней $(1 - 2/\sqrt{\kappa})^{2N} \approx (1 - 1/\sqrt{\kappa})^{2N}$ закрывается ускоренными методами разделов 6 и 12: они сходятся со знаменателем $1 - O(1/\sqrt{\kappa})$ и совпадают с нижней оценкой по порядку.

6. Чебышёвское ускорение

Возвращаемся к квадратичной задаче — сквозному примеру. Здесь теорема 4.1 точна, и вопрос «можно ли обойти знаменатель $(\varkappa - 1)/(\varkappa + 1)$, не прибегая к глобальным методам второго порядка» имеет конструктивный ответ: можно, за $O(\sqrt{\varkappa})$ итераций вместо $O(\varkappa)$, если менять шаг от итерации к итерации по правилу, заданному многочленами Чебышёва. Аппарат минимаксных полиномов с нормировкой $p(0) = 1$ построен в вопросе 11 (многочлены Чебышёва I рода); здесь он используется и развивается.

Постановка: $\varphi(x) = \frac{1}{2}x^T A x - b^T x$, A симметрична положительно определена, $\text{sp } A \subseteq [\mu_{\min}, \mu_{\max}]$, $\varkappa = \mu_{\max}/\mu_{\min}$. Градиентный метод с переменным шагом

$$x^{k+1} = x^k - \gamma_k \nabla \varphi(x^k), \quad \nabla \varphi(x) = Ax - b, \quad (19)$$

порождает ошибку $e^k = x^k - x^*$, удовлетворяющую $e^{k+1} = (I - \gamma_k A)e^k$. После k шагов $e^k = p_k(A)e^0$ с $p_k(\lambda) = \prod_{j=0}^{k-1} (1 - \gamma_j \lambda)$, $p_k(0) = 1$; выбор шагов, минимизирующий $\|e^k\|$, — это задача о наименее уклоняющемся от нуля многочлене на спектре (разобрана в вопросе 11): решение $p_k^*(\lambda) = T_k(z(\lambda))/T_k(z(0))$, где

$$z(\lambda) = \frac{\mu_{\max} + \mu_{\min} - 2\lambda}{\mu_{\max} - \mu_{\min}},$$

а шаги $\gamma_j = 1/\lambda_j$ — обратные величины к корням p_k^* (чебышёвский набор параметров, вопрос 11). Оценка:

$$\|e^k\| \leq q_k \|e^0\|, \quad q_k = \frac{2\sigma^k}{1 + \sigma^{2k}}, \quad \sigma = \frac{\sqrt{\varkappa} - 1}{\sqrt{\varkappa} + 1}, \quad (20)$$

и $q_k \leq 2\sigma^k$: линейная сходимость со знаменателем $1 - 2/\sqrt{\varkappa}$.

Прямая реализация — перемножение сомножителей $(I - \gamma_j A)$ — на компьютере не работает: при $\varkappa \gtrsim 10^2$ погрешность округления съедает результат раньше, чем q_k достигает 10^{-6} (измерено в вопросе 11, пример 4; теоретическая оговорка — [09], §6 п. 2: промежуточные операторы $I - \gamma_j A$ имеют норму, большую единицы, и произведение переполняется при неудачном порядке сомножителей). Рабочая форма — трёхчленная рекуррентность по T_k , метод чебышёвских полуитераций (англ. *Chebyshev semi-iterative method*) [02]:

$$\begin{aligned} y^{(k+1)} &= \omega_{k+1} \left(y^{(k)} - y^{(k-1)} + \gamma z^{(k)} \right) + y^{(k-1)}, \\ z^{(k)} &= b - Ay^{(k)} = -\nabla \varphi(y^{(k)}), \\ \gamma &= \frac{2}{\mu_{\max} + \mu_{\min}}, \quad \mu = \frac{\mu_{\max} + \mu_{\min}}{\mu_{\max} - \mu_{\min}}, \\ \omega_{k+1} &= 2\mu \frac{T_k(\mu)}{T_{k+1}(\mu)}, \quad y^{(1)} = y^{(0)} + \gamma z^{(0)}. \end{aligned} \quad (21)$$

Теорема 6.1 (сходимость чебышёвских полуитераций). Итерации (21) удовлетворяют

$$y^{(k)} - x^* = p_k(A) (y^{(0)} - x^*), \quad p_k(\lambda) = \frac{T_k(z(\lambda))}{T_k(z(0))},$$

и потому $\|y^{(k)} - x^*\| \leq q_k \|y^{(0)} - x^*\|$ с q_k из (20). Для точности ε по аргументу достаточно

$$k \geq \frac{\ln(2/\varepsilon)}{2\sqrt{\xi}}, \quad \xi = \frac{\mu_{\min}}{\mu_{\max}} = \frac{1}{\varkappa}, \quad (22)$$

итераций: сравните с $\frac{\varkappa}{2} \ln \frac{1}{\varepsilon}$ у стационарного шага (теорема 4.1).

Доказательство. Многочлены ошибок рекуррентности. Обозначим $e^{(k)} = y^{(k)} - x^*$; так как $z^{(k)} = -Ae^{(k)}$ и $e^{(1)} = (I - \gamma A)e^{(0)}$, первый шаг совпадает с $p_1(\lambda) = 1 - \gamma\lambda$. Для $k \geq 1$ вычтем из (21) тождество $x^* = \omega_{k+1}(x^* - x^* + 0) + x^*$ (так как $b - Ax^* = 0$):

$$e^{(k+1)} = \omega_{k+1}(e^{(k)} - e^{(k-1)} - \gamma Ae^{(k)}) + e^{(k-1)}. \quad (23)$$

Пусть p_k — многочлены, рекуррентно заданные

$$p_{k+1}(\lambda) = \omega_{k+1}(p_k(\lambda) - p_{k-1}(\lambda) - \gamma\lambda p_k(\lambda)) + p_{k-1}(\lambda), \quad p_0 \equiv 1, \quad p_1(\lambda) = 1 - \gamma\lambda.$$

По индукции $e^{(k)} = p_k(A)e^{(0)}$: база $k = 0, 1$ уже проверена, а шаг индукции — подстановка $e^{(j)} = p_j(A)e^{(0)}$ в (23). Введём многочлены

$$q_k(\lambda) = \frac{T_k(z(\lambda))}{T_k(\mu)}, \quad z(\lambda) = \frac{\mu_{\max} + \mu_{\min} - 2\lambda}{\mu_{\max} - \mu_{\min}}, \quad \mu = z(0) = \frac{\mu_{\max} + \mu_{\min}}{\mu_{\max} - \mu_{\min}}.$$

По определению γ и μ имеем $\mu\gamma\lambda = \frac{\mu_{\max} + \mu_{\min}}{\mu_{\max} - \mu_{\min}} \cdot \frac{2\lambda}{\mu_{\max} + \mu_{\min}} = \frac{2\lambda}{\mu_{\max} - \mu_{\min}}$, так что

$$z(\lambda) = \mu - \frac{2\lambda}{\mu_{\max} - \mu_{\min}} = \mu(1 - \gamma\lambda). \quad (24)$$

Проверим, что q_k удовлетворяют той же рекуррентности, что и p_k , с теми же начальными условиями; тогда $p_k \equiv q_k$. База: $q_0 \equiv 1 = p_0$ и $q_1(\lambda) = z(\lambda)/\mu = 1 - \gamma\lambda = p_1(\lambda)$ по (24). Шаг: подставим q в правую часть рекуррентности, группируя слагаемые как $\omega_{k+1}(1 - \gamma\lambda)q_k(\lambda) + (1 - \omega_{k+1})q_{k-1}(\lambda)$. Первое слагаемое по (24) равно

$$\frac{2\mu T_k(\mu)}{T_{k+1}(\mu)} \cdot \frac{z(\lambda)}{\mu} \cdot \frac{T_k(z(\lambda))}{T_k(\mu)} = \frac{2z(\lambda) T_k(z(\lambda))}{T_{k+1}(\mu)}.$$

Второе: из определения ω_{k+1} и трёхчленной рекуррентности $T_{k+1}(\mu) = 2\mu T_k(\mu) - T_{k-1}(\mu)$ следует

$$1 - \omega_{k+1} = \frac{T_{k+1}(\mu) - 2\mu T_k(\mu)}{T_{k+1}(\mu)} = -\frac{T_{k-1}(\mu)}{T_{k+1}(\mu)}, \quad (1 - \omega_{k+1})q_{k-1}(\lambda) = -\frac{T_{k-1}(z(\lambda))}{T_{k+1}(\mu)}.$$

Сумма по трёхчленной рекуррентности для T равна $(2z(\lambda)T_k(z(\lambda)) - T_{k-1}(z(\lambda)))/T_{k+1}(\mu) = T_{k+1}(z(\lambda))/T_{k+1}(\mu) = q_{k+1}(\lambda)$. Индукция завершена: $e^{(k)} = q_k(A)e^{(0)}$.

Оценка (20) — теорема о наименее уклоняющихся многочленах из вопроса 11 (доказательство там). Оценка итераций: из $q_k \leq 2\sigma^k$ условие $q_k \leq \varepsilon$ обеспечивается $\sigma^k \leq \varepsilon/2$; так как $-\ln \sigma = \ln \frac{\sqrt{\varkappa}+1}{\sqrt{\varkappa}-1} = \ln(1 + \frac{2}{\sqrt{\varkappa}-1}) \geq \frac{2}{\sqrt{\varkappa}}$, достаточно $k \geq \sqrt{\varkappa} \ln(2/\varepsilon)/2$; в обозначениях [09] $\xi = 1/\varkappa$ это формула (22). $\square$

Замечание 6.2 (почему рекуррентная форма устойчива). Множительная форма $e^k = \prod (I - \gamma_j A)e^0$ и рекуррентная (21) алгебраически эквивалентны, но численно — нет. Коэффициенты $\omega_{k+1} = 2\mu T_k(\mu)/T_{k+1}(\mu)$ при $\mu = (\varkappa + 1)/(\varkappa - 1) > 1$ убывают как $2\mu \cdot T_k(\mu)/T_{k+1}(\mu) \approx 2\mu/(2\mu) = 1$ (так как $T_{k+1}(\mu)/T_k(\mu) \rightarrow \mu + \sqrt{\mu^2 - 1} > \mu$), то же остаются ограниченными; все промежуточные векторы рекуррентности — выпуклые комбинации с ограниченными коэффициентами, и ошибки округления не накапливаются множительно (измерение — пример 2 examples.ipynb: рекуррентная форма достигает 10^{-6} при $\varkappa = 10^2$ там, где множительная останавливается на $8 \cdot 10^{-6}$ по погрешности округления; в вопросе 11 показано, что при $\varkappa \gtrsim 10^2$ множительная форма вообще не достигает 10^{-6}).

Замечание 6.3 (что нужно знать для чебышёвского ускорения). Границы спектра $\mu_{\min}, \mu_{\max}$. Оценка спектра — отдельная вычислительная задача; квадратичный метод сопряжённых

градиентов даёт тот же закон $\sqrt{\gamma}$ без всякого знания спектра (раздел 7), и в этом его практическое преимущество [02].

7. Метод сопряжённых градиентов

Метод сопряжённых градиентов (англ. *conjugate gradients*, CG) решает ту же квадратичную задачу со знаменателем $1-2/\sqrt{\kappa}$, но адаптивно: каждое направление строится из текущего градиента и предыдущего направления, без оценок спектра.

Определение 7.1. Направления $h^0, \dots, h^m$ *A-сопряжены*, если $\langle Ah^i, h^j \rangle = 0$ при $i \neq j$.

Метод строит последовательность

$$\begin{aligned} x^{k+1} &= x^k + \gamma_k h^k, & \gamma_k &= \arg \min_{\gamma} \varphi(x^k + \gamma h^k), \\ h^{k+1} &= -\nabla \varphi(x^{k+1}) + \beta_k h^k, & \beta_k &= \frac{\|\nabla \varphi(x^{k+1})\|^2}{\|\nabla \varphi(x^k)\|^2}, \end{aligned} \quad (25)$$

с начальными условиями $h^0 = -\nabla \varphi(x^0)$; шаг γ_k — точный одномерный минимум, выписываемый явно: $\gamma_k = -\langle \nabla \varphi(x^k), h^k \rangle / \langle Ah^k, h^k \rangle$.

Лемма 7.2 (сопряжённость и ортогональность). Для итераций (25) при $k < n$:

- (а) $\langle \nabla \varphi(x^{k+1}), \nabla \varphi(x^j) \rangle = 0$ для всех $j \leq k$;
- (б) направления $h^0, \dots, h^{k+1}$ *A-сопряжены*;
- (в) $\text{span}\{h^0, \dots, h^k\} = \text{span}\{\nabla \varphi(x^0), \dots, \nabla \varphi(x^k)\}$.

Доказательство. Индукция по k . База: $h^0 = -\nabla \varphi(x^0)$, (а) и (б) пусты или очевидны, (в) — тривиально.

Шаг: пусть утверждения верны до номера k включительно. Одномерный минимум по γ даёт необходимое условие $\langle \nabla \varphi(x^{k+1}), h^k \rangle = 0$. Для $j < k$ по индукции $\nabla \varphi(x^{k+1}) = \nabla \varphi(x^j) + \sum_{i=j}^k \gamma_i Ah^i$ (телескопическая сумма $\gamma_i Ah^i = A(x^{i+1} - x^i)$); скалярно умножая на h^j и используя $\langle \nabla \varphi(x^j), h^j \rangle = 0$ (одномерный минимум на шаге j) и *A-сопряжённость* h^i при $i > j$, получаем $\langle \nabla \varphi(x^{k+1}), h^j \rangle = 0$. По (в) индукции $\nabla \varphi(x^j) \in \text{span}\{h^0, \dots, h^j\}$, поэтому из $\langle \nabla \varphi(x^{k+1}), h^i \rangle = 0$ для $i \leq k$ следует (а) для пары $(k+1, j)$, $j \leq k$: вектор $\nabla \varphi(x^j)$ — комбинация $h^0, \dots, h^j$.

Для (б): $\langle Ah^{k+1}, h^j \rangle = \langle -\nabla \varphi(x^{k+1}) + \beta_k h^k, Ah^j \rangle$. При $j = k$: $\langle Ah^k, h^k \rangle \neq 0$, а $\langle \nabla \varphi(x^{k+1}), Ah^k \rangle = 0$, так как $Ah^k = (\nabla \varphi(x^{k+1}) - \nabla \varphi(x^k))/\gamma_k$ и оба скалярных произведения с $\nabla \varphi(x^{k+1})$ равны нулю по (а); при $j < k$: $\langle h^k, Ah^j \rangle = 0$ по индукции, а $\langle \nabla \varphi(x^{k+1}), Ah^j \rangle = 0$, так как $Ah^j \in \text{span}\{\nabla \varphi(x^j), \nabla \varphi(x^{j+1})\}$ по той же телескопической формуле и (а) применимо.

(в): $h^{k+1} \in \text{span}\{\nabla \varphi(x^{k+1}), h^k\} \subset \text{span}\{\nabla \varphi(x^0), \dots, \nabla \varphi(x^{k+1})\}$; обратное включение — из невырожденности треугольного перехода. $\square$

Теорема 7.3 (конечность сопряжённых градиентов). Итерации (25) для квадратичной функции с положительно определённой A находят точный минимум за не более чем n шагов: если $\nabla \varphi(x^k) \neq 0$ при $k < n$, то $x^n = x^*$; в противном случае процесс останавливается раньше. Кроме того, x^k минимизирует φ на крыловском подпространстве

$$x^0 + \mathcal{K}_k, \quad \mathcal{K}_k = \text{span}\{\nabla \varphi(x^0), A\nabla \varphi(x^0), \dots, A^{k-1}\nabla \varphi(x^0)\}.$$

Доказательство. Лемма 7.2 (а) даёт ортогональность $n + 1$ градиентов в n -мерном пространстве; значит, $\nabla\varphi(x^n) = 0$, а так как φ сильно выпукла, $\nabla\varphi(x^n) = 0$ влечёт $x^n = x^*$.

Оптимальность на $\mathcal{K}_k$: по лемме 7.2 (в) $x^k = x^0 + \sum_{i < k} \gamma_i h^i \in x^0 + \mathcal{K}_k$. Для произвольного $y = x^0 + \sum_{i < k} c_i h^i$ разложим

$$\varphi(y) = \varphi(x^k) + \langle \nabla\varphi(x^k), y - x^k \rangle + \frac{1}{2} \langle A(y - x^k), y - x^k \rangle.$$

Так как $y - x^k$ — комбинация $h^0, \dots, h^{k-1}$, первое слагаемое равно нулю (каждое $\langle \nabla\varphi(x^k), h^i \rangle = 0$ по лемме 7.2, (а) и $h^i \in \text{span}$ прошлых градиентов), второе неотрицательно. Значит, $\varphi(y) \geq \varphi(x^k)$, равенство только при $y = x^k$. $\square$

Теорема 7.4 (оценка сходимости CG). Для итераций (25)

$$\|x^k - x^*\|_A \leq 2 \sqrt{\frac{L}{\mu}} q^k \|x^0 - x^*\|_A, \quad q = \frac{\sqrt{\kappa} - 1}{\sqrt{\kappa} + 1}, \quad (26)$$

где $\|u\|_A = \sqrt{\langle Au, u \rangle}$, $\mu = \mu_{\min}(A)$, $L = \mu_{\max}(A)$.

Доказательство. По теореме 7.3 x^k минимизирует φ на $x^0 + \mathcal{K}_k$; следовательно, $e^k = x^k - x^* = p_k(A)e^0$ для некоторого многочлена p_k степени $\leq k$ с $p_k(0) = 1$ (каждый вектор крыловского подпространства есть $q(A)\nabla\varphi(x^0)$ с $q(0) = 1$ — любым; условие $p_k(0) = 1$ обеспечивает представление ошибки именно через e^0). Поэтому

$$\|e^k\|_A^2 = \min_{\substack{p(0)=1 \\ \deg p \leq k}} \langle Ap(A)^2 e^0, e^0 \rangle \leq \left(\max_{\lambda \in [\mu, L]} |p(\lambda)| \right)^2 \|e^0\|_A^2$$

для любого допустимого p ; берём чебышёвский $p(\lambda) = T_k(z(\lambda))/T_k(z(0))$ из раздела 6, для которого максимум равен $1/T_k(\mu)$, а $T_k(\mu) \geq \frac{1}{2}(\mu + \sqrt{\mu^2 - 1})^k \geq \frac{1}{2}(\frac{\sqrt{\kappa}+1}{\sqrt{\kappa}-1})^k$. Подстановка даёт (26). $\square$

Замечание 7.5 (оптимальность CG). Оценка (26) неуллучшаема: любой метод, точки которого лежат в $x^0 + \text{span}\{\nabla\varphi(x^0), \dots, \nabla\varphi(x^{k-1})\}$ (все методы первого порядка таковы), допускает задачу с $\|x^k - x^*\|_A \geq c q^k$ [13]. CG совпадает с нижней оценкой теоремы 5.1 по порядку и потому оптимален в классе методов первого порядка — при том что ему не требуется знание спектра, в отличие от чебышёвских полуитераций (21) [02].

8. Вычислительная сторона

Все числа этой таблицы — из теорем этого конспекта; их проверка расчётом — в `examples.ipynb`.

Что покупает каждый метод (квадратичная задача, $\kappa = L/\mu$, точность ε по аргументу).

Метод	Итерации	Итерация стоит	Требуется	Раздел
Градиентный, $\gamma = 1/L$	$O(\kappa \ln \frac{1}{\varepsilon})$	1 градиент	ничего	3
Градиентный, $\gamma^* = 2/(L + \mu)$	$\frac{\kappa}{2} \ln \frac{1}{\varepsilon}$	1 градиент	μ, L	4
Наискорейший спуск	не лучше стационарного	1 градиент + 1D-поиск	ничего	9
Чебышёвские полуитерации	$\frac{\sqrt{\kappa}}{2} \ln \frac{2}{\varepsilon}$	1 умножение A	μ, L	6
Сопряжённые градиенты	$O(\sqrt{\kappa} \ln \frac{1}{\varepsilon})$	1 умножение A	ничего	7
Тяжёлый шарик	$O(\sqrt{\kappa} \ln \frac{1}{\varepsilon})$ локально	1 градиент	μ, L	11
Нестерова (ускоренный)	$O(\sqrt{\kappa} \ln \frac{1}{\varepsilon})$	1 градиент	μ, L	12
Ньютон	$O(\ln \ln \frac{1}{\varepsilon})$ локально	гессиан + решение системы	хорошее x^0	13

Три практических замечания.

(1) Наискорейший спуск не ускоряет градиентный. Точная одномерная минимизация по γ даёт на квадратичной задаче тот же асимптотический знаменатель $(\kappa - 1)/(\kappa + 1)$, что и стационарный шаг γ^* (задача 2 раздела 9; теорема с неравенством Канторовича — [13]). Выбор шага — не то место, где покупается ускорение.

(2) Оценка L на практике. Константу L часто не знают; стандартный приём — бэктрекинг: стартовать с грубой оценки и дробить $\gamma \leftarrow \gamma/2$, пока не выполнится условие Армихо $f(x - \gamma \nabla f(x)) \leq f(x) - \frac{\gamma}{2} \|\nabla f(x)\|^2$ (оно гарантирует лемму спуска). Все оценки этого конспекта сохраняются с заменой L на удвоенную найденную константу; автоматическая адаптация к неизвестной гладкости — содержание универсального градиентного спуска [37], §5.

(3) Большая размерность. Память $O(n)$ у всех методов таблицы, кроме Ньютона ($O(n^2)$ на гессиан и его факторизацию); при n в миллионы это решающий аргумент за методы первого порядка и против ньютоновских — см. вопрос 02 (ML и обратные задачи).

9. Разобранные задачи

Задача 9.1. Квадратичная функция $\varphi(x) = \frac{1}{2}x^T A x - b^T x$, $\text{sp } A = [\mu, L]$, $\kappa = L/\mu = 10^3$. Найти оптимальный постоянный шаг градиентного спуска и число итераций до $\|x^N - x^*\| \leq 10^{-3} \|x^0 - x^*\|$.

Решение. По теореме 4.1 $\gamma^* = 2/(L + \mu)$, $q^* = (\kappa - 1)/(\kappa + 1) = 999/1001$. Условие $(q^*)^N \leq 10^{-3}$: $N \geq \ln 10^3 / \ln(1001/999) \approx 6\,907/0,002 \approx 3\,454$ (точное число считается в примере 1 `examples.ipynb`). Чебышёвское ускорение (теорема 6.1) требует $N \geq \frac{\sqrt{\kappa}}{2} \ln \frac{2}{\varepsilon} \approx \frac{\sqrt{1000}}{2} \ln 2000 \approx 120$ итераций — на порядок меньше; сопряжённые градиенты — того же порядка, что и чебышёв, но без знания спектра.

Задача 9.2. Наискорейший спуск на квадратичной функции с $A = \text{diag}(L, \mu)$, $x^0 = (L^{-1/2}, \mu^{-1/2})$. Показать, что последовательные направления ортогональны и найти знаменатель прогрессии по f .

Решение. Одномерный минимум: $\gamma_k = \|\nabla \varphi(x^k)\|^2 / \langle A \nabla \varphi(x^k), \nabla \varphi(x^k) \rangle$. Ортогональность последовательных направлений — необходимое условие одномерного минимума: $\frac{d}{d\gamma} f(x^{k+1} + \gamma h^k)|_{\gamma'=0} = 0$ при $\gamma' = 0$ даёт $\langle \nabla f(x^{k+1}), h^k \rangle = 0$, а $h^k = -\nabla f(x^k)$. Двумерный случай даёт чередование направлений с углом $\arctan \sqrt{\kappa}$ к осям; по неравенству Канторовича [13]

$$f(x^{k+1}) - f^* \leq \left(\frac{L - \mu}{L + \mu} \right)^2 (f(x^k) - f^*),$$

то есть тот же знаменатель, что у стационарного шага — точная одномерная минимизация не ускоряет метод (пример 1 `examples.ipynb` измеряет это на $\kappa = 10^3$).

10. Вопросы, которые стоит ожидать

- Почему градиентный метод сходится медленно на плохо обусловленной задаче, и что даёт чебышёвское ускорение? (теоремы 4.1, 6.1; ответ: знаменатель $1 - 2/\kappa$ против $1 - 2/\sqrt{\kappa}$, число итераций $O(\kappa)$ против $O(\sqrt{\kappa})$.)
- Чем сопряжённые градиенты лучше чебышёвского метода и где их эквивалентность? (раздел 7: тот же закон, но без знания спектра и с конечной сходимостью за n шагов.)
- Сходится ли градиентный спуск для произвольной гладкой функции? К чему? (теорема 3.2, (а): только $\nabla f \rightarrow 0$; замечание 3.3.)
- Когда метод Ньютона сходится квадратично и что даёт теорема Канторовича? (раздел 13: локально всегда; полулокально — условие $h \leq 1/2$.)
- Как минимизировать на выпуклом множестве и чем проекция отличается от условного градиента? (раздел 14: PGD против Франка—Вулфа; у FW линейный оракул вместо проекции.)
- Как считать градиент функционала качества, если он задан решением дифференциального уравнения? (раздел 17: через сопряжённую задачу.)

Часть II. Расширенная часть

11. Метод тяжёлого шарика

Двухшаговый метод Поляка 1963–64 гг. (англ. *heavy ball method*)

$$x^{k+1} = x^k - \alpha \nabla f(x^k) + \beta (x^k - x^{k-1}), \quad \alpha > 0, \beta \in [0, 1), \quad (27)$$

добавляет к градиентному шагу «инерцию» — слагаемое в направлении предыдущего перемещения; физическая аналогия — шарик, скатывающийся по подвешенной в вязкой среде чаше. В машинном обучении та же схема известна как метод с импульсом (англ. *momentum*); это один мост между вопросом 10 и вопросом 02 (ML и обратные задачи).

Теорема 11.1 (локальная сходимость тяжёлого шарика). Пусть f дважды дифференцируема, x^* — точка минимума с

$$\mu I \preceq \nabla^2 f(x^*) \preceq LI, \quad \mu > 0, \quad (28)$$

параметры удовлетворяют

$$0 \leq \beta < 1, \quad 0 < \alpha < \frac{2(1 + \beta)}{L}, \quad (29)$$

и начальное приближение достаточно близко к x^* . Тогда существуют константа $c > 0$ и знаменатель $q \in (0, 1)$ такие, что $\|x^k - x^*\| \leq c(q + \delta)^k$ для любого наперёд заданного $\delta > 0$; при

$$\alpha^* = \frac{4}{(\sqrt{L} + \sqrt{\mu})^2}, \quad \beta^* = \left(\frac{\sqrt{L} - \sqrt{\mu}}{\sqrt{L} + \sqrt{\mu}} \right)^2 \quad (30)$$

достигается оптимальный знаменатель

$$q^* = \frac{\sqrt{L} - \sqrt{\mu}}{\sqrt{L} + \sqrt{\mu}} = \frac{\sqrt{\kappa} - 1}{\sqrt{\kappa} + 1}. \quad (31)$$

Доказательство. Приём удвоения размерности: введём вектор $z^k = (x^k - x^*, x^{k-1} - x^*)^\top$.

По формуле Тейлора $\nabla f(x) = B(x)(x - x^*)$ с $B(x) = \int_0^1 \nabla^2 f(x^* + t(x - x^*)) dt$ (см. доказательство теоремы 4.1); тогда (27) переписывается как одношаговый процесс

$$z^{k+1} = (\mathcal{A} + \mathcal{E}_k)z^k, \quad \mathcal{A} = \begin{pmatrix} (1 + \beta)I - \alpha B & -\beta I \\ I & 0 \end{pmatrix},$$

где $B = \nabla^2 f(x^*)$, а $\mathcal{E}_k \rightarrow 0$ при $z^k \rightarrow 0$ (непрерывность $\nabla^2 f$). Лемма о спектральном радиусе: если все собственные значения матрицы $\mathcal{A}$ по модулю меньше $q < 1$, то существует эквивалентная норма $\|\cdot\|_*$, в которой $\|\mathcal{A}\|_* \leq q + \delta/2$, и при малых $\mathcal{E}_k$ $\|(\mathcal{A} + \mathcal{E}_k)z\|_* \leq (q + \delta)\|z\|_*$, откуда $\|z^k\|_* \leq (q + \delta)^k \|z^0\|_*$; эквивалентность норм в конечномерном пространстве переносит оценку на евклидову норму с константой c .

Собственные значения $\mathcal{A}$ для собственного вектора u матрицы B с собственным значением λ находятся из блочной структуры: если $z = (u, \rho u)^T$ — собственный вектор, то ρ и $\rho_{\text{св}}$ удовлетворяют $\rho^2 - \rho(1 + \beta - \alpha\lambda) + \beta = 0$, то есть

$$\rho_{\pm}(\lambda) = \frac{1 + \beta - \alpha\lambda \pm \sqrt{(1 + \beta - \alpha\lambda)^2 - 4\beta}}{2}. \quad (32)$$

Дискриминант $(1 + \beta - \alpha\lambda)^2 - 4\beta$ при условиях (29) отрицателен для $\lambda \in [\mu, L]$: функция $g(\lambda) = (1 + \beta - \alpha\lambda)^2$ на $[\mu, L]$ принимает максимум на концах, и $g(L) < 4\beta$ по условию $\alpha < 2(1 + \beta)/L$, а $g(\mu) < 4\beta$ следует из $\alpha > 0$ и $\beta > (1 - \alpha\mu)^2/4$... точнее: нам нужно $\max_{\lambda} |\rho_{\pm}(\lambda)| < 1$. Для комплексных корней ($g < 4\beta$) $|\rho_{\pm}|^2 = \beta < 1$. Для вещественных ($g \geq 4\beta$) оба корня вещественны, положительны (сумма $1 + \beta - \alpha\lambda > 0$, произведение $\beta > 0$), и меньший корень меньше единицы как $(S - \sqrt{S^2 - 4\beta})/2 < 1$ при $S = 1 + \beta - \alpha\lambda$; больший корень меньше единицы при $S < 1 + \beta$, то есть $\alpha\lambda > 0$. Итак при (29) все $|\rho_{\pm}(\lambda)| < 1$; знаменатель q — это $\max_{\lambda \in [\mu, L]} \max_{\pm} |\rho_{\pm}(\lambda)|$.

Оптимизация. Для комплексного случая $|\rho|^2 = \beta$; для вещественного больший корень по модулю равен $|1 + \beta - \alpha\lambda|$ (когда корни чисто вещественны и $S^2 \geq 4\beta$). Равновесие между двумя режимами достигается, когда оба корня при $\lambda = \mu$ и $\lambda = L$ совпадают попарно (двойные корни): $1 + \beta - \alpha\mu = 2\sqrt{\beta}$ и $1 + \beta - \alpha L = -2\sqrt{\beta}$; вычитание даёт $\alpha(L - \mu) = 4\sqrt{\beta}$; сложение: $2(1 + \beta) = \alpha(L + \mu)$. Решая систему, получаем $\sqrt{\beta} = (\sqrt{L} - \sqrt{\mu})/(\sqrt{L} + \sqrt{\mu})$ и $\alpha = 2(1 + \beta)/(L + \mu) = 4/(\sqrt{L} + \sqrt{\mu})^2$ — это (30); подстановка даёт $|\rho| = \sqrt{\beta} = q^*$ для всех $\lambda \in [\mu, L]$, то есть (31). $\square$

Замечание 11.2. Сравнение со знаменателем $q_1 = (\kappa - 1)/(\kappa + 1) \approx 1 - 2/\kappa$ градиентного спуска: при $\kappa \gg 1$

$$q_1 \approx 1 - \frac{2}{\kappa}, \quad q^* \approx 1 - \frac{2}{\sqrt{\kappa}},$$

то есть тяжёлый шарик при оптимальных параметрах сокращает число итераций в $O(\sqrt{\kappa})$ раз. Цена — знание μ и L и локальность: метод сходится лишь из окрестности минимума, а глобальная сходимост для выпуклых функций у тяжёлого шарика не гарантирована (в отличие от метода Нестерова, раздел 12). Измерение фактических знаменателей — пример 3 examples.ipynb.

12. Ускоренный метод Нестерова

Метод Нестерова 1983 г. (у [37] — быстрый градиентный метод, БГМ) сходится по нижним оценкам теоремы 5.1 глобально, для всех гладких выпуклых функций:

$$\begin{aligned} x^{k+1} &= y^k - \frac{1}{L} \nabla f(y^k), \\ y^{k+1} &= x^{k+1} + \frac{k}{k+3} (x^{k+1} - x^k), \quad x^0 = y^0. \end{aligned} \quad (33)$$

Теорема 12.1 (сходимость метода Нестерова). Пусть f L -гладкая и выпукла, $R = \|x^0 - x^*\|$. Тогда итерации (33) удовлетворяют

$$f(x^N) - f^* \leq \frac{2LR^2}{(N+1)^2}. \quad (34)$$

Если дополнительно f μ -сильно выпукла и во второй строке (33) коэффициент $\frac{k}{k+3}$ заменён на $\frac{\sqrt{\mu}-1}{\sqrt{\mu}+1}$ с $\mu = L/\mu$, то

$$f(x^N) - f^* \leq \frac{LR^2}{2} \left(\frac{\sqrt{\mu}-1}{\sqrt{\mu}+1} \right)^N. \quad (35)$$

Обе оценки совпадают с нижними оценками теоремы 5.1 по порядку.

Доказательство (схема подобных треугольников) [37.] Введём $\alpha_k > 0$ (пока свободные), $A_k = \sum_{i=0}^k \alpha_i$, $\tau_k = \alpha_{k+1}/A_{k+1} \in (0, 1)$, и три последовательности: y^k — точка оценки градиента, $x^{k+1} = y^k - \frac{1}{L} \nabla f(y^k)$ — градиентный шаг, и

$$z^{k+1} = z^k - \alpha_{k+1} \nabla f(y^k), \quad z^0 = x^0.$$

(метод подобных треугольников: треугольники (z^k, z^{k+1}, x^{k+1}) и (z^k, x^k, y^k) подобны с коэффициентом τ_k , что даёт $y^k = \tau_k z^k + (1 - \tau_k)x^k$.) Докажем индукцией

$$A_k(f(x^k) - f^*) + \frac{1}{2} \|z^k - x^*\|^2 \leq \frac{1}{2} \|x^0 - x^*\|^2. \quad (36)$$

База $k = 0$: $A_0(f(x^0) - f^*) \geq 0$ и $z^0 = x^0$.

Шаг: пусть (36) верно для k . Оценим приращение правой части. Так как $\nabla f(y^k) = L(y^k - x^{k+1})$,

$$\frac{1}{2} \|z^k - x^*\|^2 - \frac{1}{2} \|z^{k+1} - x^*\|^2 = \alpha_{k+1} \langle \nabla f(y^k), z^k - x^* \rangle - \frac{\alpha_{k+1}^2}{2} \|\nabla f(y^k)\|^2.$$

По выпуклости f (теорема 2.6) с $y = x^*$, $x = y^k$: $\langle \nabla f(y^k), z^k - x^* \rangle = \langle \nabla f(y^k), z^k - y^k \rangle + \langle \nabla f(y^k), y^k - x^* \rangle \geq \langle \nabla f(y^k), z^k - y^k \rangle + f(y^k) - f^*$. По подобию треугольников $z^k - y^k = \frac{1-\tau_k}{\tau_k}(y^k - x^k)$, и

$$\langle \nabla f(y^k), z^k - y^k \rangle = \frac{1-\tau_k}{\tau_k} \langle \nabla f(y^k), y^k - x^k \rangle \geq \frac{1-\tau_k}{\tau_k} (f(y^k) - f(x^k)),$$

где последнее неравенство — выпуклость в форме $f(x^k) \geq f(y^k) + \langle \nabla f(y^k), x^k - y^k \rangle$. Далее, лемма спуска (лемма 3.1): $f(x^{k+1}) \leq f(y^k) - \frac{1}{2L} \|\nabla f(y^k)\|^2$, то есть $-\frac{\alpha_{k+1}^2}{2} \|\nabla f(y^k)\|^2 \leq -\alpha_{k+1}^2 L(f(y^k) - f(x^{k+1}))$. Собирая:

$$\frac{1}{2} \|z^k - x^*\|^2 - \frac{1}{2} \|z^{k+1} - x^*\|^2 \geq \alpha_{k+1} (f(y^k) - f^*) + \frac{1-\tau_k}{\tau_k} \alpha_{k+1} (f(y^k) - f(x^k)) - \alpha_{k+1}^2 L(f(y^k) - f(x^{k+1})).$$

Перегруппируем правая часть как $A_{k+1}(f(x^{k+1}) - f^*) + [\alpha_{k+1} + \frac{1-\tau_k}{\tau_k}\alpha_{k+1} - \alpha_{k+1}^2 L](f(y^k) - f^*) - \frac{1-\tau_k}{\tau_k}\alpha_{k+1}(f(x^k) - f^*)$, где первое слагаемое даёт приращение левой части (36). Коэффициент при $f(y^k) - f^*$ обращается в нуль при

$$\alpha_{k+1}^2 L = A_{k+1}. \quad (37)$$

а остаток телескопирует: $-\frac{1-\tau_k}{\tau_k}\alpha_{k+1}(f(x^k) - f^*) = -A_k(f(x^k) - f^*)$ по выбору $\tau_k = \alpha_{k+1}/A_{k+1}$. Тогда (36) переходит в $k+1$.

Выбор α : условие (37) при $A_{k+1} = A_k + \alpha_{k+1}$ даёт квадратное уравнение $L\alpha_{k+1}^2 - \alpha_{k+1} - A_k = 0$, откуда $\alpha_{k+1} = \frac{1+\sqrt{1+4LA_k}}{2L}$; при $A_0 = 0$ это даёт $\alpha_1 = 1/L$, $A_k \geq \frac{k^2}{4L}$ (по индукции: $A_{k+1} = A_k + \alpha_{k+1} \geq \frac{k^2}{4L} + \frac{k}{2L} + \frac{1}{L} \cdot \frac{1}{2} \cdot 2 \geq \frac{(k+1)^2}{4L}$). Наконец, $y^k = \tau_k z^k + (1 - \tau_k)x^k$ с $\tau_k = \alpha_{k+1}/A_{k+1} = \frac{2}{k+3}$ для выписанной рекуррентности; исключая z^k (выражается через y^k и x^k из подобия), получаем вторую строку (33) с коэффициентом $\frac{k}{k+3}$. Подстановка $A_N \geq N^2/(4L)$ в (36) даёт (34).

Сильно выпуклый случай: при $\mu > 0$ в (36) квадратичный член усиливается в $(1 + \mu\alpha_{k+1})$ раз, и выбор постоянного $\alpha_k \equiv \alpha = \frac{1}{\sqrt{\mu L}}$ даёт $A_N = \frac{N}{\sqrt{\mu L}}$ и геометрическую прогрессию (35); коэффициент инерции становится постоянным $\frac{\sqrt{\mu}-1}{\sqrt{\mu}+1}$. Знаменатель (35) по порядку равен $1 - 2/\sqrt{\mu}$; по аргументу сходимость идёт со знаменателем $\sqrt{(\sqrt{\mu}-1)/(\sqrt{\mu}+1)} \approx 1 - 1/\sqrt{\mu}$. $\square$

Замечание 12.2. Метод тяжёлого шарика и метод Нестерова отличаются одним словом: (27) вычисляет градиент в текущей точке x^k , а (33) — в экстраполированной точке y^k . Из-за этой разницы тяжёлый шарик сходится лишь локально (контрпример с разрывным гессианом у [37], замечание к (1.38)), а метод Нестерова — глобально и по нижним оценкам. Оба метода дают знаменатель $1 - 2/\sqrt{\mu}$, совпадающий с нижней оценкой (18) по порядку.

13. Метод Ньютона

Метод Ньютона заменяет модель «квадратичная форма постоянной кривизны» на «квадратичная аппроксимация с настоящим гессианом»:

$$f(x+h) \approx f(x) + \langle \nabla f(x), h \rangle + \frac{1}{2} \langle \nabla^2 f(x)h, h \rangle, \quad x^{k+1} = x^k - [\nabla^2 f(x^k)]^{-1} \nabla f(x^k).$$

Для квадратичной функции — точное решение за один шаг.

Теорема 13.1 (локальная квадратичная сходимость). Пусть f дважды дифференцируема, μ -сильно выпукла, гессиан липшицев с константой M :

$$\|\nabla^2 f(x) - \nabla^2 f(y)\| \leq M \|x - y\|, \quad (38)$$

и начальное приближение удовлетворяет

$$q_0 := \frac{M}{2\mu^2} \|\nabla f(x^0)\| < 1. \quad (39)$$

Тогда x^k сходится к x^* со скоростью квадратичной прогрессии

$$\|x^k - x^*\| \leq \frac{2\mu}{M} q_0^{2^k}. \quad (40)$$

Доказательство. Обозначим $H_k = \nabla^2 f(x^k)$; по μ -сильной выпуклости $\|H_k^{-1}\| \leq \mu^{-1}$ (предложение 2.3, в). По определению шага $H_k(x^{k+1} - x^k) = -\nabla f(x^k)$, то есть $\nabla f(x^k) + H_k(x^{k+1} - x^k) = 0$. Формула Тейлора с остатком в интегральной форме:

$$\nabla f(x^{k+1}) = \nabla f(x^k) + H_k(x^{k+1} - x^k) + \int_0^1 [\nabla^2 f(x^k + t(x^{k+1} - x^k)) - \nabla^2 f(x^k)](x^{k+1} - x^k) dt,$$

где первые два слагаемых обращаются в нуль; по (38)

$$\|\nabla f(x^{k+1})\| \leq \frac{M}{2} \|x^{k+1} - x^k\|^2. \quad (41)$$

Далее, $\|x^{k+1} - x^k\| = \|H_k^{-1} \nabla f(x^k)\| \leq \mu^{-1} \|\nabla f(x^k)\|$, и (41) даёт

$$\|\nabla f(x^{k+1})\| \leq \frac{M}{2\mu^2} \|\nabla f(x^k)\|^2.$$

Обозначив $a_k = \frac{M}{2\mu^2} \|\nabla f(x^k)\|$, получаем $a_{k+1} \leq a_k^2$; при $a_0 = q_0 < 1$ имеем $a_k \leq q_0^{2^k}$, то есть $\|\nabla f(x^k)\| \leq \frac{2\mu^2}{M} q_0^{2^k}$. Остаётся перевести оценку с градиента на аргумент. По μ -сильной выпуклости и теореме 2.7 $\|x^k - x^*\| \leq \frac{2}{\mu} \|\nabla f(x^k)\| \leq \frac{4\mu}{M} q_0^{2^k}$. Константа улучшается до $2\mu/M$ стандартным шагом [13], гл. 1, §5: оценка (41) вместе с $x^{k+1} - x^k = (x^{k+1} - x^*) - (x^k - x^*)$ и $\|H_k^{-1}\| \leq \mu^{-1}$ даёт по индукции $\|x^k - x^*\| \leq \frac{2\mu}{M} a_k$, где $a_k = \frac{M}{2\mu^2} \|\nabla f(x^k)\|$, откуда $\|x^{k+1} - x^*\| \leq \frac{2\mu}{M} a_{k+1} \leq \frac{2\mu}{M} q_0^{2^{k+1}}$ — это (40). $\square$

Замечание 13.2 (существенность условия $q_0 < 1$). Без близости начального приближения метод Ньютона может расходиться: для $f(x) = \sqrt{1+x^2}$ (выпуклая, гладкая) при больших $|x^0|$ итерации уходят на бесконечность [13]. Условие (39) неработоспособно как практический критерий — $\|\nabla f(x^0)\|$ неизвестен до счёта; его роль — гарантия сходимости, а практический выбор x^0 — отдельная задача (глобализация: демпфированный шаг $x^{k+1} = x^k - \gamma_k H_k^{-1} \nabla f(x^k)$ с γ_k из одномерной минимизации или правила Армихо сходится из любой точки сильно выпуклой задачи — [13], гл. 3, §1).

Теорема 13.3 (Ньютона—Канторовича). Пусть f дважды непрерывно дифференцируема в шаре $\Omega = \{x : \|x - x^0\| \leq r\}$, гессиан невырожден в x^0 , $\Gamma_0 = [\nabla^2 f(x^0)]^{-1}$ и

$$\|\Gamma_0 \nabla f(x^0)\| \leq \eta, \quad \|\Gamma_0 \nabla^2 f(x)\| \leq K \quad (x \in \Omega), \quad h := K\eta \leq \frac{1}{2}. \quad (42)$$

Тогда при

$$r \geq r_0 = \frac{1 - \sqrt{1-2h}}{h} \eta \quad (43)$$

(при $h = 1/2$ читается $r_0 = 2\eta$) в Ω существует решение x^* уравнения $\nabla f(x) = 0$, к которому сходится метод Ньютона, причём

$$\|x^k - x^*\| \leq \frac{1}{2^k} (2h)^{2^k} \frac{\eta}{h}. \quad (44)$$

Решение единственно в Ω , если $r < r_1 = \frac{1+\sqrt{1-2h}}{h} \eta$ или $r \leq r_1$ при $h = 1/2$. Для модифицированного процесса (гессиан заморожен: $x^{k+1} = x^k - \Gamma_0 \nabla f(x^k)$) при $h < 1/2$

$$\|x'^k - x^*\| \leq \frac{\eta}{h} (1 - \sqrt{1-2h})^{k+1}.$$

Доказательство. Сведение к скалярному мажорантному уравнению. Рассмотрим веще-

ственную функцию

$$\psi(t) = \frac{K}{2}t^2 - t + \eta = \frac{h}{\eta}t^2 - t + \eta,$$

у неё $\psi(0) = \eta > 0$, $\psi'(0) = -1$ и корни $t^* = r_0$, $t^{**} = r_1$. Метод Ньютона для ψ с началом $t_0 = 0$: $t_{k+1} = t_k - \psi(t_k)/\psi'(t_k)$, сходится возрастающе к t^* при $h \leq 1/2$. Докажем по индукции

$$\|x^{k+1} - x^k\| \leq t_{k+1} - t_k. \quad (45)$$

База $k = 0$: $\|x^1 - x^0\| = \|\Gamma_0 \nabla f(x^0)\| \leq \eta = t_1 - t_0$.

Шаг: пусть $x^k \in \Omega$ и (45) верно для $k - 1$; тогда

$$x^{k+1} - x^k = [\nabla^2 f(x^k)]^{-1} \left(\int_0^1 [\nabla^2 f(x^k) - \nabla^2 f(x^{k-1} + t(x^k - x^{k-1}))](x^k - x^{k-1}) dt \right).$$

Оценим норму интеграла через K и липшицевость $\nabla^2 f$: так как $\|\Gamma_0 \nabla^2 f(x)\| \leq K$ на Ω , обратная к $\nabla^2 f(x)$ существует и $\|[\nabla^2 f(x)]^{-1} \Gamma_0^{-1}\| \leq (1 - K\|x - x^0\|)^{-1}$ по лемме о почти единичном операторе; после стандартной (громоздкой, но элементарной) оценки появляется мажоранта $\|x^{k+1} - x^k\| \leq \frac{K}{2} \frac{(t_k - t_{k-1})^2}{1 - Kt_k} = t_{k+1} - t_k$, где равенство справа — это и есть шаг Ньютона для ψ (проверяется подстановкой ψ и ψ'). Из (45) следует, что x^k фундаментальна и $\|x^k - x^0\| \leq t_k \leq t^* = r_0$, то есть $x^k \in \Omega$; предел x^* удовлетворяет $\nabla f(x^*) = 0$ (предельный переход в $\nabla f(x^k) + \nabla^2 f(x^k)(x^{k+1} - x^k) = 0$), а $\|x^k - x^*\| \leq t^* - t_k$. Оценка погрешности: решая рекуррентность для $t^* - t_k$ (она удовлетворяет той же квадратичной мажоранте), получаем $t^* - t_k \leq \frac{1}{2k} (2h)^{2k} \frac{\eta}{h}$, то есть (44). Единственность: если $\tilde{x}$ — другое решение в шаре, то $\|\tilde{x} - x^0\| \leq r$, и разностное равенство вместе с условиями (42) даёт $\|\tilde{x} - x^*\| < \|\tilde{x} - x^*\|$ при $r < r_1$ — противоречие; полное рассуждение — в [22], гл. XVIII, §1. Модифицированный процесс мажорируется геометрической прогрессией со знаменателем $1 - \sqrt{1 - 2h}$ — там же, оценка (34). $\square$

Замечание 13.4. Константа h аффинно инвариантна: при невырожденной линейной замене переменных $x = Cy$ значения η и K преобразуются так, что h сохраняется; современная форма теоремы формулируется непосредственно в аффинно-инвариантных терминах $\|[\nabla^2 f(x^0)]^{-1} \nabla f(x^0)\|$ и липшицевости $\|[\nabla^2 f(x^0)]^{-1} \nabla^2 f(x)\|$ [28]. Условие $h \leq 1/2$ точно (константа $1/2$ неулучшаема) [22].

14. Условная оптимизация

Постановка: $\min_{x \in Q} f(x)$ с выпуклым замкнутым $Q \subseteq \mathbb{R}^n$. Три рабочих подхода: штрафы (сведение к безусловной задаче), проекция градиента и условный градиент. Первый сводит задачу к уже разобранным, второй и третий — содержание лекции курса прошлого года.

14.1. Проекция на выпуклое множество

Проекцией точки y на Q называется ближайшая точка множества:

$$\text{proj}_Q(y) = \arg \min_{x \in Q} \frac{1}{2} \|x - y\|^2. \quad (46)$$

Существование при замкнутом Q (по Вейерштрассу), единственность при выпуклом Q (по строгой выпуклости квадрата расстояния). Примеры: на шар радиуса R центра x_0 — $\text{proj}(y) = x_0 + R(y - x_0)/\|y - x_0\|$; на полупространство $\{x : c^\top x \leq b\}$ — $\text{proj}(y) = y - \frac{(c^\top y - b)_+}{\|c\|^2} c$; обе проверяются прямой подстановкой в критерий ниже.

Теорема 14.1 (критерий проекции, неравенство Бурбаки—Чини—Гольдстейна). Пусть Q выпукло замкнуто. Тогда $x = \text{proj}_Q(y)$ тогда и только тогда, когда

$$\langle y - x, z - x \rangle \leq 0 \quad \forall z \in Q. \quad (47)$$

В частности,

$$\|z - \text{proj}_Q(y)\|^2 + \|y - \text{proj}_Q(y)\|^2 \leq \|z - y\|^2 \quad \forall z \in Q. \quad (48)$$

Доказательство. x минимизирует дифференцируемую выпуклую функцию $d(x) = \frac{1}{2} \|x - y\|^2$ на выпуклом Q ; по теореме 2.6 для условной задачи (вариационное неравенство первого порядка: $\langle \nabla d(x), z - x \rangle \geq 0$ для всех $z \in Q$) это условие необходимое и достаточное. Так как $\nabla d(x) = x - y$, получаем (47). Для (48) распишем $\|z - y\|^2 = \|(z - \text{proj}_Q(y)) + (\text{proj}_Q(y) - y)\|^2$ и применим (47) со скалярным произведением ≤ 0 . $\square$

Следствие 14.2 (неэкспансивность проекции). Проекция не расширяет расстояния:

$$\|\text{proj}_Q(y) - \text{proj}_Q(y')\| \leq \|y - y'\|.$$

Доказательство. Применим (47) дважды: к паре $(y, \text{proj}_Q(y))$ с $z = \text{proj}_Q(y')$ и к паре $(y', \text{proj}_Q(y'))$ с $z = \text{proj}_Q(y)$:

$$\langle y - \text{proj}_Q(y), \text{proj}_Q(y') - \text{proj}_Q(y) \rangle \leq 0, \quad \langle y' - \text{proj}_Q(y'), \text{proj}_Q(y) - \text{proj}_Q(y') \rangle \leq 0.$$

Сложим и перегруппируем:

$$\langle y - y', \text{proj}_Q(y) - \text{proj}_Q(y') \rangle \geq \|\text{proj}_Q(y) - \text{proj}_Q(y')\|^2.$$

По Коши—Буняковского левая часть не больше $\|y - y'\| \|\text{proj}_Q(y) - \text{proj}_Q(y')\|$. $\square$

14.2. Метод проекции градиента

$$x^{k+1} = \text{proj}_Q(x^k - \gamma \nabla f(x^k)), \quad \gamma = \frac{1}{L}. \quad (49)$$

Теорема 14.3 (сходимость PGD). Пусть f выпукла и L -гладка на выпуклом замкнутом Q , x^* — минимум f на Q , $R = \|x^0 - x^*\|$. Тогда итерации (49) удовлетворяют

$$f(x^N) - f^* \leq \frac{LR^2}{2N}. \quad (50)$$

Доказательство. Обозначим $y^k = x^k - \frac{1}{L} \nabla f(x^k)$, так что $x^{k+1} = \text{proj}_Q(y^k)$. По лемме спуска (лемма 3.1) $f(x^{k+1}) \leq f(y^k) \leq f(x^k) - \frac{1}{2L} \|\nabla f(x^k)\|^2$ (первая неравенство: x^{k+1} минимум на Q , y^k может быть вне Q ? — нет, применяем лемму спуска непосредственно к точке y^k). Далее, для любого $z \in Q$ по неэкспансивности и (48):

$$\|x^{k+1} - z\|^2 \leq \|y^k - z\|^2 = \|x^k - z\|^2 - \frac{2}{L} \langle \nabla f(x^k), x^k - z \rangle + \frac{1}{L^2} \|\nabla f(x^k)\|^2.$$

Возьмём $z = x^*$ и используем выпуклость ($\langle \nabla f(x^k), x^k - x^* \rangle \geq f(x^k) - f^*$) и оценку $\frac{1}{L^2} \|\nabla f(x^k)\|^2 \leq \frac{2}{L} (f(x^k) - f(x^{k+1}))$ из леммы спуска:

$$\|x^{k+1} - x^*\|^2 \leq \|x^k - x^*\|^2 - \frac{2}{L} (f(x^k) - f^*) + \frac{2}{L} (f(x^k) - f(x^{k+1})).$$

Перегруппируем и просуммируем по $k = 0, \dots, N-1$; телескопирование даёт $\frac{2}{L} \sum_{k=0}^{N-1} (f(x^{k+1}) - f^*) \leq R^2$. Так как $f(x^{k+1})$ монотонно убывает (лемма спуска) и потому каждое слагаемое не меньше $f(x^N) - f^*$, получаем $\frac{2N}{L} (f(x^N) - f^*) \leq R^2$, то есть (50). $\square$

15. Метод Франка—Вулфа (условный градиент)

Метод Франка—Вулфа (англ. *conditional gradient*) заменяет проекцию (квадратичная задача на Q) линейной задачей:

$$y^k = \arg \min_{y \in Q} \langle \nabla f(x^k), y \rangle, \quad x^{k+1} = x^k + \gamma_k (y^k - x^k), \quad \gamma_k = \frac{2}{k+2}. \quad (51)$$

Оракул (51) — линейная минимизация на Q ; для симплекса, шара, системы неравенств она существенно дешевле проекции.

Теорема 15.1 (сходимость Франка—Вулфа). Пусть f выпукла и L -гладкая на выпуклом компакте Q диаметра $R = \max_{x, y \in Q} \|x - y\|$, x^* — минимум. Тогда итерации (51) удовлетворяют

$$f(x^N) - f^* \leq \frac{2LR^2}{N+2}. \quad (52)$$

Доказательство. Обозначим $\delta_k = f(x^k) - f^*$. Из L -гладкости (неравенство (3) с $x = x^k$, $y = x^{k+1}$) и выпуклости:

$$f(x^{k+1}) \leq f(x^k) + \gamma_k \langle \nabla f(x^k), y^k - x^k \rangle + \frac{L\gamma_k^2}{2} \|y^k - x^k\|^2.$$

Так как y^k минимизирует линейную функцию на Q , $\langle \nabla f(x^k), y^k - x^k \rangle \leq \langle \nabla f(x^k), x^* - x^k \rangle \leq f^* - f(x^k) = -\delta_k$ (последнее — выпуклость, теорема 2.6), а $\|y^k - x^k\| \leq R$. Следовательно

$$\delta_{k+1} \leq (1 - \gamma_k) \delta_k + \frac{LR^2}{2} \gamma_k^2.$$

При $\gamma_k = 2/(k+2)$: индукция $\delta_k \leq \frac{2LR^2}{k+2}$. База $k = 0$: $\delta_1 \leq (1 - \gamma_0) \delta_0 + \frac{LR^2}{2} \gamma_0^2 = \frac{LR^2}{2} \leq LR^2 = \frac{2LR^2}{2}$. Шаг: пусть $\delta_k \leq \frac{2LR^2}{k+2}$; тогда

$$\delta_{k+1} \leq \frac{k}{k+2} \cdot \frac{2LR^2}{k+2} + \frac{2LR^2}{(k+2)^2} = \frac{2LR^2(k+1)}{(k+2)^2} \leq \frac{2LR^2}{k+3},$$

поскольку $(k+1)(k+3) \leq (k+2)^2$. $\square$

Замечание 15.2 (что сильная выпуклость не даёт). Встречающееся в изложениях (в том числе в слайдах лекции прошлого года) утверждение, будто при μ -сильной выпуклости f метод (51) с тем же γ_k сходится как $O(LR^2/k^2)$, неверно: доказательство отбрасывает полезное слагаемое с μ , после чего рекуррентность в точности та, что в теореме 15.1, и улучшения нет. Контрпример — $f(x) = \|x\|^2$ на симплексе $\{x \geq 0 : \sum x_i = 1\}$ (сильно выпуклая функция): для неё FW с $\gamma_k = 2/(k+2)$ сходится как $\Theta(1/k)$, и оценка $1/k^2$ нарушается; измерение — пример 5 examples.ipynb. Ускорение до $O(1/k^2)$ достигается при сильной выпуклости множества Q (кривизна, условие Лакост-Жюльен—Ягги), а не функции.

16. Негладкая оптимизация

Для недифференцируемых выпуклых функций условие $\nabla f = 0$ заменяется условием на множество — субдифференциал (англ. *subdifferential*). Субградиентом функции f в точке x называется вектор g , такой что

$$f(y) \geq f(x) + \langle g, y - x \rangle \quad \forall y; \quad (53)$$

множество всех субградиентов — субдифференциал $\partial f(x)$.

Теорема 16.1 (свойства субдифференциала). Пусть f выпукла. Тогда:

- (а) $\partial f(x)$ непусто, выпукло и замкнуто для любого x ;
- (б) для дифференцируемой в x выпуклой f $\partial f(x) = \{\nabla f(x)\}$;
- (в) x^* — точка минимума f тогда и только тогда, когда $0 \in \partial f(x^*)$.

Доказательство. (а) Множество $\partial f(x)$ — пересечение замкнутых полупространств по параметру y (выпуклость и замкнутость). Непустота: эпиграф $\text{epi } f$ выпукл и замкнут, точка $(x, f(x))$ — его граничная; по теореме об отделимости через неё проходит опорная гиперплоскость с нормалью $(g, -1)$, $g \neq 0$... точнее, существует ненулевой $(a, \beta) \in \mathbb{R}^n \times \mathbb{R}$ с $\langle a, y - x \rangle + \beta(t - f(x)) \leq 0$ для $(y, t) \in \text{epi } f$; обязательно $\beta < 0$ (иначе при $y = x$, $t \rightarrow \infty$ противоречие), делим на $-\beta$ и получаем (53) с $g = -a/\beta$.

(б) Дифференцируемость: из (53) с $y = x + td$ после деления на t и предельных переходов $t \rightarrow 0+$ и $t \rightarrow 0-$ получаем $\langle g, d \rangle = \langle \nabla f(x), d \rangle$ для всех d .

(в) Если $0 \in \partial f(x^*)$, то (53) даёт $f(y) \geq f(x^*)$ для всех y . Обратно, если x^* — минимум, то $f(y) \geq f(x^*) = f(x^*) + \langle 0, y - x^* \rangle$, то есть 0 — субградиент. $\square$

Метод: субградиентный спуск $x^{k+1} = x^k - \gamma_k g^k$, $g^k \in \partial f(x^k)$. Сходимость медленнее градиентного: для L_0 -липшицевой выпуклой f ($\|g\| \leq L_0$ для $g \in \partial f$) усреднённая точка $\bar{x}^N$ с весами γ_k удовлетворяет $f(\bar{x}^N) - f^* \leq L_0 R / \sqrt{N}$, и оценка неулучшаема [37], §2. Медленность не поправима: это цена отсутствия гладкости, а не недочёт метода.

17. Градиент функционала через сопряжённую задачу

Завершает конспект приложение, замыкающее его на вопрос 02 (ML и обратные задачи): как вычислить градиент функционала невязки, если значение функционала требует решения дифференциального уравнения. Постановка — линейная обратная задача: пусть A — линейный оператор (прямая задача), по измерениям f ищется q из условия $Aq \approx f$ методом минимизации функционала невязки

$$J(q) = \|Aq - f\|^2 \quad (54)$$

(квадратичный функционал качества из раздела 1; обычно к нему добавляют регуляризатор Тихонова — см. вопрос 02).

Теорема 17.1 (градиент через сопряжённый оператор). Пусть A — непрерывный линейный оператор между гильбертовыми пространствами. Тогда $J(q) = \|Aq - f\|^2$ фреше дифференцируем и

$$J'(q) = 2A^*(Aq - f), \quad (55)$$

где A^* — оператор, сопряжённый к A .

Доказательство. Разложим приращение:

$$J(q + \delta q) - J(q) = 2 \langle Aq - f, A \delta q \rangle + \|A \delta q\|^2 = 2 \langle A^*(Aq - f), \delta q \rangle + o(\|\delta q\|),$$

поскольку $\|A \delta q\| \leq \|A\| \|\delta q\|$ и потому $\|A \delta q\|^2 = O(\|\delta q\|^2) = o(\|\delta q\|)$. Сравнивая с определением фреше-дифференциала $J(q + \delta q) - J(q) = \langle J'(q), \delta q \rangle + o(\|\delta q\|)$, получаем (55). $\square$

Если прямая задача задана дифференциальным уравнением, сопряжённый оператор вычисляется через сопряжённое дифференциальное уравнение, и формула (55) обретает вычислительный смысл. Пример — обратная задача теплопроводности с обратным временем [14], гл. 8: прямая задача

$$u_t = -u_{xx}, \quad x \in (0, l), \quad t \in (0, T); \quad u(0, t) = u(l, t) = 0; \quad u(x, T) = q(x),$$

по измеренному $f(x) = u(x, 0)$ + шум минимизируется функционал (54) с A — оператором прямой задачи ($q \mapsto u(\cdot, 0)$). Сопряжённая задача для ψ :

$$\psi_t = -\psi_{xx}; \quad \psi(0, t) = \psi(l, t) = 0; \quad \psi(x, 0) = 2(u(x, 0) - f(x)),$$

и интегрированием по частям на прямоугольнике $(0, l) \times (0, T)$ для разности решений δu , порождённой приращением δq , получается

$$J(q + \delta q) - J(q) = \int_0^l \psi(x, T) \delta q(x) dx + o(\|\delta q\|),$$

то есть градиент вычисляется одним решением сопряжённой задачи: $J'(q) = \psi(\cdot, T)$. Цена одного градиента — одна прямая и одна сопряжённая задача, не зависящая от размерности q ; конечные разности по параметрам потребовали бы $O(\dim q)$ решений прямой задачи. Этот приём — основа градиентных методов для обратных задач и обратного распространения ошибки в обучении сетей (вопрос 02).

18. Что почитать ещё: темы за рамками вопроса

Стохастический градиентный спуск (англ. *SGD*) — градиентный спуск по случайной несмещённой оценке градиента с дисперсией D : для выпуклых гладких задач оценка $f(\bar{x}^N) - f^* = O(\sqrt{DR}/\sqrt{N})$ и неулучшаема [37], приложение; для сильно выпуклых — линейная сходимость до $O(D/(L\mu))$ -окрестности. Дисперсия снижается минибатчингом; методы редукции дисперсии (SVRG, SAGA) убирают плату $O(1/\sqrt{N})$. Это рабочая лошадка вопроса 02.

Зеркальный спуск (англ. *mirror descent*) — замена евклидовой проекции на «проекцию» по дивергенции Брэгмана, определяемой выбором прокс-функции; для задач на симплексе заменяет $O(\sqrt{\ln n})$ штраф за размерность. Объявлен в заголовке колоды лекции прошлого года; вопрос 10 его не требует, см. [37], §2.

Универсальный градиентный спуск [37], §5 — метод, автоматически настраивающийся на неизвестную степень гладкости $\nu \in [0, 1]$ через бэктрекинг по L ; связка с правилом выбора шага раздела 8.

Квазиньютоновские методы (BFGS и др.) — итерации $x^{k+1} = x^k - \gamma_k H_k \nabla f(x^k)$ с матрицами H_k , обновляемыми по разностям градиентов так, чтобы выполнялось квазиньютоновское условие $H_{k+1} y^k = p^k$; на квадратичной задаче сходятся за n шагов, на общей — сверхлинейно [12], гл. 5, §2; [13], гл. 3, §3.

Помехи. При зашумлённом градиенте нижняя оценка асимптотически $O(1/k)$ для выпуклых и геометрическая для сильно выпуклых, и градиентный метод с убывающим шагом асимптотически оптимален [13], гл. 4, §5 — вопрос для функционала качества в условиях шумных измерений.

19. Источники

Основные источники вопроса. Локаторы (страницы) даны в README этого вопроса.

[12] — условия оптимальности первого и второго порядка, выпуклость и сильная выпуклость, субдифференциал, метод сопряжённых направлений и квазиньютоновские схемы. Теорема о существовании и единственности минимума и условия второго порядка — по этой книге.

[13] — теория скорости сходимости градиентного спуска (точная оценка и оптимальный шаг), локальная квадратичная сходимость Ньютона с контрпримерами, наискорейший спуск и неравенство Канторовича, метод тяжёлого шарика, сопряжённые градиенты и их оптимальность, нижние оценки при помехах. Теоремы 4.1, 11.1, 13.1 и разбор наискорейшего спуска — по этой книге.

[37] — градиентный спуск с постоянным шагом и оценки в трёх режимах (теорема 3.2), нижние оценки (теорема 5.1), метод Нестерова и метод подобных треугольников (теорема 12.1), субградиентный метод и стохастический спуск, проекция градиента, бэктрекинг. Материал лекции курса прошлого года.

[02] — чебышёвские полуитерации и устойчивая трёхчленная рекуррентность (теорема 6.1), метод сопряжённых градиентов и оценка в энергетической норме.

[09] — чебышёвский набор итерационных параметров: оценка q_n и число итераций $n_0(\varepsilon)$ (следствие теоремы 6.1), неустойчивость множительной формы (замечание 6.2).

[22] — теорема Ньютона—Канторовича с полным доказательством (теорема 13.3), точность константы $1/2$.

[28] — аффинно-инвариантная форма теоремы Канторовича и таблица оценок погрешности (замечание к теореме 13.3).

[14] — градиент функционала невязки через сопряжённую задачу (теорема 17.1 и пример обратной задачи теплопроводности).