# PCA (главных компонент) и ICA (независимых компонент)

Вопрос 16

Крохалев Е. М.

2026

# Постановка

# Зачем это нужно

- Данные — $N$ наблюдений над вектором признаков из $\mathbb{R}^p$; записываем их строками в матрицу $X$.
- **Сжатие размерности:** заменить данные их проекцией на $q$-мерное подпространство с минимальными потерями — метод главных компонент (англ. *principal component analysis*, PCA).
- **Разделение источников:** признаки — линейные смеси независимых латентных источников (англ. latent sources); восстановить источники по смесям — анализ независимых компонент (англ. independent component analysis, ICA). Классика — задача «коктейльной вечеринки» (англ. cocktail party problem): микрофоны принимают смеси речи и музыки.
- Сквозной пример: три датчика регистрируют смеси трёх источников (синус, меандр, пила) с фиксированной матрицей смешения $A$.

# Формальная постановка

Линейная модель ранга $q$ ищет представление $x_i \approx \mu + V_q\lambda_i$ с ортонормированными столбцами $V_q$ и минимизирует ошибку реконструкции

$$J_q(\mu, V_q, \{\lambda_i\}) = \sum_{i=1}^{N} \|x_i - \mu - V_q\lambda_i\|^2.$$

Модель ICA: $X = AS$, где компоненты $S$ независимы, негауссовы (не более одной гауссовской компоненты), $\mathsf{E}S = 0$, $\mathsf{D}S = I$; матрица смешения (англ. mixing matrix) $A$ невырождена. Задача — восстановить $A$ и $S$.

# Основные результаты: сингулярное разложение

# Сингулярное разложение

**Определение 1 (сингулярное разложение)**

Сингулярным разложением (англ. singular value decomposition, SVD) матрицы $X$ называется представление

$$X = U\Sigma V^{\intercal},$$

где $U \in \mathbb{R}^{N\times N}$ и $V \in \mathbb{R}^{p\times p}$ ортогональны, а $\Sigma \in \mathbb{R}^{N\times p}$ имеет вид $\Sigma = \operatorname{diag}(\sigma_1, \dots, \sigma_\rho)$, $\rho = \min\{N, p\}$, с $\sigma_1 \geq \dots \geq \sigma_\rho \geq 0$. Числа $\sigma_j$ называются сингулярными числами, столбцы $u_j$ матрицы $U$ — левыми, столбцы $v_j$ матрицы $V$ — правыми сингулярными векторами.

Свойства: $\|X\|_2 = \sigma_1$, $\|X\|_F^2 = \sum_j \sigma_j^2$; столбцы $V$ — собственные векторы $X^{\intercal}X$ со значениями $\sigma_j^2$; $X = \sum_j \sigma_j u_j v_j^{\intercal}$.

# Теорема Эккарта — Янга

**Теорема 2 (Эккарт — Янг, спектральная норма)**

*Пусть* $X \in \mathbb{R}^{N\times p}$, $r = \operatorname{rank} X$, $q < r$, *и* $X = \sum_{j=1}^{r} \sigma_j u_j v_j^{\intercal}$ *— сингулярное разложение. Тогда*

$$\min_{\operatorname{rank} B \le q} \|X - B\|_2 = \|X - X_q\|_2 = \sigma_{q+1}, \qquad X_q := \sum_{j=1}^{q} \sigma_j u_j v_j^{\intercal}.$$

**Теорема 3 (Эккарт — Янг, норма Фробениуса)**

*В тех же обозначениях*

$$\min_{\operatorname{rank} B \le q} \|X - B\|_F^2 = \|X - X_q\|_F^2 = \sum_{j=q+1}^{r} \sigma_j^2.$$

**Схема доказательства:** ядро любой $B$ ранга $\le q$ пересекается с $\operatorname{span}\{v_1, \dots, v_{q+1}\}$, и на единичном векторе пересечения $\|Xz\| \ge \sigma_{q+1}$; в норме Фробениуса — ортогональная инвариантность нормы и лемма о взвешенных суммах. Полное доказательство — в theory.pdf.

# Основные результаты: PCA

# Решение через сингулярное разложение

**Теорема 4 (главные компоненты через сингулярное разложение)**

*Пусть $\bar{X} = U\Sigma V^{\mathsf{T}}$ – сингулярное разложение центрированной матрицы данных, $V_q = (v_1 \ \ldots \ v_q)$ – матрица из первых $q$ правых сингулярных векторов. Тогда минимум $J_q$ достигается при $\mu = \bar{x}$, $\lambda_i = V_q^{\mathsf{T}}(x_i - \bar{x})$ и равен*

$$\min J_q = \sum_{j=q+1}^{p} \sigma_j^2,$$

*где $\sigma_j$ – сингулярные числа $\bar{X}$. При этом: координаты точек в базисе столбцов $V_q$ – первые $q$ столбцов матрицы $U_q\Sigma_q$ (главные компоненты наблюдений); реконструкция точки $x_i$ равна $\bar{x} + V_q V_q^{\mathsf{T}}(x_i - \bar{x})$ – ортогональная проекция центрированной точки на $\operatorname{range} V_q$.*

**Схема:** частичная оптимизация по $\mu$ и $\lambda_i$ даёт $\mu = \bar{x}$, $\lambda_i = V_q^{\mathsf{T}}(x_i - \bar{x})$; остаток — $\|\bar{X}(I - V_q V_q^{\mathsf{T}})\|_F^2$, это задача Эккарта — Янга о приближении матрицей ранга не выше $q$.

# Эквивалентность постановок

**Теорема 5 (эквивалентность постановок)**

*Минимизация ошибки реконструкции и последовательная максимизация дисперсии дают одно и то же подпространство* $\operatorname{span}\{v_1, \dots, v_q\}$ *— первые* $q$ *правых сингулярных векторов центрированной матрицы* $\bar{X}$*, то есть собственных векторов ковариационной матрицы* $S$*, отвечающих* $q$ *наибольшим собственным значениям.*

Свойства: главные компоненты $z_j = \bar{X} v_j$ попарно некоррелированы, упорядочены по дисперсии $\sigma_j^2 / N$; доля объяснённой дисперсии $\rho_q = \sum_{j \le q} \sigma_j^2 / \sum_j \sigma_j^2$. Выбор $q$ — по доле $\rho_q$, по «локтю» спектра или по сравнению с шумовым спектром.

# Латентные переменные: почему PCA не разделяет источники

# Лемма о неопределённости вращения

**Лемма 6 (неопределённость вращения)**

*Пусть* $X = AS$ *с* $\mathsf{E}S = 0$ *и* $\mathsf{D}S = I$ *(векторная запись:* $\mathsf{D}S = \mathsf{E}SS^{\mathsf{T}} = I$*). Тогда для любой ортогональной матрицы* $R \in \mathbb{R}^{p \times p}$ *пара* $(AR, R^{\mathsf{T}}S)$ *даёт ту же смесь:* $X = (AR)(R^{\mathsf{T}}S)$*, причём* $\mathsf{E}(R^{\mathsf{T}}S) = 0$ *и* $\mathsf{D}(R^{\mathsf{T}}S) = I$*. Если* $S$ *гауссовы и независимы, то* $R^{\mathsf{T}}S$ *снова гауссовы и независимы с той же ковариацией* $I$*.*

Некоррелированность инвариантна относительно поворотов, поэтому по ковариации (то есть по PCA) направления источников не определены: выделяется лишь подпространство, а внутри него — любой базис. Сингулярное разложение выделяется оптимальностью приближения, а не свойствами источников.

# Основные результаты: ICA

# Идентифицируемость

**Лемма 7 (допустимые преобразования)**

*Пусть $X = AS$ – модель ICA, $P$ – матрица перестановки. Тогда для любой диагональной $D$ с $d_j = \pm 1$ пара $(APD,\ D^{-1}P^{\mathsf{T}}S)$ – снова модель ICA с той же смесью: компоненты $D^{-1}P^{\mathsf{T}}S$ независимы, имеют нулевые средние и единичные дисперсии, и гауссовых компонент по-прежнему не больше одной. Знаки $d_j = \pm 1$ свободны; свободы масштаба при нормировке $\mathsf{D}S_j = 1$ не остаётся: замена $S_k \mapsto S_k/c$ ломает единичность дисперсии при любом $c \neq \pm 1$.*

**Теорема 8 (идентифицируемость ICA)**

*Пусть $X = AS$ и $X = BS'$ – две модели ICA с независимыми компонентами, у которых не более одной компоненты гауссовска. Тогда $B = APD$ с матрицей перестановки $P$ и диагональной $D$ с $d_j = \pm 1$, то есть источники определены однозначно с точностью до перестановки и знака (нормировка единичной дисперсии снимает свободу масштаба). Если все компоненты гауссовы, допустимыми являются все преобразования $B = AQ$ с ортогональной $Q$.*

**Схема:** для $T = B^{-1}A$ строка с двумя ненулевыми записями дала бы две независимые линейные формы от пары источников; по лемме Марчинкевичу об независимых линейных формах тогда обе переменные нормальны — противоречие. Значит $T = DP$.

# Отбеливание

Отбеливание (англ. whitening) — преобразование $Z = MX$ с $\mathsf{E}Z = 0$, $\mathsf{D}Z = I$.

**Предложение 1 (отбеливание через сингулярное разложение)**

*Пусть* $\mathsf{D}X = \mathsf{E}XX^{\mathsf{T}}$ *существует и положительно определена, и* $\mathsf{D}X = V\Lambda V^{\mathsf{T}}$ *– её спектральное разложение. Тогда* $M = \Lambda^{-1/2}V^{\mathsf{T}}$ *– отбеливающее преобразование. Если* $X = AS$ *– модель ICA, то после отбеливания смесь имеет вид* $Z = \widetilde{A}S$ *с ортогональной* $\widetilde{A} = MA$.

После отбеливания поиск матрицы смешения — поиск ортогональной матрицы, и независимость компонент равносильна максимальному отклонению от гаусса.

**Следствие 9**

*Негэнтропия неотрицательна: $J(Y) \geq 0$ с равенством только для гауссовского распределения. Взаимная информация неотрицательна и равна нулю только для независимых компонент.*

Для отбеленных $X$ и ортогональной $A$, $Y = A^{\mathsf{T}} X$:

$$I(Y) = \sum_j H(Y_j) - H(X) = \text{const} - \sum_j J(Y_j),$$

поэтому минимизация взаимной информации равносильна максимизации суммы негэнтропий (англ. negentropy) — поиску максимально негауссовых проекций. Негэнтропия заменяется оценкой $J(Y) \approx (\mathsf{E}G(Y) - \mathsf{E}G(\nu))^2$ с $G(u) = -\frac{1}{a}\log\cosh(au)$, $1 \leq a \leq 2$; классическая мера — куртозис (англ. kurtosis, эксцесс) $\mathsf{E}Y^4 - 3$.

# Алгоритм FastICA

Одна компонента: максимизация $\mathsf{E}G(w^{\mathsf{T}}Z)$ при $\|w\| = 1$. Лагранж даёт $\mathsf{E}[Zg(w^{\mathsf{T}}Z)] = \beta w$; один шаг метода Ньютона с приближённым якобианом $\mathsf{E}[g'(w^{\mathsf{T}}Z)]I$ (корректен для отбеленных данных) после нормировки даёт итерацию фиксированной точки

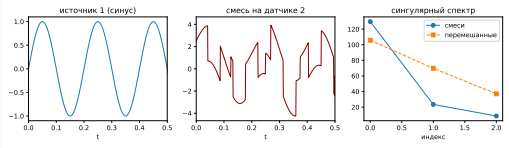
$$w^{+} = \mathsf{E}\big[Z\, g(w^{\mathsf{T}}Z)\big] - \mathsf{E}\big[g'(w^{\mathsf{T}}Z)\big]\, w, \qquad w \leftarrow w^{+}/\|w^{+}\|,$$

с $g(u) = -\tanh(au)$ для $G(u) = -\frac{1}{a}\log\cosh(au)$. Несколько компонент — последовательно с ортогонализацией Грама — Шмидта или симметрично. Источники: $\widehat{S} = \widehat{A}^{\dagger} Z$.

# Численная иллюстрация

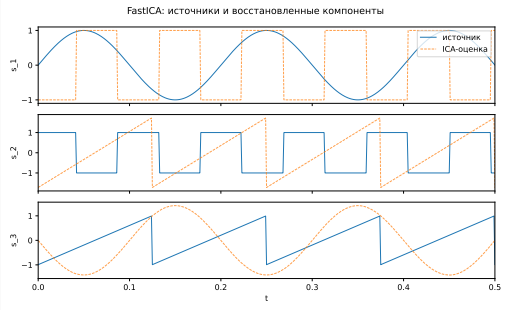
# PCA: спектр и ошибка реконструкции

- Теорема Эккарта — Янга на данных: ошибка при $q = 2$ равна $\sigma_3^2$ до машинного нуля (пин в ноутбуке).
- Первая компонента берёт $\rho_1 \approx 0{,}96$ дисперсии, но направления главных компонент не совпадают с направлениями источников (углы порядка $7$–$22^\circ$) — лемма о вращении в действии.
- Перемешивание временных меток схлопывает спектр: «локоть» исчезает.



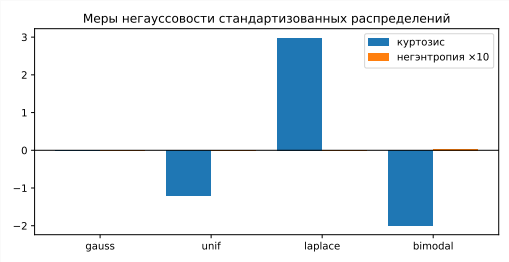
# ICA: разделение источников

- Своя реализация итерации фиксированной точки и эталон sklearn дают одни и те же компоненты (корреляция $1$ с точностью до знака).
- Каждый восстановленный сигнал совпадает с одним источником: модуль выборочной корреляции с нужным источником $\geq 0{,}99999$; матрица $WMA$ — перестановочная со знаками.
- Суммарно 10 итераций (пин).



# Гауссовский контрпример и меры негауссовости

- Те же алгоритм и та же $A$, но гауссовы источники: матрица $WMA$ не приближается к перестановочной, углы строк до осей источников $15°$–$42°$ — неидентифицируемость, а не плохая сходимость.
- Меры негауссовости: куртозис гаусса $\approx 0$, равномерного $\approx -1{,}2$, лапласова $\approx +3$; прокси-негэнтропия положительна вне гаусса (пины).



# Задачи и применения

# Разобранная задача

**Некоррелированность не влечёт независимости.** $\xi \sim U[-1,1]$, $\eta = \xi^2$: $\operatorname{cov}(\xi,\eta) = \mathsf{E}\xi^3 = 0$, но $\mathsf{P}(|\xi| > \frac{1}{2}, \eta < \frac{1}{4}) = 0 \neq \frac{1}{2} \cdot \frac{1}{2}$. Вывод: ковариационные методы не различают вращений, ICA — различает.

# Где это работает

| Постановка | Что минимизируется (или вычисляется) | Ответ |
|---|---|---|
| Сжатие данных, $q$ задано | $\|\bar{X} - \bar{X}H_q\|_F^2$ | проекция на первые $q$ сингулярных направлений |
| Выбор размерности $q$ | порог на доле $\rho_q$ или «локоть» спектра | $q$ |
| Гребневая регрессия в базисе ГК | сжатие коэффициентов $\sigma_j^2/(\sigma_j^2 + \alpha)$ | устойчивые коэффициенты |
| Слепое разделение источников (англ. blind source separation) | взаимная информация компонент | $W = A^{-1}$ с точностью до перестановки и знака |
| Предобработка перед обучением | — | отбеливание признаков |

# Итог

# Что нужно помнить

- Теорема Эккарта — Янга: усечённое SVD — наилучшее приближение ранга $q$; ошибка — $\sigma_{q+1}$ (спектральная норма) или хвост спектра (Фробениус).
- PCA: центрирование, SVD; минимизация реконструкции = максимизация дисперсии; компоненты некоррелированны, упорядочены по дисперсии.
- PCA не идентифицирует источники: некоррелированность инвариантна относительно поворотов.
- ICA: независимость вместо некоррелированности; идентифицируемость с точностью до перестановки и знака; без негауссовости (все компоненты гауссовы) задача не имеет единственного решения.
- Схема ICA: отбеливание (PCA с нормировкой) → ортогональный поиск → FastICA: итерация фиксированной точки максимизирует негэнтропию.