PCA (главных компонент) и ICA (независимых компонент)

Вопрос 16

Крохалев Е. М.

2026

Постановка

Зачем это нужно

- Данные — N наблюдений над вектором признаков из $\mathbb{R}^p$; записываем их строками в матрицу X.
- **Сжатие размерности:** заменить данные их проекцией на q-мерное подпространство с минимальными потерями — метод главных компонент (англ. *principal component analysis*, PCA).
- **Разделение источников:** признаки — линейные смеси независимых латентных источников (англ. latent sources); восстановить источники по смесям — анализ независимых компонент (англ. independent component analysis, ICA). Классика — задача «коктейльной вечеринки» (англ. cocktail party problem): микрофоны принимают смеси речи и музыки.
- Сквозной пример: три датчика регистрируют смеси трёх источников (синус, меандр, пила) с фиксированной матрицей смешения A.

Формальная постановка

Линейная модель ранга q ищет представление $x_i \approx \mu + V_q\lambda_i$ с ортонормированными столбцами V_q и минимизирует ошибку реконструкции

$$J_q(\mu, V_q, \{\lambda_i\}) = \sum_{i=1}^{N} \|x_i - \mu - V_q\lambda_i\|^2.$$

Модель ICA: $X = AS$, где компоненты S независимы, негауссовы (не более одной гауссовской компоненты), $\mathsf{E}S = 0$, $\mathsf{D}S = I$; матрица смешения (англ. mixing matrix) A невырождена. Задача — восстановить A и S.

Основные результаты: сингулярное разложение

Сингулярное разложение

Определение 1 (сингулярное разложение)

Сингулярным разложением (англ. singular value decomposition, SVD) матрицы X называется представление

$$X = U\Sigma V^{\intercal},$$

где $U \in \mathbb{R}^{N\times N}$ и $V \in \mathbb{R}^{p\times p}$ ортогональны, а $\Sigma \in \mathbb{R}^{N\times p}$ имеет вид $\Sigma = \mathrm{diag}(\sigma_1, \dots, \sigma_\rho)$, $\rho = \min\{N, p\}$, с $\sigma_1 \geq \dots \geq \sigma_\rho \geq 0$. Числа σ_j называются сингулярными числами, столбцы u_j матрицы U — левыми, столбцы v_j матрицы V — правыми сингулярными векторами.

Свойства: $\|X\|_2 = \sigma_1$, $\|X\|_F^2 = \sum_j \sigma_j^2$; столбцы V — собственные векторы $X^{\intercal}X$ со значениями σ_j^2; $X = \sum_j \sigma_j u_j v_j^{\intercal}$.

Теорема Эккарта — Янга

Теорема 2 (Эккарт — Янг, спектральная норма)

Пусть $X \in \mathbb{R}^{N\times p}$, $r = \operatorname{rank} X$, $q < r$, и $X = \sum_{j=1}^{r} \sigma_j u_j v_j^{\intercal}$ — сингулярное разложение. Тогда

$$\min_{\operatorname{rank} B \le q} \|X - B\|_2 = \|X - X_q\|_2 = \sigma_{q+1}, \qquad X_q := \sum_{j=1}^{q} \sigma_j u_j v_j^{\intercal}.$$

Теорема 3 (Эккарт — Янг, норма Фробениуса)

В тех же обозначениях

$$\min_{\operatorname{rank} B \le q} \|X - B\|_F^2 = \|X - X_q\|_F^2 = \sum_{j=q+1}^{r} \sigma_j^2.$$

Схема доказательства: ядро любой B ранга $\le q$ пересекается с $\operatorname{span}\{v_1, \dots, v_{q+1}\}$, и на единичном векторе пересечения $\|Xz\| \ge \sigma_{q+1}$; в норме Фробениуса — ортогональная инвариантность нормы и лемма о взвешенных суммах. Полное доказательство — в theory.pdf.

Основные результаты: PCA

Решение через сингулярное разложение

Теорема 4 (главные компоненты через сингулярное разложение)

Пусть $\bar{X} = U\Sigma V^{\mathsf{T}}$ – сингулярное разложение центрированной матрицы данных, $V_q = (v_1 \ \ldots \ v_q)$ – матрица из первых q правых сингулярных векторов. Тогда минимум J_q достигается при $\mu = \bar{x}$, $\lambda_i = V_q^{\mathsf{T}}(x_i - \bar{x})$ и равен

$$\min J_q = \sum_{j=q+1}^{p} \sigma_j^2,$$

где σ_j – сингулярные числа $\bar{X}$. При этом: координаты точек в базисе столбцов V_q – первые q столбцов матрицы $U_q\Sigma_q$ (главные компоненты наблюдений); реконструкция точки x_i равна $\bar{x} + V_q V_q^{\mathsf{T}}(x_i - \bar{x})$ – ортогональная проекция центрированной точки на $\operatorname{range} V_q$.

Схема: частичная оптимизация по μ и λ_i даёт $\mu = \bar{x}$, $\lambda_i = V_q^{\mathsf{T}}(x_i - \bar{x})$; остаток — $\|\bar{X}(I - V_q V_q^{\mathsf{T}})\|_F^2$, это задача Эккарта — Янга о приближении матрицей ранга не выше q.

Эквивалентность постановок

Теорема 5 (эквивалентность постановок)

Минимизация ошибки реконструкции и последовательная максимизация дисперсии дают одно и то же подпространство $\operatorname{span}\{v_1, \dots, v_q\}$ *— первые* q *правых сингулярных векторов центрированной матрицы* $\bar{X}$*, то есть собственных векторов ковариационной матрицы* S*, отвечающих* q *наибольшим собственным значениям.*

Свойства: главные компоненты $z_j = \bar{X} v_j$ попарно некоррелированы, упорядочены по дисперсии σ_j^2 / N; доля объяснённой дисперсии $\rho_q = \sum_{j \le q} \sigma_j^2 / \sum_j \sigma_j^2$. Выбор q — по доле ρ_q, по «локтю» спектра или по сравнению с шумовым спектром.

Латентные переменные: почему PCA не разделяет источники

Лемма о неопределённости вращения

Лемма 6 (неопределённость вращения)

Пусть $X = AS$ с $\mathsf{E}S = 0$ и $\mathsf{D}S = I$ (векторная запись: $\mathsf{D}S = \mathsf{E}SS^{\mathsf{T}} = I$). Тогда для любой ортогональной матрицы $R \in \mathbb{R}^{p \times p}$ пара $(AR, R^{\mathsf{T}}S)$ даёт ту же смесь: $X = (AR)(R^{\mathsf{T}}S)$, причём $\mathsf{E}(R^{\mathsf{T}}S) = 0$ и $\mathsf{D}(R^{\mathsf{T}}S) = I$. Если S гауссовы и независимы, то $R^{\mathsf{T}}S$ снова гауссовы и независимы с той же ковариацией I.

Некоррелированность инвариантна относительно поворотов, поэтому по ковариации (то есть по PCA) направления источников не определены: выделяется лишь подпространство, а внутри него — любой базис. Сингулярное разложение выделяется оптимальностью приближения, а не свойствами источников.

Основные результаты: ICA

Идентифицируемость

Лемма 7 (допустимые преобразования)

Пусть $X = AS$ – модель ICA, P – матрица перестановки. Тогда для любой диагональной D с $d_j = \pm 1$ пара $(APD,\ D^{-1}P^{\mathsf{T}}S)$ – снова модель ICA с той же смесью: компоненты $D^{-1}P^{\mathsf{T}}S$ независимы, имеют нулевые средние и единичные дисперсии, и гауссовых компонент по-прежнему не больше одной. Знаки $d_j = \pm 1$ свободны; свободы масштаба при нормировке $\mathsf{D}S_j = 1$ не остаётся: замена $S_k \mapsto S_k/c$ ломает единичность дисперсии при любом $c \neq \pm 1$.

Теорема 8 (идентифицируемость ICA)

Пусть $X = AS$ и $X = BS'$ – две модели ICA с независимыми компонентами, у которых не более одной компоненты гауссовска. Тогда $B = APD$ с матрицей перестановки P и диагональной D с $d_j = \pm 1$, то есть источники определены однозначно с точностью до перестановки и знака (нормировка единичной дисперсии снимает свободу масштаба). Если все компоненты гауссовы, допустимыми являются все преобразования $B = AQ$ с ортогональной Q.

Схема: для $T = B^{-1}A$ строка с двумя ненулевыми записями дала бы две независимые линейные формы от общей переменной; по теореме Дармуа — Скитовича обе такие переменные нормальны — противоречие посылке. Значит $T = DP$.

Отбеливание

Отбеливание (англ. whitening) — преобразование $Z = MX$ с $\mathsf{E}Z = 0$, $\mathsf{D}Z = I$.

Предложение 1 (отбеливание через сингулярное разложение)

Пусть $\mathsf{D}X = \mathsf{E}XX^{\mathsf{T}}$ существует и положительно определена, и $\mathsf{D}X = V\Lambda V^{\mathsf{T}}$ – её спектральное разложение. Тогда $M = \Lambda^{-1/2}V^{\mathsf{T}}$ – отбеливающее преобразование. Если $X = AS$ – модель ICA, то после отбеливания смесь имеет вид $Z = \widetilde{A}S$ с ортогональной $\widetilde{A} = MA$.

После отбеливания поиск матрицы смешения — поиск ортогональной матрицы, и независимость компонент равносильна максимальному отклонению от гаусса.

Следствие 9

Негэнтропия неотрицательна: $J(Y) \geq 0$ с равенством только для гауссовского распределения. Взаимная информация неотрицательна и равна нулю только для независимых компонент.

Для отбеленных X и ортогональной A, $Y = A^{\mathrm{T}} X$:

$$I(Y) = \sum_j H(Y_j) - H(X) = \text{const} - \sum_j J(Y_j),$$

поэтому минимизация взаимной информации равносильна максимизации суммы негэнтропий (англ. negentropy) — поиску максимально негауссовых проекций. Негэнтропия заменяется оценкой $J(Y) \approx (\mathsf{E}G(Y) - \mathsf{E}G(\nu))^2$ с $G(u) = -\frac{1}{a}\log\cosh(au)$, $1 \leq a \leq 2$; классическая мера — куртозис (англ. kurtosis, эксцесс) $\mathsf{E}Y^4/(\mathsf{E}Y^2)^2 - 3$, для стандартизованной величины — $\mathsf{E}Y^4 - 3$.

Алгоритм FastICA

Одна компонента: ищутся экстремумы $(\mathsf{E}G(w^{\mathsf{T}}Z) - \mathsf{E}G(\nu))^2$ при $\|w\| = 1$ (максимумы — супергауссовы компоненты, минимумы — субгауссовы; поэтому не максимум $\mathsf{E}G$, а именно экстремумы). Лагранж даёт $\mathsf{E}[Z g(w^{\mathsf{T}}Z)] = \beta w$; один шаг метода Ньютона с приближённым якобианом $\mathsf{E}[g'(w^{\mathsf{T}}Z)]I$ (корректен для отбеленных данных) после нормировки даёт итерацию фиксированной точки

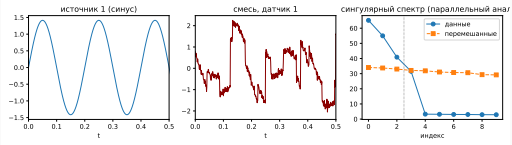
$$w^{+} = \mathsf{E}\big[Z\, g(w^{\mathsf{T}}Z)\big] - \mathsf{E}\big[g'(w^{\mathsf{T}}Z)\big]\, w, \qquad w \leftarrow w^{+}/\|w^{+}\|,$$

с $g(u) = -\tanh(au)$ для $G(u) = -\frac{1}{a}\log\cosh(au)$. Несколько компонент — последовательно (ортогонализация Грама — Шмидта после каждого шага) либо симметрично: $W \leftarrow (WW^{\mathsf{T}})^{-1/2}W$ без накопления ошибок по компонентам. Источники: $\hat{S} = \widetilde{A}^{\dagger}Z$.

Численная иллюстрация

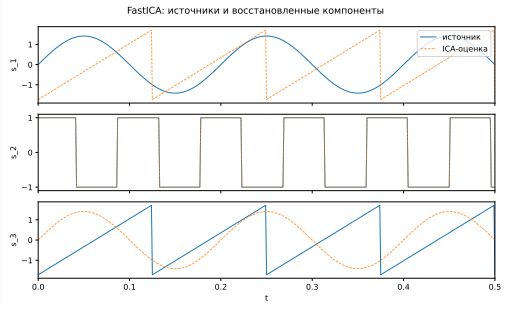
PCA: спектр и ошибка реконструкции

- $p = 10$ каналов: 9 локальных датчиков пишут три смеси троекратно + 1 фоновый; столбцы стандартизованы. Спектр: три различных сигнальных $\sigma \approx 65, 55, 41$, локоть после $q = 3$; эталон перемешивания выравнивается ($\sigma \approx 29$–34), выделяются ровно 3 компоненты (пин). Ошибка реконструкции при $q = 3$ равна хвосту спектра.
- Проверка разделения: $\max_k |\operatorname{corr}(PC_j, s_k)| \approx 0{,}76$–$0{,}84$ заметно ниже единицы — каждая главная компонента честная смесь всех источников (V далека от перестановок), PCA не разделяет. Та же метрика у ICA (пример 2): $\geq 0{,}99999$ — контраст на одной шкале.



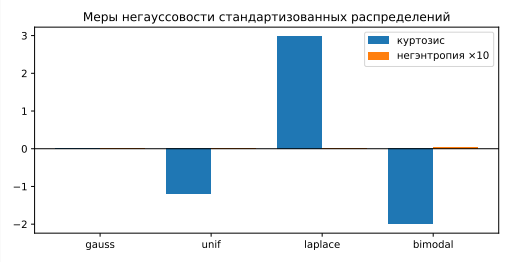
ICA: разделение источников

- Все три источника субгауссовы (куртозис $-1{,}5$, -2, $-1{,}2$): постановка через экстремумы находит и минимумы — итерация сходится к стационарным точкам.
- Своя реализация и эталон sklearn дают одни и те же компоненты; каждый восстановленный сигнал совпадает с одним источником (корреляция $\geq 0{,}99999$), матрица WMB близка к перестановочной со знаками (максимальный побочный элемент $\approx 2 \cdot 10^{-3}$).
- Суммарно 9 итераций (пин).



Гауссовский контрпример и меры негауссовости

- Те же алгоритм и та же B, но гауссовы источники: матрица WMB не приближается к перестановочной, углы строк до осей источников $15°$–$42°$ — неидентифицируемость, а не плохая сходимость.
- Меры негауссовости: куртозис гаусса ≈ 0, равномерного $\approx -1{,}2$, лапласова $\approx +3$; прокси-негэнтропия положительна вне гаусса (пины).



Задачи и применения

Разобранная задача

Некоррелированность не влечёт независимости. $\xi \sim U[-1,1]$, $\eta = \xi^2$: $\operatorname{cov}(\xi,\eta) = \mathsf{E}\xi^3 = 0$, но $\mathsf{P}(|\xi| > \frac{1}{2}, \eta < \frac{1}{4}) = 0 \neq \frac{1}{2} \cdot \frac{1}{2}$. Вывод: ковариационные методы не различают вращений, ICA — различает.

Где это работает

Постановка	Что минимизируется (или вычисляется)	Ответ
Сжатие данных, q задано	$\|\bar{X} - \bar{X}H_q\|_F^2$	проекция на первые q сингулярных направлений
Выбор размерности q	порог на доле ρ_q или «локоть» спектра	q
Гребневая регрессия в базисе ГК	сжатие коэффициентов $\sigma_j^2/(\sigma_j^2+\alpha)$	устойчивые коэффициенты
Слепое разделение источников (англ. blind source separation)	взаимная информация компонент	$W = A^{-1}$ с точностью до перестановки и знака
Предобработка перед обучением	—	отбеливание признаков

Применения

Где методы работают

- PCA: сжатие и уменьшение размерности признаков, визуализация, регрессия на главных компонентах (защита от мультиколлинеарности), компактные признаки изображений (eigenfaces); обобщения — вероятностный, ядерный и разреженный PCA.
- ICA: удаление артефактов в ЭЭГ и МЭГ (моргание, пульс, наводка), независимые пространственные паттерны в фМРТ, разделение аудио, независимые факторы финансовых рядов; линия методов — от куртозиса к правдоподобию и Infomax.

Итог

Что нужно помнить

- Теорема Эккарта — Янга: усечённое SVD — наилучшее приближение ранга q; ошибка — σ_{q+1} (спектральная норма) или хвост спектра (Фробениус).
- PCA: центрирование, SVD; минимизация реконструкции = максимизация дисперсии; компоненты некоррелированны, упорядочены по дисперсии.
- PCA не идентифицирует источники: некоррелированность инвариантна относительно поворотов.
- ICA: независимость вместо некоррелированности; идентифицируемость с точностью до перестановки и знака; без негауссовости (все компоненты гауссовы) задача не имеет единственного решения.
- Схема ICA: отбеливание (PCA с нормировкой) → ортогональный поиск → FastICA: итерация фиксированной точки ищет экстремумы $\mathrm{E}G$ (максимумы — супергауссовы, минимумы — субгауссовы источники).