Вопрос 16. PCA (главных компонент) и ICA (независимых компонент)

Конспект теории с полными доказательствами

Крохалев Е. М.

2026

Содержание

1 Постановка и мотивация **1**

2 Сингулярное разложение **2**

3 Теорема Эккарта — Янга **4**

4 Главные компоненты **6**

5 Латентные переменные и факторный анализ **9**

6 Анализ независимых компонент **10**
6.1 Отбеливание 12
6.2 Меры негауссовости 12
6.3 Алгоритм FastICA 14

7 PCA и ICA: различие постановок **16**

8 Вычислительная сторона **16**

9 Применения **17**

10 Разобранные задачи **17**

11 Вопросы, которые стоит ожидать **19**

12 Источники **19**

1 Постановка и мотивация

Дана матрица данных X размера $N \times p$: строки $x_1, \dots, x_N \in \mathbb{R}^p$ — N независимых наблюдений над вектором признаков размерности p (англ. *features*). К этим данным в машинном обучении ставятся две разные задачи, и обе решаются линейными методами.

Сжатие размерности. Найти q-мерное линейное подпространство (обычно $q \ll p$), на котором данные теряют как можно меньше: наблюдение заменяется его ортогональной проекцией на подпространство, и хочется, чтобы восстановленные по проекции точки были как можно ближе к исходным. Ответ даёт метод главных компонент (англ. *principal component analysis*, PCA). Мотивация прикладная: p велико (изображения, спектры, многоканальные записи), а полезная структура данных живёт в подпространстве малой размерности; сжатие уменьшает стоимость хранения и последующего обучения. Математически это — задача о наилучшем приближении матрицы матрицей меньшего ранга, и её решением управляет теорема Эккарта — Янга.

Разделение источников. Предположим, что наблюдаемые признаки суть линейные смеси p независимых латентных источников (англ. *latent sources*), которые измерить напрямую нельзя: канал записи «слышит» все источники сразу. Задача — восстановить источники по смесям. Ответ даёт анализ независимых компонент (англ. *independent component analysis*, ICA). Классическая постановка — задача «коктейльной вечеринки» (англ. *cocktail party problem*): несколько микрофонов регистрируют смеси речи и музыки, требуется слепое разделение источников (англ. *blind source separation*). Метод работает, пока источники негауссовы: именно отклонение от нормального распределения и несёт информацию, позволяющую различить направления смешения.

Обе задачи опираются на одни и те же инструменты: ковариационную матрицу и её спектр (вопрос 08, случайные величины и корреляционная теория), ортогональные проекции и наилучшие приближения (вопрос 09, гильбертовы пространства), сингулярное разложение — тот же объект, что стоит в основе МНК и гребневой регуляризации (вопрос 18, линейная и логистическая регрессии). Различие постановок принципиально: PCA минимизирует ошибку реконструкции и работает со вторыми моментами; ICA требует независимости компонент — условия на все совместные моменты, — и потому восстанавливает источники там, где PCA принципиально не может.

Сквозная прикладная постановка вопроса — многоканальная регистрация: p датчиков принимают линейные смеси p источников сигнала. На ней разобраны оба метода и их сравнение (численная иллюстрация — в `examples.ipynb`).

2 Сингулярное разложение

Всюду в разделе $X \in \mathbb{R}^{N\times p}$ — вещественная матрица, $r = \operatorname{rank} X$.

Определение 2.1 (сингулярное разложение)**.** Сингулярным разложением (англ. singular value decomposition, SVD) матрицы X называется представление

$$X = U\Sigma V^{\mathsf{T}},$$

где $U \in \mathbb{R}^{N\times N}$ и $V \in \mathbb{R}^{p\times p}$ ортогональны, а $\Sigma \in \mathbb{R}^{N\times p}$ имеет вид $\Sigma = \operatorname{diag}(\sigma_1, \dots, \sigma_\rho)$, $\rho = \min\{N, p\}$, с $\sigma_1 \geq \dots \geq \sigma_\rho \geq 0$. Числа σ_j называются сингулярными числами, столбцы u_j матрицы U — левыми, столбцы v_j матрицы V — правыми сингулярными векторами.

Обозначения. Ранг r равен числу строго положительных сингулярных чисел: $\sigma_1 \geq \dots \geq \sigma_r > 0 = \sigma_{r+1} = \dots = \sigma_\rho$. Тонкая форма разложения (без дополнения U и V до квадратных матриц): $X = U_r\Sigma_r V_r^{\mathsf{T}}$ с $U_r \in \mathbb{R}^{N\times r}$, $\Sigma_r = \operatorname{diag}(\sigma_1, \dots, \sigma_r)$, $V_r \in \mathbb{R}^{p\times r}$, — называется компактным сингулярным разложением.

Теорема 2.2 (о сингулярном разложении)**.** *Для любой вещественной матрицы $X \in \mathbb{R}^{N\times p}$ сингулярное разложение существует, и сингулярные числа определены однозначно.*

Доказательство. Существование докажем индукцией по $\rho = \min\{N, p\}$.

База $\rho = 1$ тривиальна: матрица $X = u_1\sigma_1 v_1^{\mathsf{T}}$ есть строка (столбец), норма которой и есть σ_1. Если $X = 0$, сингулярное разложение тривиально: $\sigma_j = 0$ при всех j.

Шаг индукции. Пусть $X \neq 0$ и $\|X\|_2 = \sigma_1$. По определению операторной нормы существуют единичные векторы $v_1 \in \mathbb{R}^p$ и $u_1 \in \mathbb{R}^N$ такие, что $Xv_1 = \sigma_1 u_1$ (вектор v_1 берём как реализующий максимум $\|Xv\|_2$ при $\|v\|_2 = 1$, а $u_1 = Xv_1/\|Xv_1\|_2$). Дополним v_1 столбцами $V_1 \in \mathbb{R}^{p\times(p-1)}$ до ортогональной матрицы $\widetilde{V} = [v_1\ V_1]$, а u_1 — столбцами $U_1 \in \mathbb{R}^{N\times(N-1)}$ до ортогональной $\widetilde{U} = [u_1\ U_1]$. Тогда

$$\widetilde{U}^{\mathsf{T}} X \widetilde{V} = \begin{pmatrix} \sigma_1 & w^{\mathsf{T}} \\ 0 & B \end{pmatrix}, \qquad w \in \mathbb{R}^{p-1},\ B \in \mathbb{R}^{(N-1)\times(p-1)}.$$

Покажем, что $w = 0$. Применив матрицу справа к вектору $z = (\sigma_1, w^{\mathsf{T}})^{\mathsf{T}} / \sqrt{\sigma_1^2 + \|w\|^2}$, получаем

$$\left\| \widetilde{U}^{\mathsf{T}} X \widetilde{V} z \right\|_2^2 \geq (\sigma_1^2 + \|w\|^2),$$

поскольку первая координата произведения равна $(\sigma_1^2 + \|w\|^2)/\sqrt{\sigma_1^2 + \|w\|^2}$. С другой стороны, умножение слева и справа на ортогональные матрицы не меняет 2-норму, поэтому

$$\left\| \widetilde{U}^{\mathsf{T}} X \widetilde{V} z \right\|_2^2 \leq \|X\|_2^2 = \sigma_1^2.$$

Следовательно $\|w\|^2 = 0$, то есть $w = 0$. По предположению индукции матрица B имеет сингулярное разложение $B = U_B \Sigma_B V_B^{\mathsf{T}}$, и тогда

$$X = \widetilde{U} \begin{pmatrix} 1 & 0 \\ 0 & U_B \end{pmatrix} \begin{pmatrix} \sigma_1 & 0 \\ 0 & \Sigma_B \end{pmatrix} \begin{pmatrix} 1 & 0 \\ 0 & V_B \end{pmatrix}^{\mathsf{T}} \widetilde{V}^{\mathsf{T}}$$

— разложение X. Оно сингулярное, поскольку σ_1 остаётся наибольшим сингулярным числом: блок B получен из X умножениями на ортогональные матрицы и отбрасыванием строки и столбца, поэтому $\|B\|_2 \leq \|X\|_2 = \sigma_1$, и все сингулярные числа B (это Σ_B) не превосходят σ_1. Доказательство заодно показывает $\|X\|_2 = \sigma_1$: верхняя граница $\|Xz\|_2 \leq \sigma_1 \|z\|_2$ следует из диагональности Σ, а равенство достигается на v_1.

Единственность сингулярных чисел. Если $X = U\Sigma V^{\mathsf{T}}$, то

$$X^{\mathsf{T}} X = V \Sigma^{\mathsf{T}} \Sigma V^{\mathsf{T}},$$

то есть столбцы V — ортонормированная система собственных векторов матрицы $X^{\mathsf{T}}X$, а числа σ_j^2 — её собственные значения. Так как матрица $X^{\mathsf{T}}X$ симметрична и неотрицательно определена, её собственные значения вполне определены матрицей X (теорема о спектральном разложении симметричной матрицы, вопрос 08), и из неотрицательности σ_j следует однозначность $\sigma_j = \sqrt{\lambda_j(X^{\mathsf{T}}X)}$. □

Предложение 2.3 (свойства сингулярного разложения)**.** *Пусть $X = U\Sigma V^{\mathsf{T}}$ — сингулярное разложение, $r = \operatorname{rank} X$. Тогда:*

1. $\operatorname{range} X = \operatorname{span}\{u_1, \dots, u_r\}$, $\ker X = \operatorname{span}\{v_{r+1}, \dots, v_p\}$*; 2. столбцы v_j — собственные векторы $X^{\mathsf{T}}X$ с собственными значениями σ_j^2; столбцы u_j — собственные векторы XX^{T} с теми же ненулевыми собственными значениями σ_j^2, $j \leq r$; 3. $X = \sum_{j=1}^{r} \sigma_j u_j v_j^{\mathsf{T}}$ — сумма r матриц ранга один; 4. $\|X\|_2 = \sigma_1$ и $\|X\|_F^2 = \sum_{j=1}^{\rho} \sigma_j^2$, где $\|\cdot\|_F$ — норма Фробениуса:* $\|X\|_F^2 = \operatorname{tr}(X^{\mathsf{T}}X) = \sum_{i,j} x_{ij}^2$.

Доказательство. 1. Из $Xv_j = \sigma_j u_j$ и линейности: образ X — линейная оболочка $u_1, \dots, u_r$ (столбцы u_j с $j > r$ соответствуют нулевым σ_j и в разложение не входят). Если $z \in \operatorname{span}\{v_{r+1}, \dots, v_p\}$, то $z = \sum_{j>r} c_j v_j$ и $Xz = \sum_{j>r} c_j \sigma_j u_j = 0$, так что $\ker X$ содержит эту оболочку; по теореме о ранге и дефекте её размерность $p - r$, то есть совпадает с размерностью $\ker X$, и ядра равны.

2. $X^{\mathsf{T}}Xv_j = V\Sigma^{\mathsf{T}}\Sigma V^{\mathsf{T}} v_j = \sigma_j^2 v_j$; аналогично $XX^{\mathsf{T}}u_j = \sigma_j^2 u_j$.

3. Следует из разбиения $U\Sigma V^{\mathsf{T}} = \sum_j u_j \sigma_j v_j^{\mathsf{T}}$ (сумма по ненулевым σ_j сокращается до $j \leq r$).

4. $\|X\|_2 = \sigma_1$ доказано в конце теоремы 2.2. Для нормы Фробениуса: $\|X\|_F^2 = \operatorname{tr}(X^{\mathsf{T}}X) = \operatorname{tr}(V\Sigma^{\mathsf{T}}\Sigma V^{\mathsf{T}}) = \operatorname{tr}(\Sigma^{\mathsf{T}}\Sigma) = \sum_j \sigma_j^2$ — след матрицы инвариантен относительно циклических перестановок. □

Замечание 2.4. Заметим симметрию: сингулярные векторы определены неоднозначно — одно и то же сингулярное значение может иметь кратностью больше единицы, и тогда любой поворот внутри соответствующего собственного подпространства $X^{\intercal}X$ даёт другое допустимое разложение. Сингулярные числа — величины однозначные. Эта неоднозначность встанет в разделе о латентных переменных: она и мешает PCA идентифицировать источники.

3 Теорема Эккарта — Янга

Центральный результат, управляющий сжатием данных, — теорема Эккарта — Янга (англ. *Eckart—Young theorem*): наилучшее приближение матрицы матрицей ранга не выше q даётся усечённым сингулярным разложением. Теорема верна в двух нормах, и оба варианта — часть её содержания: в спектральной норме ответ — одно число σ_{q+1}, в норме Фробениуса — сумма хвоста спектра.

Теорема 3.1 (Эккарт — Янг, спектральная норма)**.** *Пусть $X \in \mathbb{R}^{N\times p}$, $r = \operatorname{rank} X$, $q < r$, и $X = \sum_{j=1}^{r} \sigma_j u_j v_j^{\intercal}$ — сингулярное разложение. Тогда*

$$\min_{\operatorname{rank} B \le q} \|X - B\|_2 = \|X - X_q\|_2 = \sigma_{q+1}, \qquad X_q := \sum_{j=1}^{q} \sigma_j u_j v_j^{\intercal}.$$

Доказательство. Оценка сверху. Для X_q имеем $X - X_q = \sum_{j>q} \sigma_j u_j v_j^{\intercal}$, и это сингулярное разложение матрицы $X - X_q$ с наибольшим сингулярным числом σ_{q+1}; по пункту 4 предложения 2.3 $\|X - X_q\|_2 = \sigma_{q+1}$. При этом $\operatorname{rank} X_q \le q$ по построению.

Оценка снизу. Пусть B произвольна с $\operatorname{rank} B \le q$. Ядро B имеет размерность не менее $p-q$, поэтому

$$\ker B \;\cap\; \operatorname{span}\{v_1, \dots, v_{q+1}\} \neq \{0\}$$

(сумма размерностей $(p-q)+(q+1) = p+1$ превосходит p; стандартная формула Грассмана для суммы подпространств). Возьмём единичный вектор z из этого пересечения: $Bz = 0$, $z = \sum_{j=1}^{q+1} c_j v_j$ с $\sum_j c_j^2 = 1$. Тогда

$$\|X - B\|_2^2 \ge \|(X - B)z\|_2^2 = \|Xz\|_2^2 = \sum_{j=1}^{q+1} \sigma_j^2 c_j^2 \ge \sigma_{q+1}^2 \sum_{j=1}^{q+1} c_j^2 = \sigma_{q+1}^2,$$

где первое неравенство — определение операторной нормы, равенство в середине — ортонормированность u_j и $Xv_j = \sigma_j u_j$, а последнее неравенство — упорядоченность $\sigma_1 \ge \dots \ge \sigma_{q+1}$. Итак, для любой B ранга не выше q имеем $\|X - B\|_2 \ge \sigma_{q+1}$, и оценка достигается на усечённом разложении. □

Для нормы Фробениуса нужны две технические леммы.

Лемма 3.2. *Пусть $a_1, \dots, a_d$ — ортонормированная система в евклидовом пространстве E, $L = \operatorname{span}\{a_1, \dots, a_d\}$. Тогда для любого $b \in E$*

$$\|\operatorname{pr}_{L^{\perp}} b\|^2 = \|b\|^2 - \sum_{j=1}^{d} \langle b, a_j \rangle^2 .$$

Доказательство. По теореме Пифагора $b = \operatorname{pr}_L b + \operatorname{pr}_{L^{\perp}} b$ с ортогональными слагаемыми, поэтому $\|b\|^2 = \|\operatorname{pr}_L b\|^2 + \|\operatorname{pr}_{L^{\perp}} b\|^2$, а $\operatorname{pr}_L b = \sum_j \langle b, a_j \rangle a_j$ и квадрат его длины равен $\sum_j \langle b, a_j \rangle^2$ в силу ортонормированности a_j. □

Лемма 3.3. *Пусть $s_1 \ge s_2 \ge \dots \ge s_r > 0$ и числа $t_1, \dots, t_r$ удовлетворяют $0 \le t_j \le 1$ и $t_1 + \dots + t_r \ge r - q$ для некоторого $q < r$. Тогда*

$$\sum_{j=1}^{r} s_j t_j \;\ge\; \sum_{j=q+1}^{r} s_j.$$

Доказательство. Индукция по r при фиксированном q.

База $r = q + 1$. Тогда $\sum_j t_j \ge 1$ и

$$\sum_{j=1}^{r} s_j t_j \ge s_r \sum_{j=1}^{r} t_j \ge s_r = s_{q+1},$$

так как $s_j \ge s_r$ для всех $j \le r$.

Шаг индукции. Пусть $r > q + 1$. По условию $\sum_{j=1}^{r-1} t_j \ge (r-q) - t_r \ge 1 - t_r$ (ведь $r - q \ge 2$), поэтому существуют числа $\delta_1, \dots, \delta_{r-1}$ с

$$0 \le \delta_j \le t_j \ (j = 1, \dots, r-1), \qquad \delta_1 + \dots + \delta_{r-1} = 1 - t_r.$$

Положим $t'_j = t_j - \delta_j$, $j = 1, \dots, r-1$. Тогда $0 \le t'_j \le 1$ и

$$t'_1 + \dots + t'_{r-1} = (t_1 + \dots + t_{r-1}) - (1 - t_r) \ge (r-q) - 1 = (r-1) - q,$$

то есть семейство (t'_j) удовлетворяет посылке леммы с $r-1$ вместо r, и по предположению индукции

$$\sum_{j=1}^{r-1} s_j t'_j \ge s_{q+1} + \dots + s_{r-1}.$$

Тогда, пользуясь $s_j \ge s_r$ и $\delta_j \le 1$,

$$\sum_{j=1}^{r} s_j t_j = \sum_{j=1}^{r-1} s_j t'_j + \sum_{j=1}^{r-1} s_j \delta_j + s_r t_r \ge \sum_{j=q+1}^{r-1} s_j + s_r \Big(\sum_{j=1}^{r-1} \delta_j + t_r \Big) = \sum_{j=q+1}^{r-1} s_j + s_r,$$

что и требовалось. □

Теорема 3.4 (Эккарт — Янг, норма Фробениуса)**.** *В условиях теоремы 3.1*

$$\min_{\operatorname{rank} B \le q} \|X - B\|_F^2 = \|X - X_q\|_F^2 = \sum_{j=q+1}^{r} \sigma_j^2.$$

Доказательство. Оценка сверху. $\|X - X_q\|_F^2 = \sum_{j>q} \sigma_j^2$ по пункту 4 предложения 2.3 (сингулярные числа $X - X_q$ — это $\sigma_{q+1}, \dots$).

Оценка снизу. Так как норма Фробениуса инвариантна относительно умножения на ортогональные матрицы слева и справа ($\|UAV\|_F^2 = \operatorname{tr}(V^{\mathsf T} A^{\mathsf T} U^{\mathsf T} U A V) = \operatorname{tr}(A^{\mathsf T} A) = \|A\|_F^2$), достаточно доказать неравенство для диагональной матрицы Σ вместо X: при $B = U \widetilde{B} V^{\mathsf T}$ имеем $\|X - B\|_F = \|\Sigma - \widetilde{B}\|_F$ и $\operatorname{rank} \widetilde{B} = \operatorname{rank} B$.

Пусть $\widetilde{B} \in \mathbb{R}^{N \times p}$, $\operatorname{rank} \widetilde{B} \le q$. Обозначим через $\bar{\Sigma}$ и $\bar{B}$ её левые верхние блоки размера $r \times r$ (там, где Σ имеет ненулевые σ_j); тогда $\|\Sigma - \widetilde{B}\|_F^2 \ge \|\bar{\Sigma} - \bar{B}\|_F^2$, причём $\operatorname{rank} \bar{B} \le q$. Обозначим $L = \operatorname{range} \bar{B} \subseteq \mathbb{R}^r$, $d = \dim L \le q$ и выберем в L ортонормированный базис $f_1, \dots, f_d$, дополненный до ортонормированного базиса $f_1, \dots, f_r$ всего $\mathbb{R}^r$.

Так как столбцы $\bar{B}$ лежат в L,

$$\|\bar{\Sigma} - \bar{B}\|_F^2 = \sum_{i=1}^{r} \|\bar{\Sigma}^{(i)} - \bar{B}^{(i)}\|^2 \geq \sum_{i=1}^{r} \|\operatorname{pr}_{L^\perp} \bar{\Sigma}^{(i)}\|^2 = \sum_{i=1}^{r} \sigma_i^2 \|\operatorname{pr}_{L^\perp} e_i\|^2 = \sum_{i=1}^{r} \sigma_i^2 t_i,$$

где e_i — векторы стандартного базиса, а $t_i := \|\operatorname{pr}_{L^\perp} e_i\|^2 \in [0,1]$ (квадрат длины проекции единичного вектора; использована лемма 3.2). По той же лемме, применённой к e_i и ортонормированному базису $f_{d+1}, \dots, f_r$ пространства $L^\perp$,

$$\sum_{i=1}^{r} t_i = \sum_{i=1}^{r} \sum_{j=d+1}^{r} \langle e_i, f_j \rangle^2 = \sum_{j=d+1}^{r} \|f_j\|^2 = r - d \geq r - q.$$

Значит, применима лемма 3.3:

$$\|\Sigma - \widetilde{B}\|_F^2 \geq \sum_{i=1}^{r} \sigma_i^2 t_i \geq \sum_{i=q+1}^{r} \sigma_i^2.$$

Оценка достигается на $B = X_q$, что завершает доказательство. □

Следствие 3.5. *Расстояние от X до множества матриц ранга $\leq q$ равно σ_{q+1} в спектральной норме и $\left(\sum_{j>q} \sigma_j^2\right)^{1/2}$ — в норме Фробениуса, и в обеих нормах его даёт усечённое сингулярное разложение.*

Замечание о множествах матриц: условие $\operatorname{rank} B \leq q$ равносильно обращению в нуль всех миноров порядка $q+1$ — системе многочленных уравнений от коэффициентов, поэтому множество матриц ранга не выше q замкнуто (и минимум в теоремах 3.1, 3.4 на нём достигается); условие полного ранга $\rho = \min\{N, p\}$ равносильно $\sigma_\rho > 0$ и потому открыто, а всюду плотно: любую матрицу можно сколь угодно мало изменить, добившись полного ранга.

4 Главные компоненты

Метод главных компонент прямо следует из теоремы Эккарта — Янга. Запишем наблюдения в строках матрицы $X \in \mathbb{R}^{N \times p}$ и будем искать q-мерное аффинное подпространство, наилучшим образом приближающее данные.

Определение 4.1 (модель ранга q и ошибка реконструкции)**.** Линейной моделью ранга q для данных $x_1, \dots, x_N \in \mathbb{R}^p$ называется представление

$$x_i \approx \mu + V_q \lambda_i, \qquad i = 1, \dots, N,$$

где $\mu \in \mathbb{R}^p$, $V_q \in \mathbb{R}^{p \times q}$ имеет ортонормированные столбцы (направления компонент), $\lambda_i \in \mathbb{R}^q$ — координаты точки в базисе столбцов V_q. Ошибка реконструкции — функционал

$$J_q(\mu, V_q, \{\lambda_i\}) = \sum_{i=1}^{N} \|x_i - \mu - V_q \lambda_i\|^2.$$

Геометрически модель — аффинная гиперплоскость $\mu + \operatorname{range} V_q$ в $\mathbb{R}^p$; μ — точка на ней, столбцы V_q — ортонормированный базис направлений.

Лемма 4.2 (частичная оптимизация)**.** *Для фиксированного V_q минимум J_q по μ и $\{\lambda_i\}$ достигается при*

$$\mu = \bar{x} := \tfrac{1}{N}\sum_{i=1}^{N} x_i, \qquad \lambda_i = V_q^{\mathsf{T}}(x_i - \bar{x}),$$

и равен $\sum_{i=1}^{N} \|(x_i - \bar{x}) - V_q V_q^{\mathsf{T}}(x_i - \bar{x})\|^2$.

Доказательство. Обозначим $y_i = x_i - \mu$ и запишем разложение $y_i = V_q V_q^{\mathsf{T}} y_i + (I - V_q V_q^{\mathsf{T}}) y_i$: первое слагаемое лежит в $\operatorname{range} V_q$, второе — в ортогональном дополнении, по теореме Пифагора

$$J_q = \sum_i \|V_q(\lambda_i - V_q^{\mathsf{T}} y_i)\|^2 + \sum_i \|(I - V_q V_q^{\mathsf{T}}) y_i\|^2.$$

Первое слагаемое неотрицательно и обращается в нуль при $\lambda_i = V_q^{\mathsf{T}} y_i$; при этом выборе λ_i оно исчезает при любом μ, поэтому остаётся минимизировать по μ сумму $\sum_i \|(I - V_q V_q^{\mathsf{T}})(x_i - \mu)\|^2$. Матрица $I - V_q V_q^{\mathsf{T}}$ — матрица ортогональной проекции, поэтому

$$\sum_i \|(I - V_q V_q^{\mathsf{T}})(x_i - \mu)\|^2 = \sum_i \left\|(I - V_q V_q^{\mathsf{T}})x_i - (I - V_q V_q^{\mathsf{T}})\mu\right\|^2,$$

и это — сумма квадратов расстояний от точек $(I - V_q V_q^{\mathsf{T}})x_i$ до точки $(I - V_q V_q^{\mathsf{T}})\mu$; минимум по μ достигается, когда $(I - V_q V_q^{\mathsf{T}})\mu = (I - V_q V_q^{\mathsf{T}})\bar{x}$. В частности, $\mu = \bar{x}$ — допустимая точка минимума (любое смещение μ вдоль $\operatorname{range} V_q$ не меняет значения, поэтому решение не единственно, но существование точки минимума и значение функционала определены однозначно). Подставляя $\mu = \bar{x}$ и $\lambda_i = V_q^{\mathsf{T}}(x_i - \bar{x})$, получаем заявленное значение. □

Обозначения. Центрированная матрица данных $\bar{X} := X - \mathbf{1}\bar{x}^{\mathsf{T}}$ (из каждой строки вычтено среднее). Выборочная ковариационная матрица

$$S := \tfrac{1}{N}\bar{X}^{\mathsf{T}}\bar{X}.$$

После леммы 4.2 задача сведена к выбору q-мерного подпространства: надо минимизировать

$$\sum_{i=1}^{N} \|(x_i - \bar{x}) - V_q V_q^{\mathsf{T}}(x_i - \bar{x})\|^2 = \|\bar{X} - \bar{X} V_q V_q^{\mathsf{T}}\|_F^2 = \|\bar{X}(I - V_q V_q^{\mathsf{T}})\|_F^2.$$

Теорема 4.3 (главные компоненты через сингулярное разложение)**.** *Пусть $\bar{X} = U\Sigma V^{\mathsf{T}}$ — сингулярное разложение центрированной матрицы данных, $V_q = (v_1 \ \dots \ v_q)$ — матрица из первых q правых сингулярных векторов. Тогда минимум J_q достигается при $\mu = \bar{x}$, $\lambda_i = V_q^{\mathsf{T}}(x_i - \bar{x})$ и равен*

$$\min J_q = \sum_{j=q+1}^{p} \sigma_j^2,$$

где σ_j — сингулярные числа $\bar{X}$. При этом:

1. *координаты точек в базисе столбцов V_q — первые q столбцов матрицы $U_q\Sigma_q$ (главные компоненты наблюдений);*
2. *реконструкция точки x_i равна $\bar{x} + V_q V_q^{\mathsf{T}}(x_i - \bar{x})$ — ортогональная проекция центрированной точки на $\operatorname{range} V_q$.*

Доказательство. Матрица $H_q := V_q V_q^\top$ — матрица ортогональной проекции на q-мерное подпространство $\operatorname{range} V_q$; матрица $I - H_q$ — проекция на ортогональное дополнение, причём $\operatorname{rank}(I - H_q) = p - q$. По лемме 4.2

$$\min_{\mu,\{\lambda_i\}} J_q = \min_{V_q} \|\bar{X}(I - H_q)\|_F^2 = \min_{H_q} \|\bar{X} - \bar{X}H_q\|_F^2,$$

а последний минимум — это минимум $\|\bar{X} - B\|_F$ по матрицам B ранга не выше q: любая $B = \bar{X}V_qV_q^\top$ сама имеет такой вид (проектор $H_q = V_qV_q^\top$ выбирается среди всех ортопроекторов ранга q), и, обратно, для любой B ранга $\le q$ с сингулярным разложением $B = P\Gamma Q^\top$ подстановка $V_q = Q_q$ даёт $\bar{X}H_q$ — проекцию строк $\bar{X}$ на $\operatorname{range} Q_q$, по невязке не хуже B (это содержание оценки снизу в доказательстве теоремы 3.4). По теореме 3.4 минимум равен $\sum_{j>q} \sigma_j^2$ и достигается на первых q сингулярных векторах. Реконструкция — проекция по построению; столбцы $U\Sigma$ равны $\bar{X}v_j$ (из $\bar{X} = U\Sigma V^\top$ следует $\bar{X}v_j = \sigma_j u_j$), поэтому координаты λ_i образуют первые q столбцов $U\Sigma$. □

Замечание 4.4. Заметим порядок действий: сначала центрирование, потом сингулярное разложение. Без центрирования первое сингулярное направление тяготело бы к вектору средних — на практике PCA почти всегда применяют к центрированным данным. Второй стандартный шаг при разномасштабных признаках — стандартизация (деление столбцов на выборочные стандартные отклонения): иначе признак с большей дисперсией (измеренный в больших единицах) «перетянет» на себя компоненты.

Определение 4.5 (максимизация дисперсии)**.** Направление первой главной компоненты — вектор

$$v_1 \in \arg\max_{\|v\|=1} v^\top S v;$$

направление k-й главной компоненты — вектор

$$v_k \in \arg\max_{\substack{\|v\|=1 \\ v \perp v_1,\dots,v_{k-1}}} v^\top S v.$$

Теорема 4.6 (эквивалентность постановок)**.** *Минимизация ошибки реконструкции (теорема 4.3) и последовательная максимизация дисперсии (определение 4.5) дают одно и то же подпространство* $\operatorname{span}\{v_1, \dots, v_q\}$ *— первые q правых сингулярных векторов центрированной матрицы $\bar{X}$, то есть собственных векторов ковариационной матрицы S, отвечающих q наибольшим собственным значениям.*

Доказательство. По предложению 2.3 сингулярное разложение $\bar{X} = U\Sigma V^\top$ даёт $S = \frac{1}{N} V\Sigma^\top\Sigma V^\top$: столбцы v_j — собственные векторы S с собственными значениями σ_j^2/N. Значит, утверждение теоремы — переформулировка вариационного принципа для симметричной матрицы: наибольшему собственному значению отвечает максимум квадратичной формы $v^\top S v$ на единичной сфере, и максимум на подпространстве, ортогональному первым $k-1$ собственным векторам, достигается на следующем собственном векторе. Вариационный принцип докажем для полноты. Пусть $S = W\Lambda W^\top$ — спектральное разложение, $\lambda_1 \ge \dots \ge \lambda_p$. Для $\|v\| = 1$ в базисе W: $v^\top S v = \sum_j \lambda_j c_j^2$, $\sum_j c_j^2 = 1$, поэтому $v^\top S v \le \lambda_1$, с равенством на w_1. Пусть $v \perp w_1, \dots, w_{k-1}$; тогда $c_1 = \dots = c_{k-1} = 0$ и $v^\top S v = \sum_{j \ge k} \lambda_j c_j^2 \le \lambda_k$ с равенством на w_k. Индукция по k завершает доказательство: максимум дисперсии на ортогональном дополнении даёт следующий сингулярный вектор. □

Предложение 4.7 (свойства главных компонент)**.** *Пусть $z_j = \bar{X}v_j = \sigma_j u_j \in \mathbb{R}^N$ — j-й главный компонент (вектор значений компоненты по всем наблюдениям). Тогда:*

1. выборочная дисперсия z_j равна σ_j^2/N; 2. компоненты попарно некоррелированы: $z_j^{\mathsf{T}} z_k = 0$ при $j \neq k$; 3. компоненты упорядочены по убыванию дисперсии; 4. доля объяснённой дисперсии первыми q компонентами равна

$$\rho_q = \frac{\sum_{j=1}^{q} \sigma_j^2}{\sum_{j=1}^{p} \sigma_j^2}.$$

Доказательство. 1. $\|z_j\|^2 = \sigma_j^2 \|u_j\|^2 = \sigma_j^2$; выборочная дисперсия $\frac{1}{N}\|z_j\|^2$ (центрированность следует из $\bar{X}^{\mathsf{T}}\mathbf{1} = 0$ и $z_j \in \operatorname{range} \bar{X}$). 2. $z_j^{\mathsf{T}} z_k = \sigma_j \sigma_k u_j^{\mathsf{T}} u_k = 0$ при $j \neq k$ по ортонормированности U. 3. Следует из упорядоченности $\sigma_1 \geq \ldots \geq \sigma_p$. 4. Сумма выборочных дисперсий всех компонент равна $\frac{1}{N}\|\bar{X}\|_F^2 = \frac{1}{N}\sum_j \sigma_j^2$ (предложение 2.3); доля — отношение частичной суммы к полной. □

Замечание 4.8. Выбор числа компонент q — содержательный, а не формальный шаг. Рабочие критерии: доля объяснённой дисперсии ρ_q (на практике берут ρ_q близкой к единице; точный порог — содержательное решение по задаче); «локоть» графика σ_j; сравнение сингулярного спектра с его шумовым ожиданием — в данных без структуры сингулярные числа центрированной матрицы ведут себя как сингулярные числа случайной гауссовой матрицы, и компоненты, не выделяющиеся над этим фоном, обычно отбрасывают. Эталон строится независимым перемешиванием каждого столбца: метод главных компонент инвариантен к общей перестановке строк (наблюдений), но перемешивание каждого признака по своей перестановке разрушает корреляции между признаками, и спектр выравнивается к шумовому. Сравнение спектров делается на стандартизованных признаках (параллельный анализ на корреляционной матрице): перемешивание не меняет дисперсий каналов, и без стандартизации крупные по дисперсии каналы сохраняли бы крупные сингулярные числа, неся «локоть» сквозь эталон. Численная иллюстрация всех трёх критериев — в ноутбуке examples.ipynb.

Замечание 4.9 (связь с гребневой регрессией). Главные компоненты — рабочий базис гребневой регрессии (вопрос 18, линейная и логистическая регрессии): МНК в базисе столбцов V имеет коэффициенты $\hat{\theta}_j = u_j^{\mathsf{T}} y/\sigma_j$, гребень сжимает их с множителями $\sigma_j^2/(\sigma_j^2 + \alpha)$, поэтому малые главные компоненты (малые σ_j) подавляются сильнее всего. PCA же решает противоположную задачу: отбросить малые компоненты целиком. Оба метода — спектральная обработка одной и той же матрицы данных.

5 Латентные переменные и факторный анализ

Сингулярное разложение можно прочитать как модель скрытых переменных (англ. *latent variables*). Запишем компактное разложение центрированной матрицы в форме $\bar{X} = FA^{\mathsf{T}}$ с $F = \sqrt{N}\,U$ и $A = V\Sigma/\sqrt{N}$: тогда каждый столбец $\bar{X}$ (признак) — линейная комбинация столбцов F, причём столбцы F имеют нулевое среднее, единичную выборочную дисперсию и попарную выборочную некоррелированность: $\frac{1}{N}F^{\mathsf{T}}F = I$. В терминах случайных величин:

$$X_j = \sum_{k=1}^{p} a_{jk} F_k, \qquad j = 1, \ldots, p,$$

то есть $X = AF$: каждый наблюдаемый признак — линейная смесь латентных некоррелированных переменных с единичной дисперсией. (Латентные переменные обозначены F, а не S: буква S уже занята выборочной ковариацией из раздела «Главные компоненты»; вектор источников модели ICA ниже обозначается S, области действия разнесены.) Естественный вопрос: можно ли назвать F_k «источниками», порождающими данные?

Лемма 5.1 (неопределённость вращения)**.** *Пусть $X = AS$ с $\mathsf{E}S = 0$ и $\mathsf{D}S = I$ (векторная запись: $\mathsf{D}S = \mathsf{E}SS^{\mathsf{T}} = I$). Тогда для любой ортогональной матрицы $R \in \mathbb{R}^{p\times p}$ пара*

$(AR, R^{\mathsf{T}}S)$ даёт ту же смесь: $X = (AR)(R^{\mathsf{T}}S)$, причём $\mathsf{E}(R^{\mathsf{T}}S) = 0$ и $\mathsf{D}(R^{\mathsf{T}}S) = I$. Если S гауссовы и независимы, то $R^{\mathsf{T}}S$ снова гауссовы и независимы с той же ковариацией I.

Доказательство. Первое равенство: $(AR)(R^{\mathsf{T}}S) = A(RR^{\mathsf{T}})S = AS = X$. Нулевое среднее очевидно. Ковариация:

$$\mathsf{D}(R^{\mathsf{T}}S) = \mathsf{E}R^{\mathsf{T}}SS^{\mathsf{T}}R = R^{\mathsf{T}}(\mathsf{E}SS^{\mathsf{T}})R = R^{\mathsf{T}}IR = I.$$

Последнее утверждение: линейное преобразование гауссового вектора гауссово (характеристическая функция линейно преобразованного гауссового вектора снова гауссова — вопрос 08), некоррелированные гауссовы компоненты независимы, а ковариация I сохраняет независимость. □

Вывод: по ковариационной структуре данные X не определяют A даже с точностью до перестановки: целиком повёрнутое разложение $X = (AR)(R^{\mathsf{T}}S)$ равноправно. Сингулярное разложение выделяется не свойствами источников, а своей оптимальностью на каждом ранге (теорема Эккарта — Янга) — это свойство приближения, а не идентификации. Лемма объясняет, почему PCA не решает задачу разделения источников: некоррелированность инвариантна относительно поворотов.

Классический факторный анализ (англ. *factor analysis*) смягчает модель, разрешив каждому признаку собственный шум:

$$X = AS + e, \qquad \mathsf{E}S = 0,\ \mathsf{D}S = I,\ \mathsf{E}e = 0,\ \mathsf{D}e = D_e = \operatorname{diag}(\tau_1^2, \dots, \tau_p^2),$$

с некоррелированными S и e. Тогда ковариационная матрица наблюдений

$$\mathsf{D}X = AA^{\mathsf{T}} + D_e.$$

Но лемма 5.1 в силе и здесь: пары (A, S) и $(AR, R^{\mathsf{T}}S)$ не различимы по $\mathsf{D}X$, так как $(AR)(AR)^{\mathsf{T}} = ARR^{\mathsf{T}}A^{\mathsf{T}} = AA^{\mathsf{T}}$. В психометрии под неопределённостью подразумевали свободу «вращения факторов» с целью интерпретируемости; математически это недоопределённость модели. Заметим и различие постановок: PCA аппроксимирует ковариационную структуру данных, факторный анализ после стандартизации признаков моделирует корреляционную структуру (диагональ D_e вычитает именно специфические дисперсии признаков).

6 Анализ независимых компонент

Анализ независимых компонент снимает неопределённость вращения, заменив некоррелированность независимостью распределений.

Определение 6.1 (модель ICA)**.** Моделью анализа независимых компонент называется

$$X = AS,$$

где $S = (S_1, \dots, S_p)^{\mathsf{T}}$ — вектор независимых (в совокупности) случайных величин с нулевыми средними и единичными дисперсиями, не более чем одна из которых гауссовска, $A \in \mathbb{R}^{p \times p}$ невырождена. Матрица A — матрица смешения (англ. mixing matrix). Задача — восстановить A и S по независимым реализациям вектора X.

«Не более чем одна гауссовска» — существенная посылка: без неё, как показано в лемме 5.1 и теореме 6.4, матрица смешения определена лишь с точностью до ортогонального множителя.

Обозначения. Компоненты S_j — источники (англ. sources); компоненты наблюдаемого X — смеси (англ. mixtures). Записи $X = AS$ и $X_j = \sum_k a_{jk} S_k$ эквивалентны. Матрица $W = A^{-1}$ — матрица разделения (англ. *unmixing matrix*): $S = WX$.

Лемма 6.2 (допустимые преобразования)**.** *Пусть $X = AS$ — модель 6.1, P — матрица перестановки. Тогда для любой диагональной D с $d_j = \pm 1$ пара $(APD,\ D^{-1}P^{\mathsf{T}}S)$ — снова модель 6.1 с той же смесью: компоненты $D^{-1}P^{\mathsf{T}}S$ независимы, имеют нулевые средние и единичные дисперсии, и гауссовых компонент по-прежнему не больше одной. Знаки $d_j = \pm 1$ свободны; свободы масштаба при нормировке $\mathsf{D}S_j = 1$ не остаётся: замена $S_k \mapsto S_k/c$ ломает единичность дисперсии при любом $c \neq \pm 1$.*

Доказательство. $(APD)(D^{-1}P^{\mathsf{T}}S) = A(PP^{\mathsf{T}})S = AS = X$. Компоненты $D^{-1}P^{\mathsf{T}}S$ — это переставленные и знакопеременные компоненты S: независимость совокупности сохраняется, средние нулевые, дисперсии равны $d_j^{-2} = 1$ (посылка $d_j = \pm 1$). Число гауссовских компонент при перестановке и смене знака не меняется. Что масштаб $c \neq \pm 1$ недопустим, видно из $\mathsf{D}(S_k/c) = 1/c^2 \neq 1$: посылка единичной дисперсии модели 6.1 его исключает. □

Обратная сторона — других свобод у модели нет — и есть содержание идентифицируемости ICA. Нам понадобится классический результат о независимых линейных формах.

Теорема 6.3 (Дармуа — Скитович)**.** *Пусть $X_1, \dots, X_n$ независимы, $L_1 = \sum_j a_j X_j$, $L_2 = \sum_j b_j X_j$. Если L_1 и L_2 независимы, то каждая компонента X_j, для которой $a_j b_j \neq 0$, нормальна.*

Это классический результат теории характеризаций: доказательство — в монографии Кагана, Линника и Рао о характеризационных задачах математической статистики (М.: Наука, 1972; англ. издание: Kagan, Linnik, Rao, *Characterization Problems in Mathematical Statistics*, Wiley, 1973); именно через неё устроен вывод идентифицируемости ICA в работе Comon (1994). Не путать с теоремой Марчинкевича: та утверждает, что если характеристическая функция имеет вид $e^{P(t)}$ с многочленом P, то $\deg P \leq 2$; это ограничение на многочлен, а не критерий независимости линейных форм.

Теорема 6.4 (идентифицируемость ICA)**.** *Пусть $X = AS$ и $X = BS'$ — две модели 6.1 с независимыми компонентами, у которых не более одной компоненты гауссовска. Тогда $B = APD$ с матрицей перестановки P и диагональной D с $d_j = \pm 1$, то есть источники определены однозначно с точностью до перестановки и знака (нормировка единичной дисперсии снимает свободу масштаба — лемма 6.2). Если гауссовы все компоненты, допустимыми являются все преобразования $B = AQ$ с ортогональной Q (лемма 5.1); если гауссовых компонент $k \geq 2$, свободным является произвольное ортогональное вращение внутри их k-мерного подпространства.*

Доказательство. Гауссовский случай ($k = p$) доказан в лемме 5.1: для независимых гауссовских S с $\mathsf{D}S = I$ вектор $Q^{\mathsf{T}}S$ снова независим и гауссов при любой ортогональной Q, так что разложения $X = (AQ)(Q^{\mathsf{T}}S)$ равноправны. При $2 \leq k < p$ то же рассуждение применяется к гауссовой части: ортогональное вращение внутри её подпространства сохраняет независимость и единичную ковариацию, остальные компоненты не трогаем.

Пусть теперь не более одной компоненты S гауссовска. Положим $T = B^{-1}A$, так что $Y := B^{-1}X = TS$ — вектор с независимыми компонентами (это и есть S'); при этом $TT^{\mathsf{T}} = I$, поскольку $I = \mathsf{D}Y = T\mathsf{D}S\,T^{\mathsf{T}}$. Докажем, что $T = DP$ с диагональной D и перестановкой P.

Предположим, что две строки $i \neq m$ матрицы T имеют общий ненулевой столбец k. Теорема 6.3, применённая к независимым формам Y_i, Y_m, делает нормальной компоненту S_k. Общим такой столбец может быть только один: два общих столбца k_1, k_2 дали бы по той же теореме две нормальные компоненты S_{k_1}, S_{k_2}, противоречие посылке. Но при единственном общем столбце k_0

$$(TT^{\mathsf{T}})_{im} = \sum_j t_{ij}t_{mj} = t_{ik_0}\,t_{mk_0} \neq 0,$$

что противоречит $TT^{\mathsf{T}} = I$. Значит, у любых двух строк общих ненулевых столбцов нет вовсе: каждый столбец T имеет ровно одну ненулевую запись, а невырожденность T даёт

ровно одну ненулевую запись в каждой строке. Это и есть $T = DP$ с перестановкой P и диагональной D; наконец, $D^2 = TT^{\mathsf{T}} = I$, то есть $d_j = \pm 1$: свобода масштаба снята нормировкой дисперсий. □

Заметим, что посылка «не более одна компонента гауссовска» использована в самом начале: она — единственное, что запрещает двум строкам два общих ненулевых столбца. Знак каждого источника по отдельности неразличим уже из тождества $a_{jk}S_k = (-a_{jk})(-S_k)$; масштаб, как показано в лемме 6.2, снимает нормировка дисперсии.

Замечание 6.5 (независимость и некоррелированность). Независимость сильнее некоррелированности: из независимости следует $\mathsf{E}S_jS_k = \mathsf{E}S_j\,\mathsf{E}S_k = 0$, обратное неверно — некоррелированные величины могут быть сильно зависимы (пример в разобранных задачах). Посылка $\mathsf{D}S = I$ фиксирует вторые моменты; независимость фиксирует все совместные моменты, и именно поэтому она различает вращения, а ковариация — нет. Здесь проходит граница между PCA и ICA: PCA использует только ковариацию и потому инвариантен относительно поворотов (лемма 5.1), ICA использует всё распределение.

6.1 Отбеливание

Практическая схема ICA двухступенчата: сначала данные приводятся к стандартному виду, затем ищется ортогональная матрица.

Определение 6.6 (отбеливание)**.** Преобразование $Z = MX$ называется отбеливающим (англ. whitening), если $\mathsf{E}Z = 0$ и $\mathsf{D}Z = I$.

Предложение 6.7 (отбеливание через сингулярное разложение)**.** *Пусть* $\mathsf{D}X = \mathsf{E}XX^{\mathsf{T}}$ *существует и положительно определена, и* $\mathsf{D}X = V\Lambda V^{\mathsf{T}}$ *— её спектральное разложение. Тогда* $M = \Lambda^{-1/2}V^{\mathsf{T}}$ *— отбеливающее преобразование. Если* $X = AS$ *— модель 6.1, то после отбеливания смесь имеет вид* $Z = \widetilde{A}S$ *с ортогональной* $\widetilde{A} = MA$.

Доказательство. $\mathsf{E}Z = M\mathsf{E}X = 0$; $\mathsf{D}Z = M(\mathsf{D}X)M^{\mathsf{T}} = \Lambda^{-1/2}V^{\mathsf{T}}V\Lambda V^{\mathsf{T}}V\Lambda^{-1/2} = \Lambda^{-1/2}\Lambda\Lambda^{-1/2} = I$. Далее, $\mathsf{D}S = I$ даёт $I = \mathsf{D}Z = \widetilde{A}\mathsf{D}S\,\widetilde{A}^{\mathsf{T}} = \widetilde{A}\widetilde{A}^{\mathsf{T}}$, то есть $\widetilde{A}$ ортогональна. □

Отбеливание обычно делают через сингулярное разложение центрированной выборочной матрицы: $Z = \sqrt{N}\,U$ — те самые главные компоненты, нормированные на единичную дисперсию. После отбеливания задача свелась к поиску ортогональной матрицы: $Z = \widetilde{A}S$ с $\widetilde{A}^{\mathsf{T}}\widetilde{A} = I$, и источники восстанавливаются $S = \widetilde{A}^{\mathsf{T}}Z$. Поиск ортогональной матрицы — малоразмерная задача, для неё и строятся итерационные алгоритмы следующего пункта.

6.2 Меры негауссовости

Критерий независимости нужно превратить в оптимизируемый функционал. Такими функционалами служат меры отклонения распределения от нормального.

Определение 6.8 (дифференциальная энтропия)**.** Дифференциальной энтропией случайной величины Y с плотностью g называется

$$H(Y) = -\int g(y)\log g(y)\,dy.$$

Взаимной информацией компонент случайного вектора $Y = (Y_1, \dots, Y_p)^{\mathsf T}$ с совместной плотностью g называется

$$I(Y) = \sum_{j=1}^{p} H(Y_j) - H(Y).$$

Негэнтропией случайной величины Y называется

$$J(Y) = H(Y_{\text{gauss}}) - H(Y),$$

где Y_{gauss} — гауссовская случайная величина с той же дисперсией, что и Y.

Лемма 6.9 (энтропия линейного преобразования)**.** *Пусть X — случайный вектор в $\mathbb{R}^p$ с плотностью, C — невырожденная матрица, $Y = CX$. Тогда*

$$H(Y) = H(X) + \log|\det C|.$$

Доказательство. Пусть f — плотность X, g — плотность Y. По формуле преобразования плотности $g(y) = f(C^{-1}y)\,|\det C|^{-1}$. Тогда

$$H(Y) = -\int g(y)\log g(y)\,dy = -\int f(C^{-1}y)\,|\det C|^{-1}\big[\log f(C^{-1}y) - \log|\det C|\big]dy.$$

Замена $x = C^{-1}y$, $dy = |\det C|\,dx$:

$$H(Y) = -\int f(x)\log f(x)\,dx + \log|\det C|\int f(x)\,dx = H(X) + \log|\det C|,$$

так как $\int f = 1$. □

Теорема 6.10 (максимум энтропии у гаусса при фиксированной дисперсии)**.** *Среди всех случайных величин с плотностью, нулевым средним и дисперсией σ^2 максимальную дифференциальную энтропию имеет нормальное распределение:*

$$H(Y) \le \tfrac{1}{2}\log\!\big(2\pi e\,\sigma^2\big),$$

с равенством только для нормального распределения.

Доказательство. Пусть g — плотность Y, $\varphi(x) = (2\pi\sigma^2)^{-1/2}e^{-x^2/(2\sigma^2)}$ — нормальная плотность с той же дисперсией. Рассмотрим дивергенцию Кульбака — Лейблера

$$D(g\|\varphi) = \int g(x)\log\frac{g(x)}{\varphi(x)}\,dx \ge 0$$

(неотрицательность — интегральное неравенство Женсона, применённое к выпуклой функции $\psi(x) = x\log x$ по вероятностной мере $\varphi\,dx$: $\int \varphi\,\psi(g/\varphi) \ge \psi\big(\int \varphi\cdot(g/\varphi)\big) = \psi(1) = 0$; равенство лишь при $g = \varphi$ почти всюду). Раскроем:

$$D(g\|\varphi) = \int g\log g\,dx - \int g(x)\log\varphi(x)\,dx = -H(Y) - \int g(x)\Big[-\tfrac{x^2}{2\sigma^2} - \tfrac{1}{2}\log(2\pi\sigma^2)\Big]dx.$$

Здесь $\int x^2 g(x)\,dx = \sigma^2$ по посылке, поэтому

$$D(g\|\varphi) = -H(Y) + \tfrac{1}{2} + \tfrac{1}{2}\log(2\pi\sigma^2) = -H(Y) + \tfrac{1}{2}\log(2\pi e\sigma^2) \ge 0,$$

что и требовалось. □

Следствие 6.11. *Негэнтропия неотрицательна: $J(Y) \ge 0$ с равенством только для гауссовского распределения. Взаимная информация неотрицательна и равна нулю только для независимых компонент.*

Доказательство. Первая часть — немедленное следствие теоремы 6.10 применительно к стандартизованной Y/σ. Вторая: по определению $I(Y) = D(g\|\prod_j g_j)$ — дивергенция Кульбака — Лейблера совместной плотности от произведения маргинальных; неотрицательность и условие равенства $g = \prod_j g_j$ — это независимость по определению. □

Теперь критерий независимости оптимизируем: пусть X отбелен, $\mathsf{D}X = I$, A ортогональна, $Y = A^{\mathsf{T}}X$. По лемме 6.9 и ортогональности ($\log|\det A^{\mathsf{T}}| = \log 1 = 0$):

$$I(Y) = \sum_j H(Y_j) - H(X).$$

Первое слагаемое — константа минус сумма негэнтропий:

$$\sum_j H(Y_j) = \sum_j \bigl(H(Y_{j,\text{gauss}}) - J(Y_j)\bigr) = \text{const} - \sum_j J(Y_j),$$

так как $\mathsf{D}Y_j = 1$ и гауссовская эталонная энтропия для всех Y_j одна и та же. Итак: **минимизация взаимной информации эквивалентна максимизации суммы негэнтропий компонент** — для отбеленных данных поиск независимых компонент есть поиск максимально негауссовых проекций. Это содержание формул, которыми оперирует [16] §14.7.

Негэнтропию напрямую по выборке не оценить (нужна плотность), поэтому её заменяют приближением. Используется квадратичная оценка

$$J(Y) \approx \bigl(\mathsf{E}\,G(Y) - \mathsf{E}\,G(\nu)\bigr)^2,$$

где $\nu \sim \mathcal{N}(0,1)$, а G — любая «хорошая» немногочленная функция; стандартный выбор с параметром $1 \le a \le 2$:

$$G(u) = -\tfrac{1}{a}\log\cosh(au).$$

Приближение обосновывается разложением по кумулянтам: для стандартизованной Y с малыми кумулянтами негауссовости функционал $(\mathsf{E}G(Y) - \mathsf{E}G(\nu))^2$ локально эквивалентен положительно определённой квадратичной форме от кумулянтов, то есть является мерой отклонения от гаусса того же порядка, что и сама J; это изложение обзора Hyvärinen—Oja (2000), на котором стоит §14.7 в [16]. Классическая, более ранняя и менее устойчивая к выбросам мера — куртозис (англ. *kurtosis*, эксцесс)

$$\operatorname{kurt}(Y) = \frac{\mathsf{E}Y^4}{(\mathsf{E}Y^2)^2} - 3 \;:$$

для гауссовской величины он равен нулю при любой дисперсии; аддитивен четвёртый кумулянт $\kappa_4 = \mathsf{E}Y^4 - 3(\mathsf{E}Y^2)^2$, на который куртозис нормирован (задача 10.3); первые алгоритмы ICA максимизировали $|\operatorname{kurt}|$. Для стандартизованной величины ($\mathsf{E}Y^2 = 1$) определение сводится к $\mathsf{E}Y^4 - 3$.

6.3 Алгоритм FastICA

Остаётся решить задачу максимизации суммы негэнтропий по ортогональным матрицам. Алгоритм FastICA решает её покомпонентно: одно направление за раз с последующей ортогонализацией.

Одна компонента. По Hyvärinen—Oja (2000) направления источников отвечают экстремумам $\mathsf{E}G(w^{\mathsf{T}}Z)$: супергауссовы компоненты дают максимумы, субгауссовы — минимумы; максимизировать $\mathsf{E}G$ напрямую нельзя — такая постановка нашла бы только супергауссовы направления. Негэнтропия нормирована так, что $J \ge 0$ и равна нулю только на гауссе,

поэтому «максимум негэнтропии» корректен для обоих типов источников; в алгоритме работают с экстремумами приближения, где максимумы и минимумы F равноправны (квадрат снимает знак): Решаем задачу об экстремумах приближения:

$$\operatorname{extr}_{\|w\|=1} \left(\mathsf{E}\, G(w^{\mathsf{T}} Z) - \mathsf{E}\, G(\nu)\right)^2, \qquad \nu \sim \mathcal{N}(0,1),$$

где Z — отбеленные данные (реализации z_i заменяют распределение: математические ожидания заменяются выборочными средними). Обозначим $F(w) = \mathsf{E}G(w^{\mathsf{T}} Z) - \mathsf{E}G(\nu)$. Точки экстремума удовлетворяют уравнению

$$\nabla_w \big(F(w)\big)^2 = 2F(w)\, \mathsf{E}\big[Z\, g(w^{\mathsf{T}} Z)\big] = 0, \qquad g = G',$$

то есть либо $F(w) = 0$, либо $\mathsf{E}[Zg(w^{\mathsf{T}} Z)] = 0$; нетривиальные экстремумы отыскиваются из уравнения Лагранжа для F на сфере

$$\mathsf{E}\big[Z\, g(w^{\mathsf{T}} Z)\big] - \beta w = 0, \qquad \beta = \mathsf{E}\big[(w^{\mathsf{T}} Z)\, g(w^{\mathsf{T}} Z)\big]$$

(скалярное произведение уравнения с w при $\|w\| = 1$). Для $G(u) = -\frac{1}{a}\log\cosh(au)$ имеем $g(u) = G'(u) = -\tanh(au)$ (знак контрастной функции на результат не влияет: замена g на $-g$ лишь меняет знак вектора w^+, который снимается нормировкой).

Решаем уравнение итерациями Ньютона. Левая часть $F(w) = \mathsf{E}[Zg(w^{\mathsf{T}} Z)] - \beta w$ имеет якобиан

$$F'(w) = \mathsf{E}\big[ZZ^{\mathsf{T}} g'(w^{\mathsf{T}} Z)\big] - \beta I.$$

Для отбеленных данных Z и типичных g матрицу $\mathsf{E}[ZZ^{\mathsf{T}} g'(w^{\mathsf{T}} Z)]$ заменяют скалярным приближением $\mathsf{E}[g'(w^{\mathsf{T}} Z)]\, I$: это тот шаг, где используется отбеливание (для произвольной ковариации Z такая замена некорректна). Тогда шаг Ньютона $w \leftarrow w - F'(w)^{-1} F(w)$ превращается после умножения на скаляр $\mathsf{E}[g'(w^{\mathsf{T}} Z)] - \beta$ (который после последующей нормировки w на единичную длину отбрасывается) в итерацию фиксированной точки

$$w^+ = \mathsf{E}\big[Z\, g(w^{\mathsf{T}} Z)\big] - \mathsf{E}\big[g'(w^{\mathsf{T}} Z)\big]\, w, \qquad w \leftarrow w^+ / \|w^+\|.$$

Каждая итерация есть один шаг метода Ньютона для лагранжева уравнения с приближённым якобианом; в отличие от прямой максимизации, здесь нет шага по направлению и длине шага — всё скрыто в преобразовании Ньютона.

Несколько компонент. Найденное w_1 фиксируют; следующие направления ищут тем же итерационным шагом с ортогонализацией относительно уже найденных (последовательная схема, англ. *deflation*): после каждого шага

$$w \leftarrow w - \sum_{k<j} (w^{\mathsf{T}} w_k)\, w_k, \qquad w \leftarrow w / \|w\|.$$

Ортогональность сохраняется: если w_k ортонормированы, проекция вычитает вклад всех предыдущих направлений; это последовательная схема, и ошибка вычисления одной компоненты переносится на следующие. Симметричный вариант обновляет все q направлений независимо и затем ортогонализует матрицу $W \leftarrow (WW^{\mathsf{T}})^{-1/2} W$ (положительно определённый корень) — такой шаг симметричен по компонентам, ошибки не накапливаются от компоненты к компоненте, что важно при q, близком к p.

Восстановление источников. Найденные w_j — строки $\widetilde{A}^{\dagger}$: оценки источников $\widehat{S}_j = w_j^{\mathsf{T}} Z$, матрица разделения $W = \widetilde{A}^{\dagger} M$, где M — отбеливающее преобразование.

Замечание 6.12. Отбеливание — не просто удобство, а структурный шаг: оно сводит поиск матрицы смешения к компактной ортогональной группе и делает корректным скалярное приближение якобиана. Если пропустить отбеливание, тот же итерационный шаг применяют к произвольной матрице смешения с нормировкой — это вариант алгоритма без предобработки, он менее устойчив. Быстрота: одна итерация — $O(Np)$ операций; практически

сходимость наступает за считанные десятки итераций, что и объясняет имя метода.

7 PCA и ICA: различие постановок

Методы решают разные задачи над одними данными, и их часто противопоставляют на примере смеси независимых равномерных величин [16]: распределение смеси равномерно на параллелограмме (образ единичного квадрата под линейным отображением), главные направления — главные оси эллипса рассеяния, собственные векторы матрицы AA^{T}, в общем случае не совпадающие с осями источников; разделение источников даёт только ICA, ищущий независимость, а не дисперсию.

	PCA	ICA
Цель	наилучшая q-мерная линейная реконструкция	восстановление независимых источников
Оптимизируется	ошибка реконструкции $\|\bar{X} - \bar{X}H_q\|_F^2$ (равносильно — дисперсия проекции)	независимость компонент (сумма негэнтропий после отбеливания)
Моменты распределения	вторые (ковариация)	все (негауссовость — минимум)
Свойство решения	направления ортогональны	компоненты независимы, матрица смешения после отбеливания ортогональна
Идентифицируемость	направления определены однозначно с точностью до знака (при различных σ_j); неопределённость вращения относится к латентным факторам модели, а не к главным направлениям	с точностью до перестановки и знака (при не более чем одной гауссовской компоненте)
Гауссовские источники	работает (по ковариации), источники не различаются	не работает: без негауссовости решение не единственно
Типичное применение	сжатие, визуализация, предобработка признаков	слепое разделение источников, выделение сигналов

8 Вычислительная сторона

Практический расчёт метода опирается на стандартные численные процедуры.

PCA сводится к сингулярному разложению центрированной матрицы $\bar{X}$ (или к спектральному разложению $S = \frac{1}{N}\bar{X}^{\mathsf{T}}\bar{X}$ — устойчивее прямое SVD, без формирования S). Стоимость — $O(Np^2)$ операций при использовании стандартных алгоритмов [02]; хранение матрицы U не требуется, если нужны только направления и доля объяснённой дисперсии.

ICA двухступенчат: отбеливание (это же PCA с нормировкой компонент, $O(Np^2)$) и затем итерации FastICA, каждая из которых — $O(Np)$ операций (выборочные средние $\mathsf{E}[Zg(w^{\mathsf{T}}Z)]$ и $\mathsf{E}[g'(w^{\mathsf{T}}Z)]$). Практический итог: сходимость за считанные десятки итераций, общая стоимость порядка стоимости одного сингулярного разложения. Выбор функции G влияет на устойчивость: $G(u) = -\log\cosh(au)/a$ умеренно растёт и устойчива к выбросам; мера через четвёртый момент (куртозис) чувствительна к хвостам, чем объясняется историческая смена стандартов [16].

Где работает конструкция.

Постановка	Что минимизируется (или вычисляется)	Ответ	Что покупается
Сжатие данных, q задано	$\|\bar{X} - \bar{X}H_q\|_F^2$	проекция на первые q сингулярных направлений	q-мерное представление с долей дисперсии ρ_q
Выбор размерности q	порог на доле ρ_q или «локоть» спектра	q	баланс объёма и потерь
Гребневая регрессия в базисе ГК	сжатие коэффициентов с множителями $\sigma_j^2/(\sigma_j^2+\alpha)$	устойчивые коэффициенты	защита от мультиколлинеарности (вопрос 18)
Слепое разделение источников	взаимная информация компонент (макс. сумма негэнтропий)	$W = A^{-1}$	восстановленные источники с точностью до перестановки и знака
Предобработка перед обучением	—	отбеливание признаков	некоррелированные входы, обычно лучше обусловленность

9 Применения

Обе процедуры — рабочие инструменты, а не только теоретические конструкции.

PCA. Сжатие данных и уменьшение размерности признаков перед обучением (регрессия на главных компонентах снимает мультиколлинеарность — вопрос 18, линейная и логистическая регрессии); визуализация многомерных данных проекцией на первые две-три компоненты; построение компактных признаков изображений (собственные изображения лица по методу eigenfaces — собственные векторы ковариационной матрицы пикселей). Вероятностный PCA интерпретирует те же главные подпространства как максимальное правдоподобие гауссовой латентной модели; нелинейные и интерпретируемые обобщения — ядерный и разреженный PCA [16] §14.5.4–14.5.5.

ICA. Слепое разделение источников в многоканальных сигналах: удаление артефактов (моргания, пульс, сетевая наводка) в ЭЭГ и МЭГ — отдельные компоненты с чёткой физической интерпретацией; выделение независимых пространственных паттернов в фМРТ; разделение аудиосигналов (та же задача «коктейльной вечеринки»); поиск независимых факторов в финансовых временных рядах. Историческая линия методов — от алгоритмов на куртозисе к максимизации правдоподобия и принципу Infomax; изложение [16] §14.7.2 держит рамку контрастных функций, на которой построен FastICA.

10 Разобранные задачи

Задача 10.1 (некоррелированность не влечёт независимости)**.** Привести пример двух случайных величин, которые некоррелированны, но зависимы.

Решение. Пусть $\xi \sim U[-1,1]$, $\eta = \xi^2$. Тогда $\mathsf{E}\xi = 0$, $\mathsf{E}\eta = \frac{1}{3}$ и

$$\operatorname{cov}(\xi,\eta) = \mathsf{E}\xi\eta - \mathsf{E}\xi\,\mathsf{E}\eta = \mathsf{E}\xi^3 = \int_{-1}^{1} \tfrac{1}{2}\xi^3\,d\xi = 0,$$

так как подынтегральная функция нечётна. Некоррелированность есть. Зависимость видна прямо: η — функция ξ (событие $\xi \in [0,1]$ определяет $\eta \in [0,1]$), например

$$\mathsf{P}(|\xi| > \tfrac{1}{2},\ \eta < \tfrac{1}{4}) = 0 \neq \mathsf{P}(|\xi| > \tfrac{1}{2})\,\mathsf{P}(\eta < \tfrac{1}{4}) = \tfrac{1}{2}\cdot\tfrac{1}{2}.$$

Итак, фиксация вторых моментов не фиксирует совместное распределение — это и есть причина, по которой ковариационные методы (PCA, факторный анализ) не идентифицируют источники, а ICA — идентифицирует.

Задача 10.2 (частичная оптимизация постановки PCA)**.** Вывести $\mu = \bar{x}$, $\lambda_i = V_q^{\mathsf{T}}(x_i - \bar{x})$ в постановке 4.1 непосредственно, дифференцированием по параметрам.

Решение. Функционал J_q квадратичен по λ_i; градиент по λ_i равен $-2V_q^{\mathsf{T}}(x_i - \mu - V_q\lambda_i)$ и обращается в нуль при $\lambda_i = V_q^{\mathsf{T}}(x_i - \mu)$ (матрица $V_q^{\mathsf{T}}V_q = I$ положительно определена — минимум). Подстановка даёт $J_q = \sum_i \|(I - V_qV_q^{\mathsf{T}})(x_i - \mu)\|^2$. Дифференцируя по μ: $-2\sum_i (I - V_qV_q^{\mathsf{T}})^2(x_i - \mu) = 0$; так как $(I - V_qV_q^{\mathsf{T}})^2 = I - V_qV_q^{\mathsf{T}}$ (проектор идемпотентен) и $\sum_i (x_i - \mu) = N(\bar{x} - \mu)$, получаем $(I - V_qV_q^{\mathsf{T}})(\bar{x} - \mu) = 0$, то есть μ отличен от $\bar{x}$ либо на элемент range V_q; выбор $\mu = \bar{x}$ допустим и оптимален. Согласуется с леммой 4.2.

Задача 10.3 (кумулянт четвёртого порядка суммы независимых слагаемых)**.** Пусть U, V независимы, $\mathsf{E}U = \mathsf{E}V = 0$, дисперсии равны σ^2. Показать, что четвёртый кумулянт $\kappa_4(X) = \mathsf{E}X^4 - 3\,(\mathsf{E}X^2)^2$ аддитивен: $\kappa_4(U+V) = \kappa_4(U) + \kappa_4(V)$, и вывести формулу куртозиса суммы: $\operatorname{kurt}(U+V) = \frac{1}{4}(\operatorname{kurt}(U) + \operatorname{kurt}(V))$ при равных дисперсиях. Почему аддитивен именно кумулянт, а не куртозис?

Решение. Раскроем четвёртый момент суммы, пользуясь независимостью (совместные моменты разбиваются на произведения):

$$\mathsf{E}(U+V)^4 = \mathsf{E}U^4 + 4\mathsf{E}U^3\mathsf{E}V + 6\mathsf{E}U^2\mathsf{E}V^2 + 4\mathsf{E}U\mathsf{E}V^3 + \mathsf{E}V^4 = \mathsf{E}U^4 + 6\sigma^4 + \mathsf{E}V^4,$$

так как $\mathsf{E}U = \mathsf{E}V = 0$, $\mathsf{E}U^2 = \mathsf{E}V^2 = \sigma^2$. При этом $\mathsf{E}(U+V)^2 = 2\sigma^2$, поэтому

$$\kappa_4(U+V) = \mathsf{E}(U+V)^4 - 3\left(\mathsf{E}(U+V)^2\right)^2 = \mathsf{E}U^4 + \mathsf{E}V^4 + 6\sigma^4 - 12\sigma^4 = \kappa_4(U) + \kappa_4(V),$$

поскольку $\kappa_4(U) + \kappa_4(V) = \mathsf{E}U^4 + \mathsf{E}V^4 - 6\sigma^4$. Аддитивность кумулянта доказана (это частное проявление общего свойства кумулянтов всех порядков). Куртозис нормирует κ_4 на квадрат дисперсии, поэтому кумулянты суммы складываются, а куртозисы — нет: при равных дисперсиях

$$\operatorname{kurt}(U+V) = \frac{\kappa_4(U) + \kappa_4(V)}{(2\sigma^2)^2} = \frac{\operatorname{kurt}(U) + \operatorname{kurt}(V)}{4}.$$

Для гауссовских U, V имеем $\kappa_4 = 0$, и сумма независимых гауссовских снова гауссовска. Следствие для ICA: для направления смеси $y = \sum_j a_j S_j$ со стандартизованными независимыми S_j

$$\kappa_4(y) = \sum_j a_j^4\,\kappa_4(S_j) = \sum_j a_j^4\,\operatorname{kurt}(S_j),$$

то есть вклад источника в негауссовость проекции пропорционален четвёртой степени коэффициента, и экстремумы $|\kappa_4|$ выделяют направления, близкие к отдельным источникам.

Задача 10.4 (почему максимум энтропии у гаусса)**.** Доказать неравенство $H(Y) \le \frac{1}{2}\log(2\pi e\sigma^2)$ прямой подстановкой плотности.

Решение. Это и есть содержание теоремы 6.10: для плотности g с дисперсией σ^2 и нормальной плотностью φ с той же дисперсией

$$\tfrac{1}{2}\log(2\pi e\sigma^2) - H(g) = \int g \log \frac{g}{\varphi} = D(g\|\varphi) \geq 0,$$

причём неотрицательность дивергенции следует из выпуклости $x \log x$: $\int \varphi \frac{g}{\varphi} \log \frac{g}{\varphi} \geq (\int g) \log(\int g) = 0$. Равенство достигается только при $g = \varphi$ почти всюду: экстремальное свойство нормального распределения — оно максимизирует энтропию при фиксированной дисперсии. Именно поэтому негэнтропия J неотрицательна и обращается в нуль только для гаусса.

11 Вопросы, которые стоит ожидать

- Почему PCA не разделяет источники? (Некоррелированность инвариантна относительно поворотов — лемма 5.1; смеси с повёрнутыми источниками имеют ту же ковариацию I.)
- Почему ICA не работает с гауссовскими источниками? (Независимость гауссовых величин определяется ковариацией; любой поворот снова даёт независимые гауссовы компоненты — теорема 6.4, гауссовский случай.)
- С точностью до чего определены компоненты ICA? (Перестановка и знак; без нормировки дисперсий добавлялась бы свобода масштаба; при отбеливании поиск — по ортогональным матрицам.)
- Что такое отбеливание и зачем оно? (Приведение $\mathsf{D}Z = I$; сводит поиск A к ортогональному и делает корректным скалярное приближение якобиана в FastICA.)
- Две постановки PCA: эквивалентны ли минимизация ошибки реконструкции и максимизация дисперсии? (Да — теорема 4.6; обе решаются сингулярным разложением.)
- Как выбрать число главных компонент? (Доля объяснённой дисперсии, «локоть» спектра, сравнение со спектром перемешанных данных.)
- Что минимизирует FastICA и почему итерация имеет такой вид? (Приближение негэнтропии; шаг — одна итерация Ньютона лагранжева уравнения с приближённым якобианом.)
- Формула Эккарта — Янга в двух нормах и её следствия.

12 Источники

Основные источники вопроса. Локаторы (параграфы и страницы) даны в README этого вопроса.

[16] (Хасти, Тибширани, Фридман) — главный источник: PCA как последовательность наилучших линейных аппроксимаций и её решение через SVD, свойство максимума дисперсии; главные компоненты в гребневой регрессии; латентные переменные, неопределённость вращения, факторный анализ; модель ICA, отбеливание, дифференциальная энтропия, взаимная информация, негэнтропия и её приближение, куртозис как классическая мера, FastICA (изложение по обзору Hyvärinen—Oja, на который опирается книга).

[01] (Бобень, Сиренева) — сингулярные базисы и сингулярное разложение с доказательством единственности сингулярных чисел, усечённое разложение, норма Фробениуса и её ортогональная инвариантность, теорема Эккарта — Янга в норме Фробениуса с доказательством (техническая лемма о взвешенных суммах).

[02] (Голуб, Ван Лоун) — сингулярное разложение с доказательством (индукция по минимальному размеру), спектральные и фробениусовы характеризации норм через сингулярные числа, численный ранг и ε-ранг, теорема Эккарта — Янга в спектральной норме с доказательством через пересечение ядер.

[06] (Турчин) — математическая статистика: ковариационная матрица и её преобразование при линейном отображении, многомерное нормальное распределение, связь независимости и некоррелированности для гауссовых векторов (фон разделов 4 и 6).

Вывод идентифицируемости ICA (теорема 6.4) дан в конспекте полностью на классической теореме Дармуа — Скитовича 6.3, которая цитируется по Кагану — Линнику — Рао (1972) и Comon (1994) без доказательства (классический результат теории характеризаций, в книгах набора отсутствует).