# Линейная и логистическая регрессии

Вопрос 18

Крохалев Е. М.

2026

# Постановка

# Зачем это нужно

- По наблюдениям $y$ от факторов $x$ восстановить зависимость и прогнозировать.
- Непрерывный отклик — линейная регрессия; бинарный — логистическая.
- Тот же сюжет, что и обучение моделей по данным: шумные измерения делают задачу плохо обусловленной, и нужна регуляризация.

# Формальная постановка

Модель: $y_i = a_i^\intercal \theta + \varepsilon_i$, $i = 1, \dots, m$; матрично

$$y = A\theta + \varepsilon,$$

$A \in \mathbb{R}^{m \times n}$ — матрица плана (первый столбец — единицы), $\theta \in \mathbb{R}^n$ — неизвестные параметры, $\sigma^2$ — дисперсия шума.

Оценка: $\widehat{\theta} = \arg\min_\theta \|A\theta - y\|_2^2$ — метод наименьших квадратов.

# Основные результаты

# МНК: нормальные уравнения

**Теорема 1 (нормальные уравнения)**

*Вектор $\hat{\theta}$ минимизирует $Q$ тогда и только тогда, когда*

$$A^{\mathsf{T}}(A\hat{\theta} - y) = 0.$$

*Если $\operatorname{rank} A = n$, то решение единственно и имеет вид*

$$\hat{\theta} = (A^{\mathsf{T}}A)^{-1}A^{\mathsf{T}}y.$$

**Схема:** разность квадратов $\|A(\theta + tz) - y\|^2$ линейна по $t$ в члене $2tz^{\mathsf{T}}A^{\mathsf{T}}(A\theta - y)$; если он не нуль, сдвиг вдоль $-A^{\mathsf{T}}(A\theta - y)$ уменьшает норму. Полное доказательство — в конспекте.

# Геометрия: проекция

- Невязка $r = y - A\hat{\theta}$ ортогональна столбцам $A$: $\hat{y} = A\hat{\theta}$ — ортогональная проекция $y$ на $\mathrm{range}(A)$.
- При неполном ранге решений много (выпуклое множество); есть единственное решение минимальной нормы:

$$\hat{\theta} = \sum_{j=1}^{r} \frac{u_j^{\mathsf{T}} y}{d_j} v_j$$

  по сингулярному разложению (псевдообратная Мура—Пенроуза).

**Теорема 2 (Гаусс — Марков)**

*При посылках (G) оценка $\hat{\theta}$ наименьших квадратов — наилучшая линейная несмещённая оценка (англ. best linear unbiased estimator, BLUE): для любой линейной оценки $\tilde{\theta} = Cy$ $(C \in \mathbb{R}^{n\times m})$, несмещённой для всех $\theta$ при верной модели ($CA = I_n$), выполнено*

$$\mathsf{D}\hat{\theta} \preceq \mathsf{D}\tilde{\theta}$$

*(разность ковариаций положительно полуопределена), и равенство достигается только при $C = (A^{\mathsf{T}}A)^{-1}A^{\mathsf{T}}$.*

**Схема:** несмещённость даёт $C = (A^{\mathsf{T}}A)^{-1}A^{\mathsf{T}} + D$ с $DA = 0$; тогда $\mathsf{D}\tilde{\theta} = \mathsf{D}\hat{\theta} + \sigma^2 DD^{\mathsf{T}}$.

# Где ломается

- Нормальность ошибок не нужна — нужны $\mathrm{E}\varepsilon = 0$, $\mathrm{D}\varepsilon = \sigma^2 I$, полный ранг.
- Без несмещённости «оптимальность» исчезает: $\widetilde{\theta} = c\widehat{\theta}$, $c < 1$, имеет меньшую дисперсию, но смещена.
- Несмещённая оценка дисперсии: $\widehat{\sigma}^2 = \|y - A\widehat{\theta}\|^2/(m-n)$; правдоподобие даёт смещённую оценку с делением на $m$.

**Теорема 3 (МНК как максимальное правдоподобие)**

*Пусть* $\varepsilon \sim \mathcal{N}(0, \sigma^2 I_m)$. *Тогда:*

*1. оценка максимального правдоподобия параметра* $\theta$ *совпадает с оценкой МНК; 2.* $\hat{\theta} \sim \mathcal{N}(\theta, \sigma^2 (A^{\mathrm{T}} A)^{-1})$; *3.* $(m-n)\hat{\sigma}^2/\sigma^2 \sim \chi^2_{m-n}$ *и оценки* $\hat{\theta}$ *и* $\hat{\sigma}^2$ *независимы; 4. оценка максимального правдоподобия дисперсии смещена:* $\hat{\sigma}^2_{\mathrm{ML}} = \frac{\|y - A\hat{\theta}\|_2^2}{m}$, $\mathsf{E}\hat{\sigma}^2_{\mathrm{ML}} = \frac{m-n}{m}\sigma^2$.

Из этого — t-статистики коэффициентов (предмет статистической проверки гипотез).

# Цена нормальных уравнений

**Теорема 4 (погрешность метода нормальных уравнений)**

*Если $\widehat{\theta}_{NE}$ — решение, вычисленное по нормальным уравнениям в машинной арифметике с точностью $u$ при точном формировании $A^{\mathsf{T}}A$ и $A^{\mathsf{T}}y$, то*

$$\frac{\|\hat{\theta}_{NE} - \hat{\theta}\|_2}{\|\hat{\theta}\|_2} \approx u\,\kappa_2(A)^2.$$

Чувствительность самой задачи к данным ($\kappa_2 = d_1/d_n$, $\sin\theta = \|r\|/\|y\|$):

$$\frac{\|\hat{\theta} - \theta\|_2}{\|\theta\|_2} \le \varepsilon\Big\{\frac{2\kappa_2(A)}{\cos\theta} + \tan\theta\,\kappa_2(A)^2\Big\} + O(\varepsilon^2).$$

При ненулевой невязке — квадратичная зависимость от обусловленности.

# QR и SVD

- QR-разложение $A = QR$: $\hat{\theta}$ из $R\hat{\theta} = Q^{\mathsf{T}} y$ — обратно устойчива схема.
- SVD: решение минимальной нормы, контроль численного ранга, отсечение малых сингулярных чисел.
- Стоимость ($m \geq n$): нормальные уравнения $mn^2 + n^3/3$; Хаусхолдер $2mn^2 - \frac{2}{3}n^3$; SVD Чана $2mn^2 + 11n^3$.

**Теорема 5 (существование, единственность и фильтр)**

*Задача гребня имеет единственное решение*

$$\hat{\theta}_\alpha = (A^\intercal A + \alpha I)^{-1} A^\intercal y,$$

*линейное по* $y$. *Если* $A = U\Sigma V^\intercal$ *— сингулярное разложение, то*

$$\hat{\theta}_\alpha = \sum_{j=1}^{n} \frac{d_j}{d_j^2 + \alpha} \, (u_j^\intercal y)\, v_j, \qquad A\hat{\theta}_\alpha = \sum_{j=1}^{n} \frac{d_j^2}{d_j^2 + \alpha} \, (u_j^\intercal y)\, u_j.$$

*Коэффициенты* $\dfrac{d_j^2}{d_j^2 + \alpha} \le 1$ *— фильтр: направления с малыми сингулярными числами сжимаются сильнее.*

Эффективные степени свободы $\mathrm{df}(\alpha) = \sum_j d_j^2/(d_j^2 + \alpha)$ падают от $n$ до $0$. Смещение есть, дисперсия меньше — обмен по кривой «смещение — дисперсия». Лассо ($L_1$-штраф) обнуляет коэффициенты и отбирает факторы.

# Обучение первыми методами

- Градиентный спуск: $\nabla Q = 2A^{\intercal}(A\theta - y)$, шаг $\eta \leq 1/L$, $L = 2d_1^2$ (лемма спуска).
- Стохастический спуск: несмещённая оценка градиента по минибатчу, шаги Роббинса–Монро, дисперсия $\sim 1/b$.
- Метод тяжёлого шарика (momentum): коэффициент $(\sqrt{\kappa} - 1)/(\sqrt{\kappa} + 1)$ вместо $(\kappa - 1)/(\kappa + 1)$.

# Логистическая регрессия: модель

**Определение 6 (логистическая модель)**

$$\mathsf{P}(y_i = 1 \mid a_i) = p_i(\theta) = s(a_i^\intercal \theta), \qquad s(z) = \frac{1}{1 + e^{-z}}.$$

Правдоподобие Бернулли; log-loss (бинарная перекрёстная энтропия):

$$Q(\theta) = \sum_{i=1}^{m} \left[\ln\left(1 + e^{a_i^\intercal \theta}\right) - y_i \, a_i^\intercal \theta\right].$$

Явной формулы минимизатора нет — обучение итеративное.

# Log-loss: градиент и гессиан

**Теорема 7 (гладкость, выпуклость, градиент и гессиан)**

*$Q$ выпукла и бесконечно дифференцируема; с обозначениями $p = (p_i), W = \operatorname{diag}(p_i(1-p_i))$:*

$$\nabla Q(\theta) = A^{\intercal}(p - y), \qquad \nabla^2 Q(\theta) = A^{\intercal} W A \succeq 0.$$

*Если $\operatorname{rank} A = n$ и все $0 < p_i < 1$, то $Q$ строго выпукла, и её минимум (если существует) единствен.*

Оценочные уравнения $A^{\intercal}(y - p) = 0$ нелинейны; при константном столбце $\sum_i y_i = \sum_i p_i$.

**Теорема 8 (метод Ньютона и IRLS)**

*Шаг Ньютона для $Q$ с текущей точки $\theta$:*

$$\theta^+ = \theta + (A^\intercal W A)^{-1} A^\intercal (y - p).$$

*Он совпадает с решением взвешенной задачи наименьших квадратов с весами $W$ и рабочим откликом $z = A\theta + W^{-1}(y - p)$:*

$$\theta^+ = \arg\min_{\varphi} (z - A\varphi)^\intercal W (z - A\varphi).$$

Сходимость: локально квадратичная; промахи гасят демпфированием (деление шага пополам). Регуляризация $\frac{\alpha}{2}\|\theta\|^2$ делает гессиан положительно определённым.

# Разделимость классов

- Разделимая выборка: $\inf Q$ не достигается, $\|\widehat{\theta}\| \to \infty$ — оценки максимального правдоподобия нет.
- Идеально точная классификация на обучении для логистической регрессии — признак ухода оценки на бесконечность.
- Выход: гребневая регуляризация (существование и единственность минимума) или остановка по изменению прогнозов.

# Метрики качества

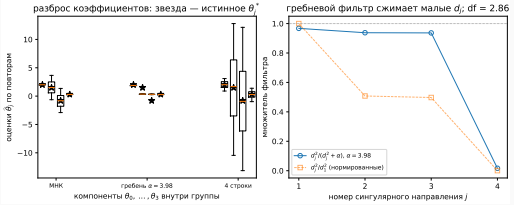
| Метрика | Определение | Когда важна |
|---|---|---|
| Accuracy | $(\mathrm{TP}+\mathrm{TN})/m$ | классы сбалансированы |
| Precision | $\mathrm{TP}/(\mathrm{TP}+\mathrm{FP})$ | цена ложной тревоги высока |
| Recall | $\mathrm{TP}/(\mathrm{TP}+\mathrm{FN})$ | цена пропуска высока |

Accuracy бесполезна при дисбалансе; порог $\pi$ в $\widehat{y}=\mathbb{1}\{p>\pi\}$ балансирует precision и recall.

# Численная иллюстрация

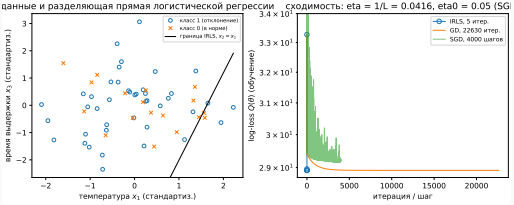
# Что считаем

- Один сквозной пример: выход процесса по двум коррелированным факторам и времени выдержки.
- МНК против гребня при мультиколлинеарности; кривая «смещение — дисперсия».
- Нормальные уравнения против QR при росте обусловленности.
- Логистическая регрессия: IRLS против GD/SGD; разделимость и регуляризация.



# Логистическая часть

- Данные с умеренным перекрытием классов: IRLS сходится за считанные итерации, GD/SGD — медленнее.
- Почти разделимые данные: без регуляризации норма вектора весов растёт, с гребнем — нет.



# Задачи

# Гребень через сингулярное разложение

**Условие.** $A = U\Sigma V^{\mathrm{T}}$. Вывести $\hat{\theta}_\alpha$ и доказать, что $\|\hat{\theta}_\alpha\|_2 < \|\hat{\theta}\|_2$ при $\alpha > 0$, если $\hat{\theta} \neq 0$.

# Гребень через сингулярное разложение

**Условие.** $A = U\Sigma V^\intercal$. Вывести $\hat{\theta}_\alpha$ и доказать, что $\|\hat{\theta}_\alpha\|_2 < \|\hat{\theta}\|_2$ при $\alpha > 0$, если $\hat{\theta} \neq 0$.

**Решение.** В базисе $V$:

$$\|\hat{\theta}_\alpha\|_2^2 = \sum_{j=1}^{n} \frac{d_j^2}{(d_j^2 + \alpha)^2} (u_j^\intercal y)^2 < \sum_{j=1}^{n} \frac{1}{d_j^2} (u_j^\intercal y)^2 = \|\hat{\theta}\|_2^2,$$

так как $d_j^2/(d_j^2 + \alpha)^2 < 1/d_j^2$.

# Где это работает

| Постановка | Что минимизируется | Ответ | Что покупается |
|---|---|---|---|
| Линейная регрессия, полный ранг | $\|A\theta - y\|_2^2$ | $(A^\top A)^{-1} A^\top y$ | несмещённость, BLUE |
| Плохо обусловлена | $\|A\theta - y\|^2 + \alpha\|\theta\|^2$ | $(A^\top A + \alpha I)^{-1} A^\top y$ | устойчивость ценой смещения |
| Большие $m, n$ | то же, итеративно | GD/SGD, momentum | масштабируемость |
| Бинарный отклик | log-loss | IRLS / GD / SGD | вероятность класса |

# Итог

## Что нужно помнить

- МНК — проекция; нормальные уравнения; полный ранг → единственность, иначе минимальная норма.
- Гаусс — Марков: BLUE при некоррелированных равнодисперсных ошибках.
- Численно: нормальные уравнения дороги при большом $\kappa_2$; QR/SVD.
- Гребень сжимает малые сингулярные направления; лассо отбирает факторы.
- Логистическая регрессия: log-loss выпукла; обучение — IRLS (Ньютон = взвешенная МНК).
- Разделимость выборки делает оценку максимального правдоподобия несуществующей — лечится регуляризацией.