Линейная и логистическая регрессии

Вопрос 18

Крохалев Е. М.

2026

Постановка

Зачем это нужно

- По наблюдениям y от факторов x восстановить зависимость и прогнозировать.
- Непрерывный отклик — линейная регрессия; бинарный — логистическая.
- Тот же сюжет, что и обучение моделей по данным: шумные измерения делают задачу плохо обусловленной, и нужна регуляризация.

Формальная постановка

Модель: $y_i = a_i^\intercal \theta + \varepsilon_i$, $i = 1, \dots, m$; матрично

$$y = A\theta + \varepsilon,$$

$A \in \mathbb{R}^{m \times n}$ — матрица плана (первый столбец — единицы), $\theta \in \mathbb{R}^n$ — неизвестные параметры, σ^2 — дисперсия шума.

Оценка: $\widehat{\theta} = \arg\min_\theta \|A\theta - y\|_2^2$ — метод наименьших квадратов.

Основные результаты

МНК: нормальные уравнения

Теорема 1 (нормальные уравнения)

Вектор $\hat{\theta}$ минимизирует Q тогда и только тогда, когда

$$A^{\mathsf{T}}(A\hat{\theta} - y) = 0.$$

Если $\operatorname{rank} A = n$, то решение единственно и имеет вид

$$\hat{\theta} = (A^{\mathsf{T}}A)^{-1}A^{\mathsf{T}}y.$$

Схема: разность квадратов $\|A(\theta + tz) - y\|^2$ линейна по t в члене $2tz^{\mathsf{T}}A^{\mathsf{T}}(A\theta - y)$; если он не нуль, сдвиг вдоль $-A^{\mathsf{T}}(A\theta - y)$ уменьшает норму. Полное доказательство — в конспекте.

Геометрия: проекция

- Невязка $r = y - A\hat{\theta}$ ортогональна столбцам A: $\hat{y} = A\hat{\theta}$ — ортогональная проекция y на $\mathrm{range}(A)$.
- При неполном ранге $r = \mathrm{rank}\, A$ решений много (выпуклое множество); есть единственное решение минимальной нормы:

$$\hat{\theta} = \sum_{j=1}^{r} \frac{u_j^{\mathsf{T}} y}{d_j} v_j$$

по сингулярному разложению (псевдообратная Мура — Пенроуза).

Теорема Гаусса — Маркова

Посылки (G): $\mathsf{E}\varepsilon = 0$, $\mathsf{D}\varepsilon = \sigma^2 I$, A полного ранга n.

Теорема 2 (Гаусс — Марков)

При посылках (G) оценка $\hat{\theta}$ наименьших квадратов — наилучшая линейная несмещённая оценка (англ. best linear unbiased estimator, BLUE): для любой линейной оценки $\tilde{\theta} = Cy$ $(C \in \mathbb{R}^{n\times m})$, несмещённой для всех θ при верной модели ($CA = I_n$), выполнено

$$\mathsf{D}\hat{\theta} \preceq \mathsf{D}\tilde{\theta}$$

(разность ковариаций положительно полуопределена), и равенство достигается только при $C = (A^{\mathsf{T}}A)^{-1}A^{\mathsf{T}}$.

Схема: несмещённость даёт $C = (A^{\mathsf{T}}A)^{-1}A^{\mathsf{T}} + D$ с $DA = 0$; тогда $\mathsf{D}\tilde{\theta} = \mathsf{D}\hat{\theta} + \sigma^2 DD^{\mathsf{T}}$.

Где ломается

- Нормальность ошибок не нужна — нужны $\mathrm{E}\varepsilon = 0$, $\mathrm{D}\varepsilon = \sigma^2 I$, полный ранг.
- Без несмещённости «оптимальность» исчезает: $\widetilde{\theta} = c\widehat{\theta}$, $c < 1$, имеет меньшую дисперсию, но смещена.
- Несмещённая оценка дисперсии: $\widehat{\sigma}^2 = \|y - A\widehat{\theta}\|^2/(m-n)$; правдоподобие даёт смещённую оценку с делением на m.

МНК и максимальное правдоподобие

Несмещённая оценка дисперсии: $\hat{\sigma}^2 = \|y - A\hat{\theta}\|_2^2/(m-n)$.

Теорема 3 (МНК как максимальное правдоподобие)

Пусть $\varepsilon \sim \mathcal{N}(0, \sigma^2 I_m)$. *Тогда:*

1. оценка максимального правдоподобия параметра θ *совпадает с оценкой МНК; 2.* $\hat{\theta} \sim \mathcal{N}(\theta, \sigma^2(A^{\mathsf{T}}A)^{-1})$; *3.* $(m-n)\hat{\sigma}^2/\sigma^2 \sim \chi^2_{m-n}$ *и оценки* $\hat{\theta}$ *и* $\hat{\sigma}^2$ *независимы; 4. оценка максимального правдоподобия дисперсии смещена:* $\hat{\sigma}^2_{\mathrm{ML}} = \frac{\|y-A\hat{\theta}\|_2^2}{m}$, $\mathsf{E}\hat{\sigma}^2_{\mathrm{ML}} = \frac{m-n}{m}\sigma^2$.

Из этого — t-статистики коэффициентов (предмет статистической проверки гипотез).

Цена нормальных уравнений

Теорема 4 (погрешность метода нормальных уравнений)

Если $\widehat{\theta}_{NE}$ — решение, вычисленное по нормальным уравнениям в машинной арифметике с точностью u при точном формировании $A^{\mathsf{T}}A$ и $A^{\mathsf{T}}y$, то

$$\frac{\|\widehat{\theta}_{NE} - \widehat{\theta}\|_2}{\|\widehat{\theta}\|_2} \approx u\,\kappa_2(A)^2.$$

Чувствительность самой задачи к данным ($\kappa_2 = d_1/d_n$; φ — угол невязки, $\sin\varphi = \|r\|/\|y\|$; δ — относительная величина возмущения данных):

$$\frac{\|\widehat{\theta} - \theta_{LS}\|_2}{\|\theta_{LS}\|_2} \le \delta\left\{\frac{2\kappa_2(A)}{\cos\varphi} + \tan\varphi\,\kappa_2(A)^2\right\} + O(\delta^2).$$

При ненулевой невязке — квадратичная зависимость от обусловленности.

QR и SVD

- QR-разложение $A = QR$: $\hat{\theta}$ из $R\hat{\theta} = Q^{\mathsf{T}} y$ — обратно устойчива схема.
- SVD: решение минимальной нормы, контроль численного ранга, отсечение малых сингулярных чисел.
- Стоимость ($m \geq n$): нормальные уравнения $mn^2 + n^3/3$; Хаусхолдер $2mn^2 - \frac{2}{3}n^3$; SVD Чана $2mn^2 + 11n^3$.

Теорема 5 (существование, единственность и фильтр)

При $\alpha > 0$ задача гребня имеет единственное решение

$$\hat{\theta}_\alpha = (A^\top A + \alpha I)^{-1} A^\top y,$$

линейное по y; при $\alpha = 0$ это оценка наименьших квадратов (единственная при полном ранге A; при неполном решение минимальной нормы получается как предел $\hat{\theta}_\alpha$ при $\alpha \to 0^+$). Если $A = U\Sigma V^\top$ – сингулярное разложение, то

$$\hat{\theta}_\alpha = \sum_{j=1}^{n} \frac{d_j}{d_j^2 + \alpha} (u_j^\top y)\, v_j, \qquad A\hat{\theta}_\alpha = \sum_{j=1}^{n} \frac{d_j^2}{d_j^2 + \alpha} (u_j^\top y)\, u_j.$$

Коэффициенты $\dfrac{d_j^2}{d_j^2 + \alpha} \le 1$ – фильтр: направления с малыми сингулярными числами сжимаются сильнее.

Эффективные степени свободы $\mathrm{df}(\alpha) = \sum_j d_j^2/(d_j^2 + \alpha)$ падают от $r = \operatorname{rank} A$ до 0; смещение есть, дисперсия меньше. Лассо (L_1-штраф) обнуляет коэффициенты и отбирает факторы.

Обучение первыми методами

- Градиентный спуск: $\nabla Q = 2A^{\intercal}(A\theta - y)$, $L = 2d_1^2$, $\mu = 2d_n^2$, $\kappa = L/\mu$ (для МНК $\kappa = \kappa_2(A)^2$); при $\eta = 1/L$ сжатие $(1 - 1/\kappa)$, оптимальный шаг $2/(L + \mu) - (\kappa - 1)/(\kappa + 1)$.
- Стохастический спуск: несмещённая оценка градиента по минибатчу, шаги Роббинса — Монро, дисперсия $\sim 1/b$.
- Метод тяжёлого шарика (momentum): коэффициент $(\sqrt{\kappa} - 1)/(\sqrt{\kappa} + 1)$ вместо $(\kappa - 1)/(\kappa + 1)$.

Логистическая регрессия: модель

Определение 6 (логистическая модель)

$$\mathsf{P}(y_i = 1 \mid a_i) = p_i(\theta) = s(a_i^\intercal \theta), \qquad s(z) = \frac{1}{1 + e^{-z}}.$$

Логит линеен: $\ln \frac{p}{1-p} = a^\intercal \theta$; e^{θ_j} — отношение шансов.

Правдоподобие Бернулли; log-loss (бинарная перекрёстная энтропия):

$$Q(\theta) = \sum_{i=1}^{m} \left[\ln\left(1 + e^{a_i^\intercal \theta}\right) - y_i \, a_i^\intercal \theta\right].$$

Явной формулы минимизатора нет — обучение итеративное.

Log-loss: градиент и гессиан

Теорема 7 (гладкость, выпуклость, градиент и гессиан)

Q выпукла и бесконечно дифференцируема; с обозначениями $p = (p_i), W = \operatorname{diag}(p_i(1-p_i))$:

$$\nabla Q(\theta) = A^{\mathsf{T}}(p - y), \qquad \nabla^2 Q(\theta) = A^{\mathsf{T}} W A \succeq 0.$$

Если $\operatorname{rank} A = n$ и все $0 < p_i < 1$, то Q строго выпукла, и её минимум (если существует) единствен. Минимум Q существует тогда и только тогда, когда выполнено условие перекрытия: для любого $z \in \mathbb{R}^n$ с $Az \neq 0$ найдётся i такой, что $a_i^{\mathsf{T}} z > 0$, $y_i = 0$, либо $a_i^{\mathsf{T}} z < 0$, $y_i = 1$.

Оценочные уравнения $A^{\mathsf{T}}(y - p) = 0$ нелинейны; при константном столбце $\sum_i y_i = \sum_i p_i$.

Теорема 8 (метод Ньютона и IRLS)

Пусть $\operatorname{rank} A = n$. *Шаг Ньютона для* Q *с текущей точки* θ:

$$\theta^{+} = \theta + (A^{\mathsf{T}} W A)^{-1} A^{\mathsf{T}} (y - p).$$

Он совпадает с решением взвешенной задачи наименьших квадратов с весами W *и рабочим откликом* $z = A\theta + W^{-1}(y - p)$:

$$\theta^{+} = \arg\min_{\vartheta} (z - A\vartheta)^{\mathsf{T}} W (z - A\vartheta).$$

Сходимость: локально квадратичная; промахи гасят демпфированием (деление шага пополам). Регуляризация $\frac{\alpha}{2}\|\theta\|^2$ делает гессиан положительно определённым.

Разделимость классов

- Разделимая или слабо разделимая выборка: минимум Q не достигается — ОМП не существует, $\|\theta_k\|$ растёт (критерий существования — условие перекрытия).
- На почти разделимых данных ОМП существует и сходимость честная (пример: плато нормы, гребень улучшает тест); ложная остановка критерия $\|\nabla Q\| < \varepsilon$ — удел точно разделимых данных.
- Идеально точная классификация обучения — признак ухода оценки на бесконечность. Выход — гребневая регуляризация или остановка по изменению прогнозов.

Метрики качества

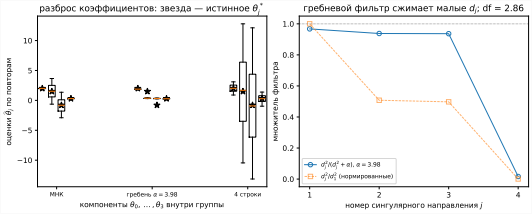
Классификация: $\hat{y} = \mathbb{1}\{p > \pi\}$, по умолчанию $\pi = 1/2$.

Метрика	Определение	Когда важна
Accuracy	$(\mathrm{TP} + \mathrm{TN})/m$	классы сбалансированы
Precision	$\mathrm{TP}/(\mathrm{TP} + \mathrm{FP})$	цена ложной тревоги высока
Recall	$\mathrm{TP}/(\mathrm{TP} + \mathrm{FN})$	цена пропуска высока
F_1	$2\,\frac{\mathrm{precision}\cdot\mathrm{recall}}{\mathrm{precision}+\mathrm{recall}}$	один баланс P и R

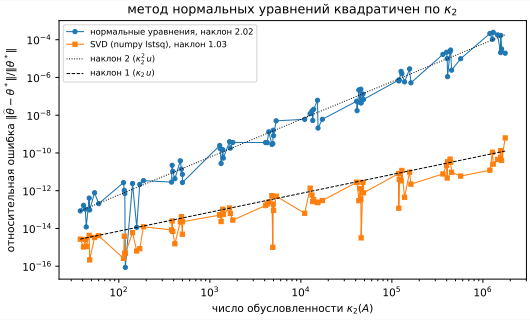
Accuracy бесполезна при дисбалансе; порог π балансирует precision и recall; компромисс целиком — ROC-кривая, её площадь — AUC.

Численная иллюстрация

Линейная часть

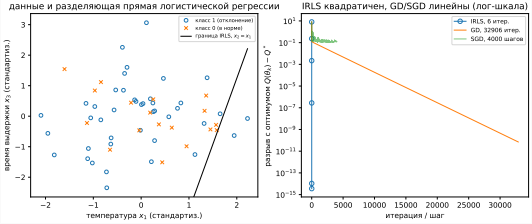


МНК против гребня: разброс коэффициентов и фильтр сингулярных чисел.

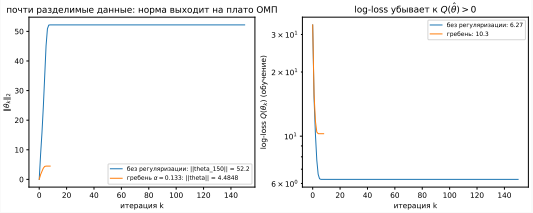


Нормальные уравнения против SVD: ошибка $\sim \kappa^2$ против $\sim \kappa$.

Логистическая часть



IRLS — квадратичная сходимость; GD/SGD — линейная ($Q - Q^*$ в лог-масштабе).



Почти разделимые данные: норма без регуляризации выходит на плато, гребень улучшает тест.

Задачи

Гребень через сингулярное разложение

Условие. $A = U\Sigma V^{\mathrm{T}}$. Вывести $\hat{\theta}_\alpha$ и доказать, что $\|\hat{\theta}_\alpha\|_2 < \|\hat{\theta}\|_2$ при $\alpha > 0$, если $\hat{\theta} \neq 0$.

Гребень через сингулярное разложение

Условие. $A = U\Sigma V^\intercal$. Вывести $\hat{\theta}_\alpha$ и доказать, что $\|\hat{\theta}_\alpha\|_2 < \|\hat{\theta}\|_2$ при $\alpha > 0$, если $\hat{\theta} \neq 0$.

Решение. В базисе V:

$$\|\hat{\theta}_\alpha\|_2^2 = \sum_{j=1}^{n} \frac{d_j^2}{(d_j^2 + \alpha)^2} (u_j^\intercal y)^2 < \sum_{j=1}^{n} \frac{1}{d_j^2} (u_j^\intercal y)^2 = \|\hat{\theta}\|_2^2,$$

так как $d_j^2/(d_j^2 + \alpha)^2 < 1/d_j^2$.

Где это работает

Постановка	Что минимизируется	Ответ	Что покупается
Линейная регрессия, полный ранг	$\|A\theta - y\|_2^2$	$(A^\top A)^{-1} A^\top y$	несмещённость, BLUE
Плохо обусловлена	$\|A\theta - y\|^2 + \alpha\|\theta\|^2$	$(A^\top A + \alpha I)^{-1} A^\top y$	устойчивость ценой смещения
Большие m, n	то же, итеративно	GD/SGD, momentum	масштабируемость
Бинарный отклик	log-loss	IRLS / GD / SGD	вероятность класса

Итог

Что нужно помнить

- МНК — проекция; нормальные уравнения; полный ранг → единственность, иначе минимальная норма.
- Гаусс — Марков: BLUE при некоррелированных равнодисперсных ошибках.
- Численно: нормальные уравнения дороги при большом κ_2; QR/SVD.
- Гребень сжимает малые сингулярные направления; лассо отбирает факторы.
- Логистическая регрессия: log-loss выпукла; обучение — IRLS (Ньютон = взвешенная МНК).
- Разделимость выборки делает оценку максимального правдоподобия несуществующей — лечится регуляризацией.