Вопрос 18. Линейная и логистическая регрессии

Конспект теории с полными доказательствами

Крохалев Е. М.

2026

Содержание

1 Постановка и мотивация 1

2 Линейная модель и оценка наименьших квадратов 2

3 Статистические свойства оценки МНК 3

4 Численная сторона МНК 6

5 Регуляризация: гребень и лассо 8

6 Обучение регрессий первыми методами 10

7 Логистическая регрессия 10

8 Метрики качества бинарной классификации 14

9 Разобранные задачи 14

10 Вопросы, которые стоит ожидать 15

11 Источники 15

1 Постановка и мотивация

Регрессия отвечает на главный вопрос математического моделирования: по наблюдениям зависимой величины y от факторов x восстановить функциональную связь и использовать её для прогноза. Когда о связи известно только то, что она приблизительно линейна, модель записывается как

$$y_i = a_i^{\mathsf{T}}\theta + \varepsilon_i, \qquad i = 1, \dots, m,$$

где $a_i \in \mathbb{R}^n$ — известный вектор факторов i-го наблюдения (первая компонента равна 1, если в модели есть свободный член), $\theta \in \mathbb{R}^n$ — неизвестный вектор параметров, ε_i — ошибка модели и измерения. Вопрос развивает два сюжета: оценка наименьших квадратов для непрерывного отклика и логистическая регрессия (англ. *logistic regression*) для бинарного.

Метод наименьших квадратов (МНК, англ. *least squares*) — проекция вектора наблюдений на линейную оболочку столбцов матрицы плана: это ортогональная проекция в смысле вопроса 09 (теория Рисса). При шумных данных постановка становится плохо обусловленной и требует регуляризации — её теория дана в вопросе 02 (регуляризация Тихонова = гребневая регрессия); здесь та же конструкция получается с оценочной стороны. Логистическая регрессия переводит линейную модель на бинарный отклик через вероятность и обучается уже не явной формулой, а методами минимизации из вопроса 10 (минимизация функций многих переменных).

Обозначения. m — число наблюдений, n — число параметров ($m \geq n$), матрица плана $A \in \mathbb{R}^{m\times n}$ имеет строки a_i^{T}. Сингулярные числа A: $d_1 \geq \ldots \geq d_n \geq 0$ (обозначение как в [вопросе 02](../02-ml-inverse-problems/), где буква σ занята дисперсией шума). Дисперсия шума — σ^2. Сигмоида: $s(z) = 1/(1+e^{-z})$. Оценки обозначаются $\hat{\theta}$, невязка МНК $r = y - A\hat{\theta}$.

2 Линейная модель и оценка наименьших квадратов

Определение 2.1 (линейная регрессионная модель)**.** Наблюдения y_i порождаются моделью

$$y_i = a_i^{\mathsf{T}}\theta + \varepsilon_i, \qquad i = 1, \ldots, m,$$

где $\theta \in \mathbb{R}^n$ неизвестно, ошибки ε_i — случайные величины. Матричная запись: $y = A\theta + \varepsilon$.

Определение 2.2 (оценка МНК)**.** Оценкой наименьших квадратов называется любой вектор

$$\hat{\theta} \in \arg\min_{\theta\in\mathbb{R}^n} Q(\theta), \qquad Q(\theta) = \|A\theta - y\|_2^2 = \sum_{i=1}^{m} (a_i^{\mathsf{T}}\theta - y_i)^2.$$

Величина $Q(\hat{\theta})$ — остаточная сумма квадратов (RSS).

Условия минимума называются нормальными уравнениями (англ. *normal equations*).

Теорема 2.3 (нормальные уравнения)**.** *Вектор $\hat{\theta}$ минимизирует Q тогда и только тогда, когда*

$$A^{\mathsf{T}}(A\hat{\theta} - y) = 0.$$

Если $\operatorname{rank} A = n$*, то решение единственно и имеет вид*

$$\hat{\theta} = (A^{\mathsf{T}}A)^{-1}A^{\mathsf{T}}y.$$

Доказательство. Для любых $\theta, z \in \mathbb{R}^n$ и $t \in \mathbb{R}$ по разности квадратов

$$\|A(\theta + tz) - y\|_2^2 = \|A\theta - y\|_2^2 + 2t\, z^{\mathsf{T}}A^{\mathsf{T}}(A\theta - y) + t^2\|Az\|_2^2. \tag{1}$$

Необходимость. Пусть $\hat{\theta}$ — минимум, но $w := A^{\mathsf{T}}(A\hat{\theta} - y) \neq 0$. Возьмём в (1) $\theta = \hat{\theta}$, $z = -w$ и малый $t > 0$: линейный член $-2t\|w\|_2^2$ отрицателен, квадратичный $t^2\|Aw\|_2^2 = o(t)$, значит при малых t правая часть меньше $Q(\hat{\theta})$ — противоречие.

Достаточность. Если $A^{\mathsf{T}}(A\hat{\theta} - y) = 0$, то в (1) линейный член обнуляется при любом z, и $\|A(\hat{\theta} + z) - y\|_2^2 = Q(\hat{\theta}) + \|Az\|_2^2 \geq Q(\hat{\theta})$.

Единственность при полном ранге. Матрица $A^{\mathsf{T}}A$ симметрична и положительно определена: для $z \neq 0$ имеем $z^{\mathsf{T}}A^{\mathsf{T}}Az = \|Az\|_2^2 > 0$, так как $\operatorname{rank} A = n$ означает $\ker A = \{0\}$. Значит $A^{\mathsf{T}}A$ обратима, и нормальные уравнения дают единственное решение $(A^{\mathsf{T}}A)^{-1}A^{\mathsf{T}}y$. □

Замечание 2.4 (геометрия). Условие $A^{\mathsf{T}}(A\hat{\theta} - y) = 0$ означает ортогональность невязки $r = y - A\hat{\theta}$ всем столбцам A, то есть всему $\operatorname{range}(A)$. Прогноз $\hat{y} = A\hat{\theta}$ — ортогональная проекция y на подпространство $\operatorname{range}(A)$: задача МНК есть задача о наилучшем приближении в гильбертовом пространстве $\mathbb{R}^m$ (вопрос 09, метрические и нормированные пространства, Рисс). При $\operatorname{rank} A = n$ проектор записывается как

$$P_A = A(A^{\mathsf{T}}A)^{-1}A^{\mathsf{T}}, \qquad \hat{y} = P_A y, \qquad r = (I - P_A)y,$$

причём $P_A^{\mathsf{T}} = P_A$, $P_A^2 = P_A$, $\operatorname{tr} P_A = n$ (след равен рангу проектора: в ортонормированном базисе $\operatorname{range}(A)$ дополненного до полного, $P_A = \operatorname{diag}(I_n, 0)$).

Теорема 2.5 (существование и минимальная норма при неполном ранге)**.** *Множество решений задачи МНК непусто, выпукло и замкнуто. Среди решений есть единственное решение минимальной евклидовой нормы; если $d_r > 0 = d_{r+1}$ и $A = U\Sigma V^{\mathsf{T}}$ — сингулярное разложение, то*

$$\hat{\theta} = \sum_{j=1}^{r} \frac{u_j^{\mathsf{T}} y}{d_j}\, v_j,$$

где u_j, v_j — столбцы U, V.

Доказательство. Сведём задачу к координатам сингулярного разложения $A = U\Sigma V^{\mathsf{T}}$: с подстановкой $\zeta = V^{\mathsf{T}}\theta$ (столбцы V ортонормированы) имеем

$$Q(\theta) = \|\Sigma\zeta - U^{\mathsf{T}} y\|_2^2 = \sum_{j=1}^{r} (d_j\zeta_j - u_j^{\mathsf{T}} y)^2 + \sum_{j=r+1}^{m} (u_j^{\mathsf{T}} y)^2, \qquad \|\theta\|_2^2 = \|\zeta\|_2^2.$$

Непустота: первые r слагаемых обращаются в нуль при $\zeta_j = u_j^{\mathsf{T}} y / d_j$ (и только так), последние от θ не зависят — значит любой $\theta = V\zeta$ с такими первыми r координатами решает задачу. Замкнутость: Q непрерывна, и множество решений есть полный прообраз точки $\min Q$.

Выпуклость: если $Q(\theta_1) = Q(\theta_2) = \min Q$, то для $\theta = (\theta_1 + \theta_2)/2$ параллелограммное тождество

$$Q(\theta) = \tfrac{1}{2}Q(\theta_1) + \tfrac{1}{2}Q(\theta_2) - \tfrac{1}{4}\|A(\theta_1 - \theta_2)\|_2^2 \le \min Q,$$

значит $\|A(\theta_1 - \theta_2)\|_2 = 0$; тогда по (1) линейный член обнуляется ($A(\theta_1 - \theta_2) \perp$ невязке) и Q постоянна на отрезке $[\theta_1, \theta_2]$, то есть любая его точка — решение.

Минимум нормы: ядро $\ker A$ натянуто на $v_{r+1}, \dots, v_n$, поэтому сужение Q на $(\ker A)^{\perp}$ в тех же координатах ζ есть сумма квадратов с $d_j \ge d_r > 0$ плюс константа — непрерывная коэрцитивная строго выпуклая функция, и на $(\ker A)^{\perp}$ минимум достигается в единственной точке θ_*. Любое решение отличается от θ_* на вектор $z \in \ker A$, ортогональный к θ_*, так что $\|\theta_* + z\|_2^2 = \|\theta_*\|_2^2 + \|z\|_2^2 \ge \|\theta_*\|_2^2$ с равенством лишь при $z = 0$: решение минимальной нормы существует и единственно. Его координаты $\zeta_j = u_j^{\mathsf{T}} y / d_j$ при $j \le r$ и $\zeta_j = 0$ при $j > r$, то есть $\theta_* = \sum_{j=1}^{r} \frac{u_j^{\mathsf{T}} y}{d_j}\, v_j$. □

Определение 2.6 (псевдообратная матрица)**.** Псевдообратной Мура — Пенроуза (англ. *Moore—Penrose pseudoinverse*) матрицы $A = U\Sigma V^{\mathsf{T}}$ называется $A^{+} = V\Sigma^{+}U^{\mathsf{T}}$, где Σ^{+} получается из Σ транспонированием и заменой положительных сингулярных чисел обратными. Решение минимальной нормы задачи МНК есть $A^{+}y$; при полном ранге столбцов $A^{+} = (A^{\mathsf{T}}A)^{-1}A^{\mathsf{T}}$.

3 Статистические свойства оценки МНК

Далее фиксируем стандартные посылки.

Обозначения (посылки (G))*.* (G1) $y = A\theta + \varepsilon$ при детерминированной матрице A полного ранга ($\operatorname{rank} A = n < m$); (G2) $\mathsf{E}\varepsilon = 0$; (G3) $\mathsf{D}\varepsilon = \sigma^2 I_m$ (ошибки некоррелированы и одинаково дисперсны). Нормальность ошибок пока не предполагается.

Теорема 3.1 (несмещённость и ковариация)**.** *При посылках (G)* $\mathsf{E}\hat{\theta} = \theta$ *и* $\mathsf{D}\hat{\theta} = \sigma^2 (A^{\mathsf{T}}A)^{-1}$.

Доказательство. Оценка линейна по y: $\hat\theta = (A^\top A)^{-1}A^\top y = \theta + (A^\top A)^{-1}A^\top\varepsilon$, откуда $\mathsf{E}\hat\theta = \theta$. Для ковариации линейного преобразования $\mathsf{D}(M\varepsilon) = M(\mathsf{D}\varepsilon)M^\top$ при $M = (A^\top A)^{-1}A^\top$ получаем $\mathsf{D}\hat\theta = \sigma^2(A^\top A)^{-1}A^\top A(A^\top A)^{-1} = \sigma^2(A^\top A)^{-1}$. □

Лемма 3.2. *Пусть $P \in \mathbb{R}^{m\times m}$ симметрична и идемпотентна,* $\operatorname{rank} P = k$*, а $\mathsf{E}\varepsilon = 0$ и $\mathsf{D}\varepsilon = \sigma^2 I_m$. Тогда $\mathsf{E}\|P\varepsilon\|_2^2 = \sigma^2 k$.*

Доказательство. Симметричная идемпотентная матрица есть ортопроектор: в её спектральном разложении $P = W\operatorname{diag}(I_k, 0)W^\top$ с ортогональной W. Тогда

$$\mathsf{E}\|P\varepsilon\|_2^2 = \mathsf{E}\big[\operatorname{tr}(P\varepsilon\varepsilon^\top P)\big] = \operatorname{tr}\big(P\,\mathsf{E}[\varepsilon\varepsilon^\top]P\big) = \sigma^2\operatorname{tr}P^2 = \sigma^2\operatorname{tr}P = \sigma^2 k,$$

где использованы линейность следа, $\mathsf{E}[\varepsilon\varepsilon^\top] = \sigma^2 I_m$ и $\operatorname{tr}P = k$ (след равен сумме собственных значений, у P их ровно k единичных). □

Теорема 3.3 (несмещённая оценка дисперсии)**.** *При посылках (G) оценка*

$$\hat\sigma^2 = \frac{\|y - A\hat\theta\|_2^2}{m - n}$$

несмещена: $\mathsf{E}\hat\sigma^2 = \sigma^2$.

Доказательство. По теореме 3.1 $A\hat\theta - A\theta = A(A^\top A)^{-1}A^\top\varepsilon = P_A\varepsilon$, поэтому $y - A\hat\theta = (I - P_A)\varepsilon$. Матрица $I - P_A$ — ортопроектор на $\operatorname{range}(A)^\perp$ ранга $m - n$ (см. замечание 2.4), остаётся применить лемму 3.2. □

Теорема Гаусса — Маркова (англ. *Gauss—Markov theorem*) утверждает, что среди линейных несмещённых оценок оценка МНК оптимальна.

Теорема 3.4 (Гаусс — Марков)**.** *При посылках (G) оценка $\hat\theta$ наименьших квадратов — наилучшая линейная несмещённая оценка (англ.* best linear unbiased estimator*, BLUE): для любой линейной оценки $\tilde\theta = Cy$ ($C \in \mathbb{R}^{n\times m}$), несмещённой для всех θ при верной модели ($CA = I_n$), выполнено*

$$\mathsf{D}\hat\theta \preceq \mathsf{D}\tilde\theta$$

(разность ковариаций положительно полуопределена), и равенство достигается только при $C = (A^\top A)^{-1}A^\top$.

Доказательство. Разложим $C = (A^\top A)^{-1}A^\top + D$. Несмещённость $\tilde\theta$ для всех θ равносильна $CA = I_n$; так как $(A^\top A)^{-1}A^\top A = I_n$, получаем $DA = 0$. Ковариация $\tilde\theta = \theta + C\varepsilon$ равна $\sigma^2 CC^\top$; вычисляем по разложению с учётом $DA = 0$:

$$CC^\top = \big((A^\top A)^{-1}A^\top + D\big)\big(A(A^\top A)^{-1} + D^\top\big) = (A^\top A)^{-1} + (A^\top A)^{-1}A^\top D^\top + DA(A^\top A)^{-1} + DD^\top.$$

Первый смешанный член: $\big(DA(A^\top A)^{-1}\big)^\top = 0$ и сам равен нулю. Итого $\mathsf{D}\tilde\theta = \mathsf{D}\hat\theta + \sigma^2 DD^\top \succeq \mathsf{D}\hat\theta$; равенство в смысле Лёвнера возможно лишь при $D = 0$. □

Замечание 3.5 (что существенно в посылках). Нормальность ошибок для BLUE не нужна — только нулевое среднее, равные дисперсии и некоррелированность. Без несмещённости оптимальность исчезает: оценка $\tilde\theta = c\hat\theta$ с $c < 1$ имеет ковариацию $c^2\mathsf{D}\hat\theta \prec \mathsf{D}\hat\theta$, но смещена. Без равенства дисперсий (гетероскедастичности) или при коррелированности ошибок $\hat\theta$ перестаёт быть BLUE, и оценку улучшают взвешенным МНК (веса обратно дисперсиям). Регуляризованные оценки (раздел 5) намеренно жертвуют несмещённостью ради меньшей дисперсии — обмен, который выгоден на дне кривой «смещение — дисперсия» (вопрос 02, машинное обучение и обратные задачи, регуляризация).

Теперь добавим нормальность ошибок и получим связь МНК с максимальным правдоподобием.

Теорема 3.6 (МНК как максимальное правдоподобие)**.** *Пусть* $\varepsilon \sim \mathcal{N}(0, \sigma^2 I_m)$*. Тогда:*

1. оценка максимального правдоподобия параметра θ *совпадает с оценкой МНК; 2.* $\hat\theta \sim \mathcal{N}(\theta, \sigma^2 (A^{\mathsf T}A)^{-1})$*; 3.* $(m-n)\hat\sigma^2/\sigma^2 \sim \chi^2_{m-n}$ *и оценки* $\hat\theta$ *и* $\hat\sigma^2$ *независимы; 4. оценка максимального правдоподобия дисперсии смещена:* $\hat\sigma^2_{\mathrm{ML}} = \frac{\|y - A\hat\theta\|_2^2}{m}$*,* $\mathsf{E}\hat\sigma^2_{\mathrm{ML}} = \frac{m-n}{m}\sigma^2$*.*

Доказательство. Логарифм правдоподобия

$$\ln L(\theta, \sigma^2) = -\frac{m}{2}\ln(2\pi\sigma^2) - \frac{\|y - A\theta\|_2^2}{2\sigma^2}.$$

При любом $\sigma^2 > 0$ максимум по θ достигается при минимуме $\|y - A\theta\|_2^2$, что и даёт п. 1. П. 2 следует из линейности $\hat\theta$ по нормально распределённому y и теоремы 3.1.

П. 3: $y - A\hat\theta = (I - P_A)\varepsilon$ (теорема 3.3). По спектральному разложению $I - P_A = G\,\mathrm{diag}(0_n, I_{m-n})G^{\mathsf T}$; вектор $\eta = G^{\mathsf T}\varepsilon/\sigma$ имеет распределение $\mathcal{N}(0, I_m)$, и

$$\frac{(m-n)\hat\sigma^2}{\sigma^2} = \frac{\|G^{\mathsf T}(I - P_A)\varepsilon\|_2^2}{\sigma^2} = \sum_{j=n+1}^{m} \eta_j^2 \sim \chi^2_{m-n}.$$

Для независимости заметим, что векторы $G^{\mathsf T}P_A\varepsilon$ (от которых линейно зависит $\hat\theta$) и $G^{\mathsf T}(I - P_A)\varepsilon$ (от которого зависит $\hat\sigma^2$) совместно гауссовы, и их ковариация равна $\sigma^2 G^{\mathsf T}P_A(I - P_A)G = 0$; некоррелированные гауссовы векторы независимы.

П. 4: сравнение формул для $\hat\sigma^2_{\mathrm{ML}}$ и $\hat\sigma^2$ вместе с теоремой 3.3 даёт $\mathsf{E}\hat\sigma^2_{\mathrm{ML}} = \frac{m-n}{m}\sigma^2$. □

Замечание 3.7 (вывод для практики). Из пп. 2–3 следует, что при нормальных ошибках статистика

$$(\hat\theta_j - \theta_j)\big/(\hat\sigma\sqrt{v_j}),$$

где v_j — j-й диагональный элемент $(A^{\mathsf T}A)^{-1}$, имеет распределение Стьюдента с $m - n$ степенями свободы — она служит для доверительных интервалов и проверки значимости отдельных коэффициентов (см. [вопрос 14](../14-interval-estimation-tests/) (интервальное оценивание и проверка гипотез)).

Замечание 3.8 (R^2 и F-критерий). Качество подгонки линейной модели принято измерять коэффициентом детерминации $R^2 = 1 - \mathrm{RSS}/\mathrm{TSS}$, где $\mathrm{TSS} = \sum_i (y_i - \bar y)^2$ — полная сумма квадратов; R^2 — доля объяснённой дисперсии. Значимость модели в целом (H_0: все коэффициенты при факторах равны нулю) проверяют F-статистикой

$$F = \frac{(\mathrm{TSS} - \mathrm{RSS})/(n-1)}{\mathrm{RSS}/(m-n)},$$

имеющей распределение Фишера $F_{n-1,\,m-n}$ при верной H_0 и нормальных ошибках (формулировка F-критерия — [16]; вывод — предмет матстатистики: проверка гипотез). Пары «R^2 — F» и «коэффициент — t» отвечают вопросам «вся модель — или ничего» и «фактор по одному».

4 Численная сторона МНК

Решение $\hat\theta = (A^{\mathsf T}A)^{-1}A^{\mathsf T}y$ само по себе не алгоритм: оно требует формирования $A^{\mathsf T}A$, и это источник потери точности. Пусть $d_1 \ge \ldots \ge d_n > 0$ — сингулярные числа A; **число обусловленности**

$$\kappa_2(A) = d_1/d_n.$$

Теорема 4.1 (погрешность метода нормальных уравнений)**.** *Если $\hat\theta_{NE}$ — решение, вычисленное по нормальным уравнениям в машинной арифметике с точностью u при точном формировании $A^{\mathsf T}A$ и $A^{\mathsf T}y$, то*

$$\frac{\|\hat\theta_{NE} - \hat\theta\|_2}{\|\hat\theta\|_2} \approx u\,\kappa_2(A)^2.$$

схема. Разложение Холецкого $A^{\mathsf T}A = GG^{\mathsf T}$ в машинной арифметике решает не исходную, а близкую систему $(A^{\mathsf T}A + E)\hat\theta_{NE} = A^{\mathsf T}y$ с $\|E\|_2 \approx u\|A^{\mathsf T}A\|_2$ (свойство устойчивости разложения Холецкого для положительно определённых матриц). По теореме о погрешности решения системы ошибка делится на $\|A^{\mathsf T}A\|_2$ и умножается на $\|(A^{\mathsf T}A)^{-1}\|_2 = 1/d_n^2$, а $\|A^{\mathsf T}A\|_2 = d_1^2$ — отсюда $u\,d_1^2/d_n^2 = u\,\kappa_2(A)^2$. □

Прямой вывод $\hat\theta$ через $A^{\mathsf T}A$ квадратично чувствителен к обусловленности. Устойчивые схемы работают с самой матрицей A.

Теорема 4.2 (решение МНК через QR-разложение)**.** *В этом разделе Q — ортогональный множитель QR-разложения, а не функционал МНК. Пусть* $\operatorname{rank} A = n$ *и $A = QR$ — тонкое QR-разложение ($Q \in \mathbb{R}^{m\times n}$ имеет ортонормированные столбцы, $R \in \mathbb{R}^{n\times n}$ верхняя треугольная). Тогда $\hat\theta$ есть единственное решение системы*

$$R\hat\theta = Q^{\mathsf T}y, \qquad \min_\theta \|A\theta - y\|_2^2 = \|(I - QQ^{\mathsf T})y\|_2^2.$$

Вычисленное таким образом $\hat\theta_{QR}$ есть точное решение задачи МНК для близких данных $A + \delta A$, $y + \delta y$ с

$$\|\delta A\|_2 \lesssim mu\|A\|_2, \qquad \|\delta y\|_2 \lesssim mu\|y\|_2$$

(обратная устойчивость), поэтому его относительная ошибка есть $O\big(u(\kappa_2(A) + \tan\varphi\,\kappa_2(A)^2)\big)$ при ненулевой невязке.

Доказательство. Ортогональные преобразования сохраняют 2-норму. Дополним Q до квадратной ортогональной $\bar Q = [\,Q\ \bar Q_\perp\,]$; тогда

$$\|A\theta - y\|_2^2 = \big\|\bar Q^{\mathsf T}(A\theta - y)\big\|_2^2 = \|R\theta - Q^{\mathsf T}y\|_2^2 + \|\bar Q_\perp^{\mathsf T}y\|_2^2,$$

поскольку $\bar Q^{\mathsf T}A = \binom{R}{0}$. Второе слагаемое от θ не зависит, первое обращается в нуль при $R\hat\theta = Q^{\mathsf T}y$; R невырождена (её сингулярные числа совпадают с $d_j > 0$), значит решение единственно. Минимальное значение равно $\|\bar Q_\perp^{\mathsf T}y\|_2^2 = \|(I - QQ^{\mathsf T})y\|_2^2$.

Утверждение обратной устойчивости — результат Лоусона и Хэнсона о методе Хаусхолдера: вычисленное $\hat R$ есть точный треугольный множитель матрицы, близкой к A с относительной погрешностью порядка mu, а обратная подстановка устойчива. Оценка ошибки следует далее из теоремы 4.3. □

Теорема 4.3 (чувствительность задачи МНК к данным). *Пусть* $\|A\theta_{LS} - y\|_2 = \min$ *с невязкой* r *и* $\|(A+\delta A)\hat{\theta} - (y+\delta y)\|_2 = \min$*;* $A, \delta A \in \mathbb{R}^{m\times n}$*,* $m \geq n$*,* $\operatorname{rank} A = n$*,* $y \neq 0$*,*

$$\delta = \max\Big\{\frac{\|\delta A\|_2}{\|A\|_2}, \frac{\|\delta y\|_2}{\|y\|_2}\Big\} < \frac{d_n}{d_1}, \qquad \sin\varphi = \frac{\|r\|_2}{\|y\|_2} \neq 1.$$

Тогда

$$\frac{\|\hat{\theta} - \theta_{LS}\|_2}{\|\theta_{LS}\|_2} \leq \delta\Big\{\frac{2\kappa_2(A)}{\cos\varphi} + \tan\varphi\,\kappa_2(A)^2\Big\} + O(\delta^2), \tag{2}$$

$$\frac{\|\hat{r} - r\|_2}{\|y\|_2} \leq \delta(1 + 2\kappa_2(A))\min(1, m-n) + O(\delta^2). \tag{3}$$

Доказательство. Пишем $\delta A = \delta E$, $\delta y = \delta f$ с $\|E\|_2 \leq \|A\|_2$, $\|f\|_2 \leq \|y\|_2$ и рассматриваем семейство $A(t) = A + tE$, $y(t) = y + tf$, $t \in [0, \delta]$. Так как $t\|E\|_2 < d_n$ при $t \leq \delta$, все $A(t)$ имеют ранг n и их решения $x(t)$ нормальных уравнений дифференцируемы; тейлоровское разложение в точке $t = 0$ даёт $\hat{\theta} = \theta_{LS} + \delta\dot{x}(0) + O(\delta^2)$ (точка применения — $t = \delta$).

Дифференцируем тождество $A(t)^{\mathsf{T}}A(t)x(t) = A(t)^{\mathsf{T}}y(t)$ в нуле:

$$A^{\mathsf{T}}A\,\dot{x}(0) = A^{\mathsf{T}}(f - E\theta_{LS}) + E^{\mathsf{T}}(y - A\theta_{LS}),$$

откуда

$$\dot{x}(0) = (A^{\mathsf{T}}A)^{-1}A^{\mathsf{T}}(f - E\theta_{LS}) + (A^{\mathsf{T}}A)^{-1}E^{\mathsf{T}}r. \tag{4}$$

Оценим нормы множителей сингулярным разложением $A = U\Sigma V^{\mathsf{T}}$:

$$\|(A^{\mathsf{T}}A)^{-1}A^{\mathsf{T}}\|_2 = \frac{1}{d_n}, \qquad \|(A^{\mathsf{T}}A)^{-1}\|_2 = \frac{1}{d_n^2}, \qquad \|A(A^{\mathsf{T}}A)^{-1}\|_2 = \frac{1}{d_n}.$$

Первое слагаемое в (4):

$$\frac{\|(A^{\mathsf{T}}A)^{-1}A^{\mathsf{T}}(f - E\theta_{LS})\|_2}{\|\theta_{LS}\|_2} \leq \frac{\|f\|_2 + \|E\|_2\|\theta_{LS}\|_2}{d_n\|\theta_{LS}\|_2} \leq \kappa_2(A)\Big(\frac{\|y\|_2}{\|A\|_2\|\theta_{LS}\|_2} + 1\Big).$$

Второе:

$$\frac{\|(A^{\mathsf{T}}A)^{-1}E^{\mathsf{T}}r\|_2}{\|\theta_{LS}\|_2} \leq \frac{\|E\|_2\|r\|_2}{d_n^2\|\theta_{LS}\|_2} \leq \tan\varphi\,\kappa_2(A)^2,$$

так как ортогональность $A\theta_{LS} \perp r$ (замечание 2.4) даёт теорему Пифагора $\|A\theta_{LS}\|_2^2 + \|r\|_2^2 = \|y\|_2^2$, то есть $\|A\|_2\|\theta_{LS}\|_2 \geq \|A\theta_{LS}\|_2 = \|y\|_2\cos\varphi$ и $\|r\|_2/\|A\|_2\|\theta_{LS}\|_2 \leq \tan\varphi$. Подстановка в (4) даёт (2).

Для невязки: $r(t) = y(t) - A(t)x(t)$, дифференцирование даёт

$$\dot{r}(0) = (I - P_A)(f - E\theta_{LS}) - A(A^{\mathsf{T}}A)^{-1}E^{\mathsf{T}}r,$$

где $P_A = A(A^{\mathsf{T}}A)^{-1}A^{\mathsf{T}}$ — ортопроектор. Используем $\|I - P_A\|_2 = \min(1, m-n)$ (при $m = n$ проектор равен I, иначе его норма равна 1), $\|f\|_2 \leq \|y\|_2$, $\|E\theta_{LS}\|_2 \leq \|A\|_2\|\theta_{LS}\|_2 \leq \kappa_2(A)\|y\|_2$ (так как $\|\theta_{LS}\|_2 = \|A^{+}y\|_2 \leq \|y\|_2/d_n$) и $\|A(A^{\mathsf{T}}A)^{-1}E^{\mathsf{T}}r\|_2 \leq \|E\|_2\|r\|_2/d_n \leq \kappa_2(A)\|r\|_2 \leq \kappa_2(A)\min(1, m-n)\|y\|_2$, что и даёт (3). □

Замечание 4.4 (как читать оценки). При нулевой невязке ($\varphi = 0$ в угле) чувствительность решения линейна по $\kappa_2(A)$ — как у квадратной системы. Член $\tan\varphi\,\kappa_2^2$ включается при ненулевой невязке и делает задачу по-настоящему плохо обусловленной при большом κ_2: квадратичная зависимость достигается на примерах, и при больших невязках оба метода — и нормальные уравнения, и QR — дают сопоставимую точность: выигрыш QR относится к режиму малых и средних невязок. Невязка, напротив, чувствительна к данным линейно.

Отсюда практическое правило: решение считают по QR-разложению (Хаусхолдер; метод Грама — Шмидта обратно устойчив для МНК только при применении к расширенной матрице $[A\ y]$, а не к A одной) или SVD, а нормальные уравнения с разложением Холецкого применяют лишь при хорошей обусловленности и $m \gg n$ — они тогда вдвое дешевле. Полный ранг приближённо определяется по сингулярным числам: порог $d_j \le \tau$ при допуске τ порядка $u\|A\|$ (или точности данных).

Стоимость методов для $m \ge n$ (ведущие члены числа флопов [02]):

Метод	Флопы	Устойчивость
Нормальные уравнения + Холецкий	$mn^2 + n^3/3$	$u\kappa_2^2$
QR Хаусхолдера	$2mn^2 - \frac{2}{3}n^3$	обратно устойчив
QR (модиф. Грам — Шмидт)	$2mn^2$	обратно устойчив
SVD (Чана)	$2mn^2 + 11n^3$	контроль ранга

SVD нужен и в другой ситуации — при неполном ранге: он выдаёт решение минимальной нормы A^+y (теорема 2.5) и позволяет отсечь малые сингулярные числа, от которых решение неустойчиво (мост к регуляризации).

5 Регуляризация: гребень и лассо

При плохой обусловленности $A^{\mathsf{T}}A$ (мультиколлинеарность факторов, $d_n \approx 0$) дисперсия $\hat\theta$ велика — оценка неустойчива (подробный разбор и связь с некорректными задачами — вопрос 02, машинное обучение и обратные задачи, регуляризация). Гребневая регрессия (англ. *ridge regression*) добавляет штраф за норму вектора параметров.

Определение 5.1 (гребневая регрессия)**.** Оценка гребневой регрессии с параметром $\alpha \ge 0$:

$$\hat\theta_\alpha = \arg\min_\theta\ Q(\alpha,\theta), \qquad Q(\alpha,\theta) = \|A\theta - y\|_2^2 + \alpha\|\theta\|_2^2.$$

Параметр α у источников именуется λ ([16]) или τ ([53]).

Теорема 5.2 (существование, единственность и фильтр)**.** *При $\alpha > 0$ задача гребня имеет единственное решение*

$$\hat\theta_\alpha = (A^{\mathsf{T}}A + \alpha I)^{-1}A^{\mathsf{T}}y,$$

линейное по y; при $\alpha = 0$ это оценка наименьших квадратов (единственная при полном ранге A; при неполном решение минимальной нормы получается как предел $\hat\theta_\alpha$ при $\alpha \to 0^+$). Если $A = U\Sigma V^{\mathsf{T}}$ — сингулярное разложение, то

$$\hat\theta_\alpha = \sum_{j=1}^{n} \frac{d_j}{d_j^2 + \alpha}\,(u_j^{\mathsf{T}}y)\,v_j, \qquad A\hat\theta_\alpha = \sum_{j=1}^{n} \frac{d_j^2}{d_j^2 + \alpha}\,(u_j^{\mathsf{T}}y)\,u_j.$$

Коэффициенты $\dfrac{d_j^2}{d_j^2+\alpha} \le 1$ — фильтр: направления с малыми сингулярными числами сжимаются сильнее. След шляпной матрицы гребня — эффективное число степеней свободы:

$$\mathrm{df}(\alpha) = \mathrm{tr}\big[A(A^{\mathsf{T}}A + \alpha I)^{-1}A^{\mathsf{T}}\big] = \sum_{j=1}^{n} \frac{d_j^2}{d_j^2 + \alpha},$$

непрерывно убывающее от $r = \mathrm{rank}\,A$ при $\alpha = 0$ до 0 при $\alpha \to \infty$.

Доказательство. По тождеству (1) с добавкой $\alpha\|\theta\|^2$:

$$Q(\alpha,\theta+tz)=Q(\alpha,\theta)+2t\,z^{\mathsf T}\big(A^{\mathsf T}(A\theta-y)+\alpha\theta\big)+t^2\big(\|Az\|_2^2+\alpha\|z\|_2^2\big).$$

При $\alpha>0$ квадратичная форма строго положительно определена ($\|Az\|_2^2+\alpha\|z\|_2^2>0$ при $z\neq 0$), значит Q строго выпукла, а необходимое условие нулевого градиента $A^{\mathsf T}A\theta+\alpha\theta=A^{\mathsf T}y$ даёт единственное решение. Фильтр получается подстановкой SVD: $A^{\mathsf T}A+\alpha I=V(\Sigma^2+\alpha I)V^{\mathsf T}$, обращение которой переводится в веса $d_j/(d_j^2+\alpha)$. Для df: след диагональной в базисе U матрицы $U\,\operatorname{diag}\big(d_j^2/(d_j^2+\alpha)\big)\,U^{\mathsf T}$ равен сумме её диагональных элементов. □

Замечание 5.3 (свойства гребня). (1) Оценка смещена: $\mathsf E\hat\theta_\alpha=(A^{\mathsf T}A+\alpha I)^{-1}A^{\mathsf T}A\,\theta\neq\theta$, зато дисперсия меньше, чем у МНК: оценка линейна по y, поэтому

$$\mathsf D\hat\theta_\alpha=\sigma^2(A^{\mathsf T}A+\alpha I)^{-1}A^{\mathsf T}A(A^{\mathsf T}A+\alpha I)^{-1}=\sigma^2\sum_{j=1}^{n}\frac{d_j^2}{(d_j^2+\alpha)^2}\,v_jv_j^{\mathsf T}\preceq\sigma^2\sum_{j=1}^{n}\frac{1}{d_j^2}\,v_jv_j^{\mathsf T}=\mathsf D\hat\theta,$$

так как у матриц общий собственный базис v_j и $d_j^2/(d_j^2+\alpha)^2\le 1/d_j^2$; сжатие нормы самой оценки разобрано в задаче 9.1. Существует α, минимизирующее среднеквадратичный риск — обмен «смещение — дисперсия» подробно разобран в вопросе 02 (машинное обучение и обратные задачи, регуляризация). (2) В отличие от МНК, гребень корректно определён при любом ранге и при $n>m$ (штраф делает матрицу системы положительно определённой). (3) Байесовский смысл: $\hat\theta_\alpha$ — MAP-оценка при гауссовском априоре $\theta\sim\mathcal N(0,\nu^2I)$ с $\alpha=\sigma^2/\nu^2$ (вывод — вопрос 02, машинное обучение и обратные задачи, регуляризация). (4) Параметр α выбирают перекрёстной проверкой — либо по минимуму контрольной ошибки, либо по правилу одной стандартной ошибки (вопрос 02, машинное обучение и обратные задачи, регуляризация).

Перед регуляризацией факторы стандартизуют (центрируют и масштабируют), иначе штраф зависит от единиц измерения; свободный член в штраф не входит.

Лассо заменяет квадратичный штраф на штраф L_1; штрафная форма

$$\min_\theta\ \|A\theta-y\|_2^2+\alpha\|\theta\|_1$$

равносильна форме с ограничением $\|\theta\|_1\le t$: задачи выпуклы, и по условиям Куна — Таккера (англ. *Karush—Kuhn—Tucker conditions*, KKT) у решения ограниченной задачи с активным ограничением $\|\theta\|_1=t$ есть множитель $\alpha\ge 0$, при котором оно минимизирует лагранжиан $\|A\theta-y\|_2^2+\alpha(\|\theta\|_1-t)$, то есть совпадает с решением штрафной задачи с тем же α; по мере ужесточения ограничения (уменьшения t) множитель растёт, норма решения монотонно убывает — внутри интервала соответствие $\alpha\leftrightarrow t$ взаимно однозначно; на краях оно стирается: всем $t\ge\|\hat\theta_{\text{OLS}}\|_1$ отвечает $\alpha=0$, а при $\alpha\ge\alpha_{\max}$ решение нулевое; при неполном ранге A решение может быть неединственным. Лассо обнуляет часть коэффициентов и отбирает факторы (лапласовский априор; сравнение гребня и лассо — вопрос 02, машинное обучение и обратные задачи, регуляризация). Геометрический механизм отбора: шар L_1 имеет углы на координатных осях, и при росте α решение прижимается к углам — координаты обнуляются (на пути переменные могут и выходить, и возвращаться). В ортонормированном случае ($A^{\mathsf T}A=I$, $\tilde\theta=A^{\mathsf T}y$ — оценка МНК) задача распадается по координатам и решается через субдифференциал:

$$\min_\theta\ (\theta-\tilde\theta_j)^2+\alpha|\theta|\quad\Longrightarrow\quad\hat\theta_j=\operatorname{sign}(\tilde\theta_j)\,\max\{0,\,|\tilde\theta_j|-\alpha/2\}$$

— мягкое пороговое преобразование: смещение в сторону нуля и обнуление малых координат. Для гребня есть явная формула, для лассо в общем случае её нет — решают численно (проксимальный градиент, координатный спуск).

6 Обучение регрессий первыми методами

Когда m велико или n велико, разложения тяжело, и обе задачи (МНК и гребень) решают градиентными итерациями — теми же методами, что и прочие задачи минимизации (вопрос 10, минимизация функций многих переменных; подробная теория скоростей — [63]).

Градиенты. Для функционала МНК $\nabla Q(\theta) = 2A^{\mathsf{T}}(A\theta - y)$, а его гессиан $2A^{\mathsf{T}}A$ имеет собственные значения на $[2d_n^2, 2d_1^2]$, поэтому константа Липшица градиента $L = 2d_1^2$; для гребня $L = 2(d_1^2 + \alpha)$. Шаг $\eta \le 1/L$ гарантирует убывание функционала (лемма спуска, [63]): $Q(\theta_{k+1}) \le Q(\theta_k) - \eta(1 - L\eta/2)\|\nabla Q(\theta_k)\|_2^2$. Для сильно выпуклой задачи отсюда — линейная сходимость в функционале $Q(\theta_k) - Q^* \le (1 - \mu/L)^k\,(Q(\theta_0) - Q^*)$ (через условие Поляка — Ложасевича, [63]), а на квадратичной задаче — в норме аргумента: $\|\theta_k - \theta^*\| \le (1 - 1/\kappa)^k \|\theta_0 - \theta^*\|$ при $\eta = 1/L$. Оптимальный постоянный шаг $\eta = 2/(L + \mu)$ улучшает коэффициент до $(\kappa{-}1)/(\kappa{+}1)$ (вывод — вопрос 10, минимизация функций многих переменных; [63]). Здесь $\mu = 2d_n^2$, $\kappa = L/\mu = \kappa_2(A)^2$ — в квадрате хуже, чем у самой матрицы A, отсюда и выгода QR/SVD при плохой обусловленности; для гребня спектр сдвинут, $\kappa = (d_1^2 + \alpha)/(d_n^2 + \alpha)$.

Стохастический спуск (англ. *stochastic gradient descent*, SGD — [63], [51]). На шаге берут случайное подмножество B (минибатч) и оценку градиента $g(\theta) = \frac{2}{|B|}\sum_{i \in B}(a_i^{\mathsf{T}}\theta - y_i)a_i$; она несмещённа для градиента среднего функционала $\frac{1}{m}Q$: $\mathsf{E}_B g(\theta) = \frac{1}{m}\nabla Q(\theta) = \frac{2}{m}A^{\mathsf{T}}(A\theta - y)$. При убывании шага по правилу Роббинса — Монро $\sum_k \eta_k = \infty$, $\sum_k \eta_k^2 < \infty$ итерации сходятся (формулировка — [63], [64]; стохастический градиентный спуск подробно разобран в вопросе 02, машинное обучение и обратные задачи, регуляризация); увеличение батча в b раз снижает дисперсию оценки в b раз.

Моментум (англ. *momentum* — [63]). Усреднение градиентов $v_{k+1} = \beta v_k + \nabla Q(\theta_k)$, $\theta_{k+1} = \theta_k - \eta v_{k+1}$ (метод тяжёлого шарика) для квадратичной задачи ускоряет сходимость до коэффициента $(\sqrt{\kappa}{-}1)/(\sqrt{\kappa}{+}1)$ вместо $(\kappa{-}1)/(\kappa{+}1)$ (вывод — вопрос 10, минимизация функций многих переменных; [63]) — практический рецепт при большом κ. Разница режимов видна на сквозном примере вопроса: градиентный спуск на log-loss с шагом $1/L$ требует порядка $2{,}5{\cdot}10^4$ итераций, тогда как IRLS сходится за 5 итераций (числа — в `examples.ipynb`, пример 3). Для log-loss гессиан $A^{\mathsf{T}}WA$ меньше своей границы $\frac{1}{4}A^{\mathsf{T}}A$: веса $p_i(1-p_i) < \frac{1}{4}$ уменьшают и μ, поэтому фактическая $\kappa = L/\mu \approx 2{,}5{\cdot}10^3$ превосходит грубую $\kappa_2^2 \approx 2{,}0{\cdot}10^3$ — последняя не является границей и даёт лишь случайное согласие с наблюдением; оценка $\kappa \ln(1/\varepsilon)$ с фактической κ даёт $\approx 4 \cdot 10^4$ — завышение в $1{,}6$ раза, граница пессимистична.

7 Логистическая регрессия

Теперь отклик бинарный: $y_i \in \{0, 1\}$ — принадлежность объекта a_i к классу 1. Линейная модель на прямую $a_i^{\mathsf{T}}\theta$ выходить не может — значения не из $\{0, 1\}$; логистическая регрессия пропускает её через сигмоиду (англ. *sigmoid*), превращая в вероятность.

Определение 7.1 (логистическая модель)**.**

$$\mathsf{P}(y_i = 1 \mid a_i) = p_i(\theta) = s(a_i^{\mathsf{T}}\theta), \qquad s(z) = \frac{1}{1 + e^{-z}}.$$

Отсюда $\mathsf{P}(y_i = 0 \mid a_i) = 1 - p_i = s(-a_i^{\mathsf{T}}\theta)$ и правило классификации $\hat{y}_i = \mathbb{1}\{a_i^{\mathsf{T}}\theta > 0\}$: разделяющая граница — гиперплоскость $a^{\mathsf{T}}\theta = 0$.

Замечание 7.2 (логит и шансы). Сигмоида обратима: $\ln \frac{p}{1-p} = a^{\mathsf{T}}\theta$ — логит вероятности линеен по факторам. Коэффициент θ_j — изменение логарифма шансов $\frac{p}{1-p}$ при приращении

x_j на единицу при прочих равных; e^{θ_j} — отношение шансов (англ. *odds ratio*). Это стандартная интерпретация коэффициентов в приложениях (скоринговые карты).

Лемма 7.3 (свойства сигмоиды)**.** $s'(z) = s(z)(1-s(z))$; $s(-z) = 1-s(z)$; $\ln s(z) = z - \ln(1+e^z)$; $\ln(1-s(z)) = -\ln(1+e^z)$.

Доказательство. Непосредственное дифференцирование и алгебра: $s(z) = e^z/(1+e^z)$, откуда $\ln s(z) = z - \ln(1+e^z)$; остальное — проверка подстановкой. □

Определение 7.4 (log-loss / бинарная перекрёстная энтропия)**.** Функция правдоподобия выборки (наблюдения независимы):

$$L(\theta) = \prod_{i=1}^{m} p_i^{y_i}(1-p_i)^{1-y_i}.$$

Логарифмическая функция потерь (англ. *log-loss*, или бинарная перекрёстная энтропия, англ. *cross-entropy*) — отрицательное логарифмическое правдоподобие:

$$Q(\theta) = -\ln L(\theta) = \sum_{i=1}^{m} \bigl[\ln(1+e^{a_i^{\mathsf{T}}\theta}) - y_i\, a_i^{\mathsf{T}}\theta\bigr].$$

Оценка максимального правдоподобия есть $\arg\min_\theta Q(\theta)$.

Явной формулы для минимизатора Q нет (система оценочных уравнений нелинейна): логистическая регрессия обучается итеративно — в этом коренное отличие от линейной.

Замечание 7.5 (почему log-loss, а не квадратичная потеря)*.* Кажущийся естественным критерий $\sum_i (y_i - p_i(\theta))^2$ с сигмоидой невыпукла: для одного наблюдения с $y_i = 0$ (обозначим $u = a_i^{\mathsf{T}}\theta$) вторая производная потери $s(u)^2$ по u равна $2s(u)^2(1-s(u))(2-3s(u))$ и отрицательна уже при $s(u) > 2/3$, поэтому критерий невыпуклый и может иметь локальные минимумы, отличные от глобального. Log-loss выпукла всюду (теорема 7.6) — это и есть причина её выбора.

Теорема 7.6 (гладкость, выпуклость, градиент и гессиан)**.** *Q выпукла и бесконечно дифференцируема; с обозначениями $p = (p_i)$, $W = \operatorname{diag}(p_i(1-p_i))$:*

$$\nabla Q(\theta) = A^{\mathsf{T}}(p - y), \qquad \nabla^2 Q(\theta) = A^{\mathsf{T}} W A \succeq 0.$$

Если $\operatorname{rank} A = n$ *и все* $0 < p_i < 1$*, то Q строго выпукла, и её минимум (если существует) единствен. Минимум Q существует тогда и только тогда, когда выполнено условие перекрытия: для любого $z \in \mathbb{R}^n$ с $Az \neq 0$ найдётся i такой, что $a_i^{\mathsf{T}} z > 0$, $y_i = 0$, либо $a_i^{\mathsf{T}} z < 0$, $y_i = 1$.*

Это известный критерий существования оценки максимального правдоподобия (Альберт — Андерсон). Отрицание условия перекрытия — ровно слабая разделимость классов через z с $Az \neq 0$ (все объекты класса 1 в полупространстве $a^{\mathsf{T}} z \geq 0$, класса 0 — в $a^{\mathsf{T}} z \leq 0$): так что теорему можно читать так — минимум существует тогда и только тогда, когда классы не разделимы даже в слабом смысле (замечание 7.11).

Доказательство. Слагаемое $y_i a_i^{\mathsf{T}}\theta$ линейно, вторые производные даёт только $\ell_i(\theta) = \ln(1+e^{a_i^{\mathsf{T}}\theta})$. По лемме 7.3 $\nabla \ell_i = s(a_i^{\mathsf{T}}\theta)\, a_i = p_i a_i$ и

$$\nabla^2 \ell_i = s'(a_i^{\mathsf{T}}\theta)\, a_i a_i^{\mathsf{T}} = p_i(1-p_i)\, a_i a_i^{\mathsf{T}}.$$

Суммирование по i даёт формулы градиента и гессиана. Для любого $z \in \mathbb{R}^n$

$$z^{\mathsf{T}} A^{\mathsf{T}} W A\, z = \sum_{i=1}^{m} p_i(1-p_i)\,(a_i^{\mathsf{T}} z)^2 \geq 0,$$

так как $0 < p_i < 1$; значит $A^{\mathsf{T}} W A \succeq 0$ и Q выпукла. Если $\operatorname{rank} A = n$ и $z \neq 0$, то $Az \neq 0$, существует i с $a_i^{\mathsf{T}} z \neq 0$, и $z^{\mathsf{T}} \nabla^2 Q\, z > 0$ — строгая выпуклость.

Достаточность. Вдоль луча $\theta = \theta_0 + tz$ пользуемся $\ln(1+e^u) \geq \max(u, 0)$. Если $a_i^{\mathsf{T}} z > 0$ и $y_i = 0$, слагаемое растёт как $t\, a_i^{\mathsf{T}} z \to +\infty$; если $a_i^{\mathsf{T}} z < 0$ и $y_i = 1$, слагаемое растёт как $-t\, a_i^{\mathsf{T}} z$ (точнее, $\ln(1+e^{a_i^{\mathsf{T}}\theta}) - a_i^{\mathsf{T}}\theta = \ln(1+e^{-a_i^{\mathsf{T}}\theta}) \to +\infty$). Значит, по условию перекрытия для любого z с $Az \neq 0$ найдётся i в одной из этих ситуаций, и $Q \to +\infty$ вдоль любого луча с $Az \neq 0$.

Коэрцитивный аргумент ведём на $(\ker A)^{\perp}$. Возьмём минимизирующую последовательность θ_k ($Q(\theta_k) \to \inf Q$) и разложим $\theta_k = \varphi_k + z_k$ по ортогональной сумме $\mathbb{R}^n = (\ker A)^{\perp} \oplus \ker A$. Сдвиг на $\ker A$ значение Q не меняет ($a_i^{\mathsf{T}}(\theta + z) = a_i^{\mathsf{T}}\theta$ при $z \in \ker A$), поэтому $Q(\varphi_k) = Q(\theta_k) \to \inf Q$. Последовательность $\{\varphi_k\}$ ограничена: иначе по подпоследовательности $\varphi_k/\|\varphi_k\| \to d \in (\ker A)^{\perp}$, $\|d\| = 1$, значит $Ad \neq 0$ (ядро пересекает своё ортогональное дополнение лишь по нулю); по выпуклости для каждого фиксированного $t > 0$ и всех k с $\|\varphi_k\| \geq t$

$$Q\Big(t\,\frac{\varphi_k}{\|\varphi_k\|}\Big) \leq \frac{t}{\|\varphi_k\|}\,Q(\varphi_k) + \Big(1 - \frac{t}{\|\varphi_k\|}\Big)Q(0),$$

переход к пределу $k \to \infty$ по непрерывности даёт $Q(td) \leq Q(0)$ при всяком $t > 0$ — ограниченность Q вдоль луча td с $Ad \neq 0$, противоречащую доказанному росту. Итак, $\{\varphi_k\}$ ограничена; у сходящейся подпоследовательности $\varphi_{k_j} \to \varphi_* \in (\ker A)^{\perp}$ по непрерывности $Q(\varphi_*) = \inf Q$: сужение Q на $(\ker A)^{\perp}$ достигает минимума. Тогда множество минимизаторов — непустое аффинное подпространство, параллельное $\ker A$. При $\operatorname{rank} A = n$ оно состоит из одной точки по строгой выпуклости.

Необходимость. Пусть условие перекрытия не выполнено: найдётся z с $Az \neq 0$ такой, что $y_i = 1 \Rightarrow a_i^{\mathsf{T}} z \geq 0$ и $y_i = 0 \Rightarrow a_i^{\mathsf{T}} z \leq 0$. Тогда вдоль луча $\theta_0 + tz$ слагаемые с $a_i^{\mathsf{T}} z > 0$ (у них $y_i = 1$) убывают строго к нулю, слагаемые с $a_i^{\mathsf{T}} z < 0$ (у них $y_i = 0$) убывают строго к нулю, а слагаемые с $a_i^{\mathsf{T}} z = 0$ постоянны; так как $Az \neq 0$, хотя бы одно слагаемое строго убывает. Значит, $Q(\theta_0 + tz)$ строго убывает по t при любом θ_0, и ни одна точка не может быть минимумом: инфимум не достигается. □

Замечание 7.7 (оценочные уравнения). Условие $\nabla Q = 0$ есть система $A^{\mathsf{T}}(y - p) = 0$ из n нелинейных уравнений; если среди столбцов A есть константа, первое из них даёт $\sum_i y_i = \sum_i p_i(\hat\theta)$: сумма предсказанных вероятностей равна числу единиц. Это свойство используют для контроля сходимости.

Теорема 7.8 (метод Ньютона и IRLS)**.** *Пусть* $\operatorname{rank} A = n$. *Шаг Ньютона для* Q *с текущей точки* θ*:*

$$\theta^{+} = \theta + (A^{\mathsf{T}} W A)^{-1} A^{\mathsf{T}}(y - p).$$

Он совпадает с решением взвешенной задачи наименьших квадратов с весами W *и рабочим откликом* $z = A\theta + W^{-1}(y - p)$*:*

$$\theta^{+} = \arg\min_{\vartheta} (z - A\vartheta)^{\mathsf{T}} W (z - A\vartheta).$$

Итерации (приведение весов W *и отклика* z *к текущей точке и решение взвешенной МНК-задачи) называются повторно взвешенными наименьшими квадратами (англ.* iteratively reweighted least squares*, IRLS); вес максимален у объектов у границы (*$p_i \approx 1/2$*).*

Доказательство. Нормальные уравнения взвешенной задачи: $A^{\mathsf{T}}WA\,\vartheta = A^{\mathsf{T}}Wz$. Подставляем $Wz = WA\theta + (y - p)$:

$$A^{\mathsf{T}}WA\,\vartheta = A^{\mathsf{T}}WA\,\theta + A^{\mathsf{T}}(y - p),$$

откуда $\vartheta = \theta + (A^{\mathsf{T}}WA)^{-1}A^{\mathsf{T}}(y - p)$ — это и есть шаг Ньютона (гессиан $\nabla^2 Q = A^{\mathsf{T}}WA$ обратим при полном ранге A, так как $W \succ 0$). □

Замечание 7.9 (сходимость и промахи). Для строго выпуклой гладкой функции метод Ньютона локально квадратично сходится к минимуму (теория — вопрос 10, минимизация функций многих переменных); глобально на практике применяют демпфирование: при возрастании Q шаг делят пополам (у [16] — стандартная рекомендация). Регуляризованный вариант $Q(\theta) + \frac{\alpha}{2}\|\theta\|_2^2$ имеет гессиан $A^{\mathsf{T}}WA + \alpha I \succ 0$ — сильную выпуклость при любом ранге A и сепарабельности классов (разделимость разбирается ниже), и тот же шаг IRLS с заменой $A^{\mathsf{T}}WA \to A^{\mathsf{T}}WA + \alpha I$.

Замечание 7.10 (GLM и асимптотика оценки). Логистическая регрессия — частный случай обобщённой линейной модели (англ. *generalized linear model*, GLM): случайное распределение — Бернулли, каноническая функция связи — логит; IRLS — общий метод Ньютона для правдоподобия GLM, бинарная перекрёстная энтропия заменяется логарифмом правдоподобия семейства. Асимптотические свойства оценки максимального правдоподобия (при выполнении условия перекрытия и стандартных условий регулярности): $\hat{\theta}$ состоятельна и асимптотически нормальна, $\mathsf{D}\hat{\theta} \approx (A^{\mathsf{T}}WA)^{-1}$ с гессианом в точке оценки — информационная матрица Фишера; отсюда тест Вальда на значимость коэффициента: $z_j = \hat{\theta}_j/\hat{\sigma}_j$ с $\hat{\sigma}_j^2$ — диагональным элементом $(A^{\mathsf{T}}\widehat{W}A)^{-1}$ асимптотически стандартно нормальна при $\theta_j = 0$ (формулировки — [16]; доказательства — предмет матстатистики: интервальное оценивание и проверка гипотез).

Замечание 7.11 (разделимость классов). Если выборка линейно разделима (существует ψ: $y_i = 1 \Rightarrow a_i^{\mathsf{T}}\psi > 0$, $y_i = 0 \Rightarrow a_i^{\mathsf{T}}\psi < 0$), то $\inf Q$ не достигается: вдоль луча $\theta = t\psi$ при $t \to \infty$ величина Q строго убывает, значит оценка максимального правдоподобия не существует ($\|\hat{\theta}\| \to \infty$), и в точной арифметике ∇Q не обращается в нуль: вдоль луча $\theta = t\psi$ градиент убывает экспоненциально, поэтому любой фиксированный порог ε рано или поздно формально пройден, не свидетельствуя о минимизаторе. Граничный случай — слабая разделимость через z с $Az \neq 0$ (все объекты класса 1 в полупространстве $a_i^{\mathsf{T}}z \geq 0$, класса 0 — в $a_i^{\mathsf{T}}z \leq 0$, некоторые на границе): вдоль луча $\theta = tz$ слагаемые не возрастают, а хотя бы одно убывает строго, поэтому Q строго убывает, уходя к конечному пределу, и минимум не достигается ни в одной точке — это отрицание условия перекрытия из теоремы 7.6. В машинной арифметике есть дополнительная ловушка: на точно разделимых данных вероятности p_i сатурируют до точных 0 и 1, гессиан вырождается, и норма градиента формально падает ниже любого порога — критерий $\|\nabla Q\| < \varepsilon$ даёт ложную остановку при продолжающемся росте $\|\theta_k\|$. Надёжные стоп-сигналы — рост $\|\theta_k\|$ и идеальная классификация обучения. На почти разделимых данных (пример 4 в examples.ipynb: вероятностная разметка с несколькими нарушениями знака) оценка максимального правдоподобия существует, IRLS честно сходится за десяток итераций, а гребень дополнительно улучшает качество на тесте. Выход для точно разделимых данных — регуляризация (гребень с малым α делает минимум существующим и единственным) либо остановка по изменению прогнозов. Это свойство важно помнить: идеально точная классификация на обучении для логистической регрессии означает, что оценка ушла на бесконечность.

Мультиномиальный случай (K классов) вводит $K - 1$ векторов параметров через логиты $\ln \frac{\mathsf{P}(G=k|a)}{\mathsf{P}(G=K|a)} = a^{\mathsf{T}}\theta_k$; после обращения (softmax, англ. *softmax*)

$$\mathsf{P}(G = k \mid a) = \frac{e^{a^{\mathsf{T}}\theta_k}}{1 + \sum_{l=1}^{K-1} e^{a^{\mathsf{T}}\theta_l}}, \quad k < K; \qquad \mathsf{P}(G = K \mid a) = \frac{1}{1 + \sum_{l=1}^{K-1} e^{a^{\mathsf{T}}\theta_l}}.$$

Структура правдоподобия и шагов Ньютона та же, но весовая матрица на наблюдение уже не диагональна [16]. Для отбора факторов применяют L_1-штраф к θ (решение — координатным спуском).

8 Метрики качества бинарной классификации

Порог классификации $\hat{y} = \mathbb{1}\{p_i > \pi\}$ (по умолчанию $\pi = 1/2$) разбивает объекты по матрице ошибок (англ. *confusion matrix*): TP и TN — верные срабатывания, FP — ложная тревога, FN — пропуск. Из неё выводят:

Метрика	Определение	Когда важна
Accuracy (доля верных, англ. *accuracy*)	$(\mathrm{TP}+\mathrm{TN})/m$	классы сбалансированы
Precision (точность, англ. *precision*)	$\mathrm{TP}/(\mathrm{TP}+\mathrm{FP})$	цена ложной тревоги высока
Recall (полнота, англ. *recall*)	$\mathrm{TP}/(\mathrm{TP}+\mathrm{FN})$	цена пропуска высока
F_1	$2\,\frac{\mathrm{precision}\cdot\mathrm{recall}}{\mathrm{precision}+\mathrm{recall}}$	один баланс P и R

Accuracy бесполезна при дисбалансе классов (достаточно отнести всех к большему классу): например, при 1% единиц константный прогноз «все нули» даёт accuracy 99%. Порог π балансирует precision и recall; компромисс целиком описывается ROC-кривой — параметрической кривой $(\mathrm{FPR}, \mathrm{TPR})$ по порогу π (англ. *receiver operating characteristic*), а её площадь AUC — вероятность того, что случайно взятый объект класса 1 получит оценку выше случайного объекта класса 0.

Где работает конструкция.

Постановка	Что минимизируется	Ответ	Что покупается
Линейная регрессия, полный ранг	$\|A\theta - y\|_2^2$	$\hat{\theta} = (A^{\mathsf{T}}A)^{-1}A^{\mathsf{T}}y$	несмещённость, BLUE (Гаусс — Марков)
Линейная регрессия, плохо обусловлена	$\|A\theta - y\|^2 + \alpha\|\theta\|^2$	$(A^{\mathsf{T}}A + \alpha I)^{-1}A^{\mathsf{T}}y$	устойчивость ценой смещения
Линейная регрессия, большие m, n	то же, итеративно	GD/SGD, momentum	масштабируемость
Логистическая регрессия	log-loss (перекрёстная энтропия)	IRLS / GD / SGD	вероятность класса, разделяющая гиперплоскость

9 Разобранные задачи

Задача 9.1. Гребень через сингулярное разложение. Пусть $A = U\Sigma V^{\mathsf{T}}$. Вывести $\hat{\theta}_\alpha$ и доказать, что $\|\hat{\theta}_\alpha\|_2 < \|\hat{\theta}\|_2$ при $\alpha > 0$, если $\hat{\theta} \neq 0$.

Решение. Формула — теорема 5.2. Для норм в базисе V:

$$\|\hat{\theta}_\alpha\|_2^2 = \sum_{j=1}^{n} \frac{d_j^2}{(d_j^2+\alpha)^2}(u_j^{\mathsf{T}}y)^2, \qquad \|\hat{\theta}\|_2^2 = \sum_{j=1}^{n} \frac{1}{d_j^2}(u_j^{\mathsf{T}}y)^2,$$

и $\dfrac{d_j^2}{(d_j^2+\alpha)^2} < \dfrac{1}{d_j^2}$ при $\alpha > 0$ и $d_j > 0$; если $\hat\theta \neq 0$, хотя бы одно слагаемое ненулевое и строгое неравенство сохраняется. ■

Задача 9.2. Градиент и гессиан log-loss непосредственно. Для одного наблюдения вычислить $\nabla_\theta \left[\ln(1+e^{a^\top\theta}) - y\,a^\top\theta\right]$ и ∇^2_θ, проверить положительную полуопределённость.

Решение. Обозначим $u = a^\top\theta$. $\frac{\partial}{\partial\theta_j}\ln(1+e^u) = \frac{e^u}{1+e^u}a_j = s(u)a_j$; линейное слагаемое даёт $-ya_j$. Градиент: $(s(u)-y)a$. Гессиан: $\frac{\partial}{\partial\theta_k}\left[s(u)a_j\right] = s'(u)a_k a_j = s(u)(1-s(u))a_j a_k$ — матрица $s(u)(1-s(u))\,aa^\top = \lambda aa^\top$ с $\lambda > 0$; для любого z: $z^\top(\lambda aa^\top)z = \lambda(a^\top z)^2 \geq 0$. Сумма по наблюдениям даёт $A^\top W A$ из теоремы 7.6. ■

Задача 9.3. Неполный ранг. $A = \begin{pmatrix}1 & 1\\ 1 & 1\end{pmatrix}$, $y = (2,0)^\top$. Найти все решения МНК и решение минимальной нормы.

Решение. Нормальные уравнения $A^\top A\theta = A^\top y$: $\begin{pmatrix}2 & 2\\ 2 & 2\end{pmatrix}\theta = \binom{2}{2}$, то есть $\theta_1+\theta_2 = 1$; множество решений — прямая $(t, 1-t)^\top$. Минимум нормы при $t = 1/2$: $\hat\theta = (1/2,\,1/2)^\top$. Проверка через SVD: $d_1 = 2$, $u_1 = v_1 = (1,1)^\top/\sqrt{2}$; $\hat\theta = \frac{u_1^\top y}{d_1}v_1 = \frac{\sqrt{2}}{2}\cdot\frac{1}{\sqrt{2}}\binom{1}{1}$. ■

Задача 9.4. Эквивалентность МНК и правдоподобия. Записать правдоподобие модели $y = A\theta+\varepsilon$, $\varepsilon \sim \mathcal{N}(0,\sigma^2 I)$, показать, что максимизация по θ совпадает с МНК, и сравнить оценки дисперсии.

Решение. Плотность: $L = (2\pi\sigma^2)^{-m/2}\exp(-\|y-A\theta\|^2/(2\sigma^2))$; минимизация $-\ln L$ по θ — минимизация $\|y-A\theta\|^2$. Оценка по σ^2: $\hat\sigma^2_{\text{ML}} = \|y-A\hat\theta\|^2/m$ с ожиданием $\frac{m-n}{m}\sigma^2$ (теорема 3.6); несмещённая $\hat\sigma^2$ делит на $m-n$. ■

10 Вопросы, которые стоит ожидать

- Выведите нормальные уравнения. Что меняется при неполном ранге матрицы плана?
- Что такое решение минимальной нормы и как его получить через SVD?
- Сформулируйте и докажите теорему Гаусса — Маркова. Какие посылки существенны?
- Почему решать задачу МНК через нормальные уравнения нельзя при большом числе обусловленности? Откуда берётся квадрат κ_2?
- Что такое гребневая регрессия, как записывается её решение через сингулярные числа, что делает фильтр с малыми d_j?
- Откуда берётся log-loss? Почему логистическую регрессию нельзя решить явной формулой?
- Запишите градиент и гессиан log-loss. Что следует из их вида для сходимости обучения?
- Что такое IRLS и почему шаг Ньютона совпадает со взвешенной МНК?
- Что произойдёт с оценкой логистической регрессии на линейно разделимой выборке?

11 Источники

Основные источники вопроса. Локаторы (страницы) даны в README этого вопроса.

[16] (Хасти, Тибширани, Фридман) — постановка МНК, нормальные уравнения и геометрия, теорема Гаусса — Маркова, гребневая регрессия с SVD-фильтром и df, вся теория логистической регрессии: правдоподобие, градиент и гессиан, IRLS, замечания о сходимости и разделимости.

[02] (Голуб, Ван Лоун) — глава о методе наименьших квадратов: нормальные уравнения и их погрешность (κ_2^2), QR-разложение и его обратная устойчивость, теорема о чувствительности решения и невязки к данным, псевдообратная матрица, решение минимальной нормы, таблица стоимости методов.

[53] (Воронцов) — МНК как эмпирический риск, мультиколлинеарность и гребень через сингулярное разложение, лассо, градиент и гессиан логистического функционала, IRLS как последовательность взвешенных МНК-задач.

[63] [64] (Меркулов) — обучение регрессий первыми методами: лемма спуска и скорости градиентного спуска, несмещённость стохастического градиента и оценки SGD, метод тяжёлого шарика.

[06] (Турчин) — математическая статистика: функция правдоподобия и метод максимального правдоподобия (фон раздела 7).

[51] (Гудфеллоу, Бенджио, Курвилль) — перекрёстная энтропия как функция потерь и обучение логистической регрессии градиентными методами.