Марковский процесс принятия решения

Вопрос 20

Крохалев Е. М.

2026

Постановка

Зачем это нужно

- Управляемая динамическая система в условиях неопределённости: состояние меняется случайно, управление влияет только на закон перехода.
- Типичные постановки: управление запасами, замена оборудования, реклама, денежные потоки; продолжение — обучение с подкреплением (англ. *reinforcement learning*).
- Тот же сквозной объект блока, что и в соседних вопросах (линейная система с обратной связью), по другую сторону границы: дискретное время, случайные переходы, ожидаемый доход вместо критерия качества.

Формальная постановка

Марковский процесс принятия решения (англ. *Markov decision process*, MDP) — набор (S, A, P, r): конечное множество состояний S, конечное множество действий A, для каждого действия a — стохастическая матрица переходных вероятностей $P(a)$ и функция дохода $r_{ij}(a)$ на переходах.

Динамика: в состоянии i_t, выбрав a_t, получаем i_{t+1} по закону $\left(p_{i_t j}(a_t)\right)$ и доход $r_{i_t i_{t+1}}(a_t)$.
Марковское свойство: будущее зависит от (i_t, a_t), но не от истории.

Стратегии и критерии

Стратегия (англ. *policy*) — правило выбора действия по истории. Классы: исторические / марковские / стационарные; случайные / детерминированные. Стационарная детерминированная: $\pi : S \to A$.

Критерии (максимум ожидаемого дохода), $v_i(a) = \sum_j p_{ij}(a) r_{ij}(a)$:

1. конечный горизонт N: $\mathsf{E} \sum_{t=0}^{N-1} \gamma^t r_{i_t i_{t+1}}(a_t)$;
2. бесконечный дисконтированный: $\mathsf{E} \sum_{t=0}^{\infty} \gamma^t r_{i_t i_{t+1}}(a_t), \gamma \in (0, 1)$;
3. средний доход: $\lim_{T \to \infty} \frac{1}{T} \mathsf{E} \sum_{t<T} r_{i_t i_{t+1}}(a_t)$.

Потеря = —доход: критерий есть средний риск Байеса общей проблемы принятия решения.

Основные результаты

Принцип оптимальности Беллмана (англ. *Bellman's principle of optimality*)

Оптимальное поведение обладает тем свойством, что, какими бы ни были принятое решение и состояние системы после первого шага, последующие решения должны составлять оптимальное относительно этого состояния поведение.

Если бы продолжение после некоторого состояния можно было улучшить, его замена улучшила бы и всю траекторию — вклад начала при аддитивном критерии не меняется.

Уравнение Беллмана для конечного горизонта

Теорема 1 (Уравнение Беллмана для конечного горизонта)

Пусть горизонт равен N, доходы и переходные вероятности могут зависеть от номера шага t (обозначения $r_{ij}^t(a)$, $p_{ij}^t(a)$), дисконт равен $\gamma \in (0, 1]$. Оптимальные значения $V_t^*(i)$ (от этапа t до конца при стартовом состоянии i) единственны и удовлетворяют уравнениям

$$V_N^*(i) = 0, \qquad V_t^*(i) = \max_{a \in A} \left[v_i^t(a) + \gamma \sum_{j=1}^{n} p_{ij}^t(a)\, V_{t+1}^*(j) \right], \quad t = N-1, \dots, 0,$$

причём оптимальная стратегия существует, марковская, детерминированная и задаётся выбором максимизирующего действия $a_t^*(i) \in \arg\max_{a \in A} [v_i^t(a) + \gamma \sum_j p_{ij}^t(a) V_{t+1}^*(j)]$.

Уравнение Беллмана для конечного горизонта

Теорема 1 (Уравнение Беллмана для конечного горизонта)

Пусть горизонт равен N, доходы и переходные вероятности могут зависеть от номера шага t (обозначения $r_{ij}^t(a)$, $p_{ij}^t(a)$), дисконт равен $\gamma \in (0, 1]$. Оптимальные значения $V_t^*(i)$ (от этапа t до конца при стартовом состоянии i) единственны и удовлетворяют уравнениям

$$V_N^*(i) = 0, \qquad V_t^*(i) = \max_{a \in A} \left[v_i^t(a) + \gamma \sum_{j=1}^{n} p_{ij}^t(a)\, V_{t+1}^*(j) \right], \quad t = N-1, \dots, 0,$$

причём оптимальная стратегия существует, марковская, детерминированная и задаётся выбором максимизирующего действия $a_t^*(i) \in \arg\max_{a \in A} [v_i^t(a) + \gamma \sum_j p_{ij}^t(a) V_{t+1}^*(j)]$.

Схема доказательства. Обратная индукция с формулой полной вероятности; полное доказательство — в `theory.pdf`.

Замечания к конечному горизонту

- Марковское свойство — существенно: именно оно позволяет ограничиться марковскими стратегиями.
- Оптимальная стратегия, вообще говоря, нестационарна: a_t^* зависит от оставшегося горизонта.
- Трудоёмкость обратной индукции $O(Nn^2|A|)$ вместо $|A|^{nN}$ стратегий на переборе.

Оператор Беллмана

$$\mathcal{T} \text{ на } \mathbb{R}^n: \qquad (\mathcal{T}V)(i) = \max_{a \in A} \left[v_i(a) + \gamma \sum_j p_{ij}(a)\, V(j) \right]$$

Теорема 2 (Сжатие оператора Беллмана)

На $\mathbb{R}^n$ с равномерной нормой $\|V\|_\infty = \max_i |V(i)|$ оператор $\mathcal{T}$ является γ-сжатием: $\|\mathcal{T}V - \mathcal{T}W\|_\infty \le \gamma \|V - W\|_\infty$ *для всех* $V, W \in \mathbb{R}^n$.

Замена выбора на максимизатор другой функции может только не увеличить максимум; $\sum_j p_{ij} = 1$.

Следствие 3 (Уравнение оптимальности Беллмана)

В задаче с бесконечным дисконтированным горизонтом существует единственная функция цены $V^* \in \mathbb{R}^n$*, удовлетворяющая уравнению оптимальности*

$$V^*(i) = \max_{a \in A} \left[v_i(a) + \gamma \sum_j p_{ij}(a) V^*(j) \right], \qquad i \in S,$$

то есть V^* *– неподвижная точка* $\mathcal{T}$*. При любом стартовом* V_0 *последовательность* $V_{k+1} = \mathcal{T} V_k$ *сходится к* V^* *со скоростью*

$$\|V_k - V^*\|_\infty \leq \gamma^k \|V_0 - V^*\|_\infty \leq \frac{\gamma^k}{1-\gamma} \|V_1 - V_0\|_\infty ,$$

а оптимальная стратегия существует, стационарная, детерминированная:

$$\pi^*(i) \in \arg\max_a \left[v_i(a) + \gamma \sum_j p_{ij}(a) V^*(j) \right],$$

причём функция цены стратегии π^* *совпадает с неподвижной точкой покомпонентно.*

Замечания к бесконечному горизонту

- Конечность A и $\gamma < 1$ существенны: при $\gamma = 1$ ряд расходится (критерий среднего дохода), при бесконечном A максимум может не достигаться.
- Исторические случайные стратегии не дают большего: оценка $V^{\pi} \leq V^{*}$ верна для произвольных π.
- То же уравнение называют уравнением Вальда—Беллмана в теории случайных процессов.

Оценка стратегии

Теорема 4 (Оценка стратегии)

Пусть π — стационарная (возможно, случайная) стратегия, P^π — порождённая ею матрица переходов, r^π — вектор одношаговых ожидаемых доходов: $r^\pi_i = v_i(\pi(i))$ (для случайной π: $r^\pi_i = \sum_a \pi(a \mid i) v_i(a)$). При $\gamma \in (0, 1)$ матрица $I - \gamma P^\pi$ обратима и функция цены π — единственное решение системы

$$V = r^\pi + \gamma P^\pi V, \qquad \text{то есть} \qquad V^\pi = (I - \gamma P^\pi)^{-1} r^\pi = \sum_{t=0}^{\infty} \gamma^t (P^\pi)^t r^\pi.$$

Спектральный радиус P^π равен 1 (стохастическая матрица), ряд Неймана сходится.

Улучшение стратегии и конечность метода

Теорема 5 (Улучшение стратегии)

Пусть π — стационарная стратегия и π' такова, что для всех i

$$\pi'(i) \in \arg\max_{a \in A} \left[v_i(a) + \gamma \sum_j p_{ij}(a)\, V^{\pi}(j) \right],$$

причём если множество $\arg\max$ совпадает с $\pi(i)$ для всех i, то $\pi' = \pi$. Тогда $V^{\pi'} \geq V^{\pi}$ покомпонентно; если хотя бы в одном состоянии выбор строго улучшает выражение в скобках, то $V^{\pi'} > V^{\pi}$ в каждом состоянии, из которого состояние улучшения достижимо.

Следствие 6 (Конечность метода итераций по стратегиям (англ. *policy iteration*))

Алгоритм «оценка стратегии — улучшение» (начиная с произвольной стационарной стратегии, повторять до совпадения двух последовательных стратегий) заканчивается не более чем за $|A|^n$ итераций, и последняя стратегия оптимальна: $V^{\pi} = V^*$.

Критерий среднего дохода

Цепь под стационарной стратегией — марковская; неприводимая конечная цепь имеет единственное стационарное распределение μ ($\mu^{\top} P = \mu^{\top}$).

$$g^{\pi} = \sum_i \mu_i \, r_i^{\pi}, \qquad g^{\pi} + f(i) = r_i^{\pi} + \sum_j p_{ij}^{\pi} \, f(j)$$

Методы: полный перебор ($|A|^n$ стратегий) и итерации по стратегиям — оценка из системы выше с фиксацией константы, улучшение по $\max_a [v_i(a) + \sum_j p_{ij}(a) f(j)]$.

Линейное программирование

Минимизировать $\sum_i b_i V(i)$, $b_i > 0$, при ограничениях

$$V(i) \geq v_i(a) + \gamma \sum_j p_{ij}(a) V(j) \quad \forall i, a$$

— решение единственно и совпадает с V^*; в двойственной задаче оптимум достигается на детерминированной стратегии (ровно одно положительное w_{ia} на состояние).

Детерминированная динамика $x_{t+1} = F_t(x_t, u_t)$, критерий $\sum_t \Phi_t(x_t, u_t) + \Theta(x_N) \to \min$;
уравнение Беллмана

$$V_t(x) = \min_{u \in U} \left[\Phi_t(x, u) + V_{t+1}(F_t(x, u))\right], \qquad V_N(x) = \Theta(x). \tag{1}$$

Необходимое условие оптимальности

Теорема 7 (Дискретный принцип максимума)

Пусть F_t, Φ_t, Θ непрерывно дифференцируемы по x, U компактно и выпукло, F_t аффинна по u и $\Phi_t(x,\cdot) + V_{t+1}(F_t(x,\cdot))$ выпукла на U и $\Phi_t(x,\cdot)$ выпукла на U, а V_t — решение (1), дифференцируемое по x. Обозначим гамильтониан

$$H_t(x,u,p) = -\Phi_t(x,u) + p^{\mathsf{T}} F_t(x,u).$$

Тогда оптимальное управление и сопряжённая переменная $p_t = -\nabla V_{t+1}(x^*_{t+1})$ удовлетворяют

$$u^*_t \in \arg\max_{u\in U} H_t(x^*_t, u, p_t), \qquad p_{t-1} = -\frac{\partial \Phi_t}{\partial x}(x^*_t, u^*_t) + \left(\frac{\partial F_t}{\partial x}(x^*_t, u^*_t)\right)^{\mathsf{T}} p_t,$$

с терминальным условием $p_{N-1} = -\nabla\Theta(x^*_N)$: формулы принципа максимума Понтрягина для дискретной задачи.

$p_t = -\nabla V_{t+1}$ — дискретный аналог $p = -\nabla S$ (та же конвенция знака); непрерывный предел — принцип максимума Понтрягина (предмет соседнего вопроса программы).

Линейно-квадратичная модель

Сквозной объект блока — дискретный двойной интегратор $x_{k+1} = Ax_k + Bu_k + w_k$, критерий E $\sum_k \gamma^k (x_k^\top Q x_k + u_k^\top R u_k) \to \min$.

Теорема 8 (Функция цены квадратична, Риккати)

В задаче с динамикой $x_{k+1} = Ax_k + Bu_k + w_k$ и критерием выше функция цены квадратична $V^*(x) = x^\top K x + c$, где $K \succeq 0$ — единственное решение алгебраического уравнения Риккати

$$K = Q + \gamma A^\top K A - \gamma^2 A^\top K B \left(R + \gamma B^\top K B\right)^{-1} B^\top K A,$$

константа $c = \frac{\gamma}{1-\gamma} \operatorname{tr}(KW)$, а оптимальное управление — стационарная линейная обратная связь

$$u^*(x) = -Lx, \qquad L = \gamma \left(R + \gamma B^\top K B\right)^{-1} B^\top K A.$$

- Шум w_k влияет только на c: обратная связь от W не зависит.
- При $R \to +0$ один полюс $A - BL$ уходит к нулю, второй — к $(2-h)/(2+h)$ (образ $s = -1$; мост к непрерывной LQ-задаче).

Численная иллюстрация

Задача садовника (по [60])

Три состояния почвы, действия «удобрять / не удобрять». Конечный горизонт $N = 3$:
$f_1 = (10{,}74;\ 7{,}92;\ 4{,}23)$ — удобрять в годы 1–2 всегда, в год 3 — кроме хорошего состояния.

Бесконечный горизонт (средний доход): оптимум $g = 2{,}256$ у стратегии «всегда удобрять»,
$\mu = \frac{1}{59}(6, 31, 22)$.

Дисконт $\gamma = 0{,}6$: оптимум $V^* = (8{,}97;\ 6{,}63;\ 3{,}38)$ у $\{1, 2, 2\}$ — дисконт меняет решение.

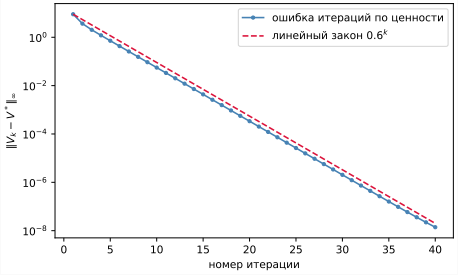
Сравнение методов и LQ

Итерации по стратегиям, $\gamma = 0{,}6$:

$$\{1,1,1\} \to \{2,2,2\} \to \{1,2,2\}, \quad 3 \text{ оценки}$$

Итерации по ценности (англ. *value iteration*): 39 шагов до 10^{-8}, знаменатель γ.

LQ-двойной интегратор: K итераций Риккати, $u^* = -Lx$, полюса $A - BL$ внутри единичного круга.



Что спрашивают на экзамене

1. Почему оптимальная стратегия стационарна, хотя допустимы исторические?
2. Чем средний доход отличается от дисконтированного?
3. Как оценить заданную стратегию? Почему итерации по стратегиям конечны?
4. Связь с принципом максимума Понтрягина (дискретный предел, $p = -\nabla S$).
5. Откуда Риккати в LQ-задаче, почему обратная связь линейна?
6. MDP как частный случай общей проблемы принятия решения (средний риск).