Вопрос 20. Марковский процесс принятия решения

Конспект теории с полными доказательствами

Крохалев Е. М.

2026

Содержание

1 Постановка и мотивация **1**

2 Определения и обозначения **2**

3 Принцип оптимальности и конечный горизонт **3**

4 Марковские цепи под стратегией **5**

5 Бесконечный дисконтированный горизонт **6**

6 Итерации по стратегиям **7**

7 Критерий среднего дохода **8**

8 Сведение к линейному программированию **11**

9 Детерминированный случай и дискретный принцип максимума **12**

10 Линейно-квадратичная модель **13**

11 Прикладная рамка **14**

12 Разобранные задачи **15**

13 Вычислительная сторона **16**

14 Вопросы, которые стоит ожидать **16**

15 Источники **16**

16 Дополнительные главы **17**
16.1 Эргодическая теорема для конечной цепи 17
16.2 Ранг $I - P$ и существование поправочной функции 18
16.3 Уравнение Вальда—Беллмана и обучение с подкреплением 18

1 Постановка и мотивация

Вопросы 04 и 06 этого блока рассматривали детерминированную динамическую систему: состояние в следующий момент однозначно определялось текущим состоянием и выбранным управлением. Здесь то же самое делается в условиях неопределённости: система эволюционирует случайно, и управление (лицо, принимающее решение) влияет лишь на закон

её поведения. Сквозной объект блока остаётся тем же — линейная система с обратной связью, — но по ту сторону границы: непрерывное время, известное состояние и критерий качества (вопрос 06) сменяются дискретным временем, случайными переходами и ожидаемым доходом.

Марковский процесс принятия решения (англ. *Markov decision process*, MDP; в части литературы — *управляемый марковский процесс*) — математическая модель многошагового принятия решений в условиях неопределённости, в которой закон движения системы обладает марковским свойством: будущее зависит от выбранного действия и текущего состояния, но не от истории. Эта постановка объединяет три линии программы. С вероятностной стороны это теория марковских цепей (вопрос 08 даёт аппарат условных ожиданий). Со стороны теории решений (вопрос 03) это та же общая проблема: заданы состояния природы, множество решений и функция потерь — только потери здесь складываются по шагам, и оптимальность понимается по математическому ожиданию суммарного дохода, то есть по среднему риску (потеря есть отрицание дохода). Со стороны оптимального управления (вопрос 06) MDP — дискретный аналог задачи на конечном или бесконечном горизонте: уравнение оптимальности Беллмана здесь — конечномерная версия уравнения Беллмана из вопроса 06, а для линейной системы с квадратичным критерием оба сходятся к уравнению Риккати.

Типичные прикладные постановки: управление запасами (сколько заказывать), замена оборудования (чинить или менять), выбор рекламной политики, управление денежными потоками; современное продолжение — обучение с подкреплением (англ. *reinforcement learning*), где закон переходов неизвестен и оптимальная стратегия ищется по наблюдениям.

2 Определения и обозначения

Обозначения. $S = \{1, 2, \dots, n\}$ — конечное множество состояний; A — конечное множество действий (альтернатив). Через $p_{ij}(a)$ обозначается вероятность того, что система, находясь в состоянии i и применив действие a, перейдёт в состояние j; матрица $P(a) = \big(p_{ij}(a)\big)_{i,j=1}^{n}$ стохастическая: $p_{ij}(a) \geq 0$, $\sum_j p_{ij}(a) = 1$. Через $r_{ij}(a)$ обозначается доход (может быть и отрицательным — тогда это затрата), получаемый при таком переходе; величина

$$v_i(a) := \sum_{j=1}^{n} p_{ij}(a)\, r_{ij}(a)$$

— ожидаемый одношаговый доход в состоянии i при действии a. Параметр $\gamma \in (0, 1)$ — коэффициент дисконтирования: доход через один шаг учитывается с весом γ. Через $\mathcal{T}$ обозначается оператор Беллмана (раздел 5), через π — стационарная стратегия, через μ^{π} — стационарное распределение порождённой ею цепи (раздел 4). Буквы A, B в разделе о линейно-квадратичной модели (раздел 10) — матрицы дискретной системы, как в вопросах 04 и 06; Q, R там — весовые матрицы критерия, как в вопросе 06.

Определение 2.1 (Марковский процесс принятия решений)**.** Марковский процесс принятия решения — набор (S, A, P, r): конечное множество состояний S, конечное множество действий A, для каждого действия $a \in A$ — стохастическая матрица переходных вероятностей $P(a)$ и функция дохода $r_{ij}(a)$ на переходах. Динамика: если в момент t система находится в состоянии i_t и выбрано действие a_t, то i_{t+1} распределено по закону $\big(p_{i_t j}(a_t)\big)_{j \in S}$, а наблюдается доход $r_{i_t i_{t+1}}(a_t)$.

Марковское свойство зашито в саму запись: закон i_{t+1} зависит от пары (i_t, a_t) и не зависит от $(i_0, a_0, \dots, i_{t-1}, a_{t-1})$. Управление, то есть выбор действий, выполняется стратегией.

Определение 2.2 (Стратегия)**.** Стратегия (политика, англ. *policy*) — правило выбора действия в каждом моменте t по всей накопленной истории $h_t = (i_0, a_0, \dots, i_{t-1}, a_{t-1}, i_t)$. Стратегия называется марковской, если выбор зависит только от пары (t, i_t): детерминированная марковская задаётся последовательностью отображений $\pi_t \colon S \to A$, случайная марковская — распределениями $\pi_t(\cdot \mid i)$ на A; стационарной — если правило не зависит от t. Детерминированная стационарная стратегия — одно отображение $\pi \colon S \to A$; случайная стационарная — набор распределений $\pi(\cdot \mid i)$ на A для каждого состояния i (детерминированные стационарные — частный случай: $\pi(a \mid i) \in \{0, 1\}$).

Оптимальность определяется критерием. Используются три основных.

Определение 2.3 (Критерии оптимальности)**.** Пусть $i_0 = i$. (1) *Конечный горизонт* (моменты $t = 0, 1, \dots, N-1$):

$$V_N^{\pi}(i) = \mathsf{E}^{\pi}\Big[\sum_{t=0}^{N-1} \gamma^t \, r_{i_t i_{t+1}}(a_t)\Big] \to \max;$$

(2) *бесконечный дисконтированный горизонт*:

$$V^{\pi}(i) = \mathsf{E}^{\pi}\Big[\sum_{t=0}^{\infty} \gamma^t \, r_{i_t i_{t+1}}(a_t)\Big] \to \max;$$

(3) *средний доход* (без дисконтирования):

$$g^{\pi} = \lim_{T \to \infty} \frac{1}{T} \, \mathsf{E}^{\pi}\Big[\sum_{t=0}^{T-1} r_{i_t i_{t+1}}(a_t)\Big] \to \max.$$

Во всех трёх случаях максимум берётся по всем стратегиям, а $V_N^*(i)$, $V^*(i)$, g^* — соответствующие оптимальные значения.

Заметим, что в постановке (2) ряд сходится абсолютно: если $M = \max_{i,j,a} \big|r_{ij}(a)\big|$, то $|V^{\pi}(i)| \le M/(1-\gamma)$ при любой стратегии. Постановки (1) и (2) — частные случаи общей проблемы принятия решения (вопрос 03): пространством решений служит множество стратегий, а функция потерь — отрицание суммарного дохода; максимум математического ожидания дохода есть минимум среднего риска Байеса. Различие критериев (2) и (3) содержательно: дисконтирование отдаёт предпочтение ближним доходам и делает задачу «сжимающей» (раздел 5), тогда как средний доход измеряет установившийся режим и требует эргодических свойств цепи (раздел 7).

3 Принцип оптимальности и конечный горизонт

Принцип оптимальности Беллмана (англ. *Bellman's principle of optimality*) — свойство аддитивных многошаговых критериев, на котором стоит всё динамическое программирование.

Предложение 3.1 (Принцип оптимальности)**.** *Оптимальное поведение обладает тем свойством, что, какими бы ни были принятое решение и состояние системы после первого шага, последующие решения должны составлять оптимальное относительно этого состояния поведение. Двойственная формулировка: каковы бы ни были состояние перед последним шагом и решение на последнем шаге, предыдущие решения должны быть оптимальны относительно этого состояния.*

Это свойство, а не теорема: его доказательство — одна строка. Если бы продолжение после некоторого состояния $\bar{x}$ на шаге $\bar{t}$ можно было улучшить, заменой продолжения на лучшее мы улучшили бы и всю траекторию, не трогая её начала; при аддитивном критерии вклад начала не меняется. Обе формулировки эквивалентны и применяются по обе

стороны рекуррентности: первая — для вывода уравнения по сокращённому горизонту (обратная индукция), вторая — для прямого прохода. Математической записью принципа служит уравнение Беллмана.

Теорема 3.2 (Уравнение Беллмана для конечного горизонта)**.** *Пусть горизонт равен N, доходы и переходные вероятности могут зависеть от номера шага t (обозначения $r_{ij}^t(a)$, $p_{ij}^t(a)$), дисконт равен $\gamma \in (0,1]$. Оптимальные значения $V_t^*(i)$ (от этапа t до конца при стартовом состоянии i) единственны и удовлетворяют уравнениям*

$$V_N^*(i) = 0, \qquad V_t^*(i) = \max_{a \in A} \Big[v_i^t(a) + \gamma \sum_{j=1}^{n} p_{ij}^t(a)\, V_{t+1}^*(j) \Big], \quad t = N-1, \dots, 0, \tag{1}$$

причём оптимальная стратегия существует, марковская, детерминированная и задаётся выбором максимизирующего действия $a_t^*(i) \in \arg\max_{a \in A} \big[v_i^t(a) + \gamma \sum_j p_{ij}^t(a) V_{t+1}^*(j) \big]$.

Доказательство. Существование: множество A конечно, значит максимум в правой части (1) при любом наборе значений $V_{t+1}^*(j)$ достигается, и рекуррентное вычисление по t от N к 0 корректно определяет функции V_t^* и выбор $a_t^*(i)$.

Оптимальность. Обозначим через $W_t(i)$ правую часть при подстановке построенной стратегии $\pi^* = (a_0^*, \dots, a_{N-1}^*)$: $W_t(i) = V_t^*(i)$ по построению. Покажем по обратной индукции, что для любой стратегии π (в том числе исторической и случайной) и любого t

$$\mathsf{E}^{\pi}\Big[\sum_{s=t}^{N-1} \gamma^{s-t} r_{i_s i_{s+1}}(a_s) \,\Big|\, i_t = i \Big] \le V_t^*(i), \tag{2}$$

причём для π^* достигается равенство при любом i. Доказательство — индукция по t вниз от N. База $t = N$: обе части нулевые. Шаг: пусть утверждение верно для $t+1$. Зафиксируем i и любую стратегию π; её действие в момент t (возможно, случайное, зависящее от истории) обозначим α. Тогда по формуле полной вероятности и марковскому свойству

$$\begin{aligned} \mathsf{E}^{\pi}\Big[\sum_{s=t}^{N-1} \gamma^{s-t} r_{i_s i_{s+1}}(a_s) \,\Big|\, i_t = i \Big] &= \mathsf{E}^{\pi}\big[v_i^t(\alpha) \mid i_t = i \big] + \gamma\, \mathsf{E}^{\pi}\Big[\sum_{s=t+1}^{N-1} \gamma^{s-t-1} r_{i_s i_{s+1}}(a_s) \,\Big|\, i_t = i \Big] \\ &= \mathsf{E}^{\pi}\Big[v_i^t(\alpha) + \gamma \sum_{j} p_{ij}^t(\alpha)\, h_{t+1}(j) \,\Big|\, i_t = i \Big], \end{aligned}$$

где $h_{t+1}(j)$ — условное математическое ожидание продолжения при условии $i_{t+1} = j$; оно зависит только от стратегии после шага t и по индуктивному предположению не превосходит $V_{t+1}^*(j)$. Значит, всё выражение не превосходит

$$\max_{a \in A} \Big[v_i^t(a) + \gamma \sum_{j} p_{ij}^t(a) V_{t+1}^*(j) \Big] = V_t^*(i),$$

что и требовалось. Для π^* неравенство обращается в равенство, так как $a_t^*(i)$ максимизирует выражение в скобках. Таким образом, π^* оптимальна, а V_t^* совпадают с оптимальными значениями; единственность оптимальных значений следует из единственности решения рекуррентной системы, доказанной выше. $\square$

Замечание 3.3. Три наблюдения, которые спрашивают следом. (1) Доказательство опирается на марковское свойство: условное распределение i_{t+1} при фиксированном действии зависит только от i_t — именно поэтому достаточно марковских стратегий, и именно здесь постановка расходилась бы с исторической (например, с цепями высших порядков). (2) Оптимальная стратегия конечного горизонта, вообще говоря, нестационарна: a_t^* зависит от t, потому что меняется оставшийся горизонт; стационарность — явление бесконечного горизонта (раздел 5). (3) Трудоёмкость обратной индукции — $O(N\, n\, |A|\, n)$ операций (на каждом из N шагов для каждой пары (i,a) сумма по j из n слагаемых) вместо перебора $|A|^{nN}$

стратегий; это тот же выигрыш, что и у метода динамического программирования в детерминированных задачах [12].

Заметим также симметрию: доказательство работает и для минимизации затрат (замена max на min и доходов издержками), — в разделах о детерминированном и линейно-квадратичном случаях мы перейдём именно на минимизацию, чтобы совпасть с конвенцией вопроса 06.

4 Марковские цепи под стратегией

Фиксируем стационарную детерминированную стратегию π. Тогда последовательность состояний $i_0, i_1, \dots$ образует однородную марковскую цепь с матрицей переходных вероятностей

$$P^{\pi} = \bigl(p_{ij}(\pi(i))\bigr)_{i,j=1}^{n},$$

а средний доход на шаге равен $v_i(\pi(i))$. Случайная стационарная стратегия порождает цепь с матрицей $P^{\pi} = \bigl(\sum_a \pi(a \mid i)\, p_{ij}(a)\bigr)$. Дальнейшие конструкции (стационарное распределение, средний доход) опираются на свойства такой цепи.

Теорема 4.1 (Уравнение Колмогорова—Чепмена)**.** *Пусть P — стохастическая матрица однородной марковской цепи, $p_{ij}^{(m)}$ — вероятность перейти из i в j ровно за m шагов. Тогда для всех $m, l \geq 1$*

$$p_{ij}^{(m+l)} = \sum_{k=1}^{n} p_{ik}^{(m)}\, p_{kj}^{(l)}.$$

Доказательство. Разобьём событие «из i за $m{+}l$ шагов в j» по состоянию k после m шагов; по формуле полной вероятности

$$p_{ij}^{(m+l)} = \sum_{k} \mathsf{P}(i_m = k \mid i_0 = i)\, \mathsf{P}(i_{m+l} = j \mid i_m = k, i_0 = i),$$

а второй множитель по марковскому свойству равен $p_{kj}^{(l)}$. □

Цепь называется *неприводимой*, если из любого состояния можно попасть в любое другое (для некоторого числа шагов), и *апериодической*, если для каждого состояния множество длин путей возвращения имеет наибольший общий делитель 1 (достаточно существования петли $p_{ii} > 0$ хотя бы в одном состоянии неприводимой цепи). Неприводимая апериодическая конечная цепь называется *эргодической*.

Теорема 4.2 (Стационарное распределение неприводимой цепи)**.** *Пусть P — стохастическая матрица конечной неприводимой цепи. Тогда существует единственное распределение $\mu = (\mu_1, \dots, \mu_n)$, $\mu_j > 0$, $\sum_j \mu_j = 1$, удовлетворяющее уравнению*

$$\mu^{\mathsf{T}} P = \mu^{\mathsf{T}}, \tag{3}$$

а среднее время возвращения в состояние j равно $1/\mu_j$. Если цепь дополнительно апериодична (эргодична), то для любого начального распределения $a^{(0)}$ вектор абсолютных вероятностей $a^{(t)} = a^{(0)} P^t$ сходится к μ.

Доказательство вынесено в дополнительные главы: существование, единственность и положительность μ — по лемме о ранге (лемма 16.3), среднее время возвращения — по тождеству Кака (дополнительные главы), сходимость $a^{(t)} \to \mu$ — по теореме 16.1 для апериодической цепи (для периодической P^t не сходится, но сходятся Цезаро-средние — замечание 16.2). Заметим, что уравнение (3) — линейная система из n уравнений с n неизвестными, одно из которых линейно зависит (строки P суммируются в единицы, поэтому столбцы

$I - P^{\mathsf{T}}$ суммируются в нуль), поэтому на практике одно уравнение заменяют условием нормировки $\sum_j \mu_j = 1$.

5 Бесконечный дисконтированный горизонт

Теперь горизонт бесконечен, доходы дисконтированы с $\gamma \in (0,1)$. Ключ к теории этого случая — оператор Беллмана на $\mathbb{R}^n$:

$$(\mathcal{T}V)(i) = \max_{a \in A} \Big[v_i(a) + \gamma \sum_j p_{ij}(a)\, V(j) \Big], \qquad V \in \mathbb{R}^n. \tag{4}$$

Теорема 5.1 (Сжатие оператора Беллмана)**.** *На $\mathbb{R}^n$ с равномерной нормой $\|V\|_\infty = \max_i |V(i)|$ оператор $\mathcal{T}$ является γ-сжатием: $\|\mathcal{T}V - \mathcal{T}W\|_\infty \le \gamma \|V - W\|_\infty$ для всех $V, W \in \mathbb{R}^n$.*

Доказательство. Для каждого i обозначим через $a_V(i)$ максимизирующее действие в определении $(\mathcal{T}V)(i)$. Поскольку $\sum_j p_{ij}(a_V(i)) = 1$, оценка $V(j) \le W(j) + \|V - W\|_\infty$ переносится на математические ожидания с весами $p_{ij}(a_V(i))$, а замена выбора на $a_V(i)$ в определении $(\mathcal{T}W)(i)$ может только не увеличить максимум; отсюда цепочка

$$\begin{aligned} (\mathcal{T}V)(i) &= v_i(a_V(i)) + \gamma \sum_j p_{ij}(a_V(i)) V(j) \\ &\le v_i(a_V(i)) + \gamma \sum_j p_{ij}(a_V(i)) W(j) + \gamma \|V - W\|_\infty \\ &\le (\mathcal{T}W)(i) + \gamma \|V - W\|_\infty . \end{aligned}$$

Симметрично $(\mathcal{T}W)(i) \le (\mathcal{T}V)(i) + \gamma \|V - W\|_\infty$, и объединение даёт $|(\mathcal{T}V)(i) - (\mathcal{T}W)(i)| \le \gamma \|V - W\|_\infty$ для всех i. □

Следствие 5.2 (Уравнение оптимальности Беллмана)**.** *В задаче с бесконечным дисконтированным горизонтом существует единственная функция цены $V^* \in \mathbb{R}^n$, удовлетворяющая уравнению оптимальности*

$$V^*(i) = \max_{a \in A} \Big[v_i(a) + \gamma \sum_j p_{ij}(a) V^*(j) \Big], \qquad i \in S, \tag{5}$$

то есть V^* — неподвижная точка $\mathcal{T}$. При любом стартовом V_0 последовательность $V_{k+1} = \mathcal{T}V_k$ сходится к V^* со скоростью

$$\|V_k - V^*\|_\infty \le \gamma^k \, \|V_0 - V^*\|_\infty \le \frac{\gamma^k}{1-\gamma} \, \|V_1 - V_0\|_\infty , \tag{6}$$

а оптимальная стратегия существует, стационарная, детерминированная:

$$\pi^*(i) \in \arg\max_a \Big[v_i(a) + \gamma \sum_j p_{ij}(a) V^*(j) \Big],$$

причём функция цены стратегии π^* совпадает с неподвижной точкой покомпонентно.

Доказательство. $\mathbb{R}^n$ с $\|\cdot\|_\infty$ — полное метрическое пространство, $\mathcal{T}$ — γ-сжатие (теорема 5.1), значит по принципу сжимающих отображений неподвижная точка существует и единственна, а итерации сходятся с первой оценкой в (6); вторая оценка — стандартное след-

ствие: для ошибки $E_k = \|V_k - V^*\|_\infty$ выполнено $E_1 \le \gamma E_0 \le \gamma \|V_1 - V_0\|_\infty + \gamma E_1$, откуда $E_1 \le \frac{\gamma}{1-\gamma}\|V_1 - V_0\|_\infty$ и $E_k \le \gamma^{k-1} E_1 \le \frac{\gamma^k}{1-\gamma}\|V_1 - V_0\|_\infty$.

Осталось связать неподвижную точку с оптимальной стратегией. Для произвольной стационарной стратегии π обозначим через U_π аффинный оператор одношагового ожидания $U_\pi V = r^\pi + \gamma P^\pi V$; он является γ-сжатием (норма $\|\gamma P^\pi\|_\infty = \gamma$), и его неподвижная точка по лемме 6.1 есть V^π; к тому же U_π монотонен: $V \ge W$ покомпонентно влечёт $U_\pi V \ge U_\pi W$.

(i) Для любой стратегии π и любого V из $V \ge \mathcal{T}V$ покомпонентно следует $V \ge V^\pi$: в самом деле, $V \ge \mathcal{T}V \ge U_\pi V$ (второе — по определению $\mathcal{T}$ как максимума), и индукция по k даёт $V \ge U_\pi^k V$ для всех k, а предел при $k \to \infty$ — это V^π. Тот же аргумент применим к любой нестационарной стратегии: для неё U_π заменяется композицией $U_{\pi_0} \circ \ldots \circ U_{\pi_{k-1}}$ с той же монотонностью, и её предел при $k \to \infty$ равен V^π — по абсолютной сходимости ряда $\sum_t \gamma^t$ композиция приближается к пределу с ошибкой $O(\gamma^k)$ независимо от стартовой точки.

(ii) Неподвижная точка $V^*_{\text{Б}}$ удовлетворяет $V^*_{\text{Б}} = \mathcal{T}V^*_{\text{Б}} \ge U_\pi V^*_{\text{Б}}$ при любой π, значит, $V^*_{\text{Б}} \ge V^\pi$ для всех π.

(iii) Наконец, для π^* из условия $\pi^*(i) \in \arg\max$ выполнено равенство $V^*_{\text{Б}} = U_{\pi^*} V^*_{\text{Б}}$, то есть $V^*_{\text{Б}}$ — решение уравнения оценки для π^*; по единственности (лемма 6.1) $V^{\pi^*} = V^*_{\text{Б}}$. Следовательно, $V^{\pi^*} = V^*_{\text{Б}} \ge V^\pi$ для всех π: π^* оптимальна, и её значение совпадает с неподвижной точкой. □

Замечание 5.3. (1) Здесь конечность A и $\gamma < 1$ существенны: при $\gamma = 1$ и бесконечном горизонте ряд ожидаемых доходов может расходиться (тогда переходят к критерию среднего дохода, раздел 7), а при бесконечном A максимум в (4) может не достигаться — оптимальной стратегии не будет, останется только ε-оптимальная. (2) Исторические и случайные стратегии преимущества не дают: оценка $V^\pi \le V^*$ доказана для произвольных π, так что стационарной детерминированной стратегии достаточно, хотя и не обязательно: оптимальных стратегий может быть много, но все они дают одну функцию цены V^*. (3) Оценка (6) показывает стоимость точности: число итераций по ценности для достижения точности ε есть $O\big(\log \frac{1}{\varepsilon} \big/ \log \frac{1}{\gamma}\big)$ — при γ близком к 1 оно велико, и на практике ускоряют метод (итерации по стратегиям, раздел 6, многосеточные и ускоренные схемы [55]).

Уравнение оптимальности (5) — то же, что называют уравнением Вальда—Беллмана в теории случайных процессов [44]: «Вальд» — за связь с последовательным анализом (остановкой момента наблюдения), «Беллман» — за принцип оптимальности.

6 Итерации по стратегиям

Итерации по ценности (последовательность $\mathcal{T}^k V_0$) сходятся линейно со знаменателем γ и не используют конечности множества стратегий. Метод итераций по стратегиям (англ. *policy iteration*) строит конечную последовательность стратегий, каждая следующая не хуже предыдущей, и заканчивается за конечное число шагов. Для него нужны две операции: оценка стратегии и её улучшение.

Теорема 6.1 (Оценка стратегии)**.** *Пусть π — стационарная (возможно, случайная) стратегия, P^π — порождённая ею матрица переходов, r^π — вектор одношаговых ожидаемых доходов: $r^\pi_i = v_i(\pi(i))$ (для случайной π: $r^\pi_i = \sum_a \pi(a \mid i) v_i(a)$). При $\gamma \in (0,1)$ матрица $I - \gamma P^\pi$ обратима и функция цены π — единственное решение системы*

$$V = r^\pi + \gamma P^\pi V, \qquad \text{то есть} \qquad V^\pi = (I - \gamma P^\pi)^{-1} r^\pi = \sum_{t=0}^{\infty} \gamma^t (P^\pi)^t r^\pi. \tag{7}$$

Доказательство. Спектральный радиус P^π равен 1 (стохастическая матрица: норма индуцированная $\|\cdot\|_\infty$ от P^π равна 1, а вектор единиц — собственный с собственным значением 1). Значит, собственные значения γP^π по модулю меньше 1, ряд Неймана сходится и $(I-\gamma P^\pi)^{-1} = \sum_{t\ge 0}\gamma^t (P^\pi)^t$. Прямая подстановка показывает, что $V = \sum_t \gamma^t (P^\pi)^t r^\pi$ удовлетворяет (7); с другой стороны, из (7) $V = (I-\gamma P^\pi)^{-1} r^\pi$ — единственность. Наконец, $(V^\pi)(i) = \mathsf{E}^\pi\big[\sum_t \gamma^t r^\pi_{i_t}\big] = \sum_t \gamma^t \mathsf{E}^\pi[r^\pi_{i_t}] = \sum_t \gamma^t \big((P^\pi)^t r^\pi\big)_i$ — это и есть ряд Неймана. □

Теорема 6.2 (Улучшение стратегии)**.** *Пусть π — стационарная стратегия и π' такова, что для всех i*

$$\pi'(i) \in \arg\max_{a\in A}\Big[v_i(a) + \gamma \sum_j p_{ij}(a)\, V^\pi(j)\Big],$$

причём при ничьей ($\pi(i)$ среди максимизаторов) сохраняется $\pi'(i)=\pi(i)$. Тогда $V^{\pi'} \ge V^\pi$ покомпонентно; если хотя бы в одном состоянии выбор строго улучшает выражение в скобках, то $V^{\pi'} > V^\pi$ в каждом состоянии, из которого состояние улучшения достижимо.

Доказательство. Обозначим $\Delta = \mathcal{T}V^\pi - V^\pi \ge 0$; по построению π' выполнено $\mathcal{T}_{\pi'}V^\pi = \mathcal{T}V^\pi = V^\pi + \Delta$, где $\mathcal{T}_{\pi'}$ — оператор ожидания по стратегии π' (линейный аффинный: $\mathcal{T}_{\pi'}V = r^{\pi'} + \gamma P^{\pi'} V$). Тогда

$$V^{\pi'} - V^\pi = \mathcal{T}_{\pi'}V^{\pi'} - \mathcal{T}_{\pi'}V^\pi = \gamma P^{\pi'}(V^{\pi'} - V^\pi) + \Delta,$$

откуда $V^{\pi'} - V^\pi = (I-\gamma P^{\pi'})^{-1}\Delta = \sum_t \gamma^t (P^{\pi'})^t \Delta \ge 0$, так как обратная матрица неотрицательна (ряд Неймана). Если $\Delta(i_0) > 0$, то из состояния i с положительной вероятностью достигается i_0 (по условию), значит $\big((P^{\pi'})^t\Delta\big)_i > 0$ для некоторого t, и неравенство строгое. □

Следствие 6.3 (Конечность метода итераций по стратегиям)**.** *Алгоритм «оценка стратегии — улучшение» (начиная с произвольной стационарной стратегии, повторять до совпадения двух последовательных стратегий) заканчивается не более чем за $|A|^n$ итераций, и последняя стратегия оптимальна: $V^\pi = V^*$.*

Доказательство. Множество стационарных детерминированных стратегий конечно ($|A|^n$ элементов), строгое улучшение по теореме 6.2 исключает возврат к уже встреченной стратегии, значит цикл не более $|A|^n$ шагов. Если на очередном шаге $\pi' = \pi$, то $\mathcal{T}V^\pi = \mathcal{T}_\pi V^\pi = V^\pi$ (второе равенство — (7)), то есть V^π — неподвижная точка $\mathcal{T}$, а по единственности (следствие 5.2) $V^\pi = V^*$. □

Замечание 6.4. На практике метод итераций по стратегиям сходится за считанные оценки (на задаче садовника — три оценки против 39 шагов итераций по ценности при $\gamma = 0{,}6$; измерено в ноутбуке этого вопроса), тогда как итерации по ценности требуют $O\big(\log \frac{1}{\varepsilon}\big)$ шагов; плата — решение линейной системы (7) на каждом шаге. Существует и промежуточная схема — модифицированные итерации по политикам, где оценка (7) выполняется приближённо, несколькими шагами $\mathcal{T}_\pi$ [55]. Все три метода — полный перебор, итерации по ценности, итерации по стратегиям — на задаче садовника разобраны в ноутбуке к этому вопросу, числа совпадают с [60].

7 Критерий среднего дохода

При $\gamma = 1$ сумма доходов за бесконечный горизонт, вообще говоря, расходится, и критерием служит средний доход g^π (определение 2.3). Средний доход целиком определяется установившимся режимом цепи, поэтому посылки теорем — эргодичность.

Теорема 7.1 (Оценка стратегии при среднем доходе)**.** *Пусть π — стационарная стратегия, породившая неприводимую марковскую цепь с матрицей P, одношаговыми доходами r_i и стационарным распределением μ. Тогда $g^\pi = \sum_i \mu_i r_i$ не зависит от начального состояния, и существует функция f (определённая с точностью до аддитивной константы), для которой*

$$g^\pi + f(i) = r_i + \sum_j p_{ij}\, f(j), \qquad i \in S. \tag{8}$$

Доказательство. Независимость от начального состояния: $\frac{1}{T}\mathsf{E}^\pi[\sum_{t<T} r_{i_t}] = \frac{1}{T} a^{(0)} (\sum_{t<T} P^t) r \to \mu^{\mathsf{T}} r$, так как Цезаро-средние $\frac{1}{T}\sum_{t<T} P^t$ сходятся к $\mathbf{1}\mu^{\mathsf{T}}$ — для апериодической цепи это следует из теоремы 16.1, для периодической — из того же доказательства, применённого к P^d на циклических классах, d — период. Существование f: по лемме о ранге (теорема 16.3 в дополнительных главах) матрица $I - P$ имеет ранг $n-1$, её ядро порождено вектором единиц, а левое ядро — вектором μ; тогда уравнение $f - Pf = r - g\mathbf{1}$ разрешимо тогда и только тогда, когда $\mu^{\mathsf{T}}(r - g\mathbf{1}) = 0$, что и даёт $g = \mu^{\mathsf{T}} r$, и решение f единственно с точностью до константы. □

Соотношение (8) отделяет установившийся режим (константа g^π, одинаковая для всех начальных состояний) от переходного процесса (функция f, определённая с точностью до константы). Оптимизация по критерию среднего дохода выполняется теми же двумя способами.

Замечание 7.2. Посылка теорем этого раздела — неприводимость цепи под каждой стационарной стратегией — сильна и в приложениях нарушается. Так, в задаче садовника (раздел 12) четыре из восьми стационарных стратегий держат систему в поглощающем состоянии 3 и имеют $\mu = (0, 0, 1)$: теорема 7.1 на них формально не распространяется. Общая рамка, покрывающая такие задачи, — *унихейновая* модель: у каждой стационарной стратегии ровно один возвратный класс, остальные состояния невозвратны, и цепь входит в класс за конечное время. В ней g^π по-прежнему не зависит от начального состояния, система оценки разрешима (bias на невозвратных состояниях выражается ожиданиями до входа в класс) [55]; неубывание g при улучшении сохраняется, но строгое возрастание g гарантируется лишь для улучшений внутри возвратного класса. Если g при улучшении не изменился, выигрыш улучшения сосредоточен на невозвратных (под новой стратегией) состояниях: если аддитивную константу потенциала нормировать по возвратному классу новой стратегии, выполнено $f' \geq f$ (строго на улучшенных состояниях), так что пара (g, f) растёт лексикографически именно в этой нормировке; при фиксированном якоре $f(n) = 0$ (шаг оценки ниже) потенциал сдвигается на константу, равную минус ожидаемому выигрышу до входа в класс, и может покомпонентно убывать. При фиксированном якоре $f(n) = 0$ монотонности нет, поэтому конечность доказывают в другой нормировке: потенциал нормируют как смещение (bias: $(\mu^{\pi'})^{\mathsf{T}} f = 0$ на возвратном классе) и при такой нормировке пара (g, f) растёт лексикографически, так что уже встреченная пара не повторяется, а стратегий конечно (Puterman, Markov Decision Processes, 1994). В задаче садовника метод корректен: стартовая стратегия $\{1, 1, 1\}$ унихейнова (строка состояния 3 даёт $g = v_3(1) = -1$ и разрешимость системы оценки при фиксации $f(3) = 0$), а все стратегии после первого улучшения неприводимы. Проверка — в ноутбуке этого вопроса.

Предложение 7.3 (Метод полного перебора)**.** *Для каждой стационарной детерминированной стратегии s решается система $\mu^{s\mathsf{T}} P^s = \mu^{s\mathsf{T}}$, $\sum_i \mu^s_i = 1$ и вычисляется $g^s = \mu^{s\mathsf{T}} r^s$; оптимальной объявляется стратегия с максимальным g^s.*

Корректность перебора гарантируется леммой: для конечного MDP, в котором каждая стационарная стратегия порождает неприводимую цепь, средний доход любой (в том числе исторической и случайной) стратегии не превосходит максимума среднего дохода по стационарным детерминированным стратегиям.

Идея доказательства. Для произвольной стратегии σ и горизонта T обозначим через $\nu_T(i, a) = \frac{1}{T}\sum_{t<T} \mathsf{P}^\sigma(i_t = i, a_t = a)$ частоты пребывания; $g_T(\sigma) = \sum_{i,a} \nu_T(i,a) v_i(a)$.

По уравнению Колмогорова—Чепмена для каждого j выполнено $\sum_a \nu_T(j,a) = \frac{1}{T}\mathsf{P}(i_0 = j) + \sum_{i,a} \nu_T(i,a) p_{ij}(a) + O(1/T)$, поэтому у любой предельной точки ν (она существует по компактности симплекса) выполнены балансное уравнение $\nu(j,\cdot) = \sum_{i,a} \nu(i,a) p_{ij}(a)$ и равенство предельного среднего дохода $\sum_{i,a} \nu(i,a) v_i(a)$. Множество таких ν — выпуклый компактный многогранник, а линейный функционал достигает на нём максимума в крайней точке. Носитель любой предельной ν есть всё S: носитель замкнут относительно переходов (балансное уравнение), а неприводимость цепей под всеми стратегиями означает достижимость любого состояния из любого, значит замкнутый носитель либо пуст, либо весь S; пустым быть не может из-за нормировки $\sum_{i,a} \nu(i,a) = 1$. Далее, матрица балансной системы в части состояний имеет ранг $n-1$ (тот же аргумент, что в лемме 16.3, применённый к смешанной матрице переходов $p_{ij}(q)$, $q(a \mid i) = \nu(i,a)/\nu(i,\cdot)$). Пусть ν — крайняя точка. Равенства многогранника — балансная система (ранг $n-1$ по приведённому выше) и нормировка $\sum_{i,a} \nu(i,a) = 1$ — в сумме имеют ранг n, поэтому по стандартному свойству базисных решений задачи линейного программирования в крайней точке не более n положительных компонент. Носитель ν полон (все n состояний i имеют $\nu(i,\cdot) > 0$), и для каждого состояния положительна хотя бы одна $\nu(i,a)$; значит, положительных компонент ровно n — по одной на состояние, и ν задаёт стационарную детерминированную стратегию $q(a \mid i) = \nu(i,a)/\nu(i,\cdot) \in \{0,1\}$. Следовательно, $\sup_\sigma g(\sigma) = \max_s g^s$. □

Лемма 7.4 (Улучшение при среднем доходе)**.** *Пусть каждая стационарная стратегия порождает неприводимую цепь. Пусть π — стационарная стратегия, (g^π, f^π) — решение системы (8) и π' выбрана по правилу $\pi'(i) \in \arg\max_a [v_i(a) + \sum_j p_{ij}(a) f^\pi(j)]$, при ничьей сохраняется $\pi'(i) = \pi(i)$. Тогда $g^{\pi'} \geq g^\pi$; если в некотором состоянии выражение под* max *строго больше $g^\pi + f^\pi(i)$, то $g^{\pi'} > g^\pi$.*

Доказательство. По построению π' для $G(i) := v_i(\pi'(i)) + \sum_j p_{ij}(\pi'(i)) f^\pi(j) - f^\pi(i) - g^\pi$ выполнено $G \geq 0$ покомпонентно (значение на $\pi'(i)$ не меньше значения на $\pi(i)$, а последнее равно g^π по (8) с π). Суммируя $G(i_t)$ вдоль цепи π' и беря математическое ожидание по стационарному распределению $\mu^{\pi'}$, получаем $0 \leq \sum_i \mu_i^{\pi'} G(i) = \sum_i \mu_i^{\pi'} v_i(\pi'(i)) - g^\pi = g^{\pi'} - g^\pi$ (первое слагаемое даёт $g^{\pi'}$ по определению стационарного распределения, член с f сокращается как $(\mu^{\pi'})^{\mathsf{T}} P^{\pi'} f^\pi - (\mu^{\pi'})^{\mathsf{T}} f^\pi = 0$). Строгость: если $G(i_0) > 0$ в состоянии i_0, то по неприводимости цепи π' (посылка) стационарное распределение $\mu^{\pi'}$ положительно в каждом состоянии, и $g^{\pi'} - g^\pi = \sum_i \mu_i^{\pi'} G(i) \geq \mu_{i_0}^{\pi'} G(i_0) > 0$. □

Лемма 7.5 (Сравнение при среднем доходе)**.** *Если для константы g и функции f выполнено*

$$g + f(i) \geq v_i(a) + \sum_j p_{ij}(a)\, f(j) \qquad \forall\, i, a,$$

то для любой (в том числе исторической и случайной) стратегии σ

$$\limsup_{T\to\infty} \frac{1}{T}\, \mathsf{E}^\sigma\Big[\sum_{t<T} r_{i_t i_{t+1}}(a_t)\Big] \leq g;$$

в частности, если средний доход g^σ существует как предел, то $g^\sigma \leq g$.

Доказательство. Неравенство выполнено для всех пар (i,a), в том числе для выбора σ на шаге t; так как a_t измерим относительно истории h_t, для условного математического ожидания имеем

$$\mathsf{E}^\sigma\big[r_{i_t i_{t+1}}(a_t) + f(i_{t+1}) \mid h_t\big] = v_{i_t}(a_t) + \sum_j p_{i_t j}(a_t)\, f(j) \leq g + f(i_t).$$

Телескопируя эти оценки по $t = 0, 1, \dots, T-1$ (итерируем условные ожидания), получаем

$$\mathsf{E}^{\sigma}\Big[\sum_{t<T} r_{i_t i_{t+1}}(a_t)\Big] \le Tg + f(i_0) - \mathsf{E}^{\sigma} f(i_T) \le Tg + 2\max_i |f(i)|;$$

делим на T и берём верхний предел. □

Метод итераций по стратегиям при этом правиле конечен. Пока на шаге улучшения есть состояние строгого улучшения, g растёт строго (лемма 7.4); если же улучшений нет ни в одном состоянии, выполнено уравнение оптимальности $g + f(i) = \max_a [v_i(a) + \sum_j p_{ij}(a) f(j)]$, и лемма сравнения 7.5 даёт оптимальность: средний доход неподвижной стратегии не меньше среднего дохода любой стратегии (а верхний предел среднего дохода у стратегий, где предел не существует, — тем более). Стратегий конечно, строгое возрастание g исключает возврат, поэтому метод заканчивается за конечное число шагов.

Метод итераций по стратегиям (шаг оценки — система (8) при фиксированной $f(n) = 0$; шаг улучшения — $\pi'(i) \in \arg\max_a [v_i(a) + \sum_j p_{ij}(a) f(j)]$) сходится: монотонность и конечность улучшений — лемма 7.4; численно метод совпадает с полным перебором на задаче садовника (ноутбук).

8 Сведение к линейному программированию

Марковская задача с бесконечным горизонтом (дисконтированная и нет) формулируется как задача линейного программирования [60]. Запишем дисконтированный случай.

Теорема 8.1 (LP-формулировка)**.** *Пусть $\gamma \in (0, 1)$. Рассмотрим задачу*

$$\min_{V \in \mathbb{R}^n} \sum_i b_i V(i) \qquad \text{при} \qquad V(i) \ge v_i(a) + \gamma \sum_j p_{ij}(a) V(j) \ \ \forall\, i, a, \tag{9}$$

где $b_i > 0$ — произвольные положительные веса. Её решение единственно и совпадает с V^*; двойственная задача —

$$\max_{w \ge 0} \sum_{i,a} w_{ia}\, v_i(a) \qquad \text{при} \qquad \sum_a w_{ja} = b_j + \gamma \sum_{i,a} p_{ij}(a)\, w_{ia} \ \ \forall\, j,$$

и среди оптимумов двойственной задачи есть вершинный, в котором для каждого i положительна ровно одна переменная $w_{ia^*(i)}$; он задаёт оптимальную детерминированную стратегию $a^*(i)$.

Идея доказательства. Ограничения прямой задачи означают $V \ge \mathcal{T} V$ покомпонентно; монотонность оператора «один шаг и продолжение по V» (та же, что в следствии 5.2) даёт $V \ge V^*$ для любого допустимого V, поэтому при $b > 0$ минимум достигается ровно на V^*. Двойственная задача получается стандартным образом; её допустимые точки — векторы ожидаемого дисконтированного времени пребывания в парах (i, a) (для $\gamma < 1$ оно конечно). В вершинном оптимуме число положительных компонент равно рангу системы (n независимых уравнений), а для каждого состояния j из ограничения $\sum_a w_{ja} \ge b_j > 0$ следует, что хотя бы одна w_{ja} положительна; значит, положительных компонент ровно n — по одной на состояние, и $q(a \mid i) = w_{ia} / \sum_a w_{ia} \in \{0, 1\}$: среди оптимальных стратегий есть детерминированная (при ничьей в оптимуме двойственной задачи возможны и смешанные оптимумы — они задают те же значение критерия и те же оптимальные действия в носителе). □

Замечание 8.2. Вариант без дисконтирования оформляется отдельно, как у [60]: веса b не используются (подстановка $\gamma = 1$ при $b > 0$ противоречива — суммирование ограничений двойственной задачи по j даёт $\sum_j b_j = 0$), а в двойственную задачу добавляется нормировка $\sum_{i,a} w_{ia} = 1$: тогда w_{ia} — совместное стационарное распределение состояния

и действия, $g = \sum_{i,a} w_{ia} v_i(a)$ — максимизируемый средний доход. Эквивалентная прямая форма — $\min z$ при $z + f(i) \geq v_i(a) + \sum_j p_{ij}(a) f(j)$: она двойственна к задаче с нормировкой (z и f — множители при ограничении $\sum_{i,a} w_{ia} = 1$ и балансных уравнениях), а не подстановка $\gamma = 1$ в (9) — при такой подстановке z сократился бы из обеих частей неравенства. Решение определено с точностью до сдвига f на константу, а z совпадает с оптимальным средним доходом. Размерность задачи ($n|A|$ переменных) делает LP-формулировку полезной теоретически (связь с двойственностью, полиномиальные алгоритмы) и в специальных классах задач, а на практике для средних размеров быстрее итерации по стратегиям.

9 Детерминированный случай и дискретный принцип максимума

Если переходы детерминированы — состояние на следующем шаге задано функцией $x_{t+1} = F_t(x_t, u_t)$, $u_t \in U$, — марковский процесс вырождается в многошаговую детерминированную задачу, а уравнение Беллмана принимает вид (в минимизирующей конвенции, согласованной с вопросом 06):

$$V_t(x) = \min_{u \in U} \big[\Phi_t(x, u) + V_{t+1}(F_t(x, u)) \big], \qquad V_N(x) = \Theta(x). \tag{10}$$

Теорема 9.1 (Дискретный принцип максимума)**.** *Пусть F_t, Φ_t, Θ непрерывно дифференцируемы по x, U компактно и выпукло, F_t аффинна по u и $\Phi_t(x, \cdot) + V_{t+1}(F_t(x, \cdot))$ выпукла на U и $\Phi_t(x, \cdot)$ выпукла на U, а V_t — решение* (10)*, дифференцируемое по x. Обозначим гамильтониан*

$$H_t(x, u, p) = -\Phi_t(x, u) + p^{\mathsf{T}} F_t(x, u).$$

Тогда оптимальное управление и сопряжённая переменная $p_t = -\nabla V_{t+1}(x^*_{t+1})$ удовлетворяют

$$u^*_t \in \arg\max_{u \in U} H_t(x^*_t, u, p_t), \qquad p_{t-1} = -\frac{\partial \Phi_t}{\partial x}(x^*_t, u^*_t) + \Big(\frac{\partial F_t}{\partial x}(x^*_t, u^*_t) \Big)^{\mathsf{T}} p_t, \tag{11}$$

с терминальным условием $p_{N-1} = -\nabla \Theta(x^*_N)$: формулы принципа максимума Понтрягина для дискретной задачи.

Доказательство. Первое соотношение: точка минимума u^*_t выпуклой функции $u \mapsto \Phi_t(x^*_t, u) + V_{t+1}(F_t(x^*_t, u))$ на выпуклом U удовлетворяет вариационному неравенству $\big(\frac{\partial \Phi_t}{\partial u} + \big(\frac{\partial F_t}{\partial u}\big)^{\mathsf{T}} \nabla V_{t+1}\big)^{\mathsf{T}} (u - u^*_t) \geq 0$ для всех $u \in U$. При $p_t = -\nabla V_{t+1}(x^*_{t+1})$ левая часть есть $-\frac{\partial H_t}{\partial u}(x^*_t, u^*_t, p_t)$, то есть $\frac{\partial H_t}{\partial u}^{\mathsf{T}} (u - u^*_t) \leq 0$ для всех $u \in U$; функция $H_t(x^*_t, \cdot, p_t) = -\Phi_t(x^*_t, \cdot) + p_t^{\mathsf{T}} F_t(x^*_t, \cdot)$ вогнута (выпуклая Φ_t и аффинная F_t), поэтому это условие первого порядка равносильно глобальному максимуму: $u^*_t \in \arg\max_{u \in U} H_t$. Второе: продифференцируем (10) по x в точке x^*_t. Вклад смещения оптимальной точки $u^*(x)$ в производную равен нулю: во внутренней точке — по условию первого порядка, на границе выпуклого U — по теореме Данскина о производной огибающей (минимизируемая функция выпукла по u на выпуклом компактном U, поэтому производная значения по x совпадает с частной производной по x, взятой в оптимальной точке):

$$\nabla V_t(x^*_t) = \frac{\partial \Phi_t}{\partial x}(x^*_t, u^*_t) + \Big(\frac{\partial F_t}{\partial x}(x^*_t, u^*_t) \Big)^{\mathsf{T}} \nabla V_{t+1}(x^*_{t+1}).$$

По определению p левая часть есть $-p_{t-1}$, а $\nabla V_{t+1}(x^*_{t+1})$ есть $-p_t$; подстановка даёт второе соотношение (11). Терминальное условие — дифференцирование $V_N = \Theta$. □

Замечание 9.2. (1) Роль динамического программирования в этом выводе — та же, что в непрерывном случае у [56]: гладкость функции цены переносит условие оптимальности с вариаций траектории на покомпонентную оптимизацию по u; связь $p_t = -\nabla V_{t+1}(x^*_{t+1})$

совпадает по знаку с формулой $p = -\nabla S$ из вопроса 06: при минимизирующей конвенции критерия обе сопряжённые переменные есть антиградиент функции цены. (2) Условие максимума — необходимое условие оптимальности. Достаточность получается при усилении выпуклости: если динамика линейна по паре (x, u), а функции Φ_t выпуклы по паре (x, u) и Θ выпукла, то вся вариация критерия вдоль сопряжённой системы телескопируется в неравенство $J(u) \geq J(u^*)$ (слагаемые с $\partial\Phi_t/\partial x$ сокращаются со сопряжённым уравнением, а выпуклость заменяет приращения неравенствами), и максимум гамильтониана становится достаточным условием; при посылках же теоремы 9.1 (выпуклость лишь по u) остаточные члены приращения по x знаком не контролируются, условие максимума остаётся условием первого порядка, и более сильным критерием служит уравнение Беллмана. (3) Дискретная задача (10) — конечно-разностная дискретизация непрерывной задачи оптимального управления [13], и непрерывный предел этих формул — принцип максимума Понтрягина (вопрос 06); MDP в этом смысле — дискретный аналог задачи оптимального управления со стохастической правой частью.

10 Линейно-квадратичная модель

Сквозной объект вопроса — дискретный двойной интегратор, тот же объект, что в вопросах 04 и 06:

$$x_{k+1} = Ax_k + Bu_k + w_k, \qquad A = \begin{pmatrix} 1 & h \\ 0 & 1 \end{pmatrix}, \quad B = \begin{pmatrix} h^2/2 \\ h \end{pmatrix}, \tag{12}$$

где $h > 0$ — шаг дискретизации непрерывного двойного интегратора $\dot{x}_1 = x_2$, $\dot{x}_2 = u$ из вопроса 06, а w_k — независимые центрированные случайные возмущения с $\mathsf{E} w_k w_k^{\mathsf{T}} = W$. Критерий — минимизация дисконтированной суммы квадратичных потерь, как в LQ-задаче вопроса 06:

$$J(x_0) = \mathsf{E}\Big[\sum_{k=0}^{\infty} \gamma^k (x_k^{\mathsf{T}} Q x_k + u_k^{\mathsf{T}} R u_k)\Big] \to \min, \qquad Q \succeq 0, \quad R \succ 0, \quad u_k \in \mathbb{R}.$$

Это MDP с непрерывным множеством состояний $\mathbb{R}^2$ и действий $\mathbb{R}$; конечномерная теория раздела 5 напрямую не применима (максимум по бесконечному A), но структура задачи позволяет найти решение аналитически.

Теорема 10.1 (Функция цены квадратична, Риккати)**.** *Пусть пара $(\sqrt{\gamma}A, B)$ стабилизируема (существует обратная связь $\tilde{u} = -\tilde{L}x$ с устойчивой $\sqrt{\gamma}(A - B\tilde{L})$), а пара $(Q^{1/2}, \sqrt{\gamma}A)$ детектируема (из $Qv = 0$ и $\sqrt{\gamma}Av = \lambda v$ с $|\lambda| \geq 1$ следует $v = 0$). Тогда в задаче с динамикой $x_{k+1} = Ax_k + Bu_k + w_k$ и критерием выше функция цены квадратична $V^*(x) = x^{\mathsf{T}} K x + c$, где $K \succeq 0$ — единственное решение алгебраического уравнения Риккати*

$$K = Q + \gamma A^{\mathsf{T}} K A - \gamma^2 A^{\mathsf{T}} K B \big(R + \gamma B^{\mathsf{T}} K B\big)^{-1} B^{\mathsf{T}} K A, \tag{13}$$

константа $c = \frac{\gamma}{1-\gamma} \operatorname{tr}(KW)$, а оптимальное управление — стационарная линейная обратная связь

$$u^*(x) = -Lx, \qquad L = \gamma\big(R + \gamma B^{\mathsf{T}} K B\big)^{-1} B^{\mathsf{T}} K A. \tag{14}$$

Доказательство. Уравнение оптимальности для этой задачи (переход к минимизации):

$$V(x) = \min_u \big[x^{\mathsf{T}} Q x + u^{\mathsf{T}} R u + \gamma\, \mathsf{E}_w V(Ax + Bu + w)\big].$$

Подставим $V(x) = x^{\mathsf{T}} K x + c$ и вычислим ожидание: $\mathsf{E}_w V(Ax+Bu+w) = (Ax+Bu)^{\mathsf{T}} K (Ax + Bu) + \operatorname{tr}(KW) + c$ (центрированность w убирает смешанные члены). Минимизируемое выражение —

$$x^{\mathsf{T}} Q x + u^{\mathsf{T}} R u + \gamma (Ax + Bu)^{\mathsf{T}} K (Ax + Bu) + \gamma c + \gamma \operatorname{tr}(KW),$$

квадратичное по u с положительно определённой матрицей $R+\gamma B^{\mathsf T}KB$; минимум во внутренней точке:

$$u^{*}=-\left(R+\gamma B^{\mathsf T}KB\right)^{-1}\gamma B^{\mathsf T}KAx=-Lx.$$

Подстановка обратно и приравнивание к $x^{\mathsf T}Kx+c$ при произвольном x даёт (13) для квадратичной части и $c=\gamma c+\gamma\,\mathrm{tr}(KW)$ — для константы.

Существование и единственность $K\succeq 0$ опираются на посылки. Последовательность $K^{(m+1)}=Q+\gamma A^{\mathsf T}K^{(m)}A-\gamma^{2}A^{\mathsf T}K^{(m)}B(R+\gamma B^{\mathsf T}K^{(m)}B)^{-1}B^{\mathsf T}K^{(m)}A$, начатая с $K^{(0)}=0$, — это итерации по ценности для квадратичных функций: она монотонно не убывает (по min-оператору) и ограничена — по стабилизируемости существует обратная связь $\tilde u=-\tilde Lx$ с устойчивой $\sqrt{\gamma}(A-B\tilde L)$, цена этой стратегии конечна (ряд с общим членом $\gamma^{k}\left\|(A-B\tilde L)^{k}\right\|^{2}$ сходится), и частичные суммы не превосходят цены никакой стратегии. Значит, предел $K\succeq 0$ существует и удовлетворяет (13). Докажем устойчивость с запасом: (13) с определением (14) есть завершение квадратов

$$K=Q+L^{\mathsf T}RL+\gamma(A-BL)^{\mathsf T}K(A-BL)\tag{15}$$

(подстановка $(R+\gamma B^{\mathsf T}KB)L=\gamma B^{\mathsf T}KA$). Пусть $(A-BL)v=\lambda v$ с $|\lambda|\ge 1/\sqrt{\gamma}$; тогда $v^{\mathsf T}Kv=v^{\mathsf T}Qv+v^{\mathsf T}L^{\mathsf T}RLv+\gamma|\lambda|^{2}v^{\mathsf T}Kv$, откуда $v^{\mathsf T}(Q+L^{\mathsf T}RL)v=(1-\gamma|\lambda|^{2})v^{\mathsf T}Kv\le 0$, то есть $Qv=0$ и $Lv=0$. Но тогда $\sqrt{\gamma}Av=\lambda\sqrt{\gamma}v$ с $|\lambda\sqrt{\gamma}|\ge 1$ и $Q^{1/2}v=0$ — противоречие с детектируемостью. Значит $\sqrt{\gamma}(A-BL)$ устойчива. Если $K_1,K_2\succeq 0$ — два решения (13) и L_i — их синтезы, то вычитание уравнений с завершением квадратов даёт $\Delta=\gamma(A-BL_1)^{\mathsf T}\Delta(A-BL_2)$ (проверяется подстановкой определений L_i), а спектральный радиус этого отображения меньше 1 (оба сомножителя устойчивы с запасом $1/\sqrt{\gamma}$), так что итерации дают $\Delta=0$. □

Замечание 10.2. (1) При $\gamma=1$, $h\to 0$ и масштабировании $Q\to hQ$, $R\to hR$ (дискретная сумма приближает интеграл критерия) уравнение (13) переходит в алгебраическое (непрерывное) уравнение Риккати вопроса 06: дискретная модель — консистентная дискретизация непрерывной LQ-задачи, предел измерен в ноутбуке (сходимость линейная по h), а синтез (14) — дискретный аналог $u=-R^{-1}B^{\mathsf T}Kx$. (2) Случайный член w_k влияет только на константу c: оптимальная обратная связь от W не зависит — то же свойство, что детерминированный LQ-регулятор вопроса 06 не меняется при добавлении аддитивных возмущений: шум «оплачивается» приращением $\frac{\gamma}{1-\gamma}\,\mathrm{tr}(KW)$ значения критерия, но не меняет закона управления. (3) Предел $R\to+0$: один полюс $A-BL$ уходит к нулю, а второй стремится к конечному пределу $(2-h)/(2+h)$ — образу непрерывного предельного полюса $s=-1$ под билинейным преобразованием (дискретизацией Тастина); полный deadbeat (оба полюса в нуле) пределом LQ-синтеза не достигается — размещение полюсов (вопрос 04) решает другую задачу. Измерение пределов — в ноутбуке.

11 Прикладная рамка

Таблица «где конструкция работает» — по постановкам [60], гл. 19, и [44].

Постановка	Состояние	Действие	Что даёт MDP
Управление запасами	уровень запаса	объём заказа	политика (s,S): заказывать при падении ниже s до уровня S
Замена оборудования	возраст/состояние машины	держать или менять	пороговый возраст замены
Реклама	оценка сбыта	канал/интенсивность рекламы	переключающаяся политика

Постановка	Состояние	Действие	Что даёт MDP
Управление денежными потоками	объём активов	портфельное действие	политика ребалансировки
Обучение с подкреплением	наблюдение среды	действие агента	стратегия, выученная по данным, когда p, r неизвестны [55]

Общая закономерность: оптимальная стратегия оказывается простой (пороговой, линейной), хотя пространство всех стратегий огромно, — это следствие структуры уравнения Беллмана, а не частное совпадение.

12 Разобранные задачи

Задача 12.1 (Садовник: конечный горизонт [60])**.** Почва ежегодно оценивается в одно из трёх состояний, удобрение меняет матрицу переходов и доходов:

$$P(1) = \begin{pmatrix} 0{,}2 & 0{,}5 & 0{,}3 \\ 0 & 0{,}5 & 0{,}5 \\ 0 & 0 & 1 \end{pmatrix}, \quad P(2) = \begin{pmatrix} 0{,}3 & 0{,}6 & 0{,}1 \\ 0{,}1 & 0{,}6 & 0{,}3 \\ 0{,}05 & 0{,}4 & 0{,}55 \end{pmatrix},$$

$$R(1) = \begin{pmatrix} 7 & 6 & 3 \\ 0 & 5 & 1 \\ 0 & 0 & -1 \end{pmatrix}, \quad R(2) = \begin{pmatrix} 6 & 5 & -1 \\ 7 & 4 & 0 \\ 6 & 3 & -2 \end{pmatrix}$$

(доходы в сотнях долларов; состояние 3 без удобрения поглощающее). Ожидаемые одношаговые доходы:

$$v(1) = (5{,}3;\ 3;\ -1), \qquad v(2) = (4{,}7;\ 3{,}1;\ 0{,}4).$$

При $N = 3$ обратная индукция даёт $f_1 = (10{,}74;\ 7{,}92;\ 4{,}22)$ (точные значения $10{,}7355$; $7{,}9225$; $4{,}22225$; у [60] третья компонента $4{,}23$ — следствие промежуточного округления), стратегия: удобрять в первые два года при любом состоянии, на третий год — кроме состояния 1.

Задача 12.2 (Садовник: бесконечный горизонт [60])**.** Восемь стационарных детерминированных стратегий; четыре с $\pi(3) = 1$ приводимы (состояние 3 поглощающее, $\mu = (0, 0, 1)$) — см. замечание 7.2. Полный перебор: максимум среднего годового дохода $g = 2{,}256$ даёт стратегия «всегда удобрять», стационарное распределение $\mu = \frac{1}{59}(6, 31, 22)$. Метод итераций по стратегиям с той же стартовой точки приходит к ней за одно улучшение. При дисконте $\gamma = 0{,}6$ оптимальной оказывается стратегия $\{1, 2, 2\}$ (не удобрять при хорошей почве) с функцией цены $V^* = (8{,}97;\ 6{,}63;\ 3{,}38)$. Обе проверки воспроизведены в ноутбуке.

Задача 12.3 (Дискретный двойной интегратор: LQ-синтез)**.** Система (12) с $h = 0{,}1$, $Q = I$, $R = 1$, $\gamma = 1$, $W = 0$ — предельный случай теоремы 10.1 ($W = 0$ обнуляет константу c; при $\gamma = 1$ посылки читаются как стабилизируемость (A, B) и детектируемость $(Q^{1/2}, A)$, и двойной интегратор ими обладает). Решение уравнения (13) даёт усиление L из (14); итерации по ценности на квадратичных функциях (та же рекуррентность, что в доказательстве теоремы 10.1) сходятся к K, а скорость сходимости измеряется в ноутбуке напрямую. Матрица $A - BL$ устойчива. Предел $R \to +0$: один полюс $A - BL$ стремится к нулю, второй — к $(2 - h)/(2 + h)$, образу полюса $s = -1$ непрерывной LQ-задачи (вопрос 06) под билинейным преобразованием (дискретизацией Тастина); это не deadbeat вопроса 04. Числа — в ноутбуке.

13 Вычислительная сторона

Три рабочих метода решения конечного MDP и их цена (сводно, разбор — в ноутбуке):

Метод	Один шаг	Число шагов	Когда применять
Полный перебор	решение $\mu P = \mu$ ($O(n^3)$)	$\lvert A\rvert^n$ стратегий	только для проверки, экспонента
Итерации по ценности	$n^2\lvert A\rvert$ скалярных операций	$O(\log \frac{1}{\varepsilon})$, знаменатель γ обычно единицы	большие n, точность ε
Итерации по стратегиям	решение системы $(I-\gamma P^\pi)V = r^\pi$ ($O(n^3)$)		средние n, высокая точность

Проклятие размерности у динамического программирования: обратная индукция на горизонте N с n состояниями стоит $O(Nn^2\lvert A\rvert)$, что умеренно, но рост n (например, сеточная дискретизация непрерывного состояния) быстро делает табличную схему непригодной — отсюда аппроксимации функции цены (линейная параметризация, нейросети) в обучении с подкреплением [55]. Другое ограничение — точное знание (P, r): Q-обучение (дополнительные главы) снимает его, оценивая Q-функцию по траекториям.

14 Вопросы, которые стоит ожидать

1. *Почему оптимальная стратегия стационарна, хотя допустимы исторические стратегии?* Остаток горизонта бесконечен и одинаков при любом моменте решения, а марковское свойство делает историю излишней: уравнение оптимальности не зависит от времени, его неподвижная точка даёт V^*, и arg max выбирает действие по текущему состоянию; история не входит в уравнение — доказательство следствия 5.2 оценивает произвольные стратегии сверху.
2. *Чем критерий среднего дохода отличается от дисконтированного?* Дисконт — сжатие, единственность решения, скорость γ^k; средний доход — эргодическая теорема, решение оценки с точностью до константы, переходный процесс отделён от установившегося (функция f).
3. *Как оценить заданную стратегию, не оптимизируя?* Система $(I-\gamma P^\pi)V = r^\pi$; при среднем доходе — система (8) с фиксацией константы.
4. *Почему метод итераций по стратегиям конечен, а по ценности — нет?* Стратегий конечно и каждое улучшение строго (по достижимости), значит цикл невозможен; по ценности сходимость асимптотическая, остановка по ε (следствие 6.3 и оценка (6)).
5. *Связь с принципом максимума Понтрягина.* Детерминированный предел, дискретный принцип максимума (теорема 9.1); в непрерывном времени $p = -\nabla S$ (вопрос 06), в дискретном $p_t = -\nabla V_{t+1}(x^*_{t+1})$ при минимизирующей конвенции.
6. *Откуда в LQ-задаче Риккати и почему обратная связь линейна?* Квадратичность функции цены проверяется подстановкой; минимизация квадратичной формы по u — линейное уравнение (теорема 10.1).
7. *MDP как частный случай общей проблемы принятия решения.* Потери = −доход, оптимальность по среднему риску; минимаксный вариант — робастные MDP против неопределённости закона переходов.
8. *Что происходит при $\gamma \to 1$?* Дисконтированная функция цены расходится как $\mu^\top r/(1-\gamma)$; нормировка $(1-\gamma)V \to g$ связывает критерии; методы усложняются (см. [55], гл. про MDP).

15 Источники

Основные: [60] (гл. 19 — постановка, все три критерия, методы, задача садовника; обозначения v_i^k, $f_n(i)$ этого конспекта согласованы с ней), [44] (приложение B — управляемые

марковские процессы, уравнение Вальда—Беллмана, идея доказательства существования оптимальной стратегии; раздел 6 — марковские цепи, уравнение Колмогорова—Чепмена с доказательством). Теория динамического программирования и принцип оптимальности: [12] (гл. 7, § 4 — две формулировки принципа, уравнение Беллмана, трудоёмкость), [15] (§ 3.5.1 — принцип оптимальности и условно-оптимальное управление), [13] (гл. 11, § 2 — дискретная задача оптимального управления, локальный принцип максимума, динамическое программирование). Непрерывные аналоги и связь с принципом максимума: [56] (гл. 2 — уравнение Беллмана; § 9 — связь с принципом максимума Понтрягина), [50] (§ 8.3–8.4 — функция оптимального времени и $p = -\nabla S$). Подложка по марковским цепям: [17] (задачи), [60] (§ 19.5 — классификация состояний, эргодические теоремы 19.5.1–19.5.2). Дополнения: [55] (строгая теория MDP, итерации, Q-обучение), [58] (алгоритмическая сторона обучения с подкреплением).

16 Дополнительные главы

Граница базового ответа — вычислительная сторона; дальше — подложка, на которую ядро опирается формулировками.

16.1 Эргодическая теорема для конечной цепи

Теорема 16.1 (Сходимость к стационарному распределению)**.** *Пусть P — стохастическая матрица конечной неприводимой апериодической цепи. Тогда существует m такое, что $\delta := \min_{i,j} (P^m)_{ij} > 0$, и для любых распределений a, b на состояниях*

$$\left\| a^{\mathsf{T}} P^t - b^{\mathsf{T}} P^t \right\|_1 \le 2(1 - n\delta)^{\lfloor t/m \rfloor}.$$

В частности, $a^{\mathsf{T}} P^t$ сходится к единственному решению μ системы (3), а $P^t \to \mathbf{1}\mu^{\mathsf{T}}$.

Доказательство. Существование m: для каждой пары (i, j) есть t_{ij} с $(P^{t_{ij}})_{ij} > 0$ (неприводимость); для фиксированного i все j с $(P^t)_{ij} > 0$ при некотором t образуют множество, замкнутое относительно суммирования индексов (по уравнению Колмогорова—Чепмена), и апериодичность означает, что наибольший общий делитель таких t равен 1, откуда все достаточно большие t представимы суммой; объединяя по конечному множеству пар (i, j), получаем единое m.

Сжатие. Обозначим $c = a - b$, $\lambda = \frac{1}{2}\|c\|_1$; тогда $c^{\mathsf{T}} = \lambda(\tilde{a}^{\mathsf{T}} - \tilde{b}^{\mathsf{T}})$ с распределениями $\tilde{a}, \tilde{b}$. Для любых двух строк $M_{i\cdot}$, $M_{i'\cdot}$ матрицы $M = P^m$ выполнено $\frac{1}{2}\sum_j |M_{ij} - M_{i'j}| = 1 - \sum_j \min(M_{ij}, M_{i'j}) \le 1 - n\delta$ (все элементы не меньше δ). Стандартная лемма Добрушина: для распределений x, y и матрицы M с $\min_{ij} M_{ij} \ge \delta$ разность $x^{\mathsf{T}} M - y^{\mathsf{T}} M$ раскладывается по разностям строк, каждая по норме не больше $1 - n\delta$, и $\left\| x^{\mathsf{T}} M - y^{\mathsf{T}} M \right\|_1 \le (1 - n\delta)\|x - y\|_1$. Значит, $\left\| a^{\mathsf{T}} P^m - b^{\mathsf{T}} P^m \right\|_1 \le (1 - n\delta)\|a - b\|_1$; итерируя по блокам длины m и пользуясь тем, что умножение на стохастическую матрицу не увеличивает $\|\cdot\|_1$-расстояние между распределениями, получаем $\left\| a^{\mathsf{T}} P^t - b^{\mathsf{T}} P^t \right\|_1 \le 2(1 - n\delta)^{\lfloor t/m \rfloor}$. Предел μ единственен как общая точка притяжения, удовлетворяет (3) (непрерывность умножения) и положителен, так как $\mu_j \ge \delta$.

Тождество Кака о среднем времени возвращения (промис теоремы 4.2): обозначим через τ_j момент первого возвращения в j при старте из j и $m_j = \mathsf{E}_j \tau_j$. Момент конечен: $\mathsf{P}_j(\tau_j > t) \le (1 - \delta)^{\lfloor t/m \rfloor}$, так как из любого состояния с вероятностью не меньше δ цепь попадает в j за m шагов. Интервалы между последовательными возвращениями независимы и одинаково распределены (сильная марковость), а между $\tau^{(k)}$ и $\tau^{(k+1)}$ состояние j встречается ровно в момент $\tau^{(k)}$; поэтому по закону больших чисел для возобновляющего потока доля времени,

проведённая цепью в j, стремится почти наверное к $1/m_j$. С другой стороны, математическое ожидание этой доли есть среднее выражений $\mathsf{P}(i_t = j) = (a^{(0)}P^t)_j$, которое стремится к μ_j (для апериодической цепи — по доказанной выше сходимости $P^t \to \mathbf{1}\mu^{\mathsf{T}}$, для периодической — по сходимости Цезаро-средних). Сходимость почти наверное к константе влечёт сходимость математических ожиданий (доля ограничена), значит $1/m_j = \mu_j$. Для периодической неприводимой цепи с периодом d время возвращения кратно d, и применение доказанного к неприводимой апериодической цепи с матрицей P^d на циклическом классе состояния j даёт $m_j = d\, m_j^{(P^d)} = d/(d\mu_j) = 1/\mu_j$ (стационарная мера P^d на классе есть $d\mu$: мера μ распределяет массу поровну между d циклическими классами). □

Замечание 16.2. Апериодичность существенна ровно в существовании m с положительным столбцом: для периодической цепи P^t не сходится (строки переставляются), но Цезаро-средние $\frac{1}{T}\sum_{t<T} P^t \to \mathbf{1}\mu^{\mathsf{T}}$ сходятся всегда — этого достаточно для критерия среднего дохода (теорема 7.1).

16.2 Ранг $I - P$ и существование поправочной функции

Лемма 16.3 (О ранге $I-P$)**.** *Для стохастической матрицы P неприводимой конечной цепи* $\operatorname{rank}(I-P) = n-1$*: ядро $I-P$ порождено $\mathbf{1}$, а левое ядро порождено распределением μ из теоремы 4.2.*

Доказательство. $(I-P)\mathbf{1} = 0$, так что $\operatorname{rank}(I-P) \le n-1$. Если $(I-P)x = 0$, то, выбрав j_0 с $x_{j_0} = \max_i x_i$, получаем $x_{j_0} = \sum_i p_{j_0 i}\, x_i \le x_{j_0}$, и равенство возможно только если $x_i = x_{j_0}$ на всех i с $p_{j_0 i} > 0$; по неприводимости все состояния достижимы из j_0, значит $x \equiv \text{const}$. Следовательно $\dim\ker(I-P) = 1$ и $\operatorname{rank}(I-P) = n-1$. Левое ядро одномерно для любой квадратной матрицы ($\dim\ker M^{\mathsf{T}} = n - \operatorname{rank} M$); пусть $y^{\mathsf{T}}(I-P) = 0$, $y \neq 0$. Тогда $|y|^{\mathsf{T}}P \ge |y^{\mathsf{T}}P| = |y|^{\mathsf{T}}$ покомпонентно, а суммы координат обеих частей равны $\sum_i |y_i|$ (строки P суммируются в единицы), значит $|y|^{\mathsf{T}}P = |y|^{\mathsf{T}}$. Носитель $|y|$ замкнут относительно переходов цепи (из $|y_j| > 0$ и $p_{ji} > 0$ следует $|y_i| > 0$), по неприводимости совпадает со всем S; нормировка $\mu := |y|/\sum_i |y_i|$ — распределение из теоремы 4.2, и оно единственно с точностью до множителя. □

16.3 Уравнение Вальда—Беллмана и обучение с подкреплением

Уравнение оптимальности (5) называют уравнением Вальда—Беллмана [44]: «Вальд» отсылает к последовательному анализу, где та же рекуррентность управляет моментом остановки наблюдений (задача о разборчивой невесте — прикладной пример [44]). В классической постановке MDP всё ещё нужны (P, r). Обучение с подкреплением снимает это требование: определяется функция действия-ценности

$$Q(s,a) = v_s(a) + \gamma \sum_j p_{sj}(a) V^*(j),$$

то есть ожидаемый дисконтированный доход при первом действии a в состоянии s и далее оптимальном поведении; $V^*(s) = \max_a Q(s,a)$, так что уравнение оптимальности эквивалентно $Q = \mathcal{T}_Q Q$ с аналогичным сжатием. Q-обучение (англ. *Q-learning*) итерирует

$$Q_{k+1}(s_k,a_k) = (1-\beta_k)Q_k(s_k,a_k) + \beta_k\bigl[r_k + \gamma \max_{a'} Q_k(s_{k+1},a')\bigr]$$

по наблюдаемым переходам (s_k, a_k, r_k, s_{k+1}), не зная p и r заранее [55]; стохастическая аппроксимация при условиях $\sum_k \beta_k = \infty$, $\sum_k \beta_k^2 < \infty$ сходится с вероятностью единица при посещаемости всех пар (s,a). В терминах программы это дальний родственник метода

проекции градиента (вопрос 10) и методов обучения нейросетей (вопрос 02): то же стохастическое приближение неподвижной точки.